TensorFlow Basics

Graph, Session

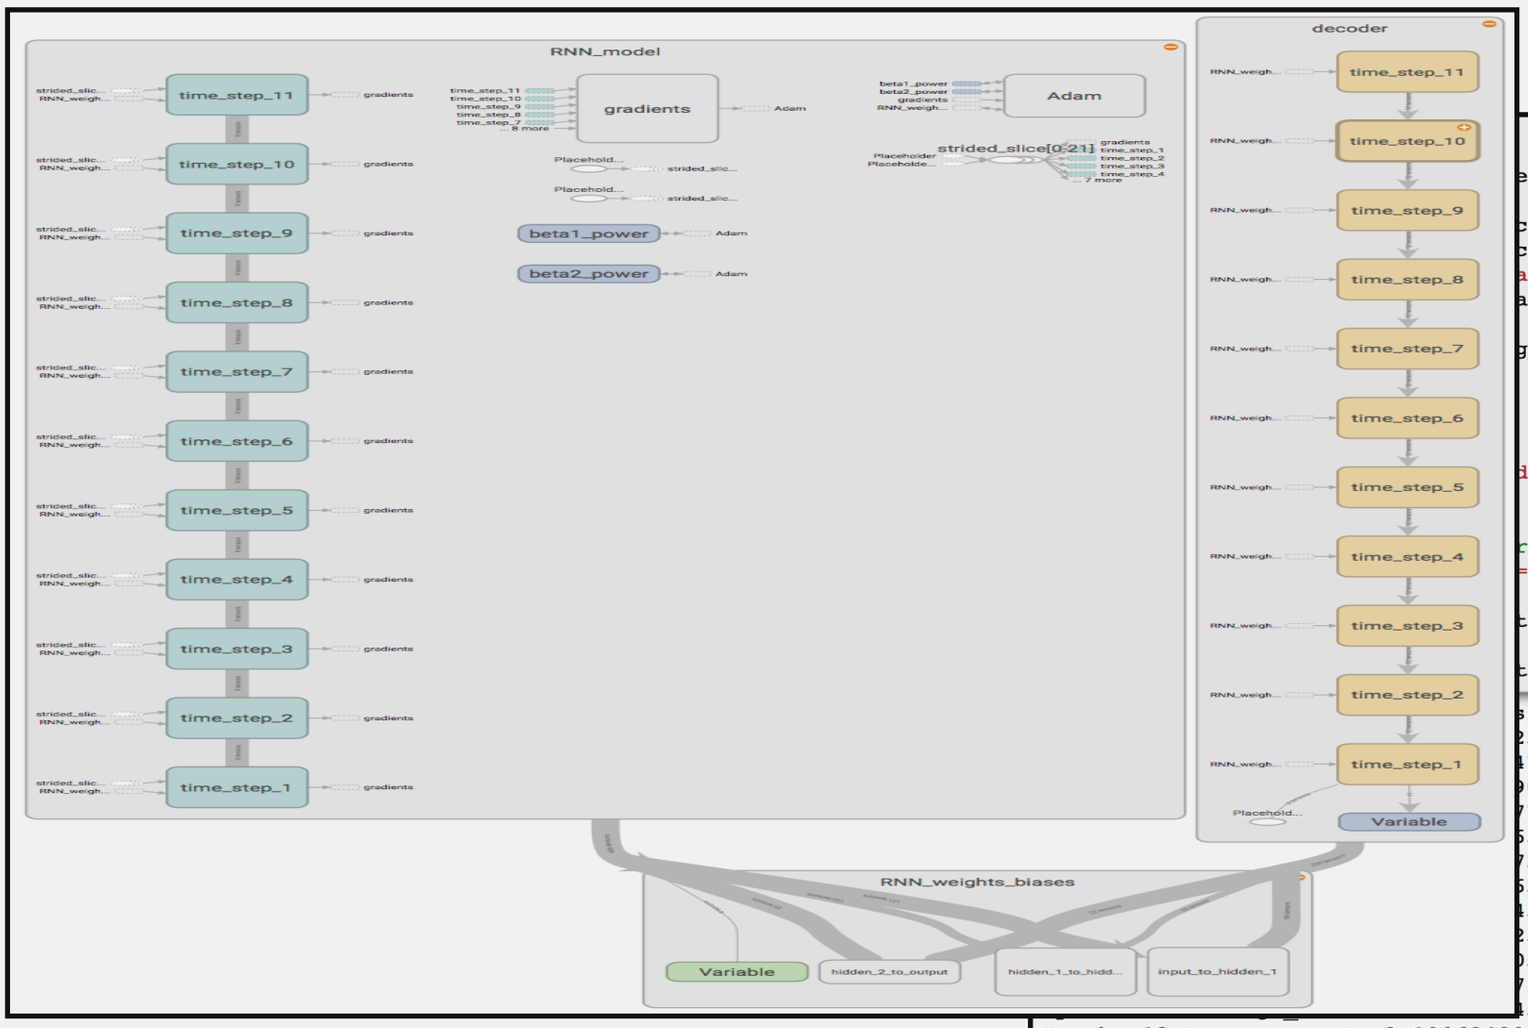


```
      epoch*mini_batch_per_epoch +  # TensorBoard: summary
      each_batch+1)                 # TensorBoard: summary
ess.run([cost, optimizer],                          # For error per epoch
        feed_dict={X: batch_x, Y: batch_y})  # For error per epoch
ch_cost                                             # For error per epoch
cost/mini_batch_per_epoch                           # For error per epoch
age_cost: {}'                                       # For error per epoch
atest_global_epoch+1, average_cost))                # For error per epoch
                                                      # Save all the variables
g_update)                                             # (including embedding)
 saver.save(sess, MODEL_FILE,                         # Save all the variables
            global_step=                              # (including embedding)
            latest_global_step+                       # Save all the variables
            ((epoch+1)*mini_batch_per_epoch))  # (including embedding)
d: {}'.format(saved_file_path))                       # Save all the variables


range(10):
==========================================')          # Printing
 {}'.format(reverse_dictionary[most_frequent_idx]))  # Printing
tput_words, feed_dict={X_test: most_frequent_idx})  # Feeding test word
                                                      # Printing
tionary[word])                                        # Printing
```

```
s...
23989684
4704411
9073989
773459
5340997
7599613
55122535
4312601
2340043
05242202
7/rnn_tensorflow/src/log_8th_word_RNN/model.ckpt-340
43206114
Epoch: 12 Average_cost: 3.190694395233603
Epoch: 13 Average_cost: 3.037706837934606
Epoch: 14 Average_cost: 2.9177206333945778
Epoch: 15 Average_cost: 2.8175760788076065
```

tensorflow는
모델을 graph로 그려내는 graphing 부분과
그 graph를 실질적으로 실행하는 session 부분으로 나뉩니다.

Graph, Session

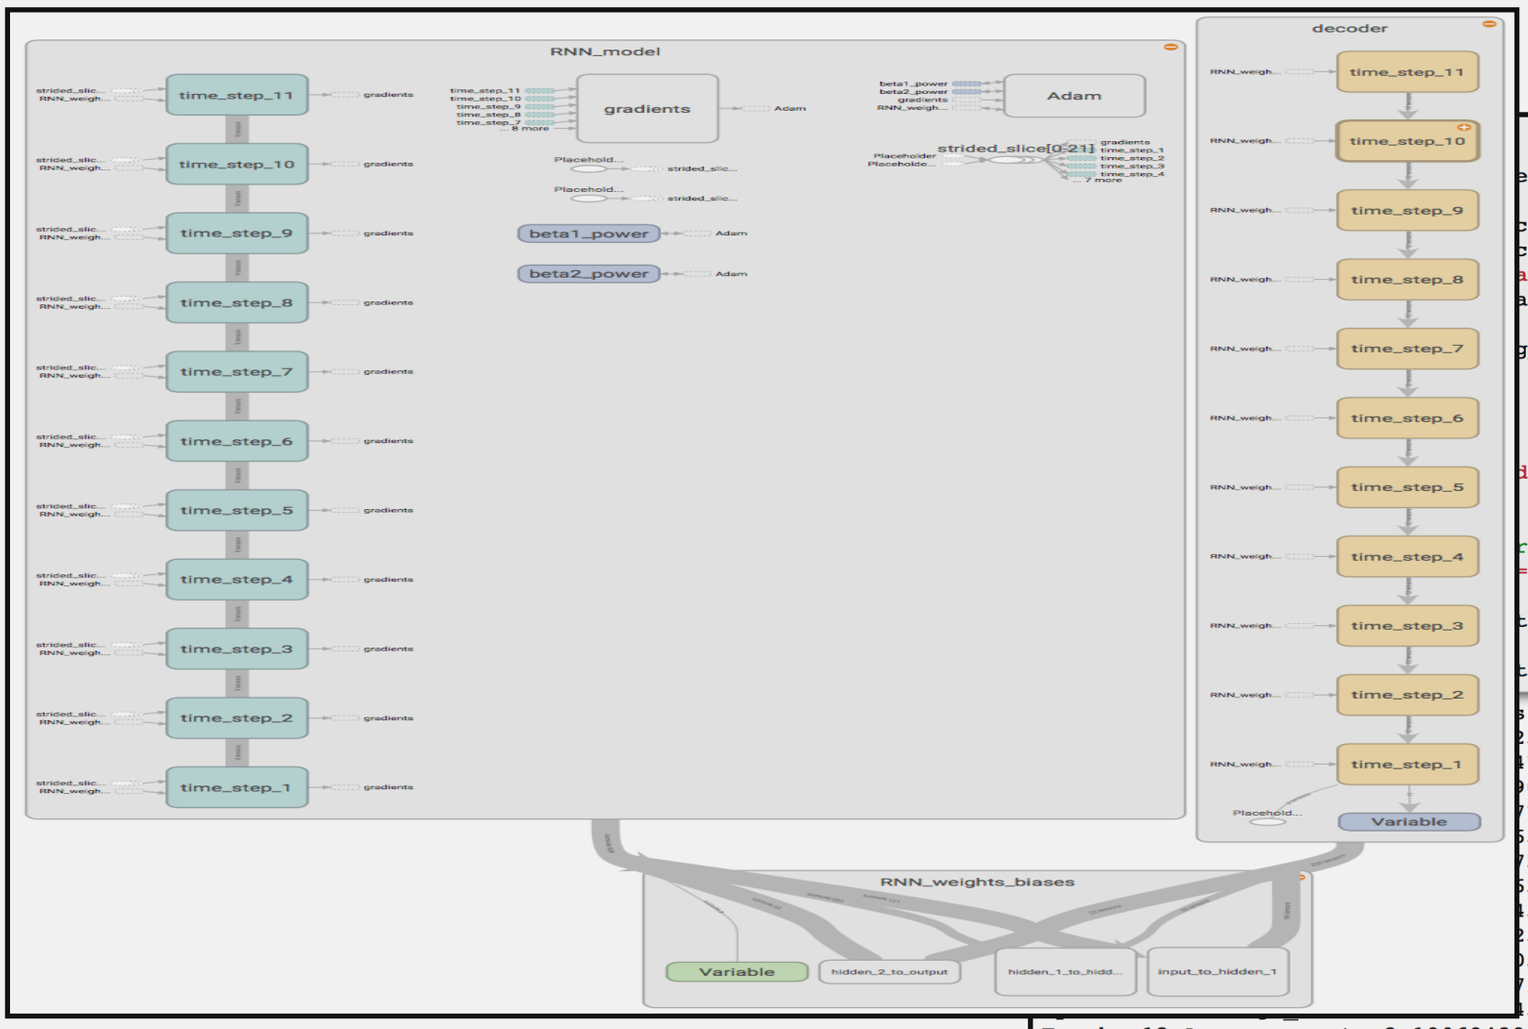


```
      epoch*mini_batch_per_epoch +  # TensorBoard: summary
      each_batch+1)                 # TensorBoard: summary
ess.run([cost, optimizer],                          # For error per epoch
        feed_dict={X: batch_x, Y: batch_y})  # For error per epoch
ch_cost                                             # For error per epoch
cost/mini_batch_per_epoch                           # For error per epoch
age_cost: {}'                                       # For error per epoch
atest_global_epoch+1, average_cost))                # For error per epoch
                                                      # Save all the variables
g_update)                                             # (including embedding)
 saver.save(sess, MODEL_FILE,                         # Save all the variables
            global_step=                              # (including embedding)
            latest_global_step+                       # Save all the variables
            ((epoch+1)*mini_batch_per_epoch))  # (including embedding)
d: {}'.format(saved_file_path))                       # Save all the variables


range(10):
==========================================')          # Printing
 {}'.format(reverse_dictionary[most_frequent_idx]))  # Printing
tput_words, feed_dict={X_test: most_frequent_idx})  # Feeding test word
                                                      # Printing
tionary[word])                                        # Printing
```

```
s...
23989684
4704411
9073989
773459
5340997
7599613
55122535
4312601
2340043
05242202
7/rnn_tensorflow/src/log_8th_word_RNN/model.ckpt-340
43206114
Epoch: 12 Average_cost: 3.190694395233603
Epoch: 13 Average_cost: 3.037706837934606
Epoch: 14 Average_cost: 2.9177206333945778
Epoch: 15 Average_cost: 2.8175760788076065
```

복잡해 보이지만 예시로 이해하면 간단합니다.

Perceptron

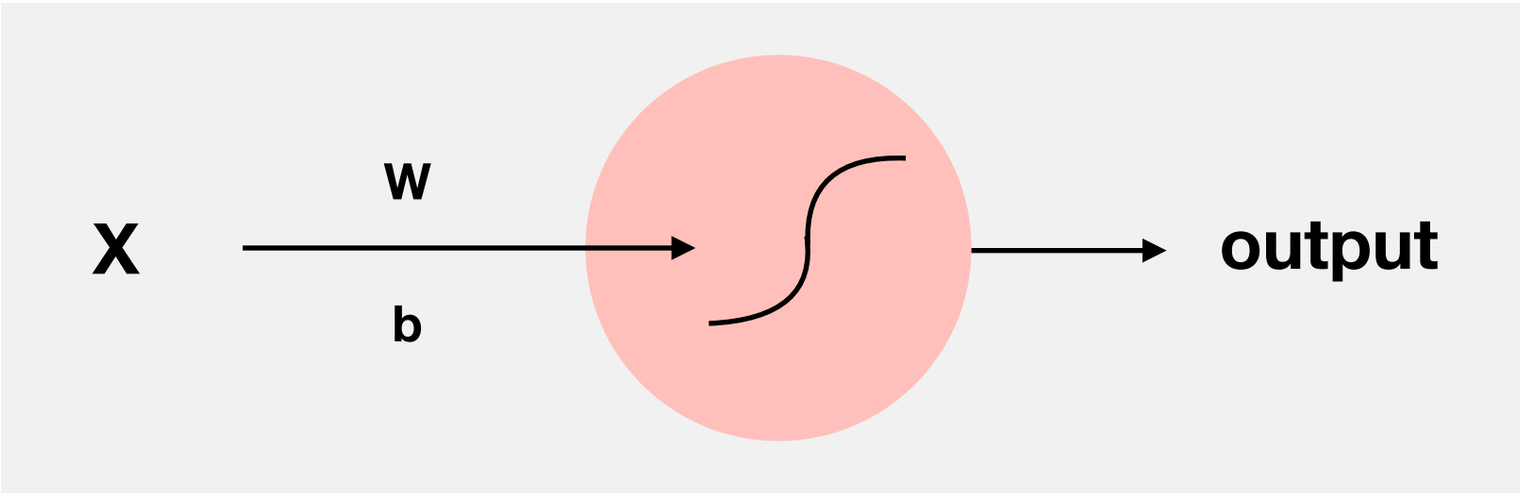

perceptron은 앞으로 배울 graphical model의 가장 기본이 되는 단위입니다.
perceptron을 통해 tensorflow의 graph와 session에 대해 알아봅시다.

Perceptron:
Graphing

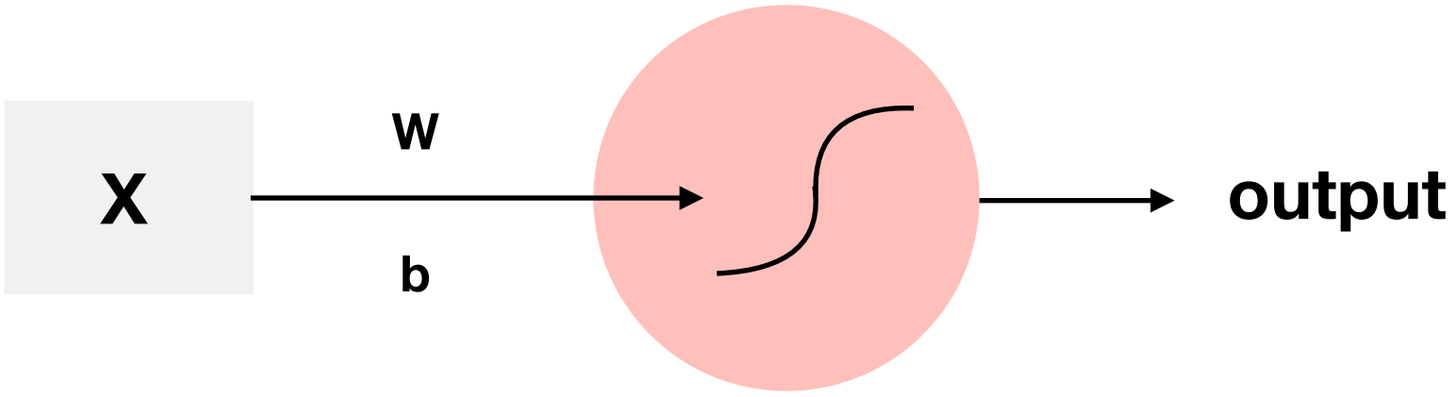

X가 들어가면

Perceptron:
Graphing

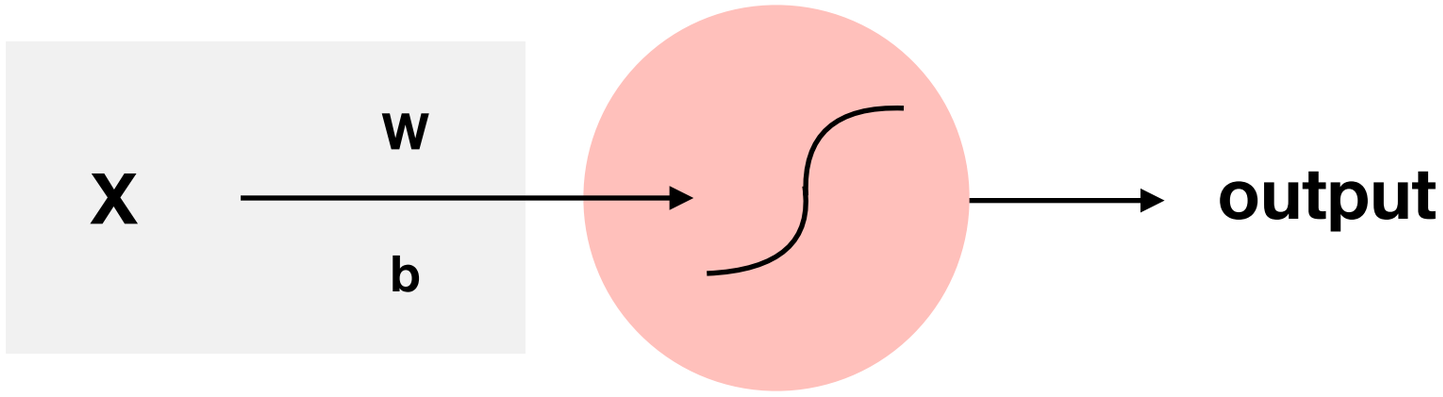

X * W + b
X에 weight을 곱하고 bias를 더합니다.

Perceptron:
Graphing

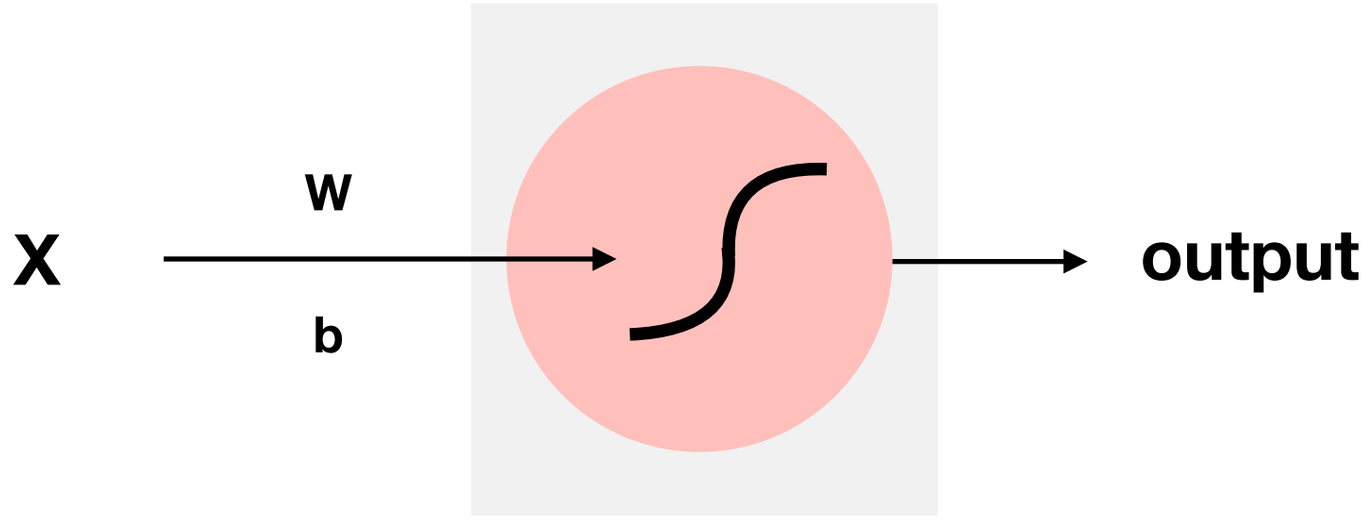

f(X * W + b) = output

구한 값에 activation function을 씌워 특정 범위의 값으로 바꿔줍니다.

e.g.
sigmoid function: 0~1
tanh function : -1~1
reLU function : 0~inf
no function : no change

Perceptron:
Graphing

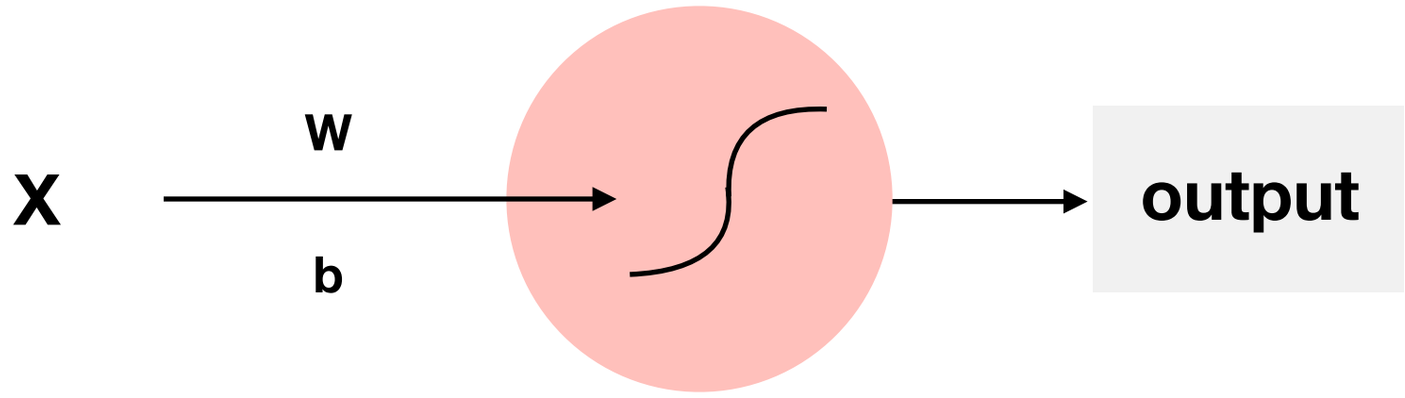

f(X * W + b) = output
최종적으로 계산되는 값을 output이라 합니다.

Perceptron:
Graphing

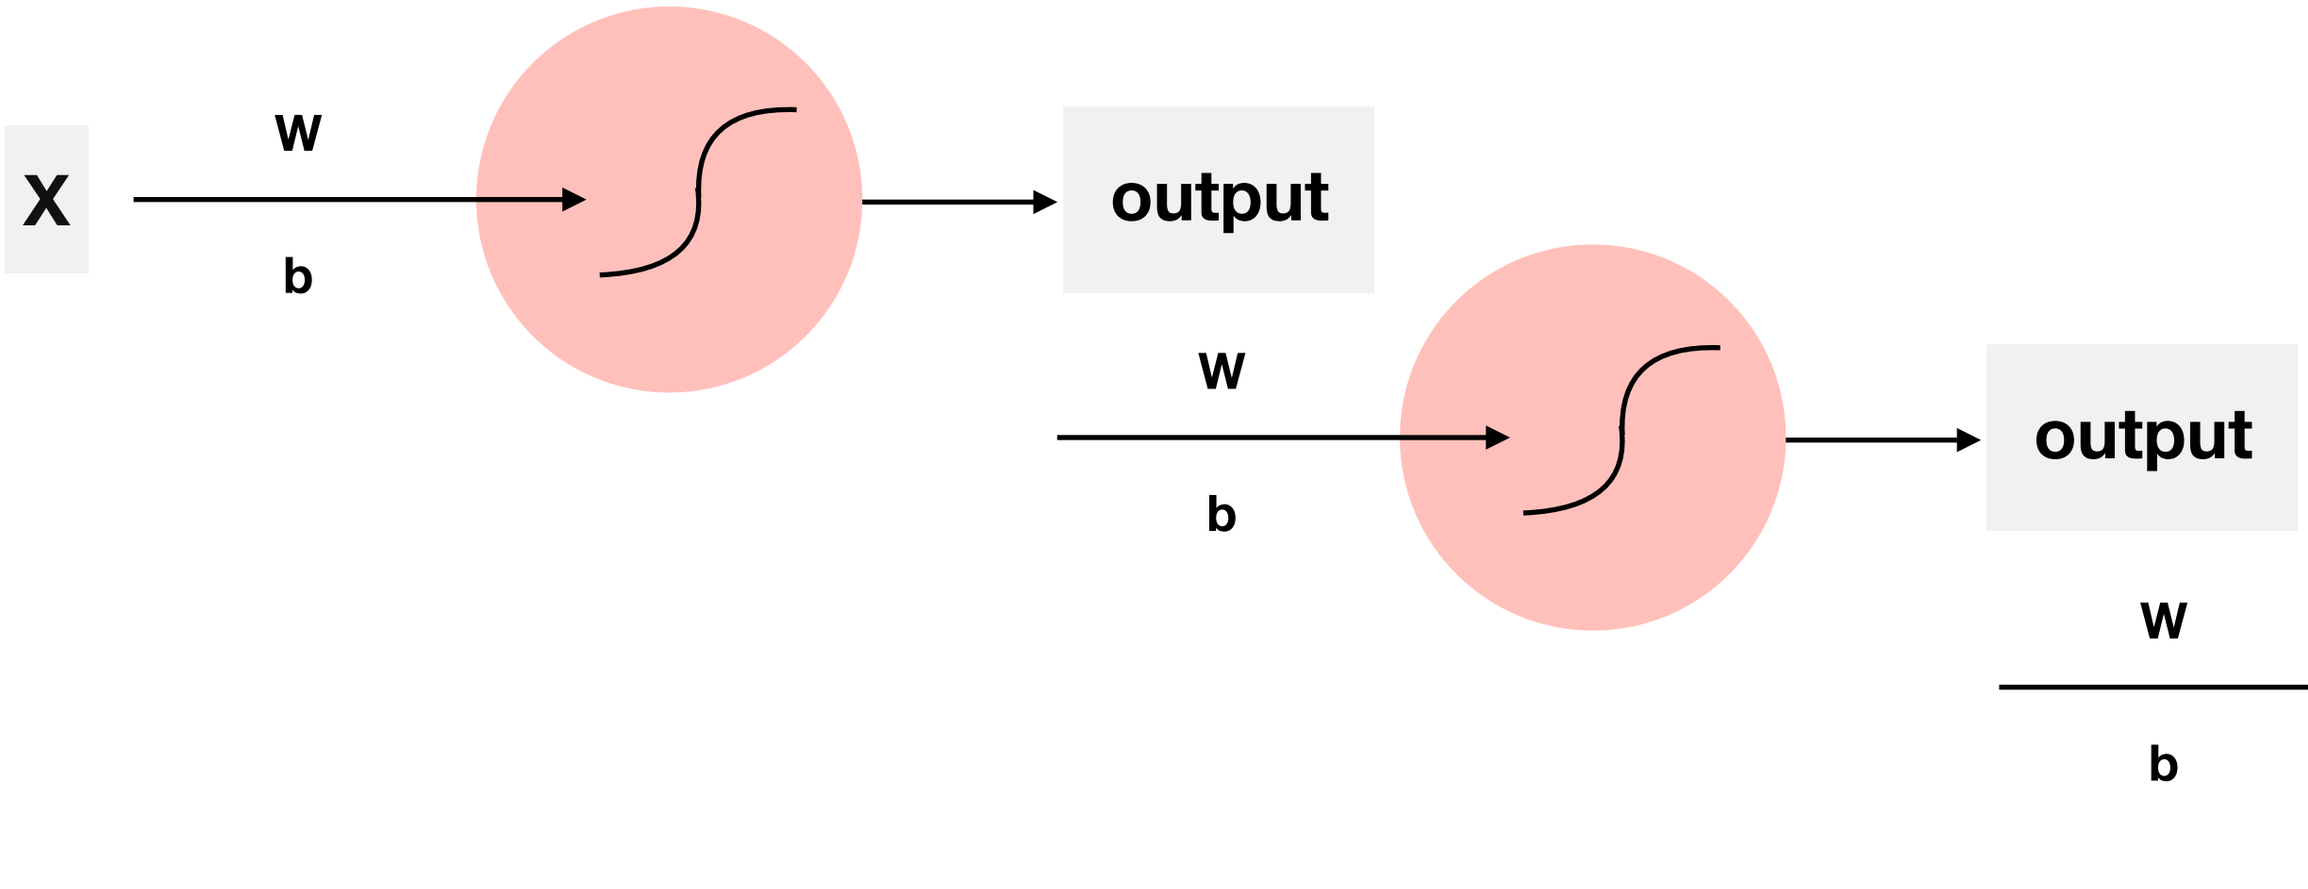

후에 사용될 연쇄된 형태의 perceptrons의 경우,
output은 X가 다음 perceptron에 얼마나 많이 전달되어야 하는지를 나타냅니다.

Perceptron:
Graphing

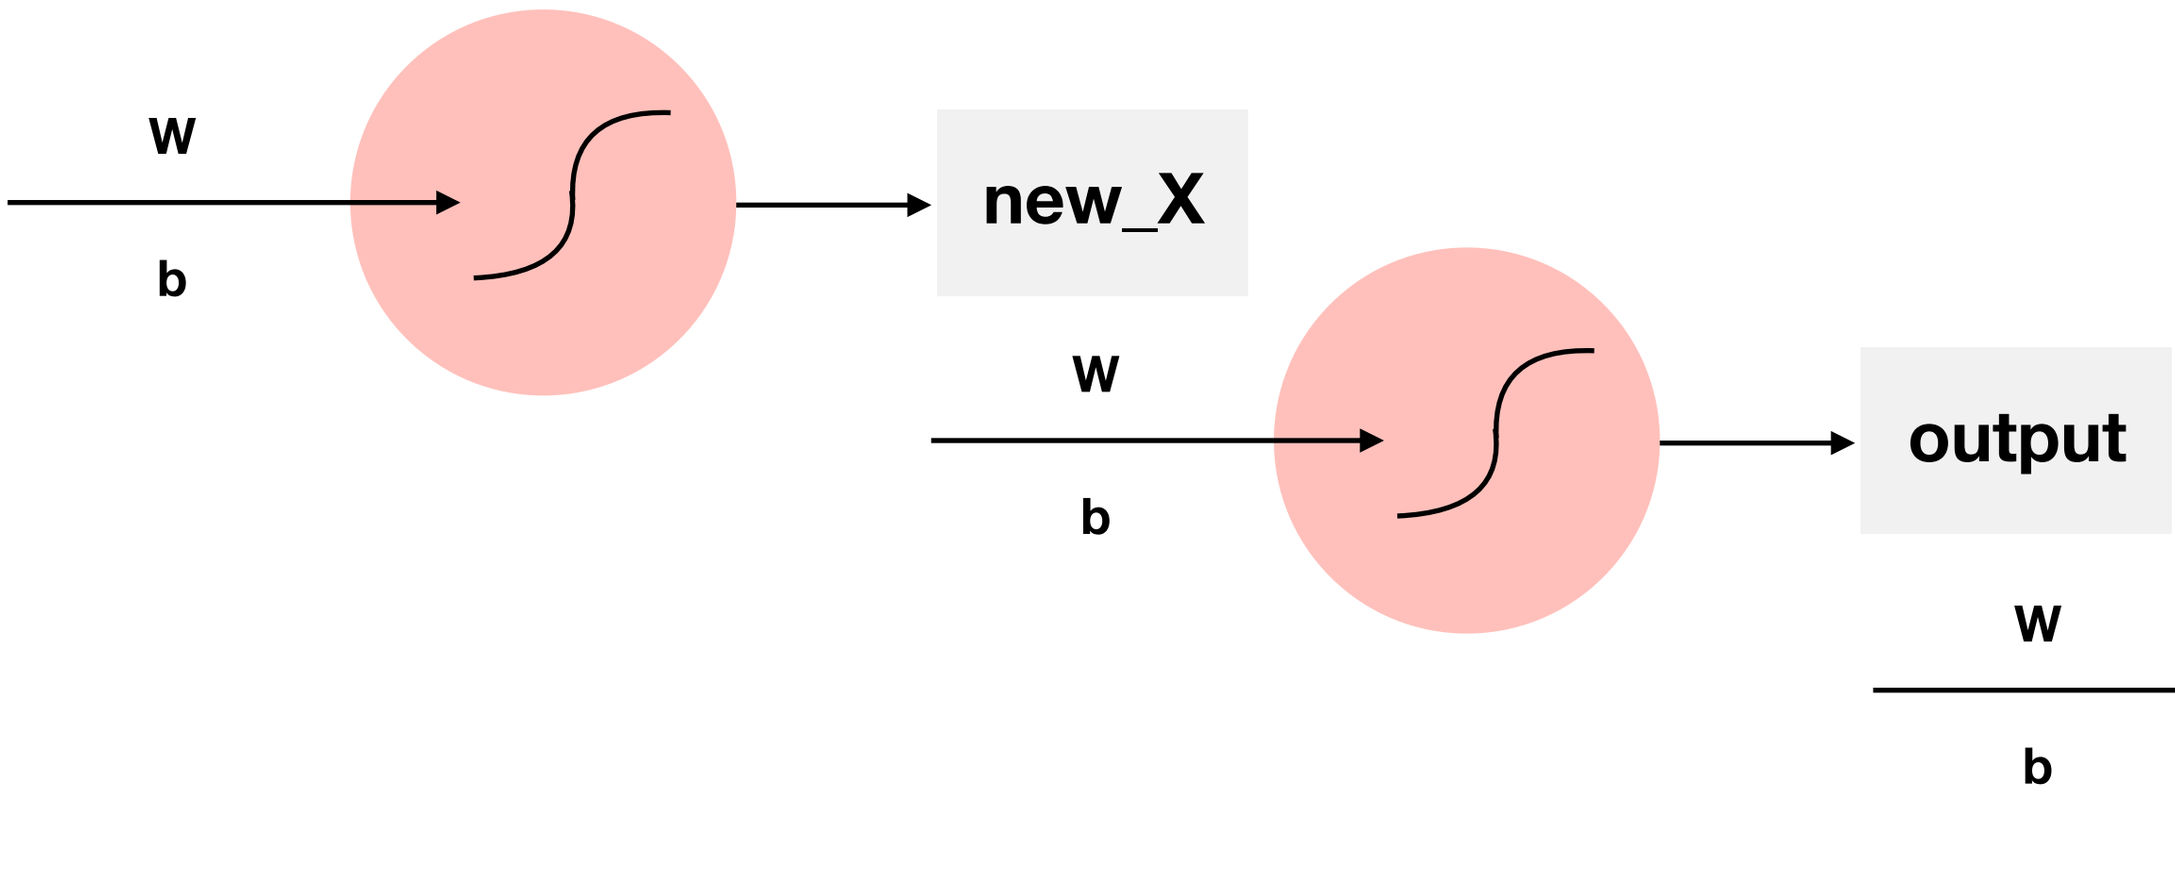

후에 사용될 연쇄된 형태의 perceptrons의 경우,
output은 X가 다음 perceptron에 얼마나 많이 전달되어야 하는지를 나타냅니다.

Perceptron:
Graphing

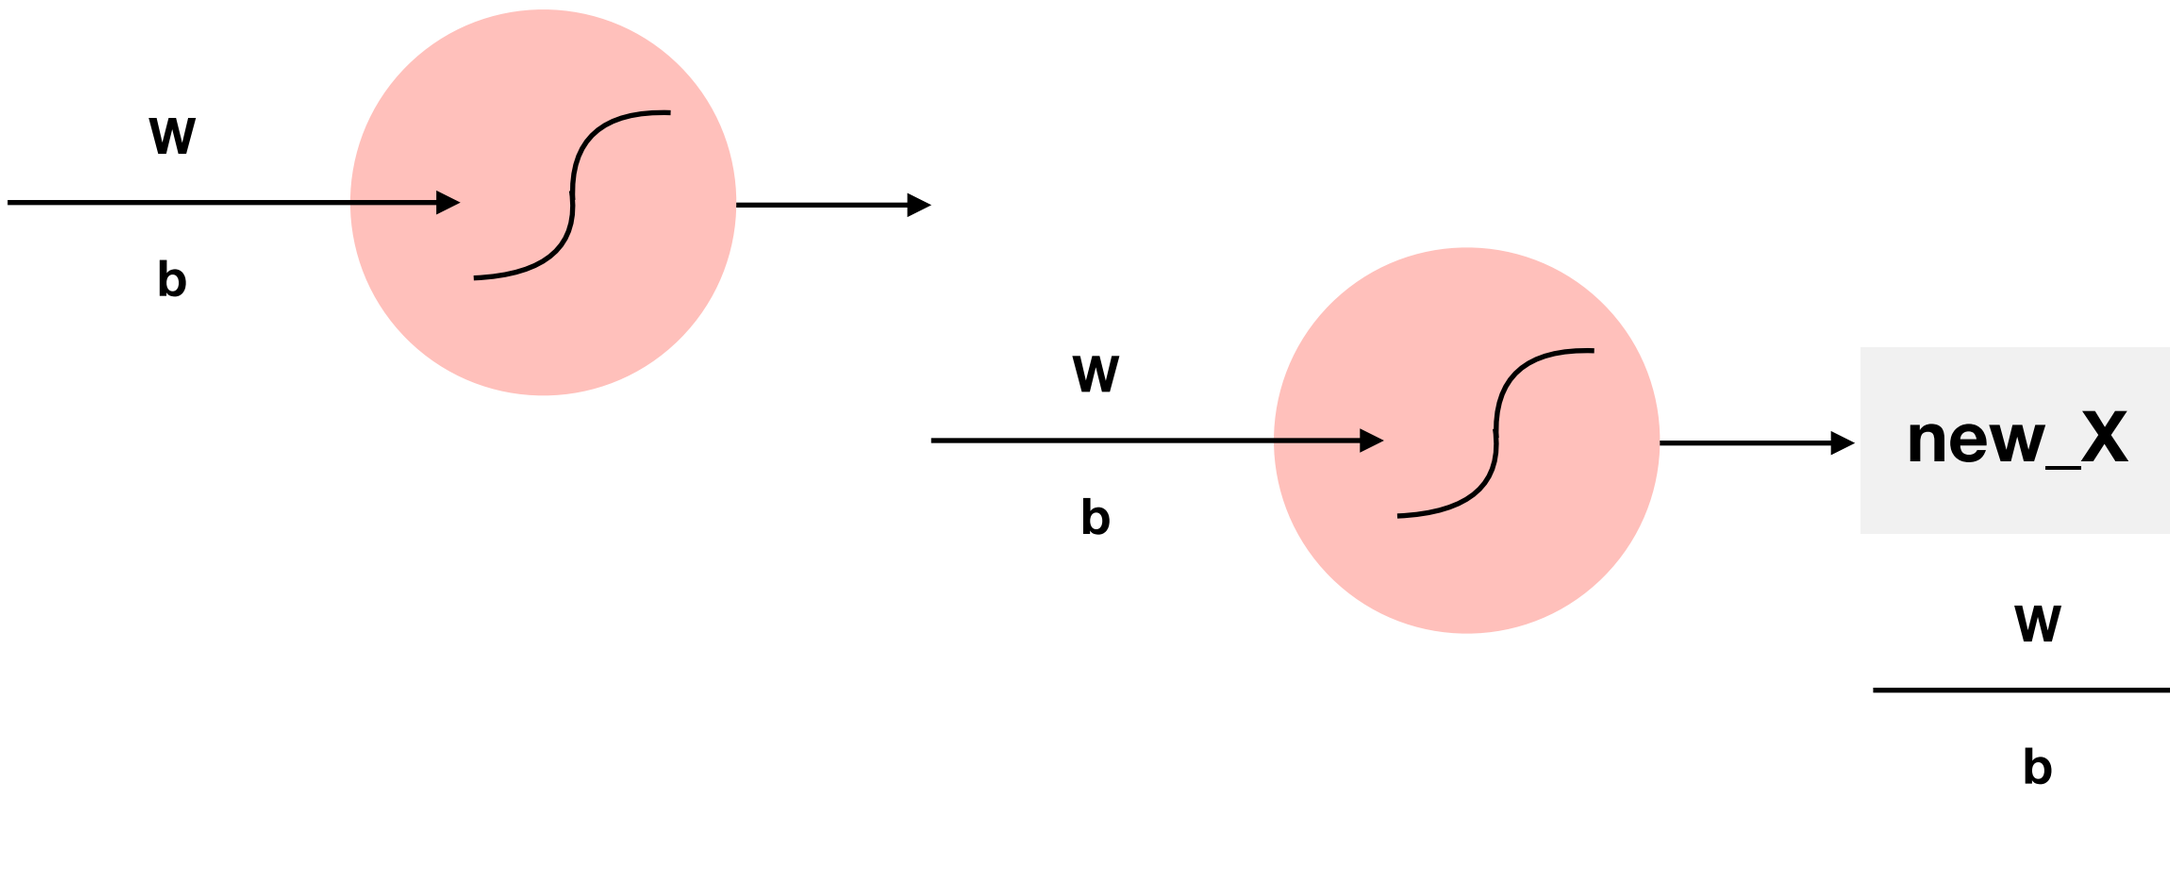

후에 사용될 연쇄된 형태의 perceptrons의 경우,
output은 X가 다음 perceptron에 얼마나 많이 전달되어야 하는지를 나타냅니다.

Perceptron:
Graphing

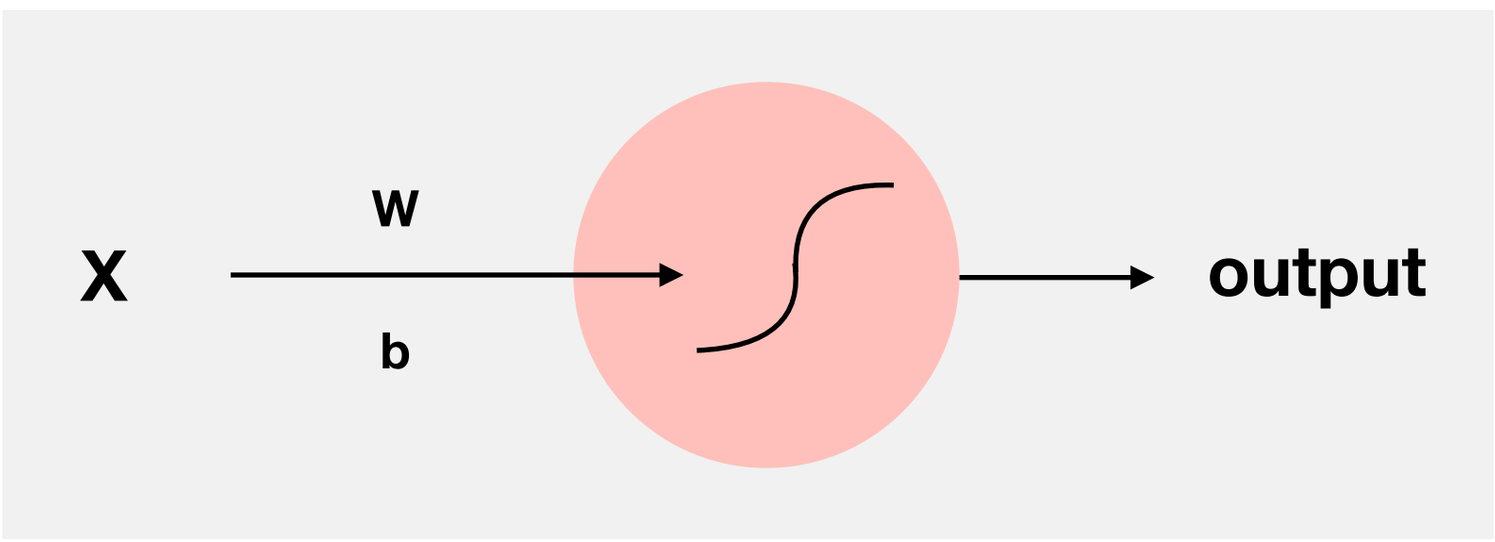

f(X * W + b) = output
위 식을 graphical model로 그리면 다음과 같고, 이 과정을 graphing이라 합니다.

Perceptron:
Session

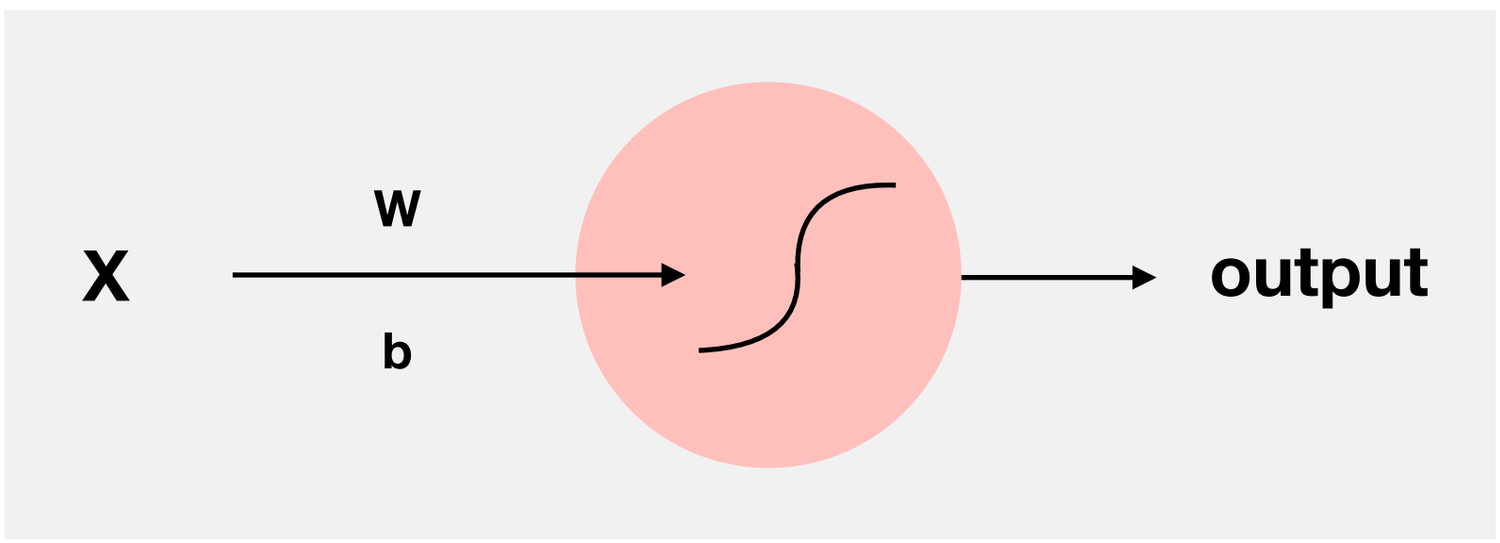

방금 만든 graph를 session에서 실행하게 되면

Perceptron:
Session

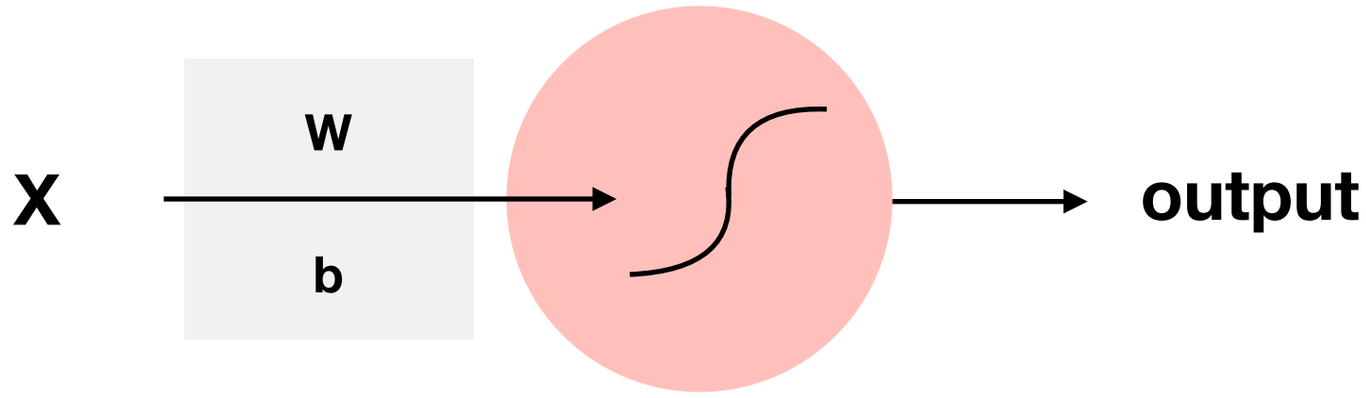

f(X * W + b) = output
먼저 weight과 bias를 random한 값으로 초기화(initialize)합니다.

이 때, initialize의 대상이 되는 것은 variables

Perceptron:
Session

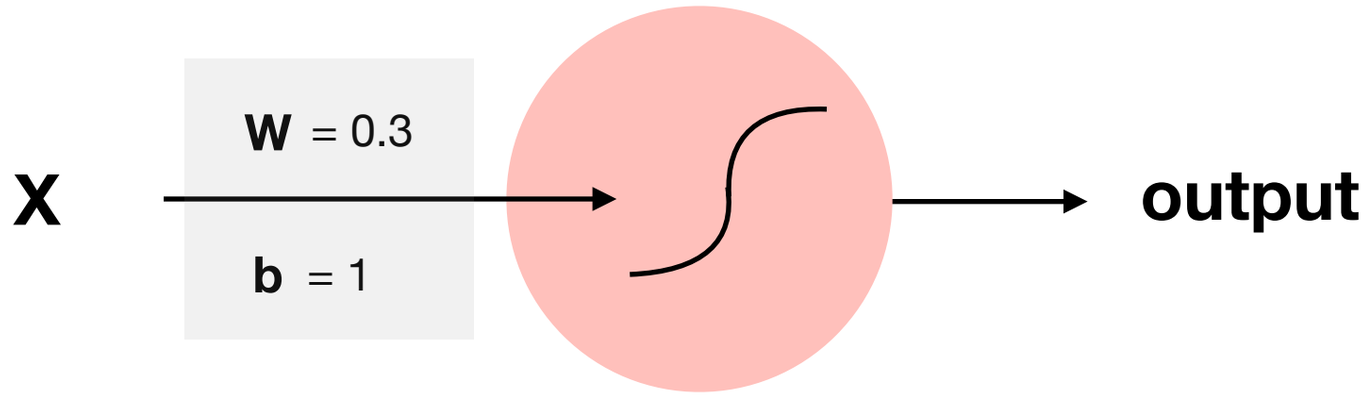

f(X * 0.3 + 1) = output

먼저 weight과 bias를 random한 값으로 초기화(initialize)합니다.

이 때, initialize의 대상이 되는 것은 variables

Perceptron:
Session

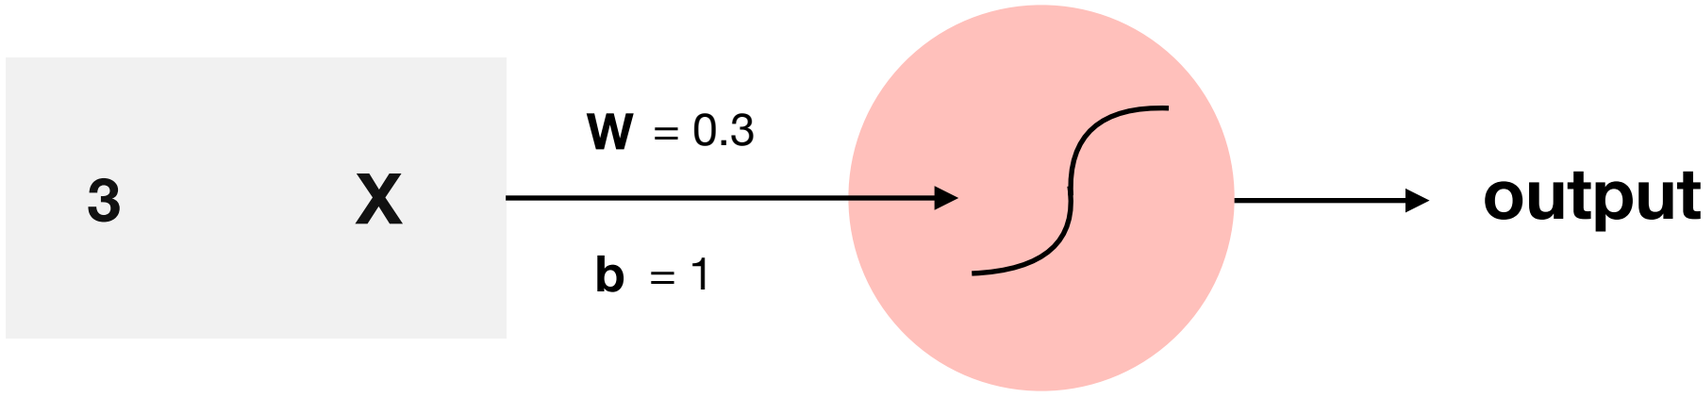

f(X * 0.3 + 1) = output
X에 준비한 input인 3을 넣습니다.

Perceptron:
Session

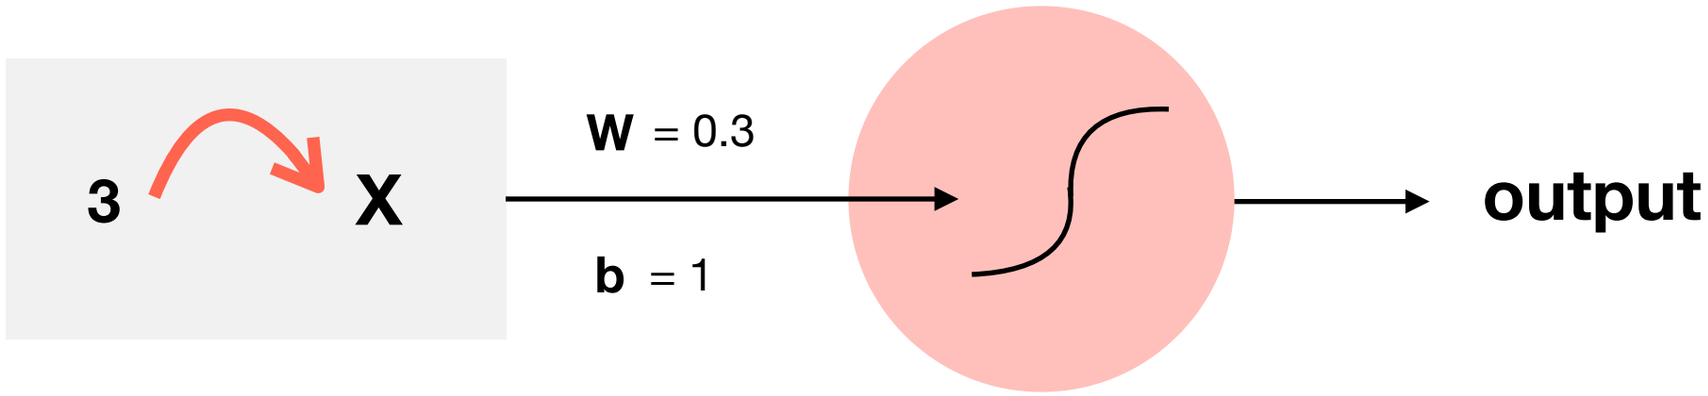

f(3 * 0.3 + 1) = output
X에 준비한 input인 3을 넣습니다.

Perceptron:
Session

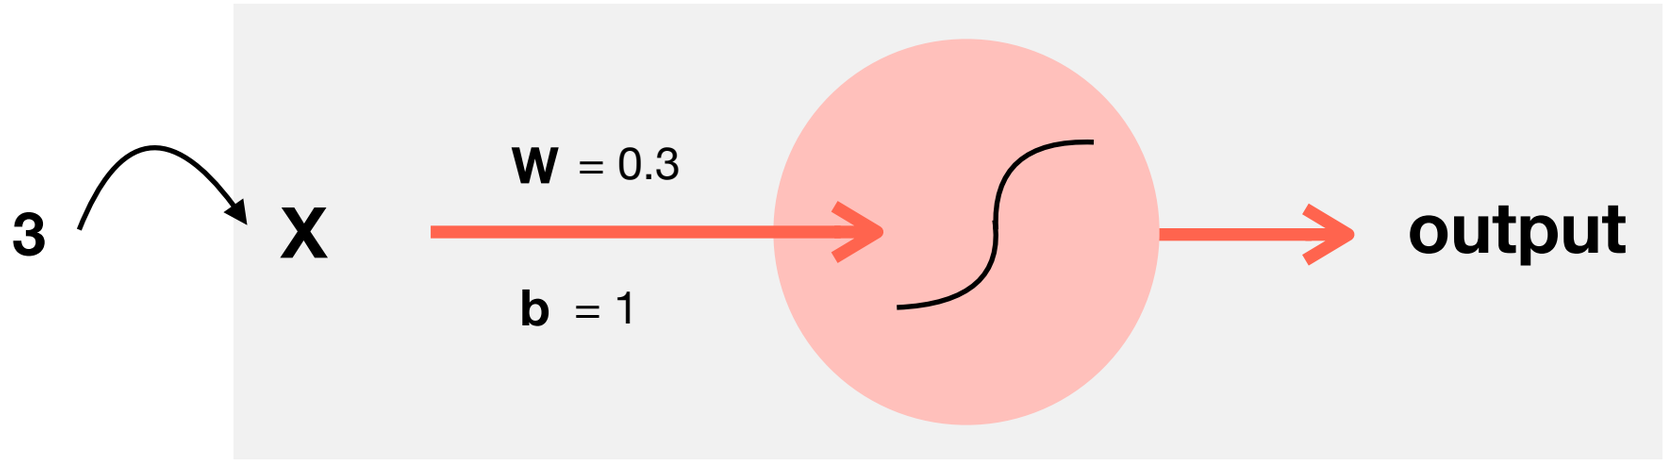

f(3 * 0.3 + 1) = output
graph를 실행(run)하여 output을 계산합니다.

Perceptron:
Session

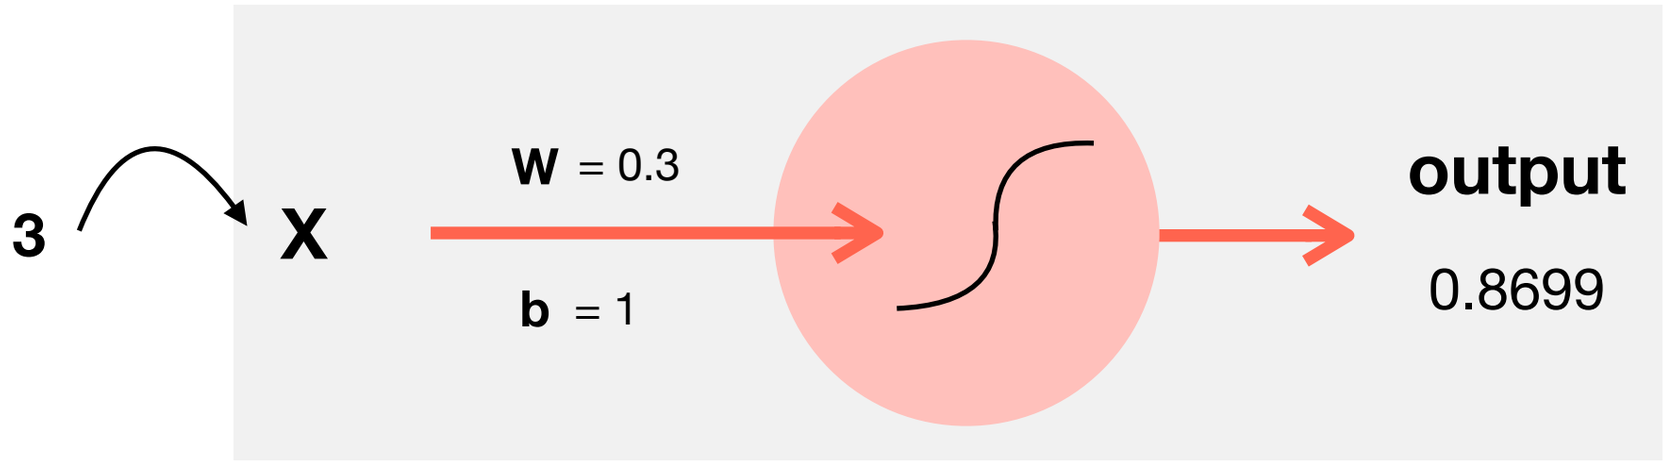

f(3 * 0.3 + 1) = 0.8699
graph를 실행(run)하여 output을 계산합니다.

Perceptron:
Session

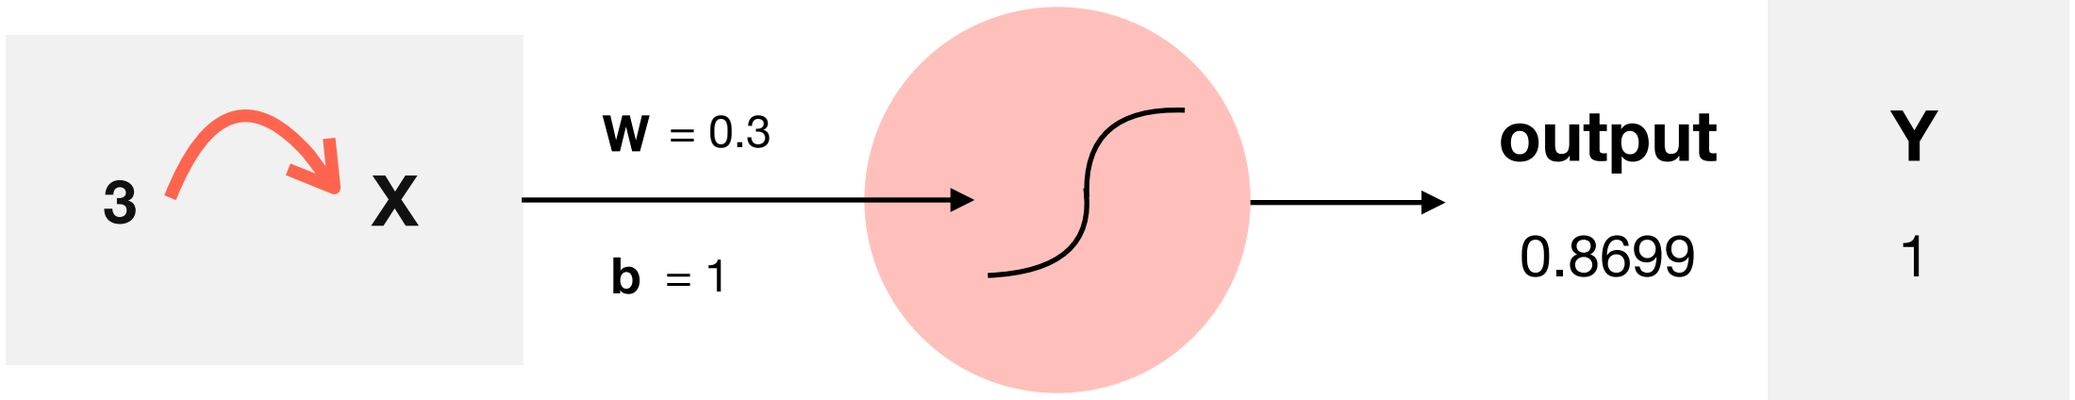

위 perceptron이 input으로 3을 받아서
output으로 정답 target (Y) 1을 돌려주길 원한다면,

1. output과 정답 target (Y)의 차이인 loss를 계산하고,
2. loss를 최소화하도록 weight과 bias를 update 해야 합니다.

Perceptron:
Session

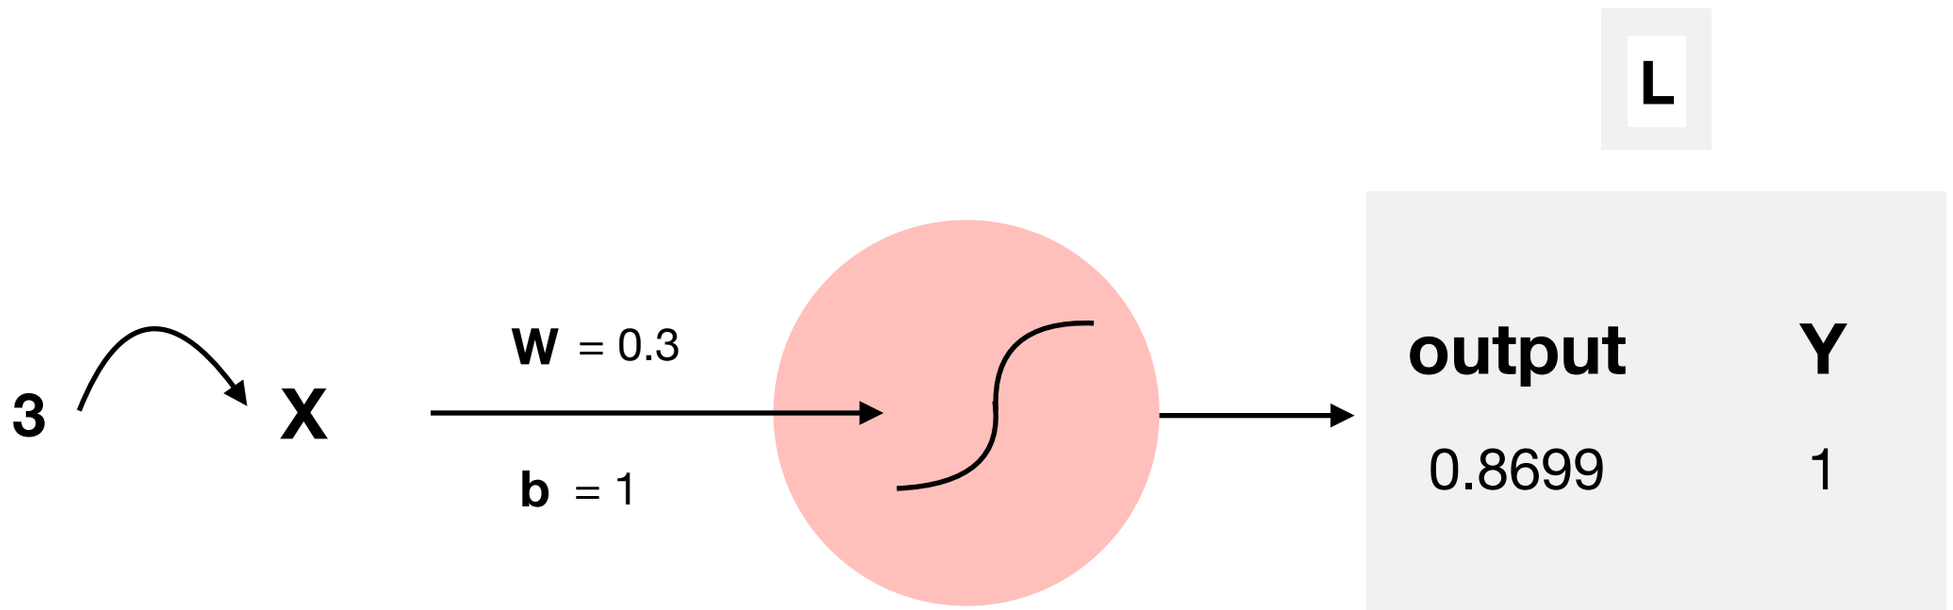

1.
loss = | output - target |
output과 정답 target (Y)의 차이인 loss를 계산하고,

Perceptron:
Session

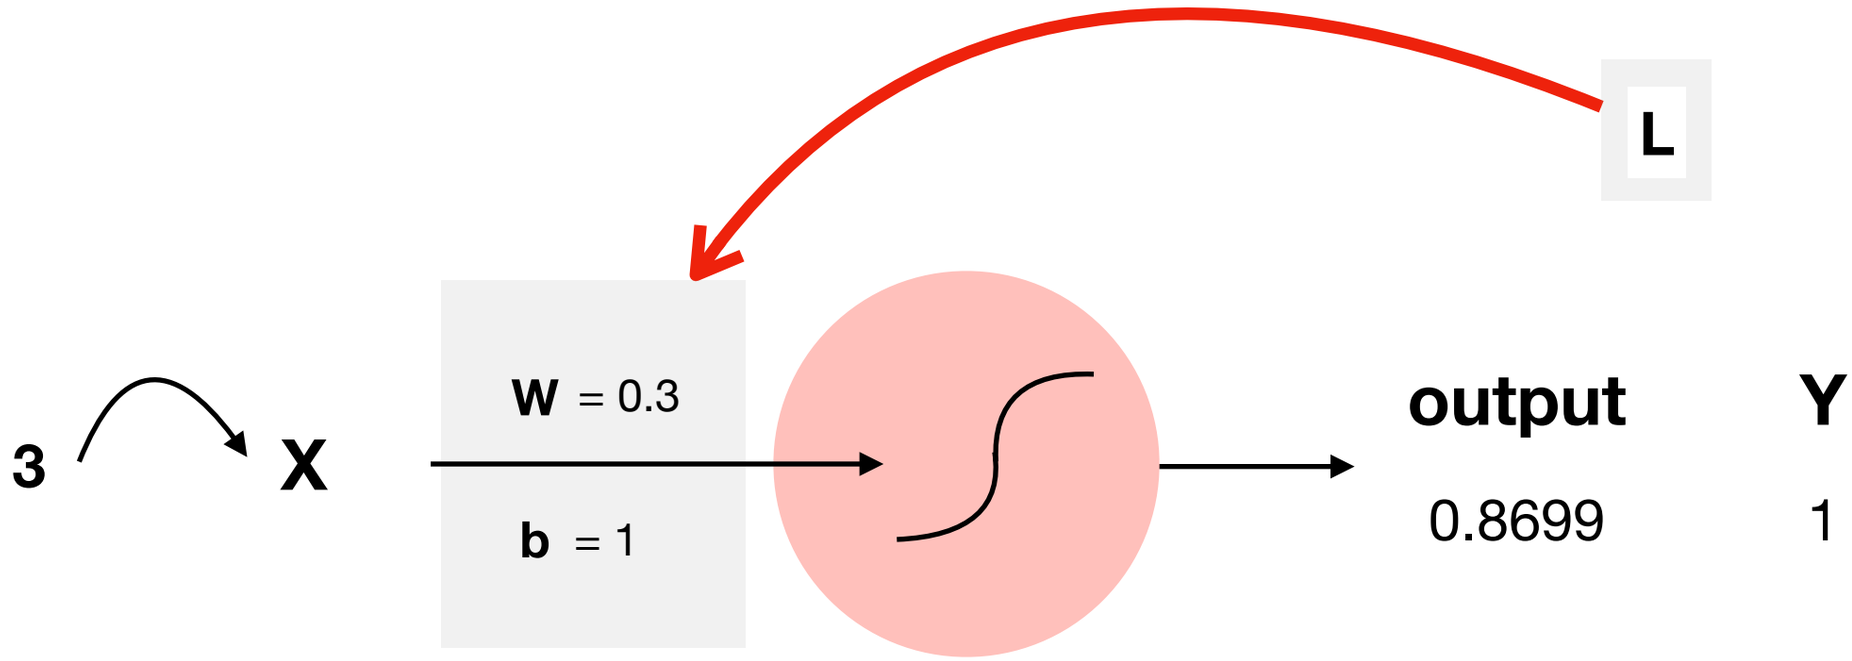

2.
loss를 최소화하도록 weight과 bias를 update 합니다.
이 과정을 optimization이라 합니다.

Perceptron:
Session

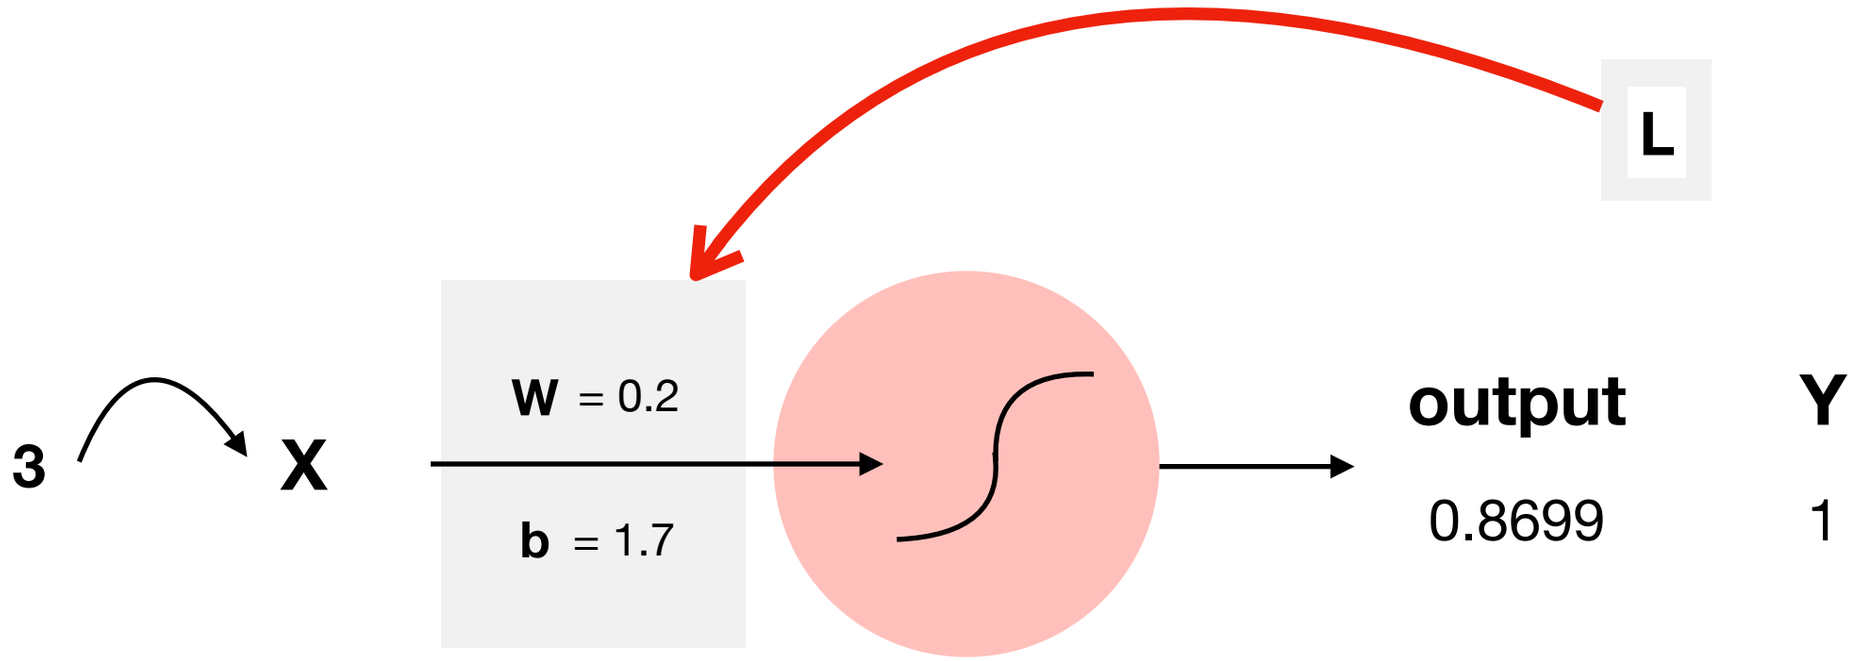

2.
loss를 최소화하도록 weight과 bias를 update 합니다.
이 과정을 optimization이라 합니다.

Perceptron:
Placeholder

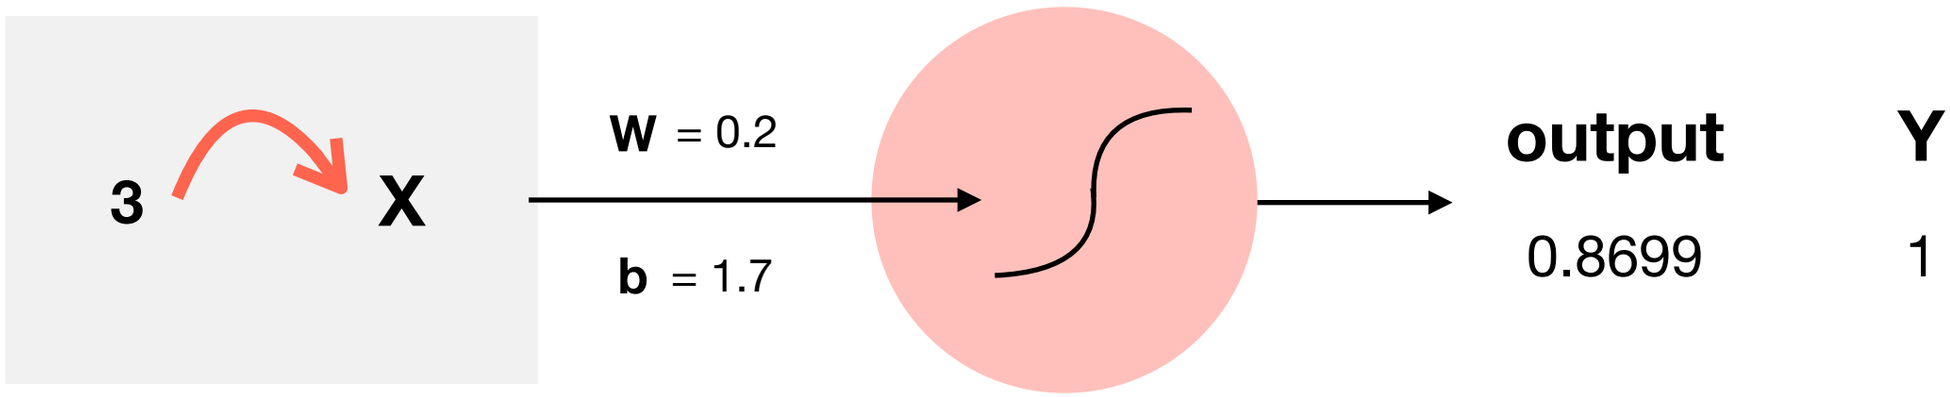

session에서 graph를 실행(run)할 때 값을 채워주어야 하는 X는 graphing 단계에서 placeholder로 정의됩니다.

Perceptron:
Variable

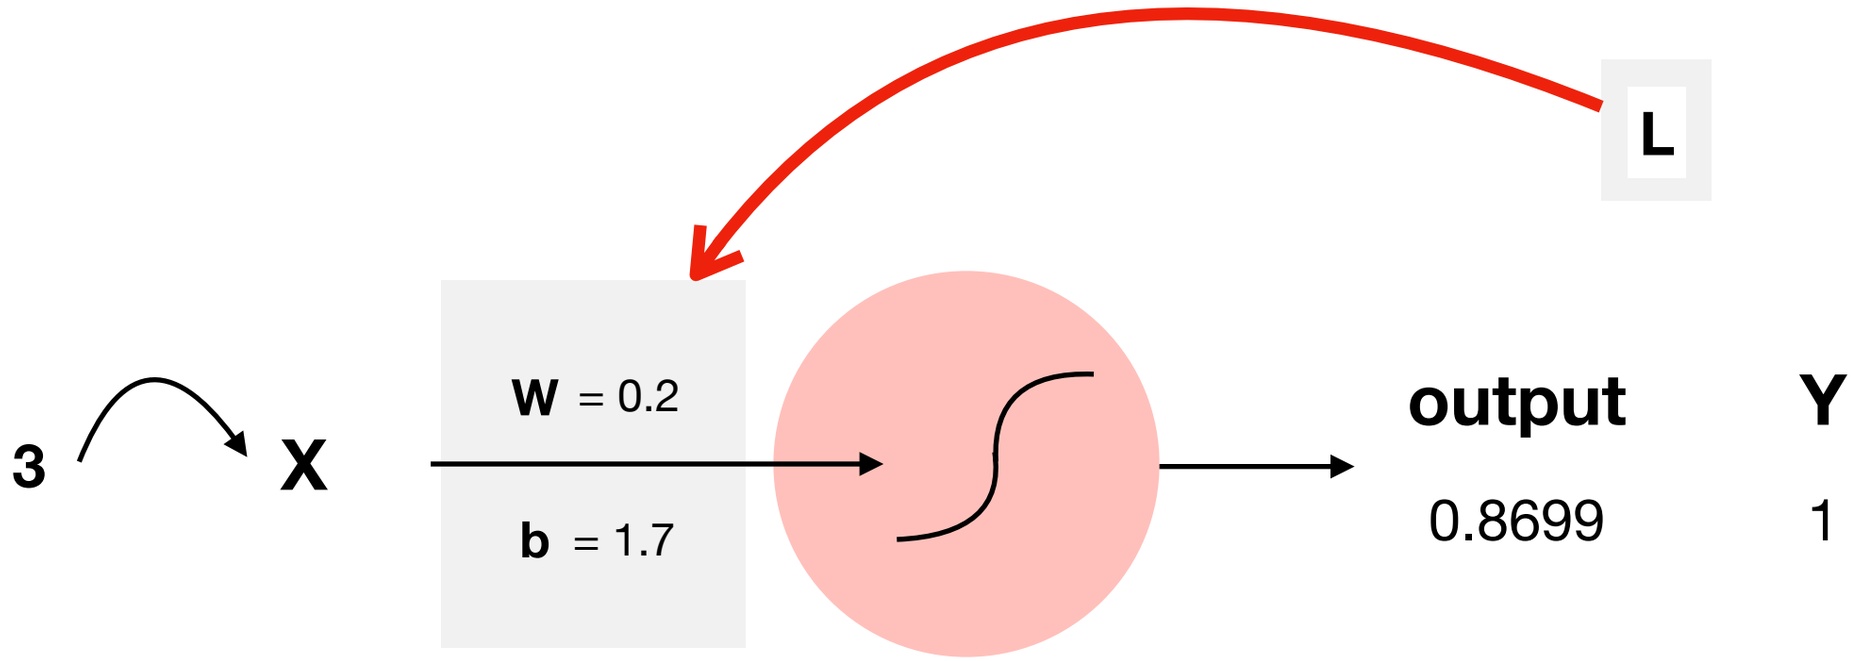

optimization 과정에서 값이 바뀌며 update 되는 weight과 bias는 graphing 단계에서 variable로 정의됩니다.

Perceptron:
Code

```
with tf.Graph().as_default():
```

graphing

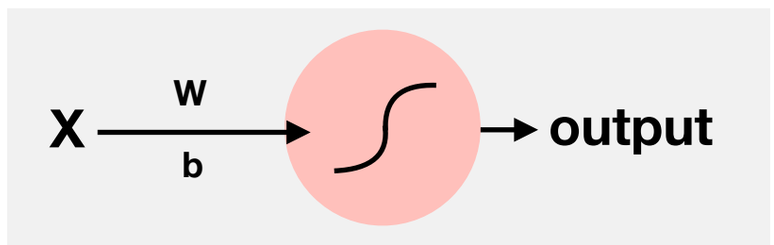


```
X = tf.placeholder
W = tf.Variables
b = tf.Variables
output = tf.sigmoid(X * W + b)
```

```
with tf.Session() as sess:
```

initialize

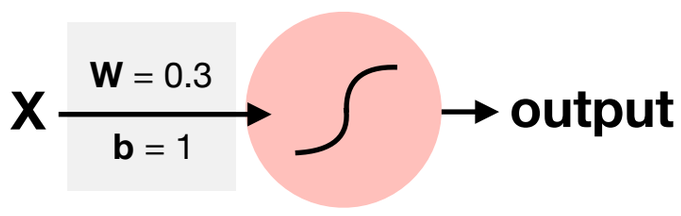


```
sess.run(initializer)
```

calculate loss

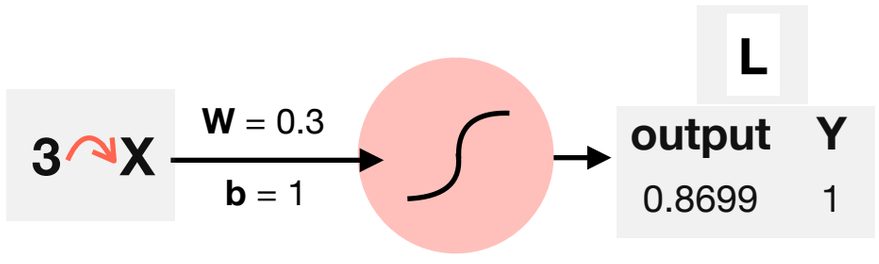


```
                tf.abs(output - target)
sess.run(loss,
                feed_dict={X:3, Y:1})
```

optimize

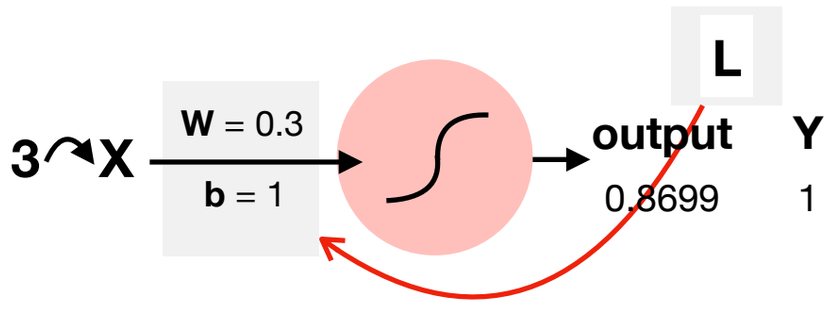


```
sess.run(optimizer)
```

Least Square Regression

Least Square Regression

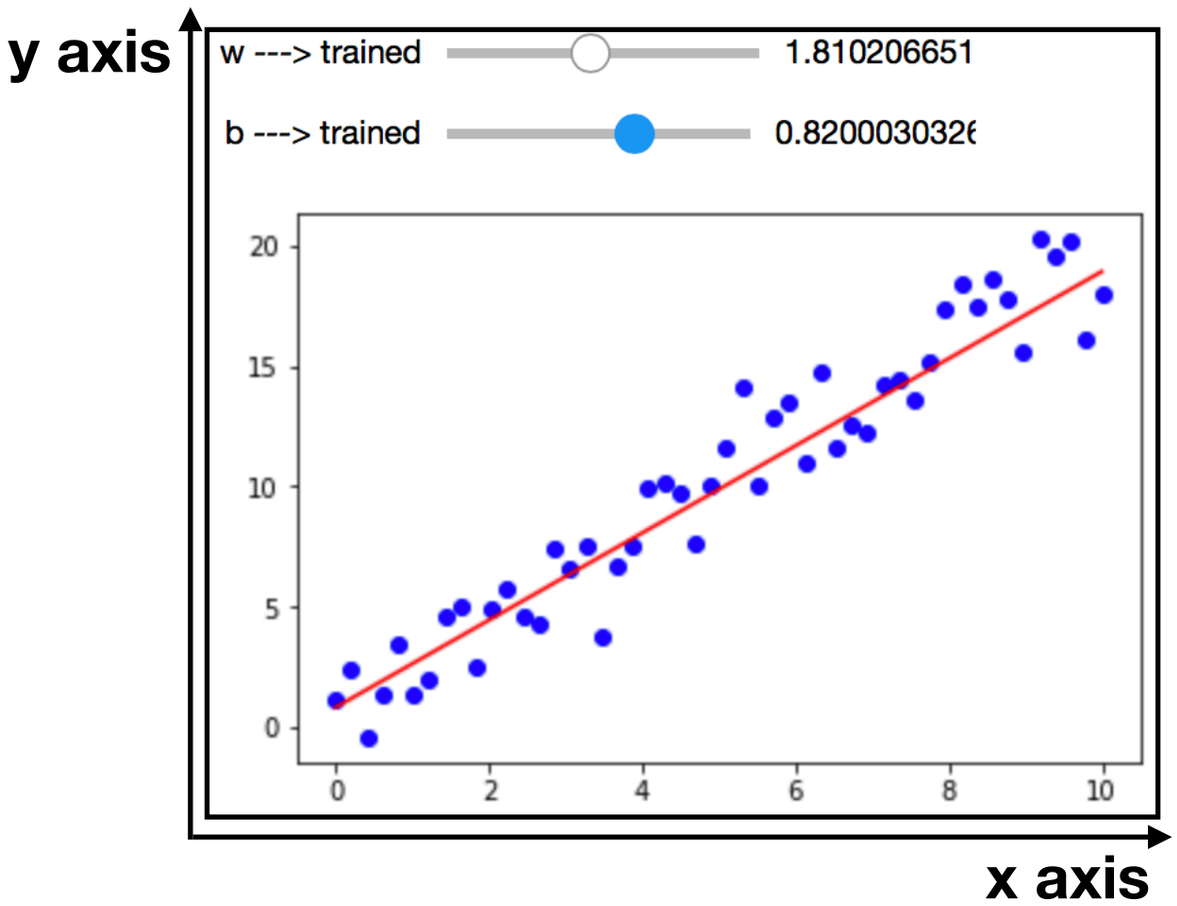

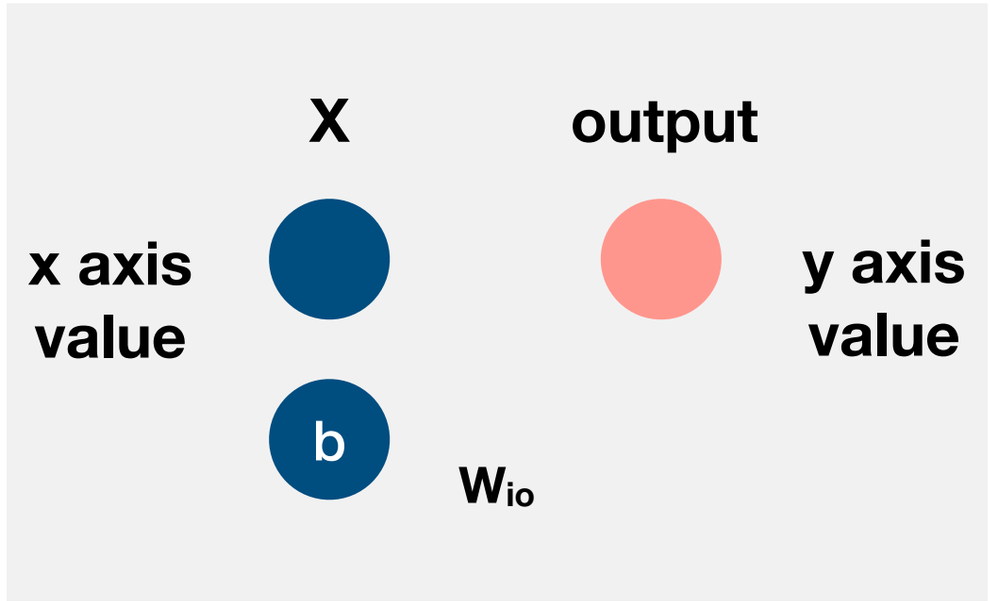

perceptrons를 이용한 least square regression graphical model

Least Square Regression

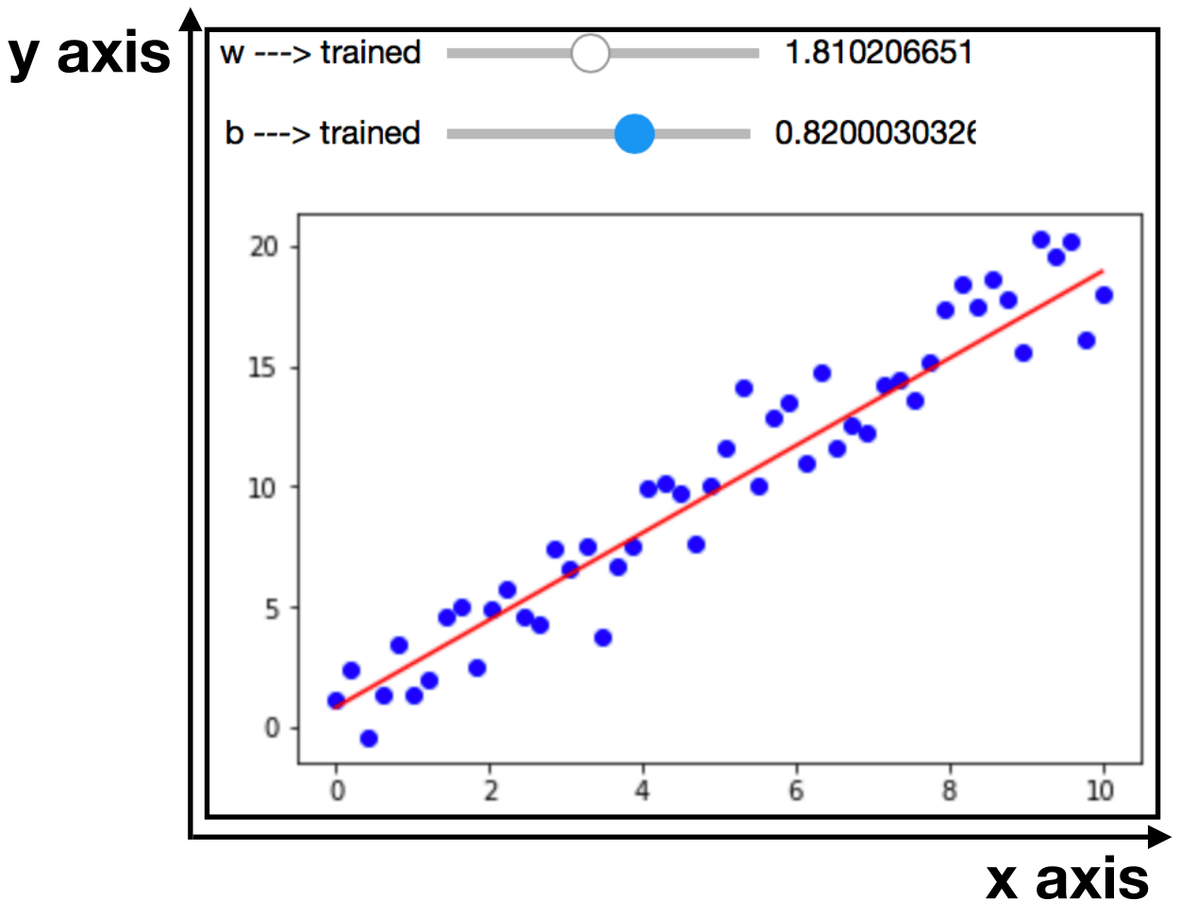

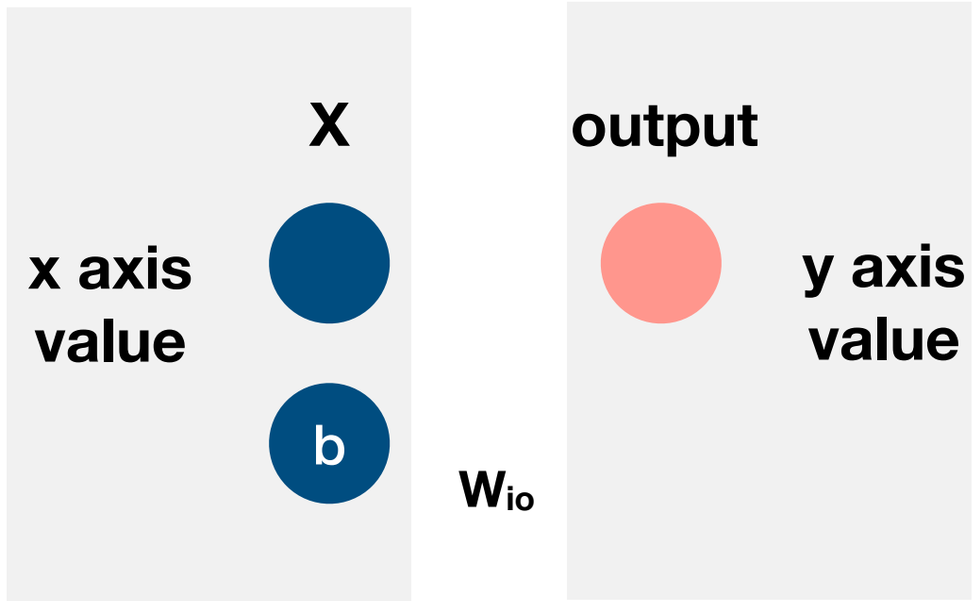

least square regression의 예시
input: 파란 데이터 포인트의 x axis value
target: 파란 데이터 포인트의 y axis value
output: 빨간 선형 모델 상의 y axis value
목적: 파란 데이터를 가장 잘 나타내는 빨간 선형 모델을 그리는 것

Least Square Regression

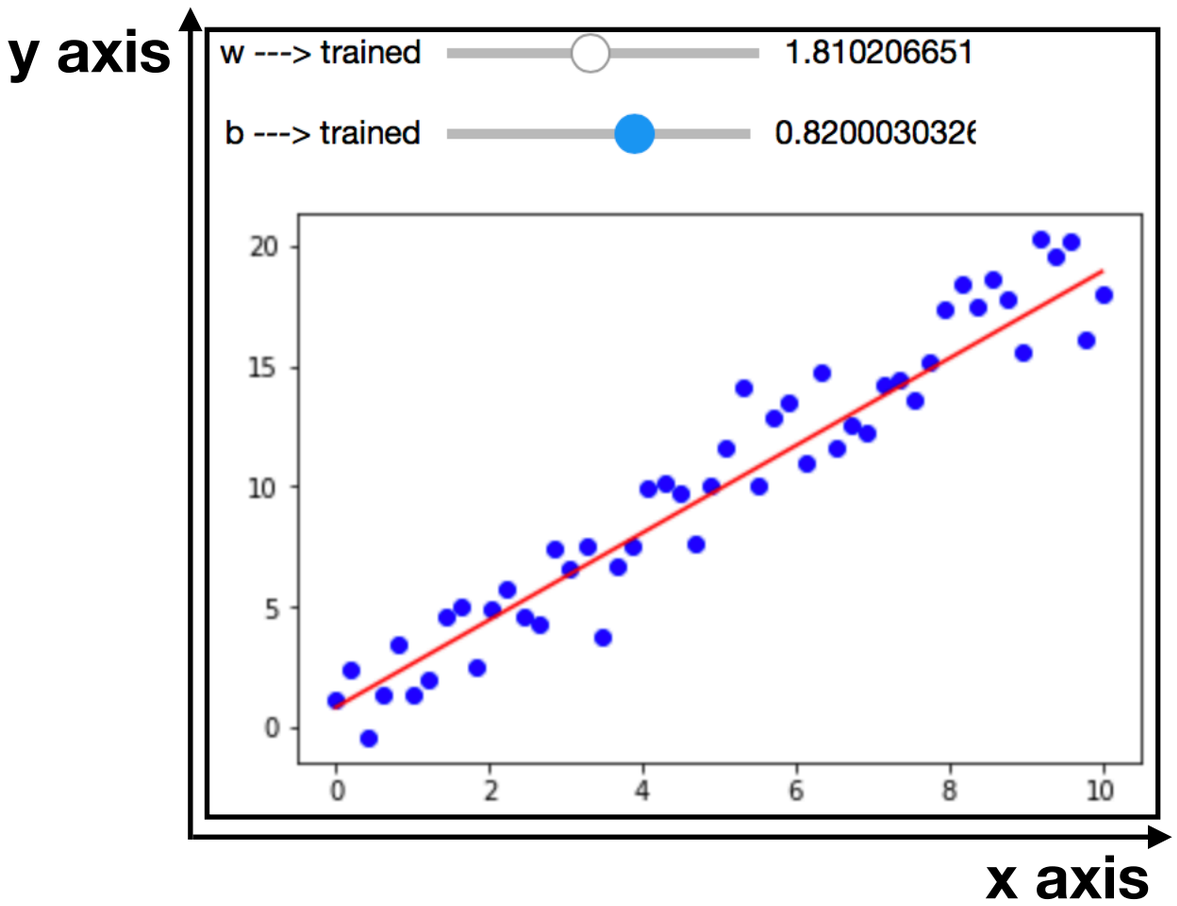

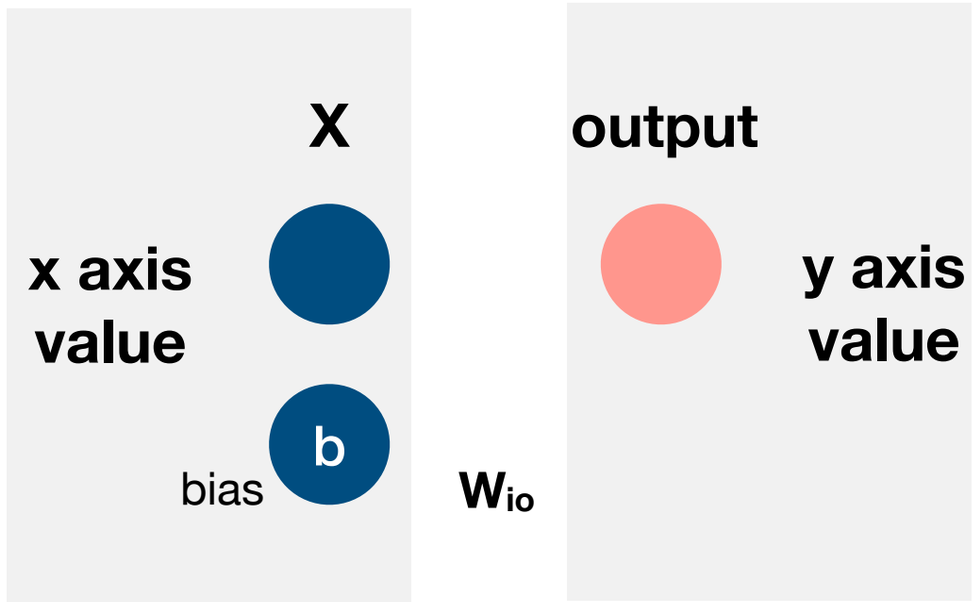

모델구조:

input layer (1 node),
output layer (1 node)
노드 숫자를 셀 때 bias node는 제외

Least Square Regression

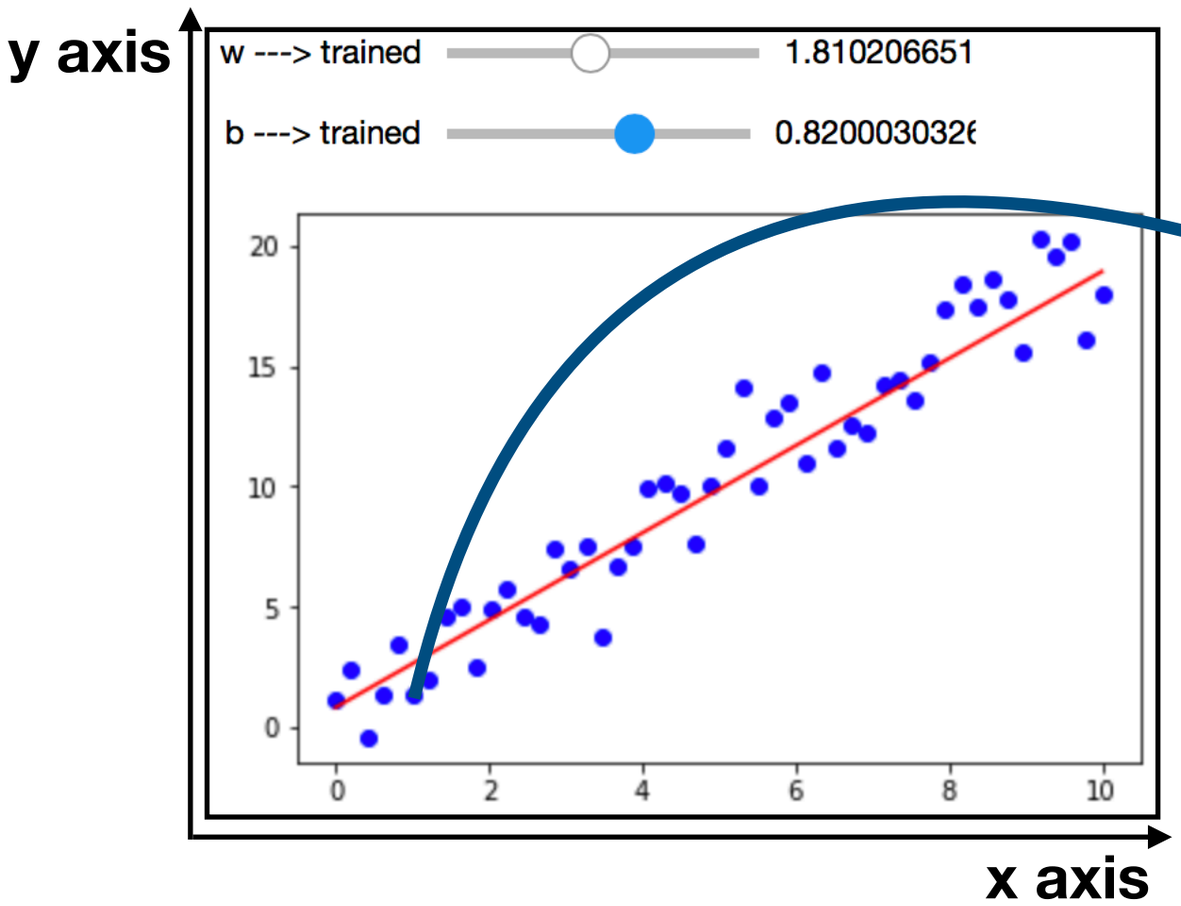

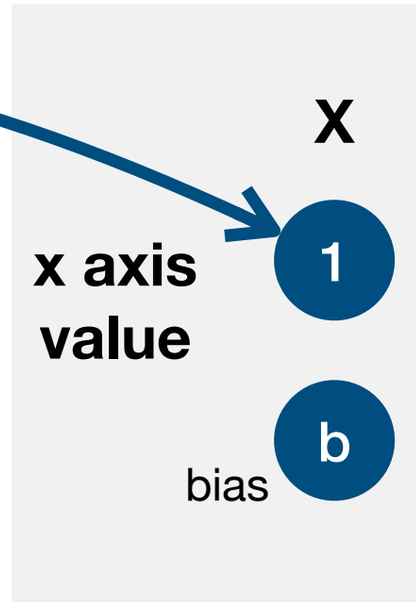

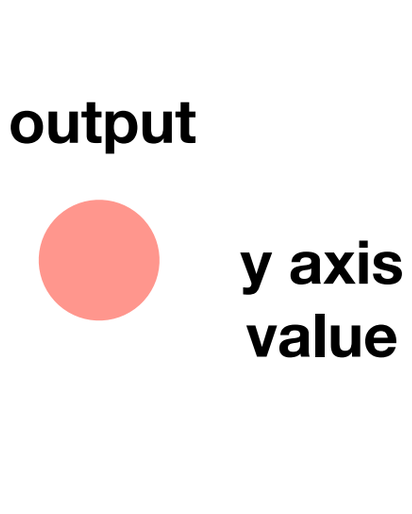

훈련:
파란 데이터 포인트의 x axis value를 input layer의 node에 넣어줍니다.

Least Square Regression

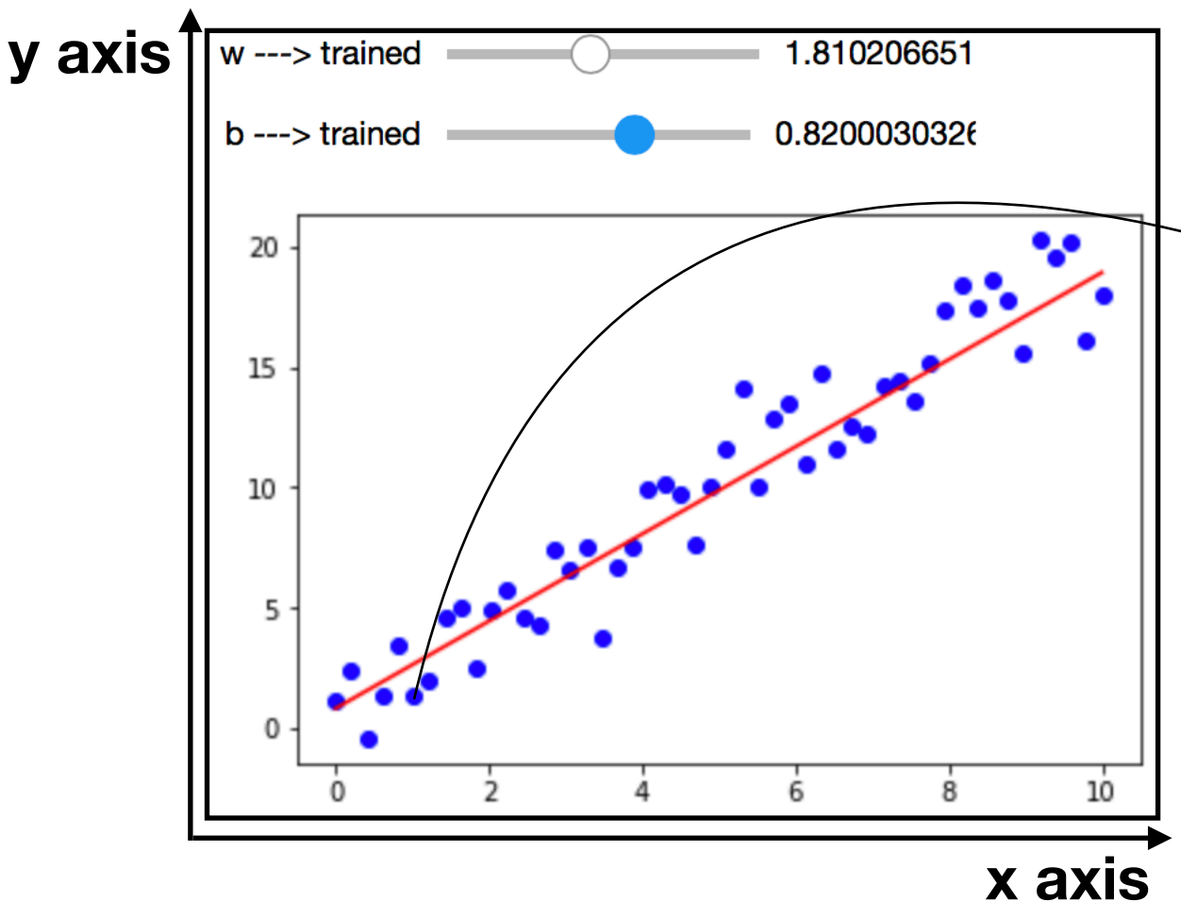

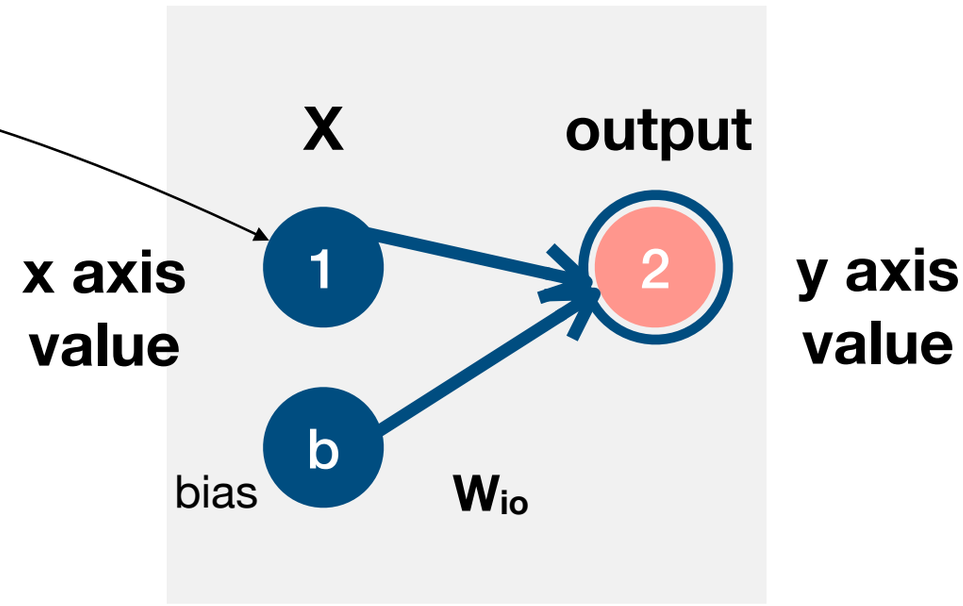

각 input layer의 node 값에 weight (진한 화살표)을 곱하고,
곱한 값을 모두 더해 output layer node에 넣어줍니다.

Least Square Regression

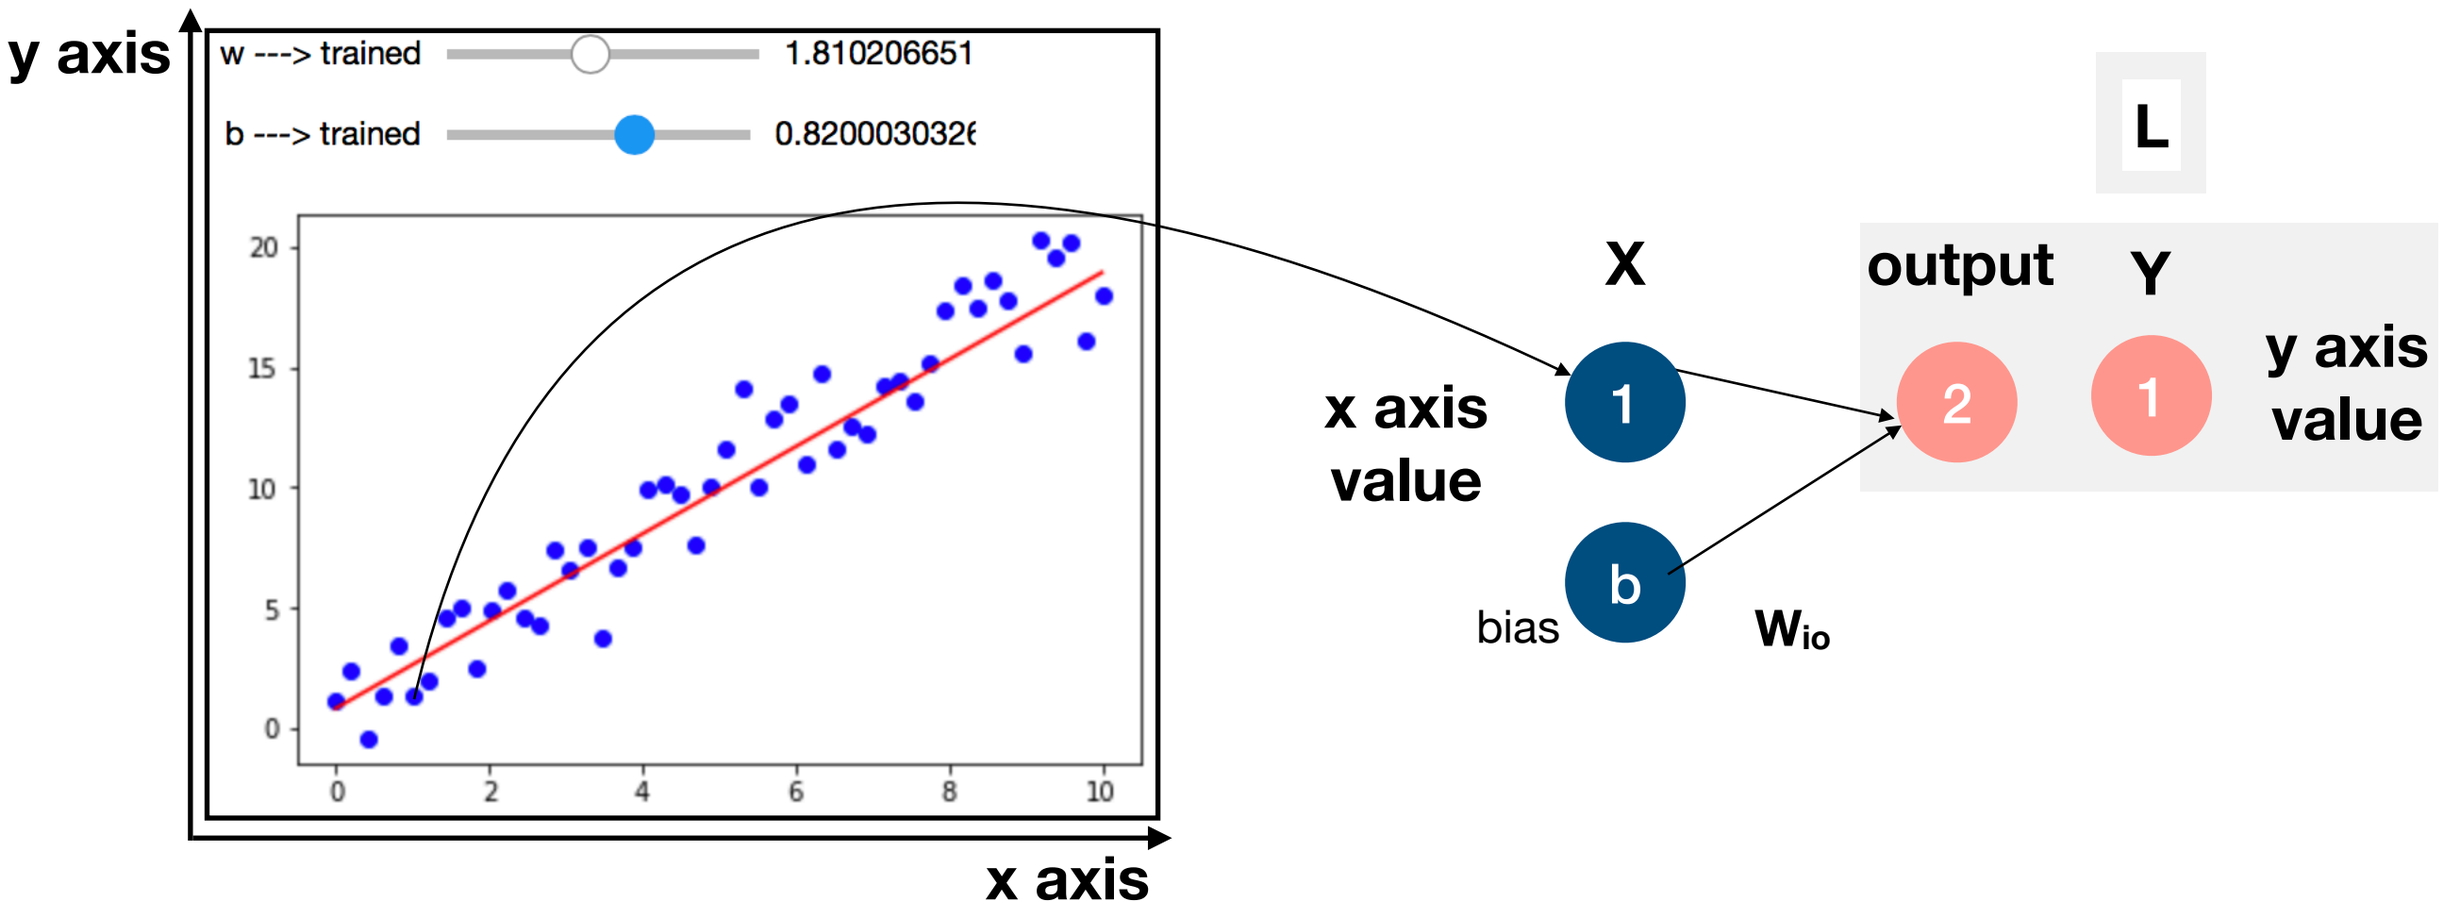

그렇게 구한 output과 정답 target (Y)을 비교하여 loss를 구합니다.

Least Square Regression

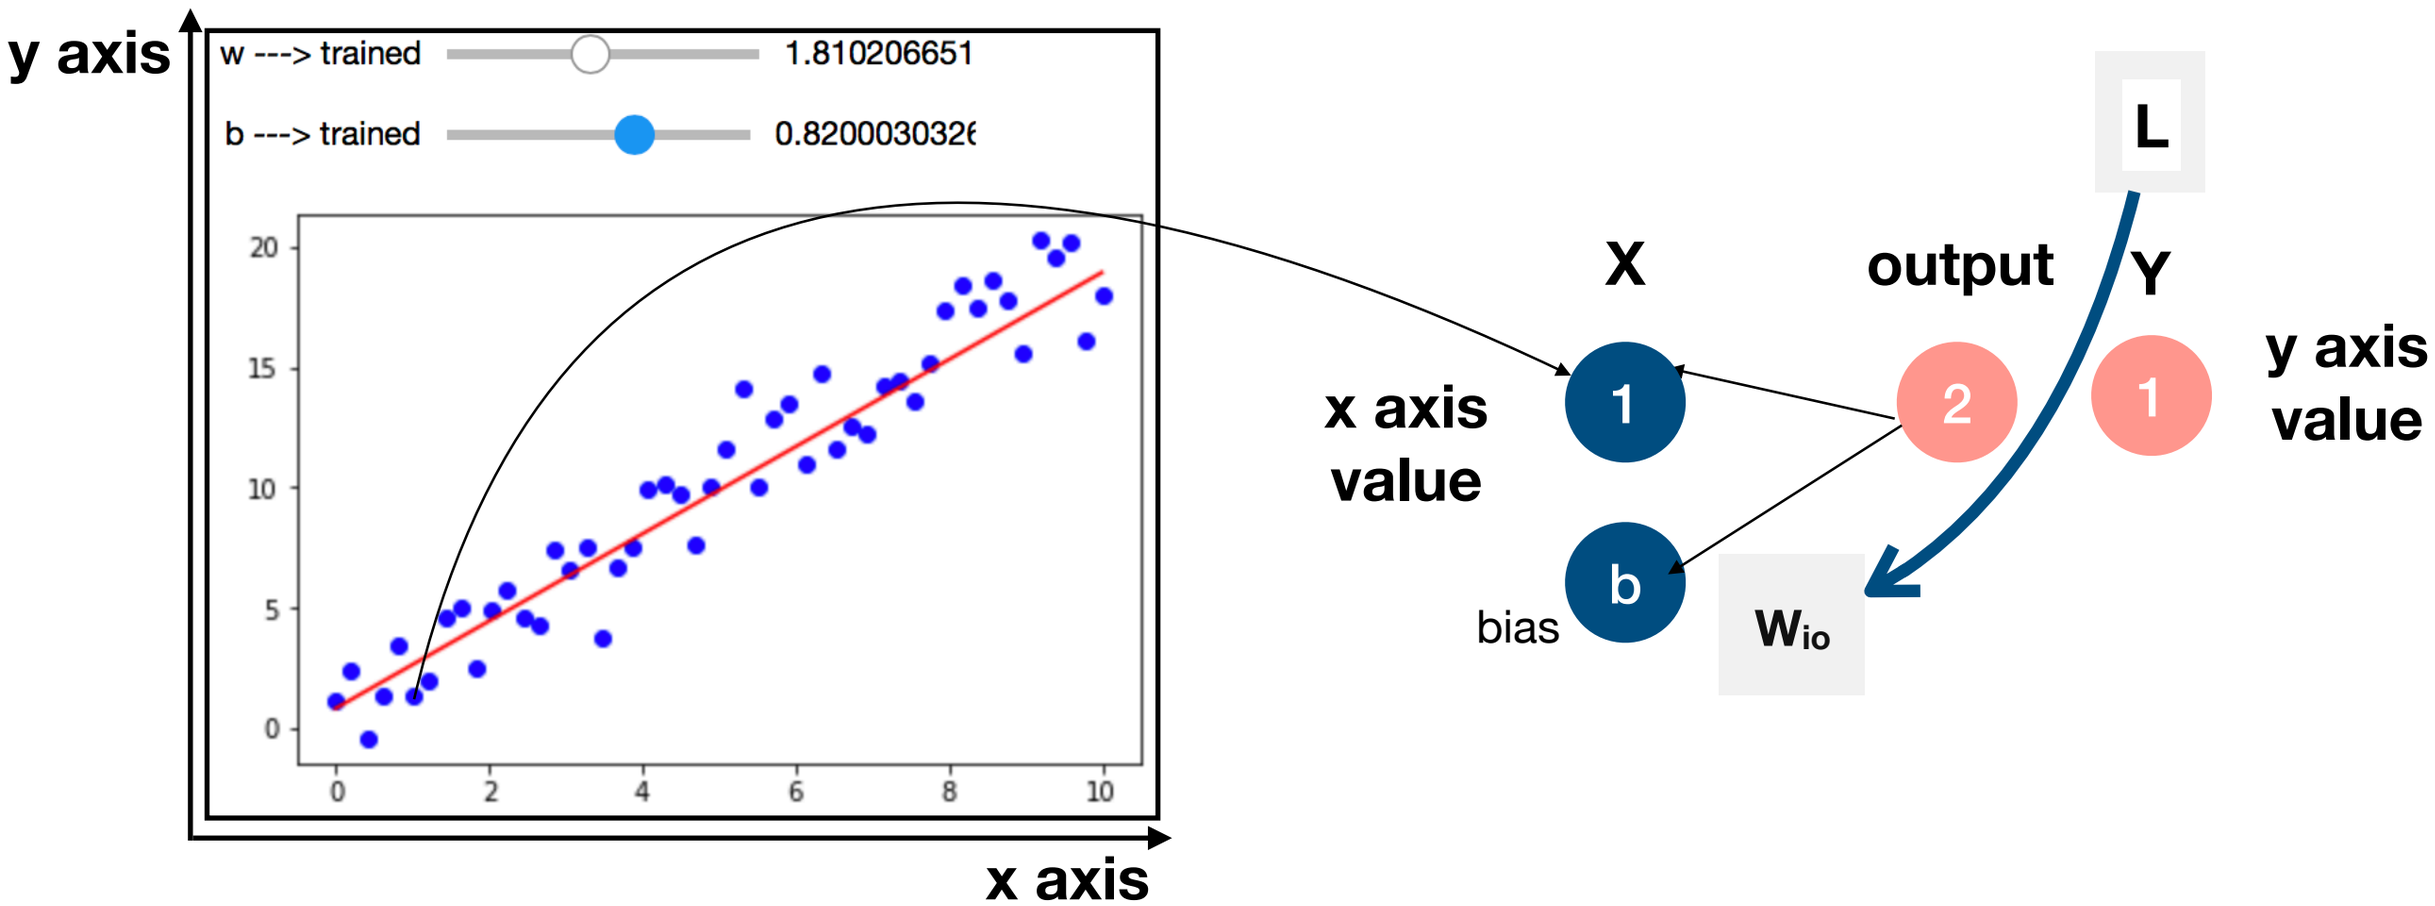

loss를 최소화하는 방향으로, weight을 update 합니다.

Logistic Regression

Logistic Regression

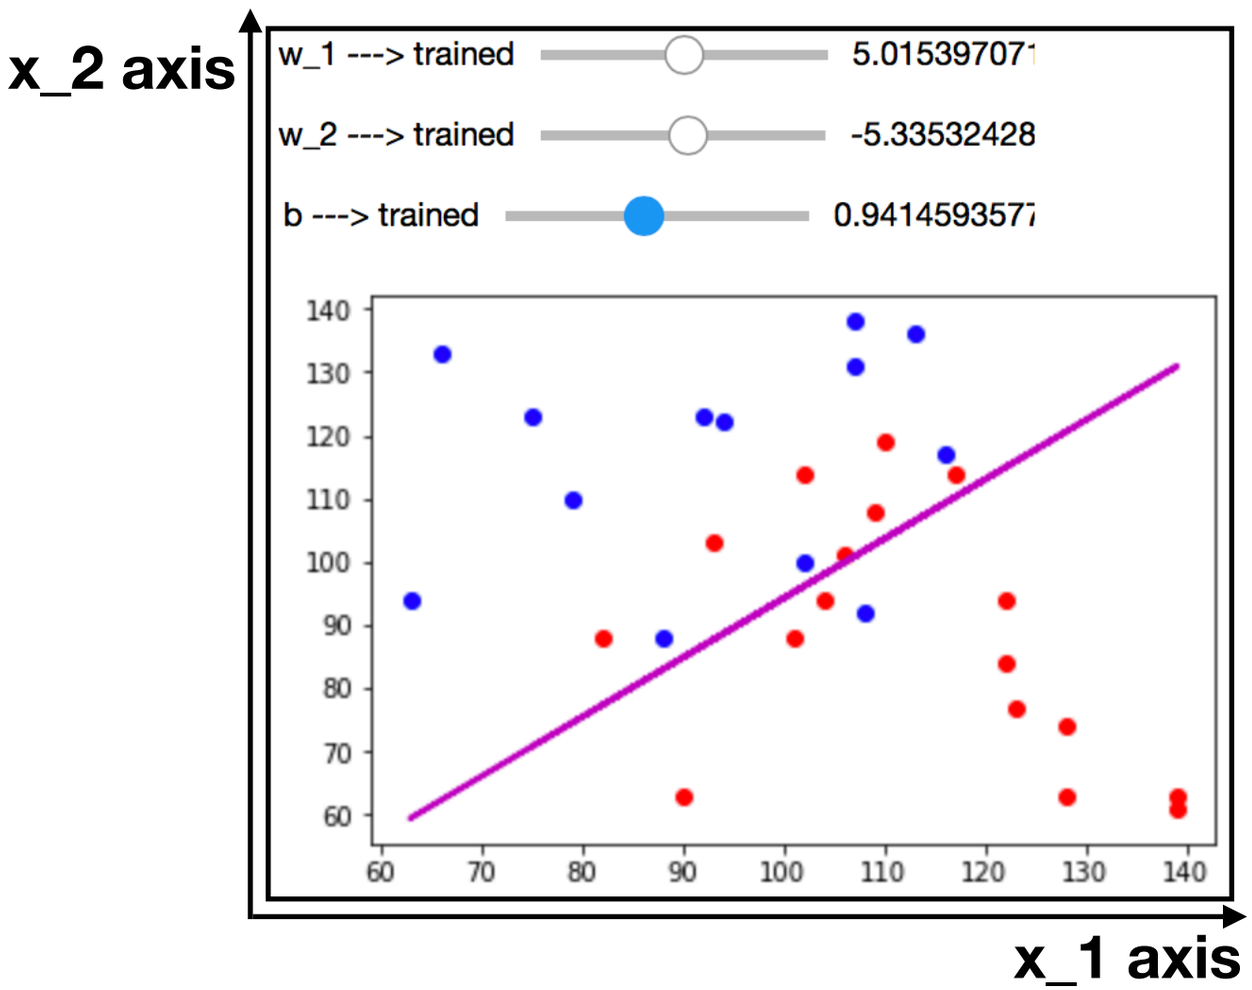

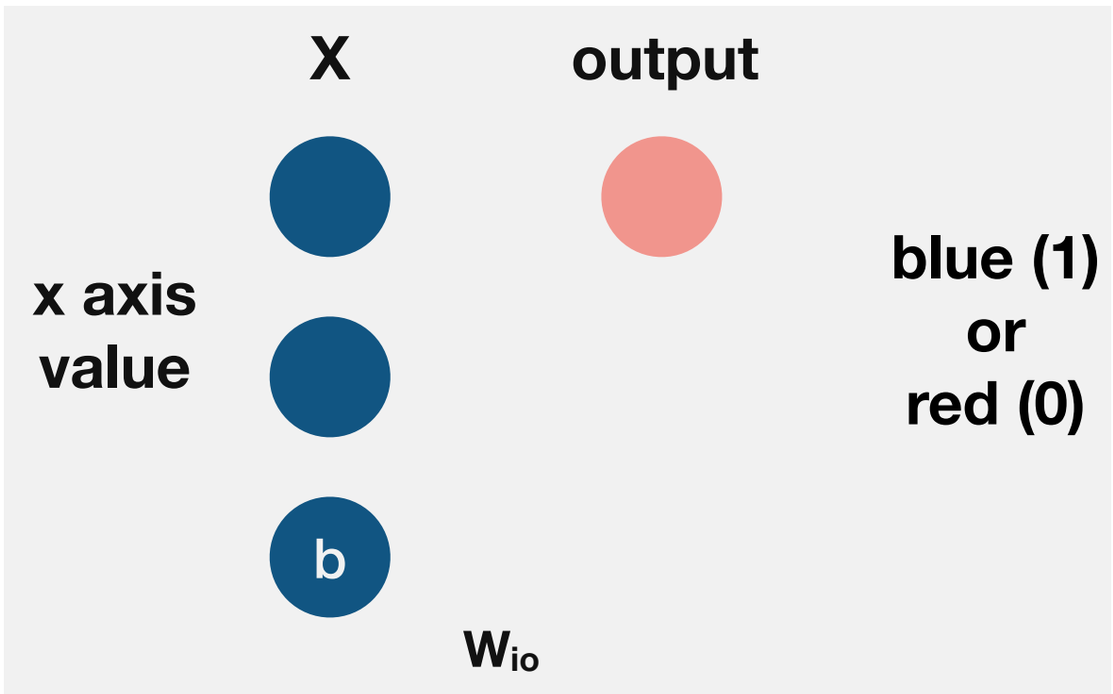

perceptrons를 이용한 logistic regression graphical model

Logistic Regression

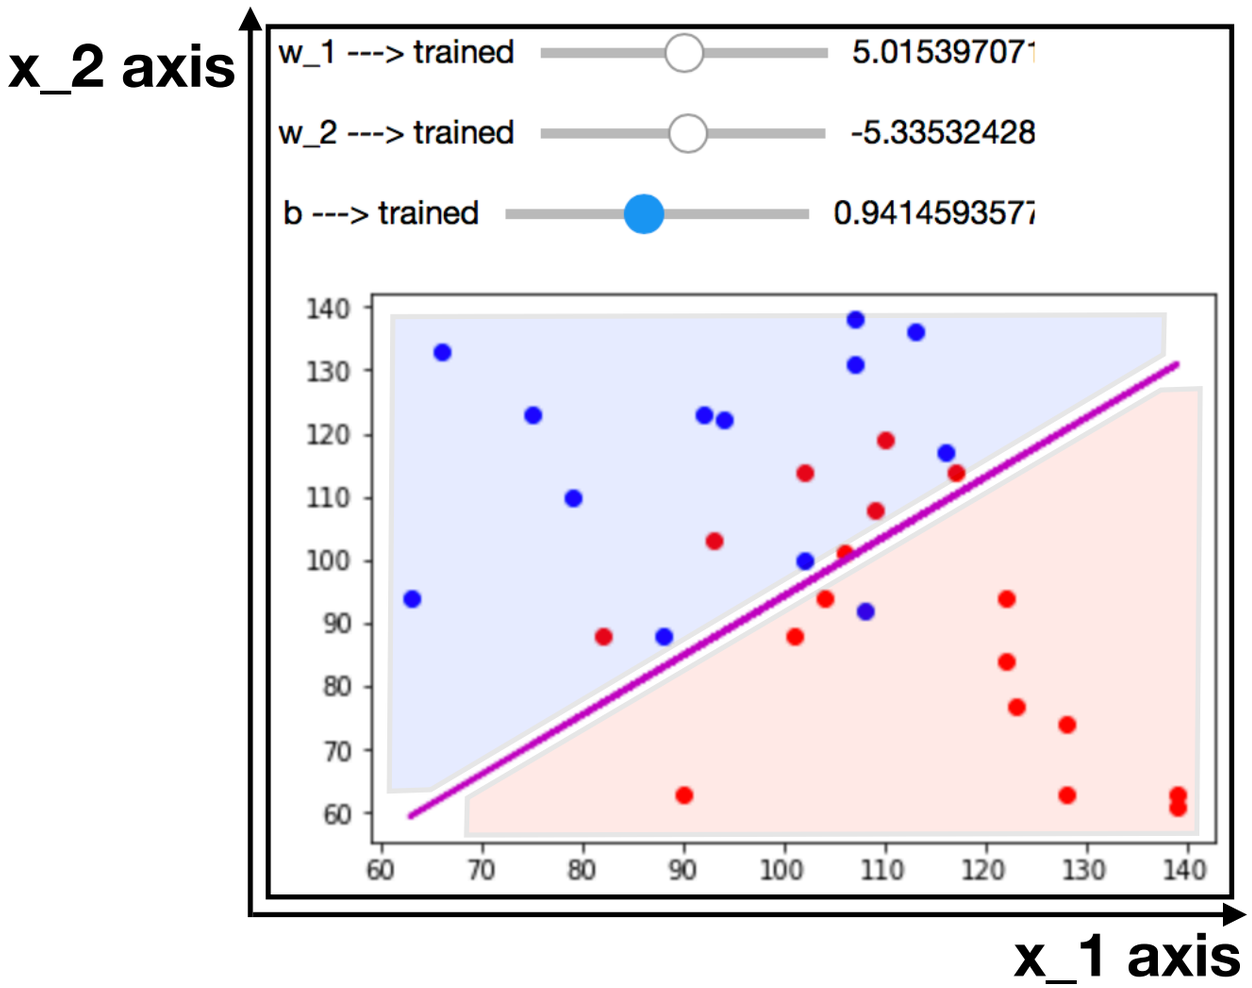

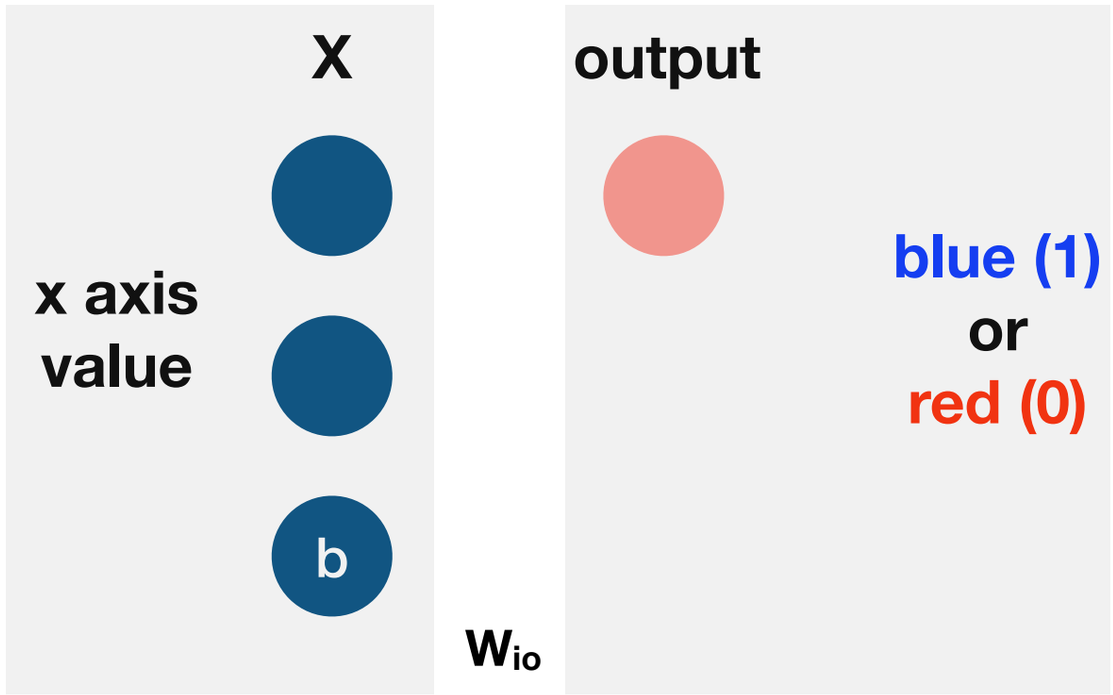

logistic regression의 예시
input: 데이터 포인트의 x_1 axis value, x_2 axis value
target: 데이터 포인트의 색깔, 파랑이면 1, 빨강이면 0
output: 선홍색 선형 모델을 기준으로 판별한 데이터 포인트의 색깔, 위는 파랑 1, 아래는 빨강 0
목적: 데이터를 가장 잘 구분하는 선형 모델을 그리는 것

Logistic Regression

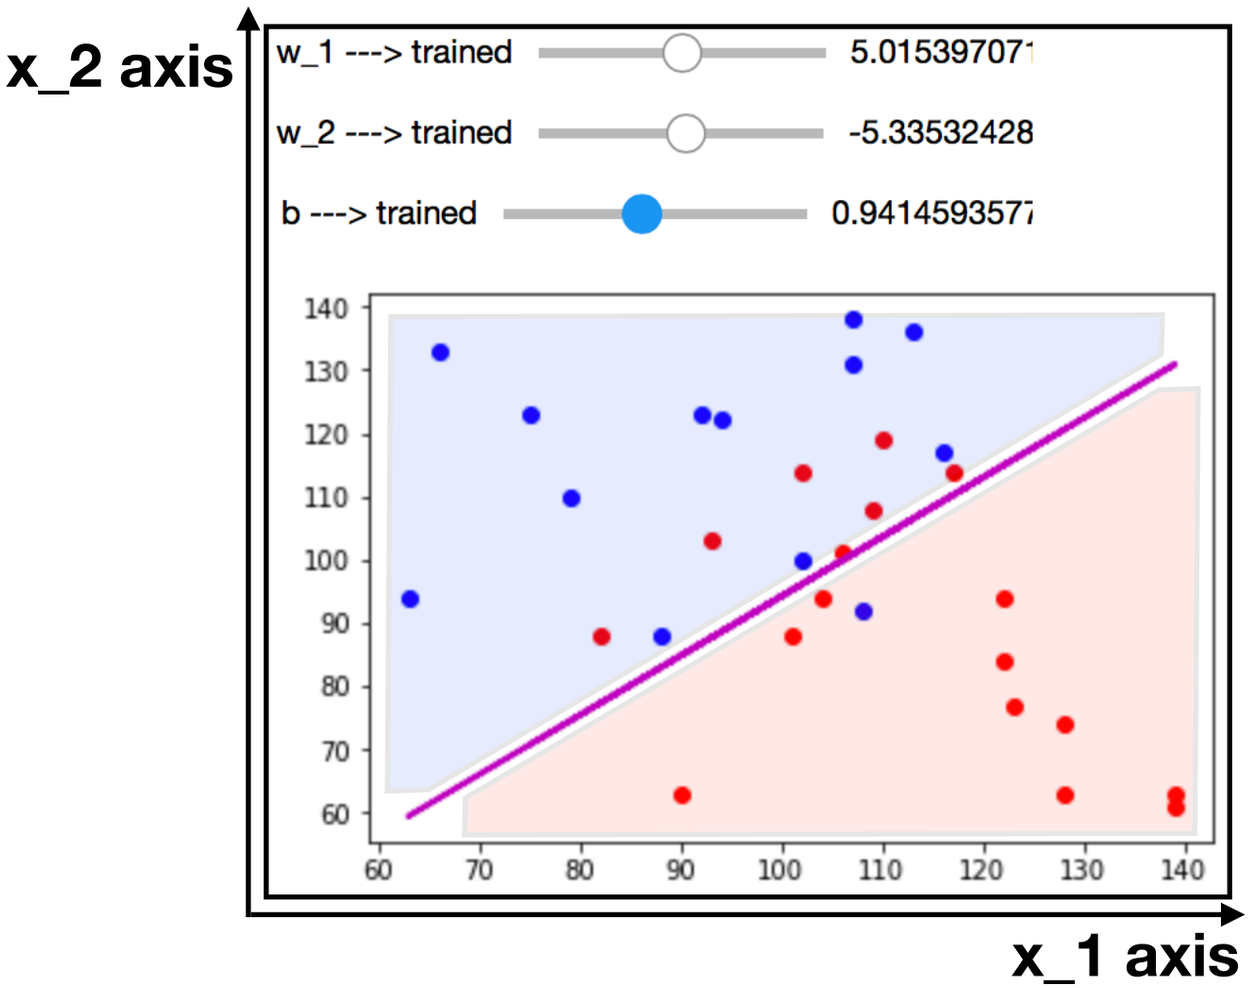

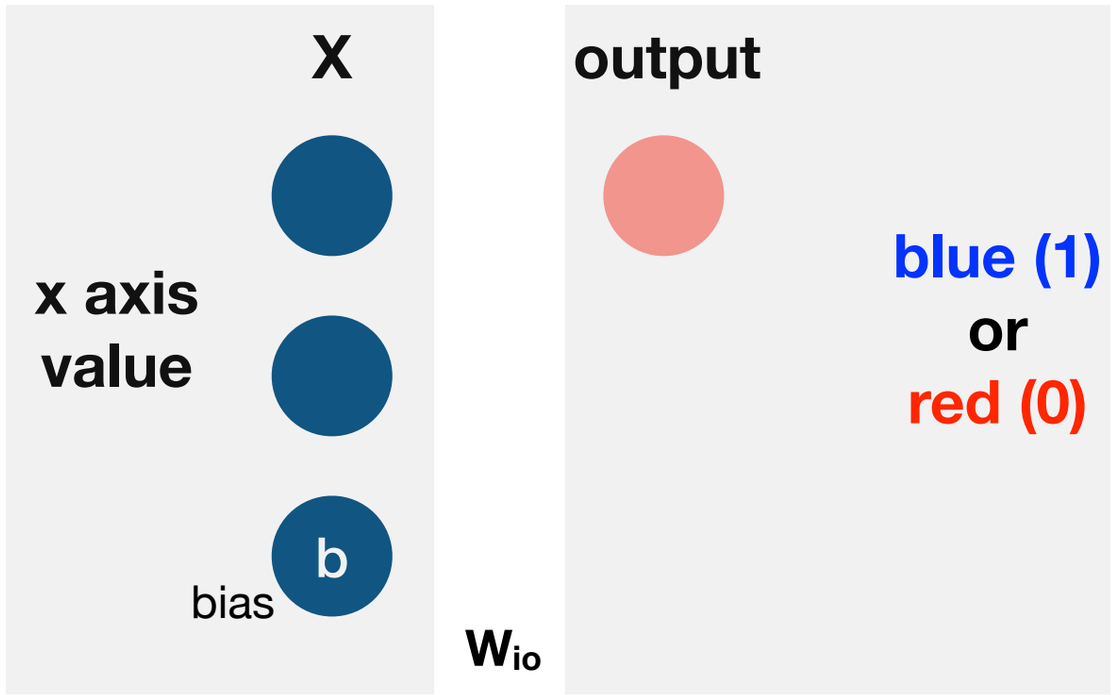

모델구조:

input layer (2 nodes),
output layer (1 node)
노드 숫자를 셀 때 bias node는 제외

Logistic Regression

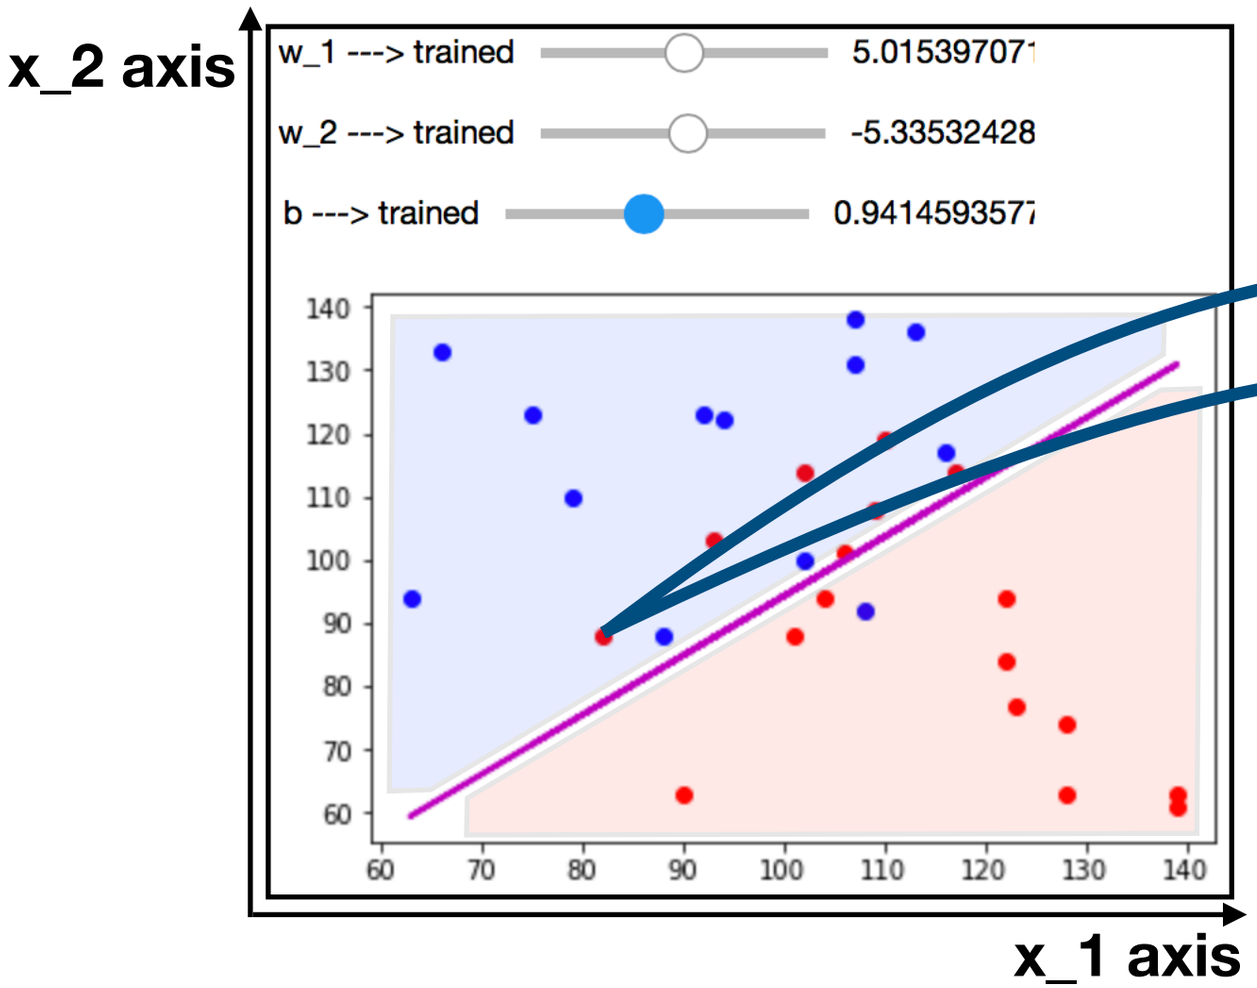

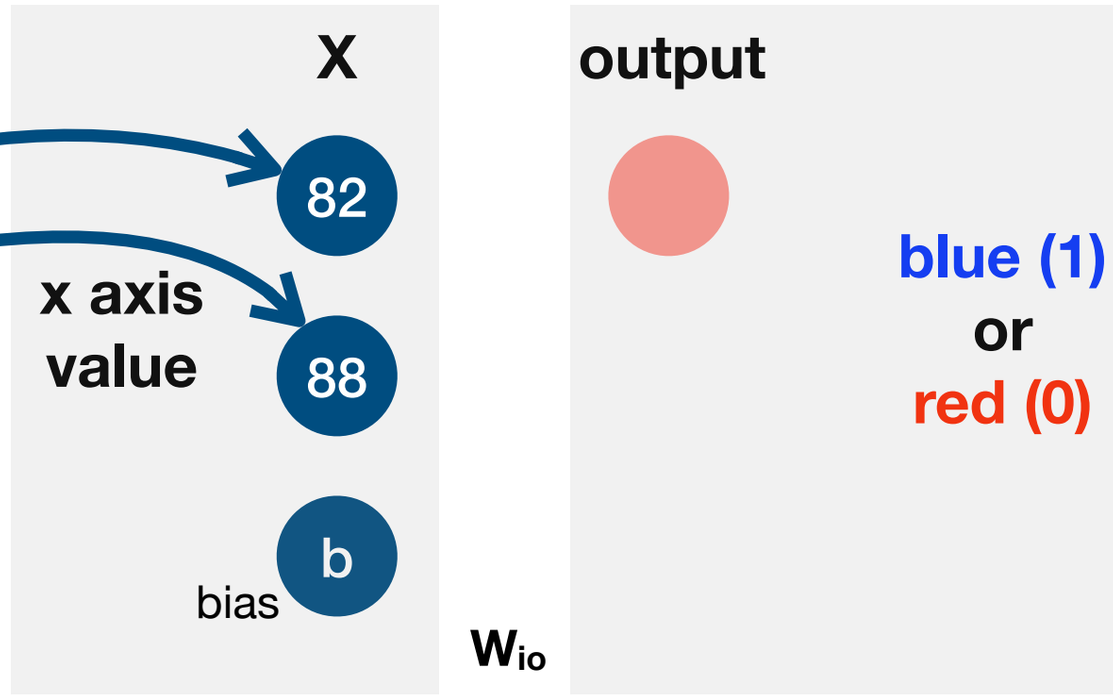

훈련:
데이터 포인트의 x_1 axis value와 x_2 axis value를 input layer의 nodes에 각각 넣어줍니다.

Logistic Regression

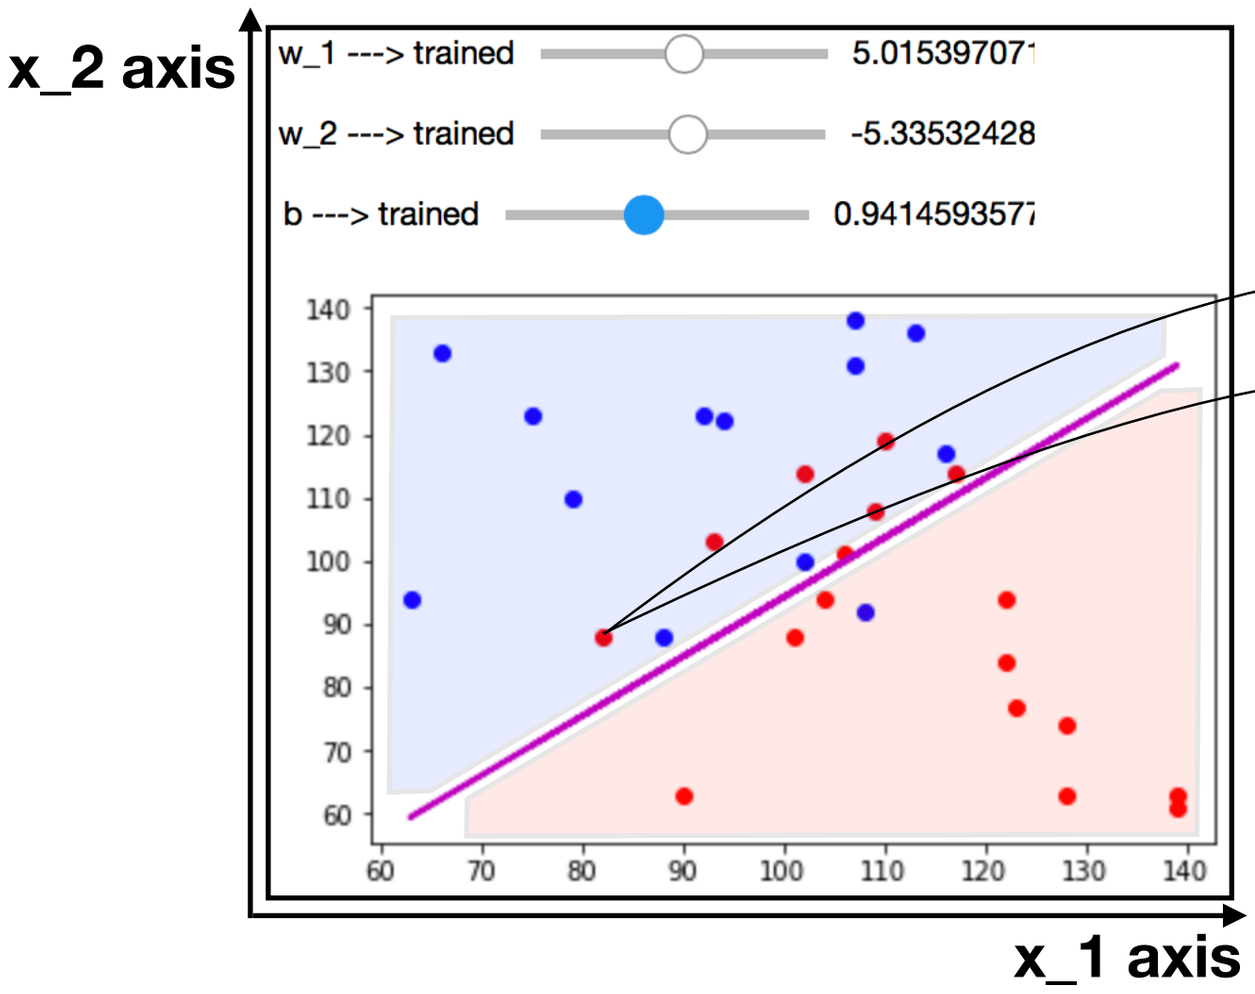

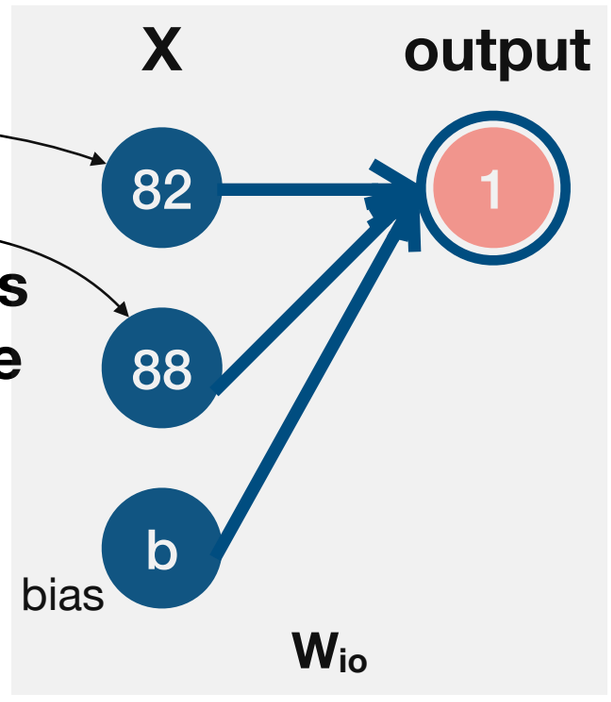

blue (1)
or
red (0)

각 input layer의 node 값에 weight (진한 화살표)을 곱하고,
곱한 값을 모두 더해 output layer node에 넣어줍니다.

Logistic Regression

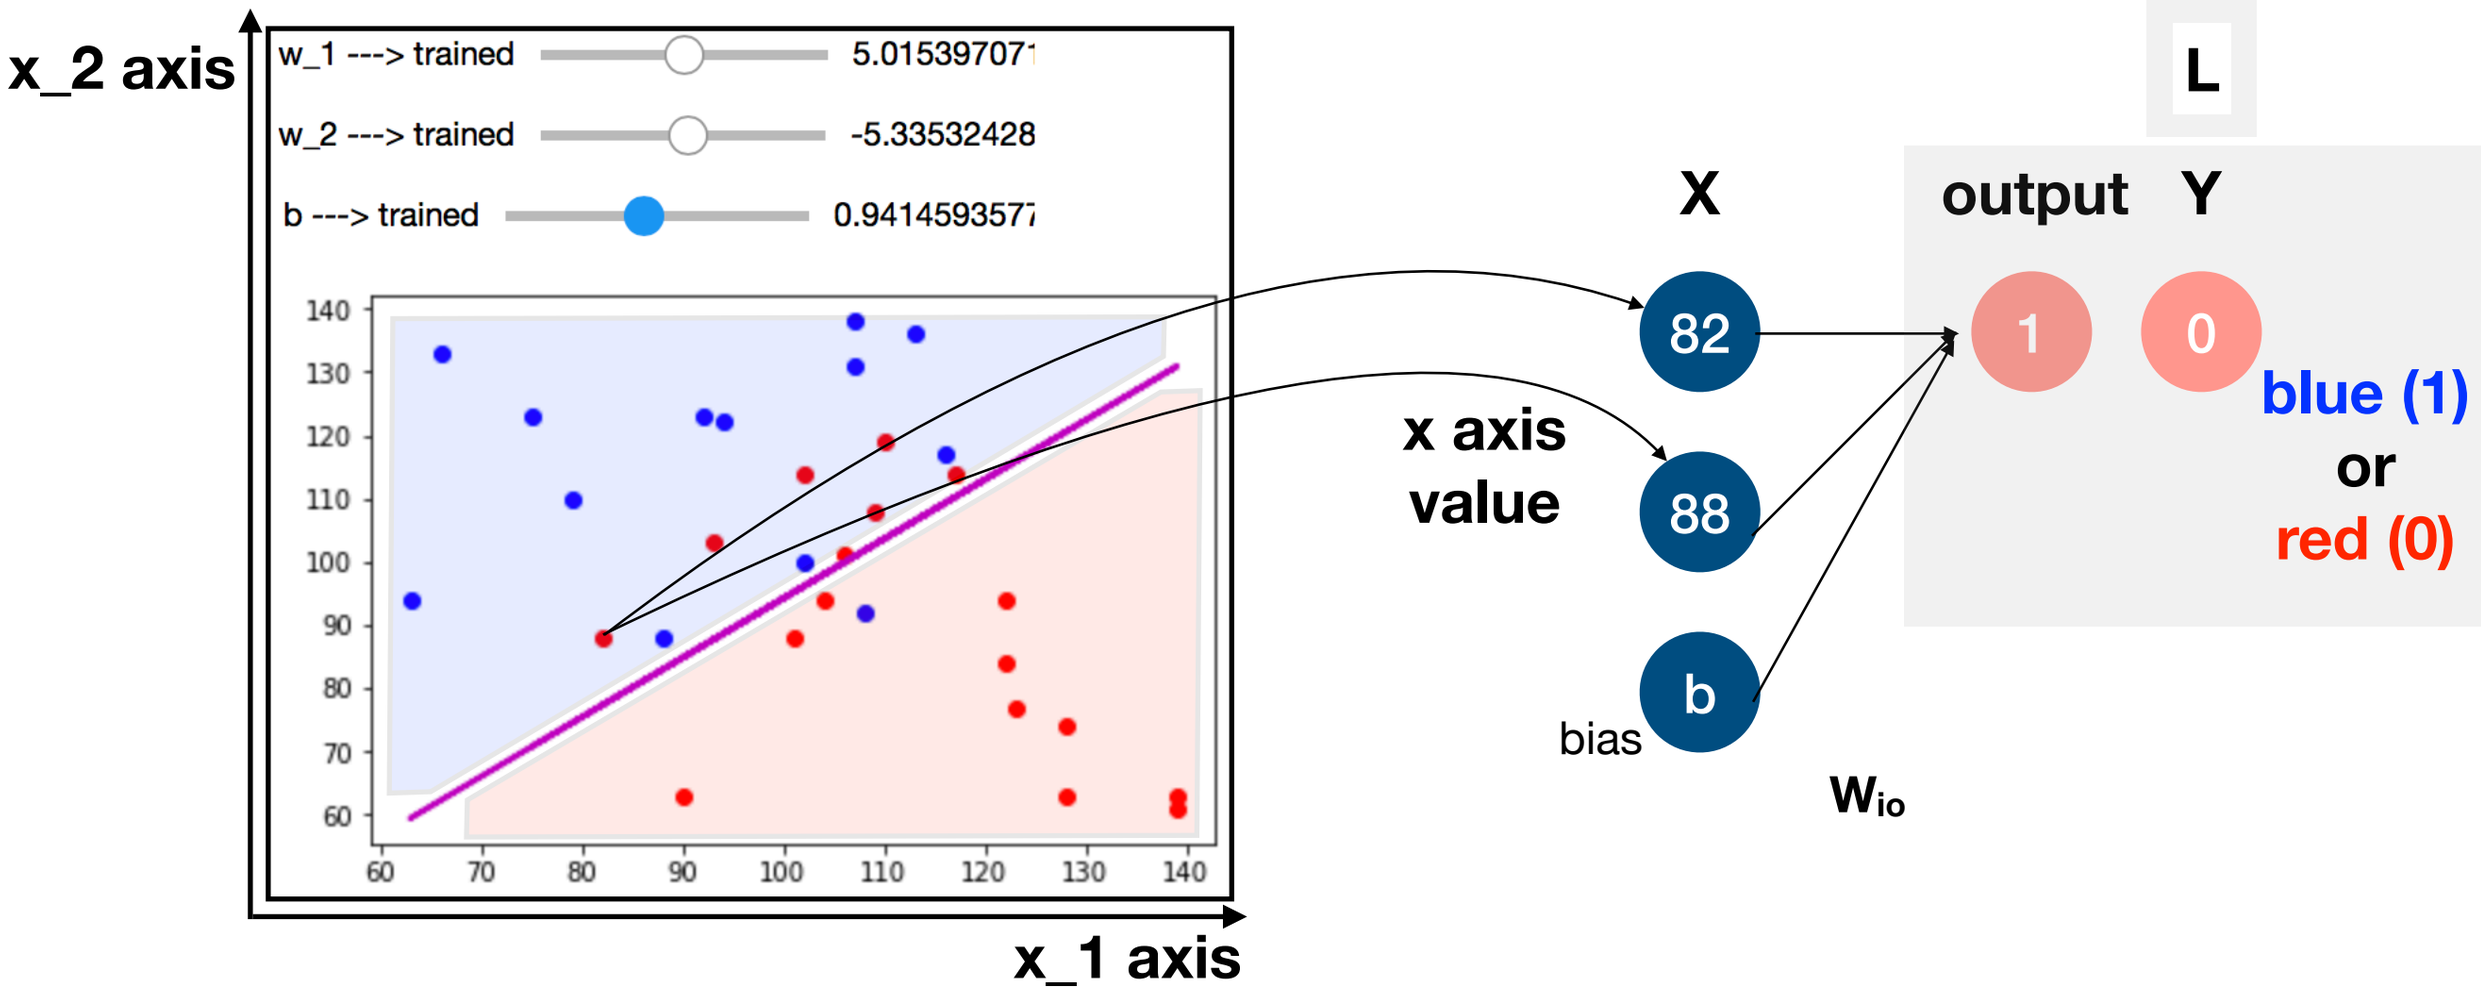

그렇게 구한 output과 정답 target (Y)을 비교하여 loss를 구합니다.

Logistic Regression

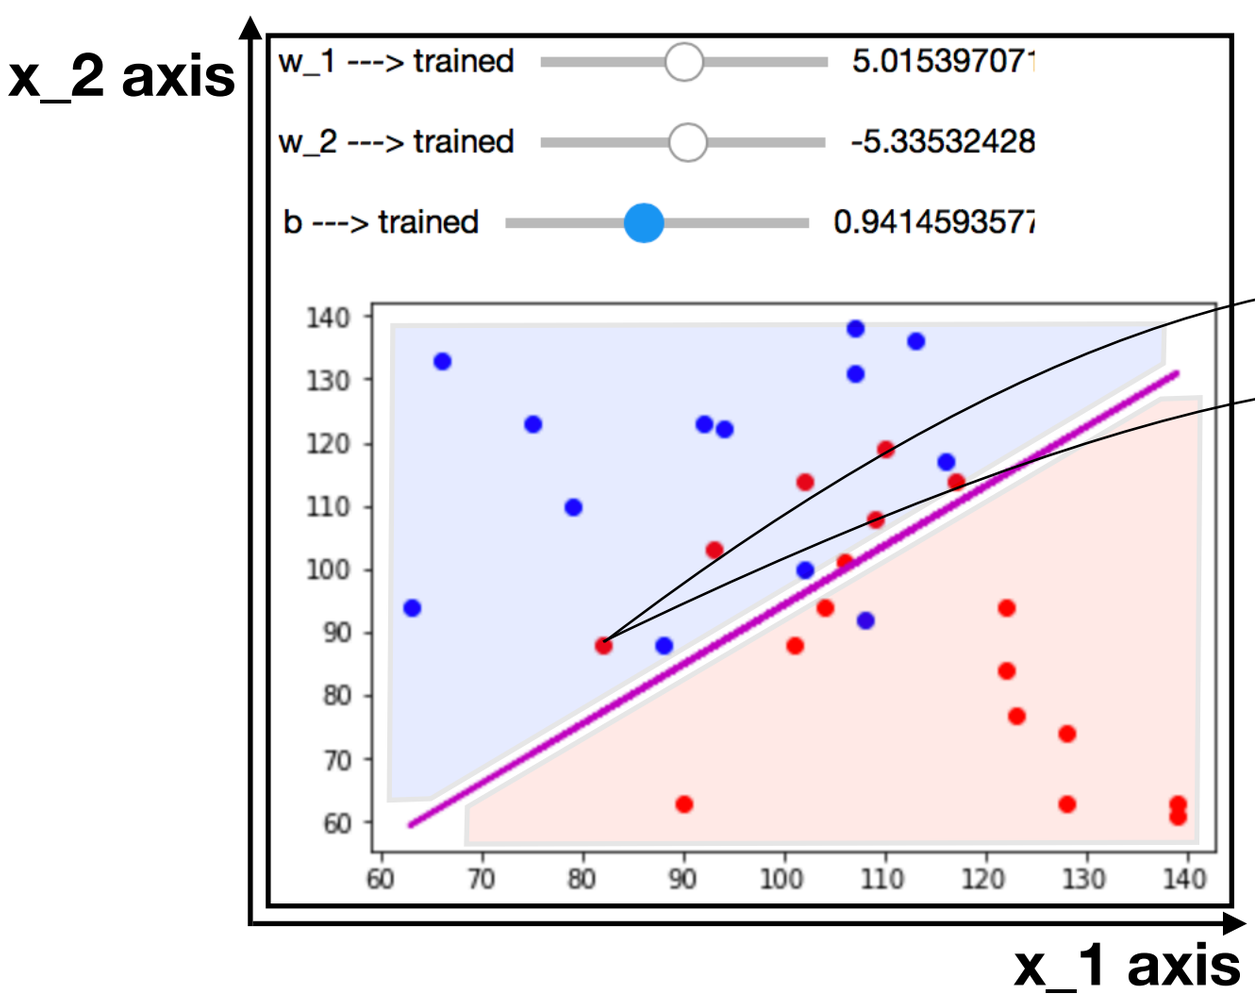

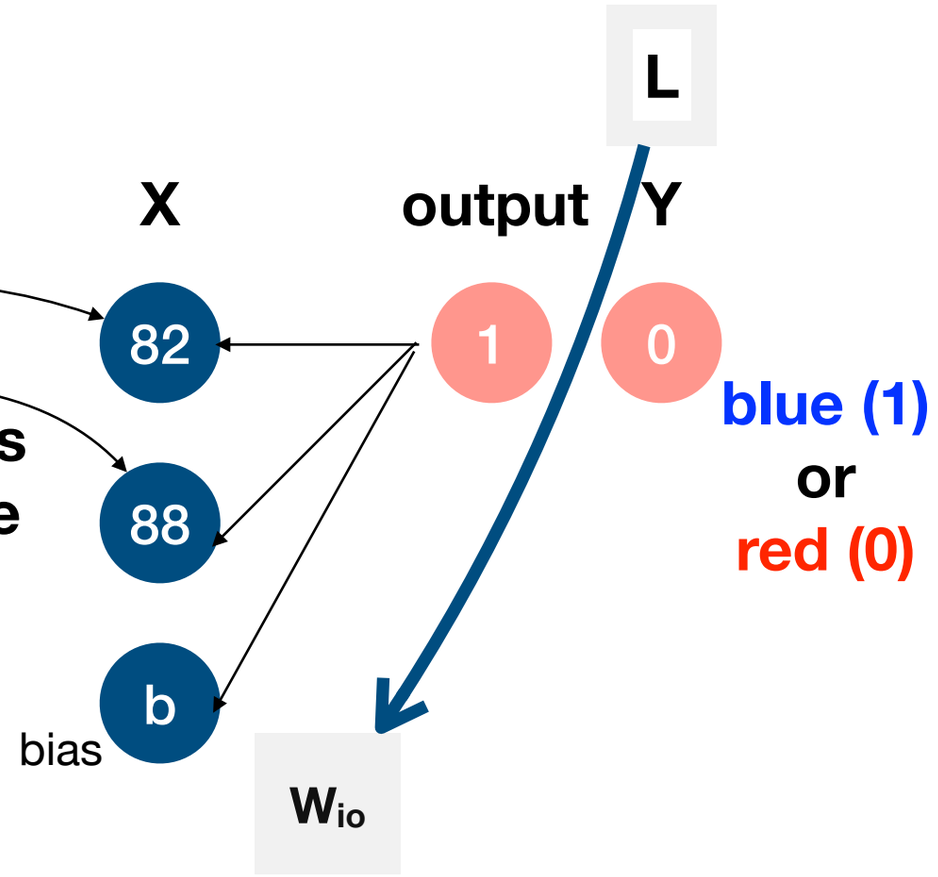

loss를 최소화하는 방향으로, weight을 update 합니다.

ANN / DNN

ANN DNN

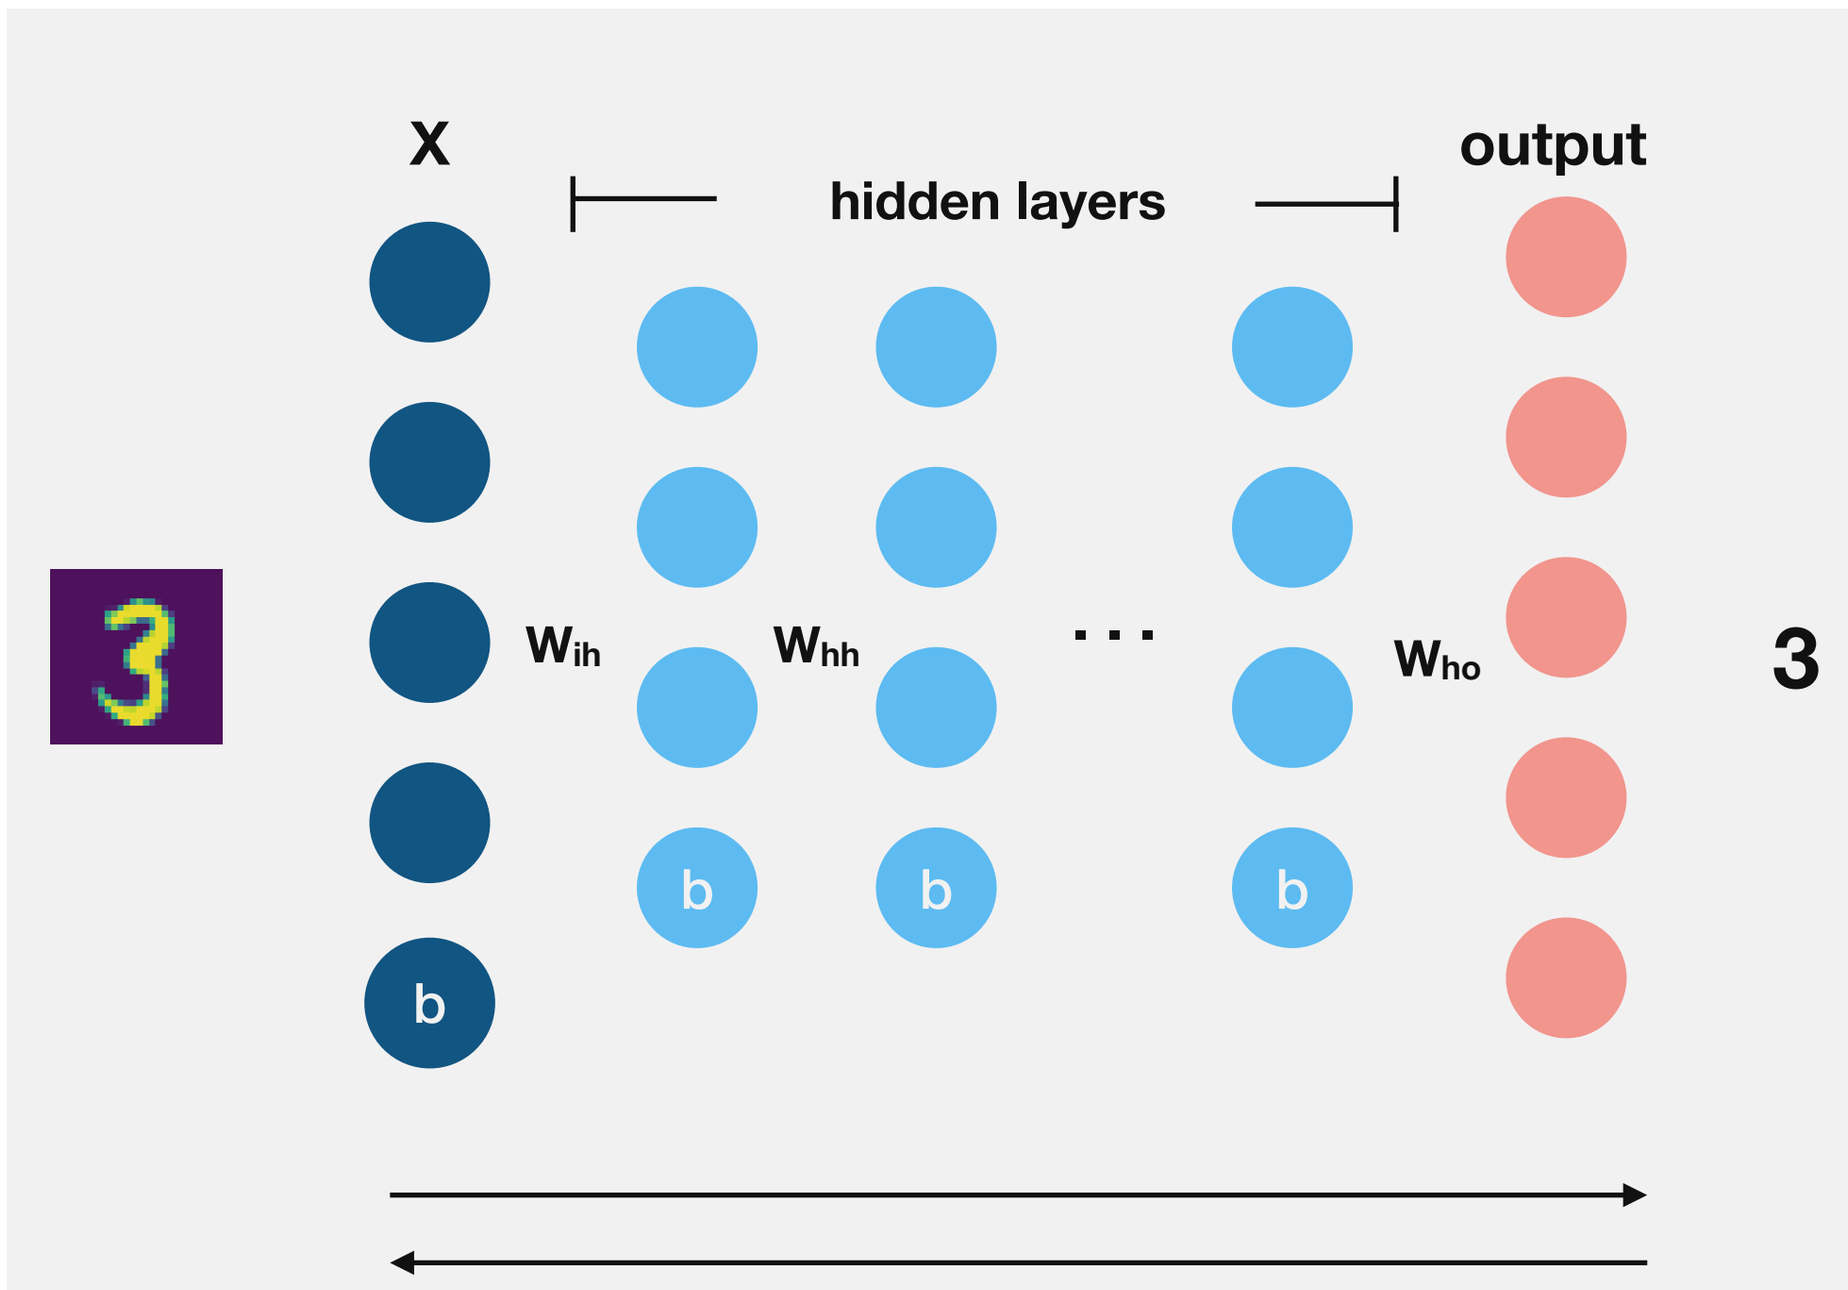

perceptrons를 이용한 ANN/DNN classifier graphical model

ANN DNN

5

5

x

b

input nodes
= 25

hidden_1

b

hidden nodes
= 3

W_{ih}

hidden_2

b

hidden nodes
= 3

W_{hh}

W_{ho}

output

3

output nodes
= 10

ANN/DNN classifier의 예시
input: 5 by 5의 이미지(X)
target: 0에서 9까지의 라벨(Y)
목적: input이 0~9 중 어떤 숫자인지 분류

ANN DNN

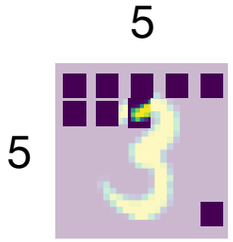

5

5

x

0.1

0.3

0.8

⋮

0.2

bias b

input nodes
= 25

hidden_1

hidden_2

b bias

b bias

hidden nodes
= 3

hidden nodes
= 3

W_{ih} W_{hh} W_{ho}

output

⋮

output nodes
= 10

모델구조:
input layer (25 nodes),
2 hidden layers (3 nodes each),
output layer (10 nodes)
노드 숫자를 셀 때 bias node는 제외

ANN DNN

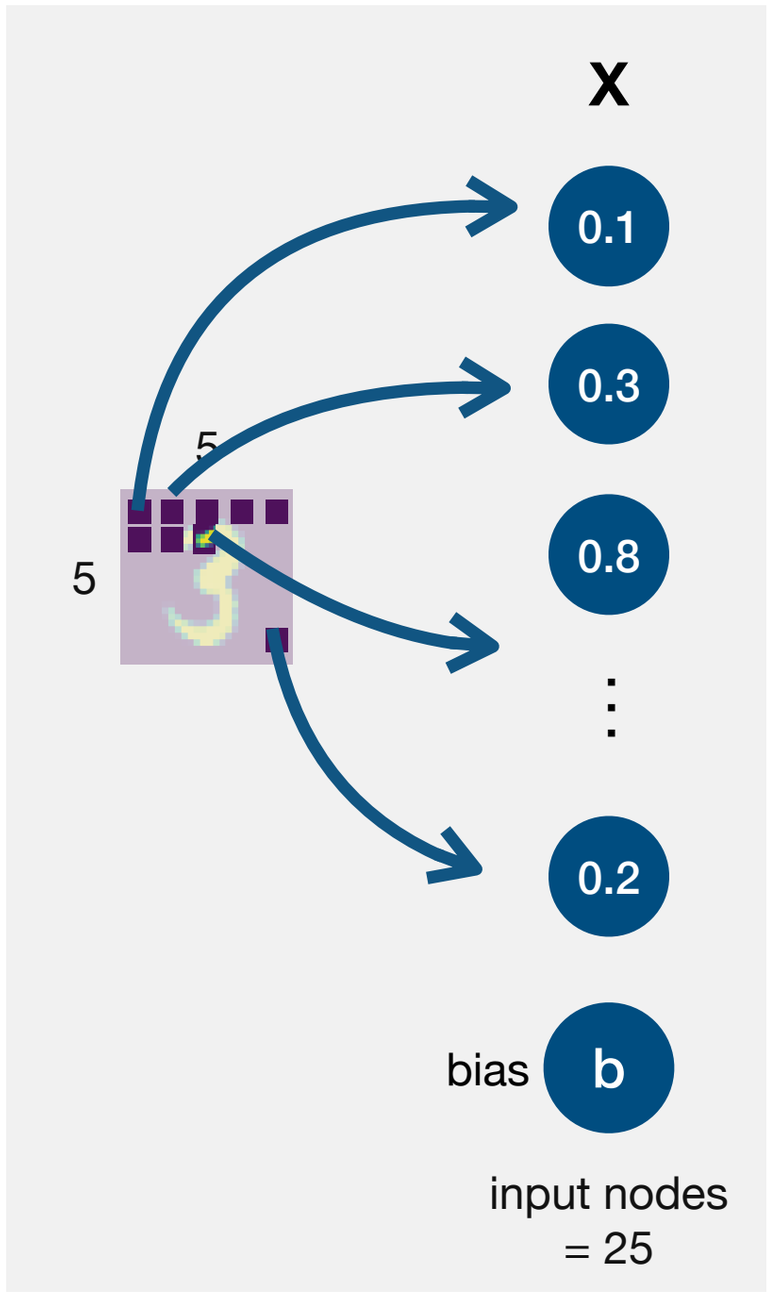

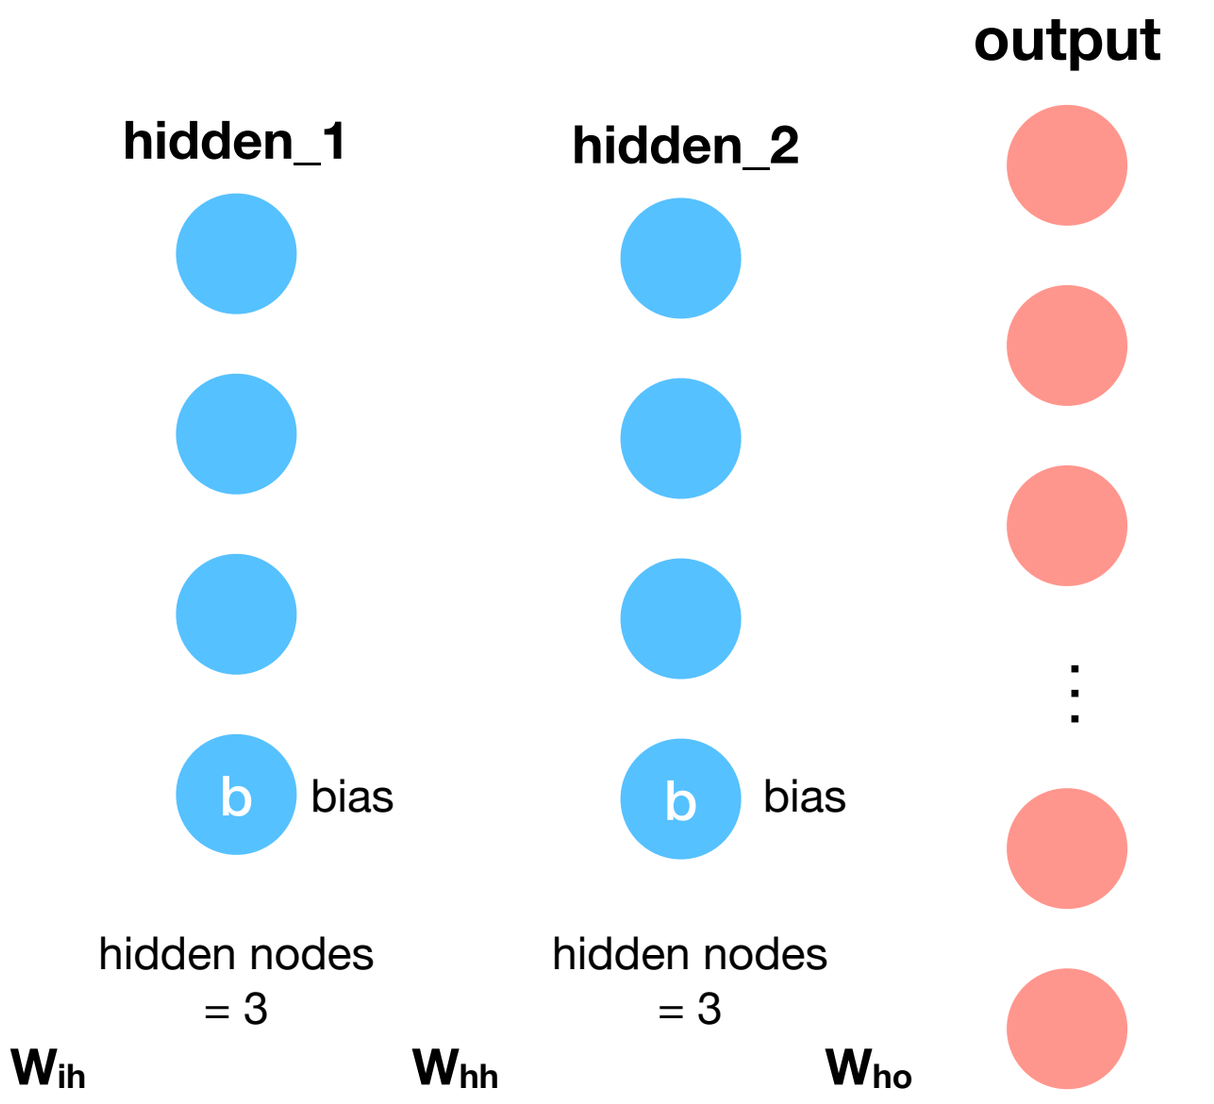

3

훈련:
이미지를 pixel 단위로 쪼개서
그 값을 각각 input layer의 nodes에 넣어줍니다.

ANN DNN

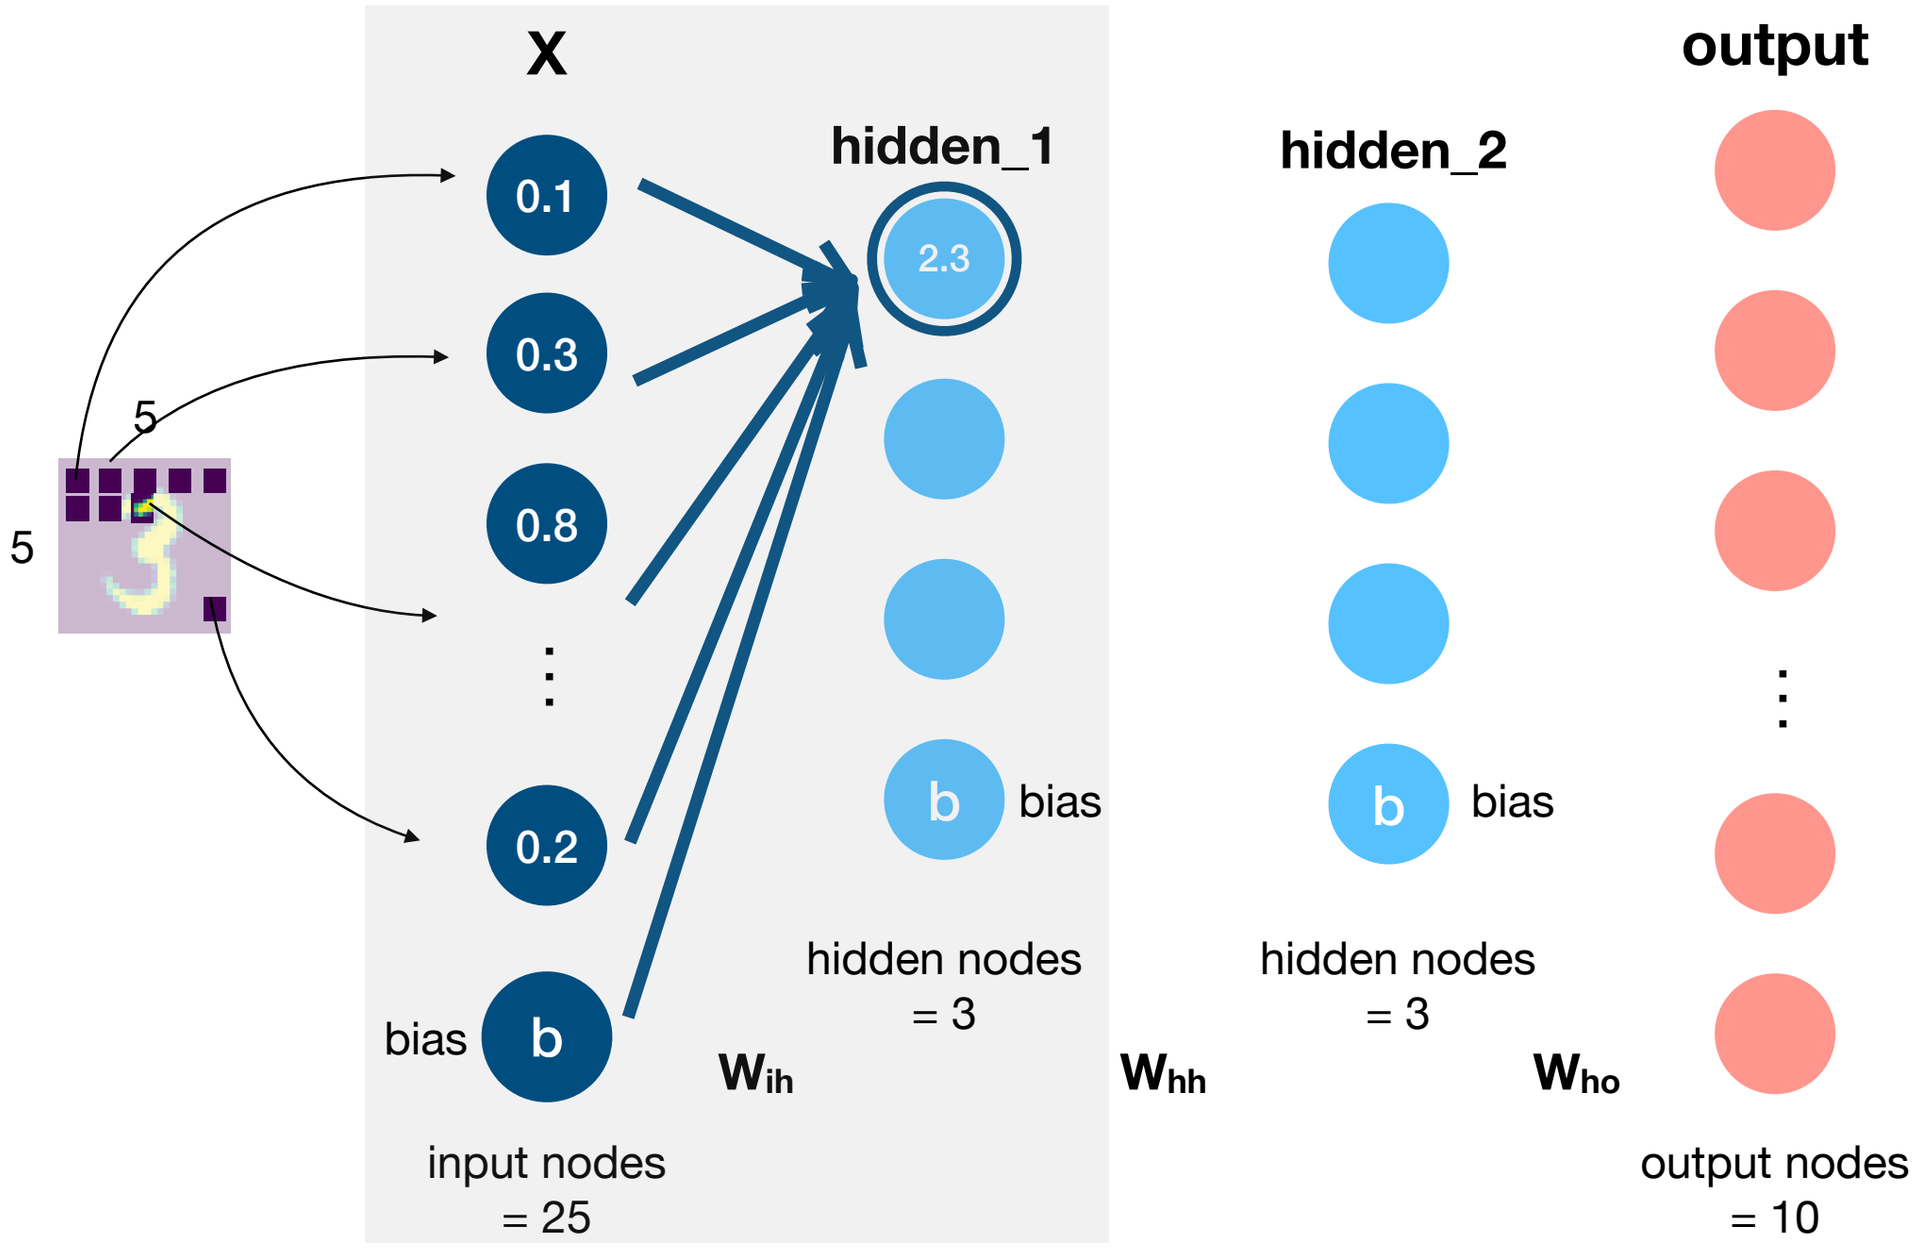

각 input layer의 node 값에 weight (진한 화살표)을 곱하고,
곱한 값을 모두 더해 첫 번째 hidden layer node에 넣어줍니다.

ANN DNN

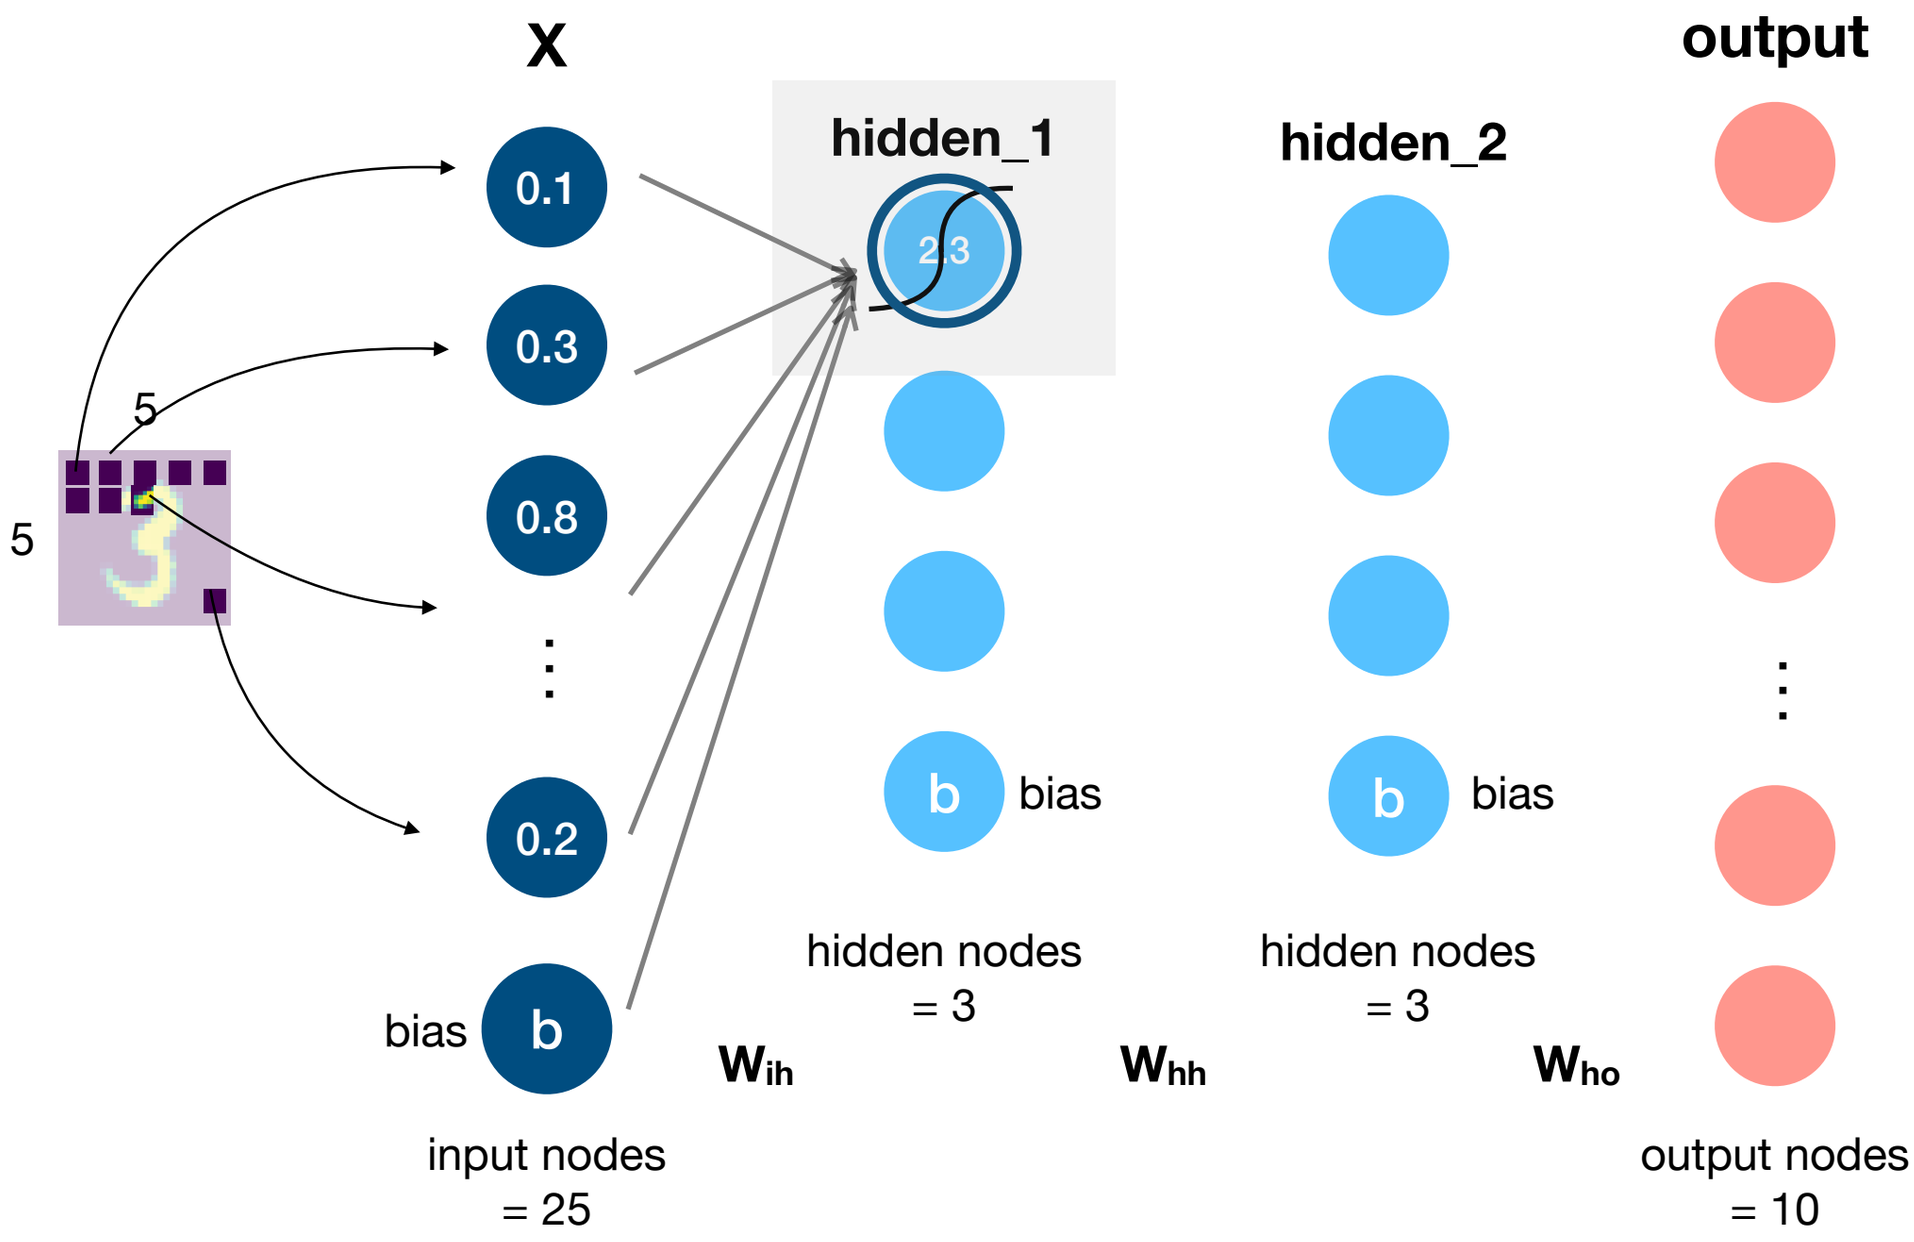

activation function을 통해서 node 값을
0과 1 사이의 값(sigmoid function)으로 바꿔줍니다.

ANN DNN

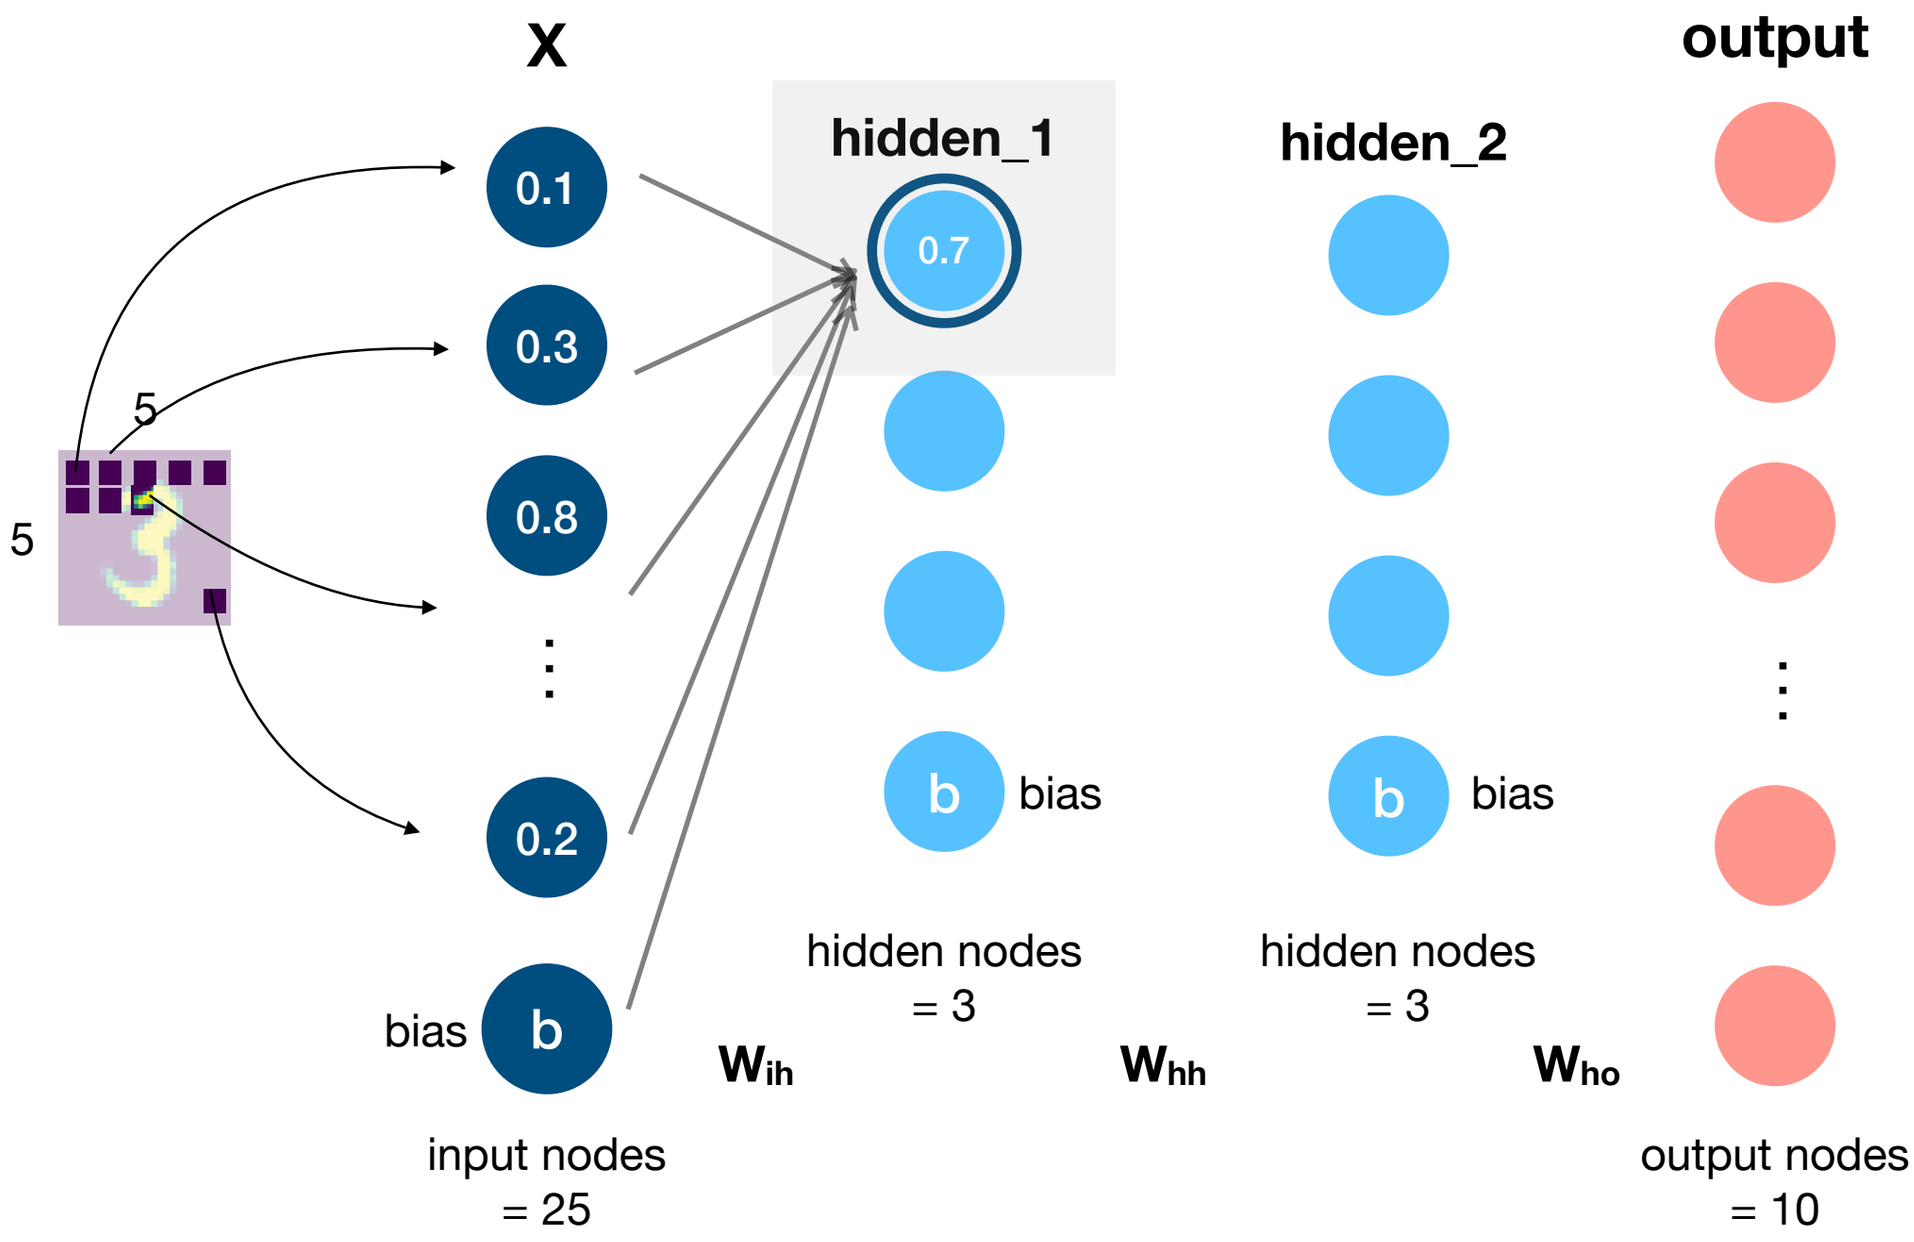

activation function을 통해서 node 값을
0과 1 사이의 값(sigmoid function)으로 바꿔줍니다.

ANN DNN

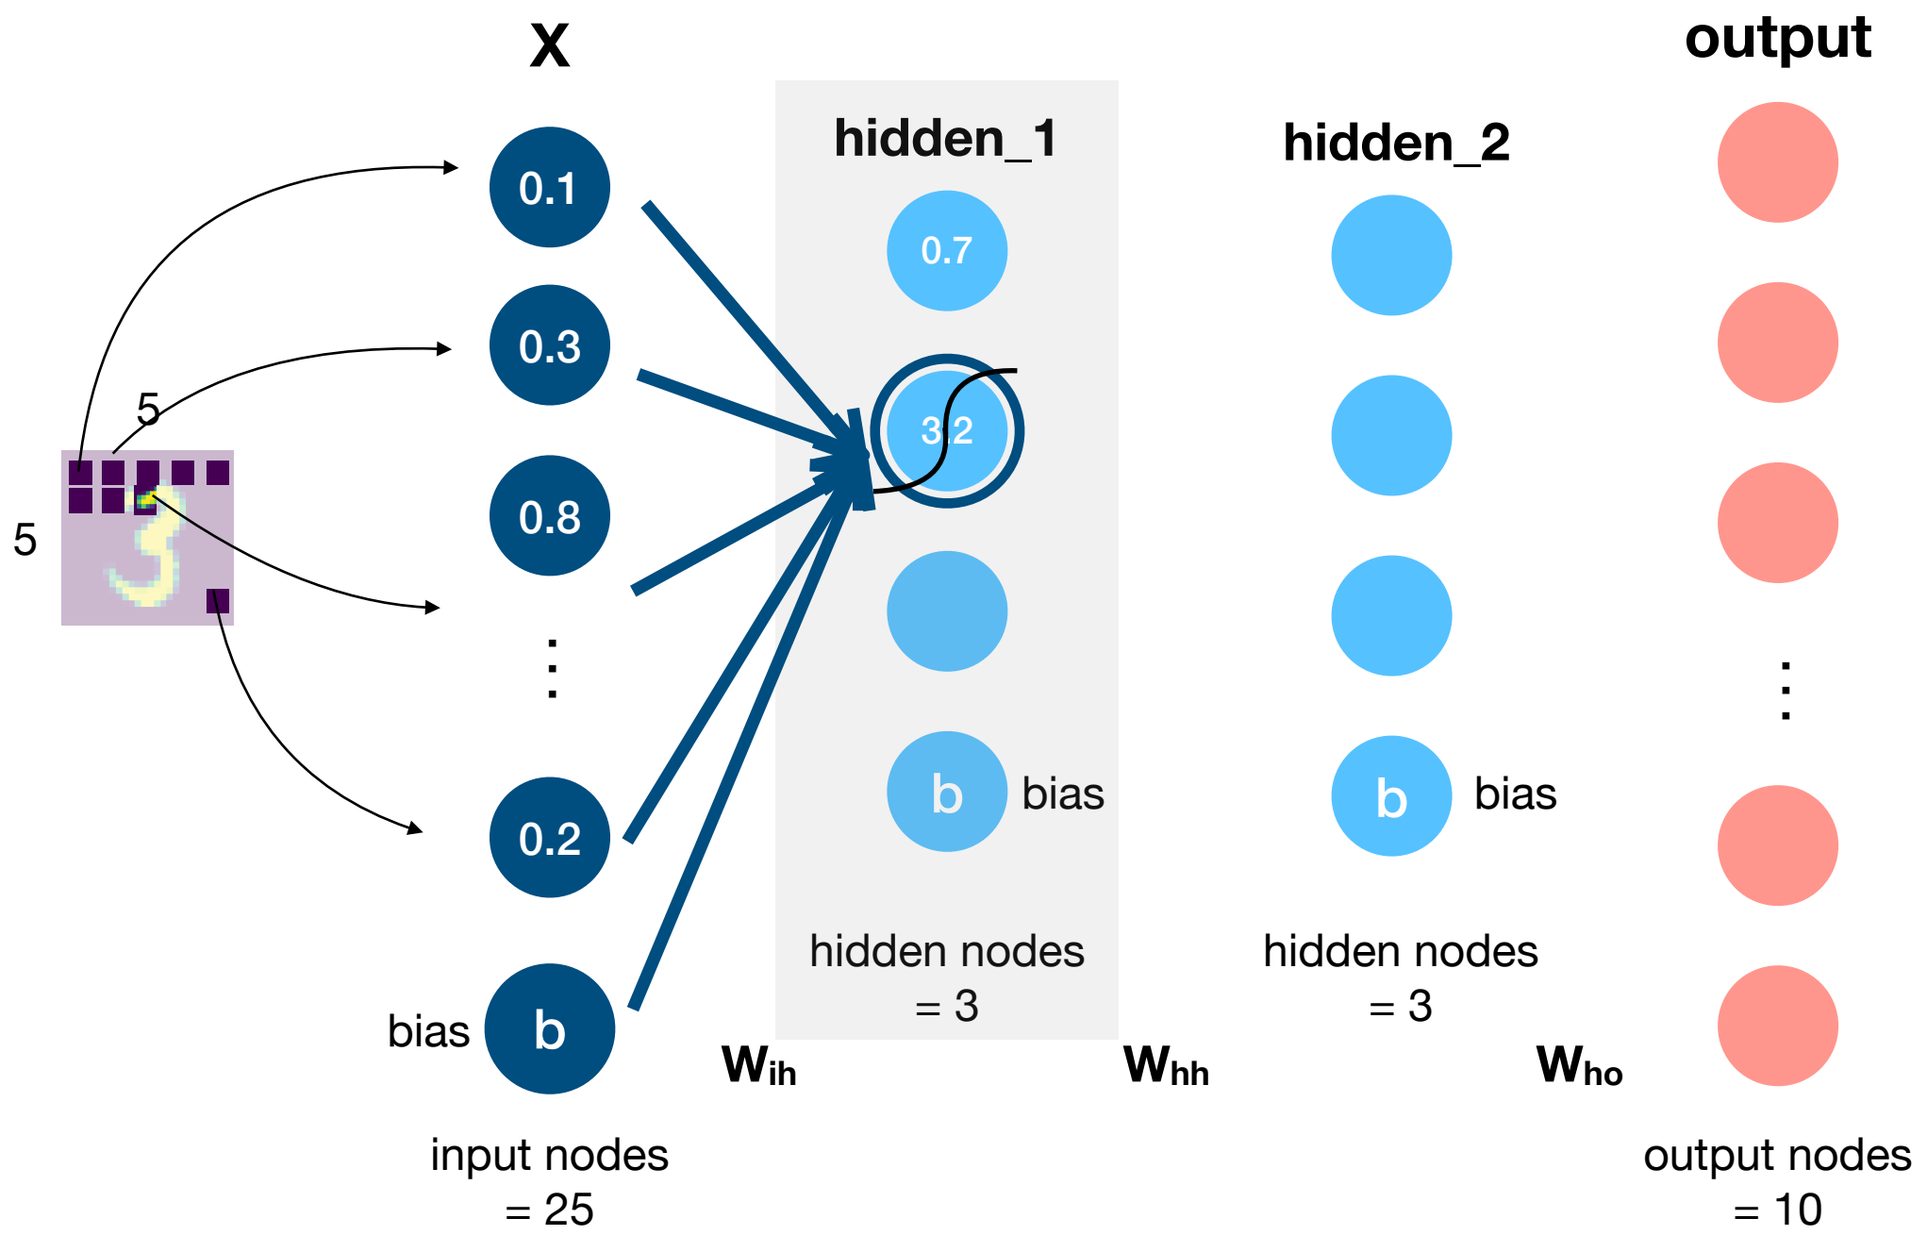

모든 hidden layer 1의 nodes에 대해 반복합니다.

ANN DNN

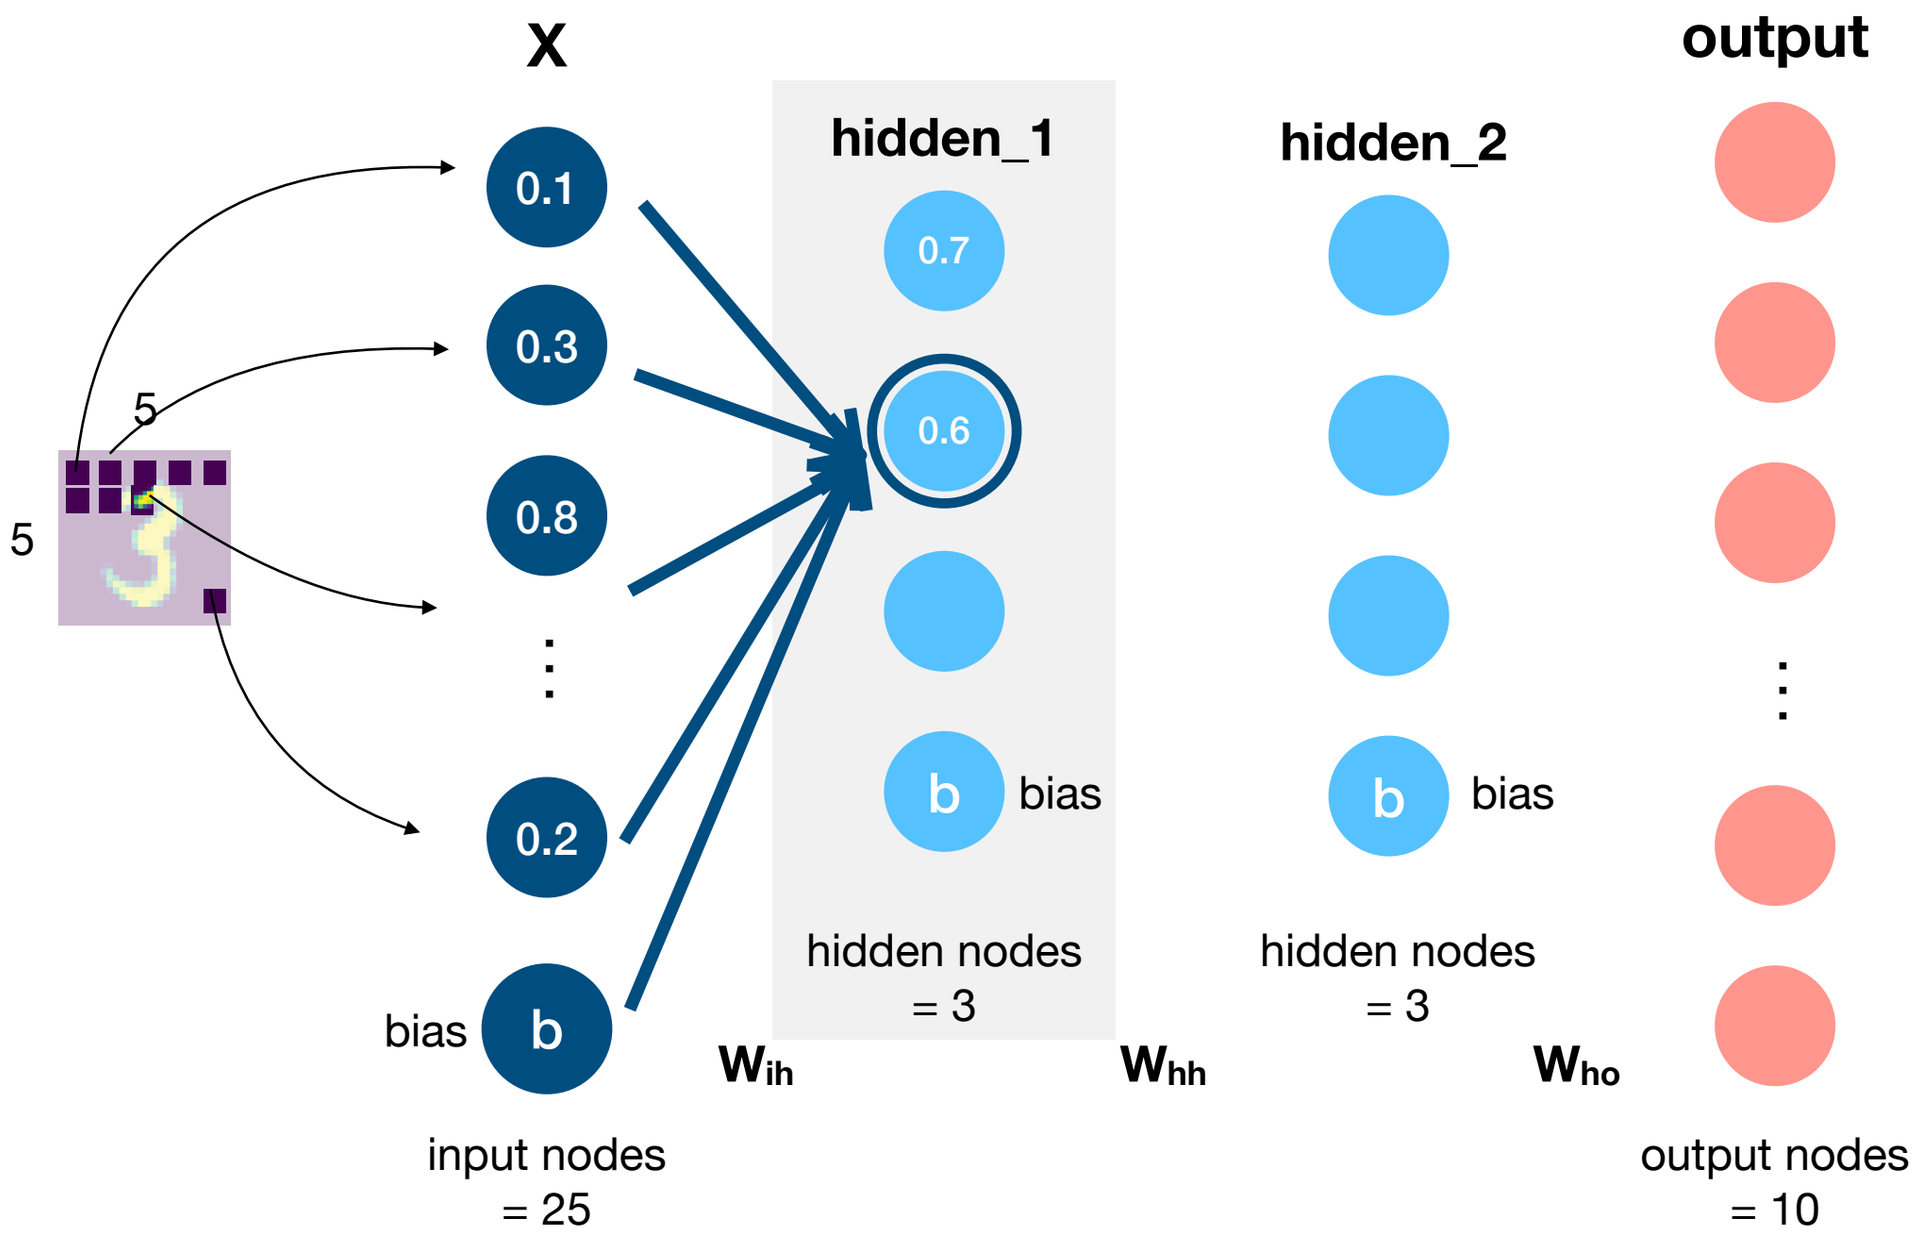

모든 hidden layer 1의 nodes에 대해 반복합니다.

ANN DNN

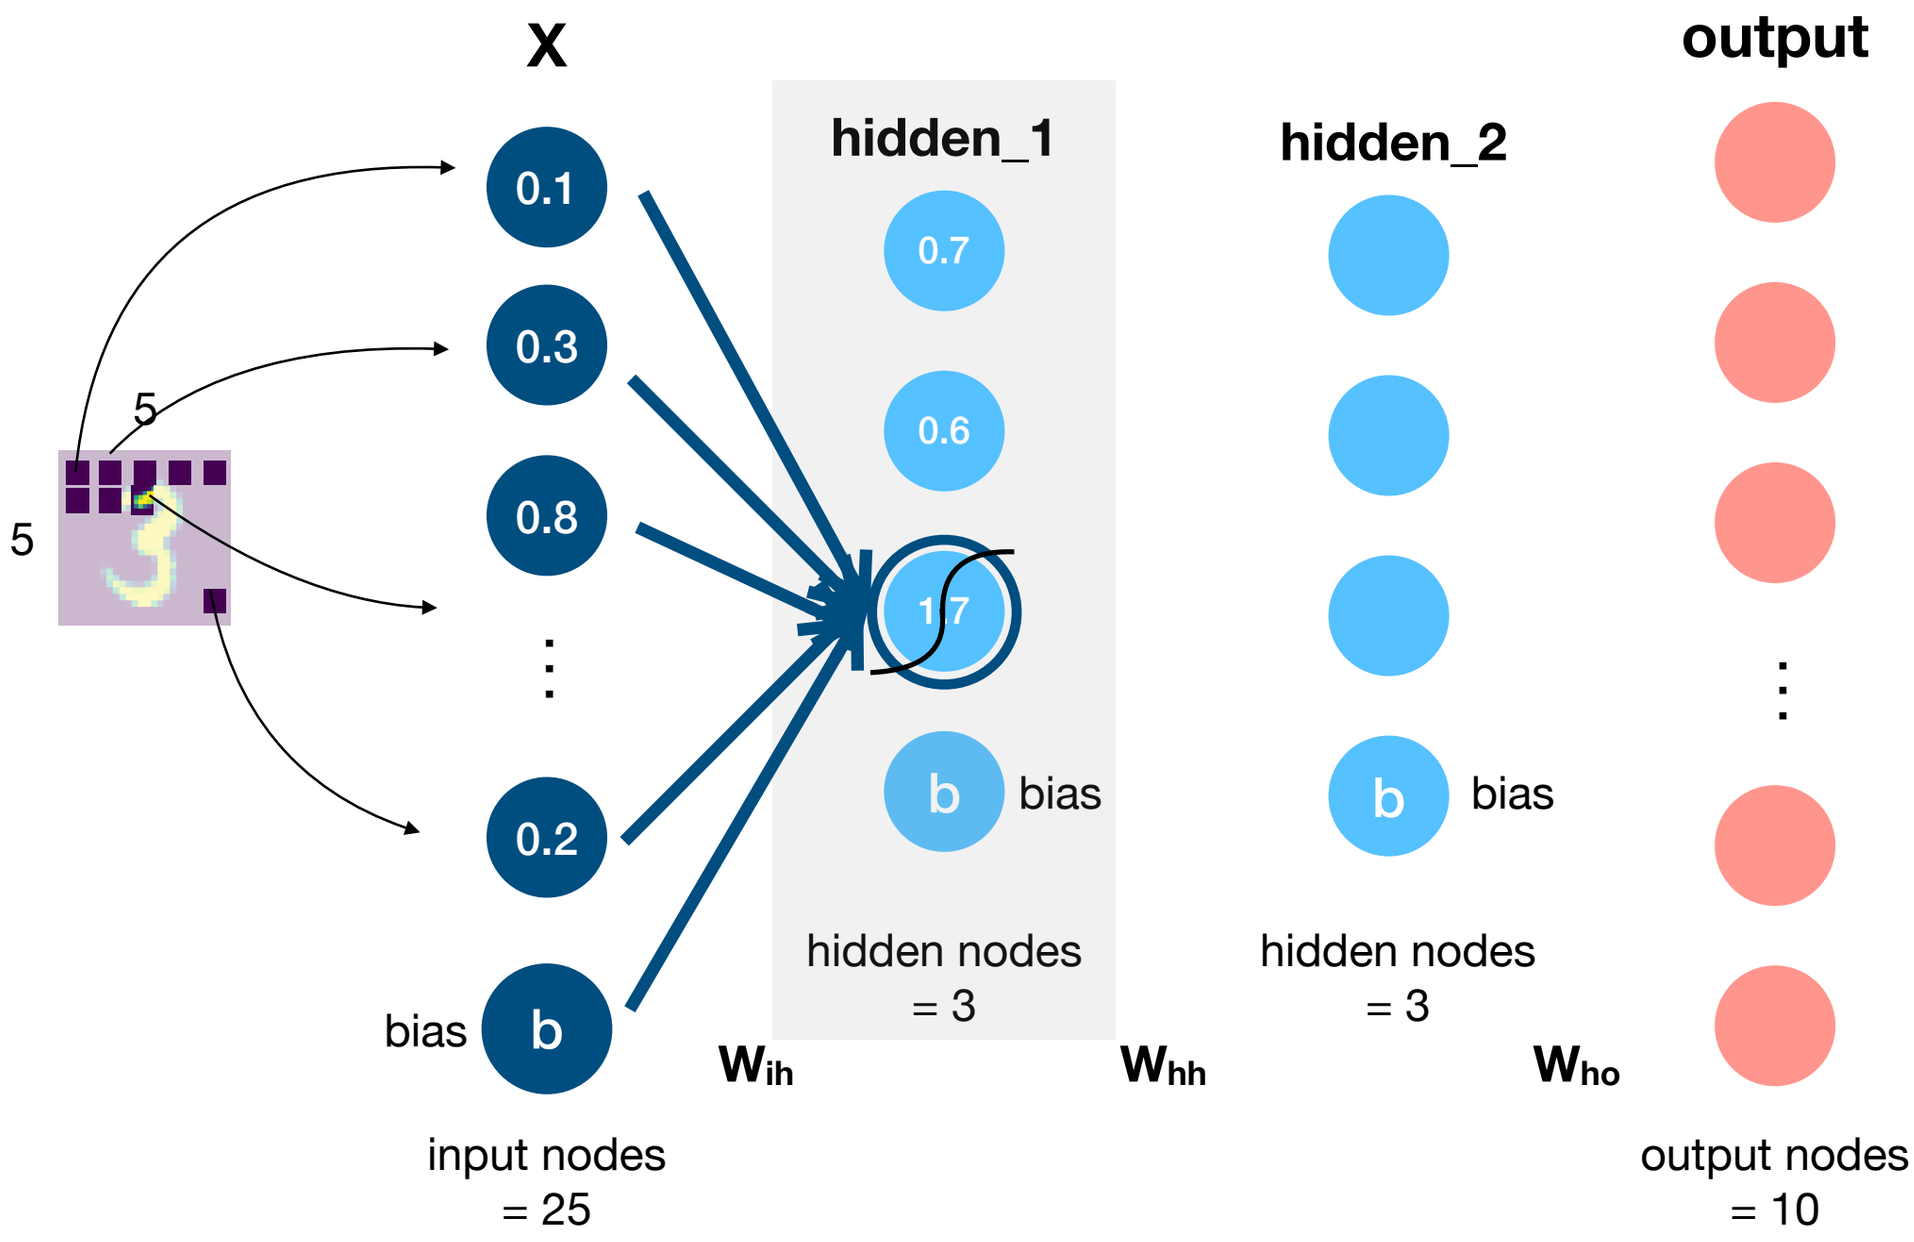

모든 hidden layer 1의 nodes에 대해 반복합니다.

ANN DNN

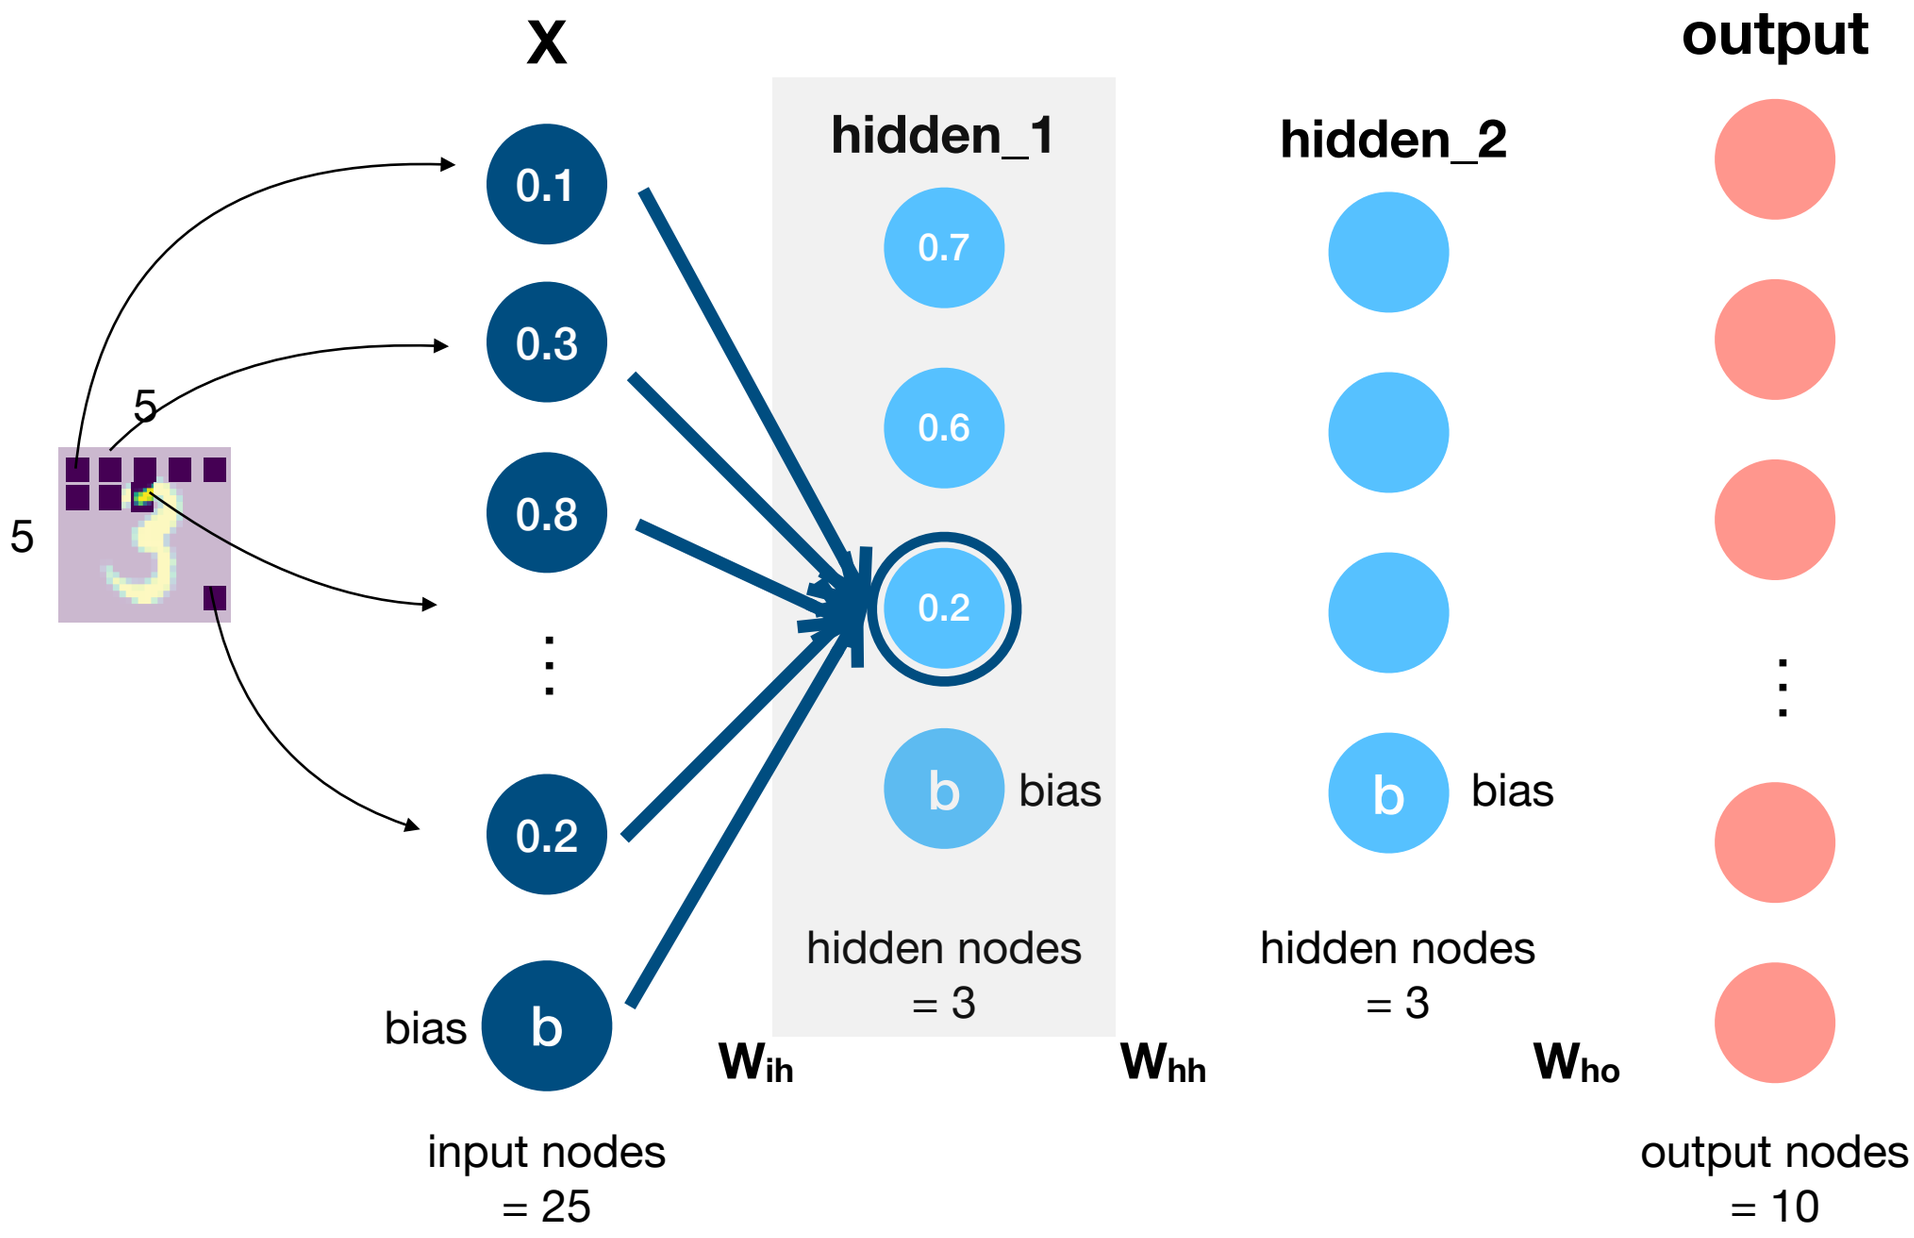

모든 hidden layer 1의 nodes에 대해 반복합니다.

ANN DNN

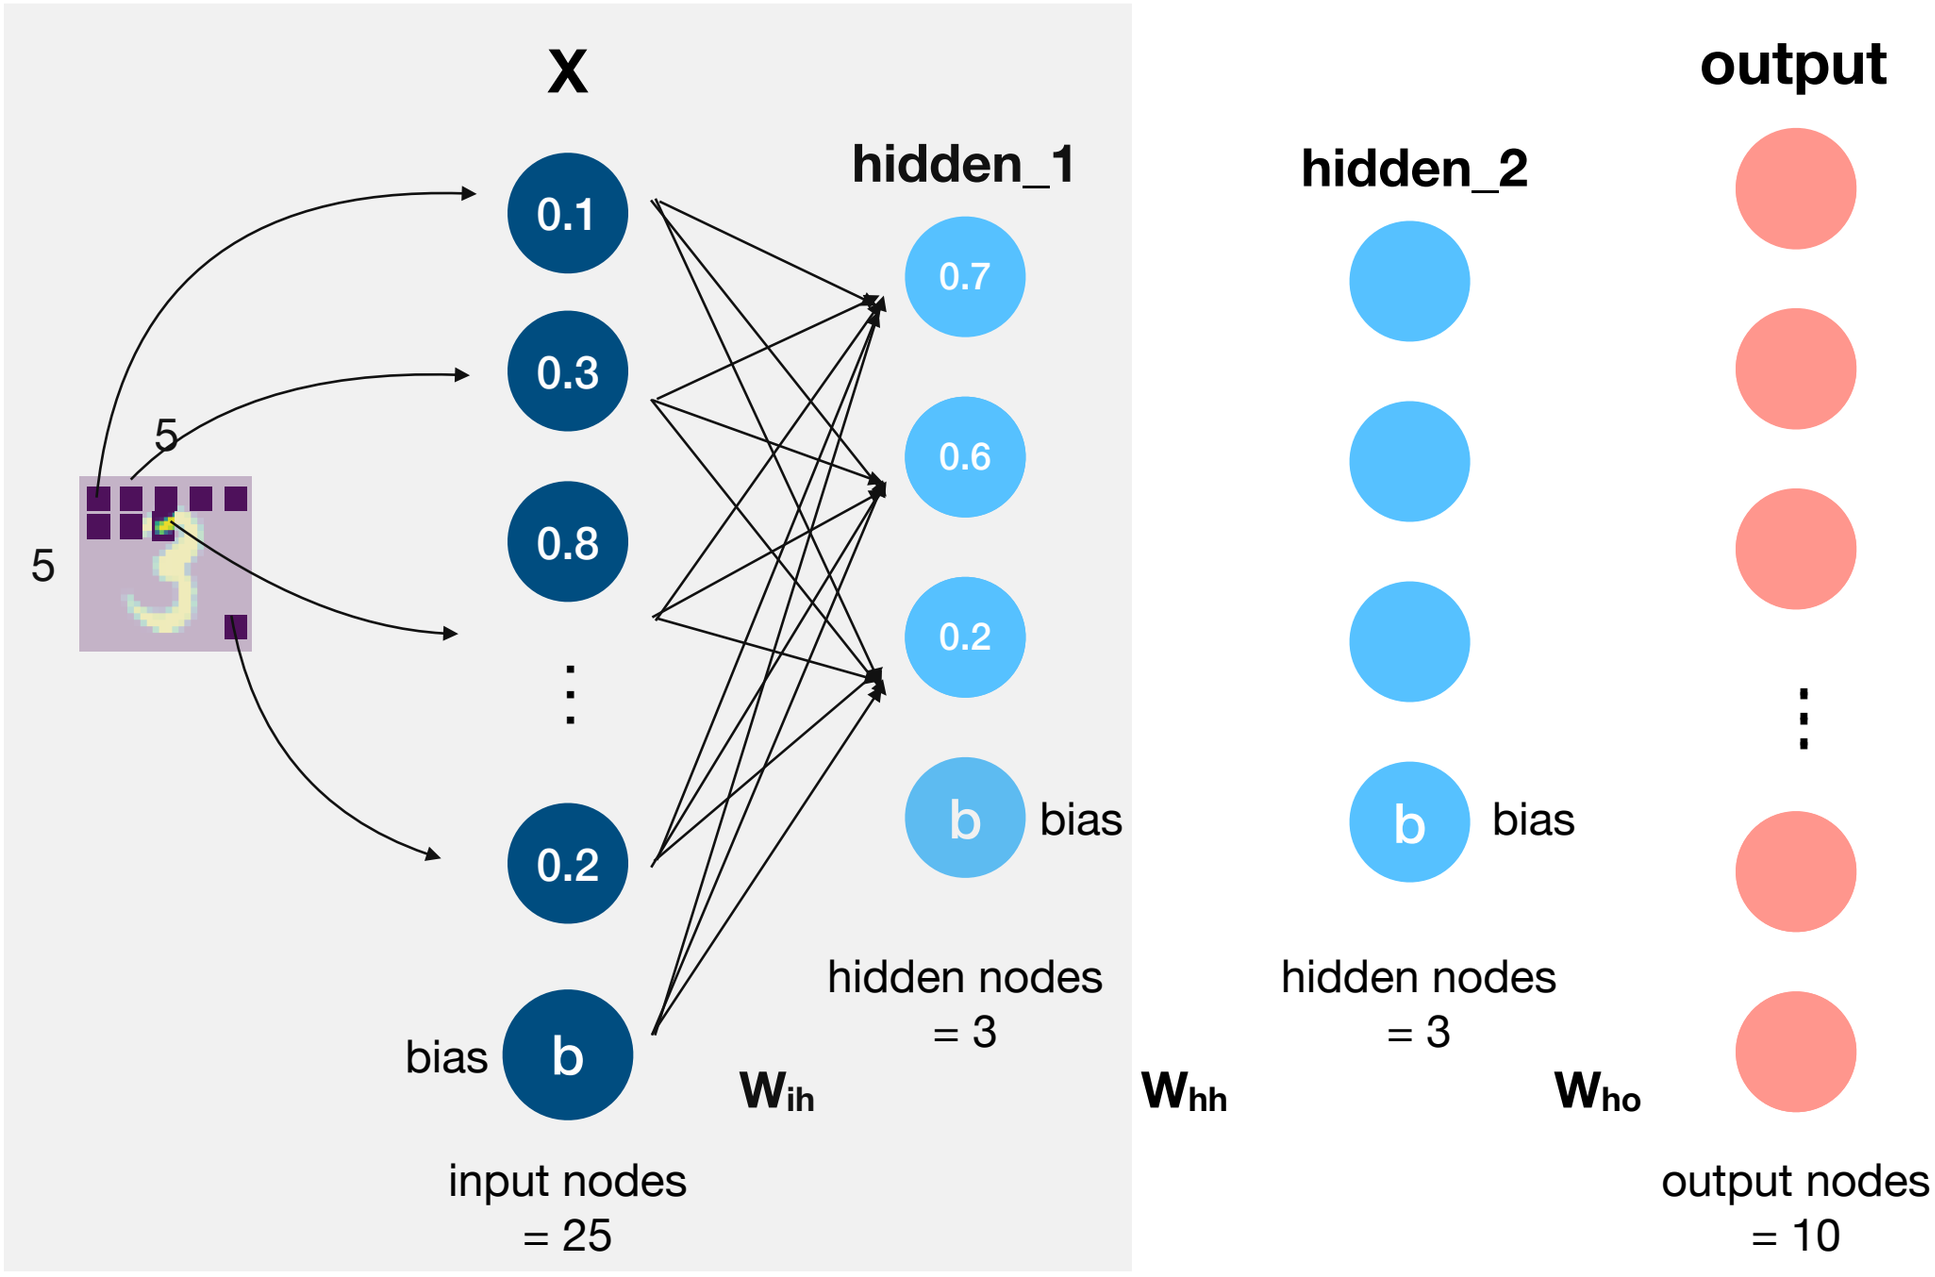

hidden layer 1까지의 nodes가 모두 계산되었습니다.
이제 hidden layer 2로 넘어갈 차례입니다.

ANN DNN

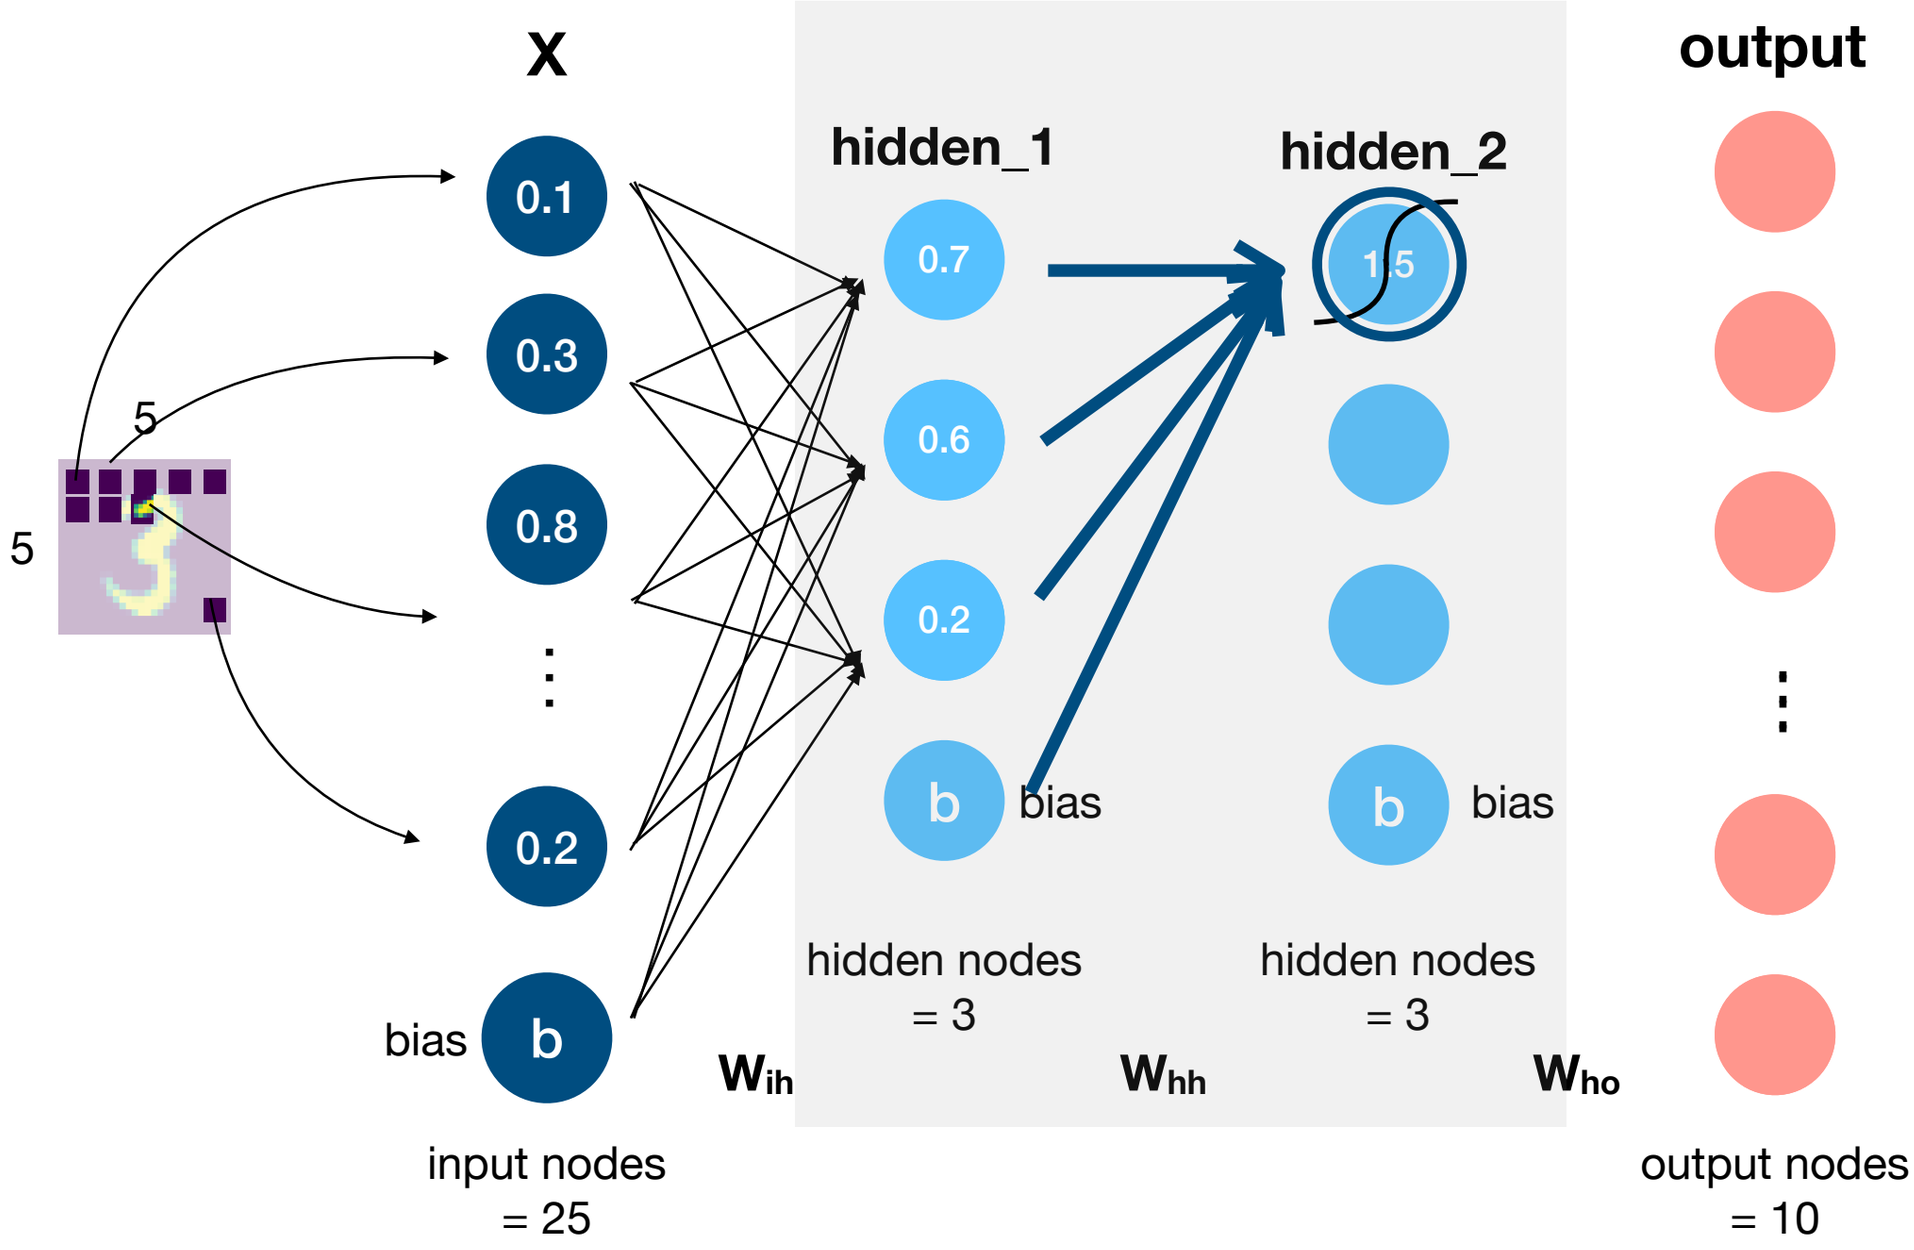

전과 같이, 각 hidden layer 1의 node 값에 weight (진한 화살표)을 곱하고 모두 더해 activation function을 건 후 hidden layer 2의 첫 번째 node에 넣어줍니다.

ANN DNN

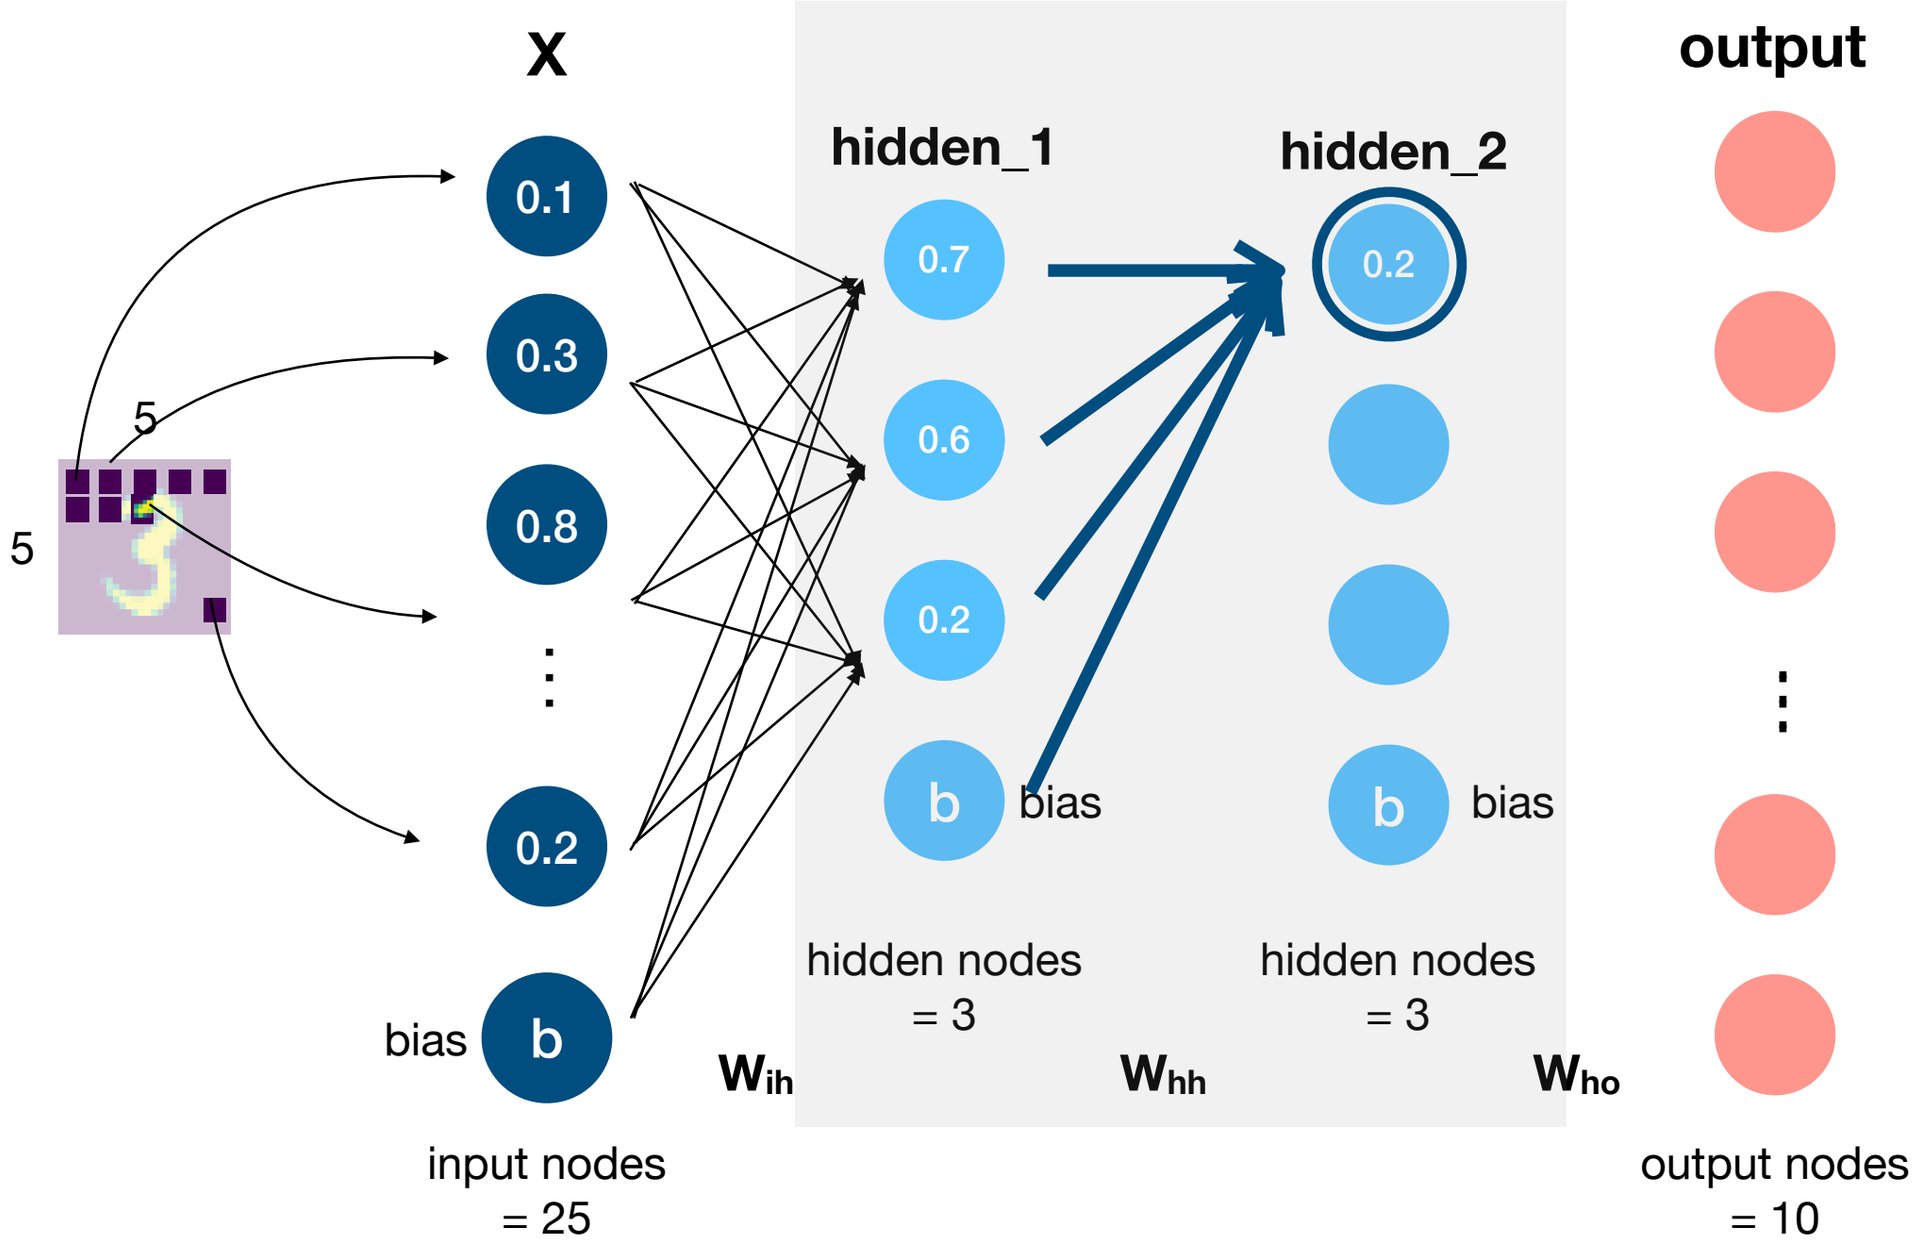

전과 같이, 각 hidden layer 1의 node 값에 weight (진한 화살표)을 곱하고 모두 더해 activation function을 건 후 hidden layer 2의 첫 번째 node에 넣어줍니다.

ANN DNN

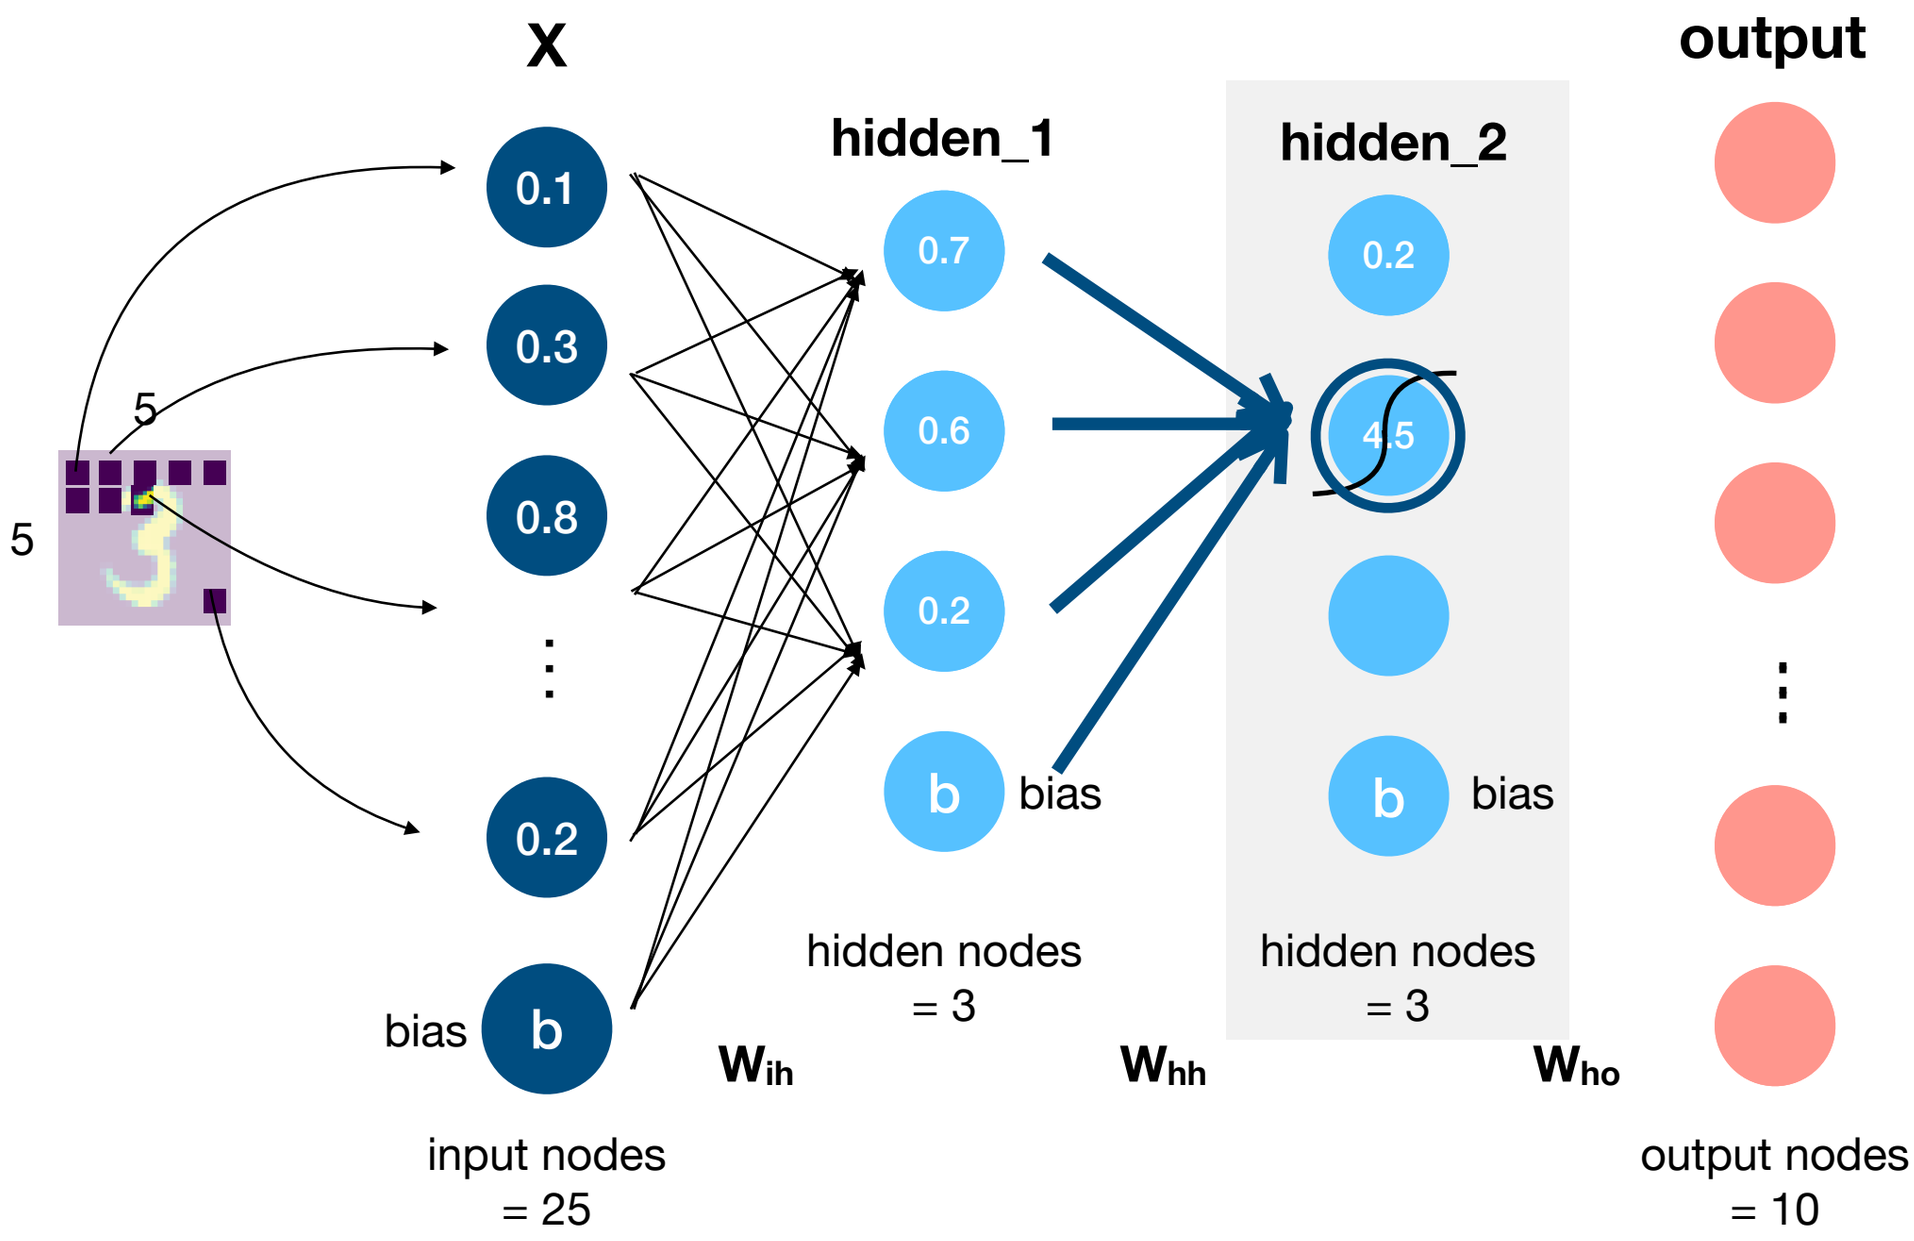

모든 hidden layer 2의 nodes에 대해 반복합니다.

ANN DNN

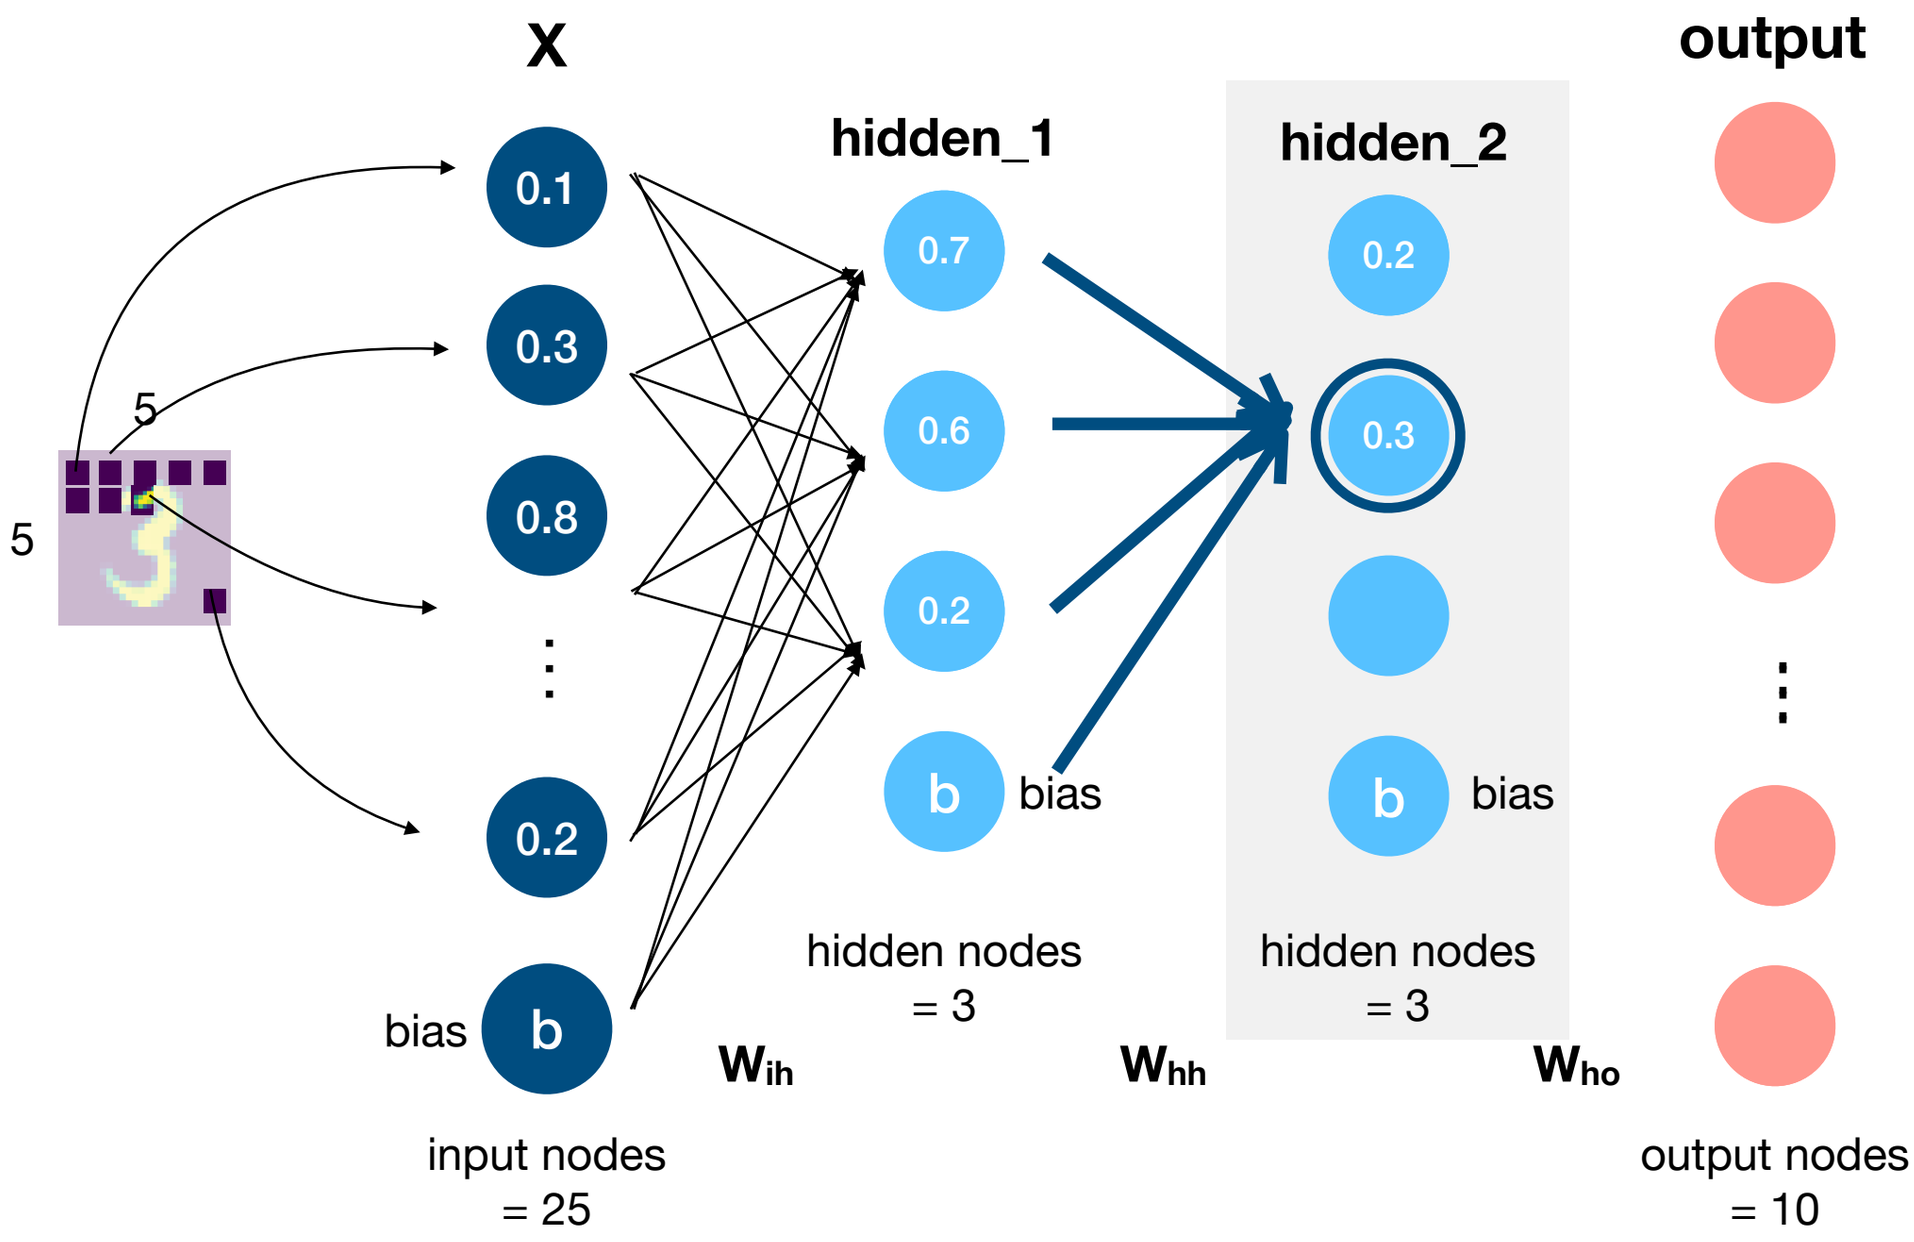

모든 hidden layer 2의 nodes에 대해 반복합니다.

ANN DNN

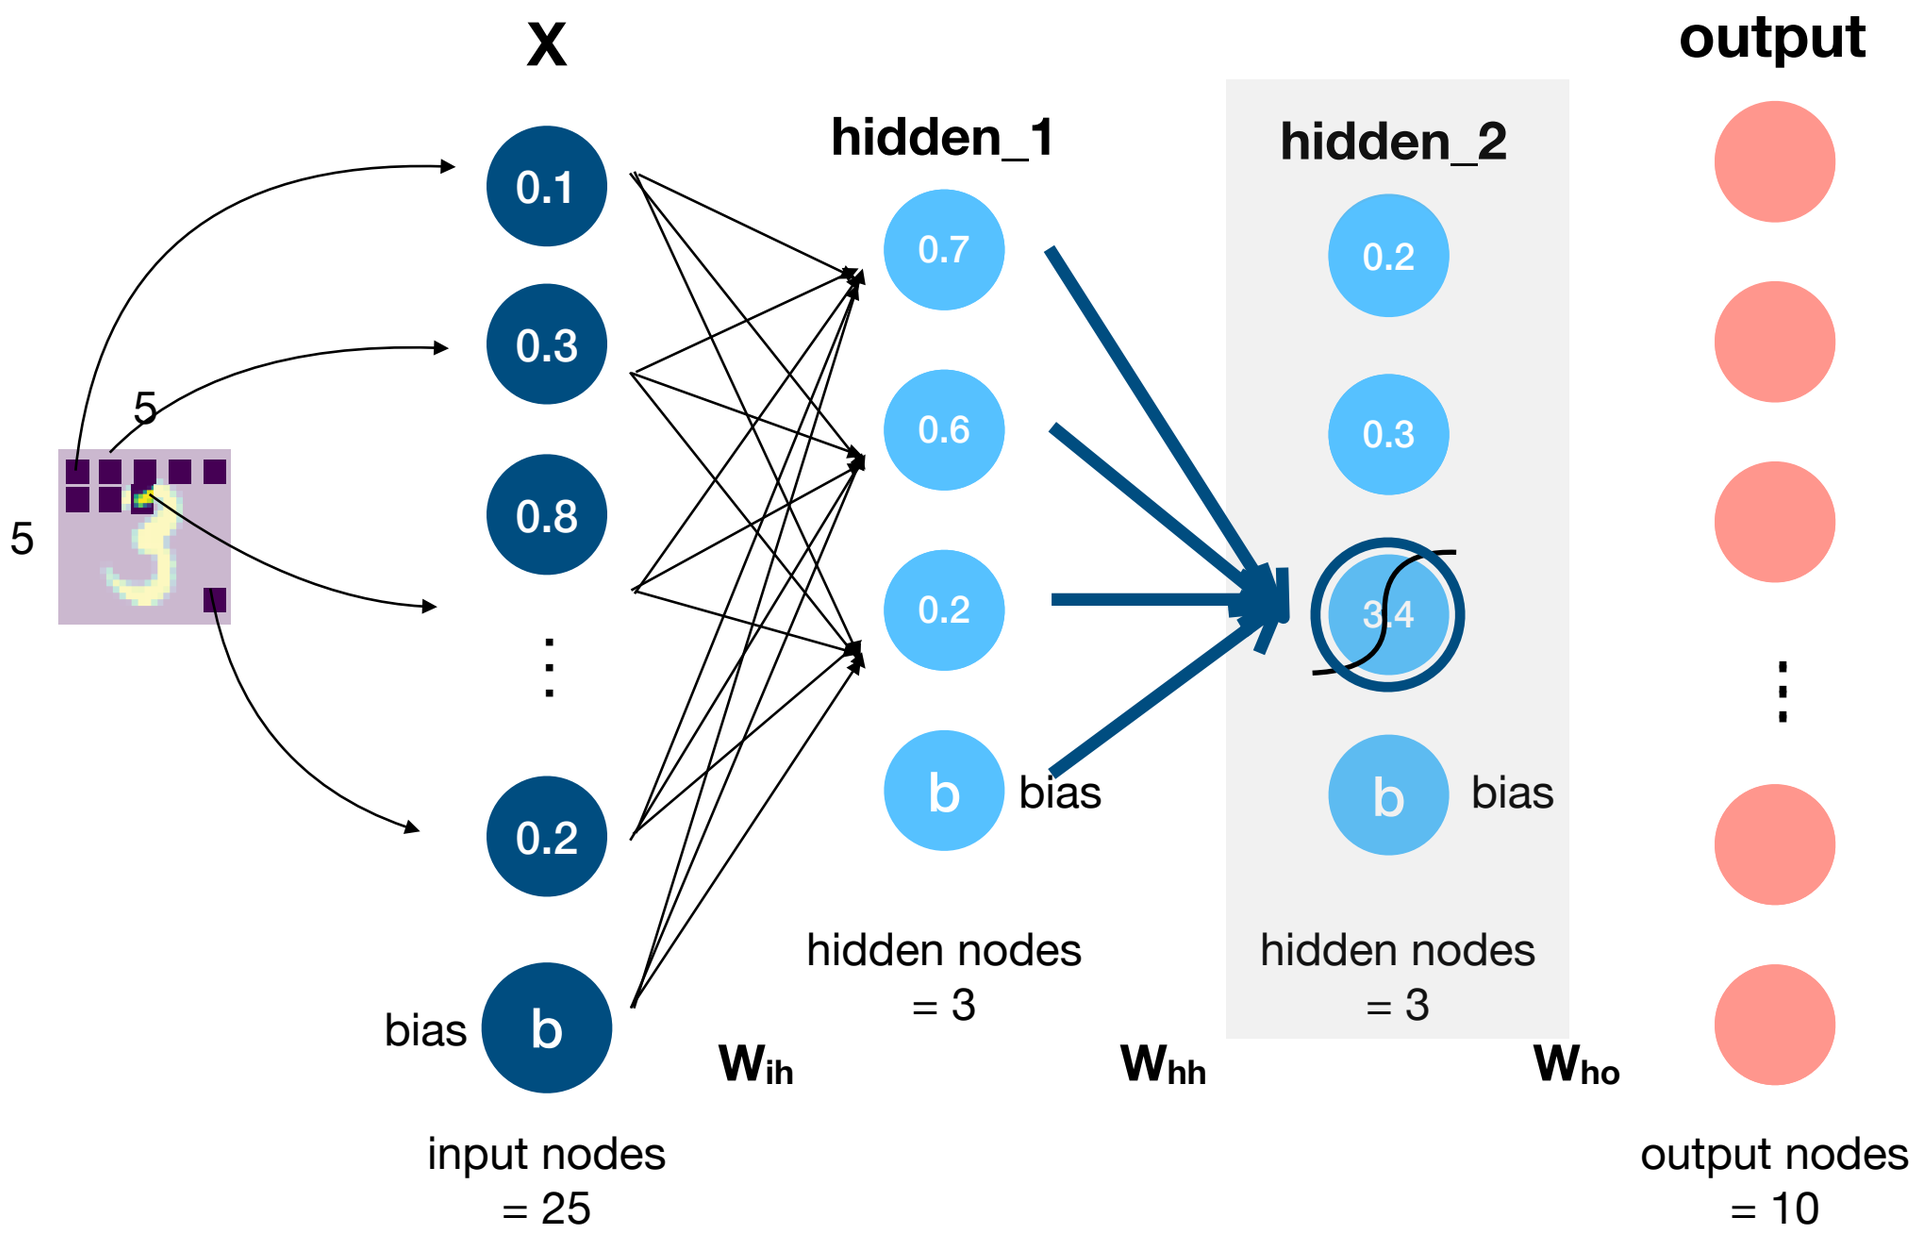

모든 hidden layer 2의 nodes에 대해 반복합니다.

ANN DNN

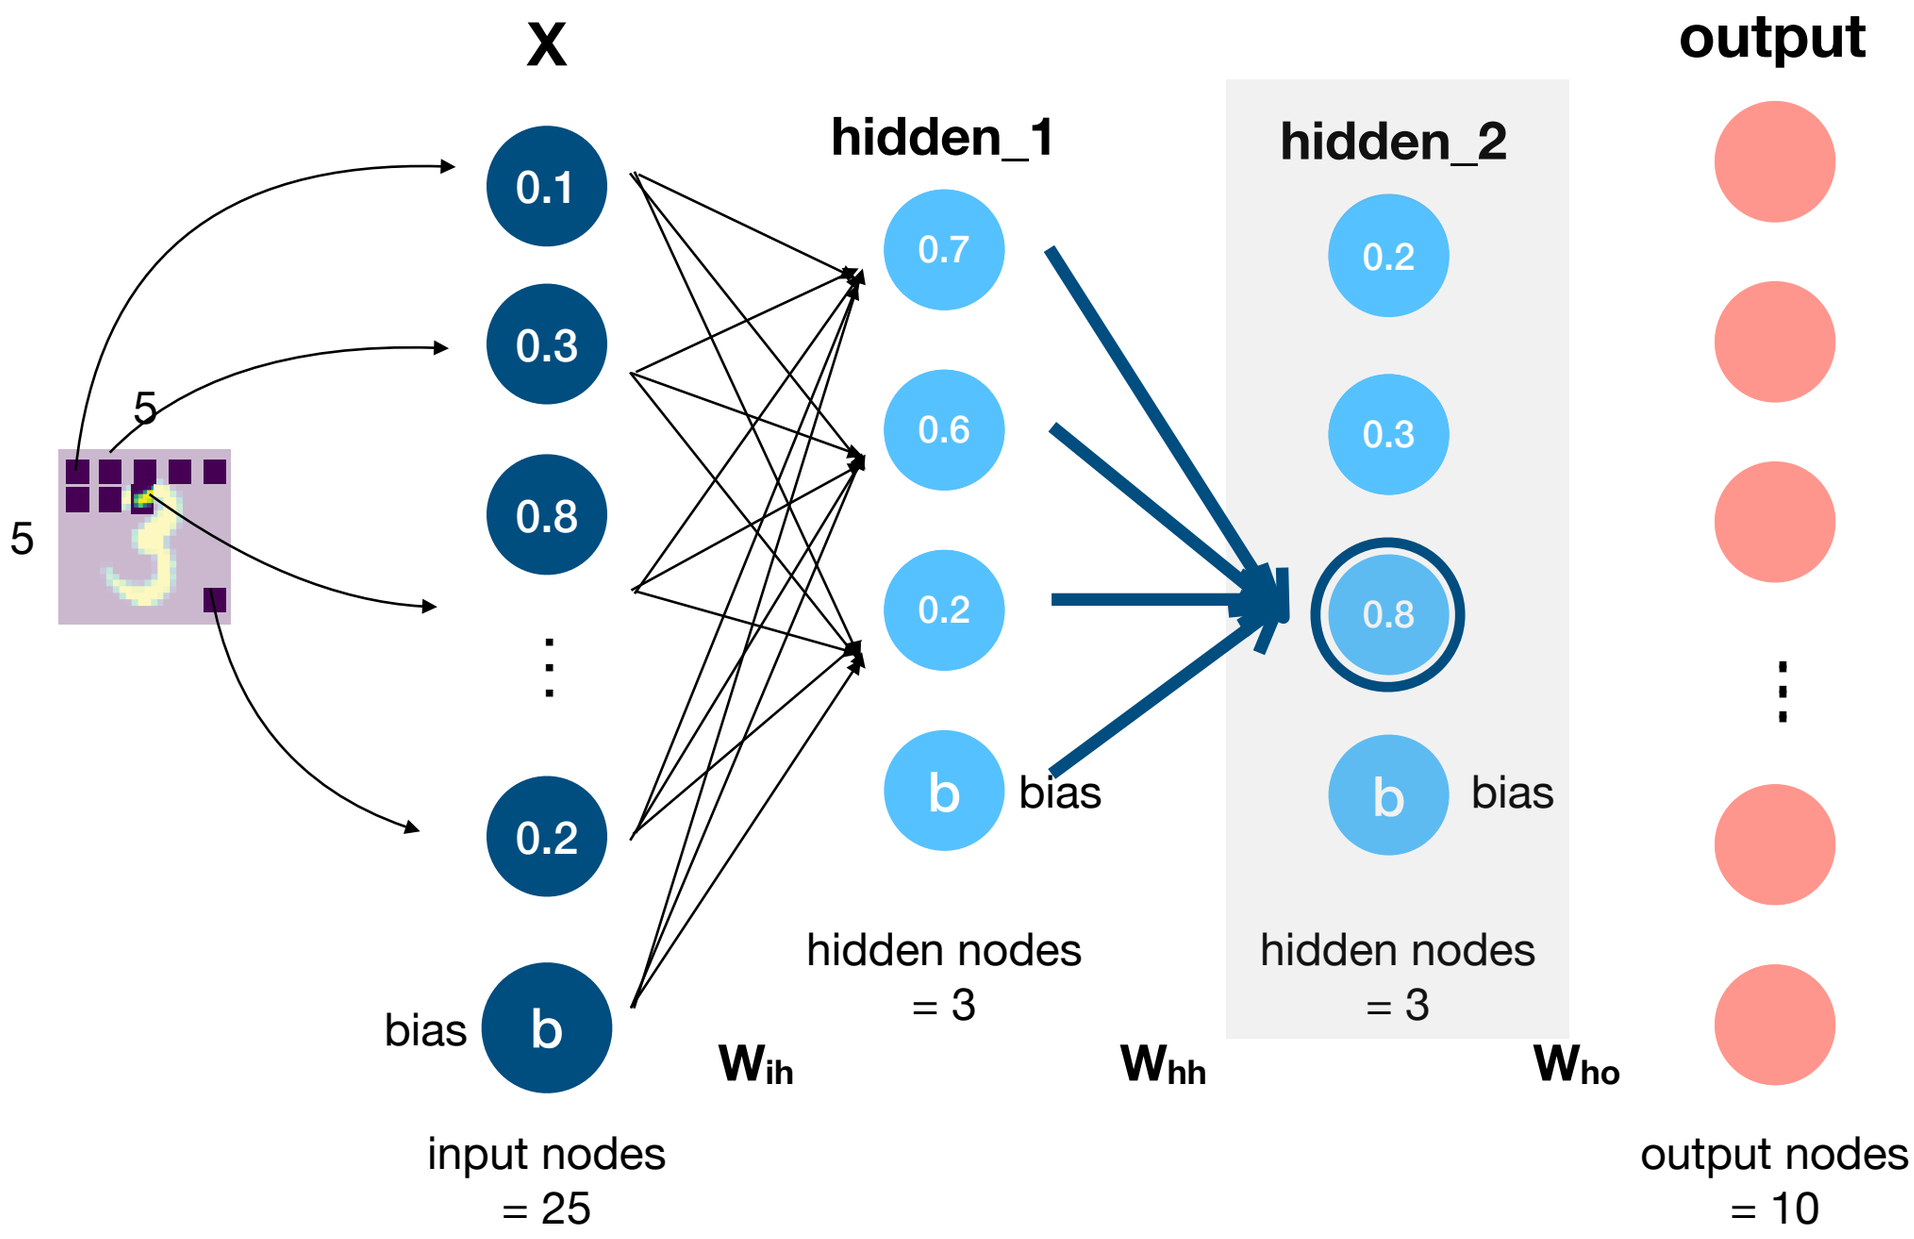

모든 hidden layer 2의 nodes에 대해 반복합니다.

ANN DNN

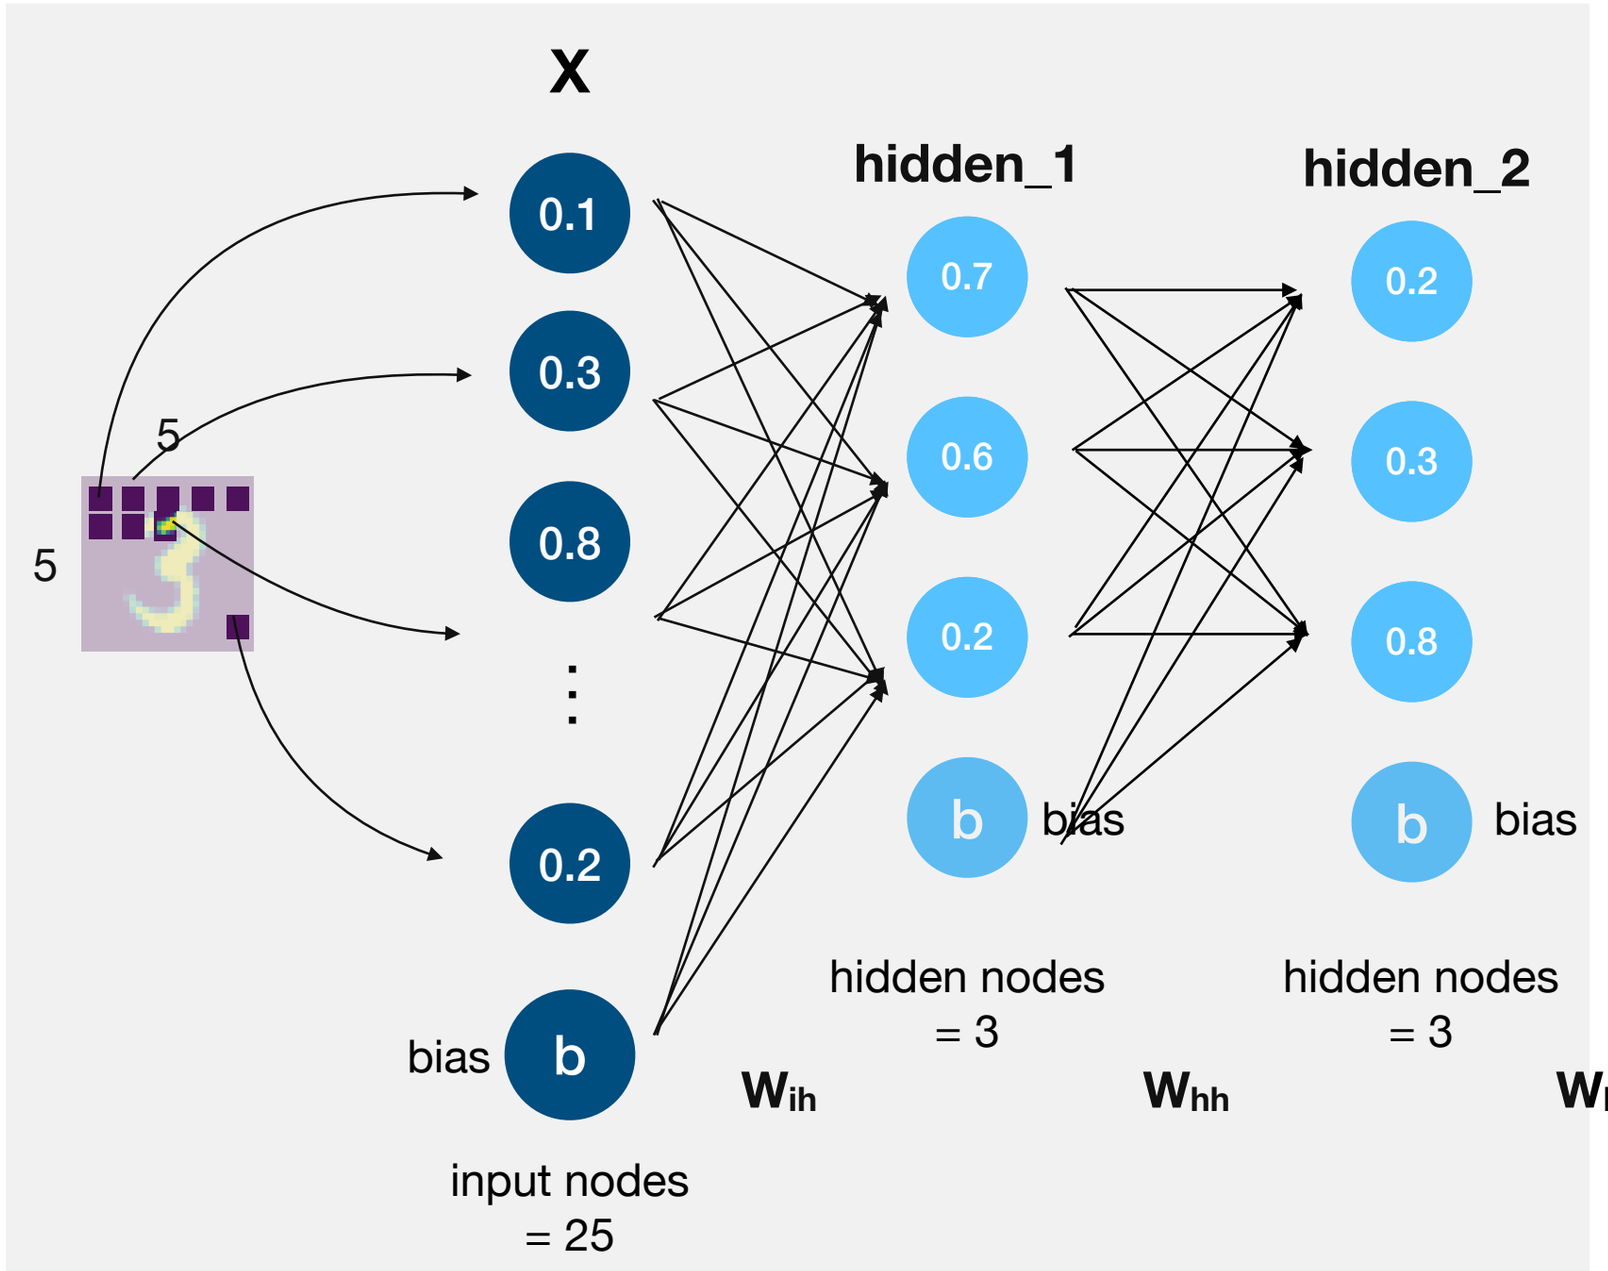

hidden layer 2까지의 nodes가 모두 계산되었습니다.
이제 output layer로 넘어갈 차례입니다.

ANN DNN

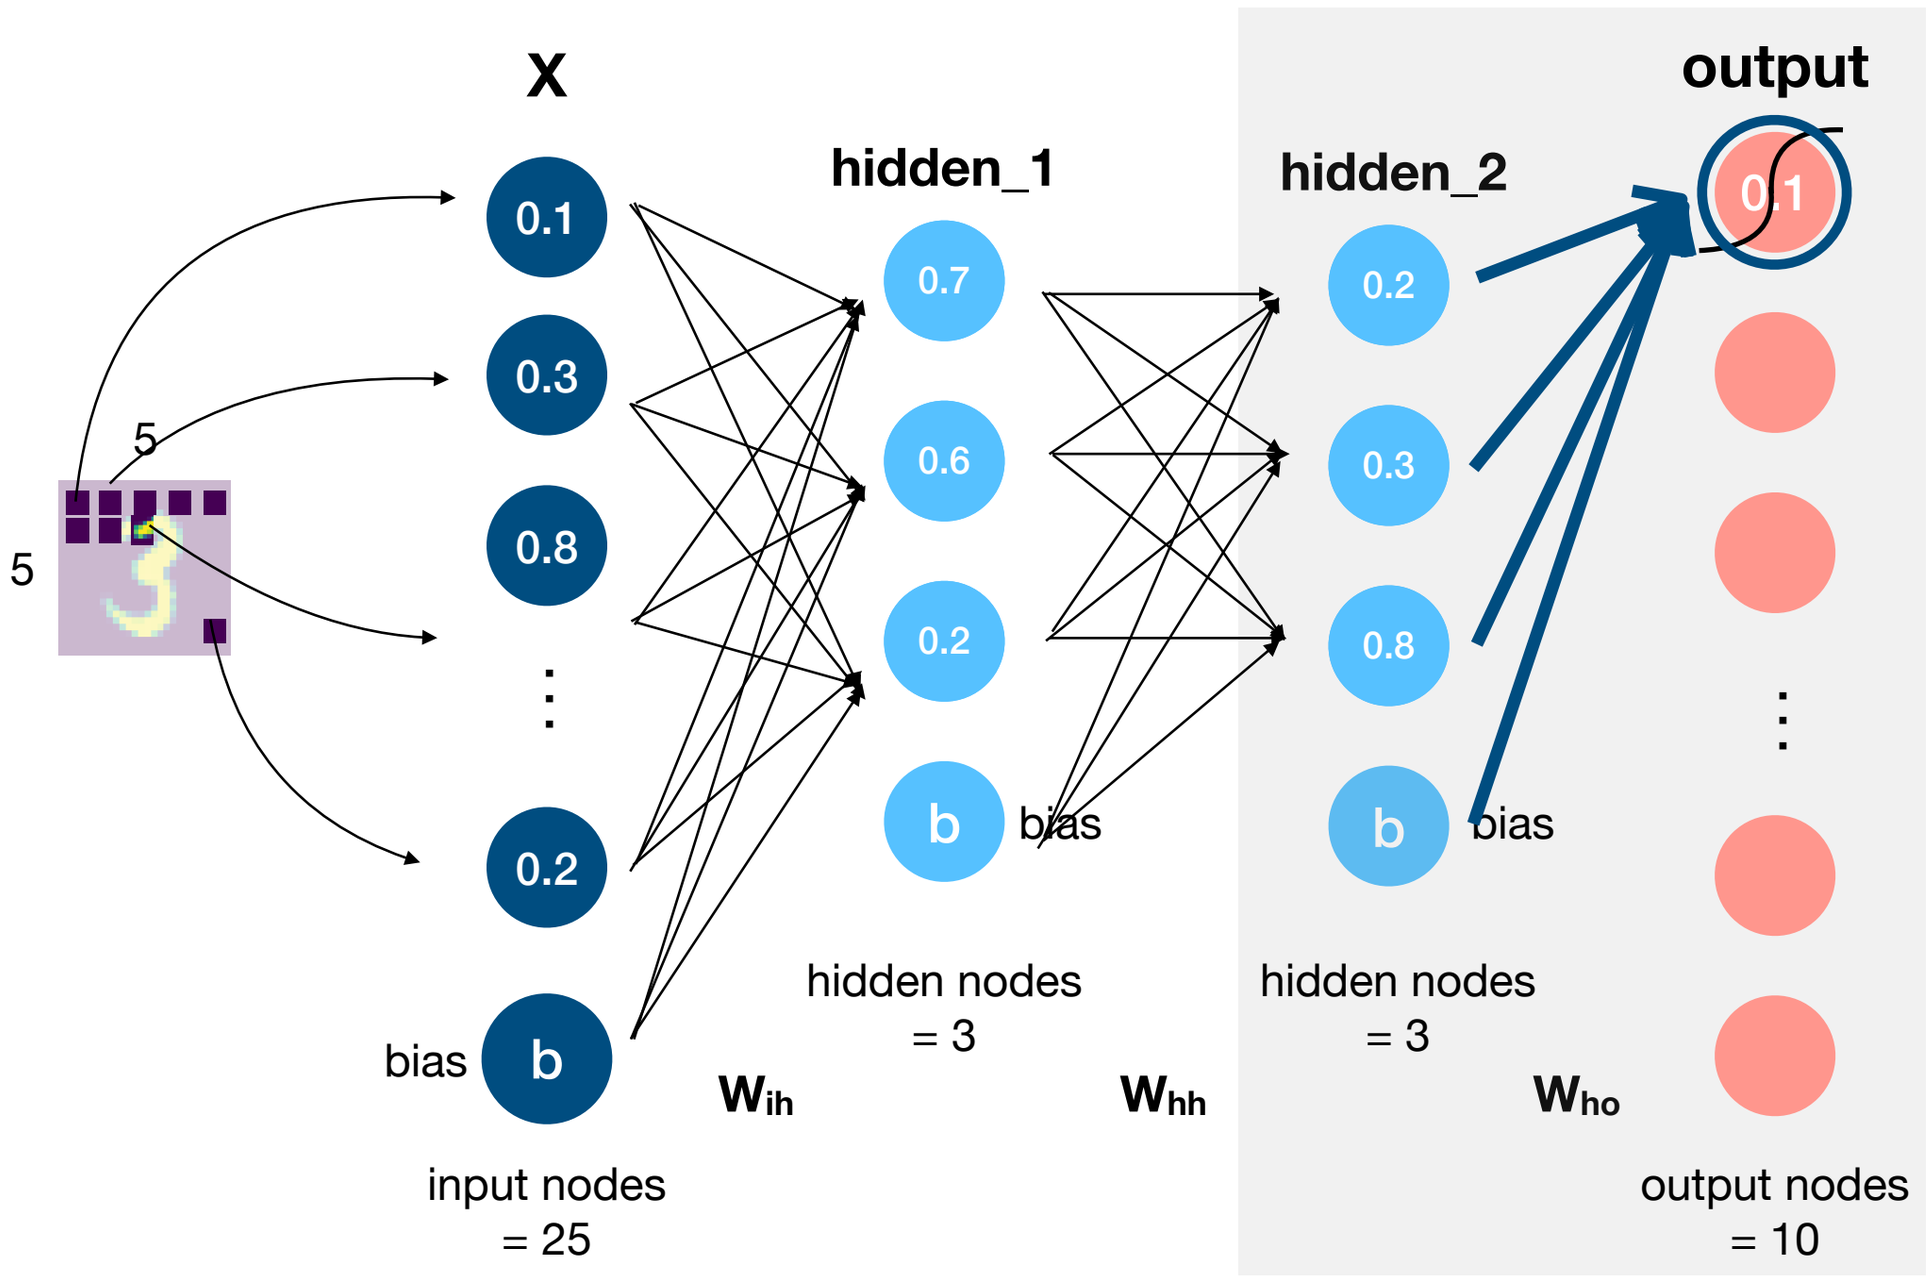

전과 같이, 각 hidden layer 2의 node 값에 weight (진한 화살표)을 곱하고 모두 더해 activation function을 건 후 output layer의 첫 번째 node에 넣어줍니다.

ANN DNN

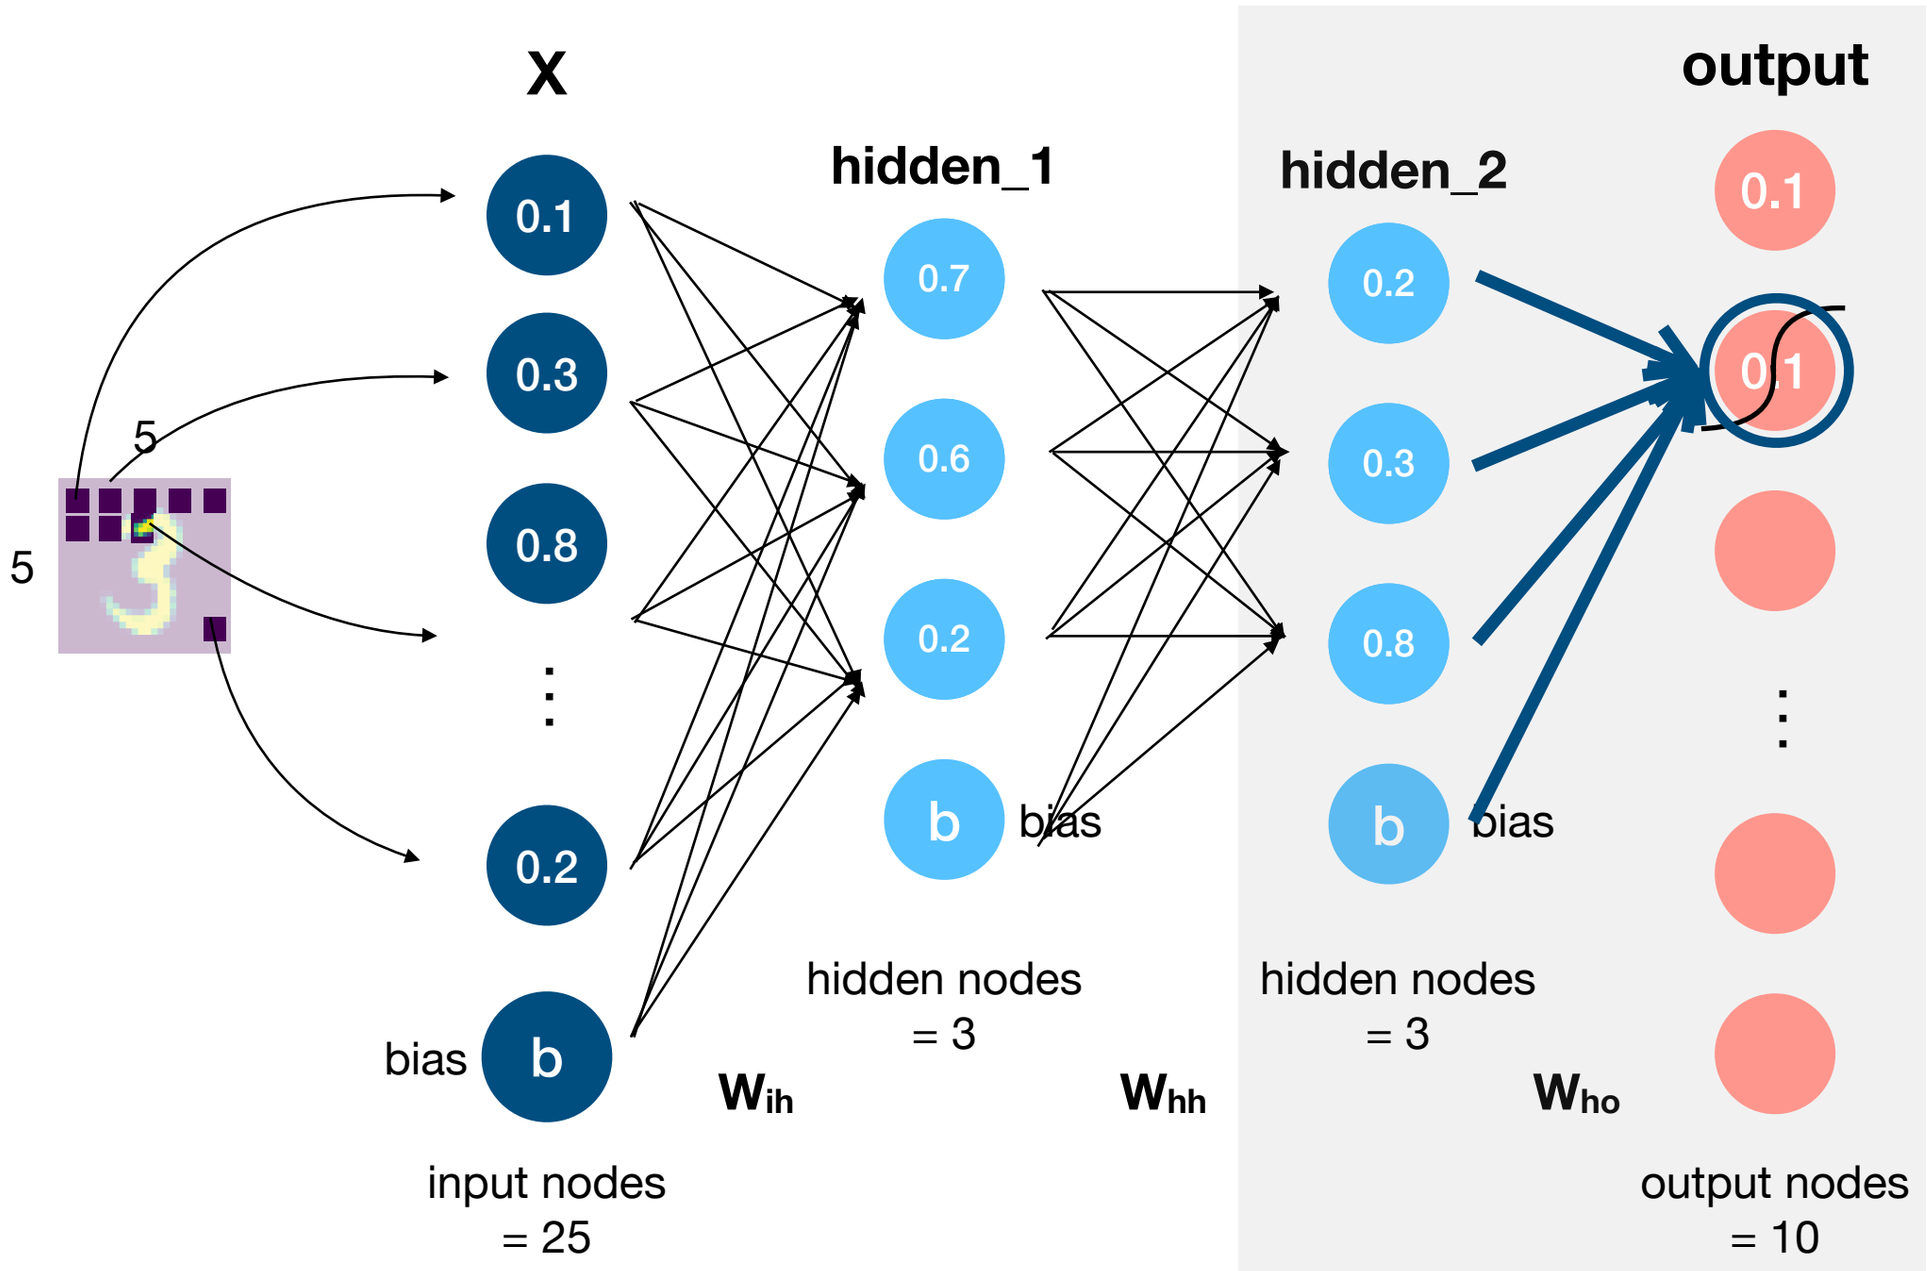

마찬가지 방식으로 반복합니다.

ANN DNN

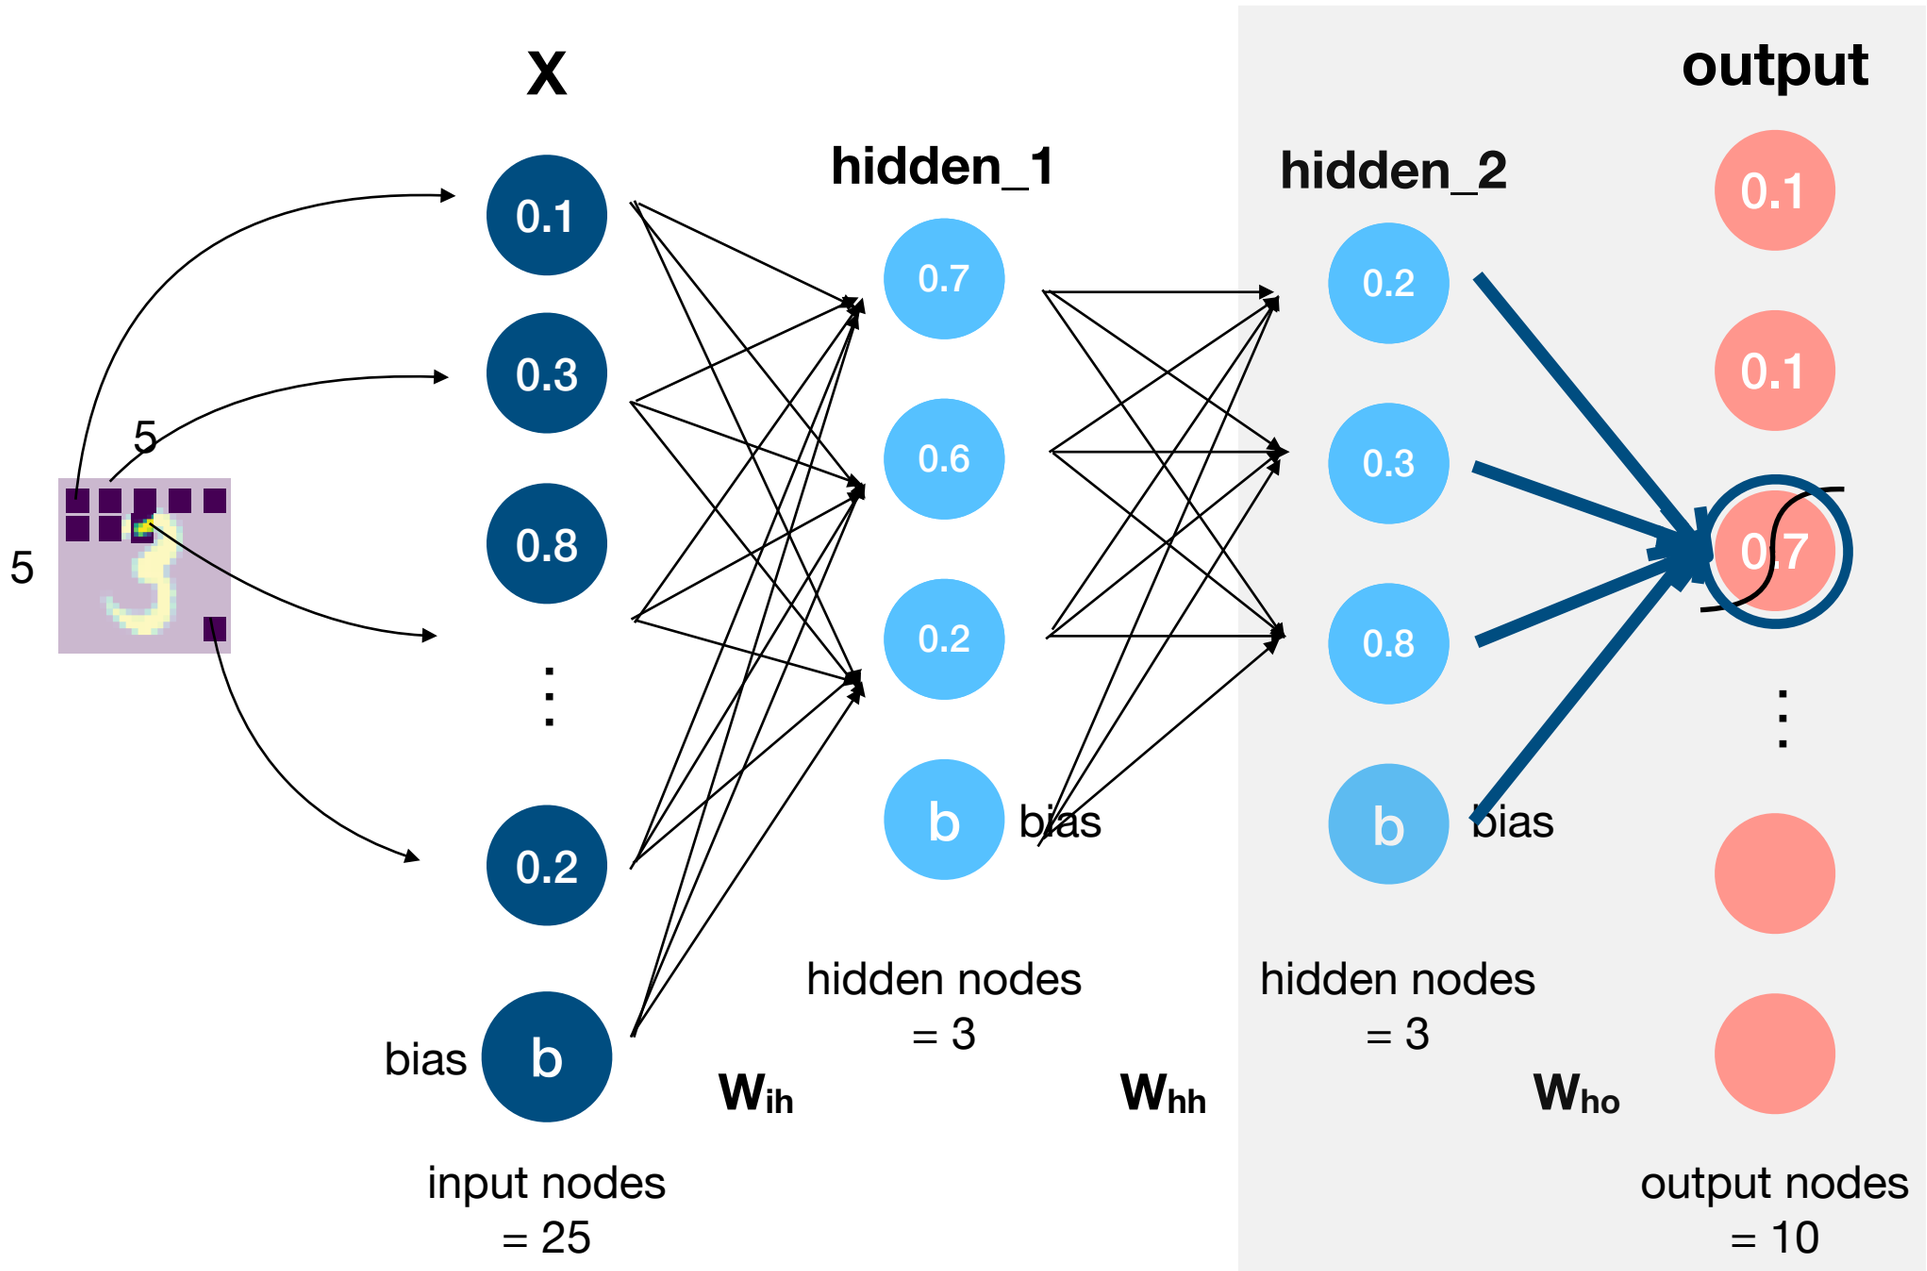

마찬가지 방식으로 반복합니다.

ANN DNN

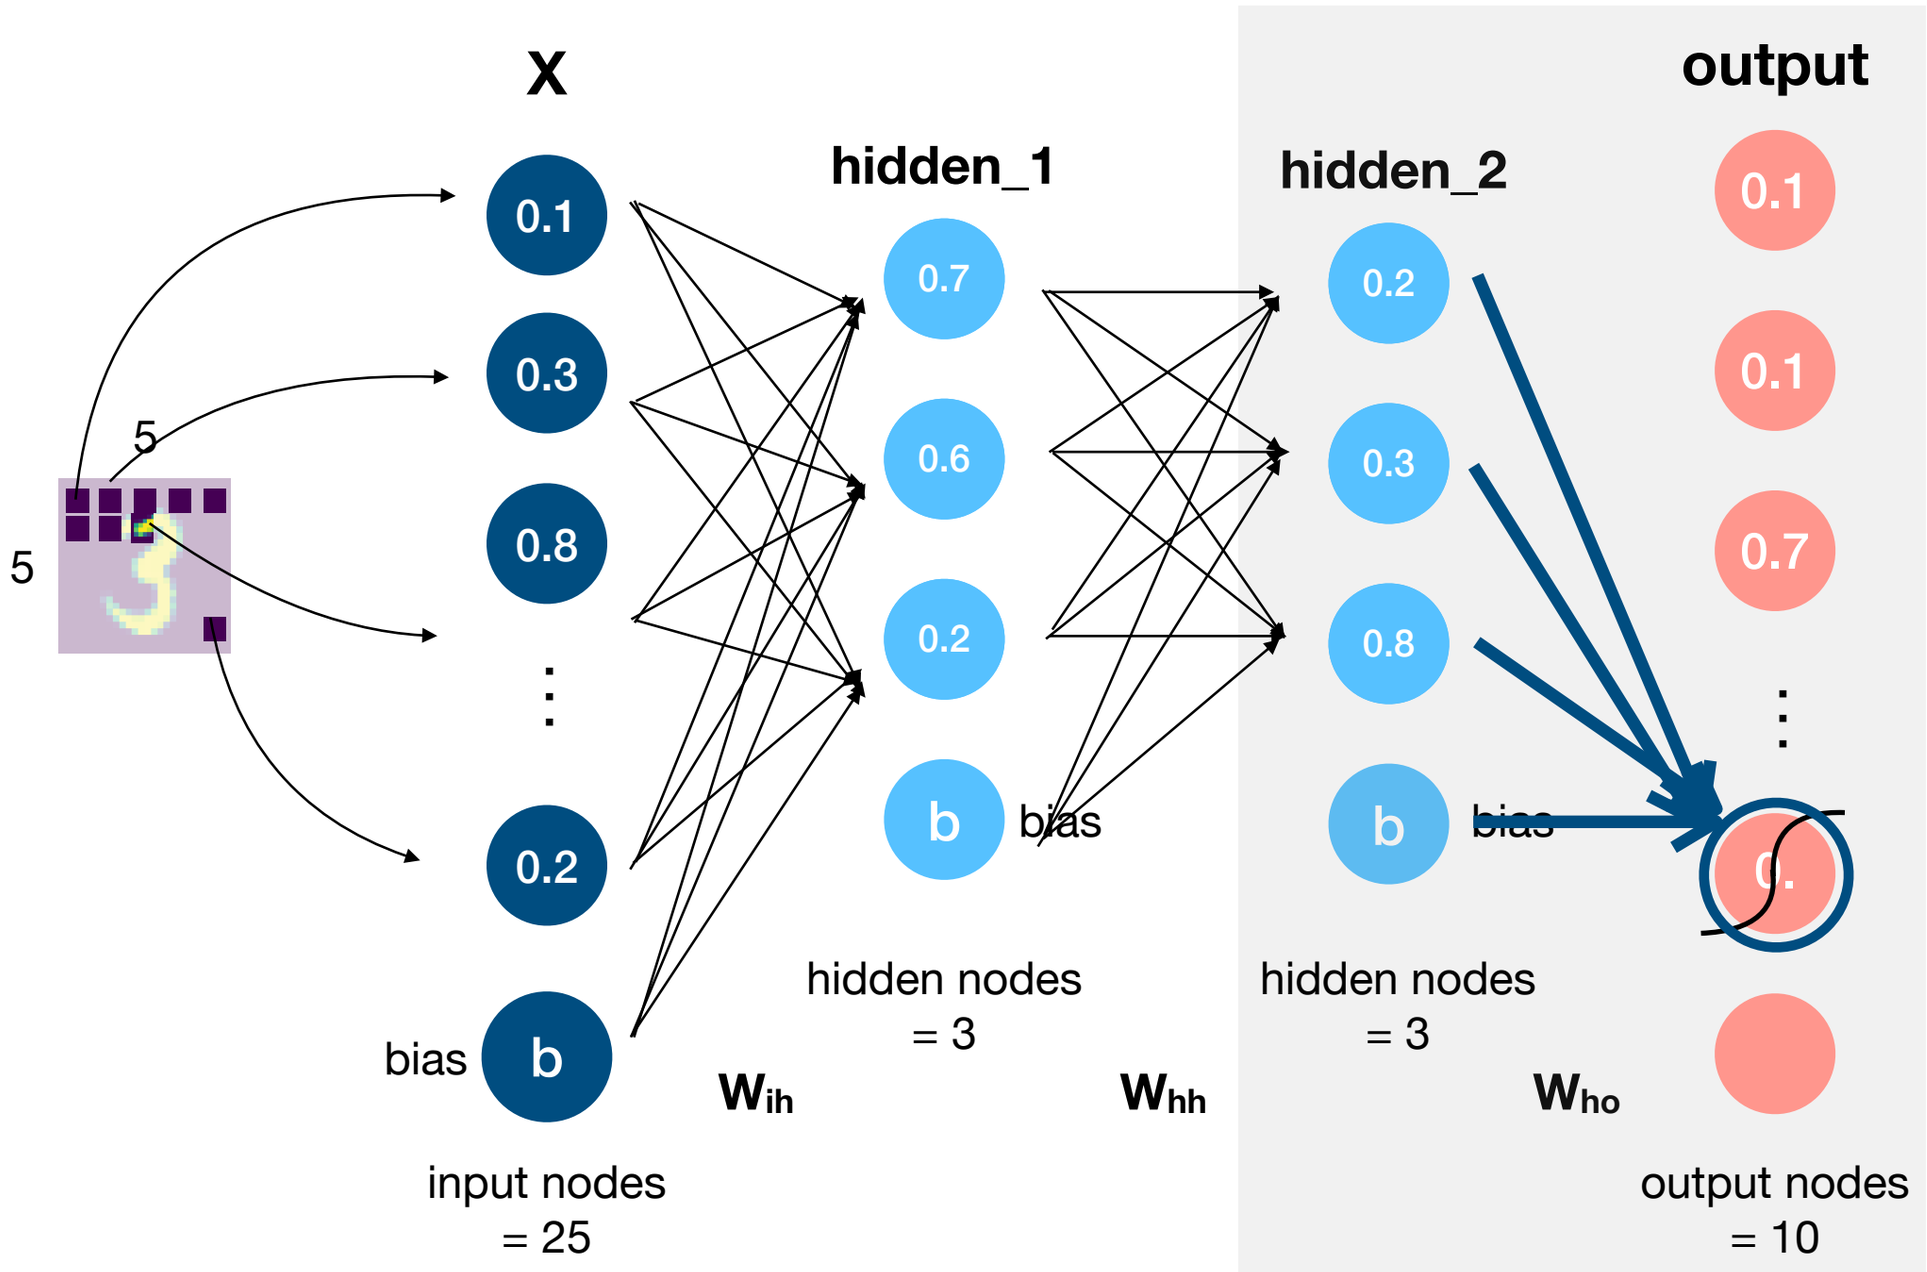

마찬가지 방식으로 반복합니다.

ANN DNN

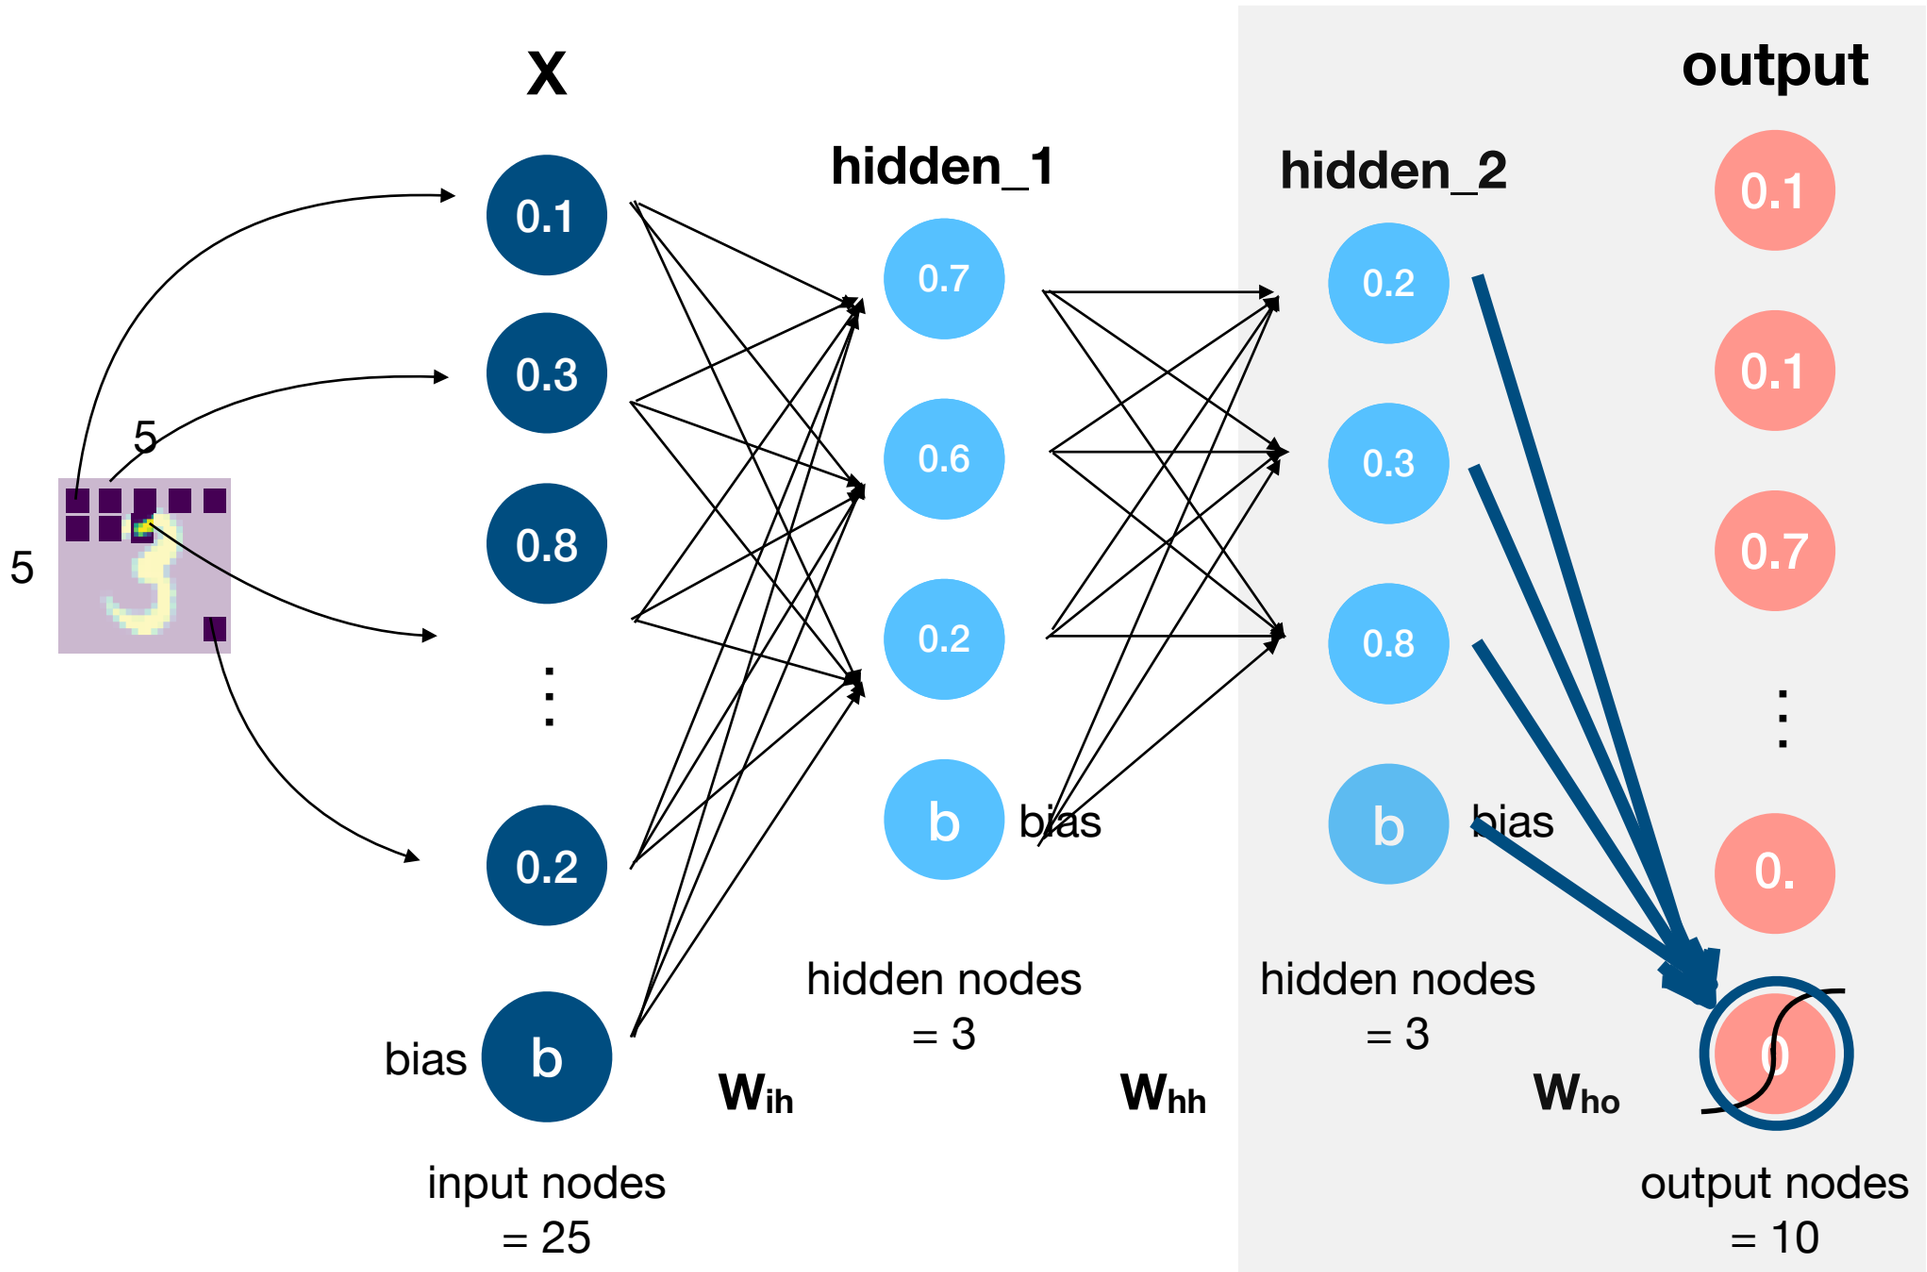

마찬가지 방식으로 반복합니다.

ANN DNN

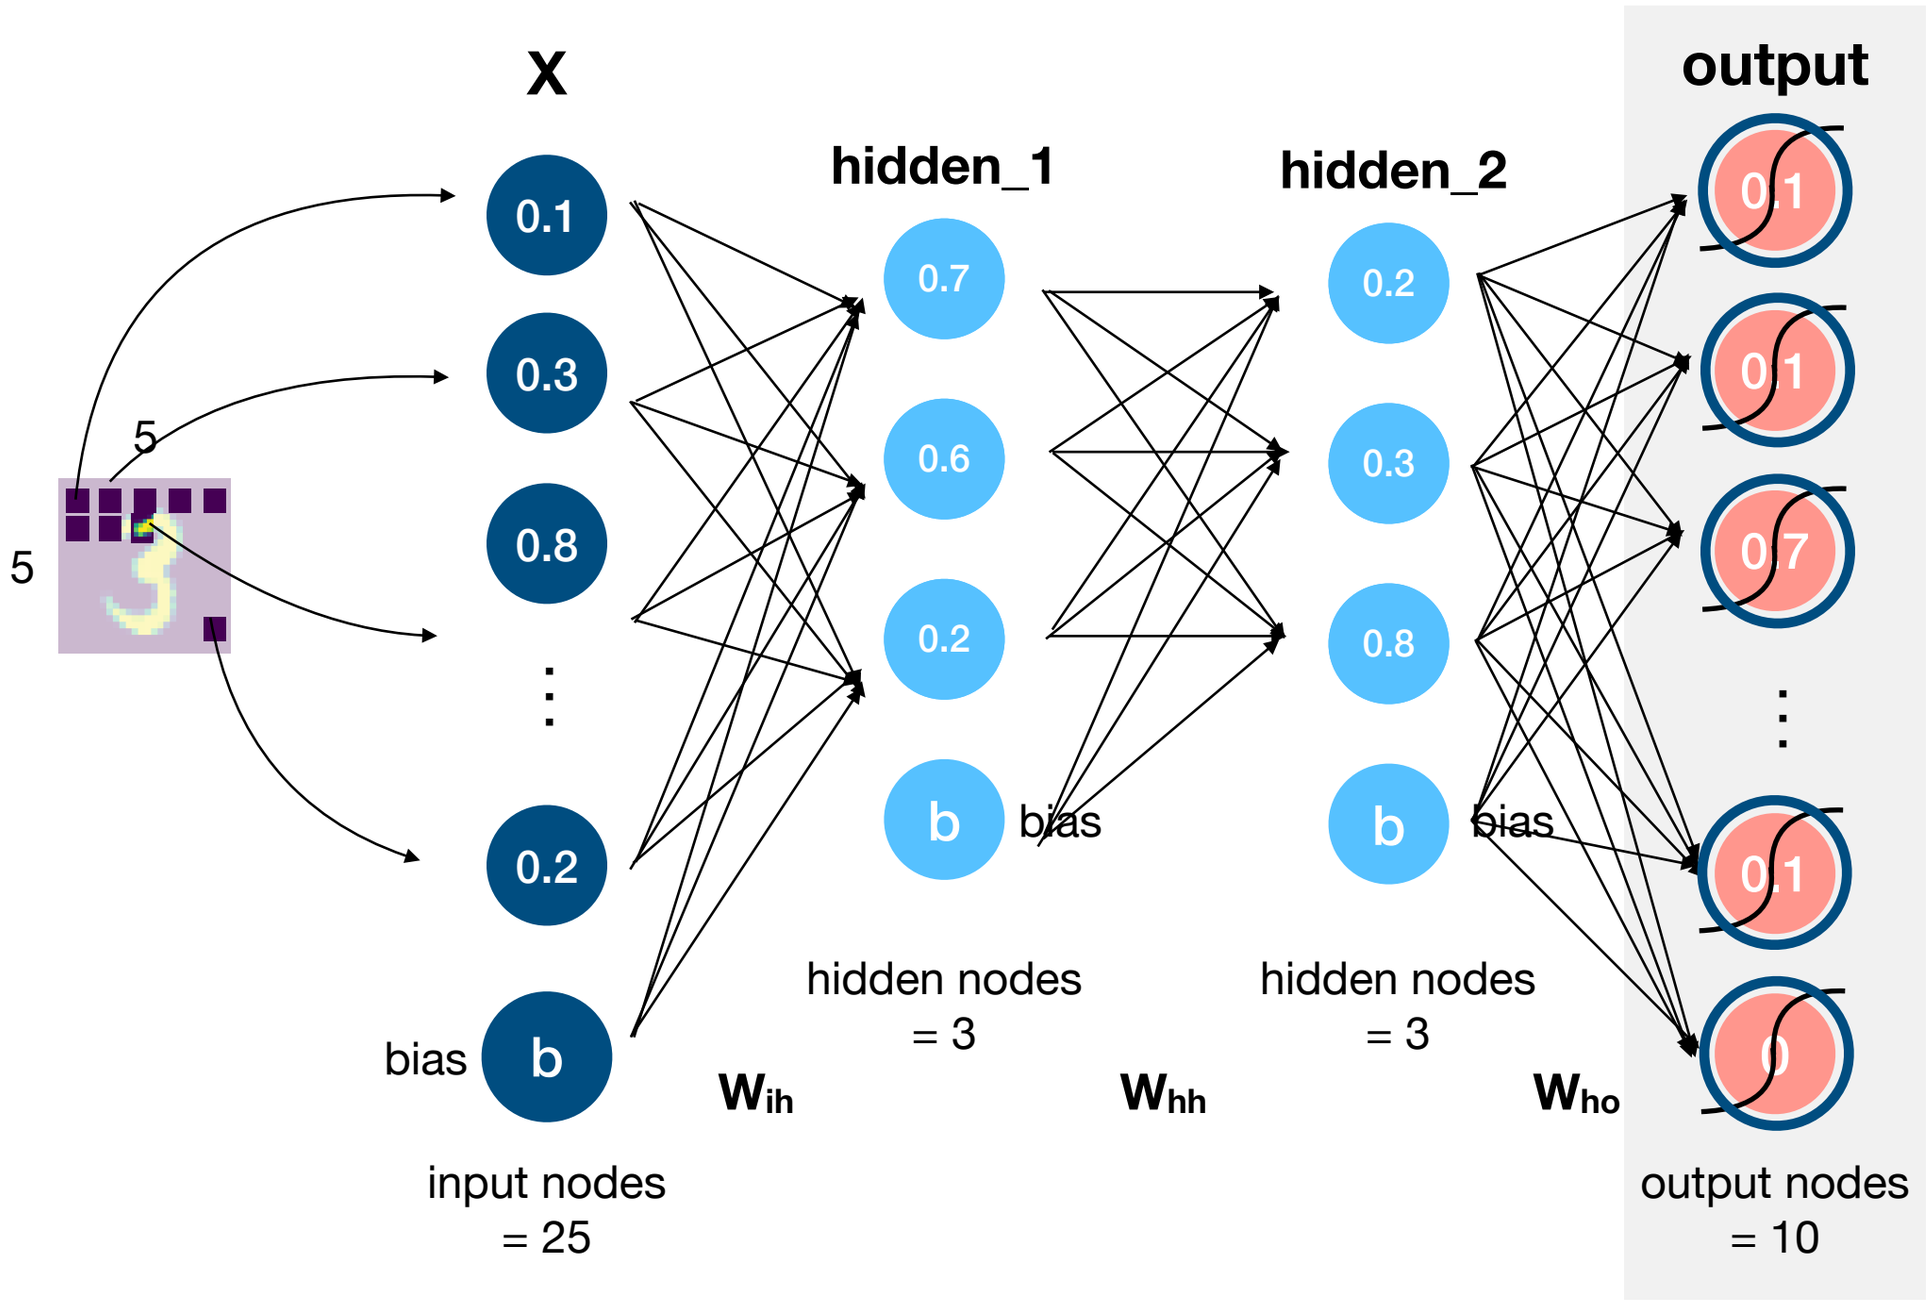

hidden layers의 activation function과는 다르게
output layer에서는 activation function으로
softmax function을 사용하며 이는 input이 각 숫자일 확률을 계산해 줍니다.

ANN DNN

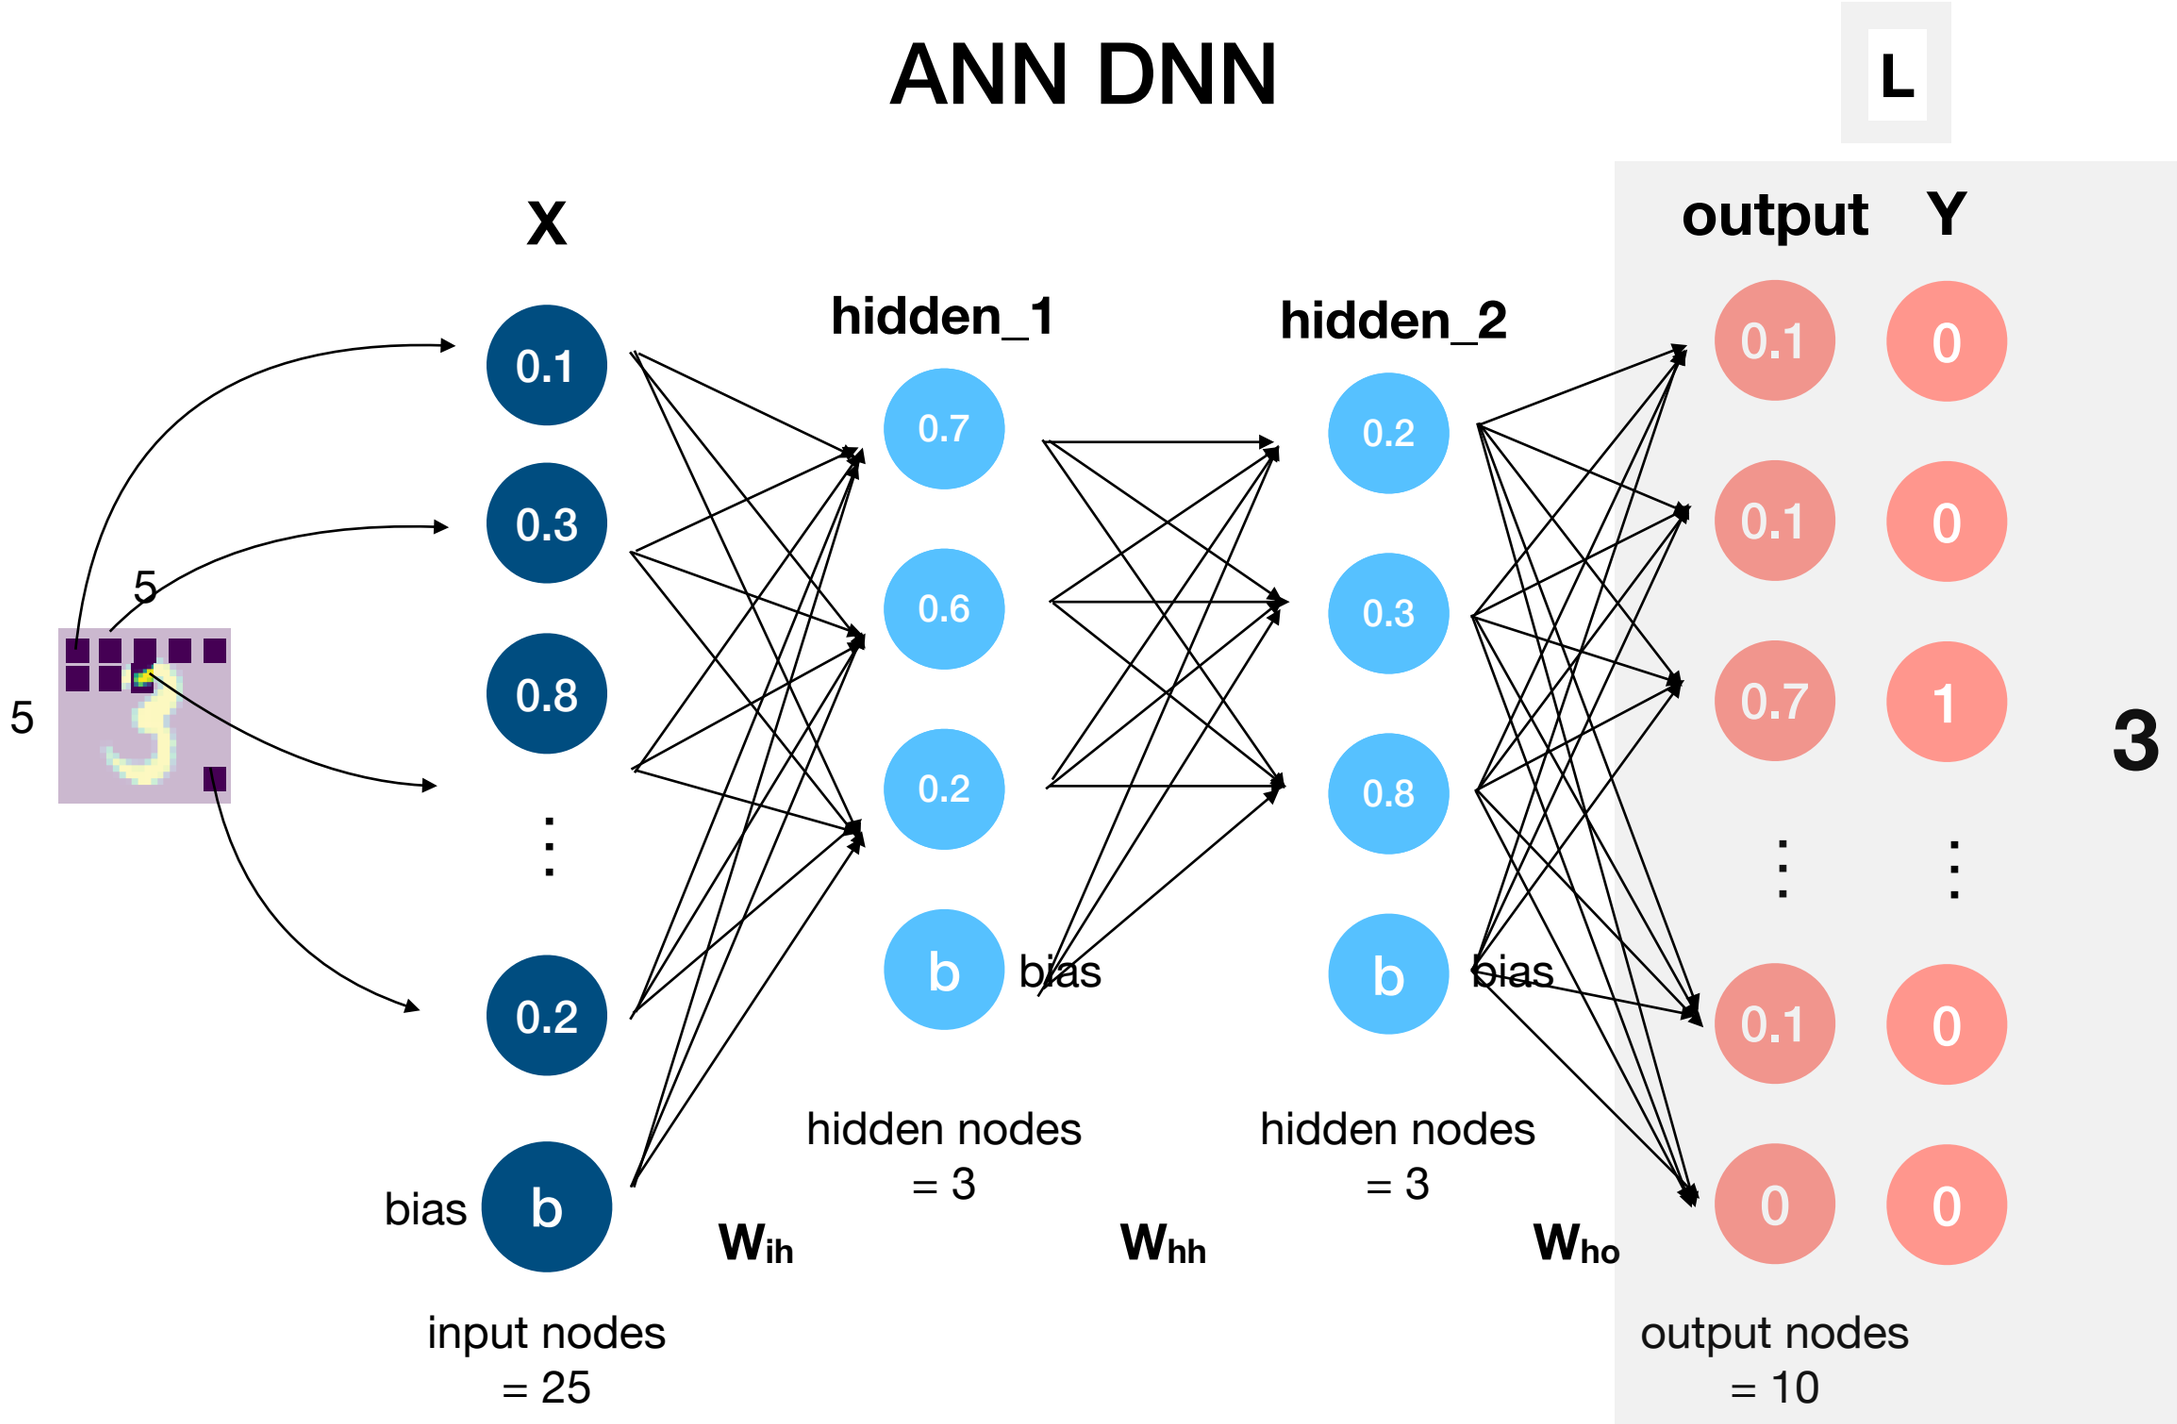

그렇게 구한 output probability와 정답 target (Y)을 비교하여 loss를 구합니다.

이 때, target은 0~9 중에 정답인 3에 해당하는
세번째 칸만 1, 나머지는 0인 one-hot vector

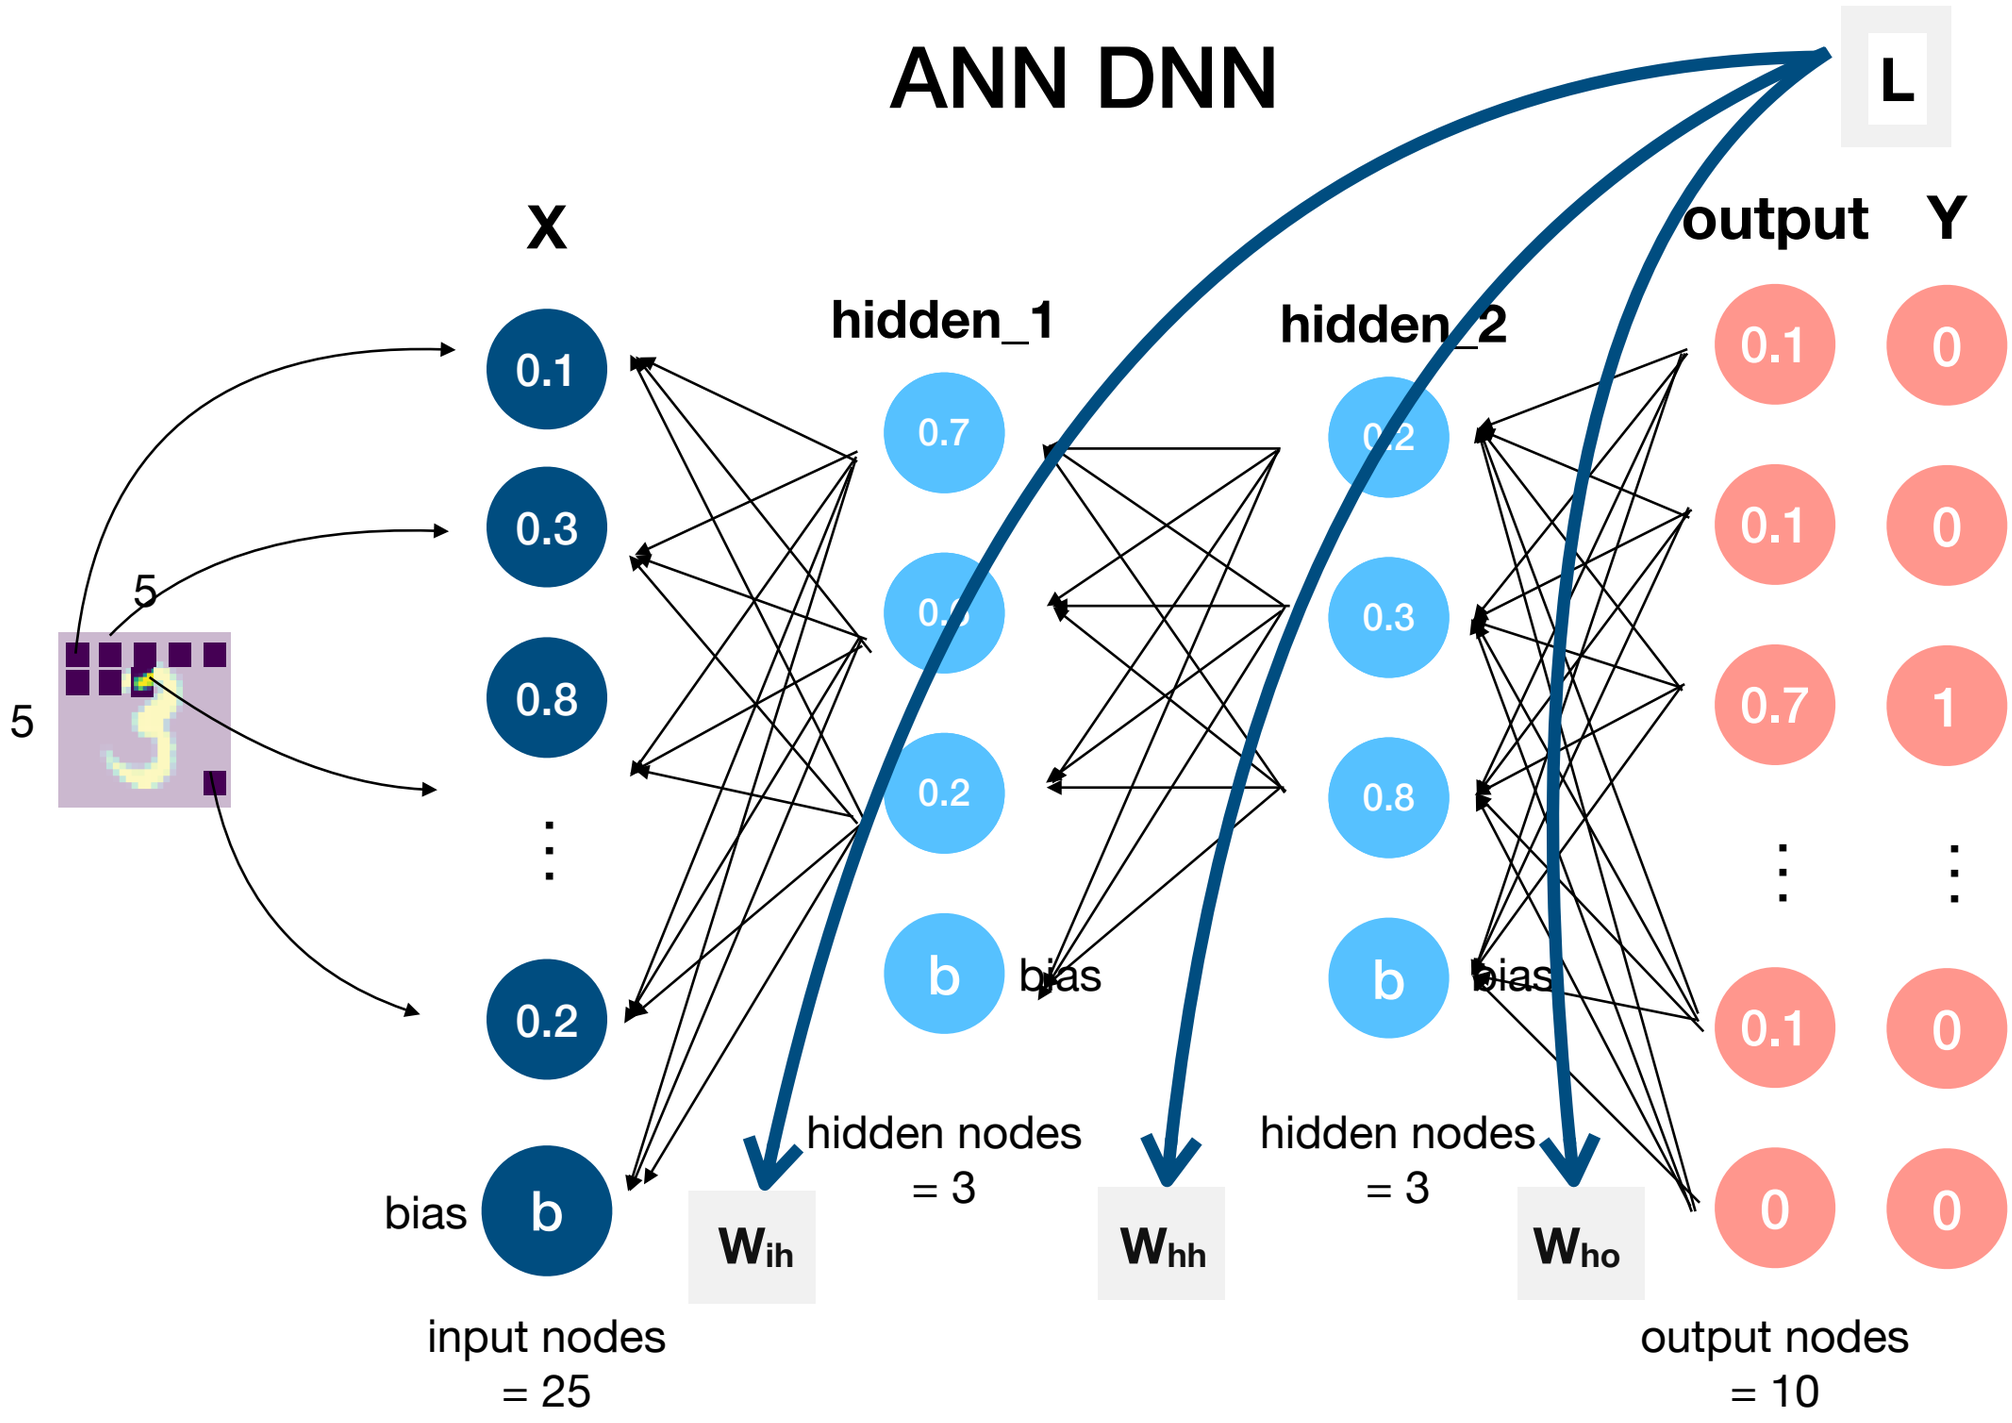

loss를 최소화하는 방향으로, weight을 update 합니다.

AE

Autoencoder

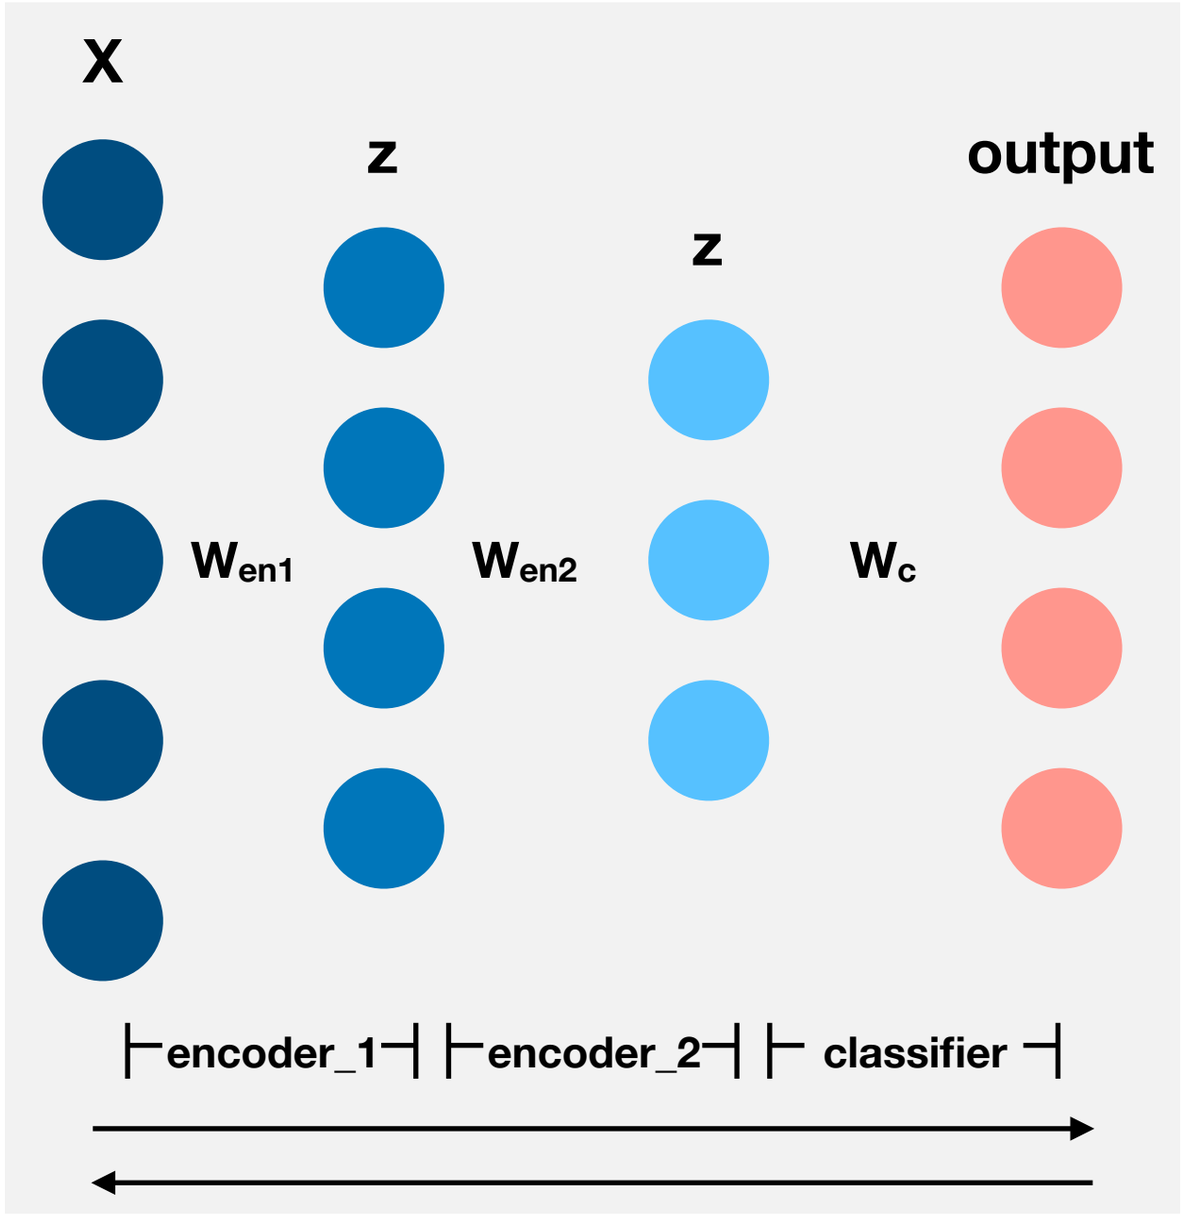

autoencoder classifier를 예시로 이해해 보겠습니다.

Autoencoder

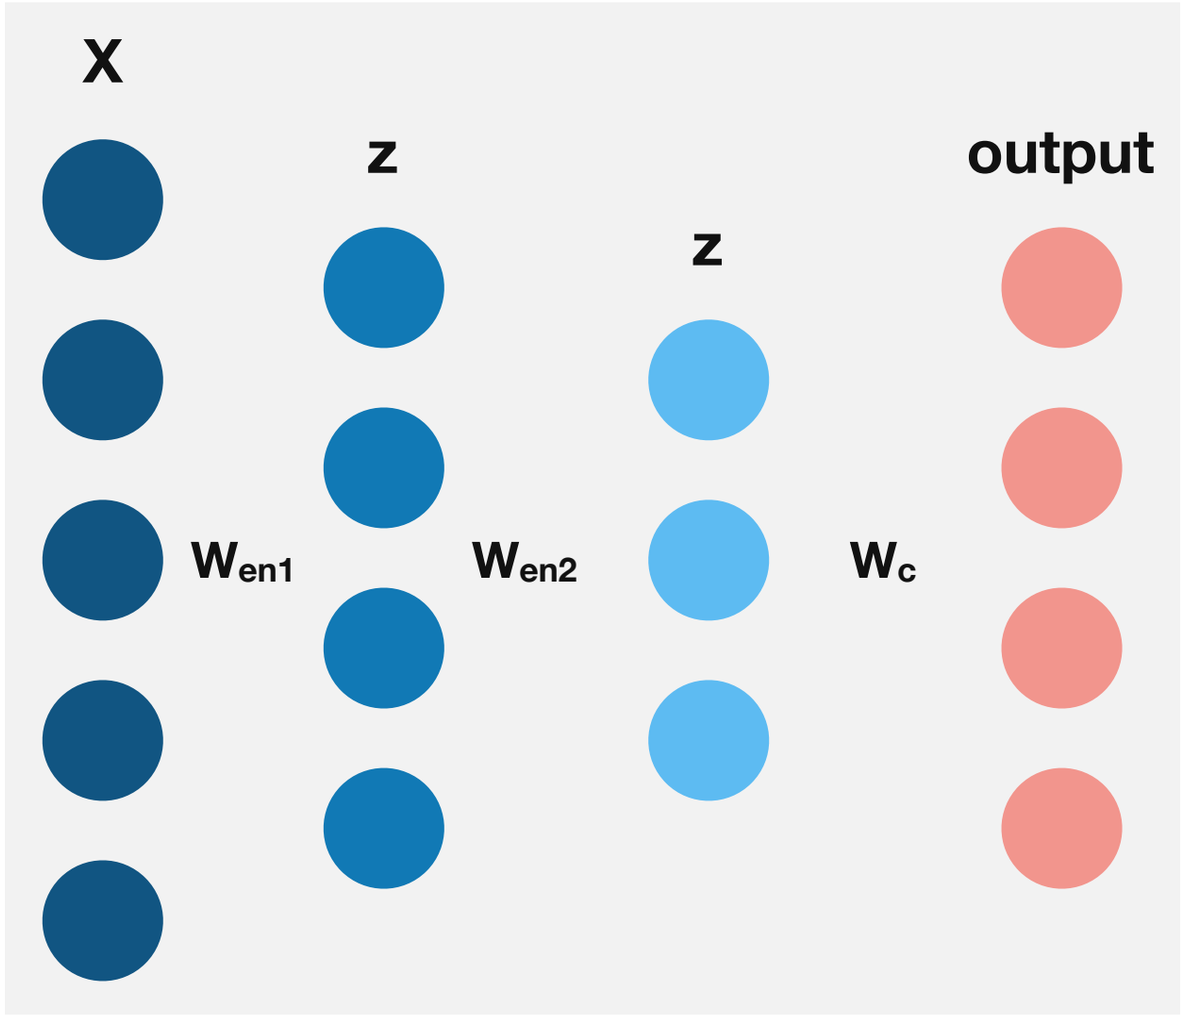

모델구조:

2 encoders
2 decoderes
1 classifier
1 fine-tuning

Autoencoder

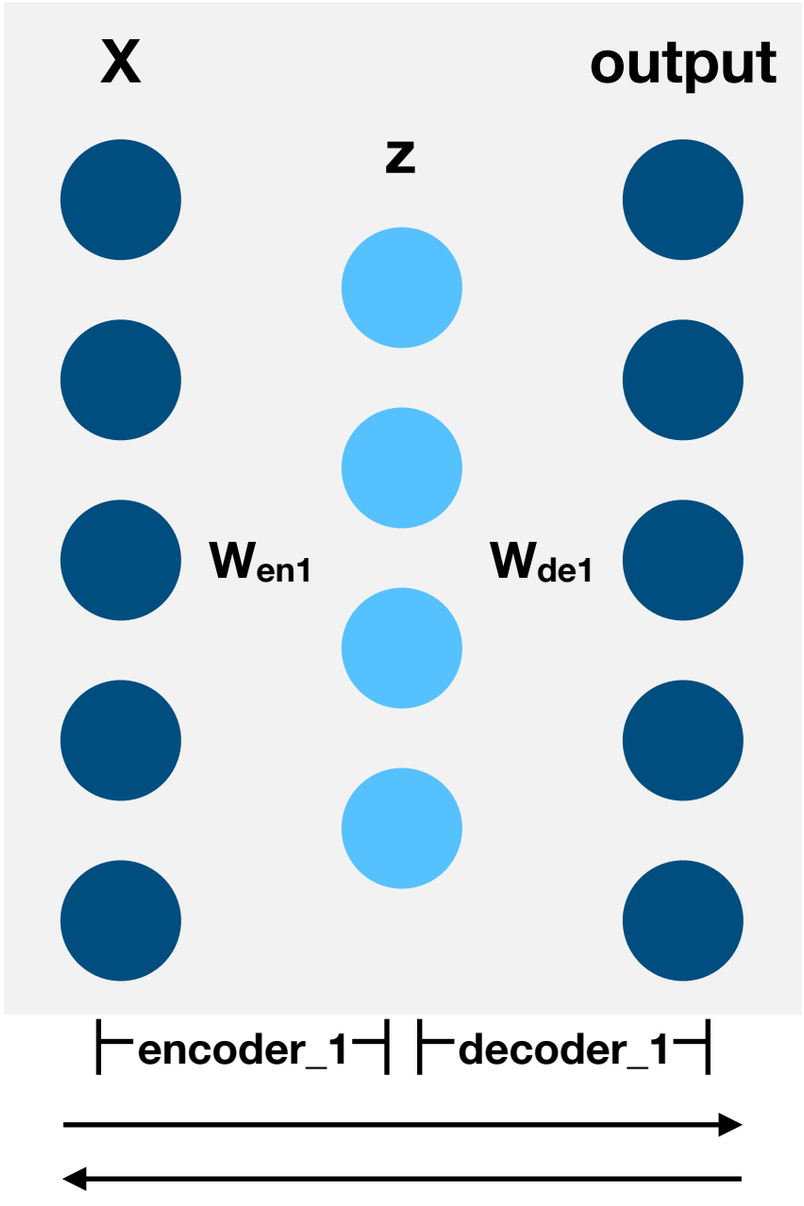

encoder_1과 decoder_1의 훈련과정

Autoencoder

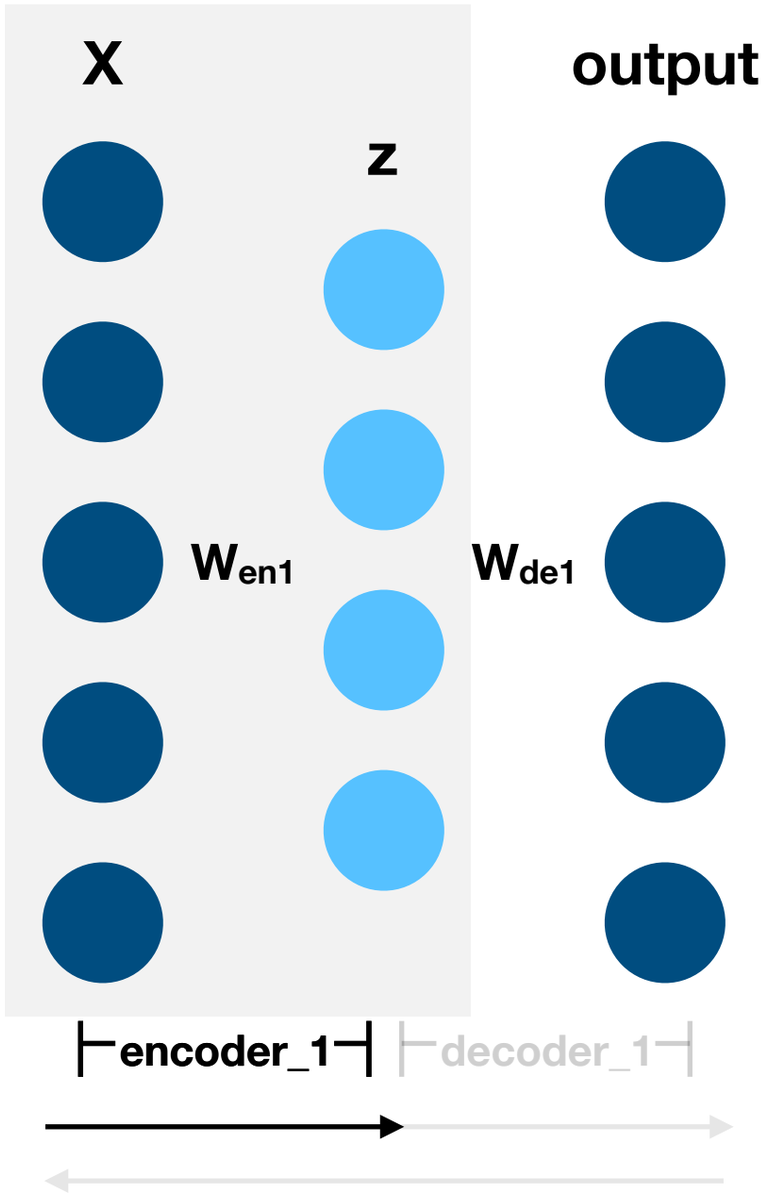

input layer에 encoder_1 weight (W_{en1})을 곱해서 z layer에 넣어줍니다.

Autoencoder

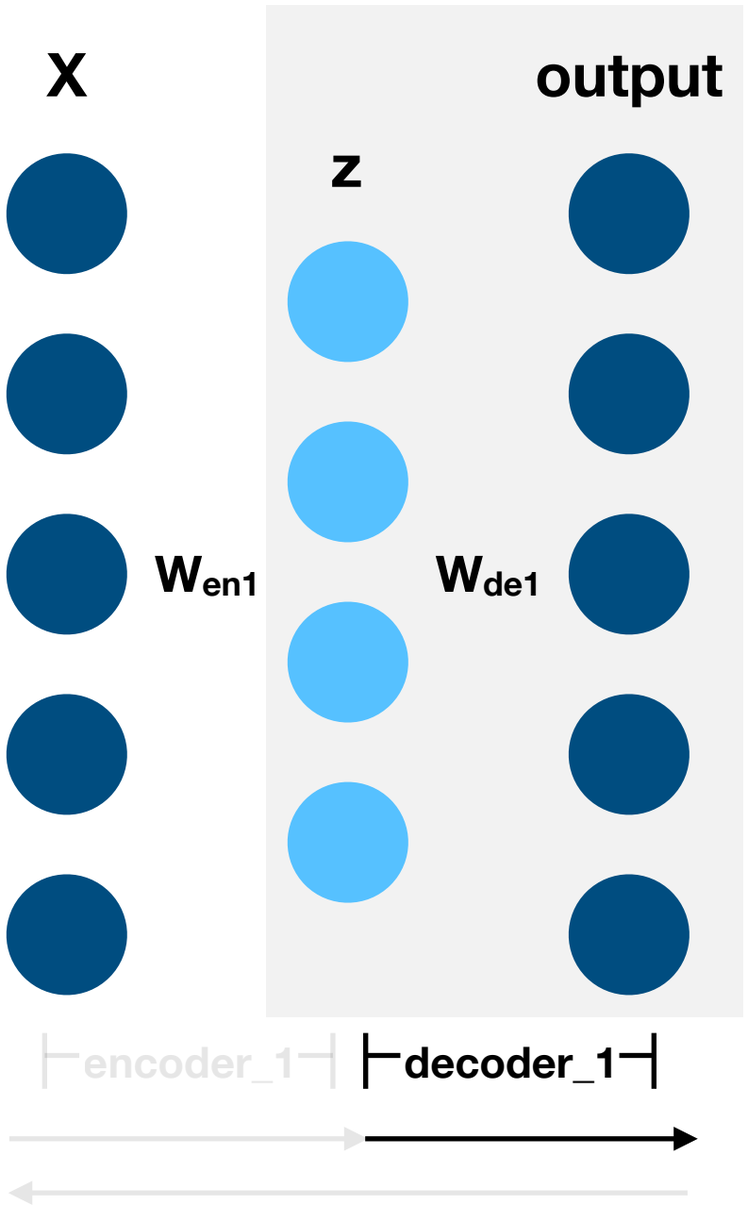

z layer에 decoder_1 weight (W_{de1})을 곱해서 output layer에 넣어줍니다.

Autoencoder

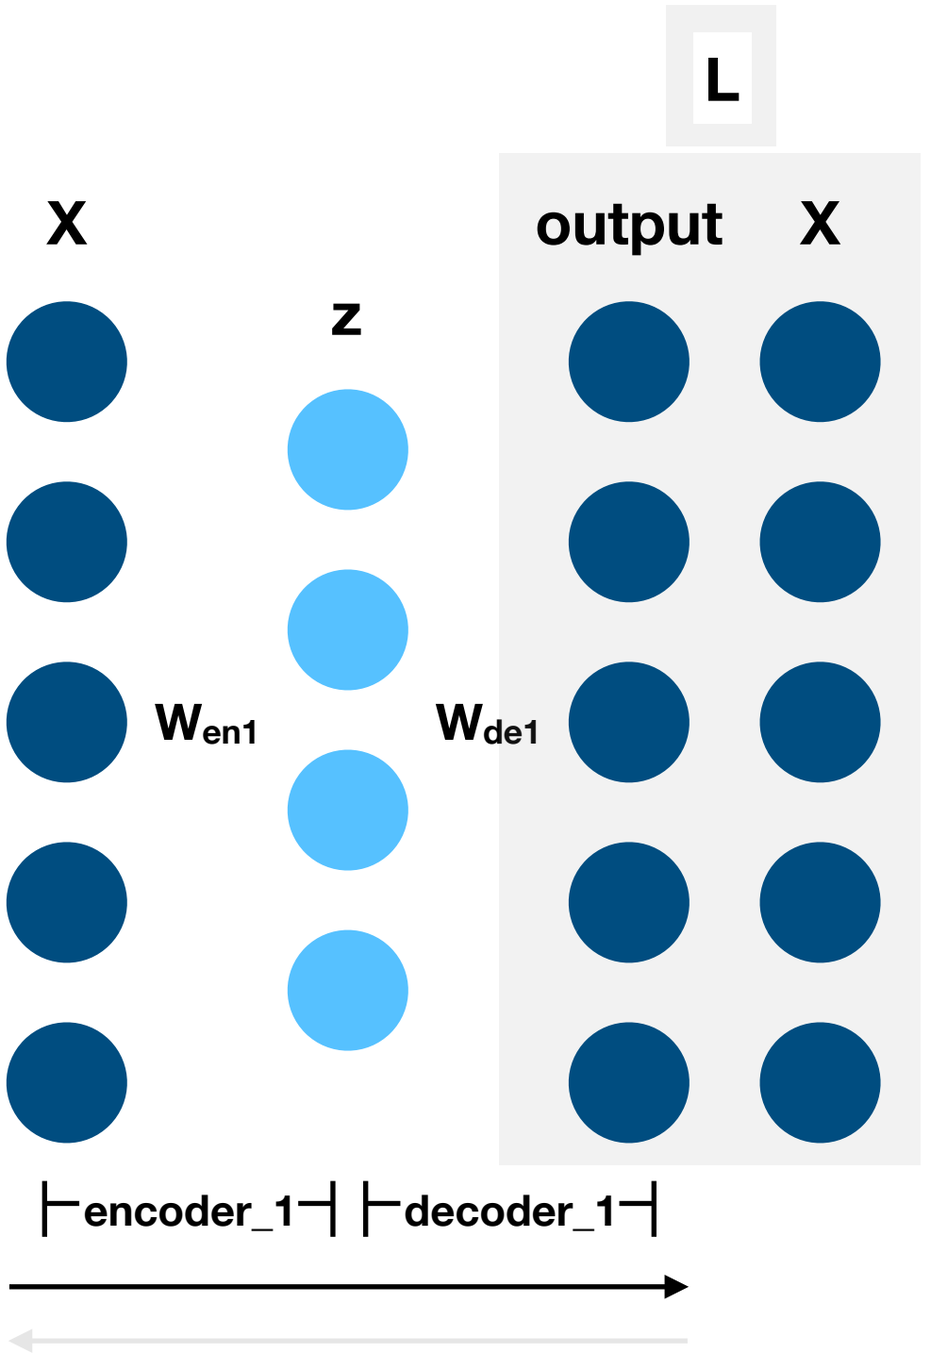

target은 input 자기 자신과 동일합니다.
output과 정답 target (X)을 비교하여 loss를 구합니다.

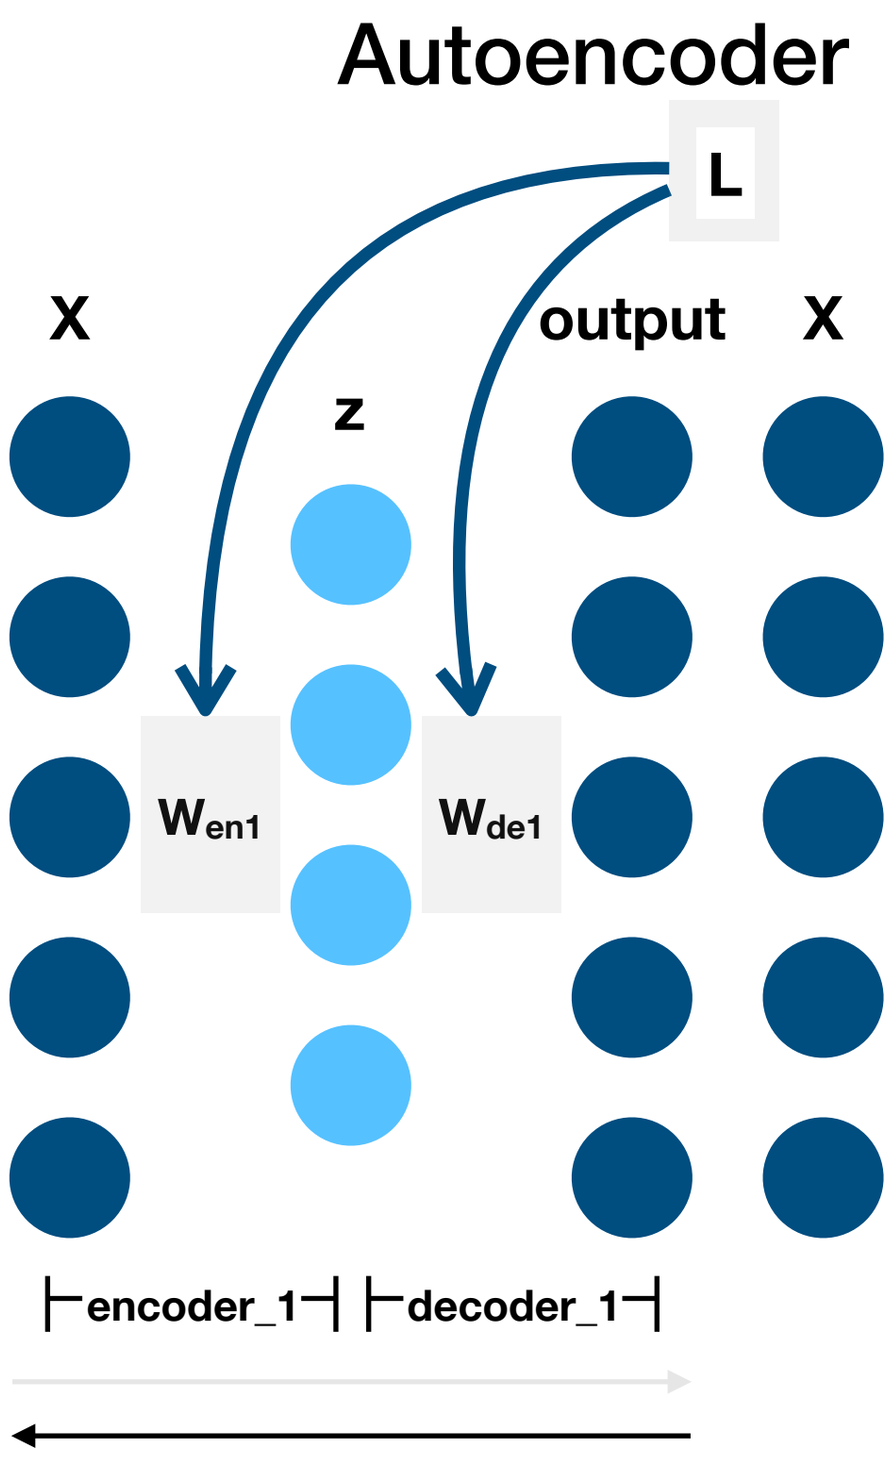

loss를 최소화하는 방향으로, weight을 update 합니다.

Autoencoder

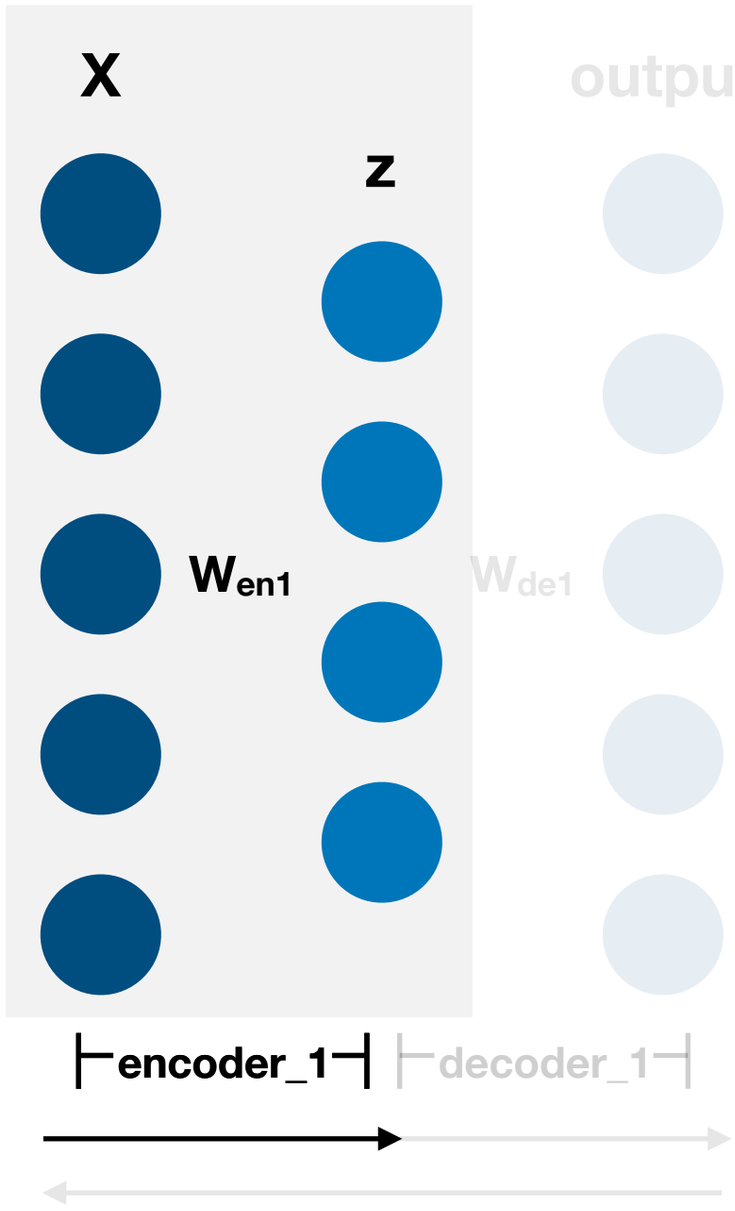

encoder_1의 훈련이 끝나면,
input을 encoder_1에 넣어 z를 구하고 이를 새로운 input Z로 삼습니다.

Autoencoder

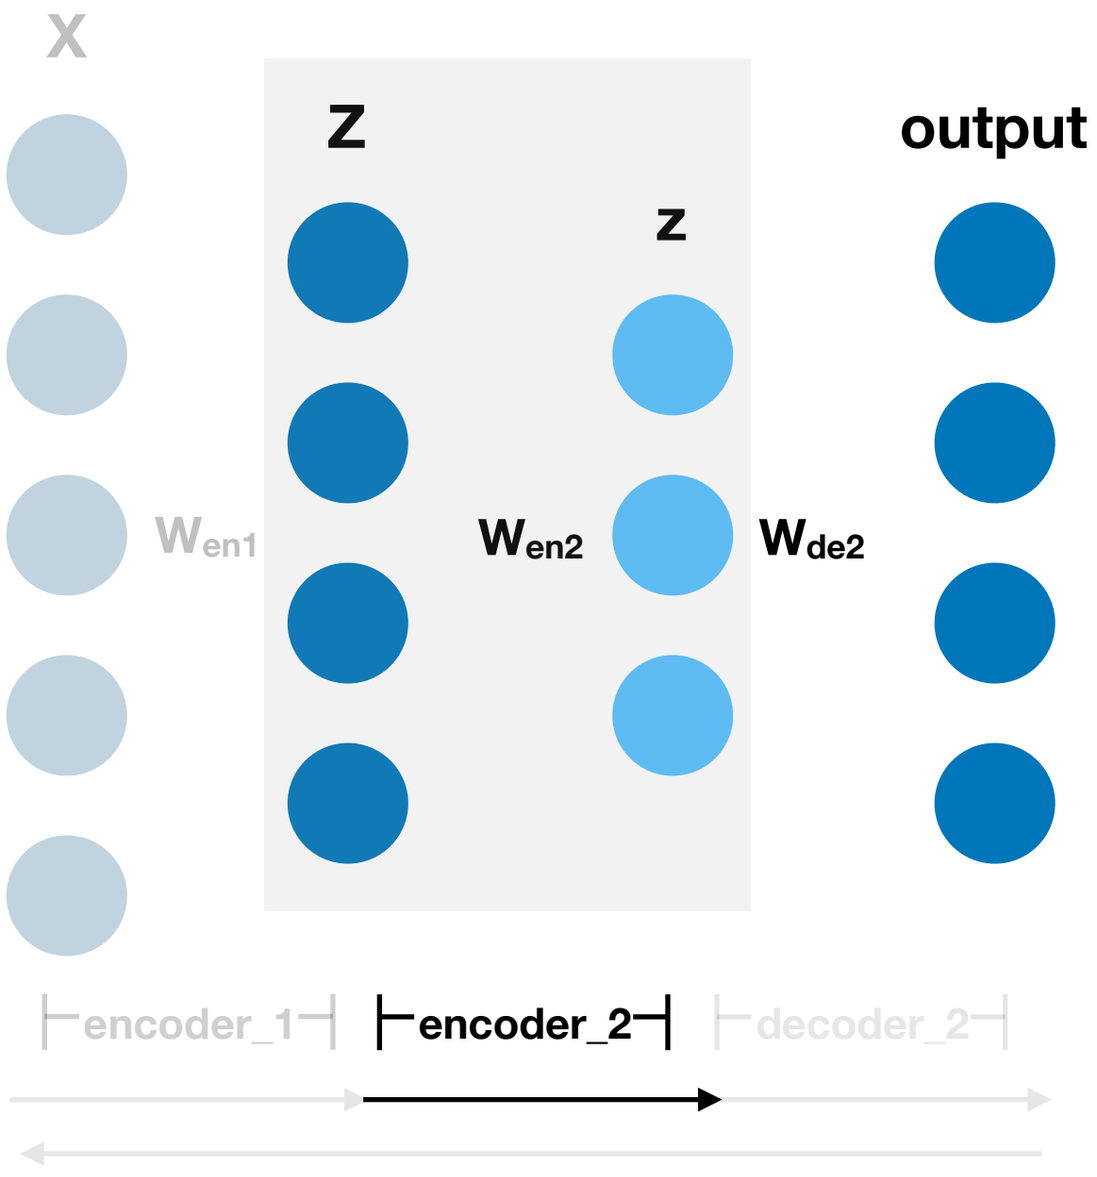

이 Z 값이 있는 layer에 encoder_2 weight (W_{en2})을 곱해서 z layer에 넣어줍니다.

Autoencoder

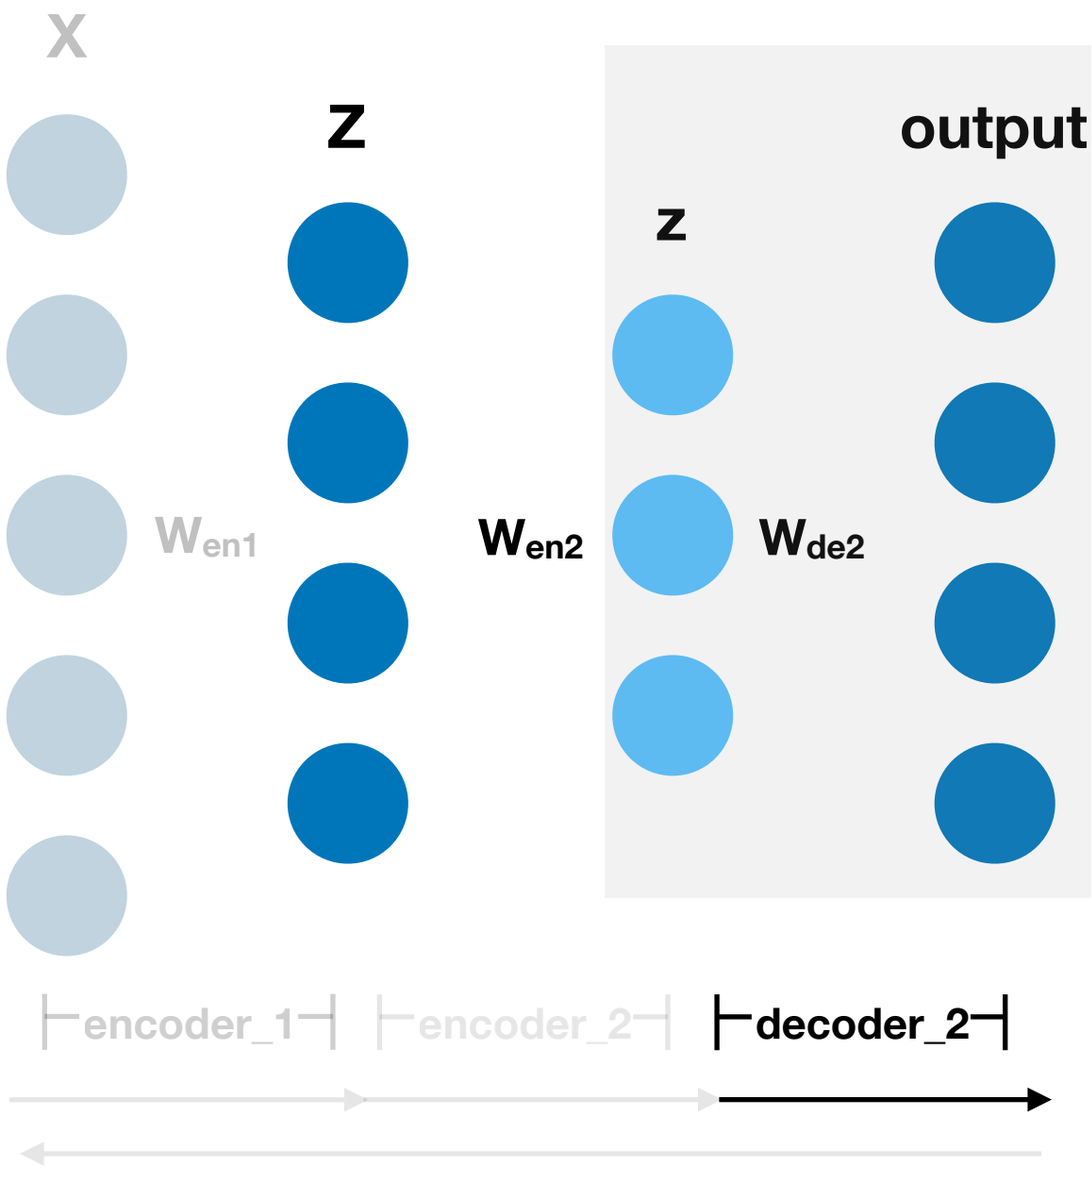

z layer에 decoder_2 weight (W_{de2})을 곱해서 output layer에 넣어줍니다.

Autoencoder

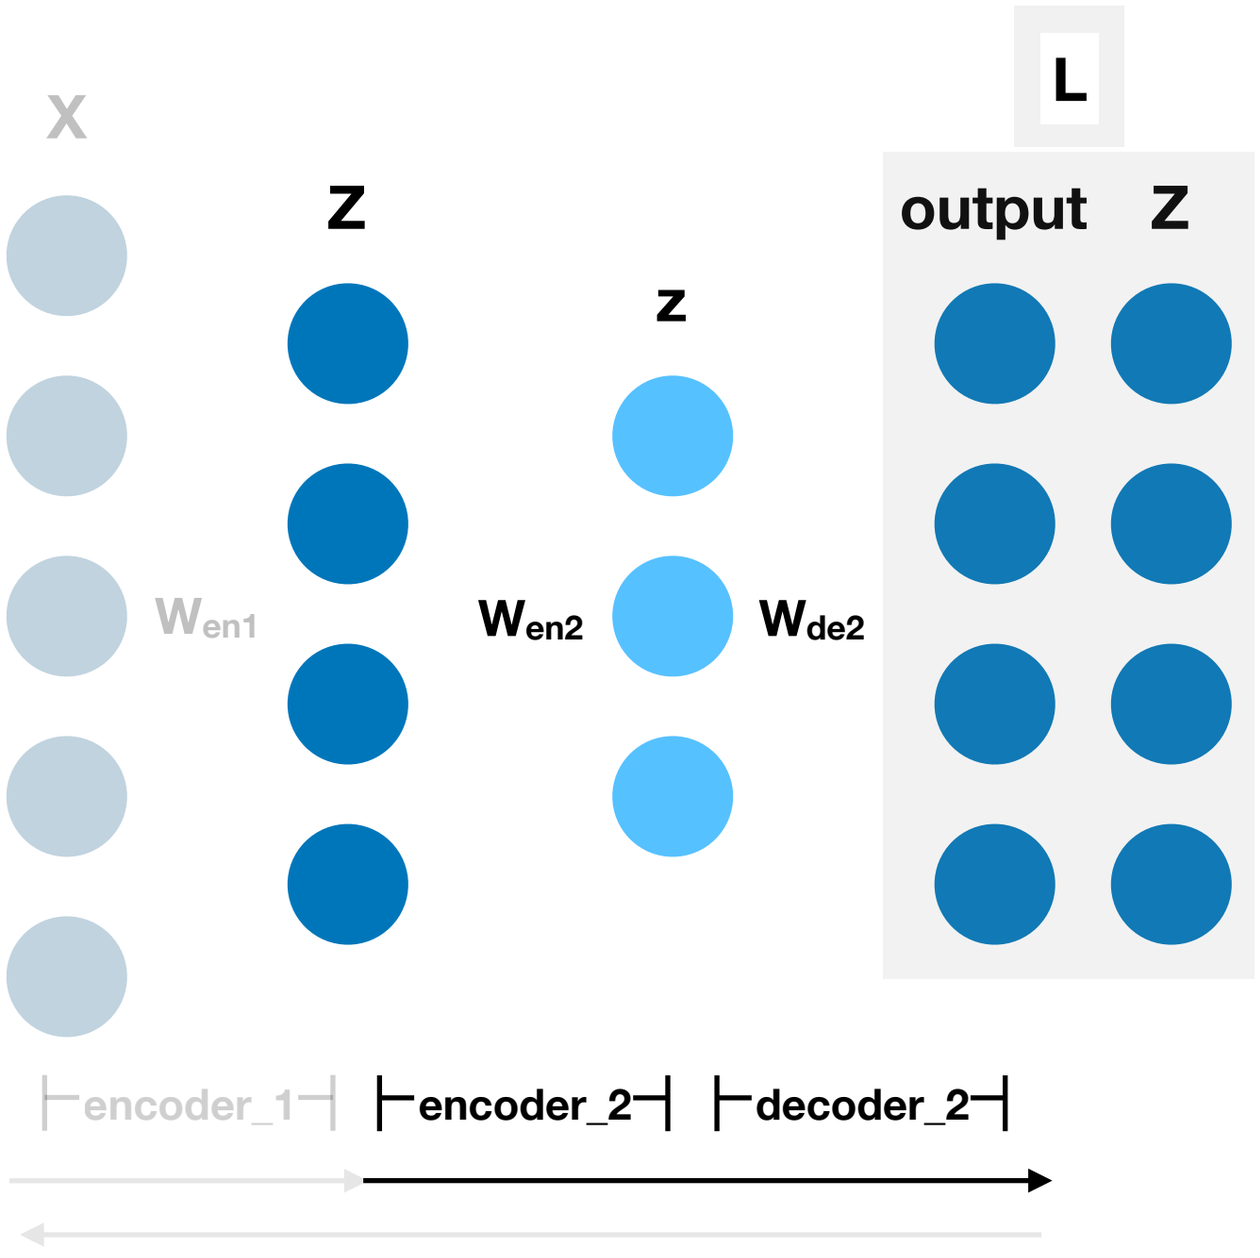

target은 Z 자기 자신과 동일합니다.
output과 정답 target (Z)을 비교하여 loss를 구합니다.

Autoencoder

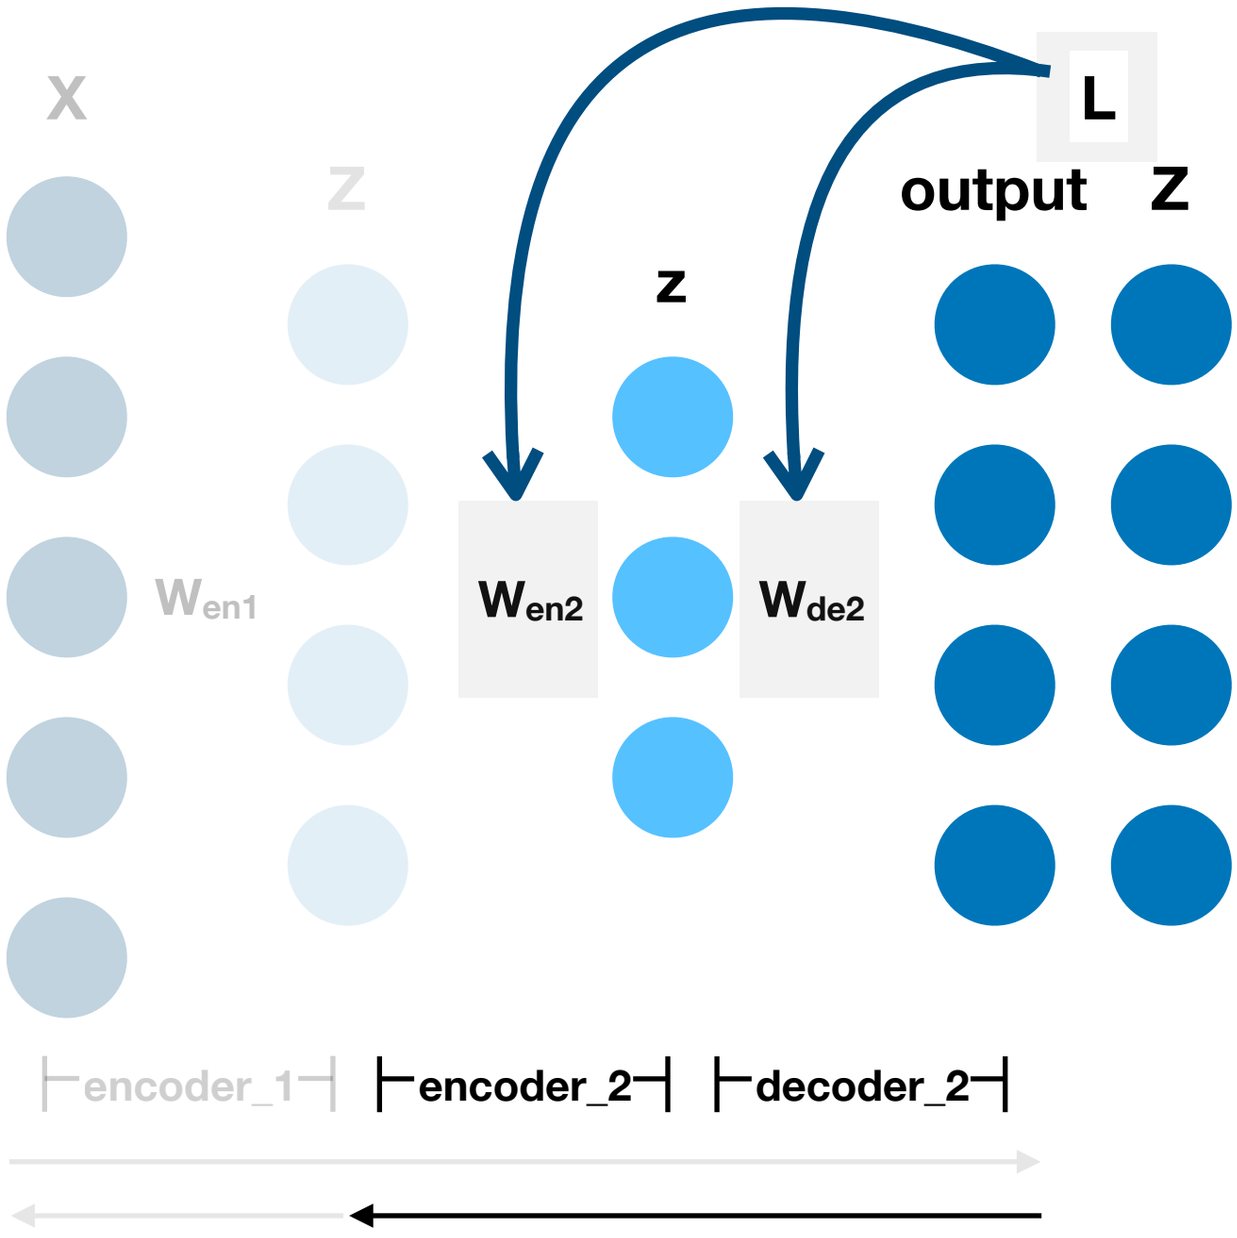

loss를 최소화하는 방향으로, weight을 update 합니다.

Autoencoder

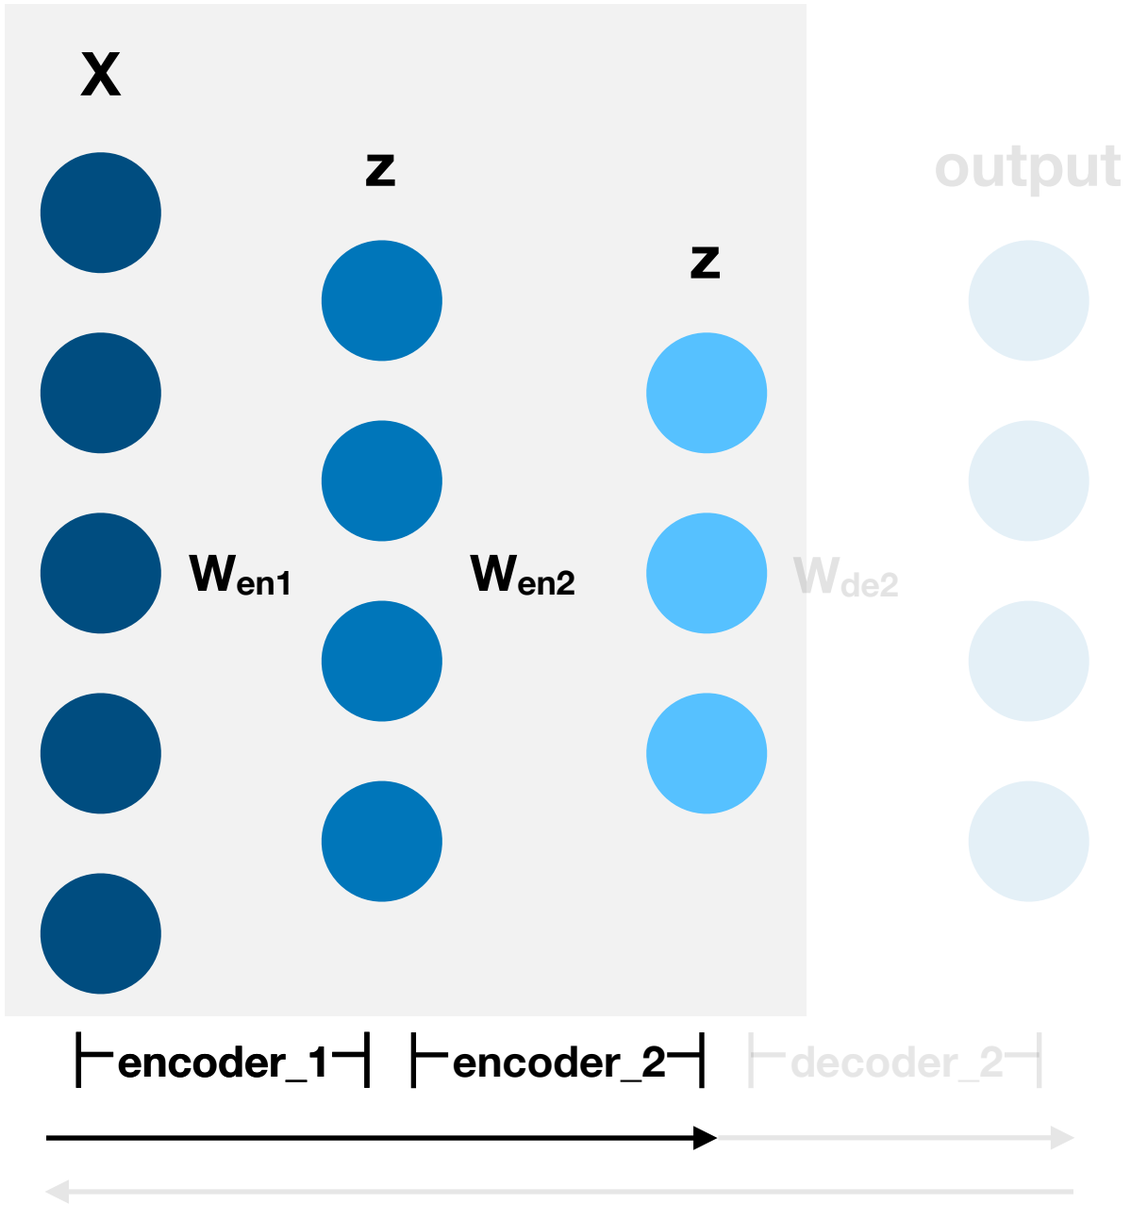

encoder 훈련이 모두 끝났습니다.
classifier 훈련을 하겠습니다.

Autoencoder

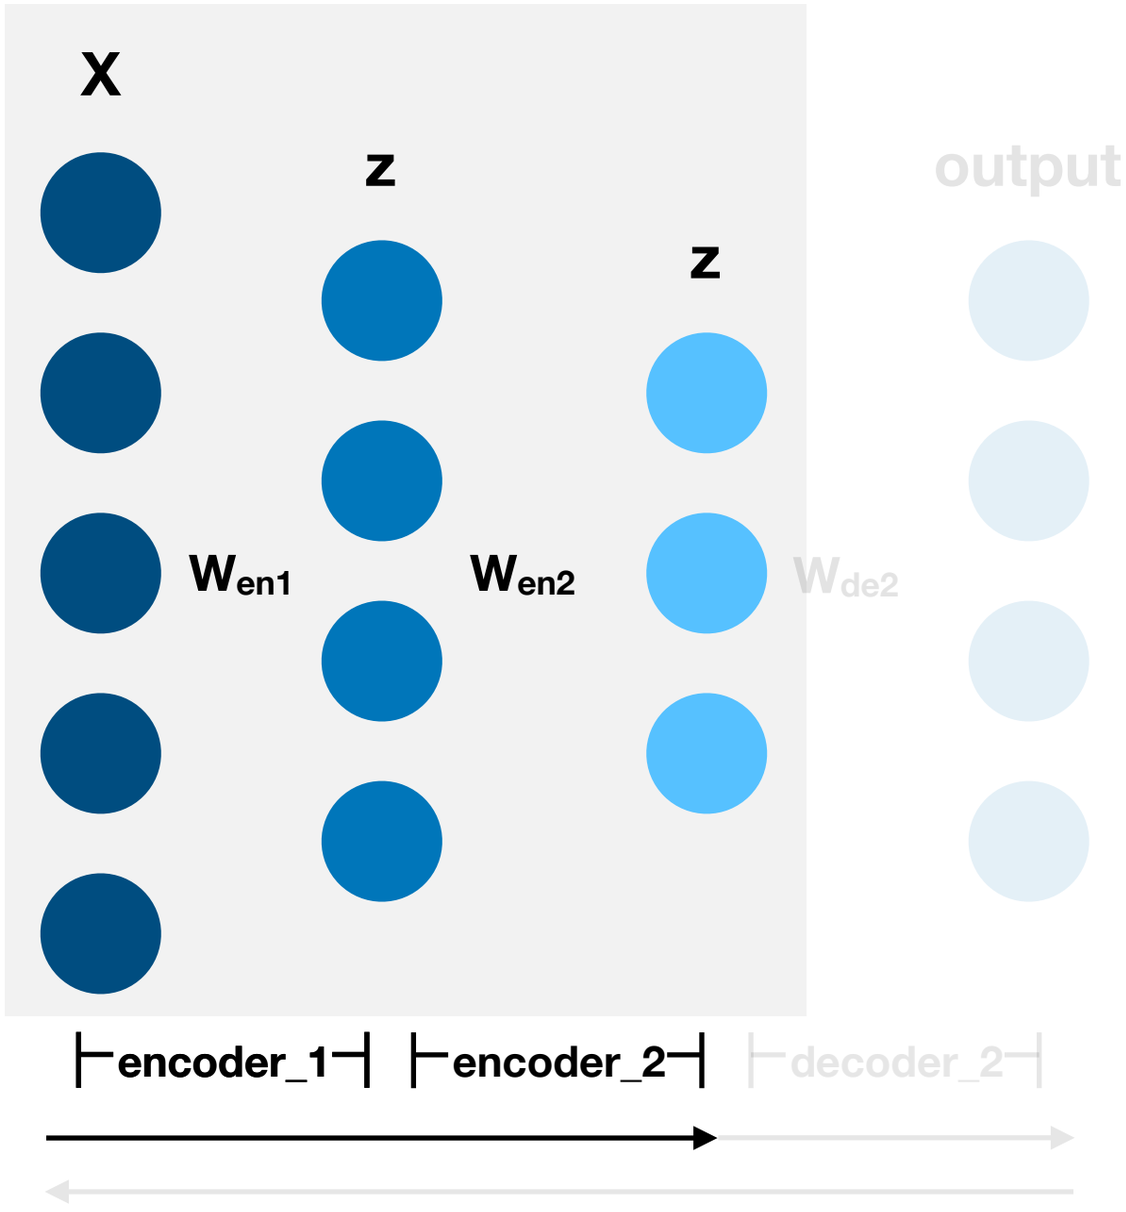

input을 encoder_1에 넣어 z를 구한 후, 다시 그 z를 encoder_2에 넣어 다음 z 값을 구합니다.
이전과 마찬가지 방식으로, 이 마지막 z를 새로운 input Z로 삼습니다.

Autoencoder

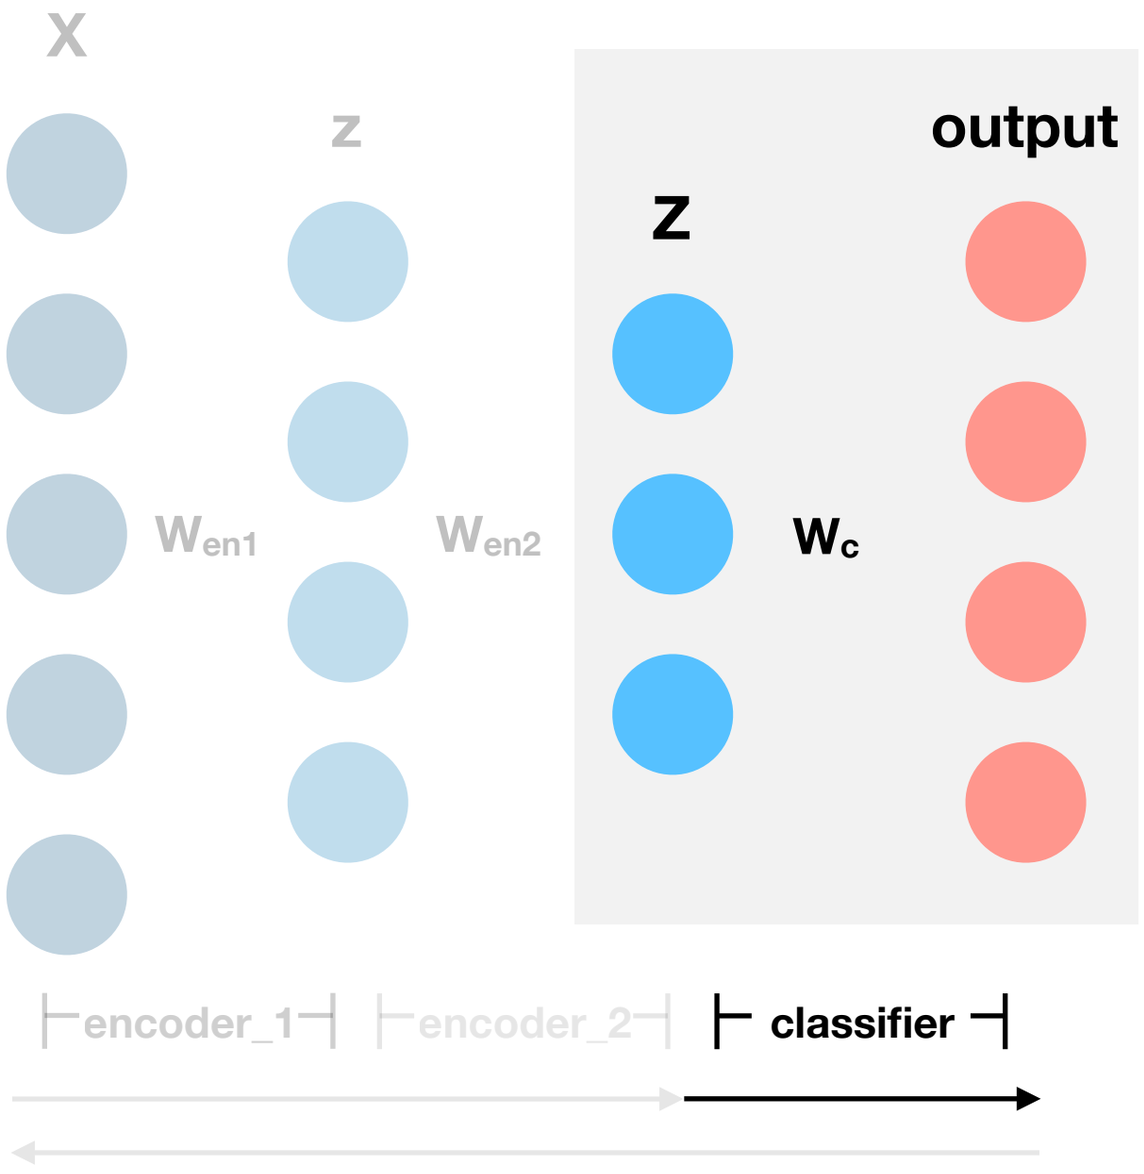

이 Z 값이 있는 layer에 classifier weight (W_c)을 곱해서 output layer에 넣어줍니다.

Autoencoder

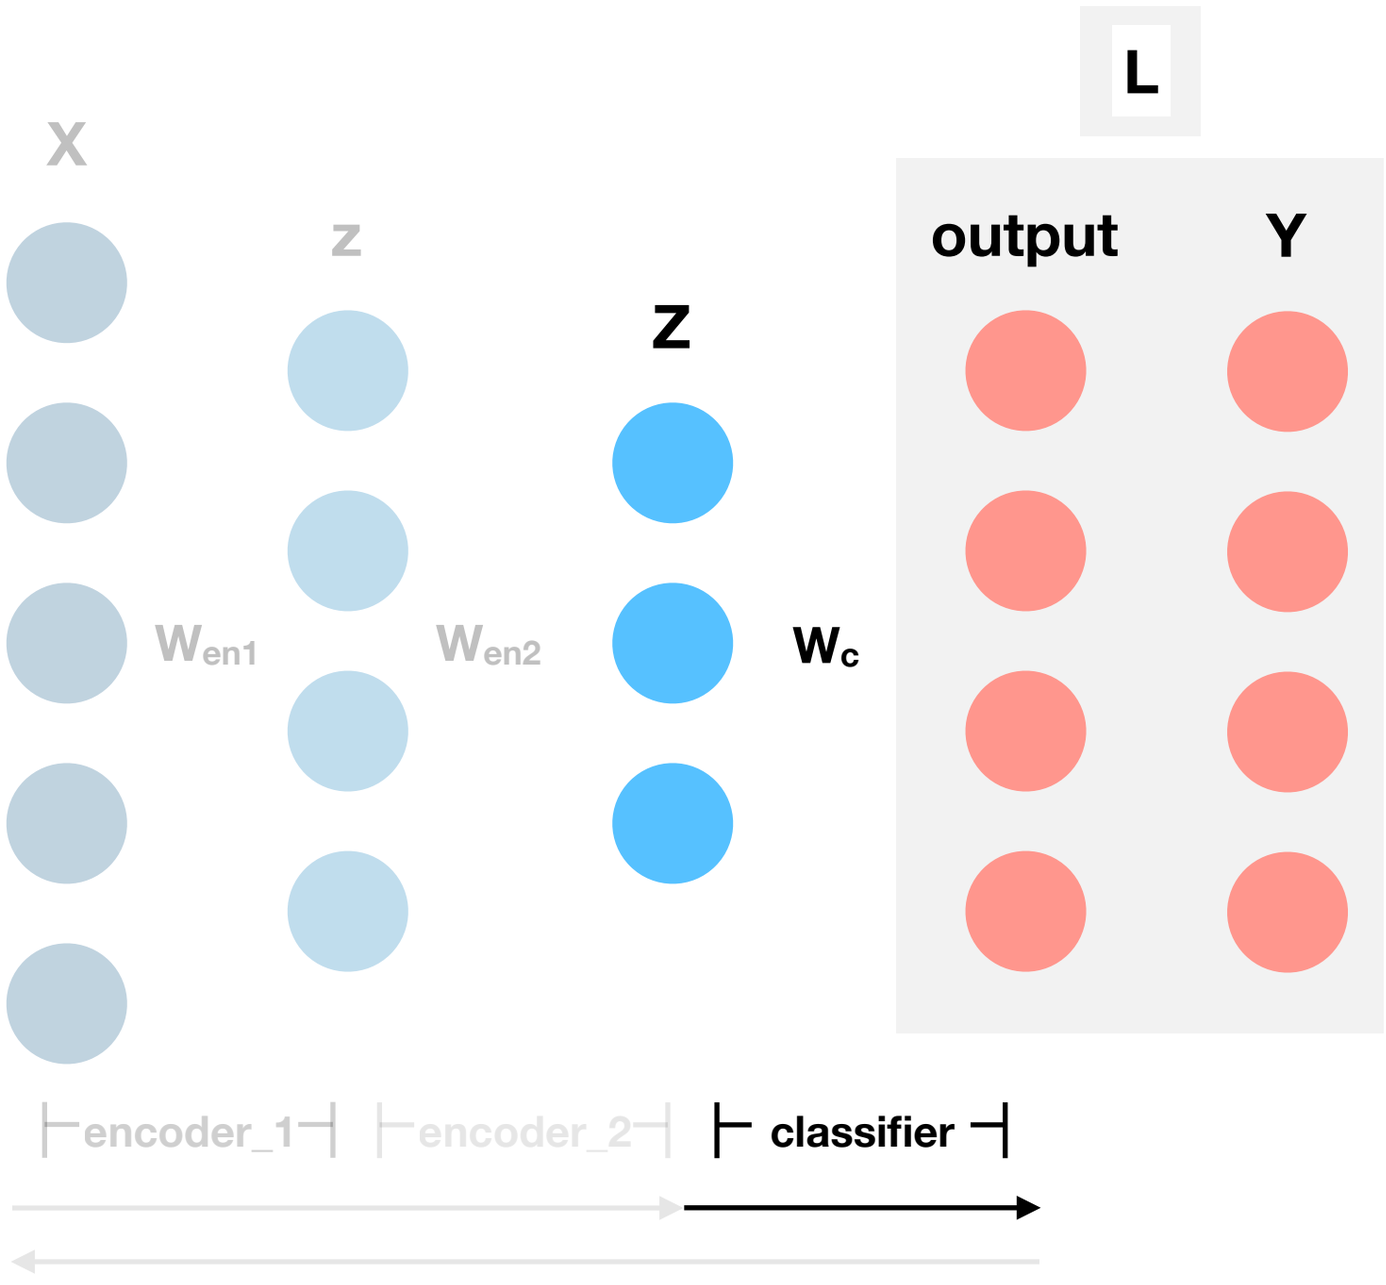

output과 정답 target (Y)을 비교하여 loss를 구합니다.

Autoencoder

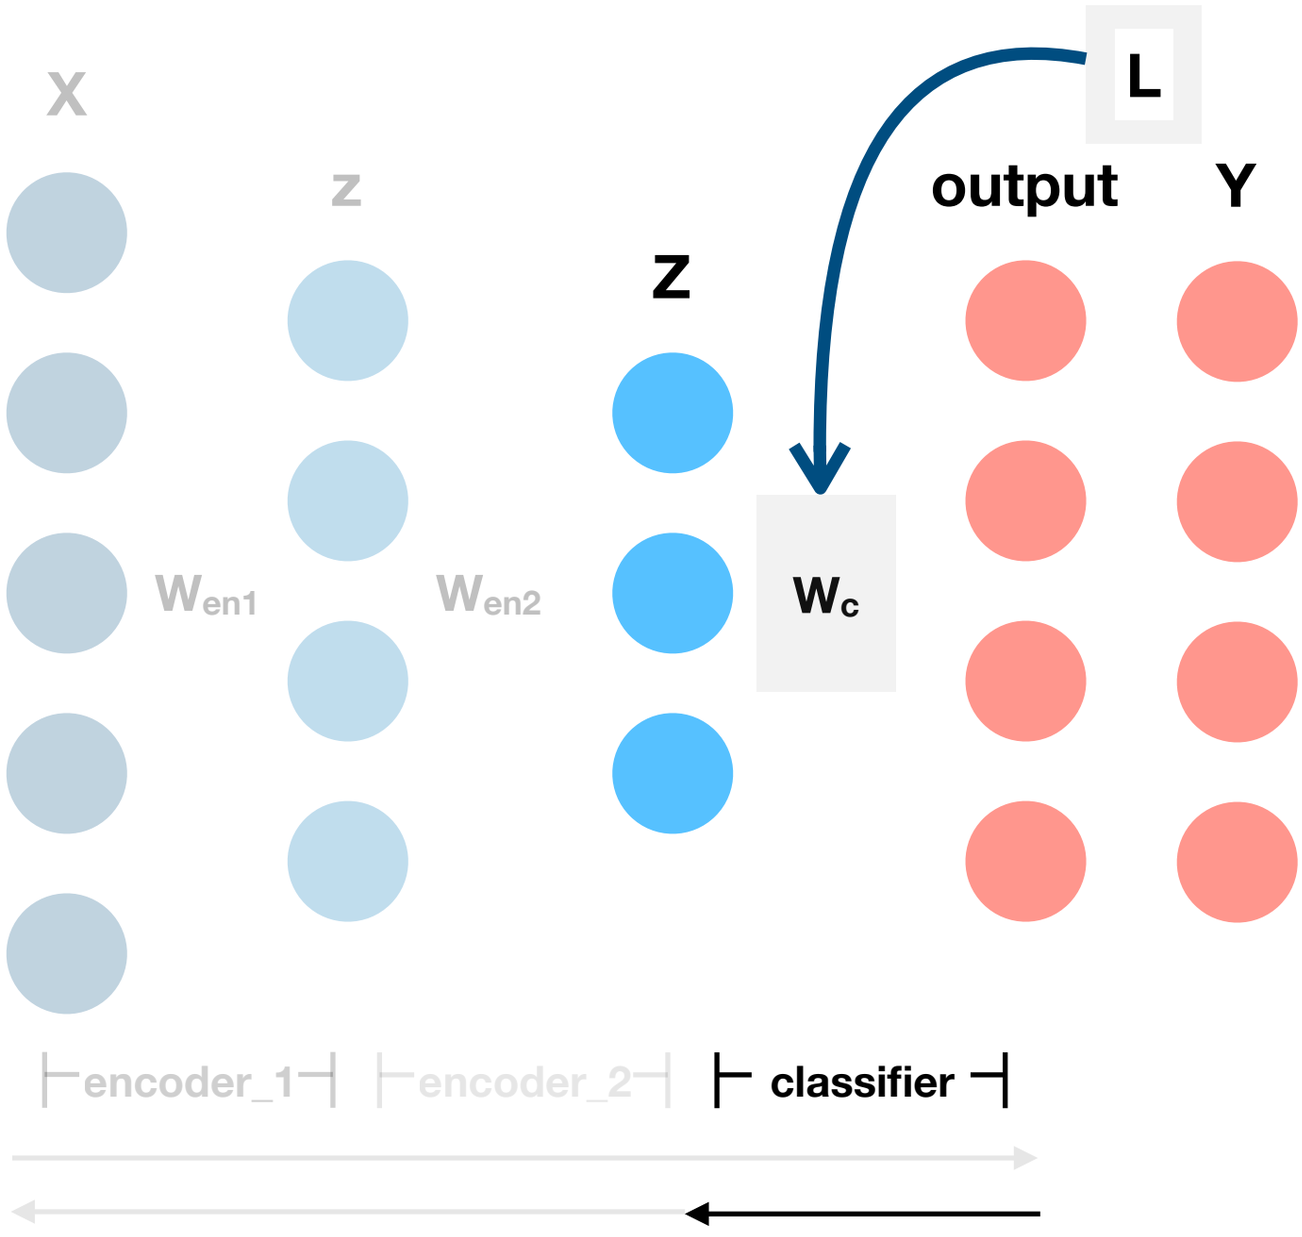

loss를 최소화하는 방향으로, weight을 update 합니다.

Autoencoder

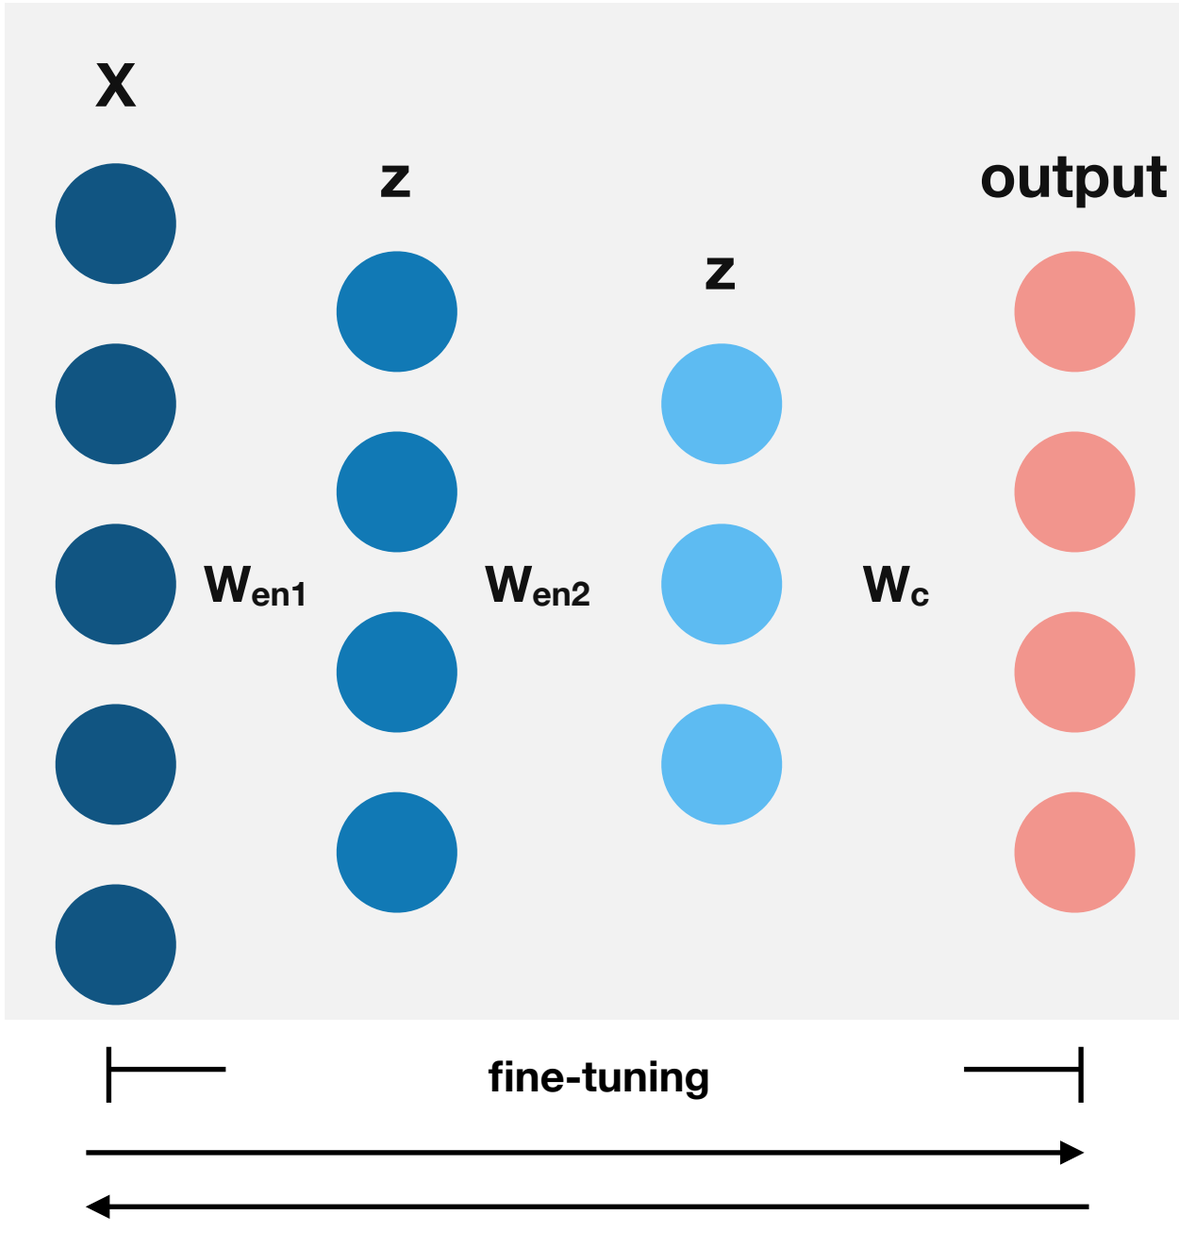

지금까지 각 layer의 weight을 따로 훈련했기 때문에,
마지막으로 모든 weight을 한꺼번에 조정해주는 fine-tuning을 해줍니다.

이 과정은 ANN 훈련 과정과 동일

CNN

Convolution

image

0	0	1	1	0
0	1	0	1	0
0	0	0	1	0
0	0	1	0	0
0	1	1	1	0

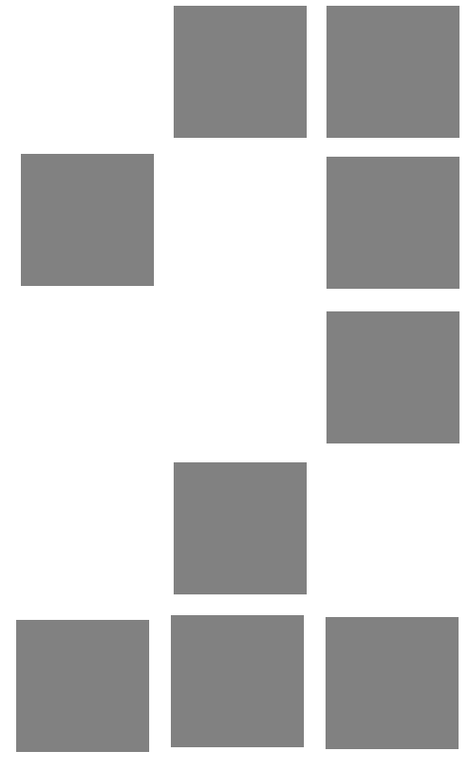

숫자 2의 이미지

Convolution

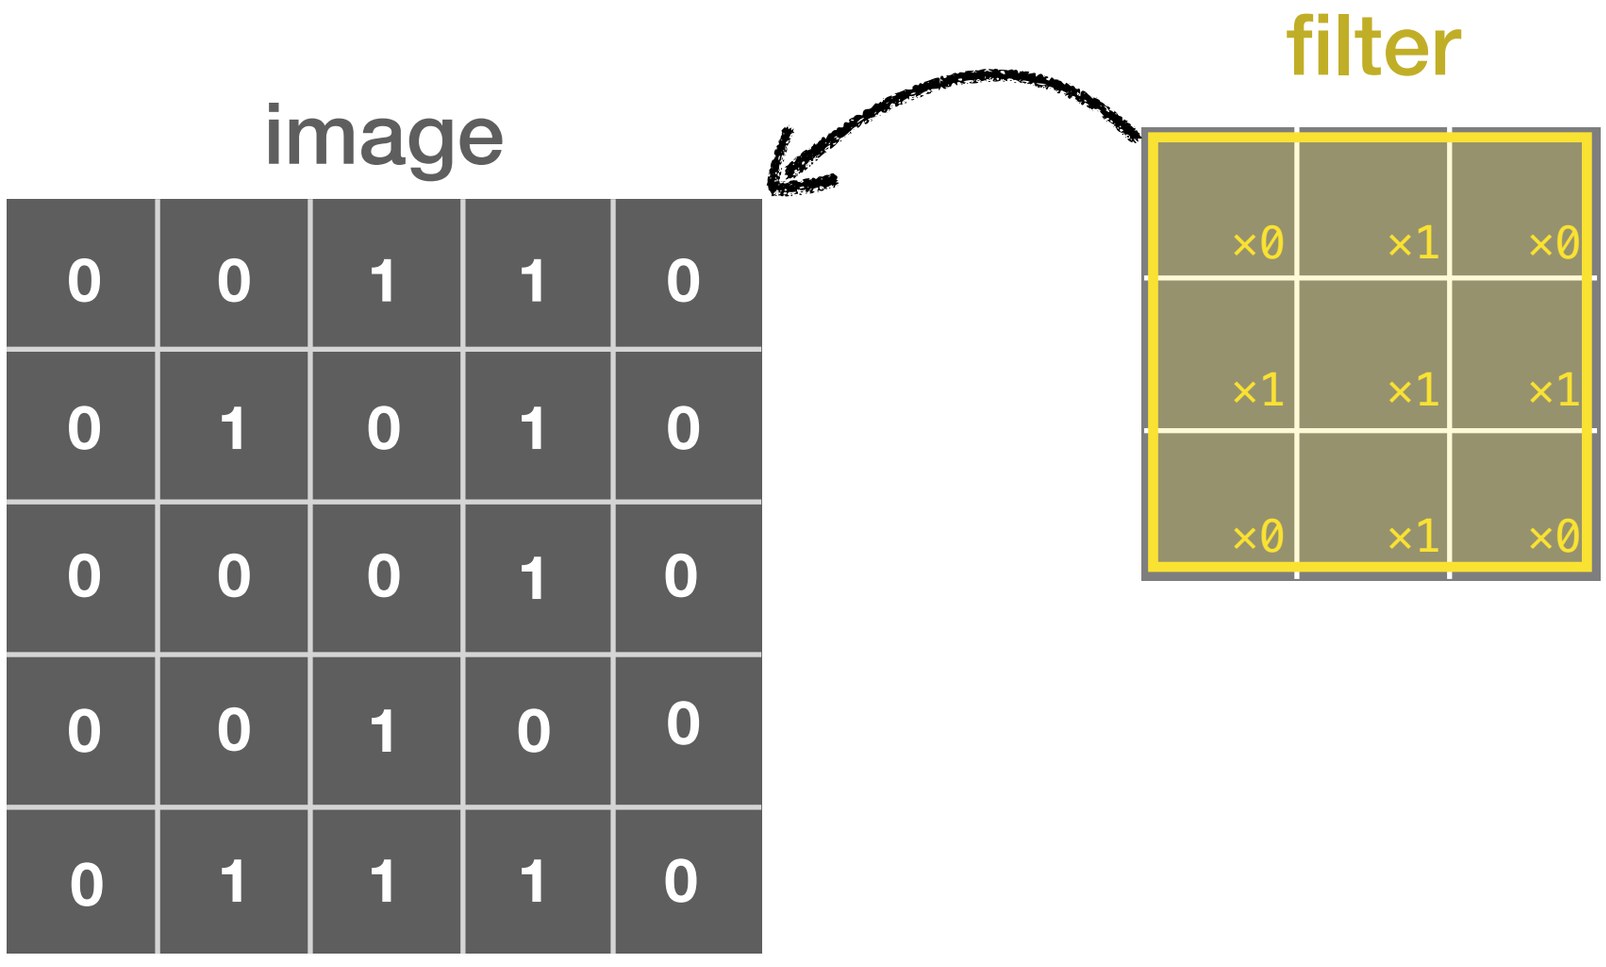

이미지 위에 필터를 씌웁니다.

Convolution

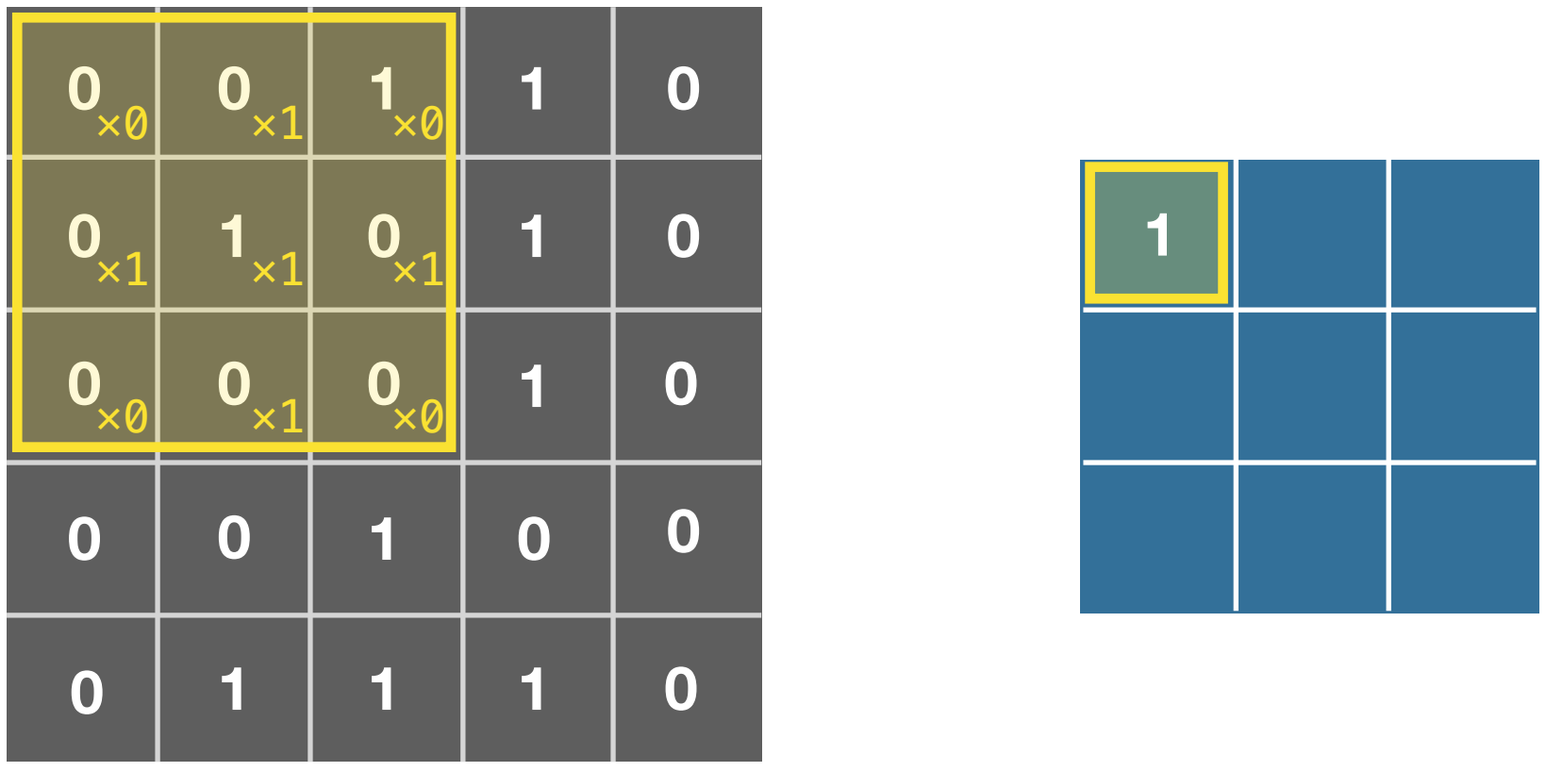

필터는 ANN에서의 weight과 같은 역할을 합니다.
필터의 각 노란색 weight 값과 이미지의 각 회색 pixel 값을 곱해서 합을 구합니다.

[0 0 1; 0 1 0; 0 0 0] ∘ [0 1 0; 1 1 1; 0 1 0] = 1

Convolution

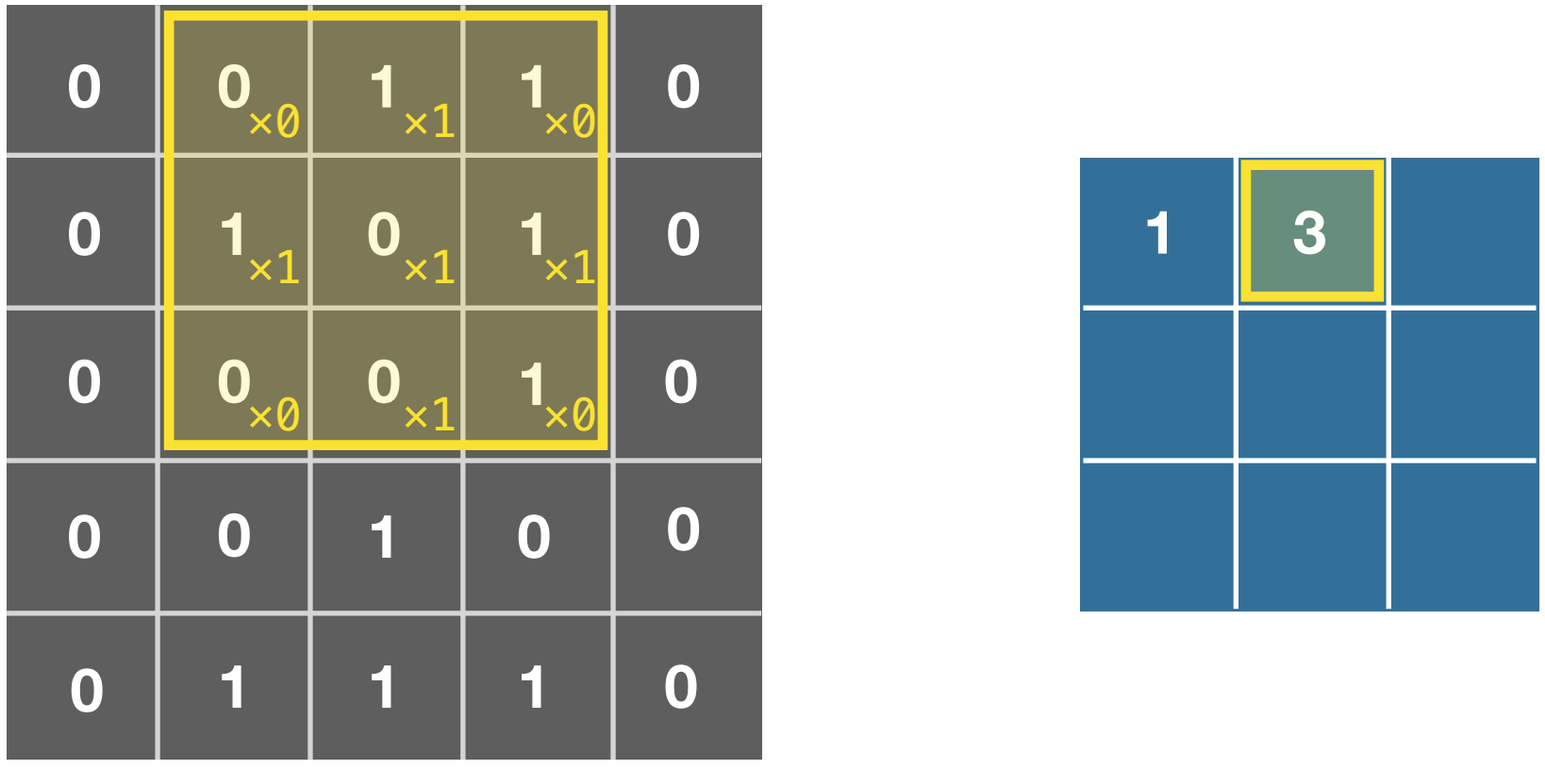

필터를 한 칸씩 옮겨가면서 값을 구해 새로운 파란색 matrix를 채워갑니다.
여기에선 필터를 한 칸씩 옮겼지만 몇 칸씩 옮길지를 설정할 수 있는데, 이것을 stride라고 합니다.

Convolution

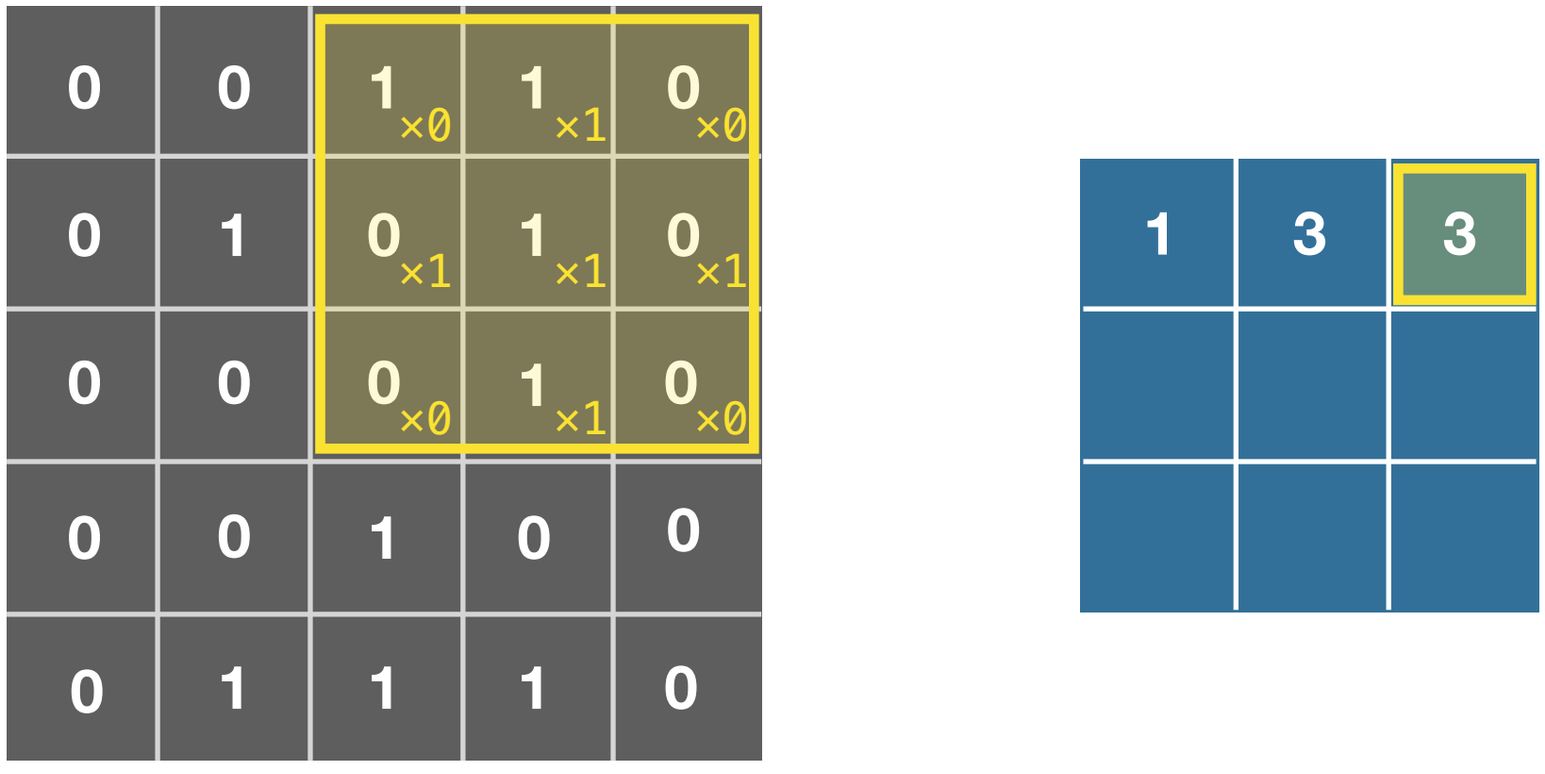

이 과정을 반복합니다.

Convolution

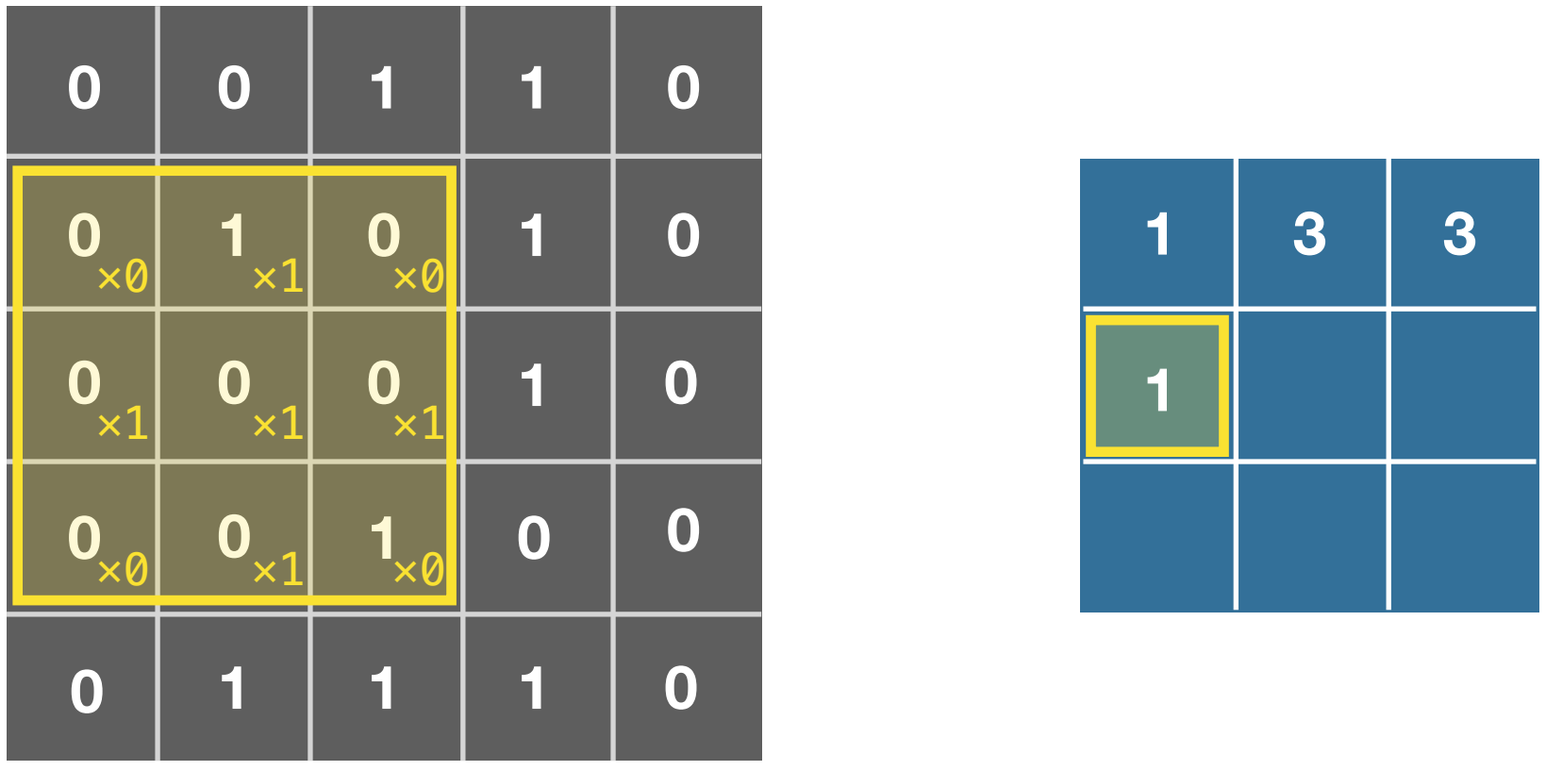

이 과정을 반복합니다.

Convolution

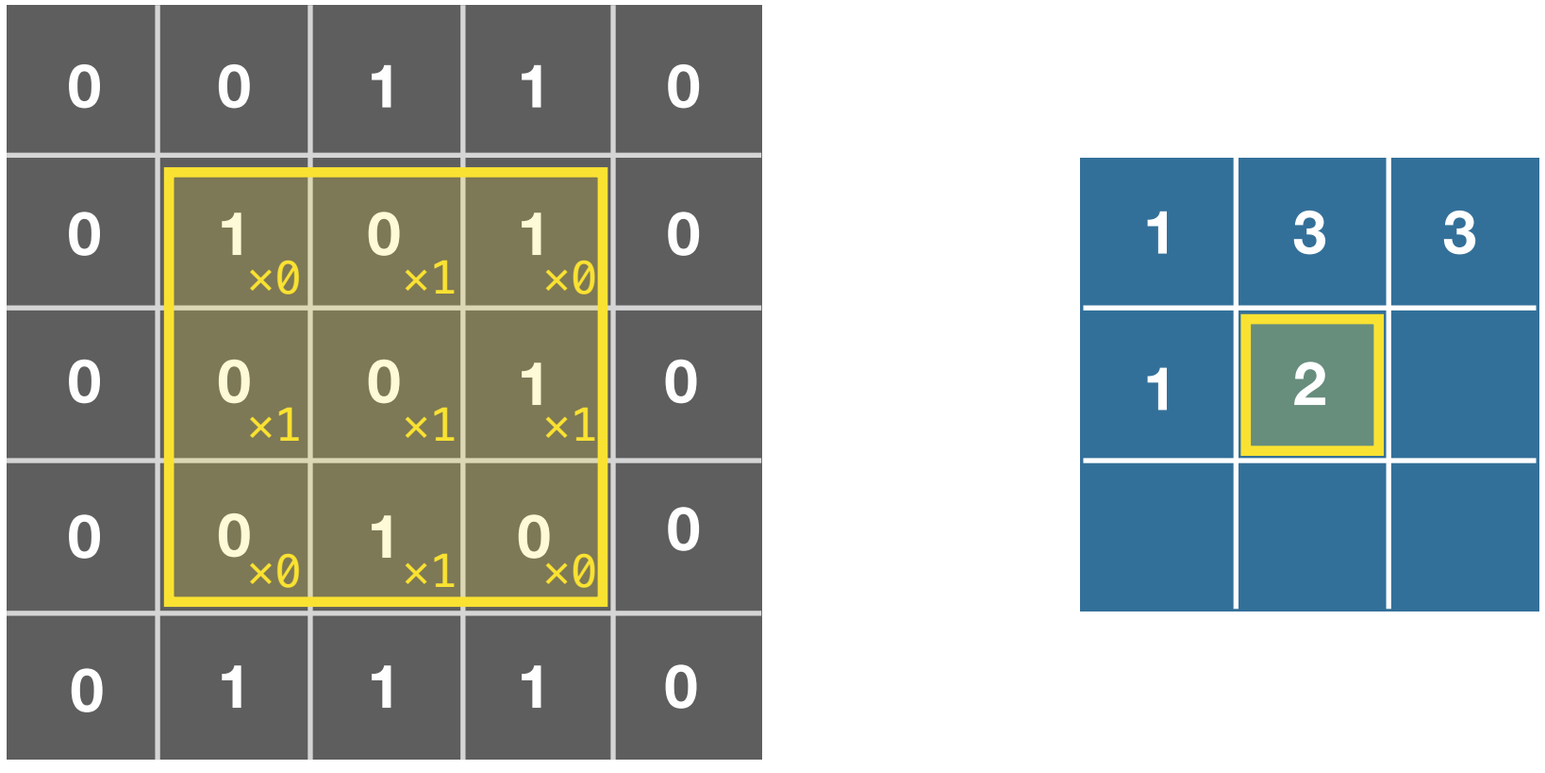

이 과정을 반복합니다.

Convolution

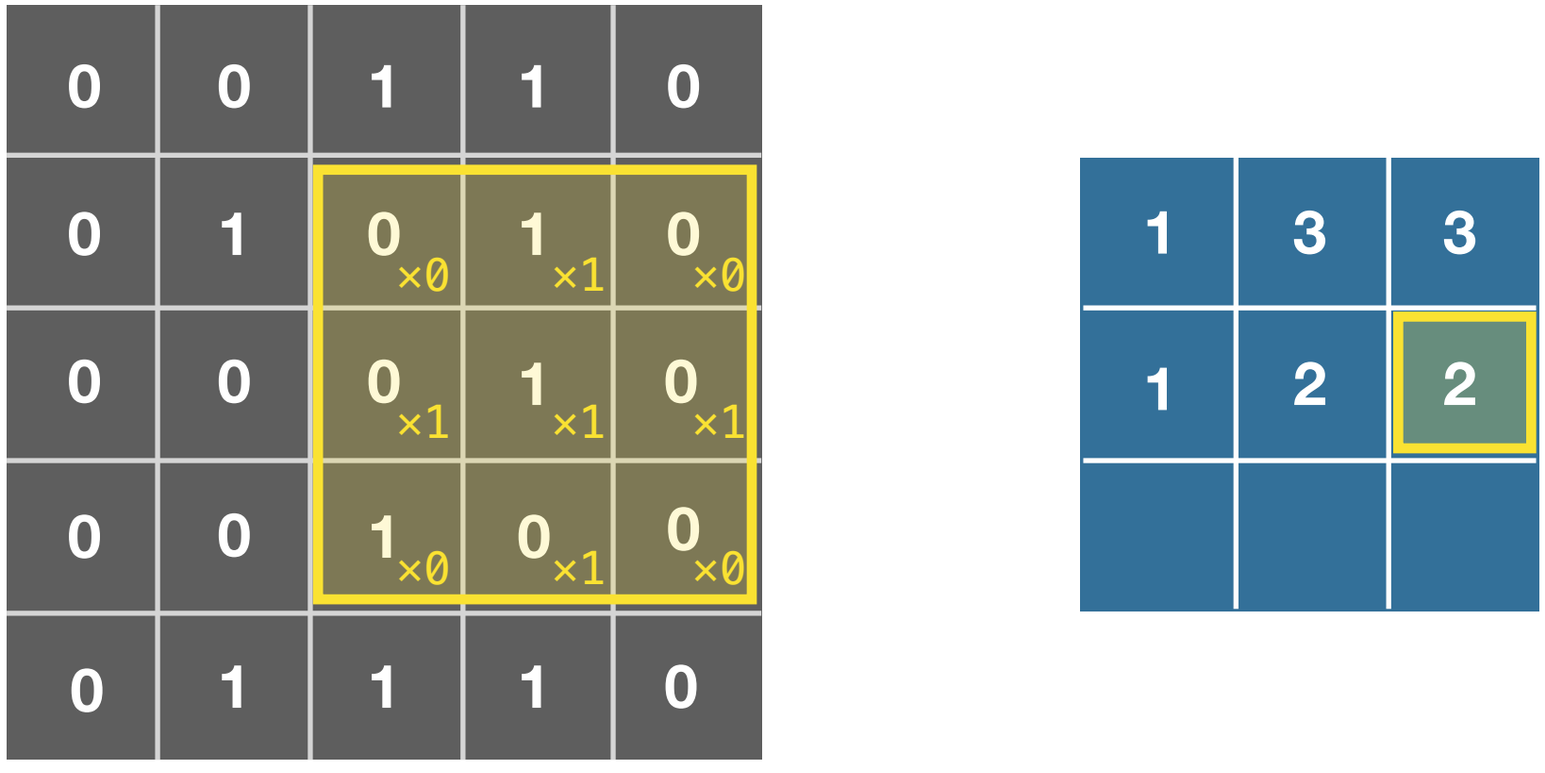

이 과정을 반복합니다.

Convolution

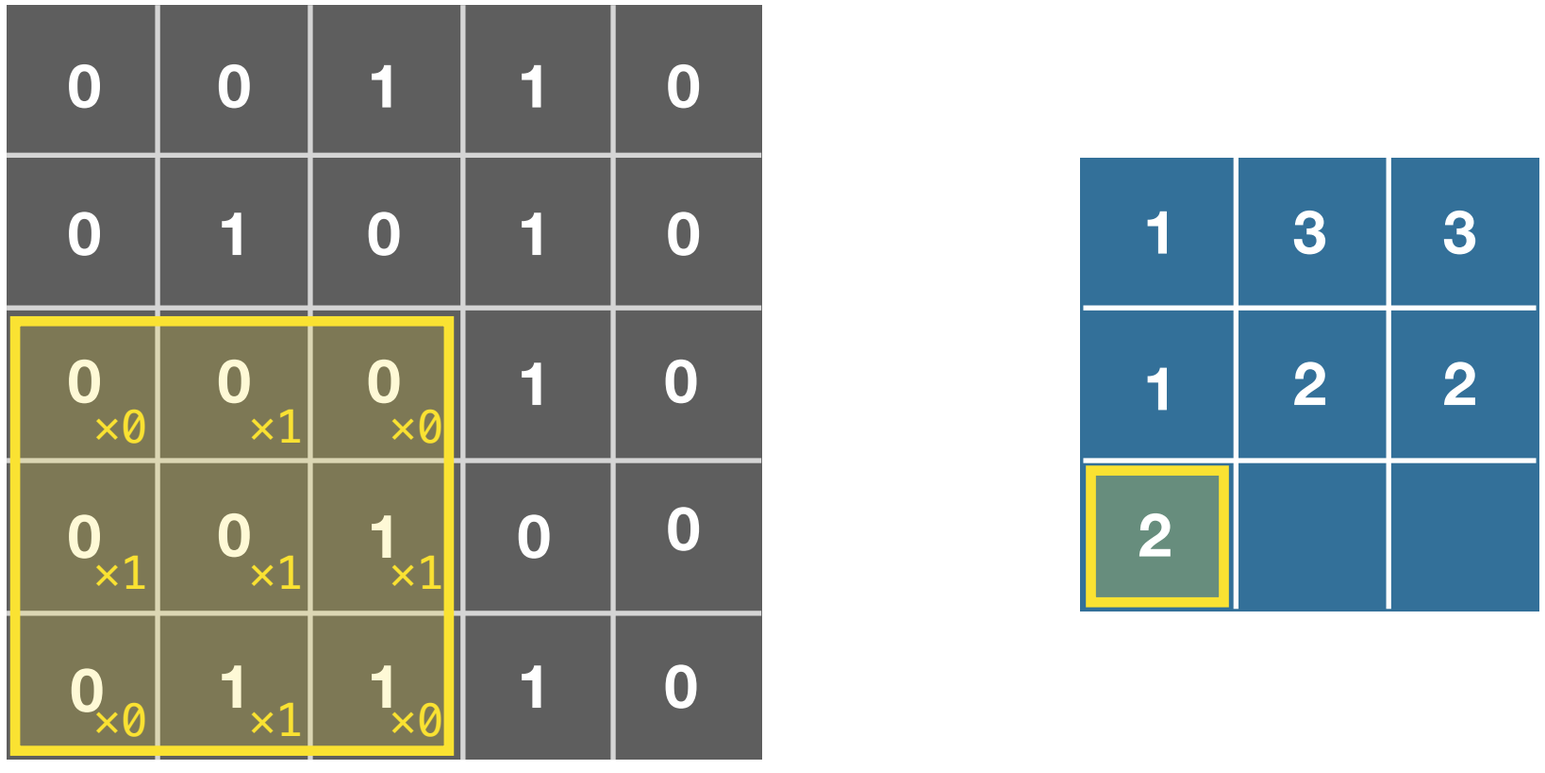

이 과정을 반복합니다.

Convolution

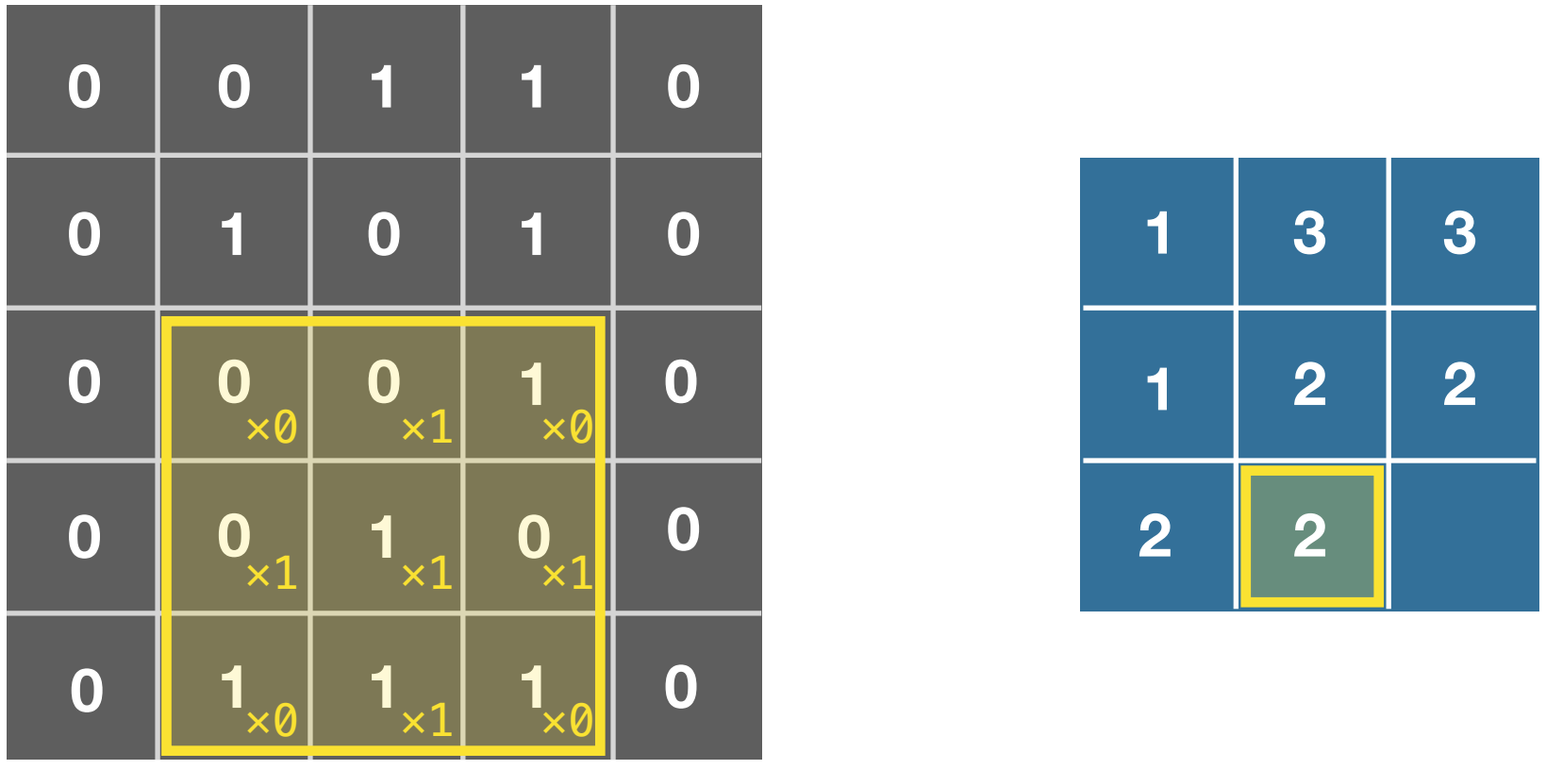

이 과정을 반복합니다.

Convolution

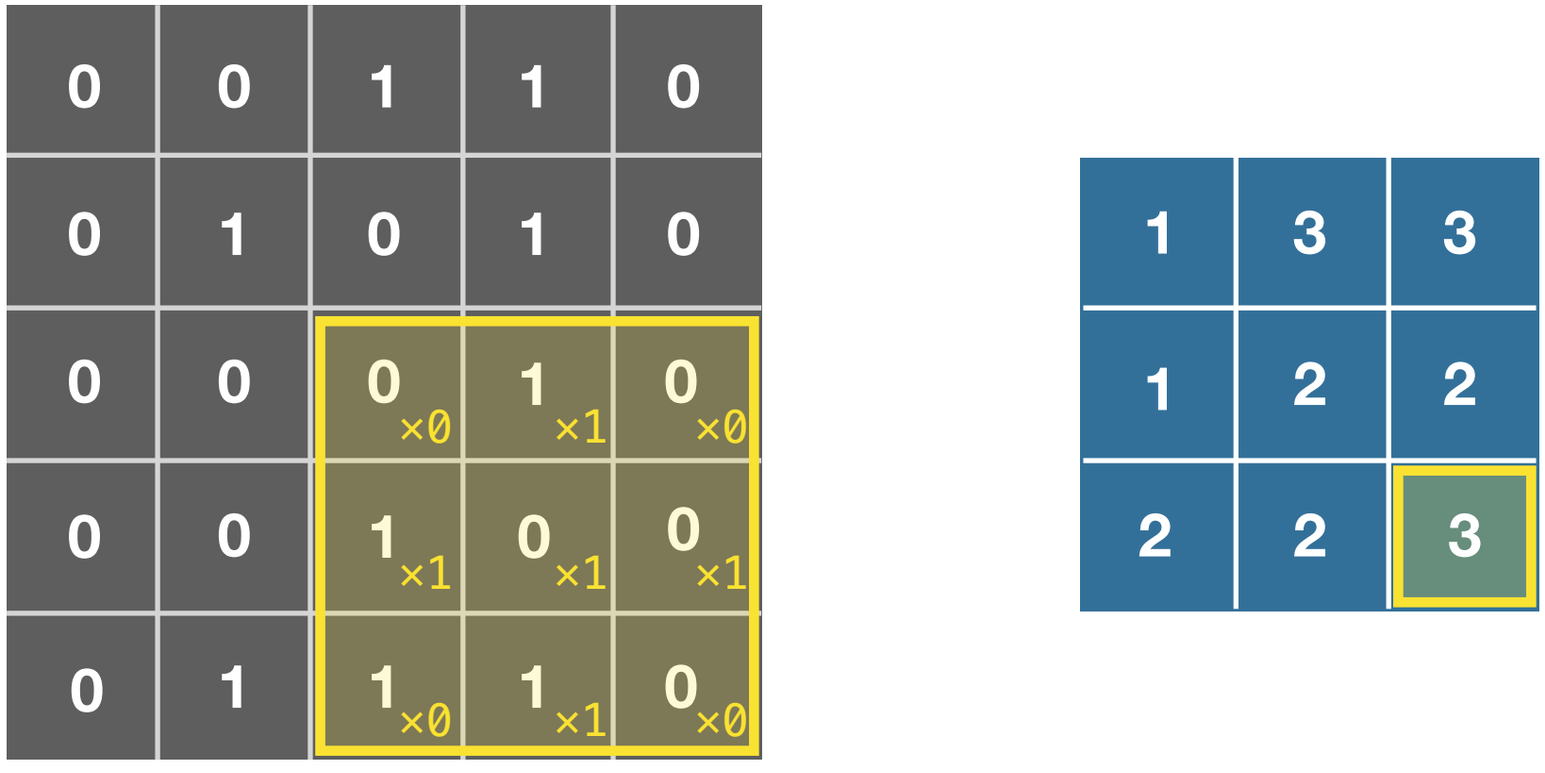

완성된 오른쪽 파란색 박스를 feature map이라고 합니다.

Max Pooling

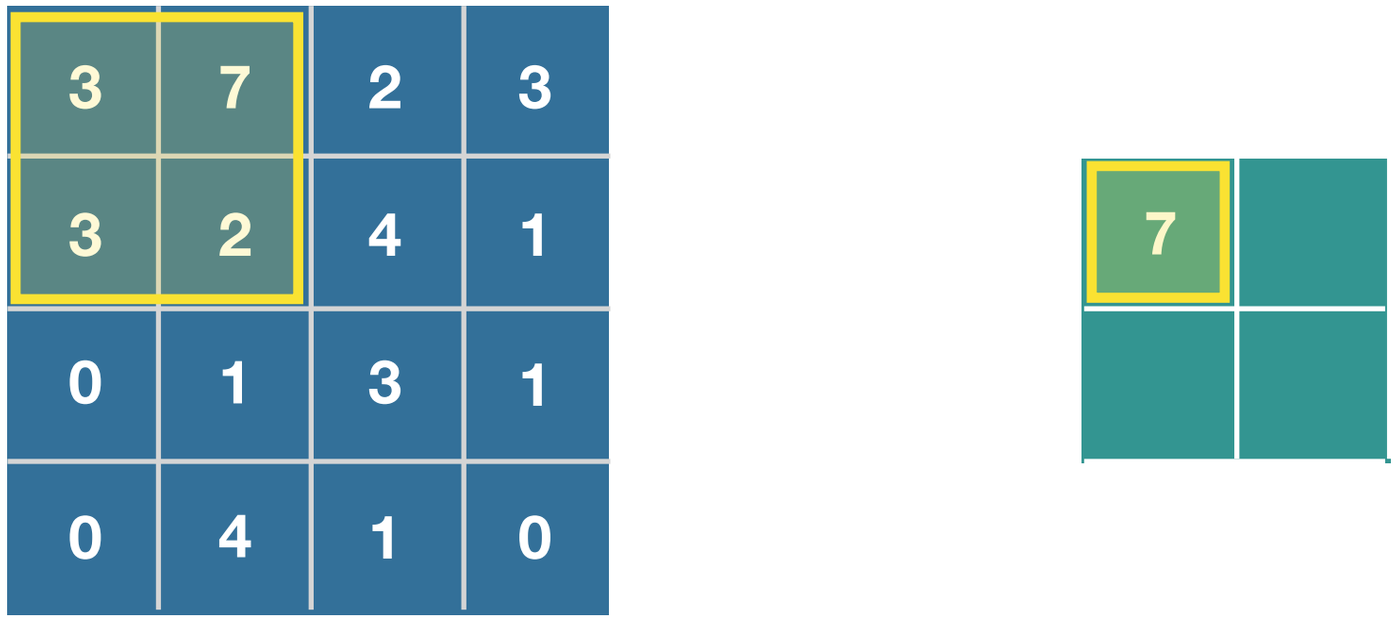

convolution의 결과로 나온 feature map이 너무 클 때, feature map의 크기를 줄여줘야 합니다.
feature map의 구획을 나눠서 각 구획에서 가장 큰 값을 뽑는 방법을 max pooling이라고 합니다.

Max Pooling

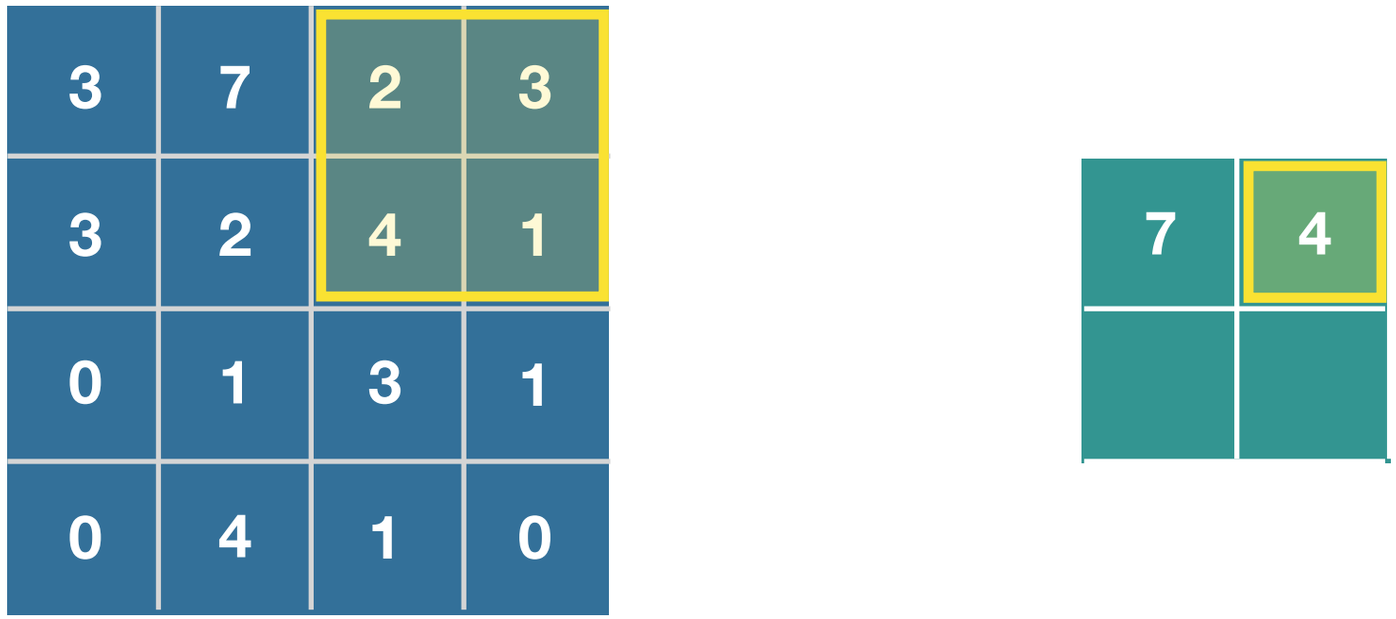

convolution의 결과로 나온 feature map이 너무 클 때, feature map의 크기를 줄여줘야 합니다.
feature map의 구획을 나눠서 각 구획에서 가장 큰 값을 뽑는 방법을 max pooling이라고 합니다.

Max Pooling

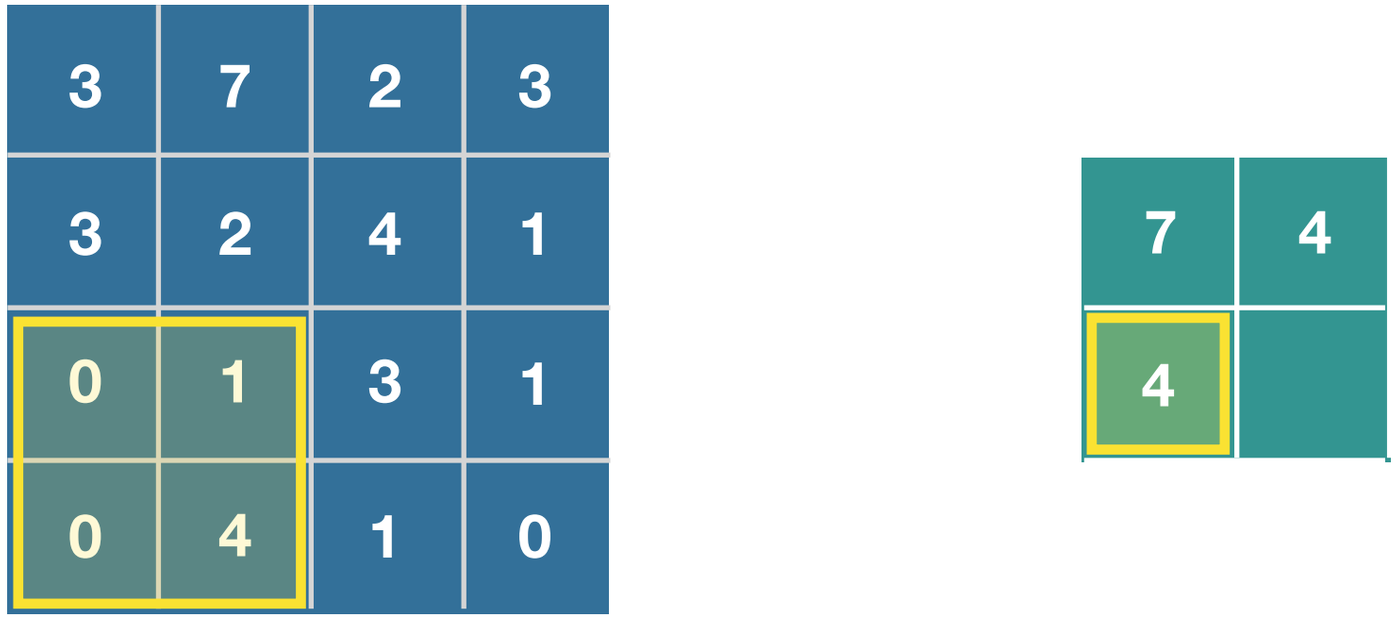

convolution의 결과로 나온 feature map이 너무 클 때, feature map의 크기를 줄여줘야 합니다.
feature map의 구획을 나눠서 각 구획에서 가장 큰 값을 뽑는 방법을 max pooling이라고 합니다.

Max Pooling

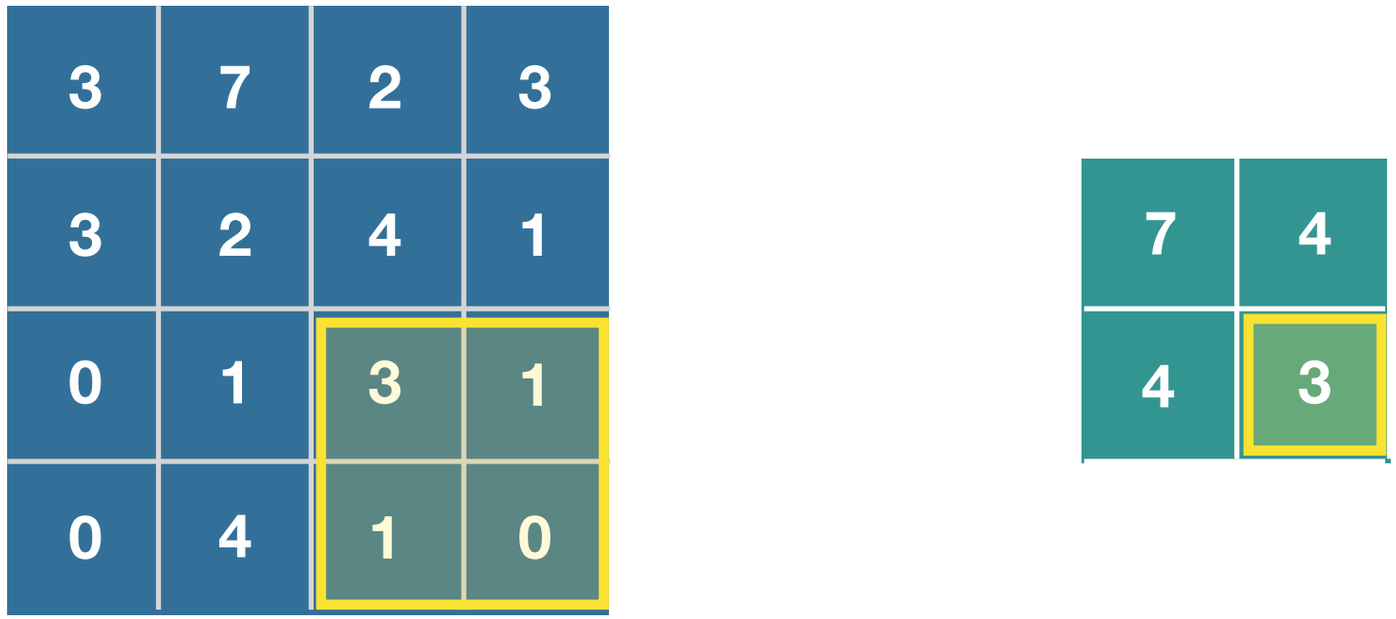

convolution의 결과로 나온 feature map이 너무 클 때, feature map의 크기를 줄여줘야 합니다.
feature map의 구획을 나눠서 각 구획에서 가장 큰 값을 뽑는 방법을 max pooling이라고 합니다.

max pooling 또한 stride를 조정할 수 있음

CNN

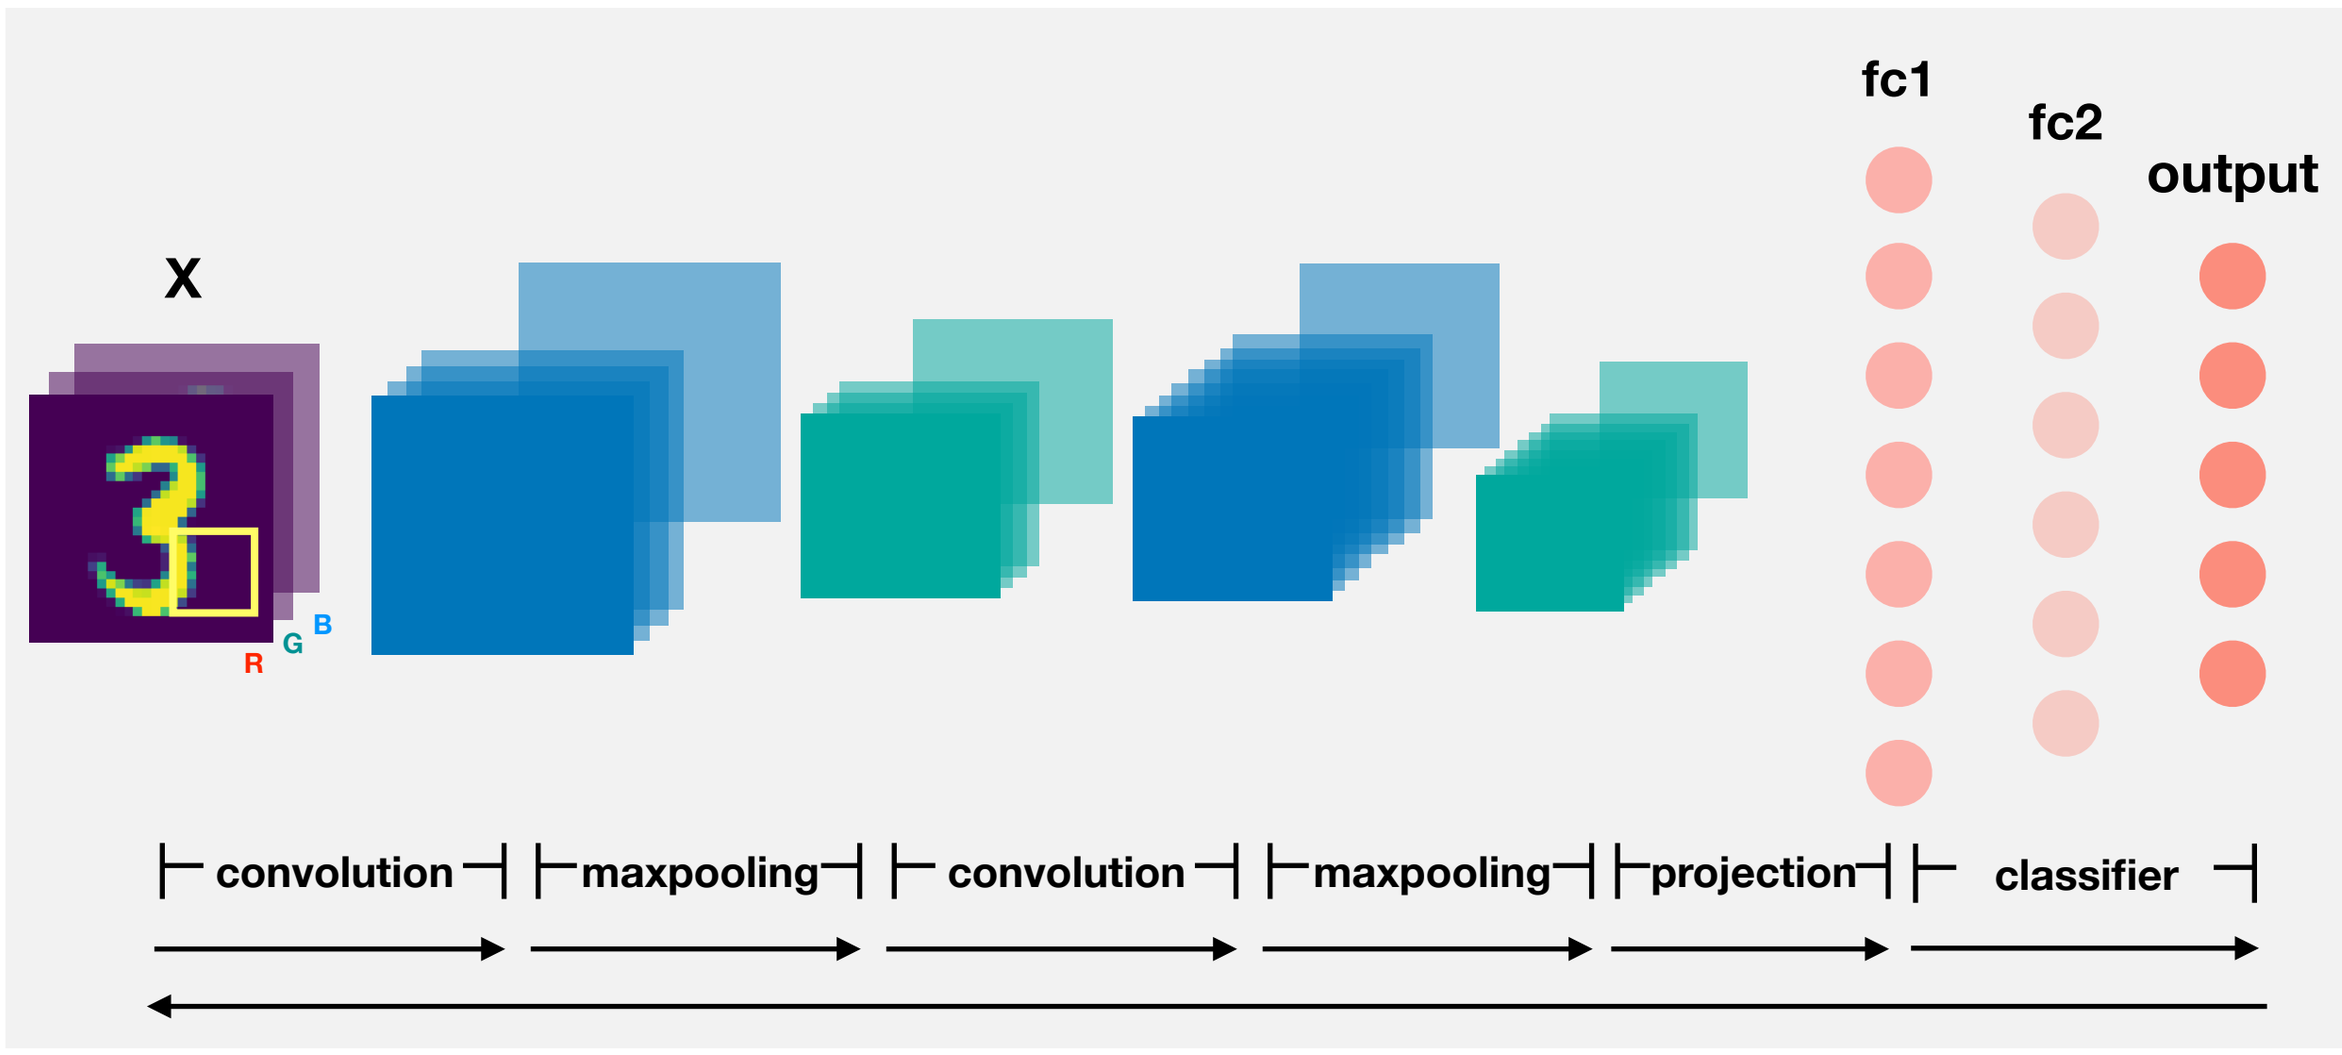

이 개념을 토대로 **CNN**을 이해해 보겠습니다.

CNN

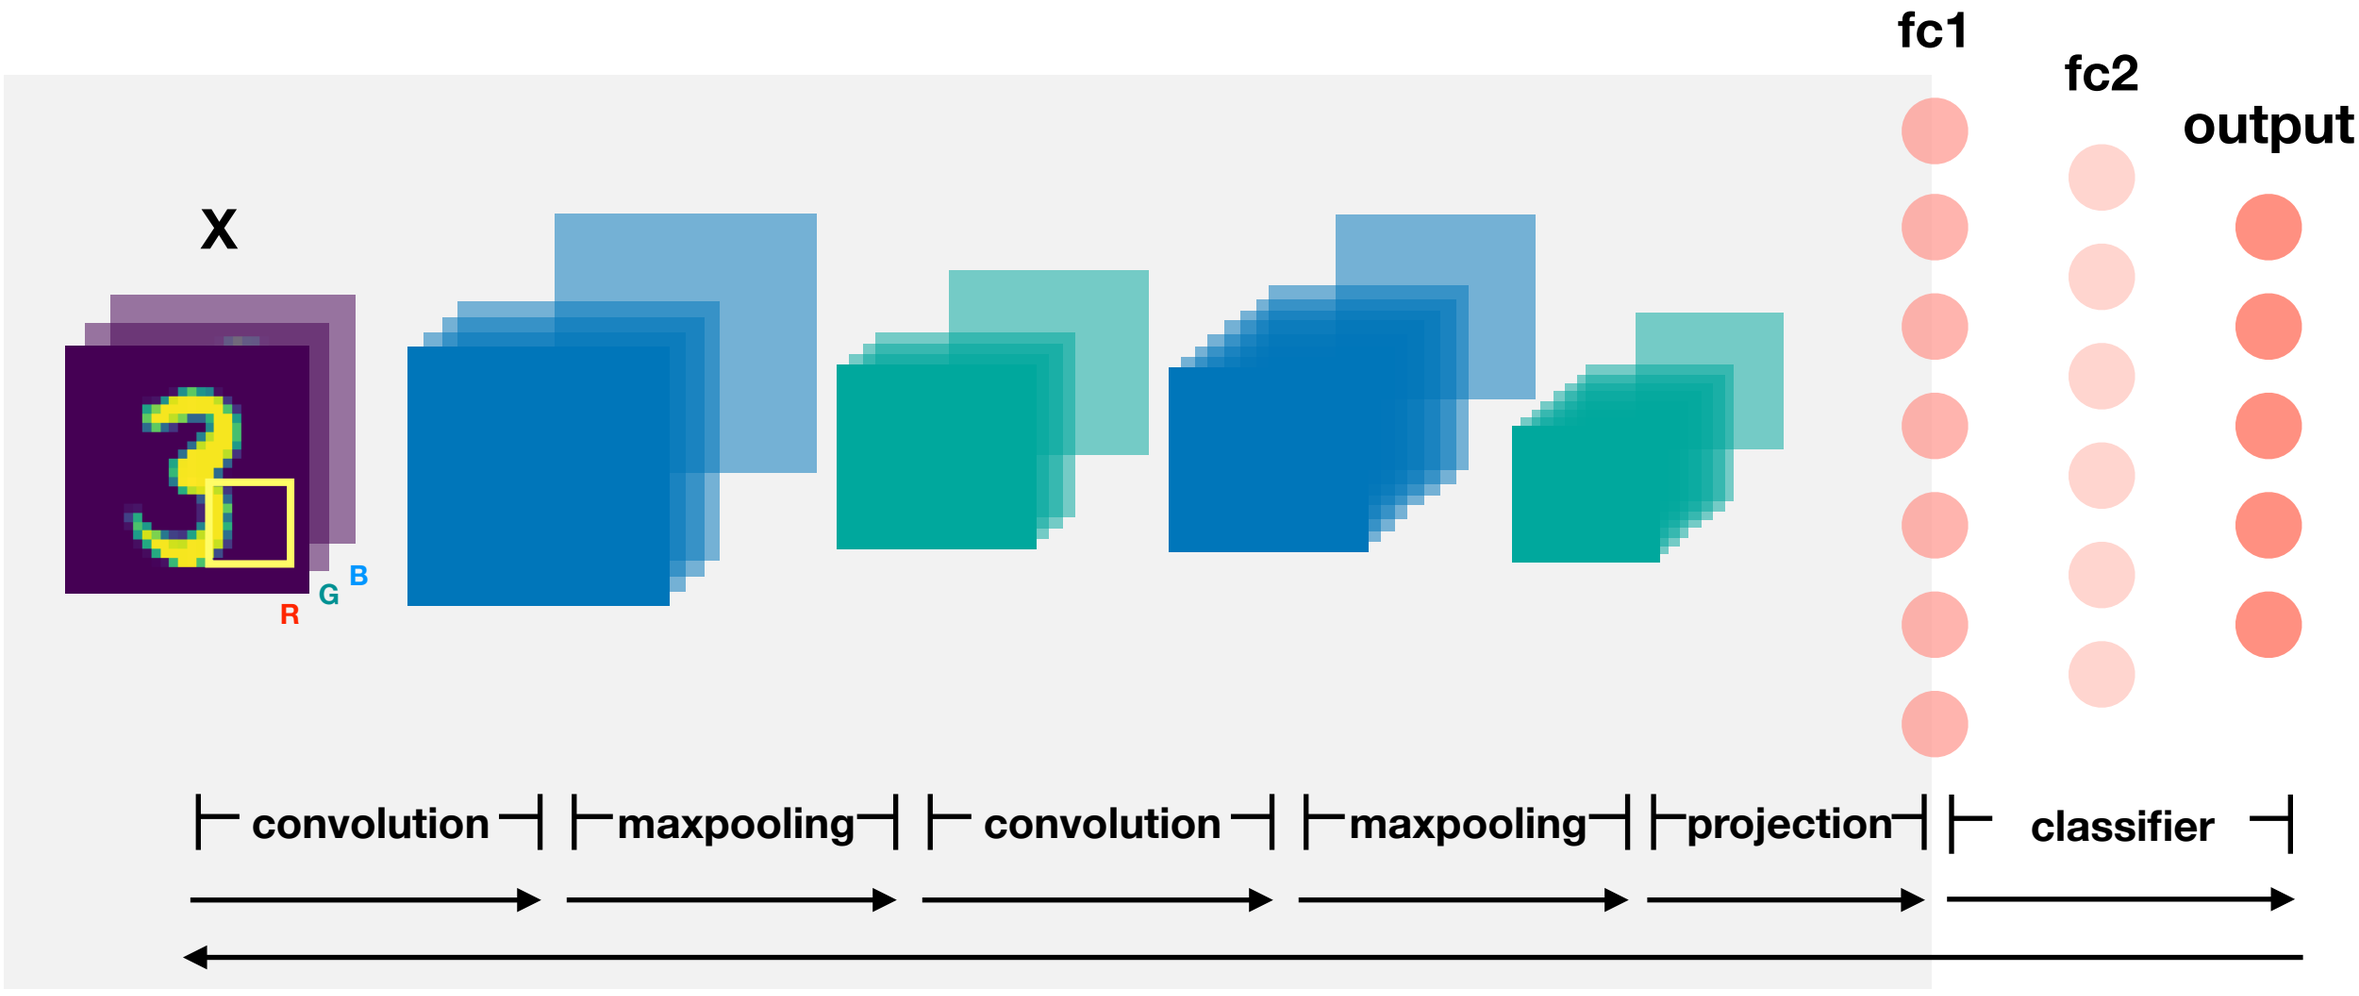

CNN은 input의 특징을 잘 반영하도록 해주는 준비과정과

CNN

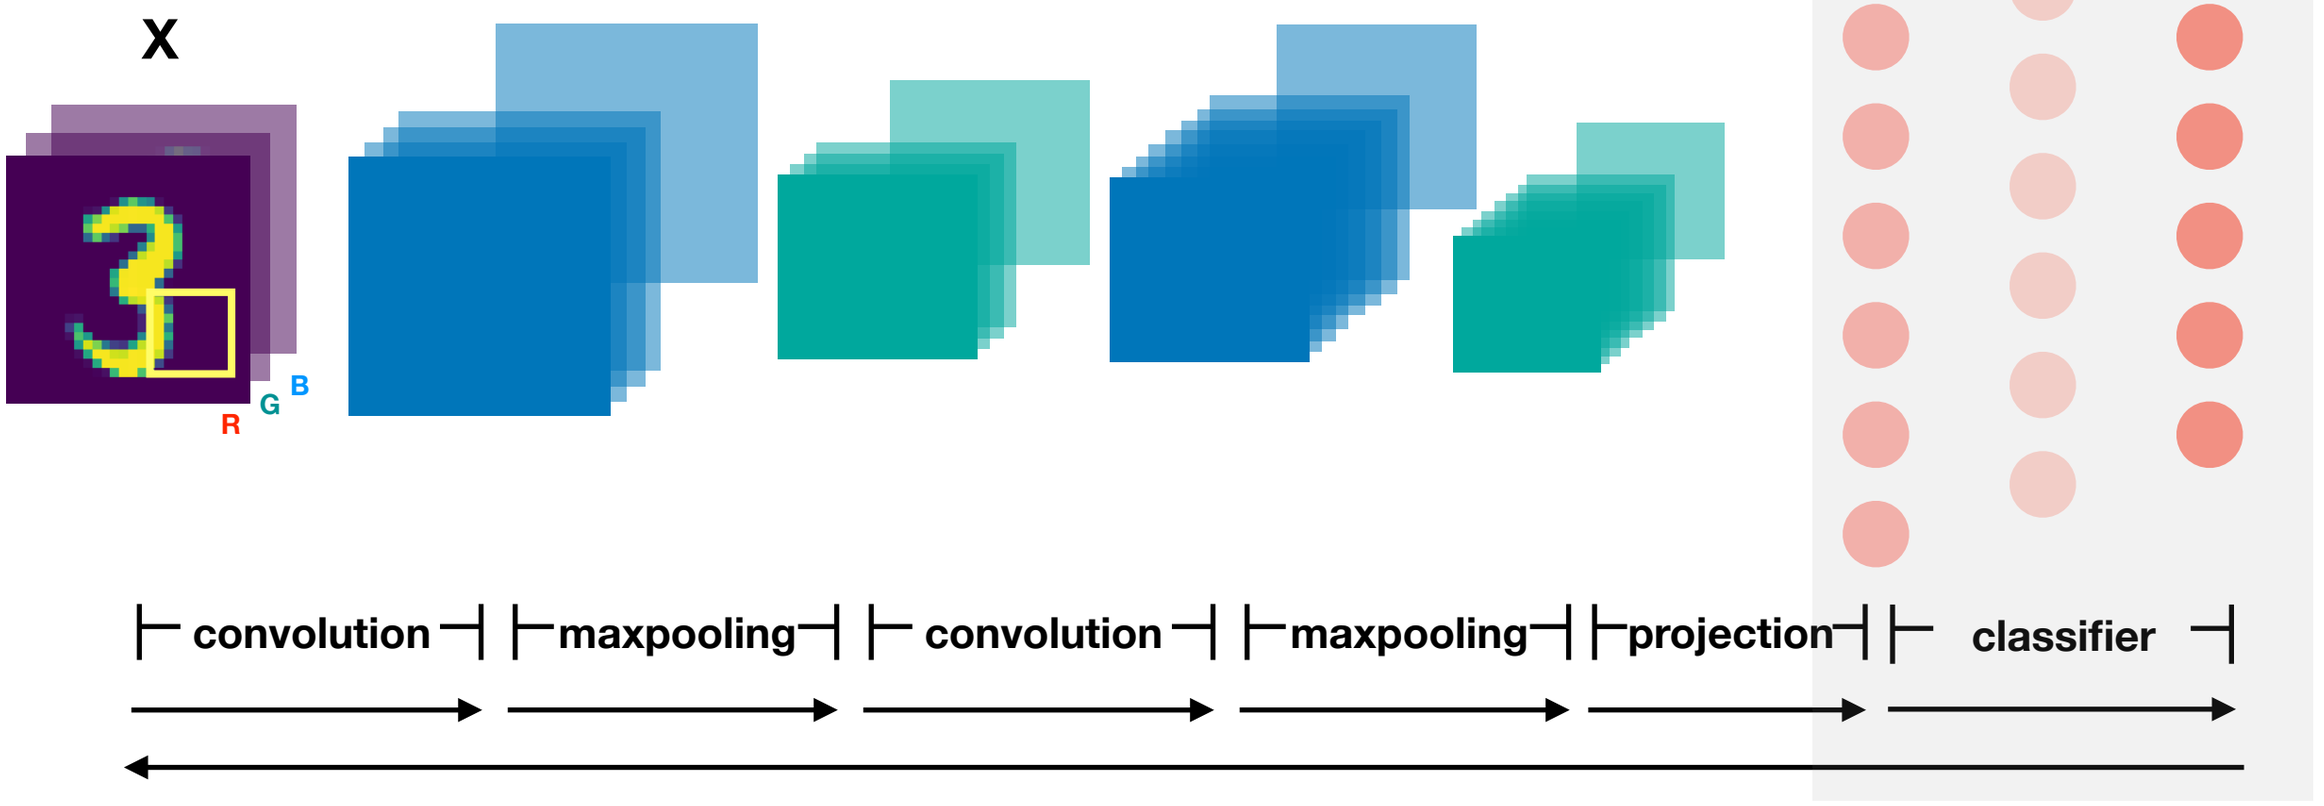

그 결과물을 분류해주는 **classifier** 부분으로 나누어져 있습니다.

CNN

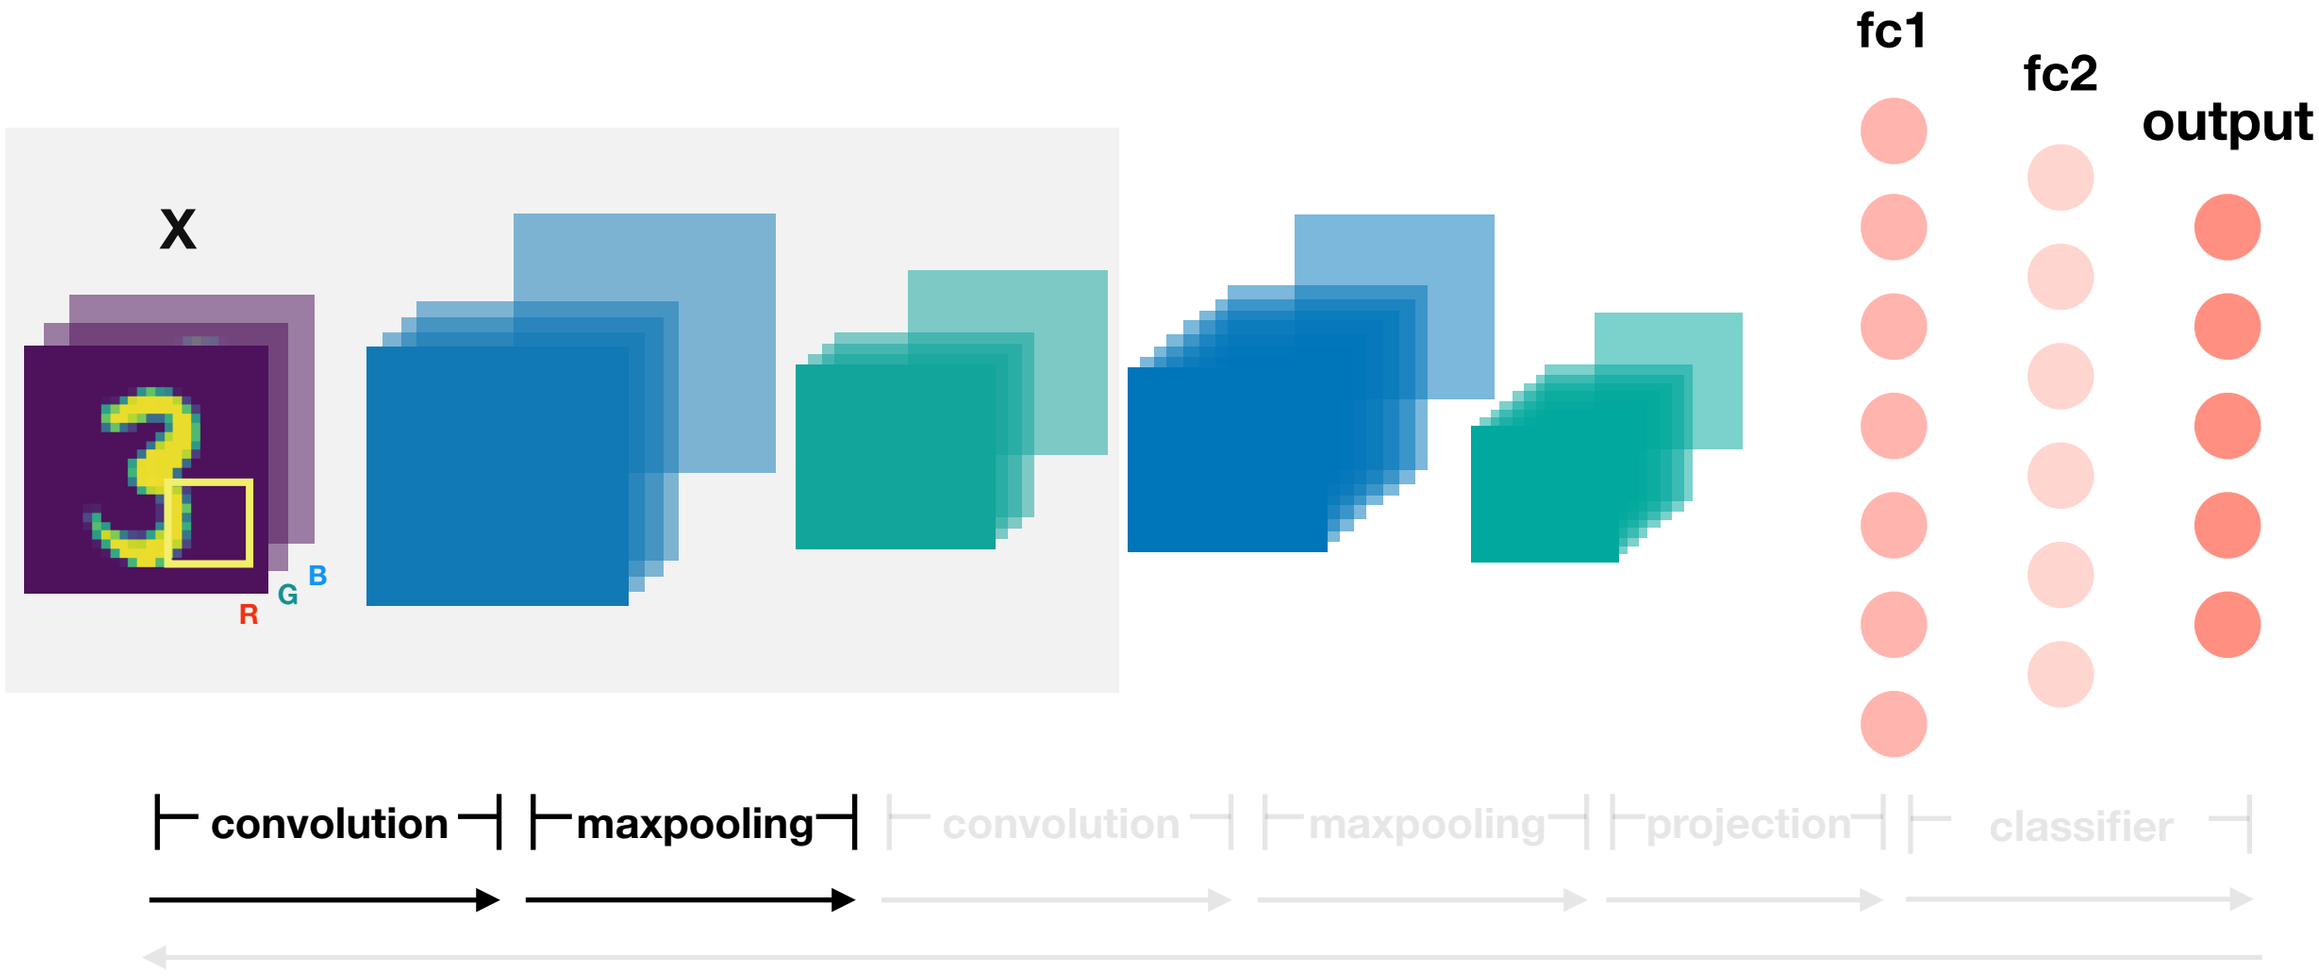

먼저 input에 convolution과 max pooling을 합니다.
이 과정을 좀 더 자세히 살펴보겠습니다.

CNN

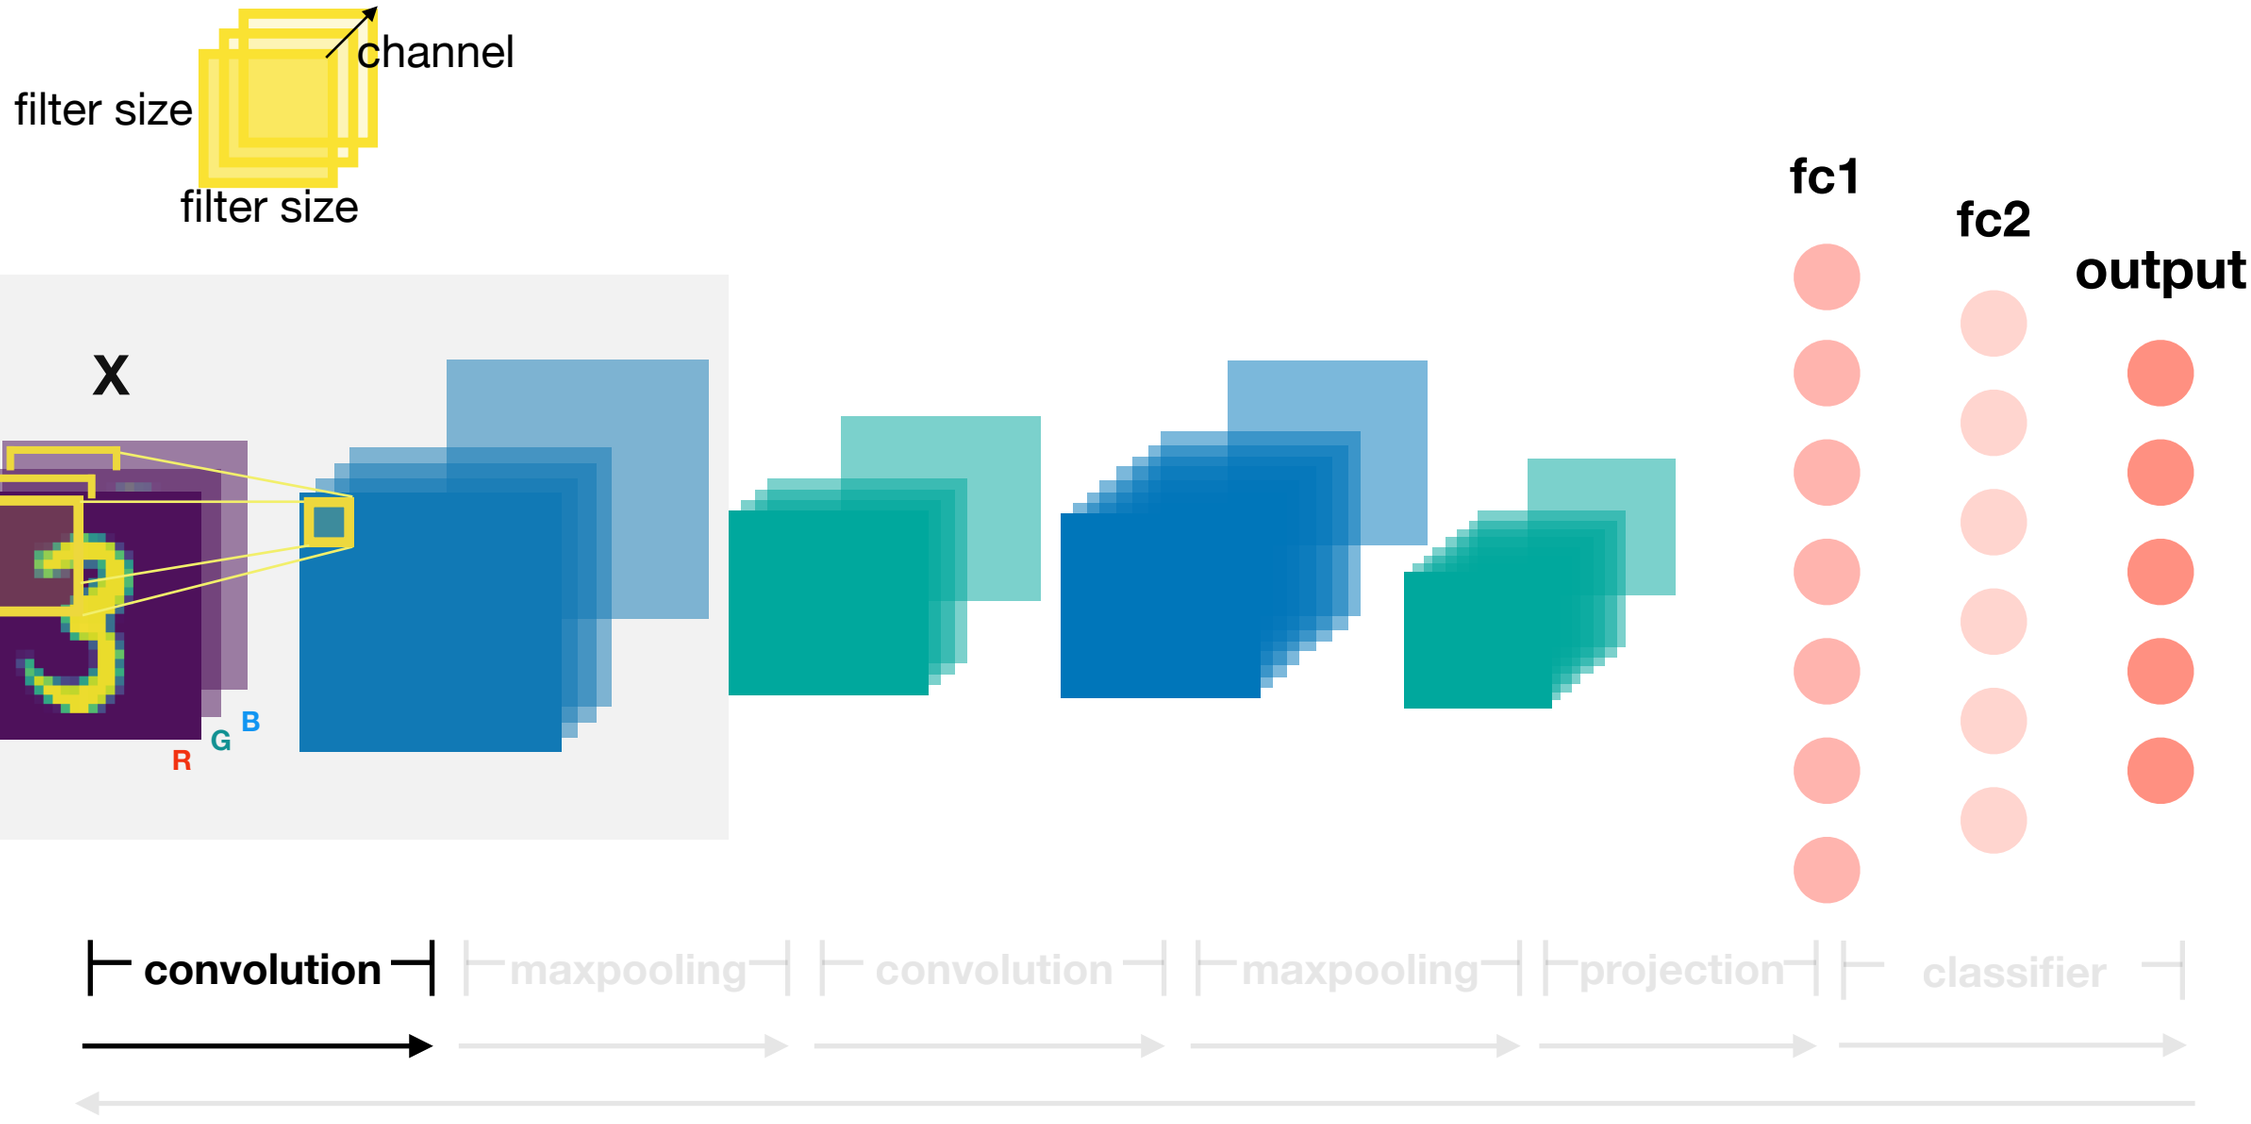

우선 첫 번째 필터(노란색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 첫 번째 feature map (제일 앞의 파란색)을 만듭니다.

CNN

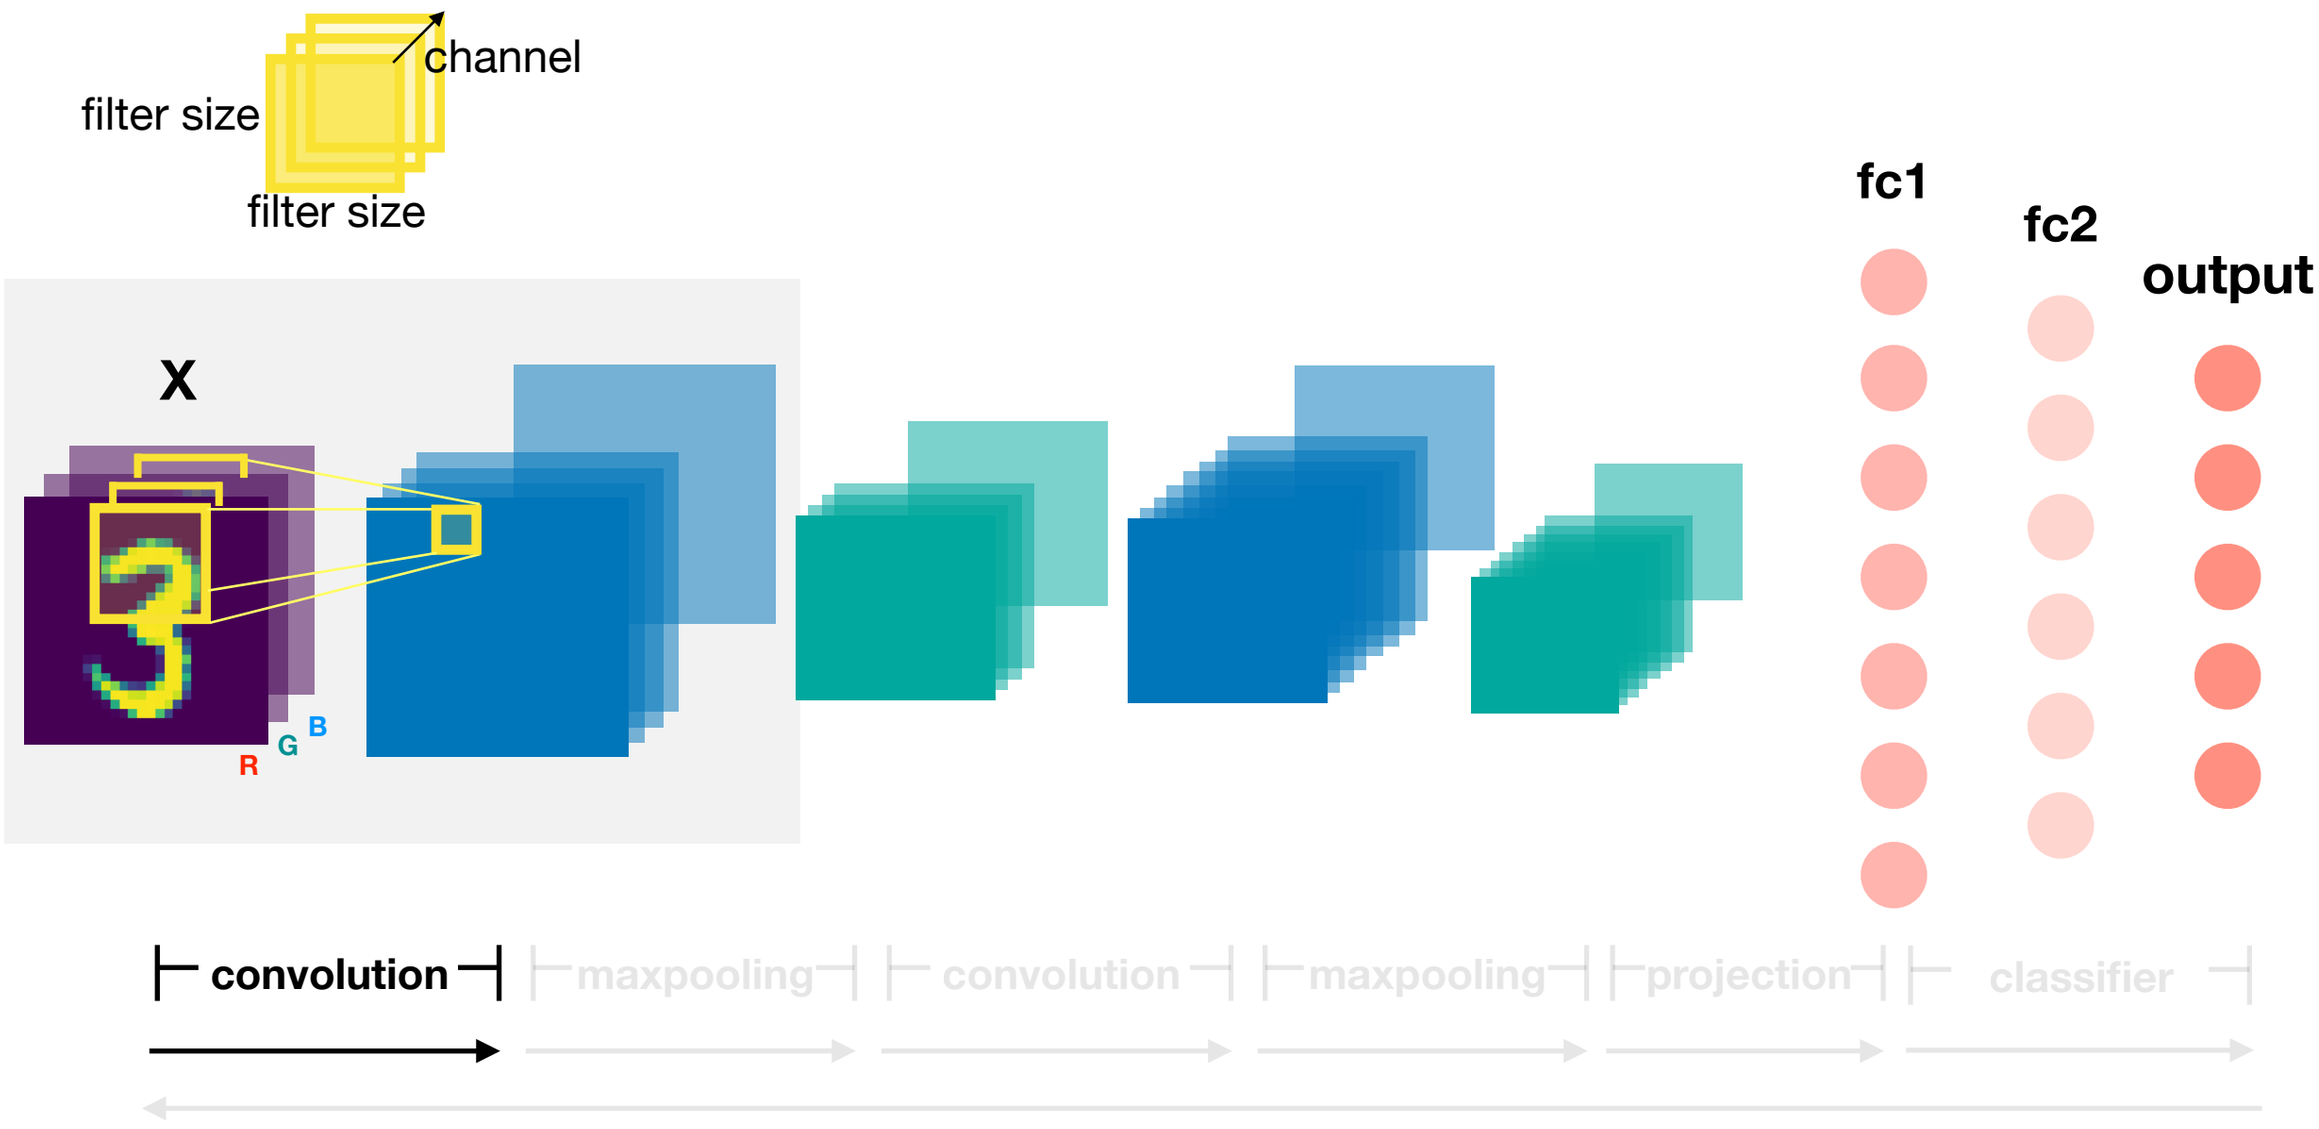

우선 첫 번째 필터(노란색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 첫 번째 feature map (제일 앞의 파란색)을 만듭니다.

CNN

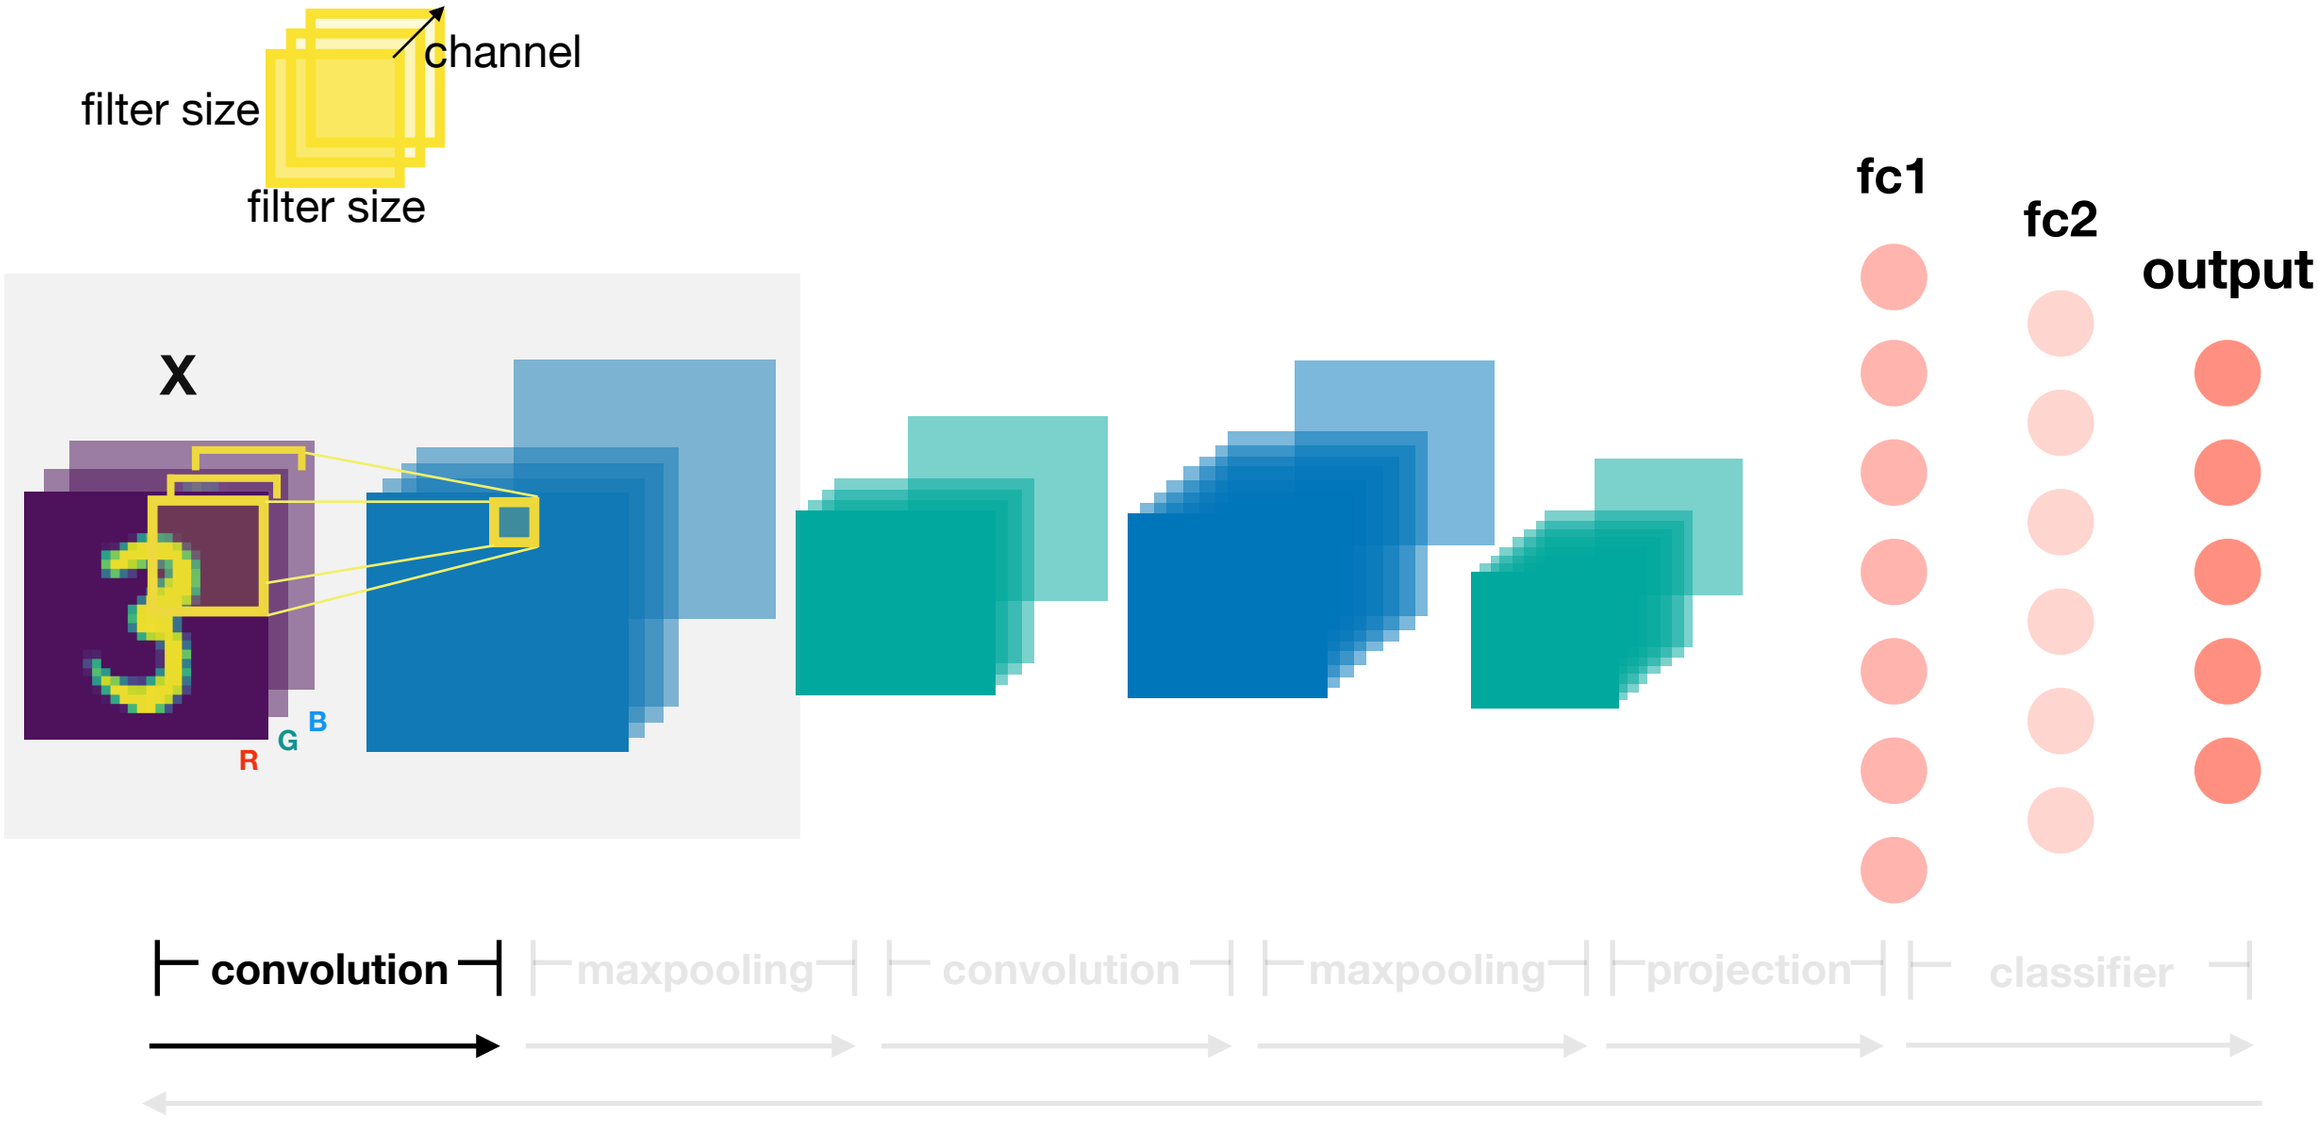

우선 첫 번째 필터(노란색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 첫 번째 feature map (제일 앞의 파란색)을 만듭니다.

CNN

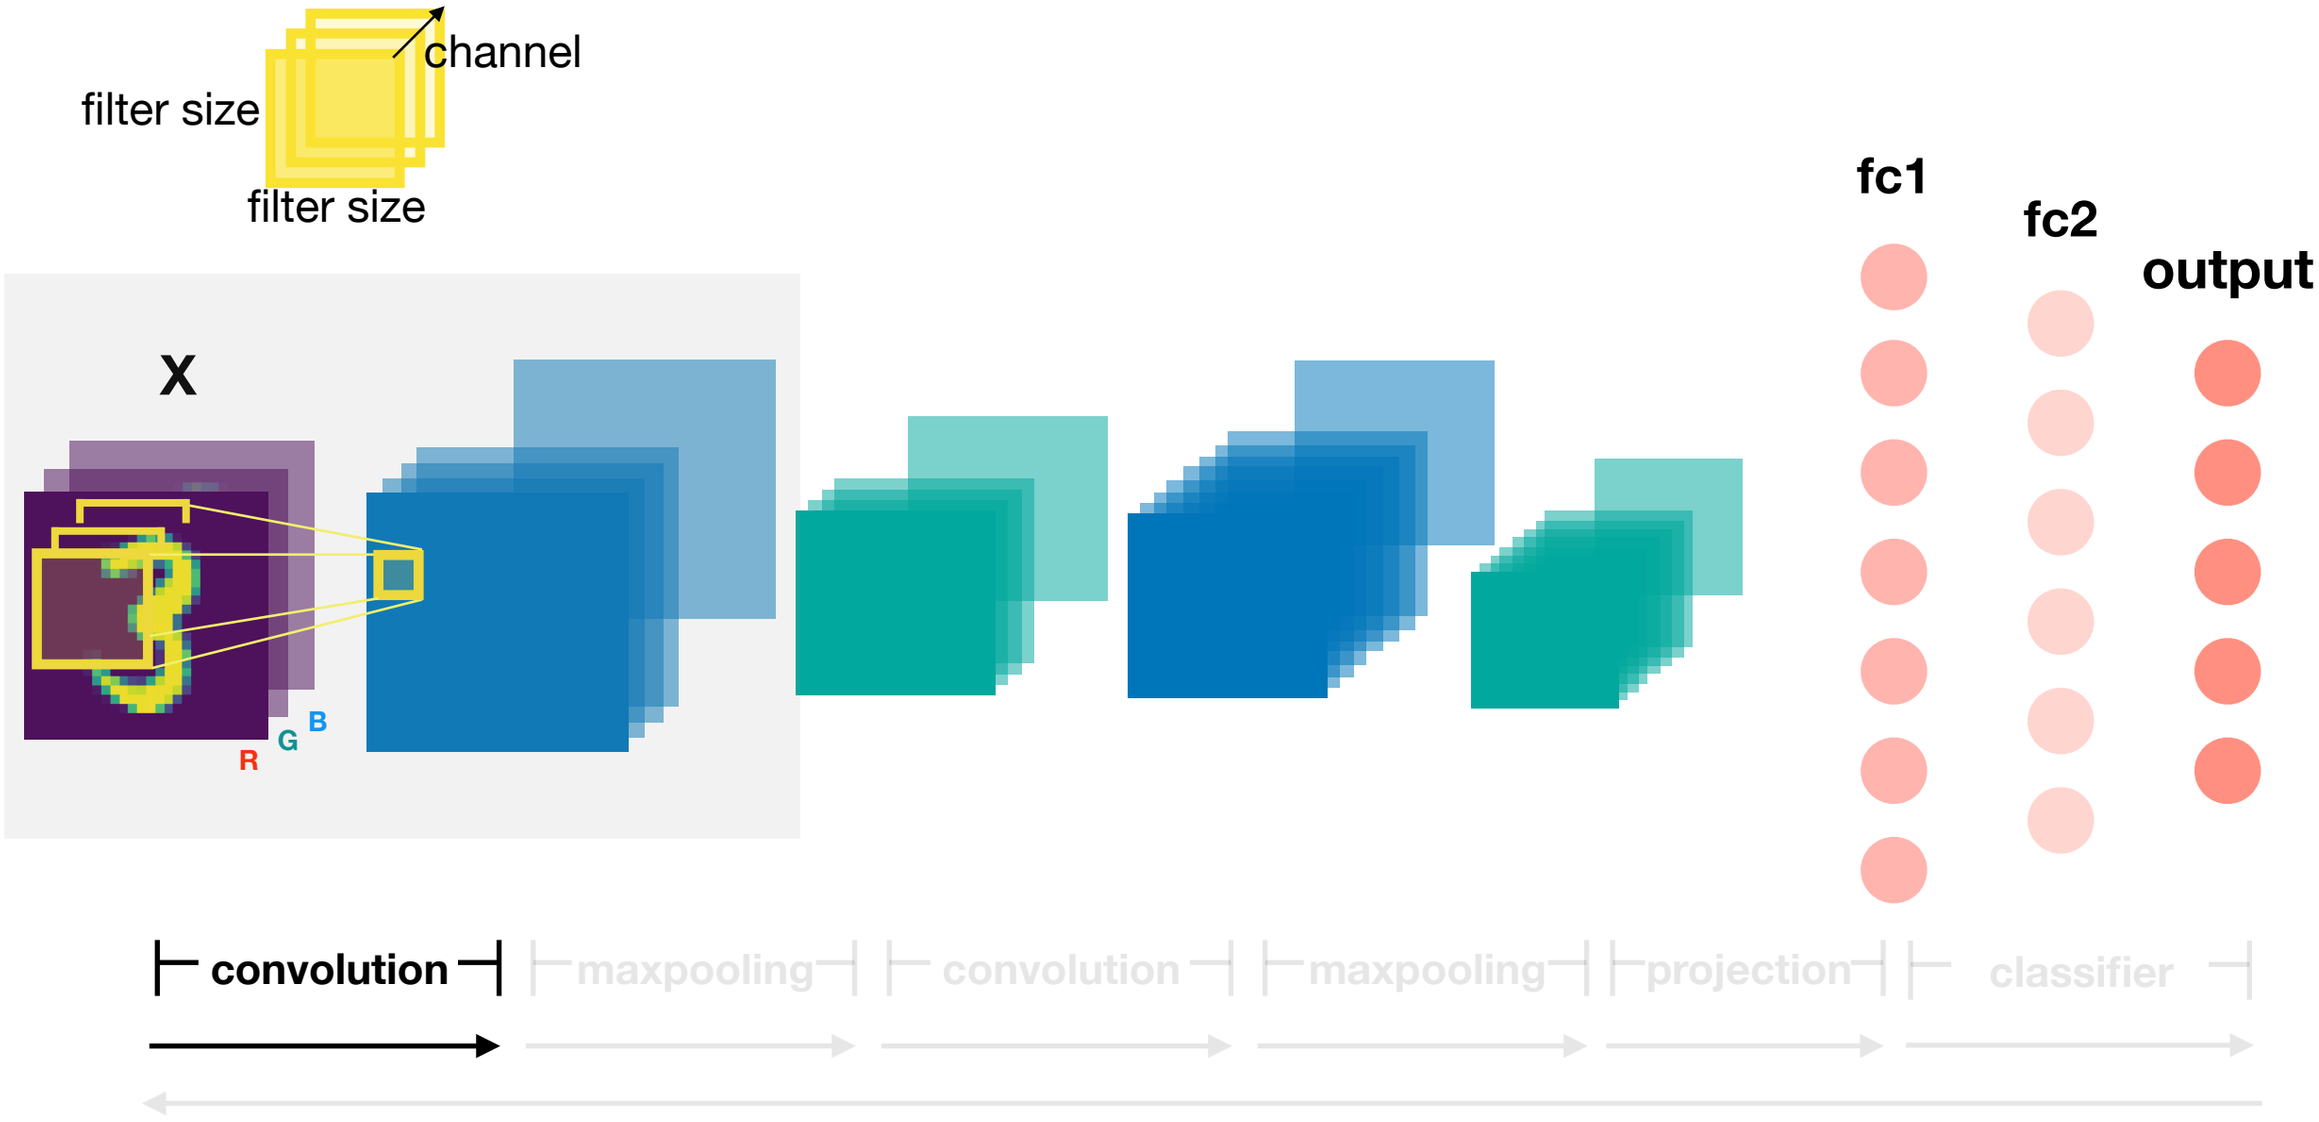

우선 첫 번째 필터(노란색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 첫 번째 feature map (제일 앞의 파란색)을 만듭니다.

CNN

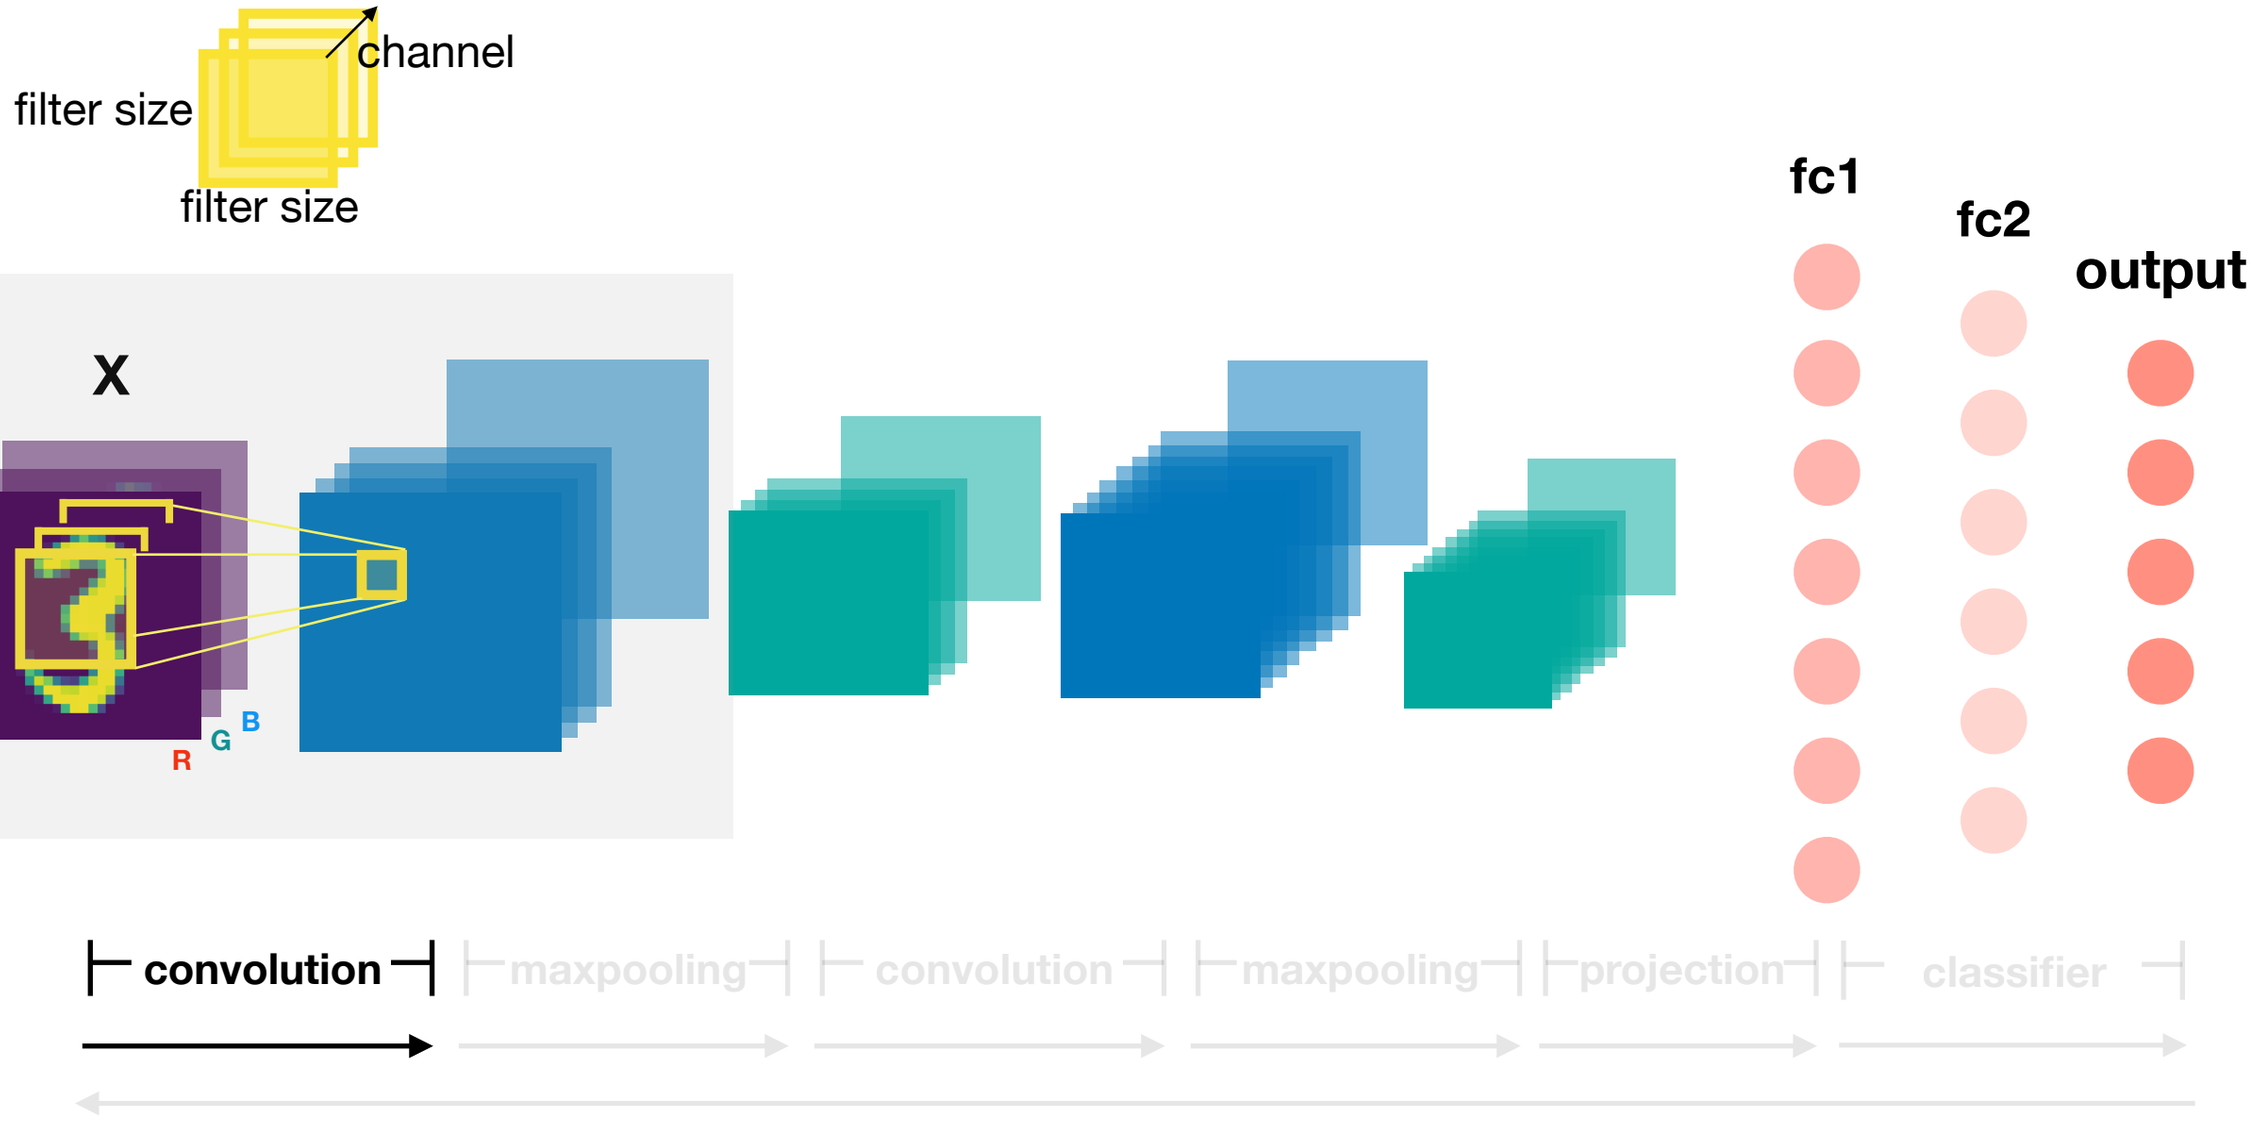

우선 첫 번째 필터(노란색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 첫 번째 feature map (제일 앞의 파란색)을 만듭니다.

CNN

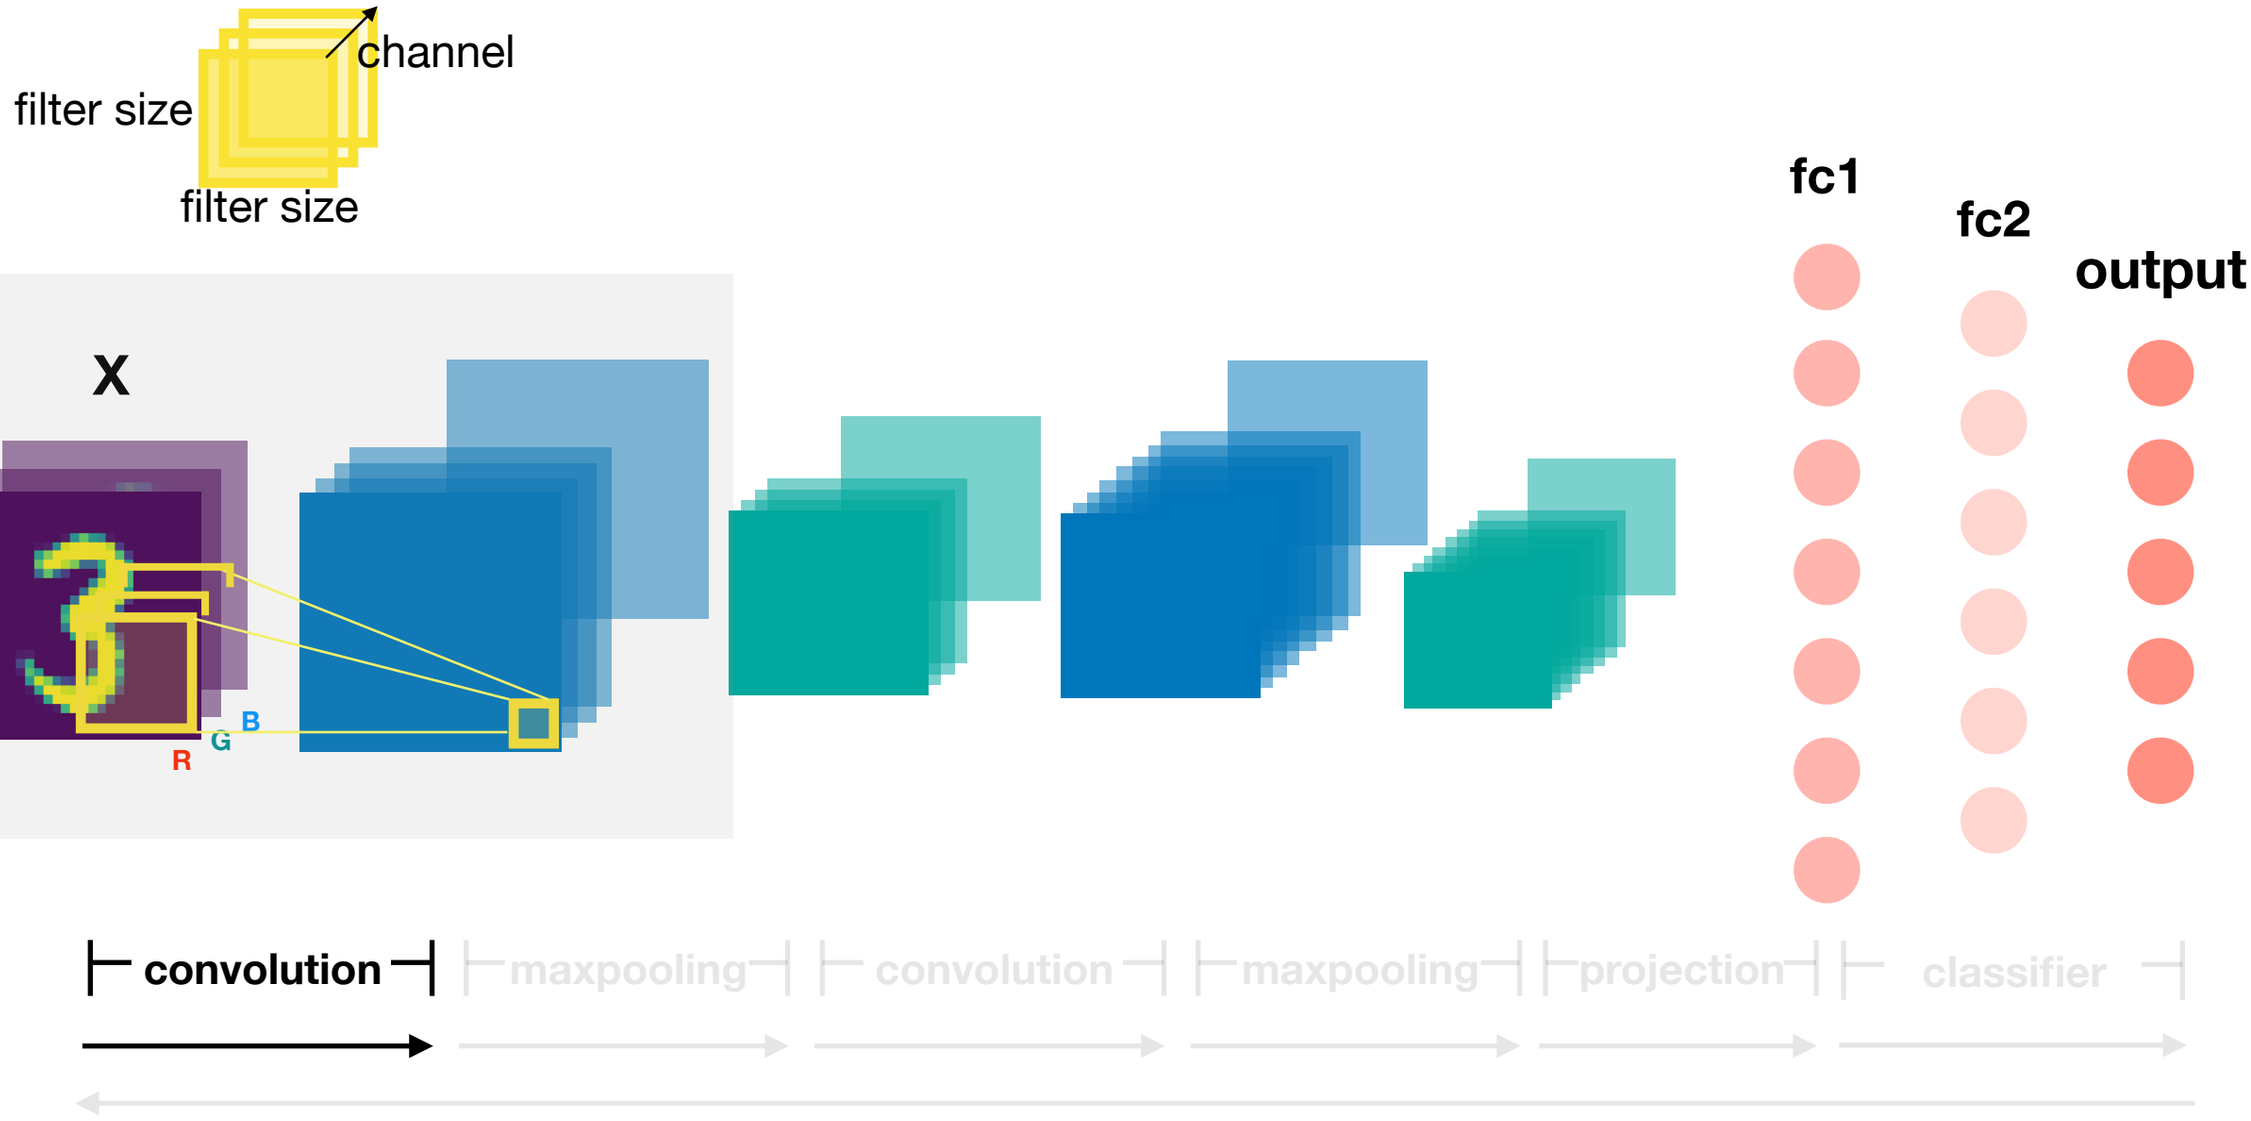

우선 첫 번째 필터(노란색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 첫 번째 feature map (제일 앞의 파란색)을 만듭니다.

CNN

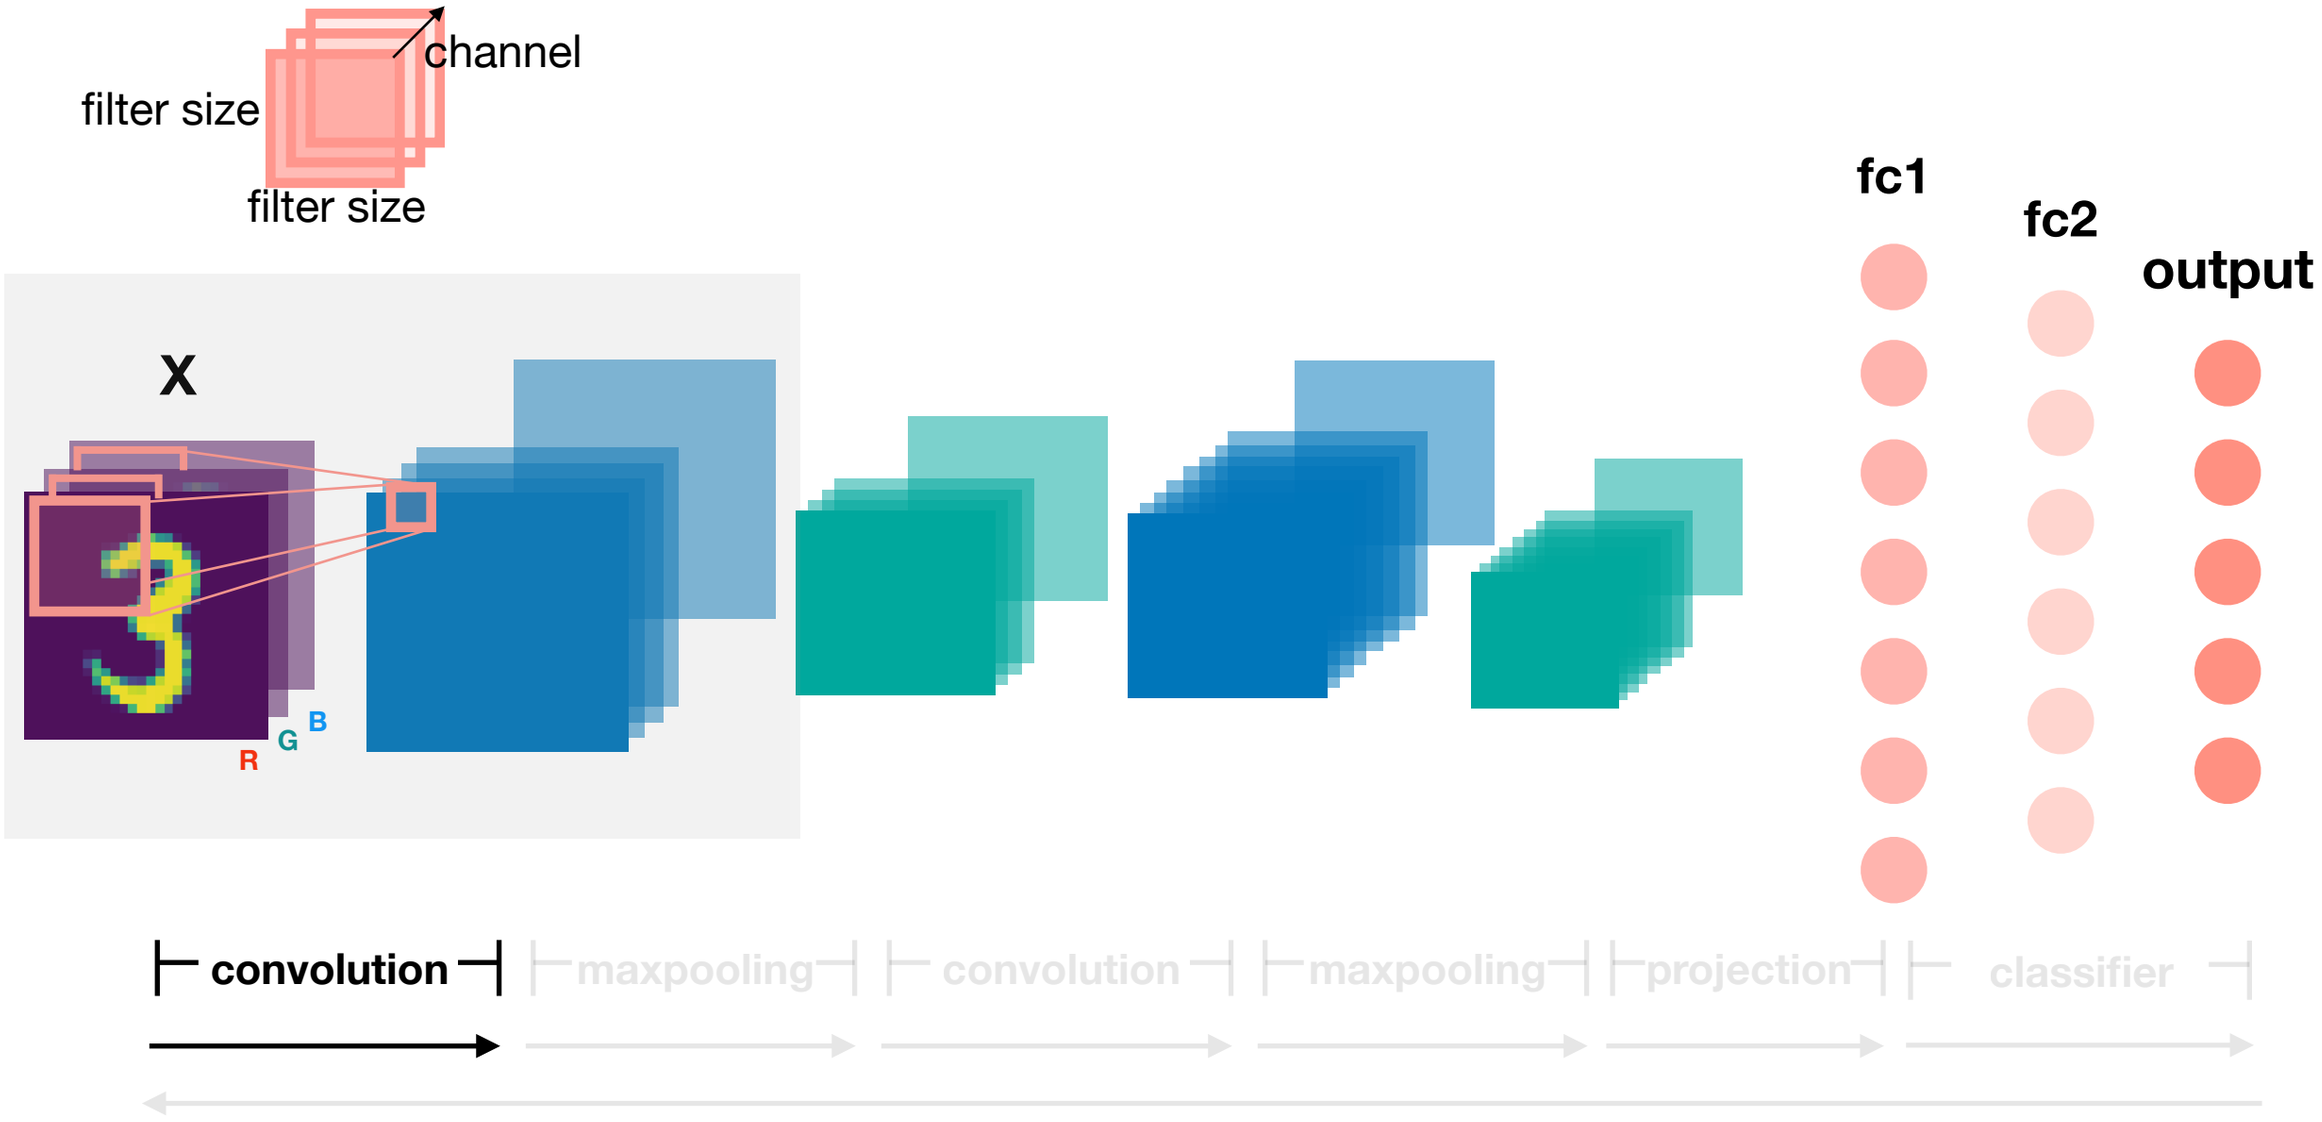

다음은 두 번째 필터(분홍색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 두 번째 feature map (두 번째 앞의 파란색)을 만듭니다.

CNN

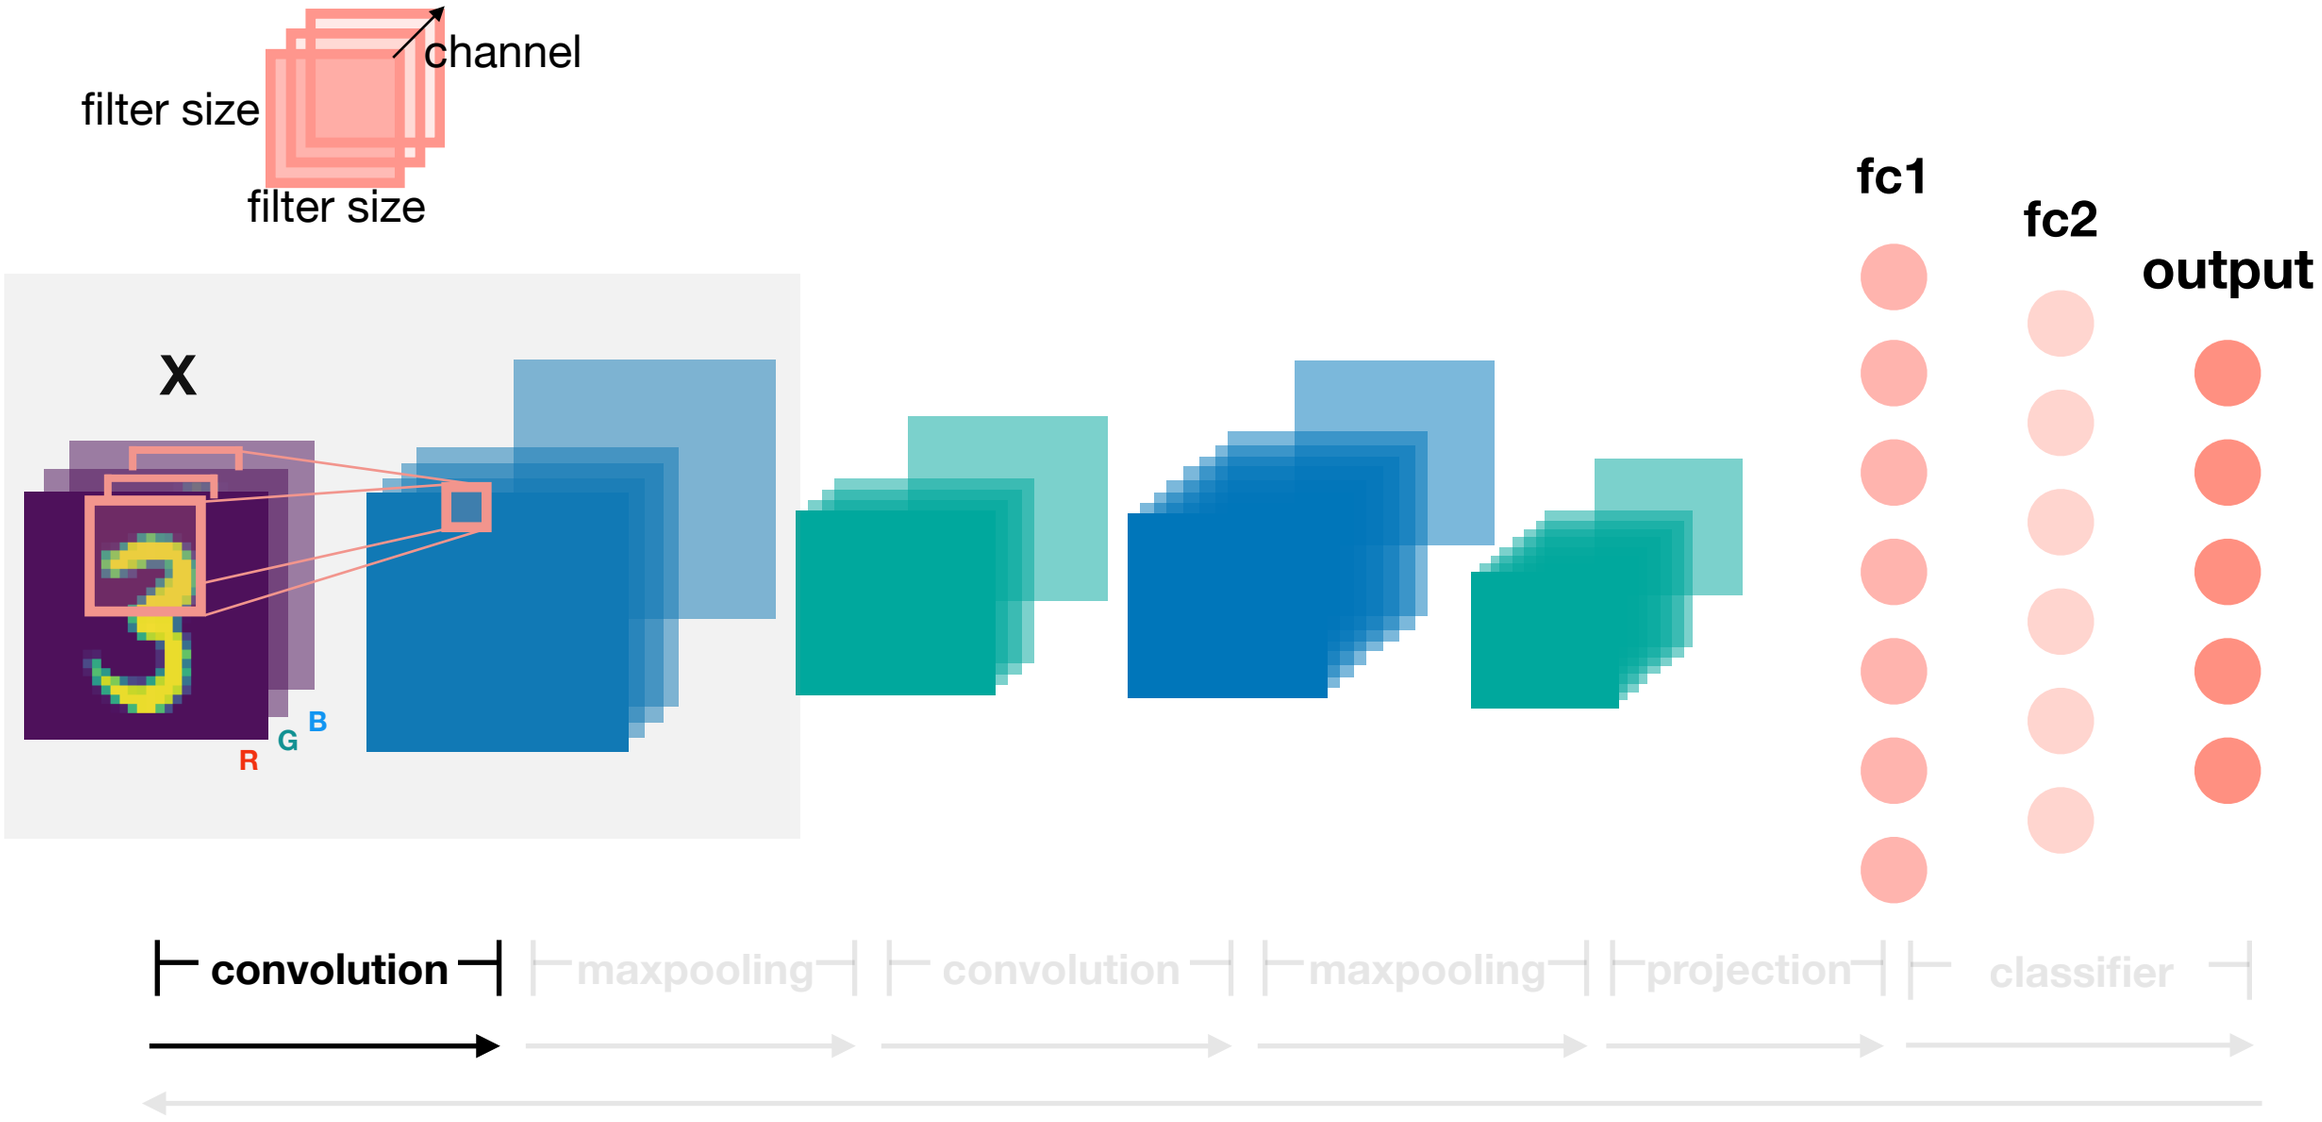

다음은 두 번째 필터(분홍색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 두 번째 feature map (두 번째 앞의 파란색)을 만듭니다.

CNN

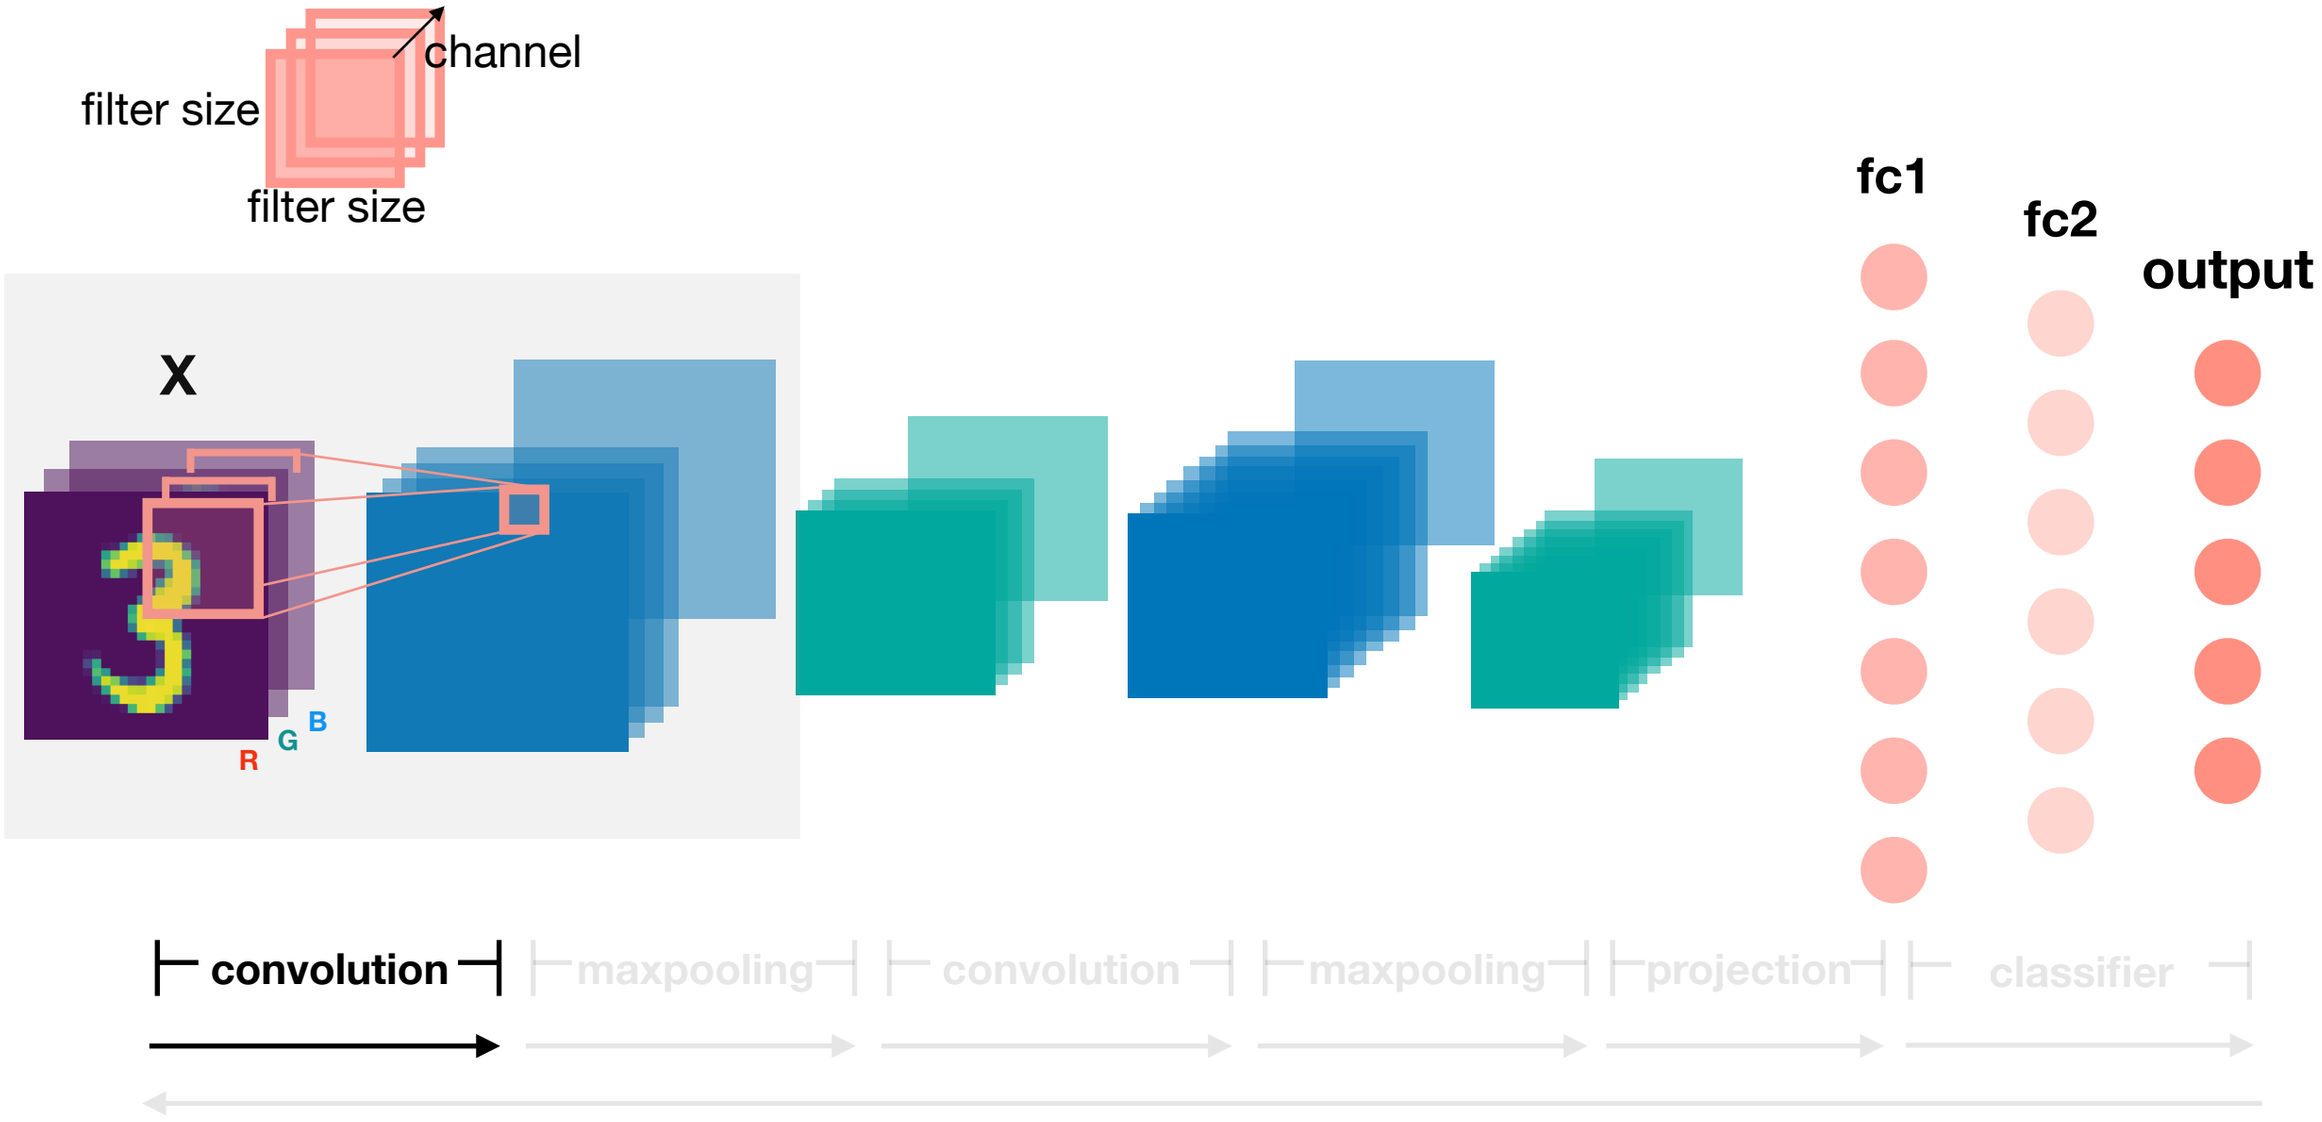

다음은 두 번째 필터(분홍색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 두 번째 feature map (두 번째 앞의 파란색)을 만듭니다.

CNN

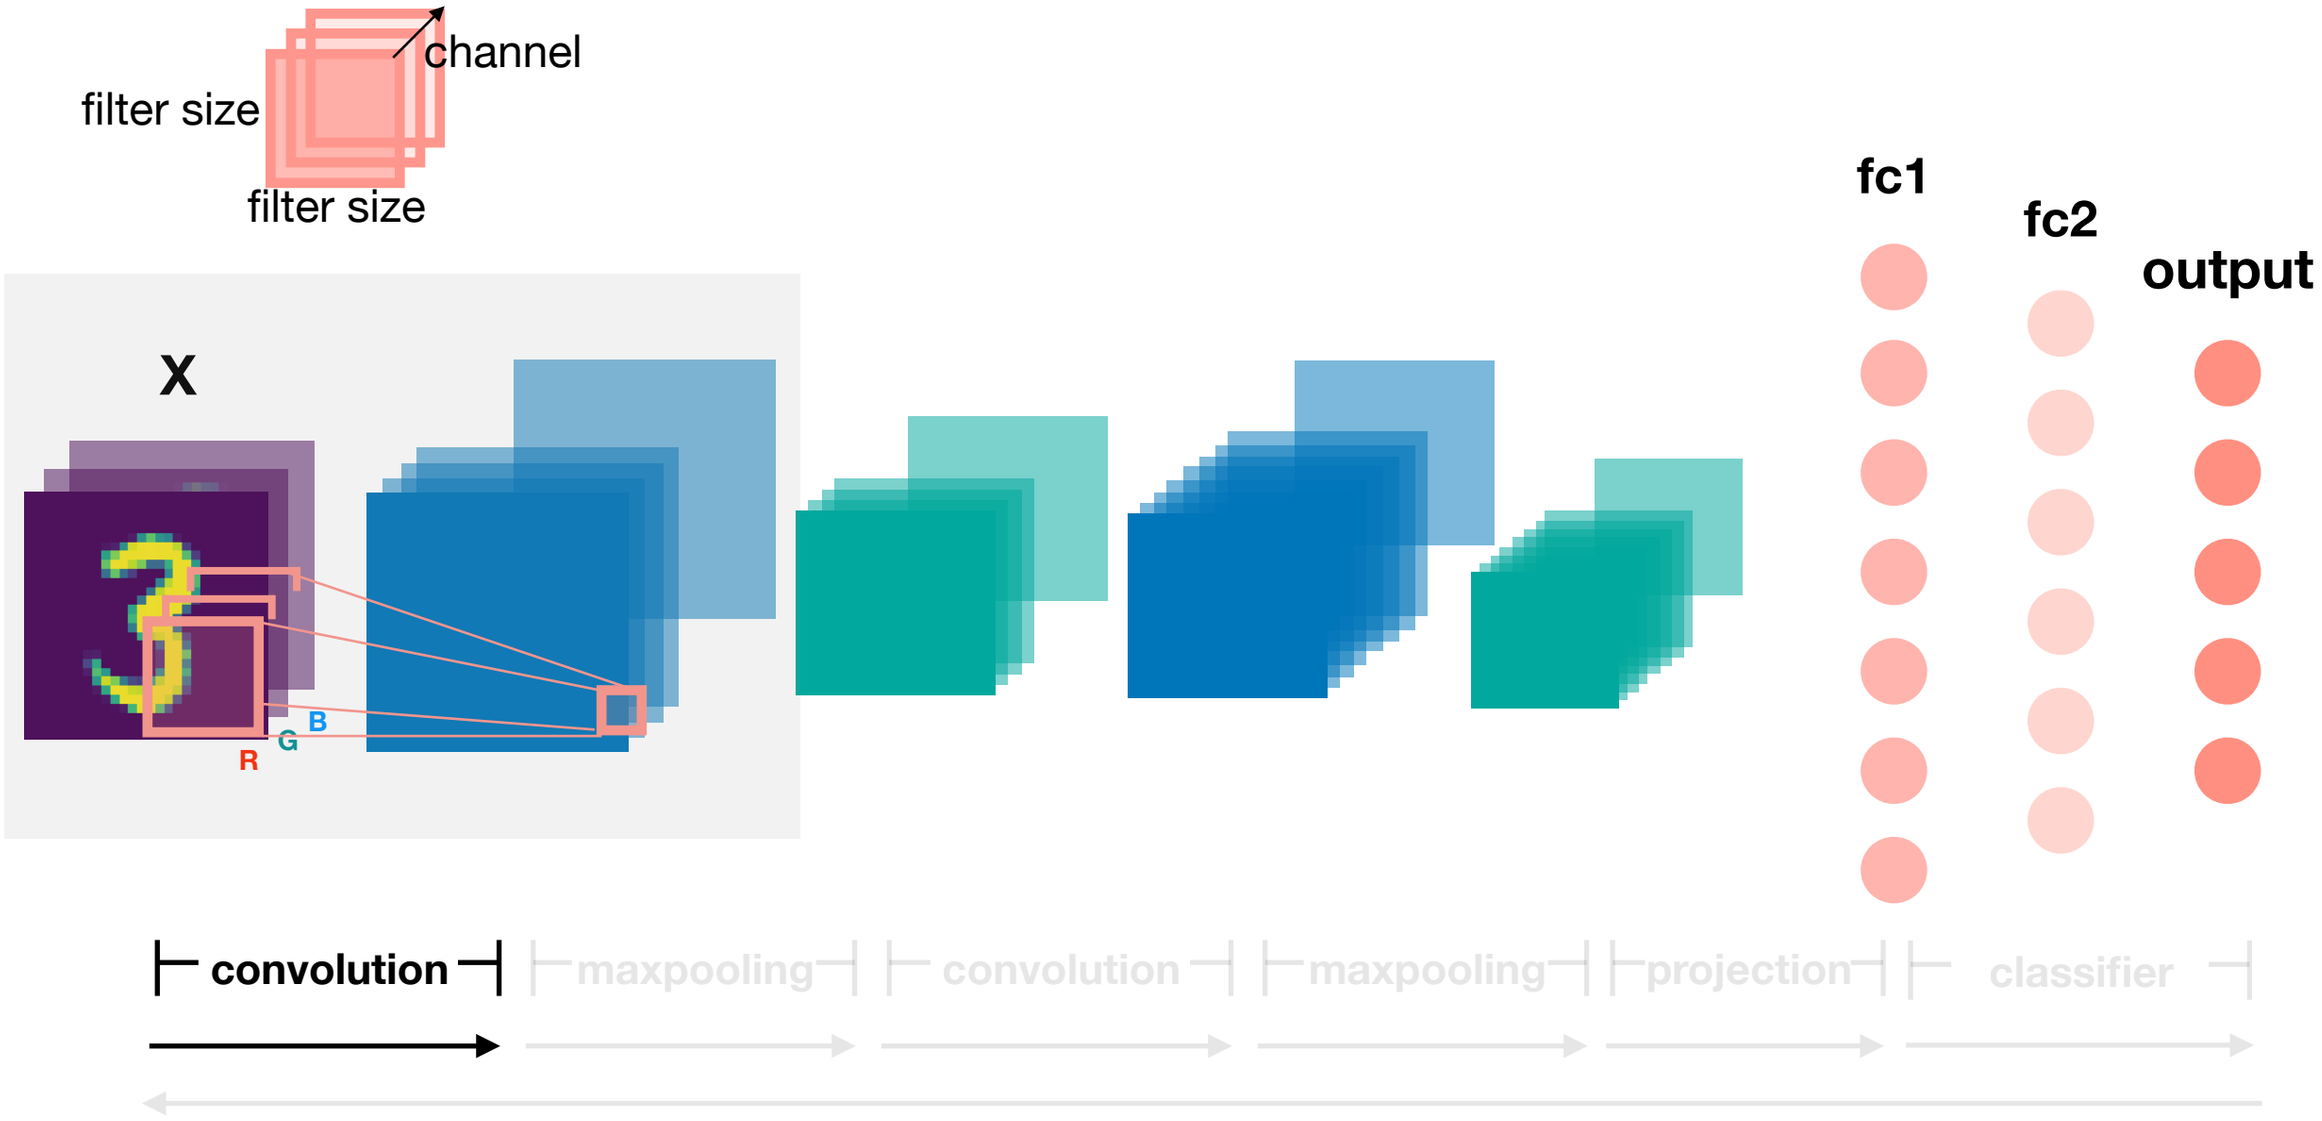

다음은 두 번째 필터(분홍색)를 input의 각 channel마다 씌웁니다.
그렇게 convolution한 값을 모두 더해 두 번째 feature map (두 번째 앞의 파란색)을 만듭니다.

CNN

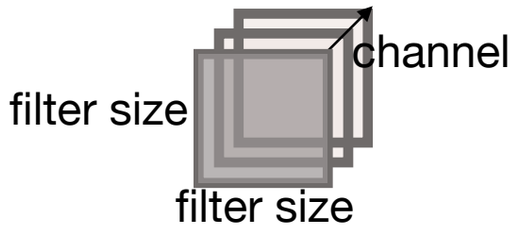

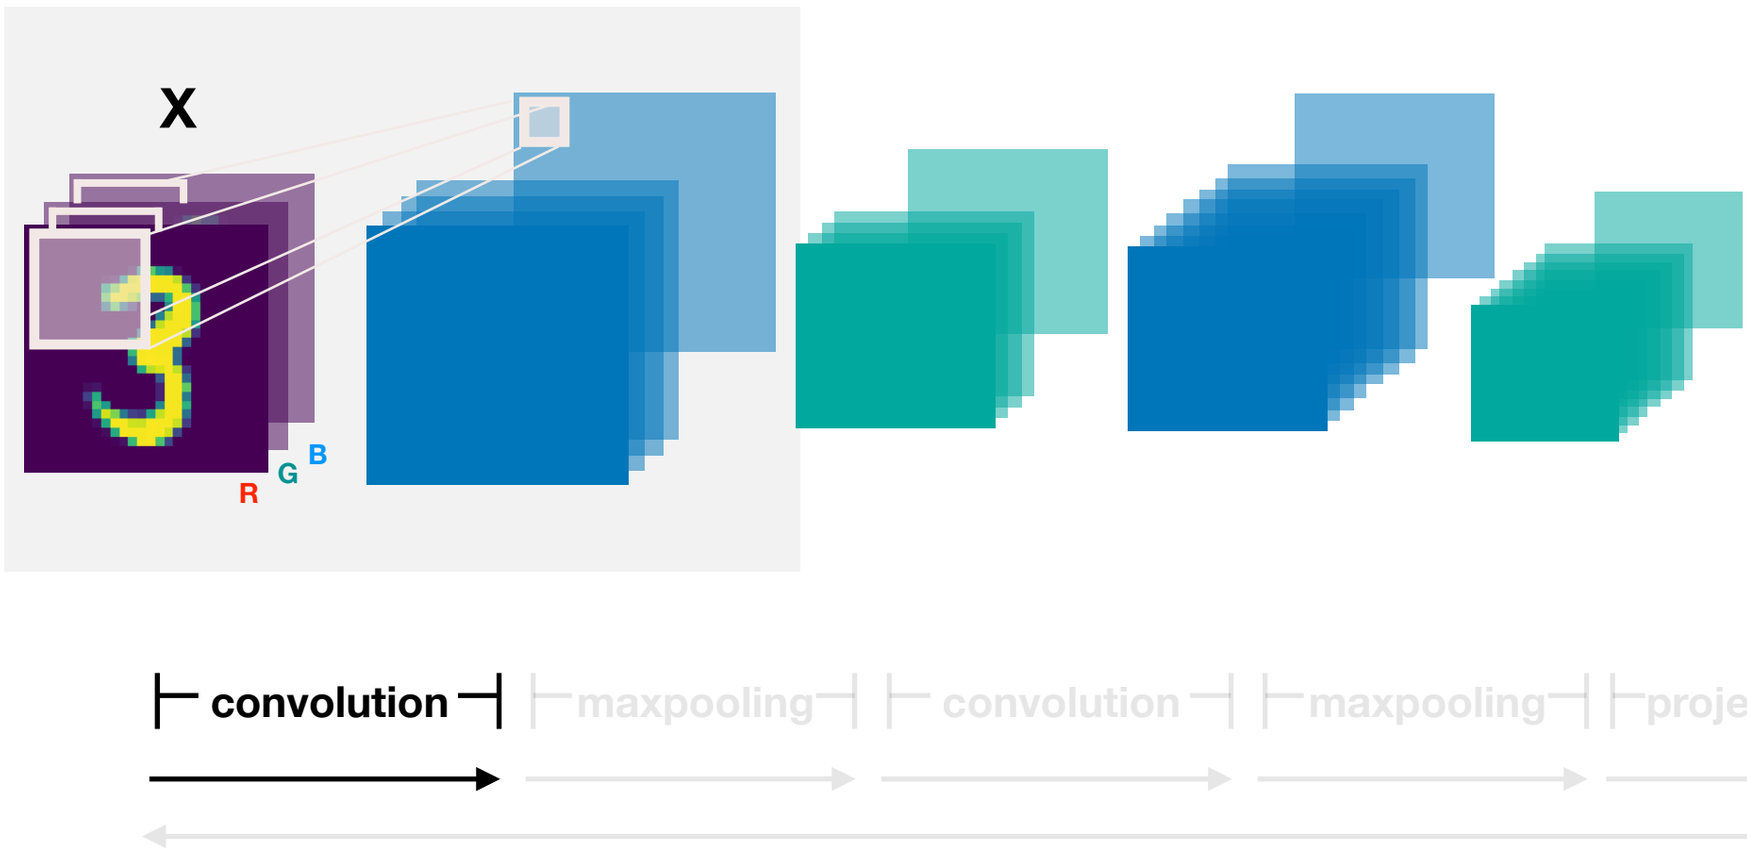

마지막 feature map (제일 뒤의 파란색)을 만들 때까지 반복합니다.

CNN

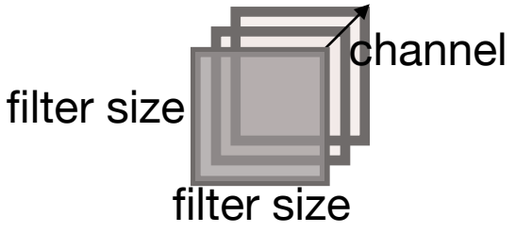

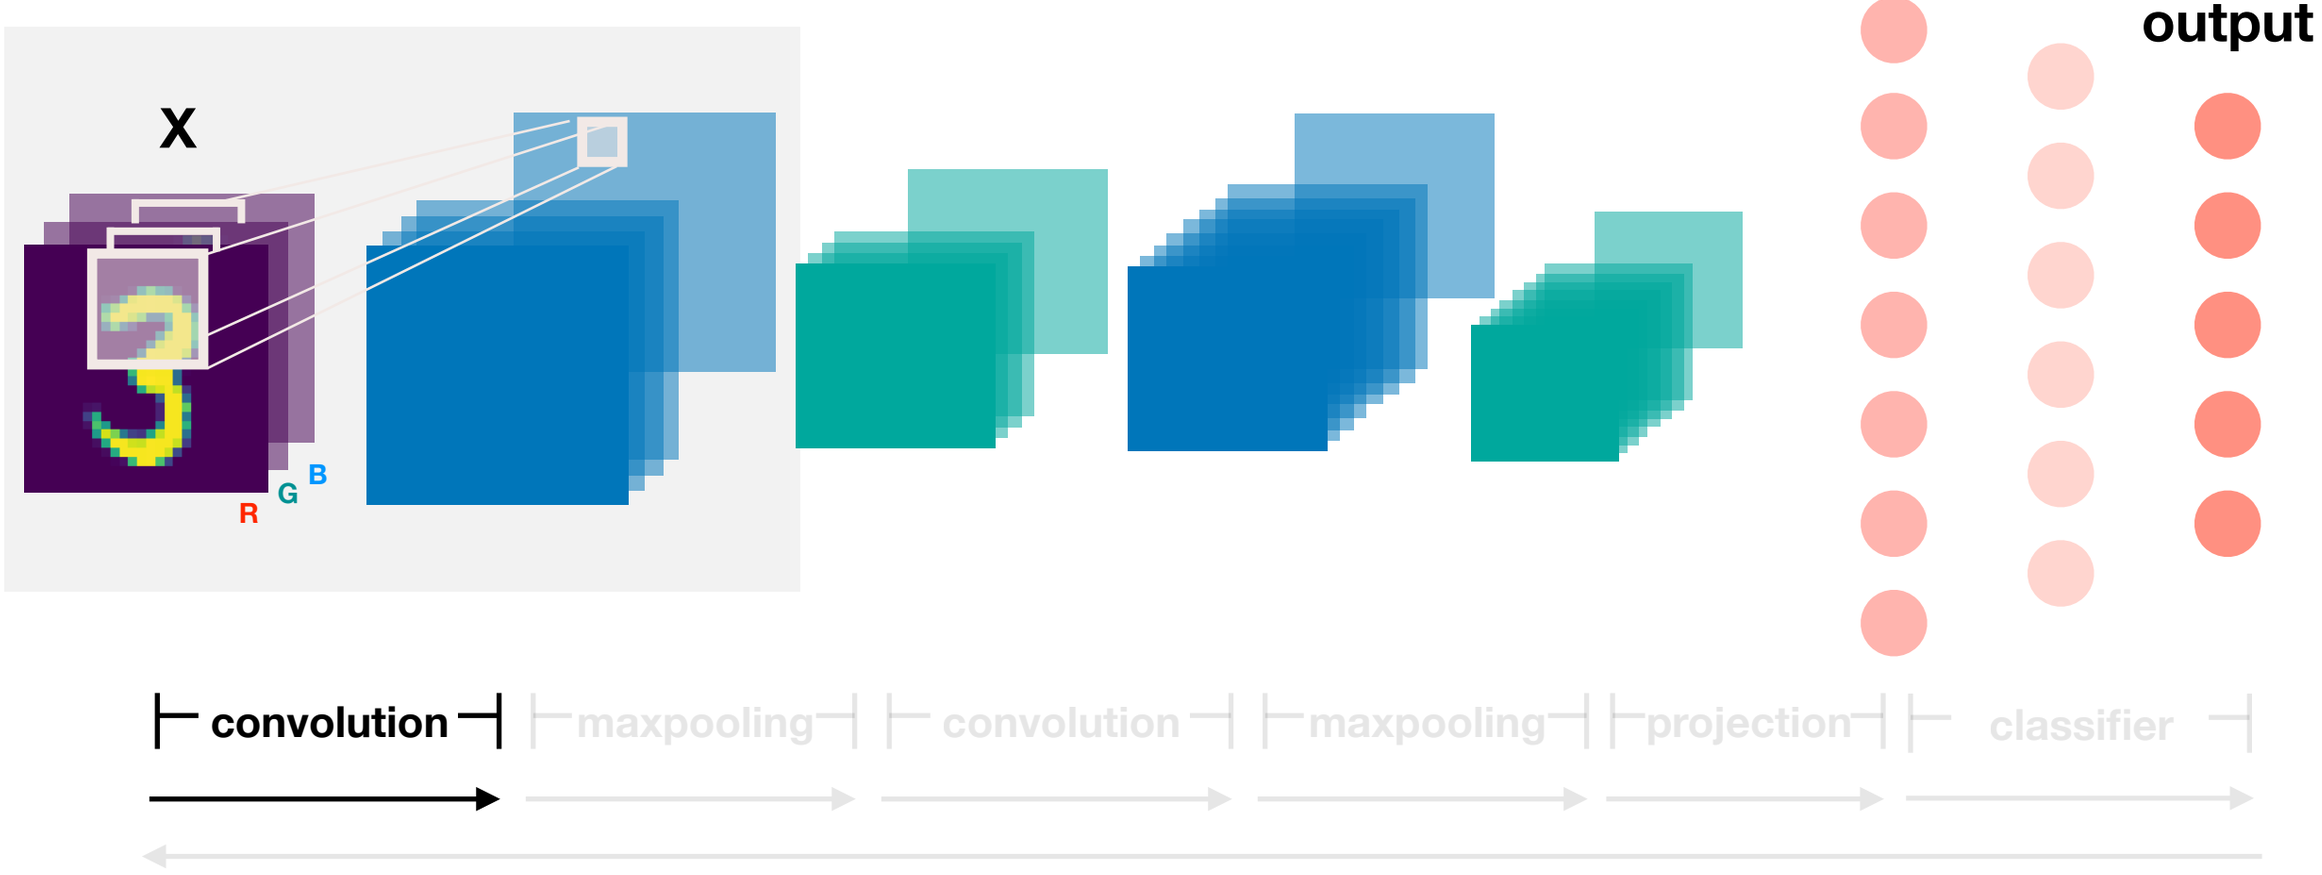

마지막 feature map (제일 뒤의 파란색)을 만들 때까지 반복합니다.

CNN

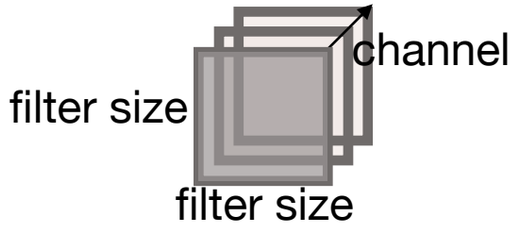

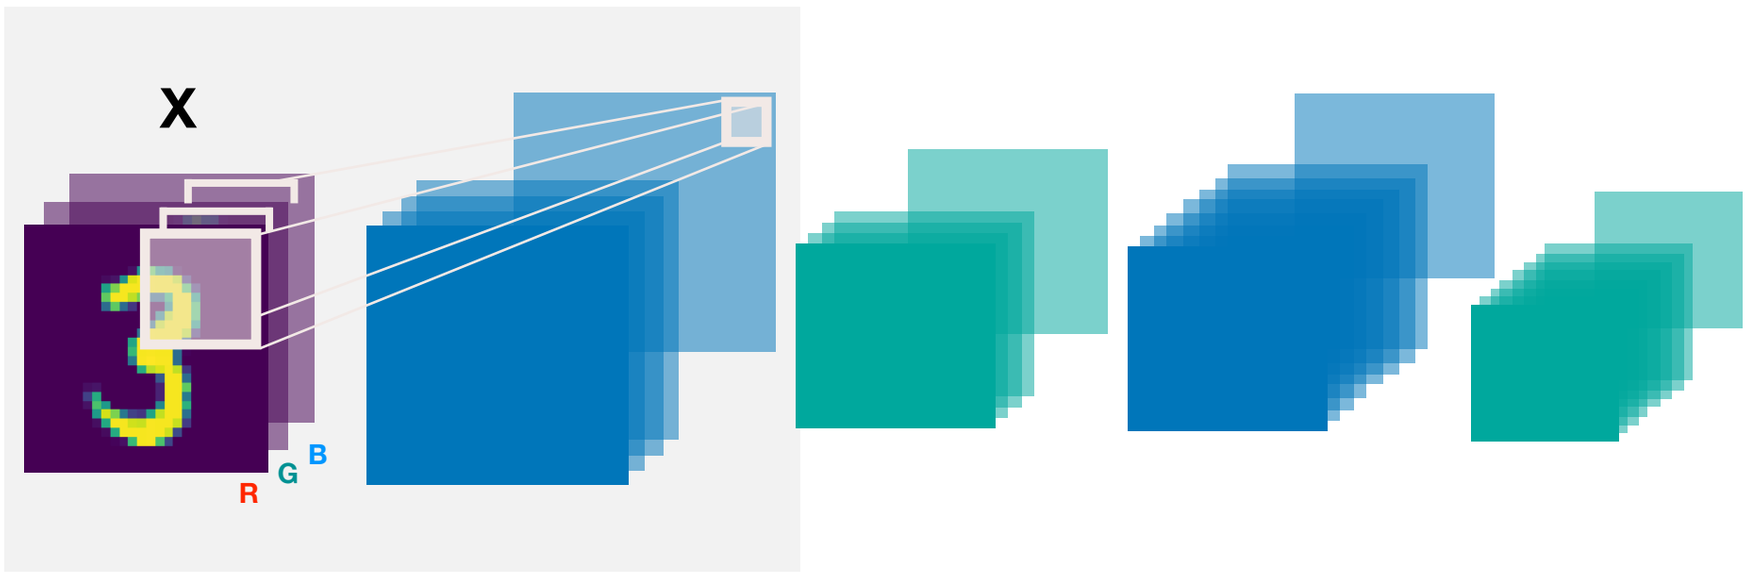

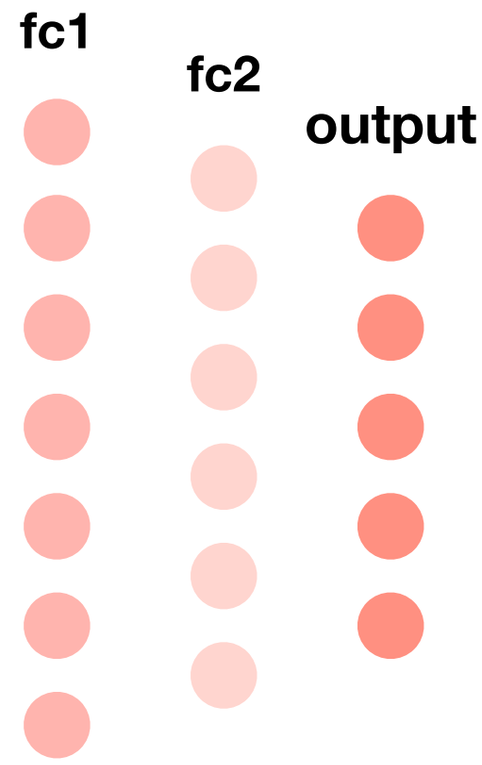

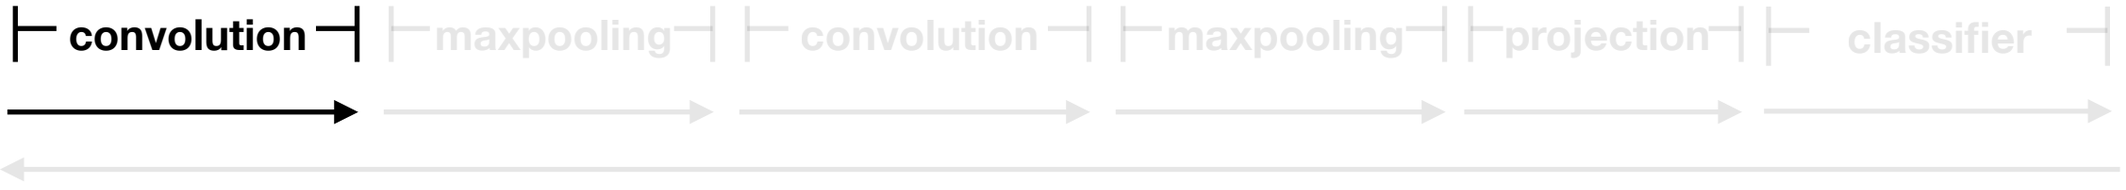

마지막 feature map (제일 뒤의 파란색)을 만들 때까지 반복합니다.

CNN

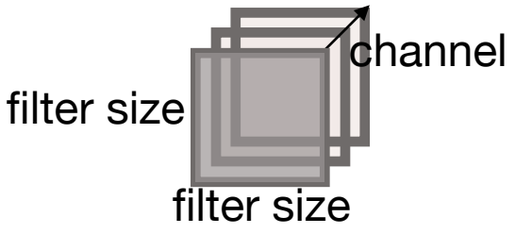

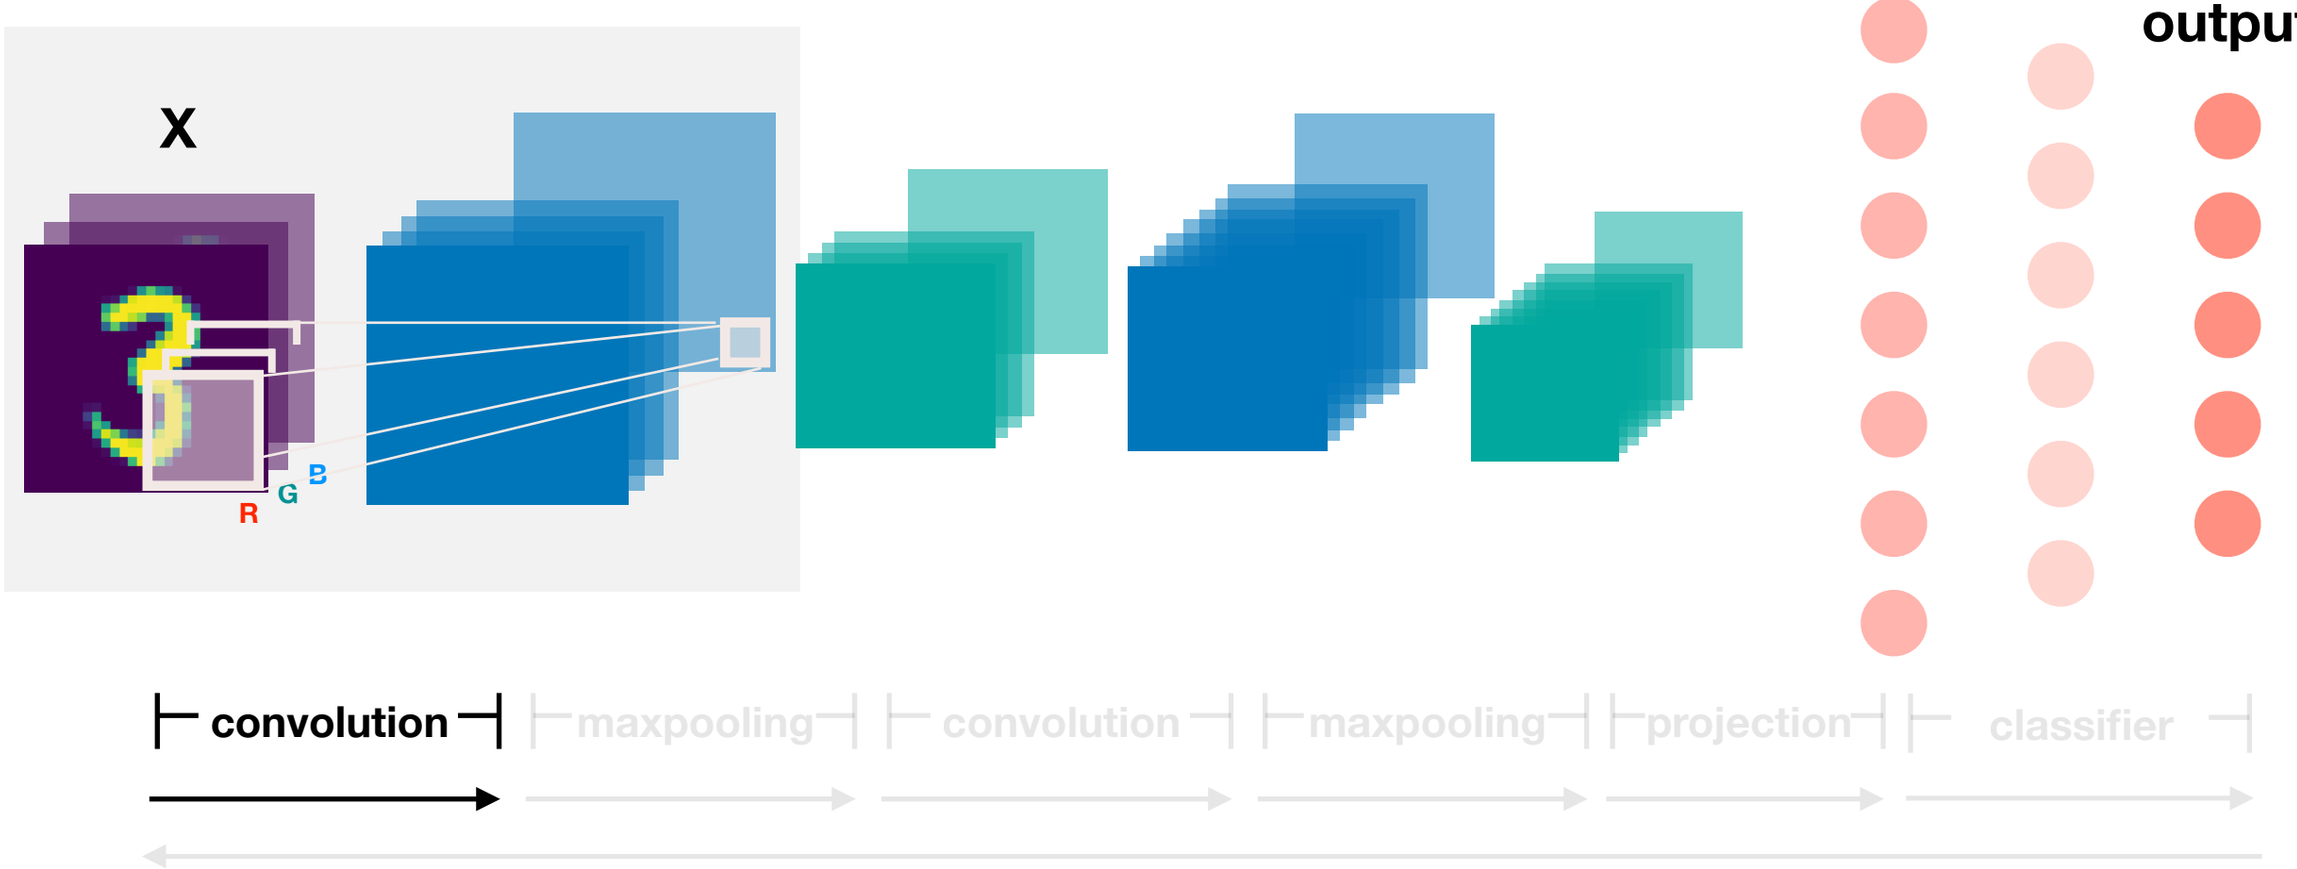

마지막 feature map (제일 뒤의 파란색)을 만들 때까지 반복합니다.

CNN

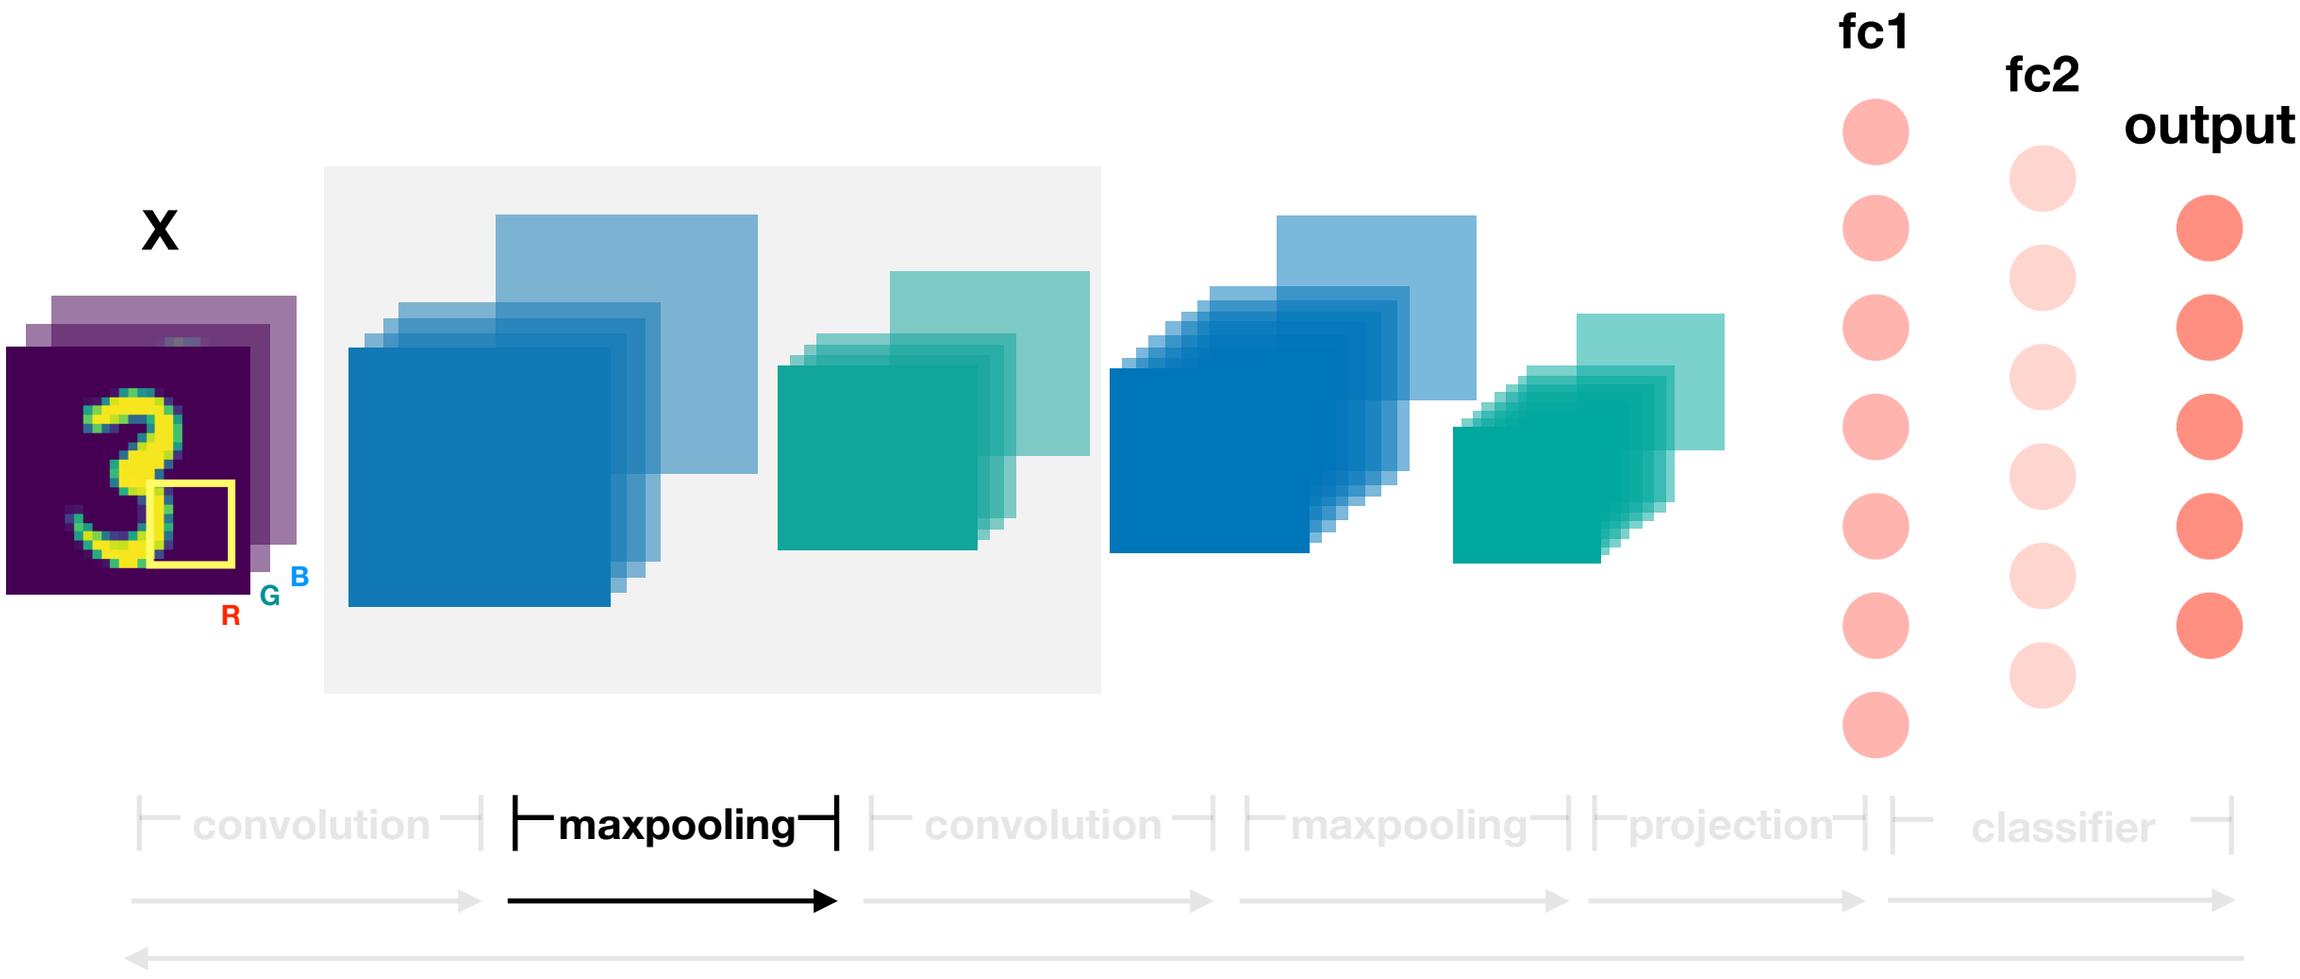

max pooling을 합니다.
이 때 feature map (파란색)과 pooling된 feature map (초록색)은 개수가 동일합니다.

CNN

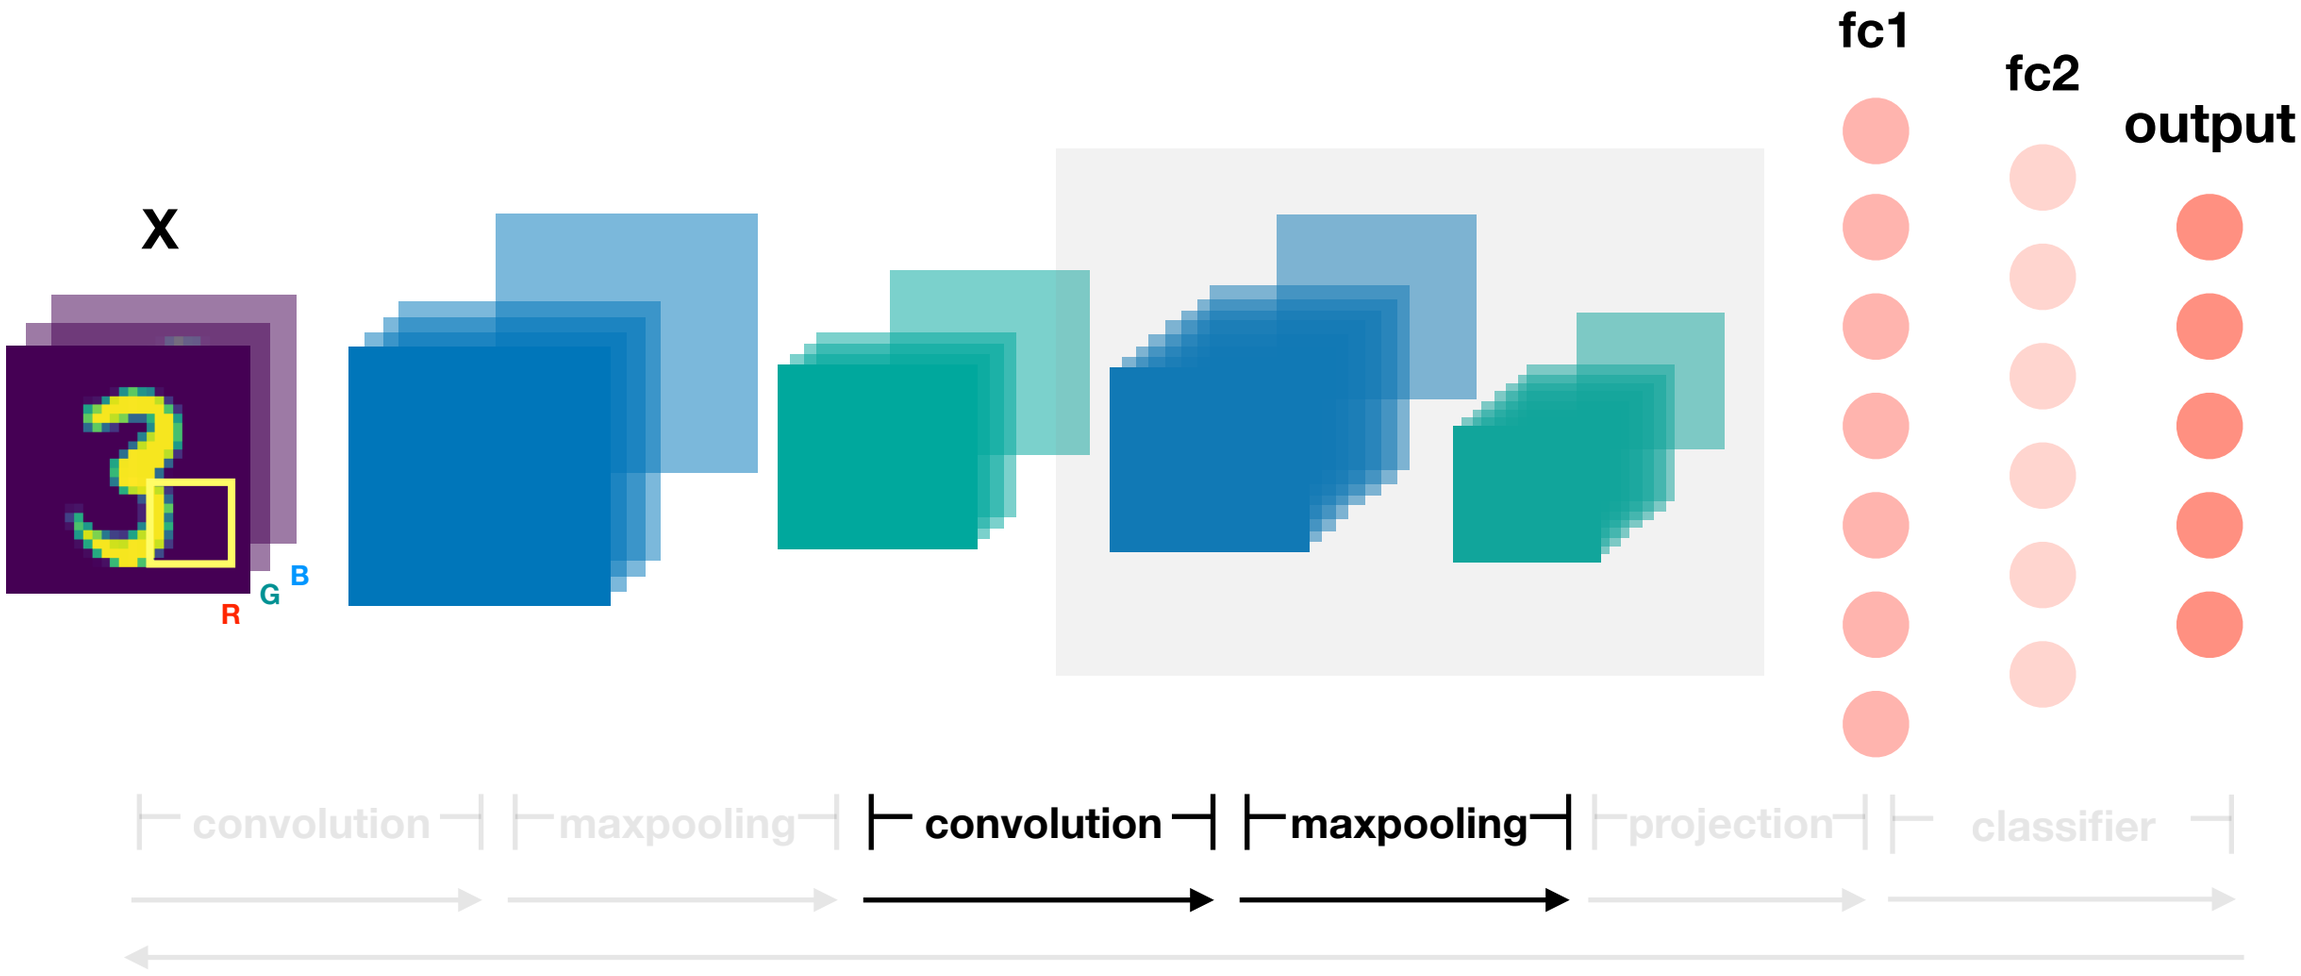

convolution과 max pooling을 반복합니다.
(원하는 만큼 하면 됩니다. 단, 이 예시에선 각각 2회만 하고 있습니다.)

CNN

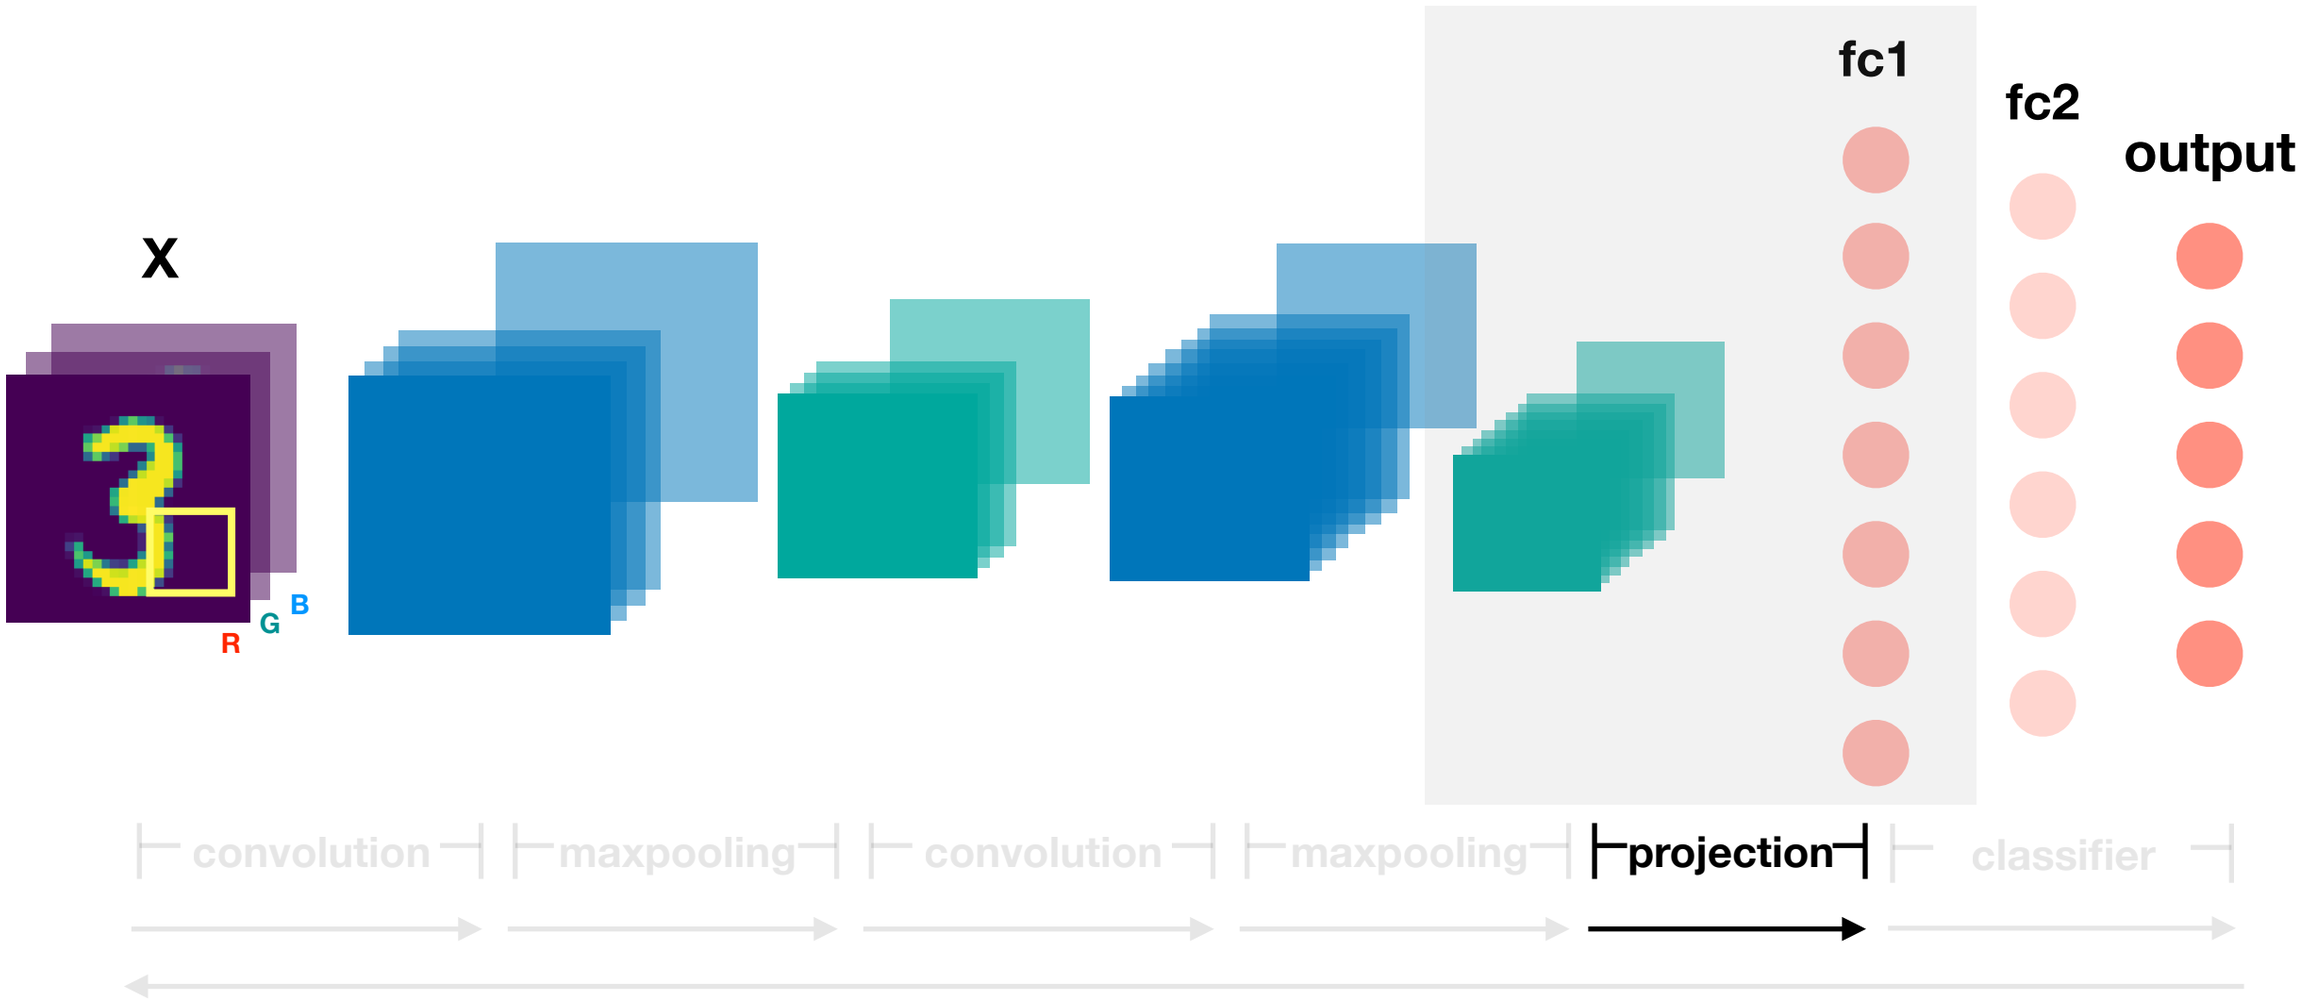

이제 완성된 feature map을 모두 모아 한 줄로 나열한 뒤 fc1 layer에 넣습니다.

CNN

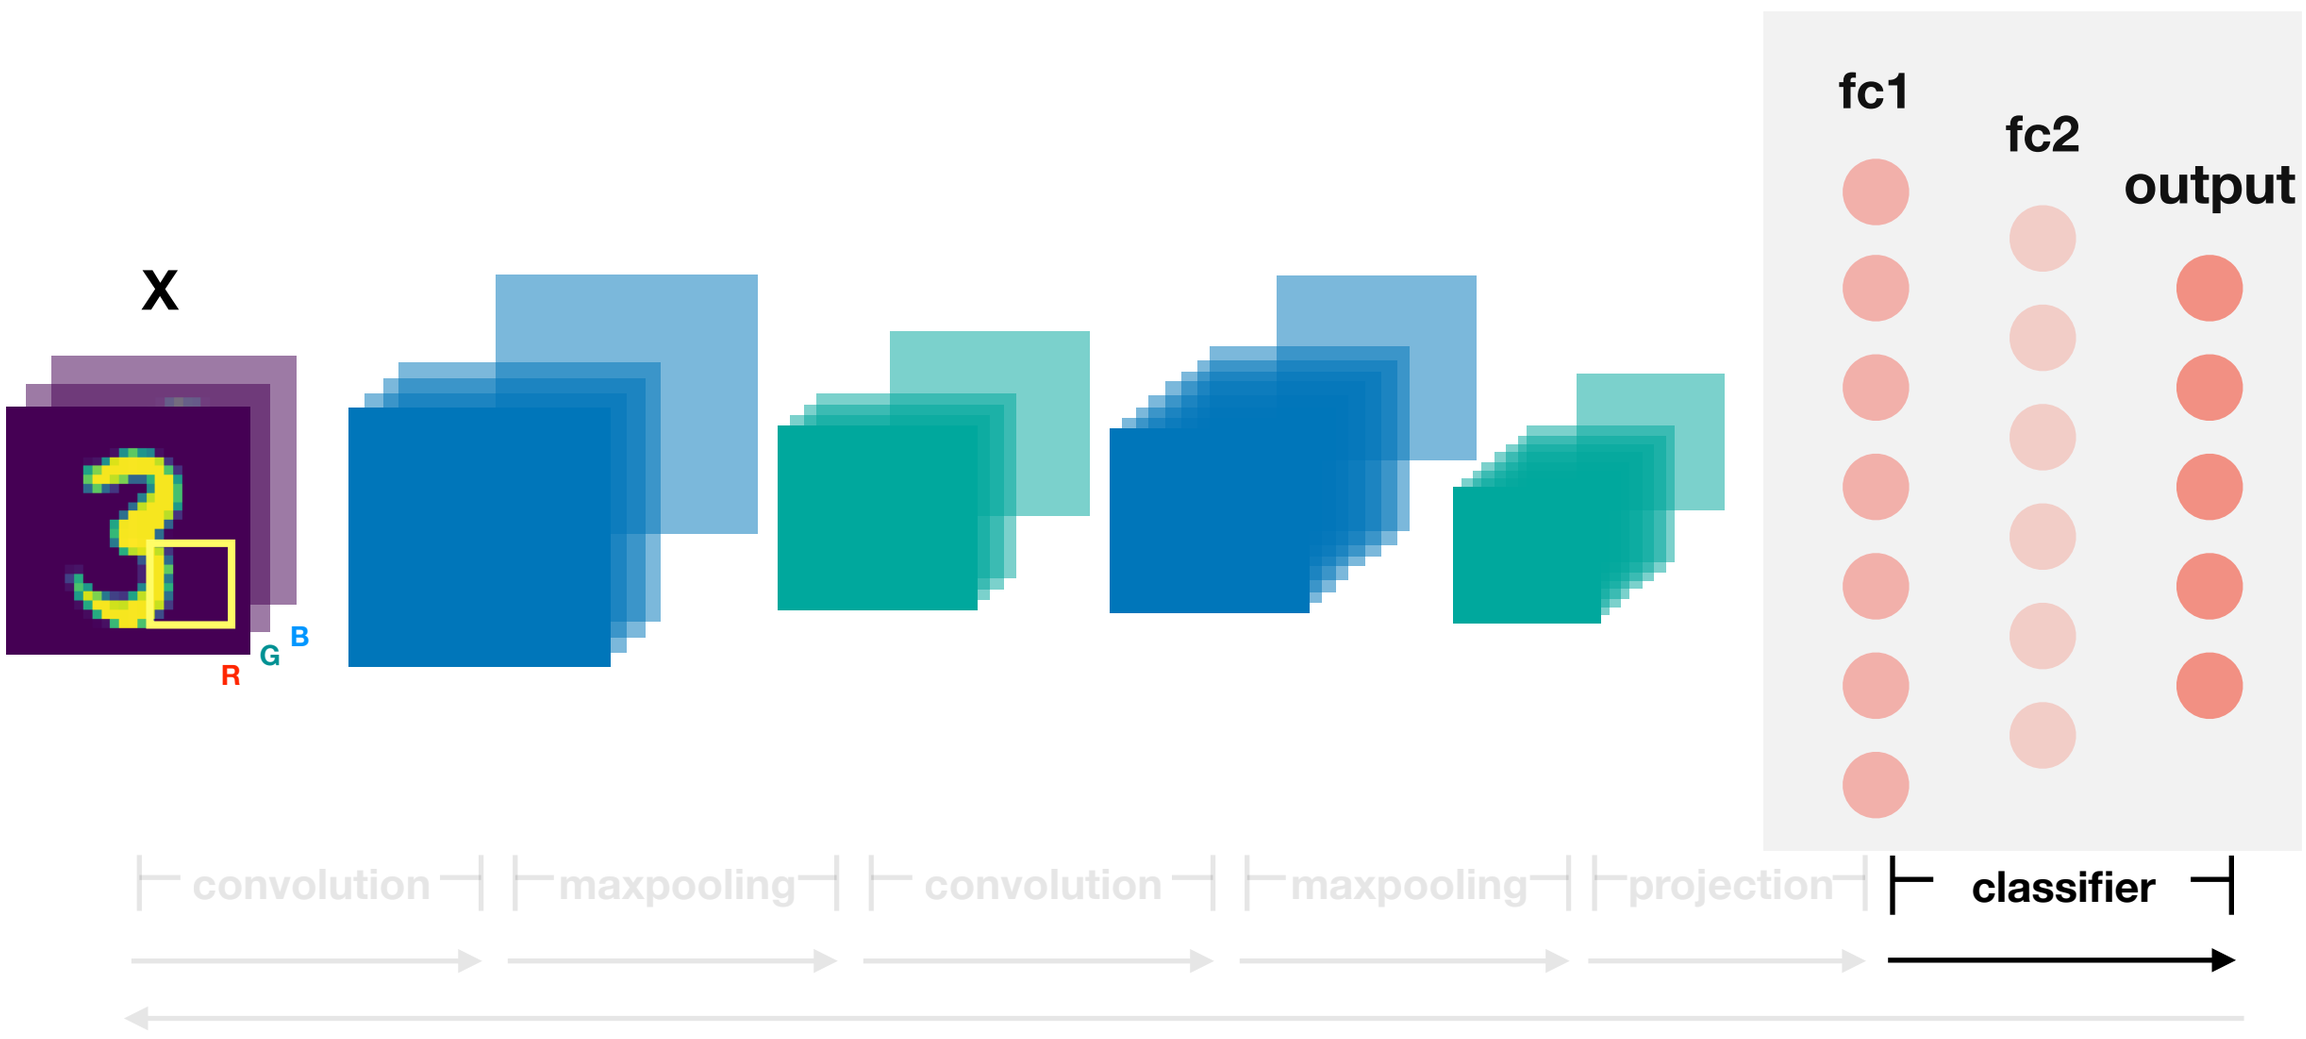

classifier 부분은 ANN과 동일합니다.

CNN

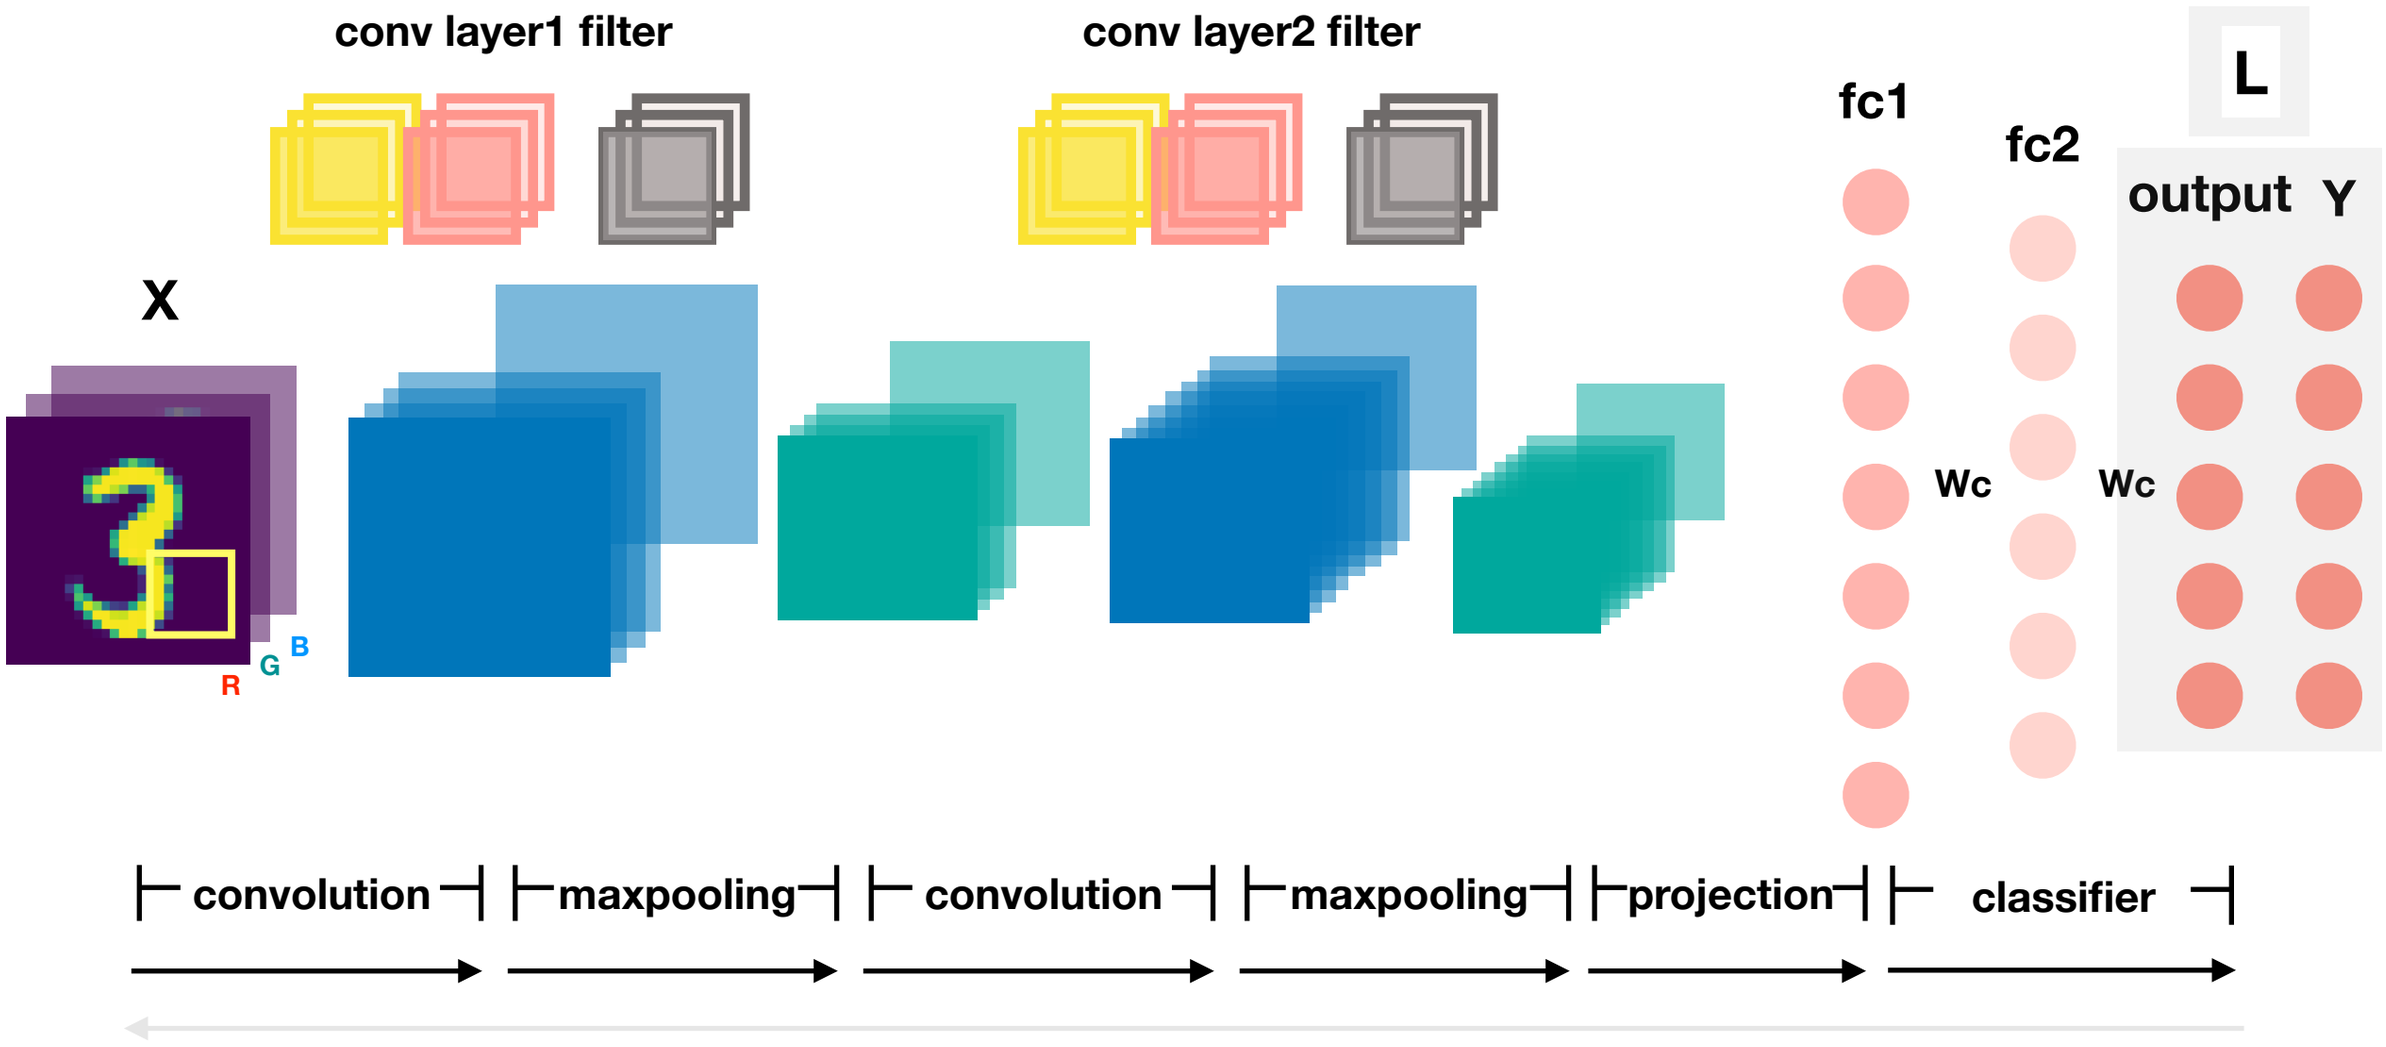

output과 정답 target (Y)을 비교하여 loss를 구합니다.

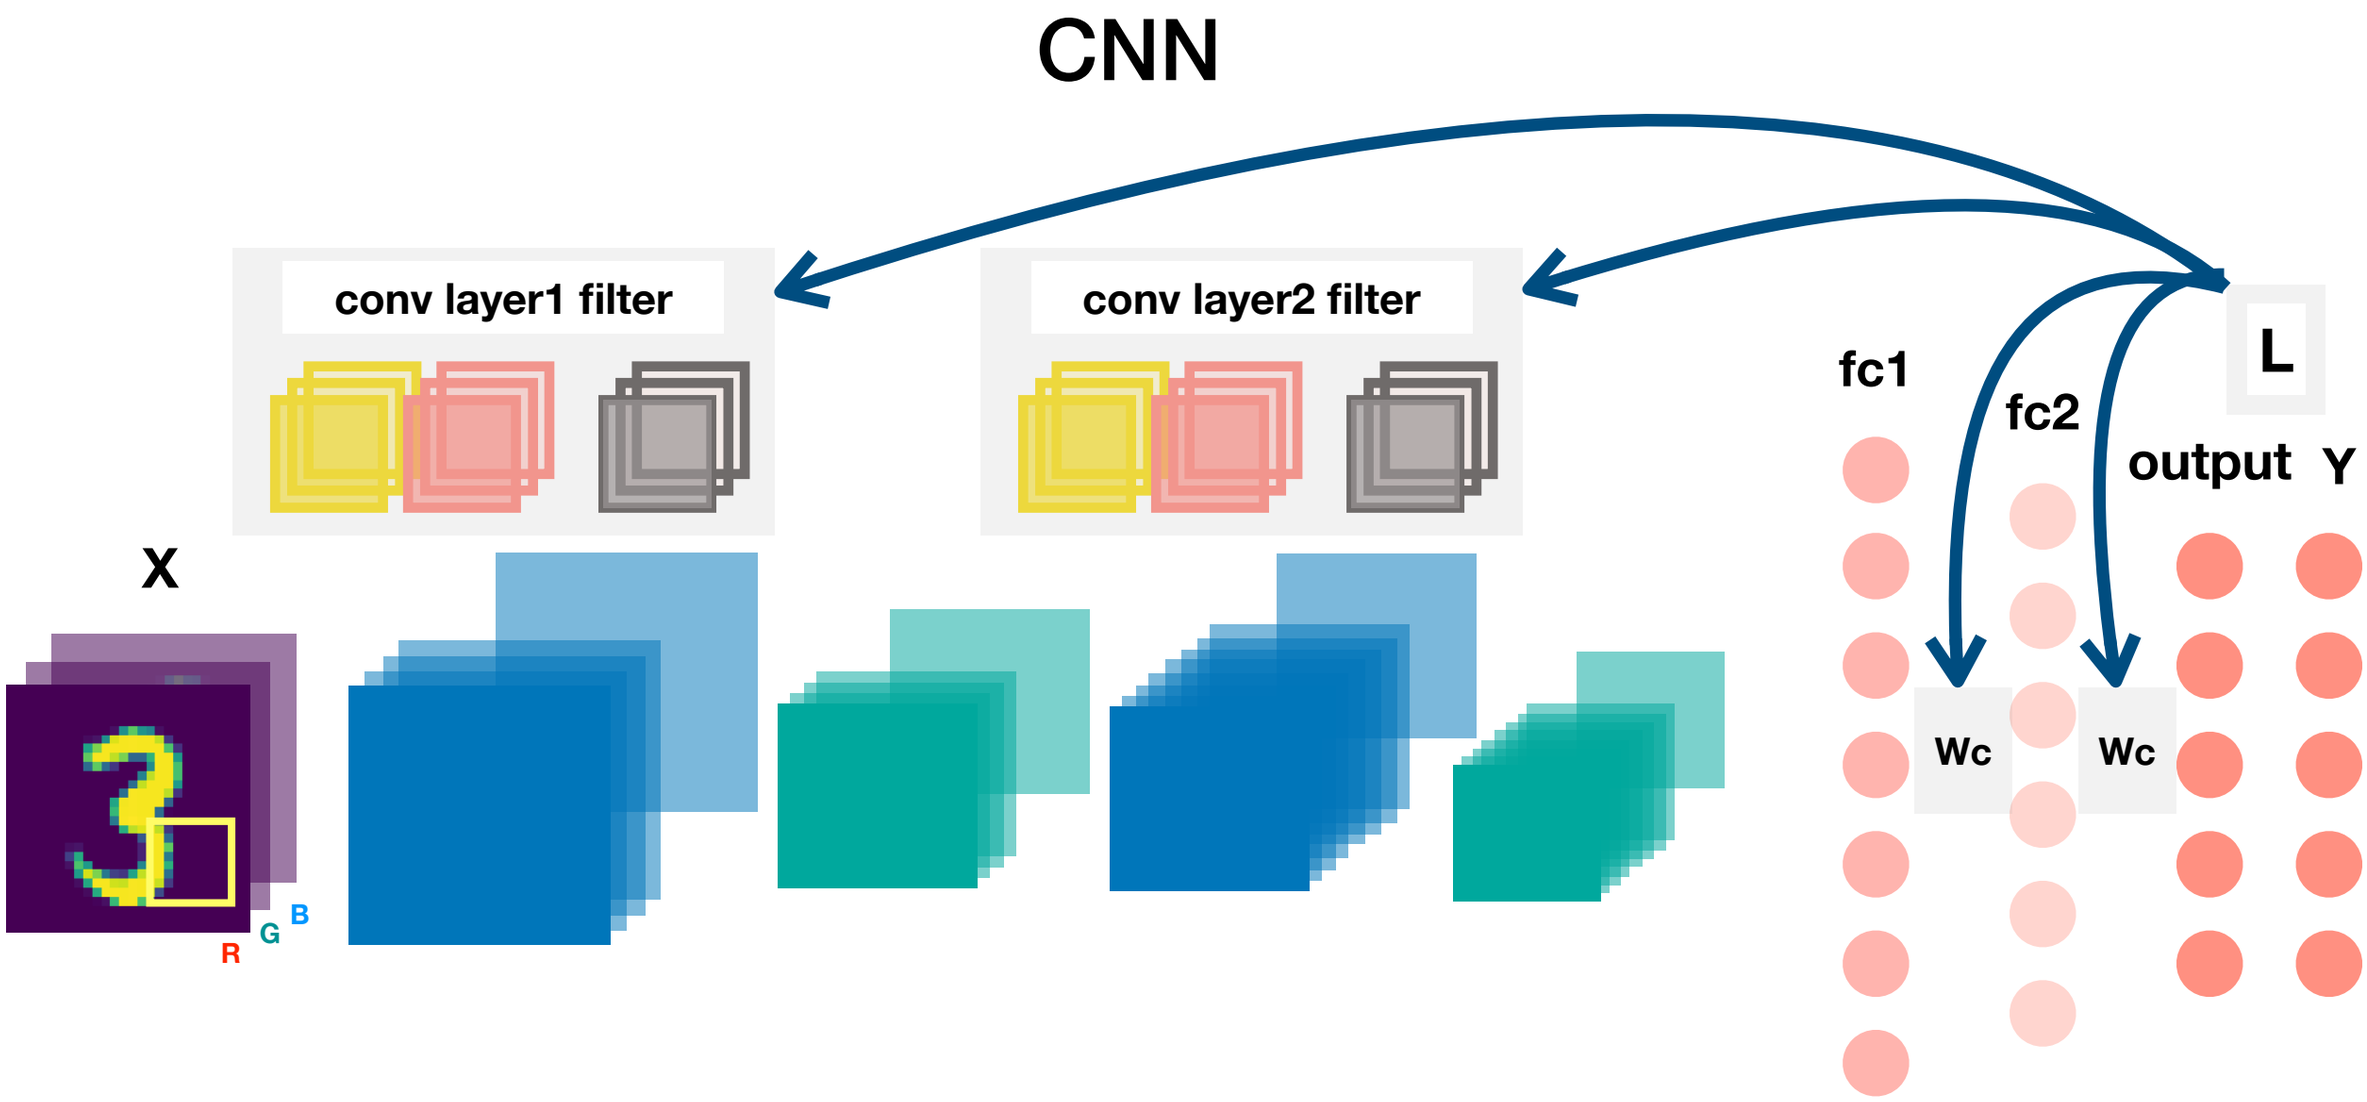

loss를 최소화하는 방향으로, weight을 update 합니다.

WORD2VEC

Word2Vec

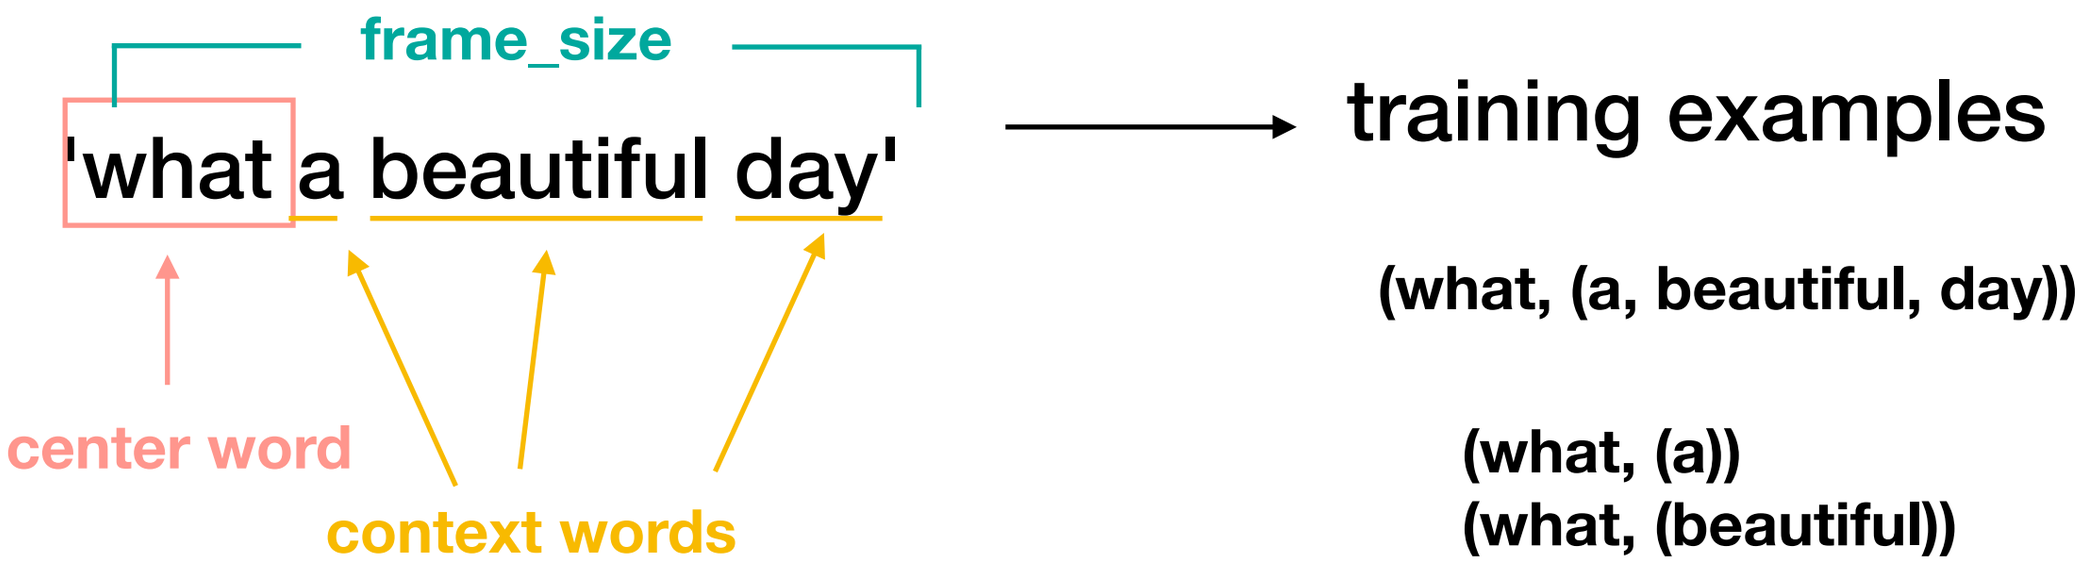

word2vec의 training data 준비방식은 다음과 같습니다.
문장의 각 단어를 center word (분홍색)로 정하고
frame size만큼의 단어를 context word (노란색)로 지정합니다.
하나의 center word가 input이 되고 그 center word에 대한 context word 각각이 target이 됩니다.

Word2Vec

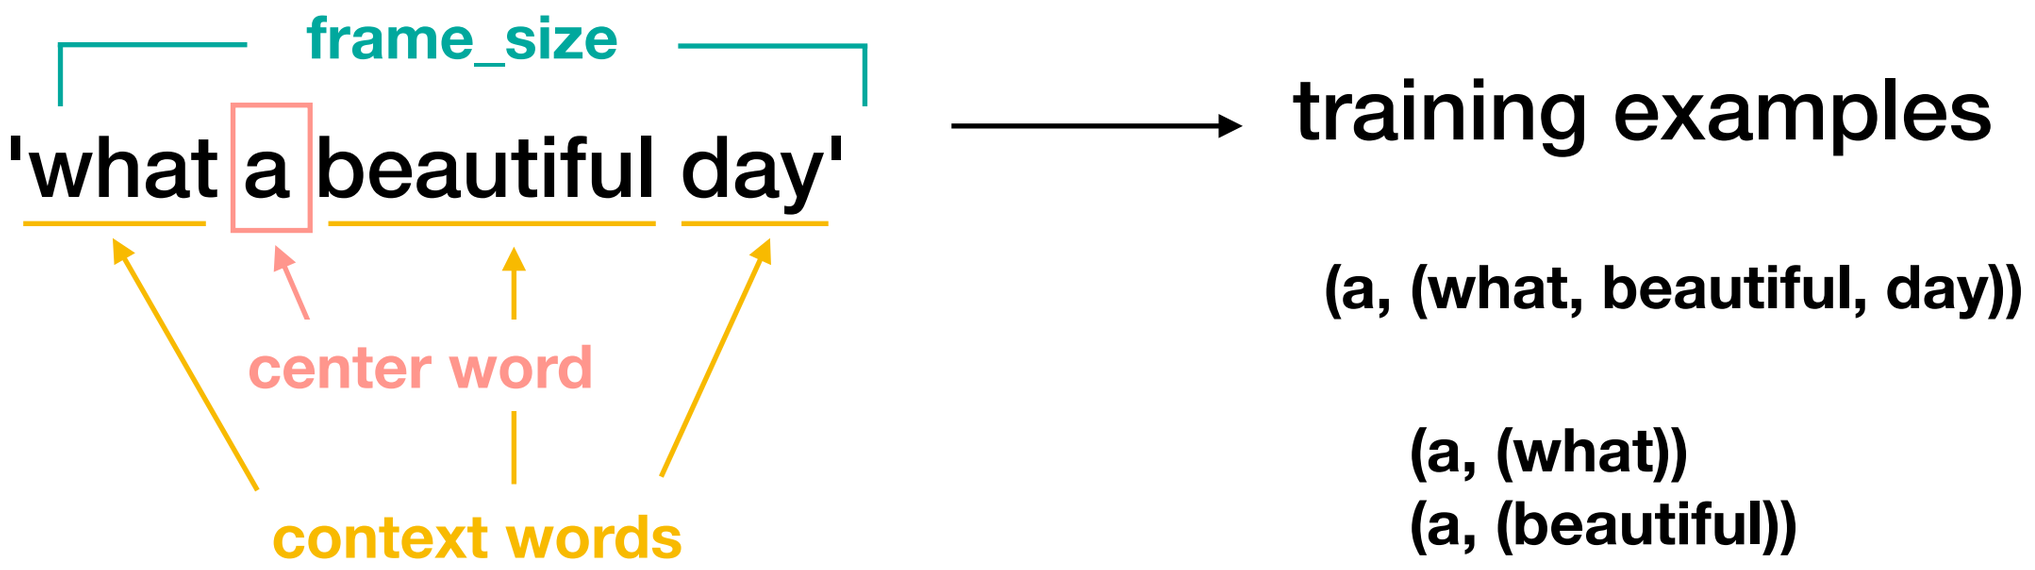

word2vec의 training data 준비방식은 다음과 같습니다.
문장의 각 단어를 center word (분홍색)로 정하고
frame size만큼의 단어를 context word (노란색)로 지정합니다.
하나의 center word가 input이 되고 그 center word에 대한 context word 각각이 target이 됩니다.

Word2Vec

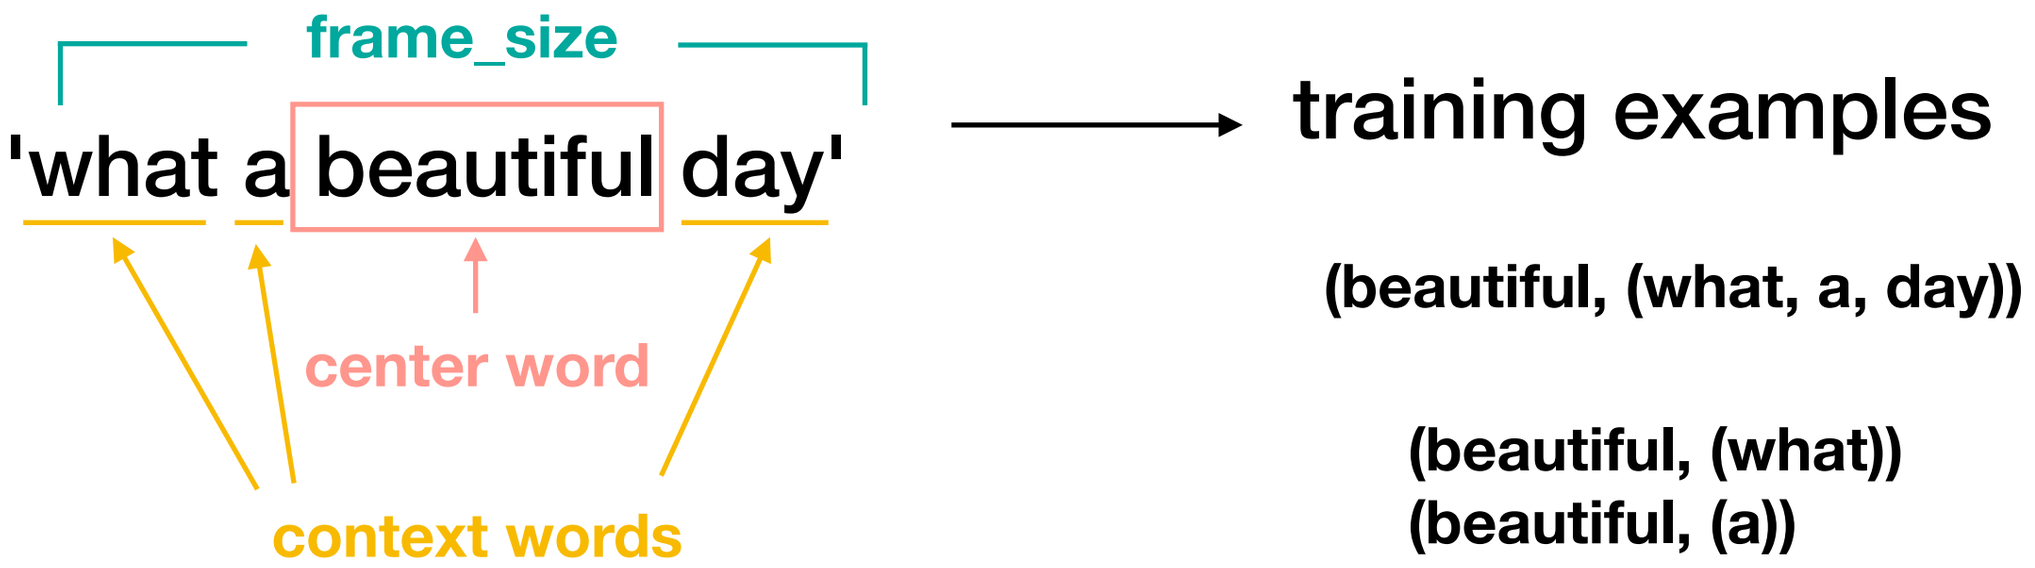

word2vec의 training data 준비방식은 다음과 같습니다.
문장의 각 단어를 center word (분홍색)로 정하고
frame size만큼의 단어를 context word (노란색)로 지정합니다.
하나의 center word가 input이 되고 그 center word에 대한 context word 각각이 target이 됩니다.

Word2Vec

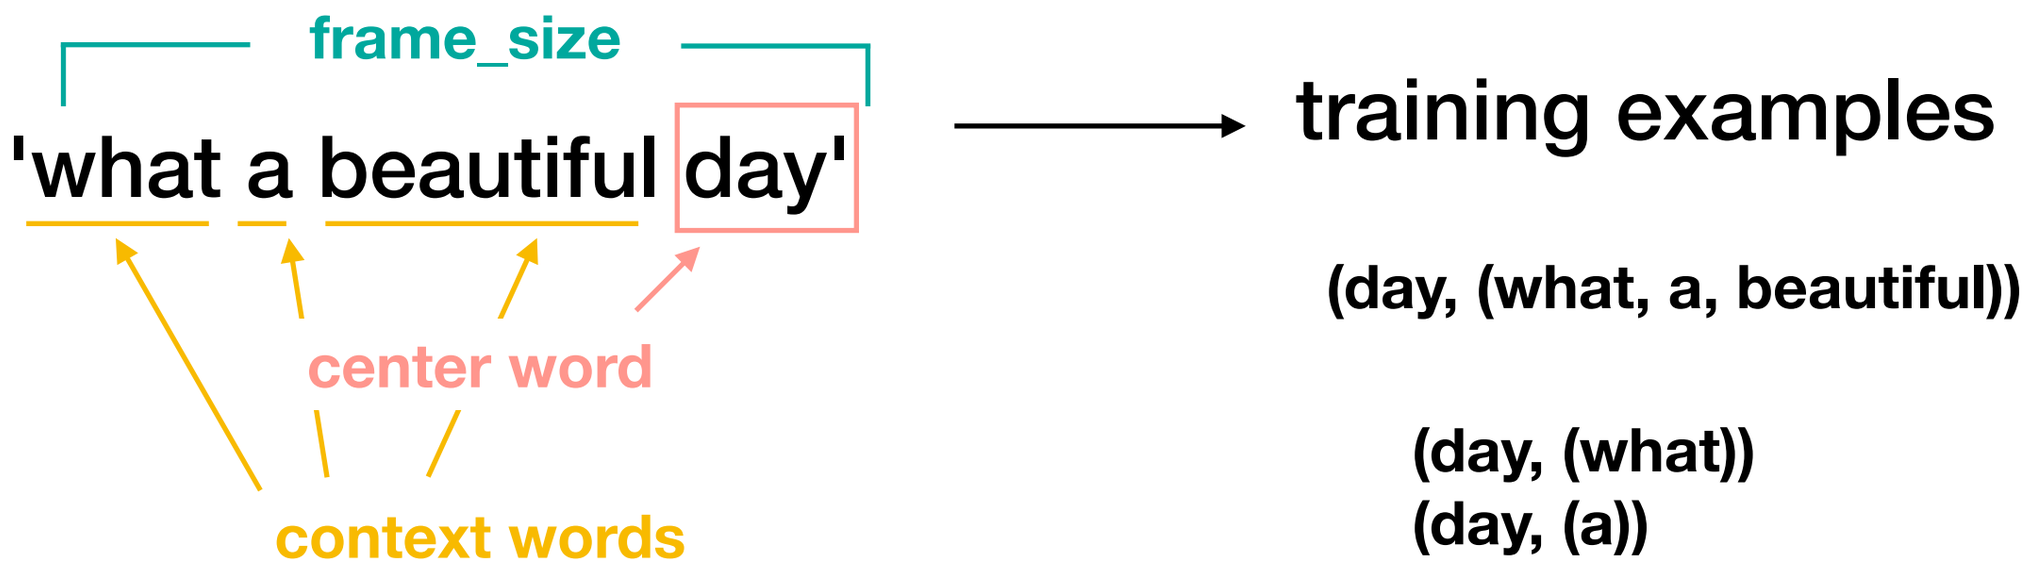

word2vec의 training data 준비방식은 다음과 같습니다.
문장의 각 단어를 center word (분홍색)로 정하고
frame size만큼의 단어를 context word (노란색)로 지정합니다.
하나의 center word가 input이 되고 그 center word에 대한 context word 각각이 target이 됩니다.

Word2Vec

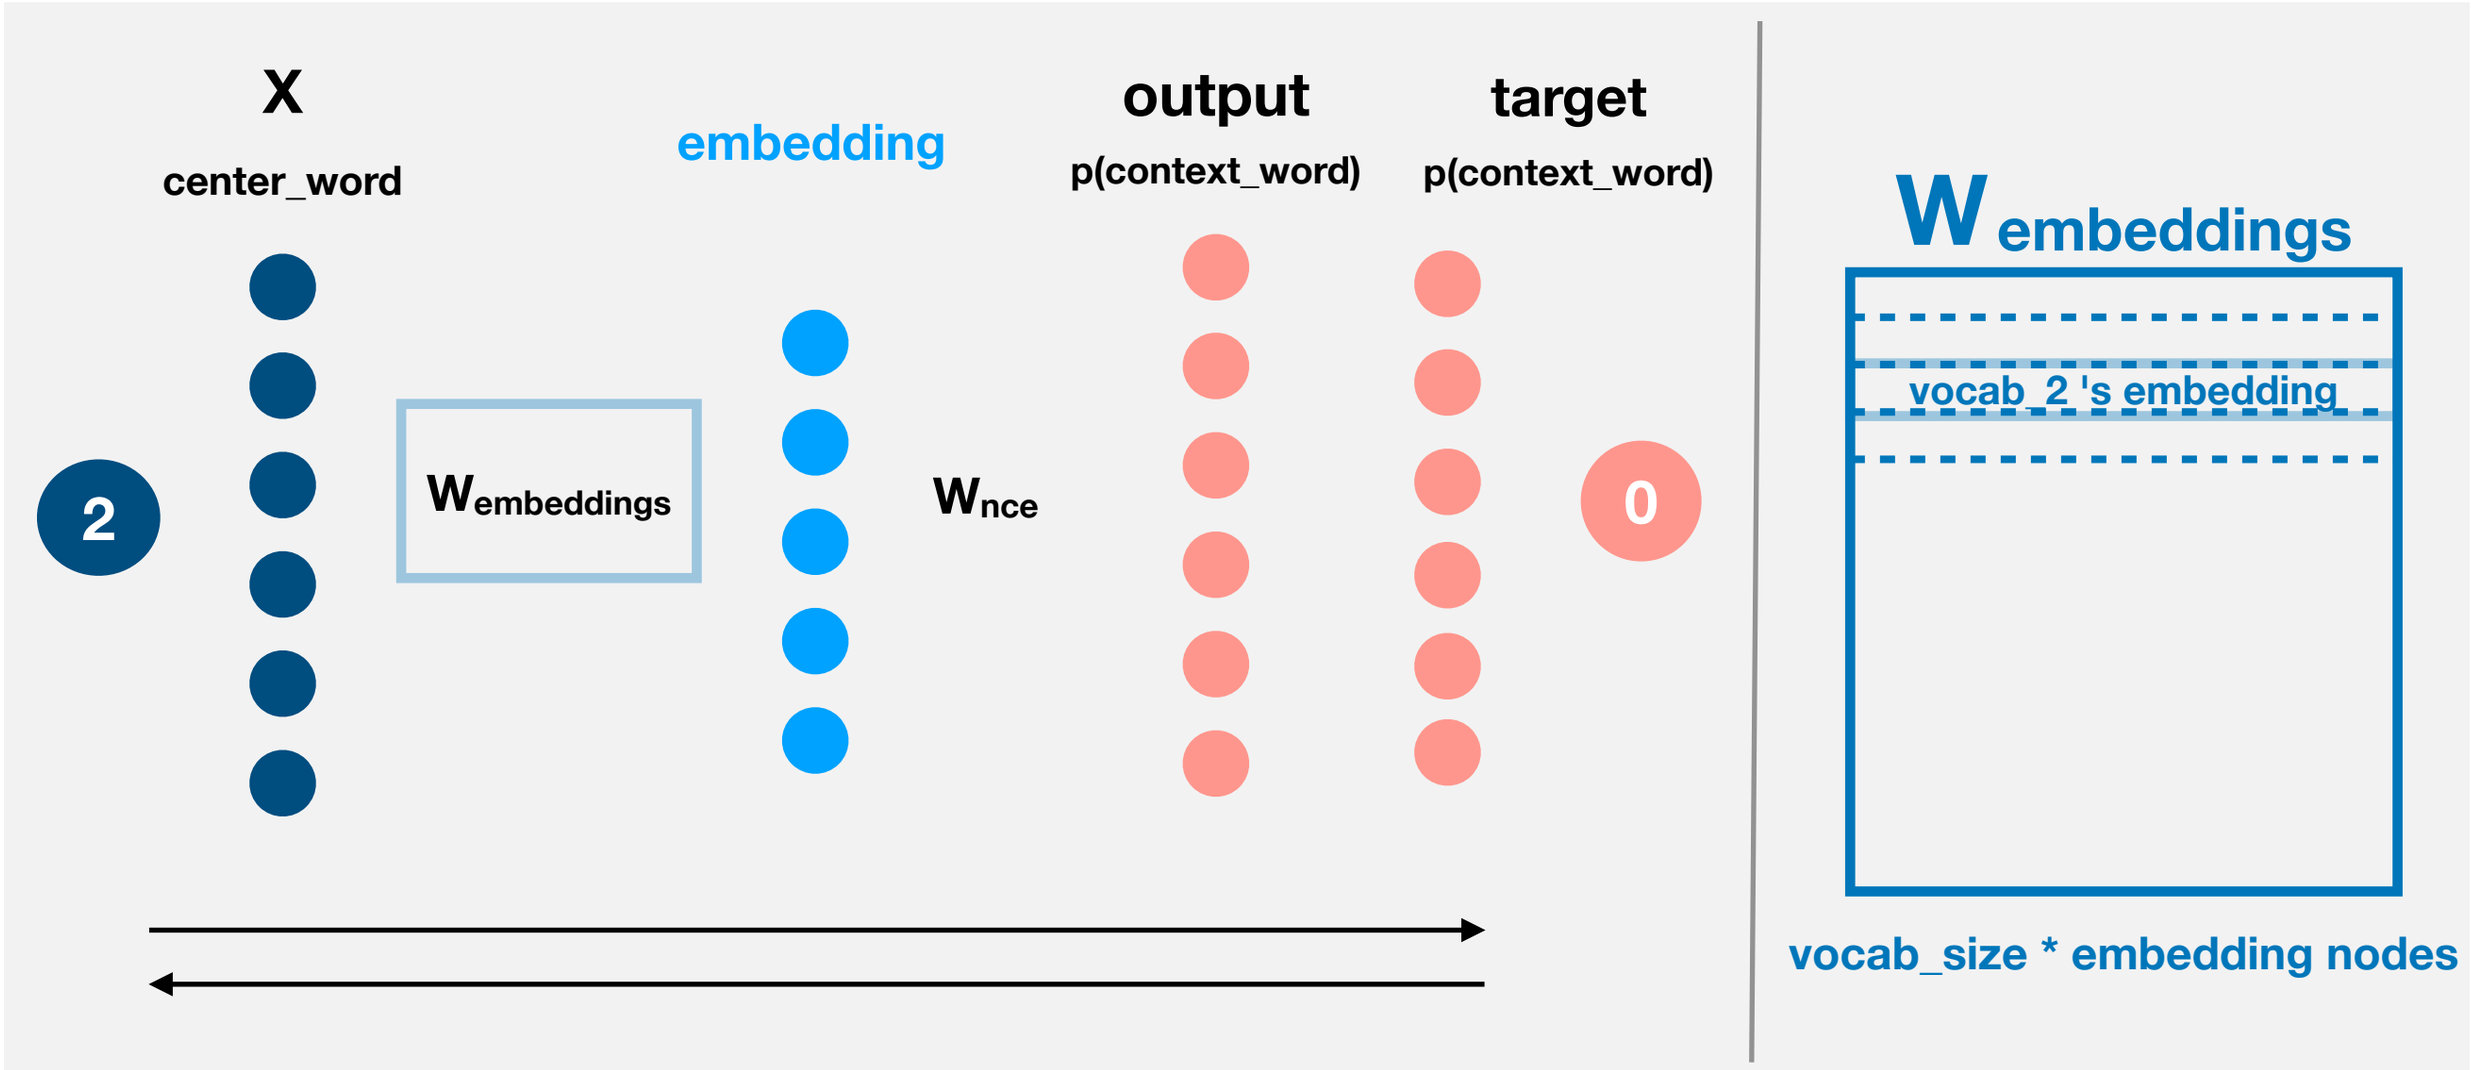

모델구조:

기본적으로 ANN classifier와 같음

input, output, target nodes는 각각 전체 단어의 수

이 예시에서는 이해의 편의를 위하여 nodes 숫자를 제한적으로 표기함

Word2Vec

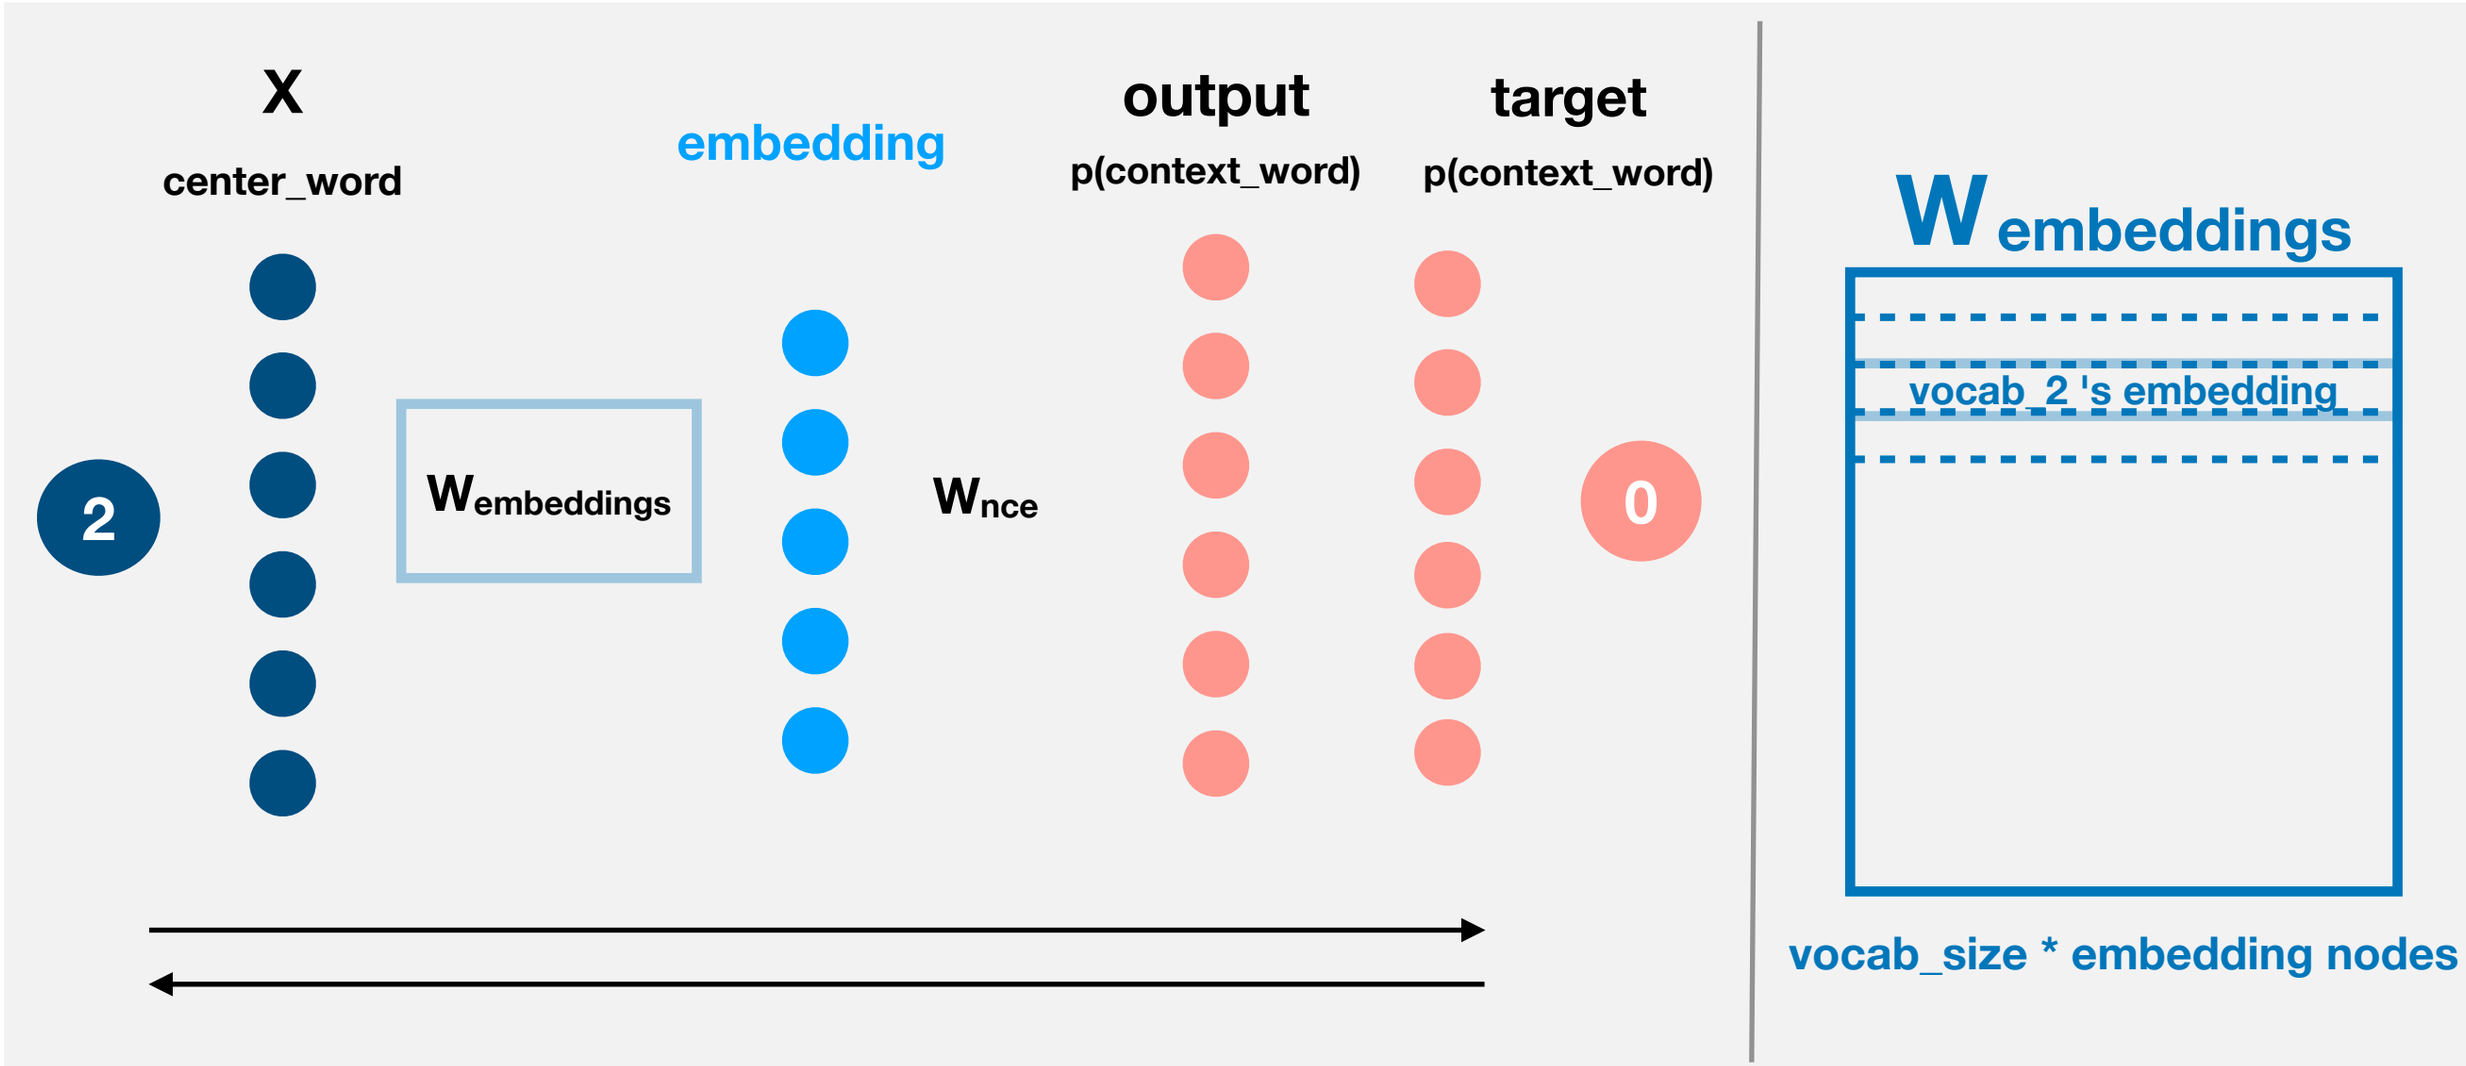

input에 들어간 단어가

hidden layer를 거쳐서

output으로 나온 값과,
target 간의 차이를 최소화하는 것이 목표입니다.

Word2Vec

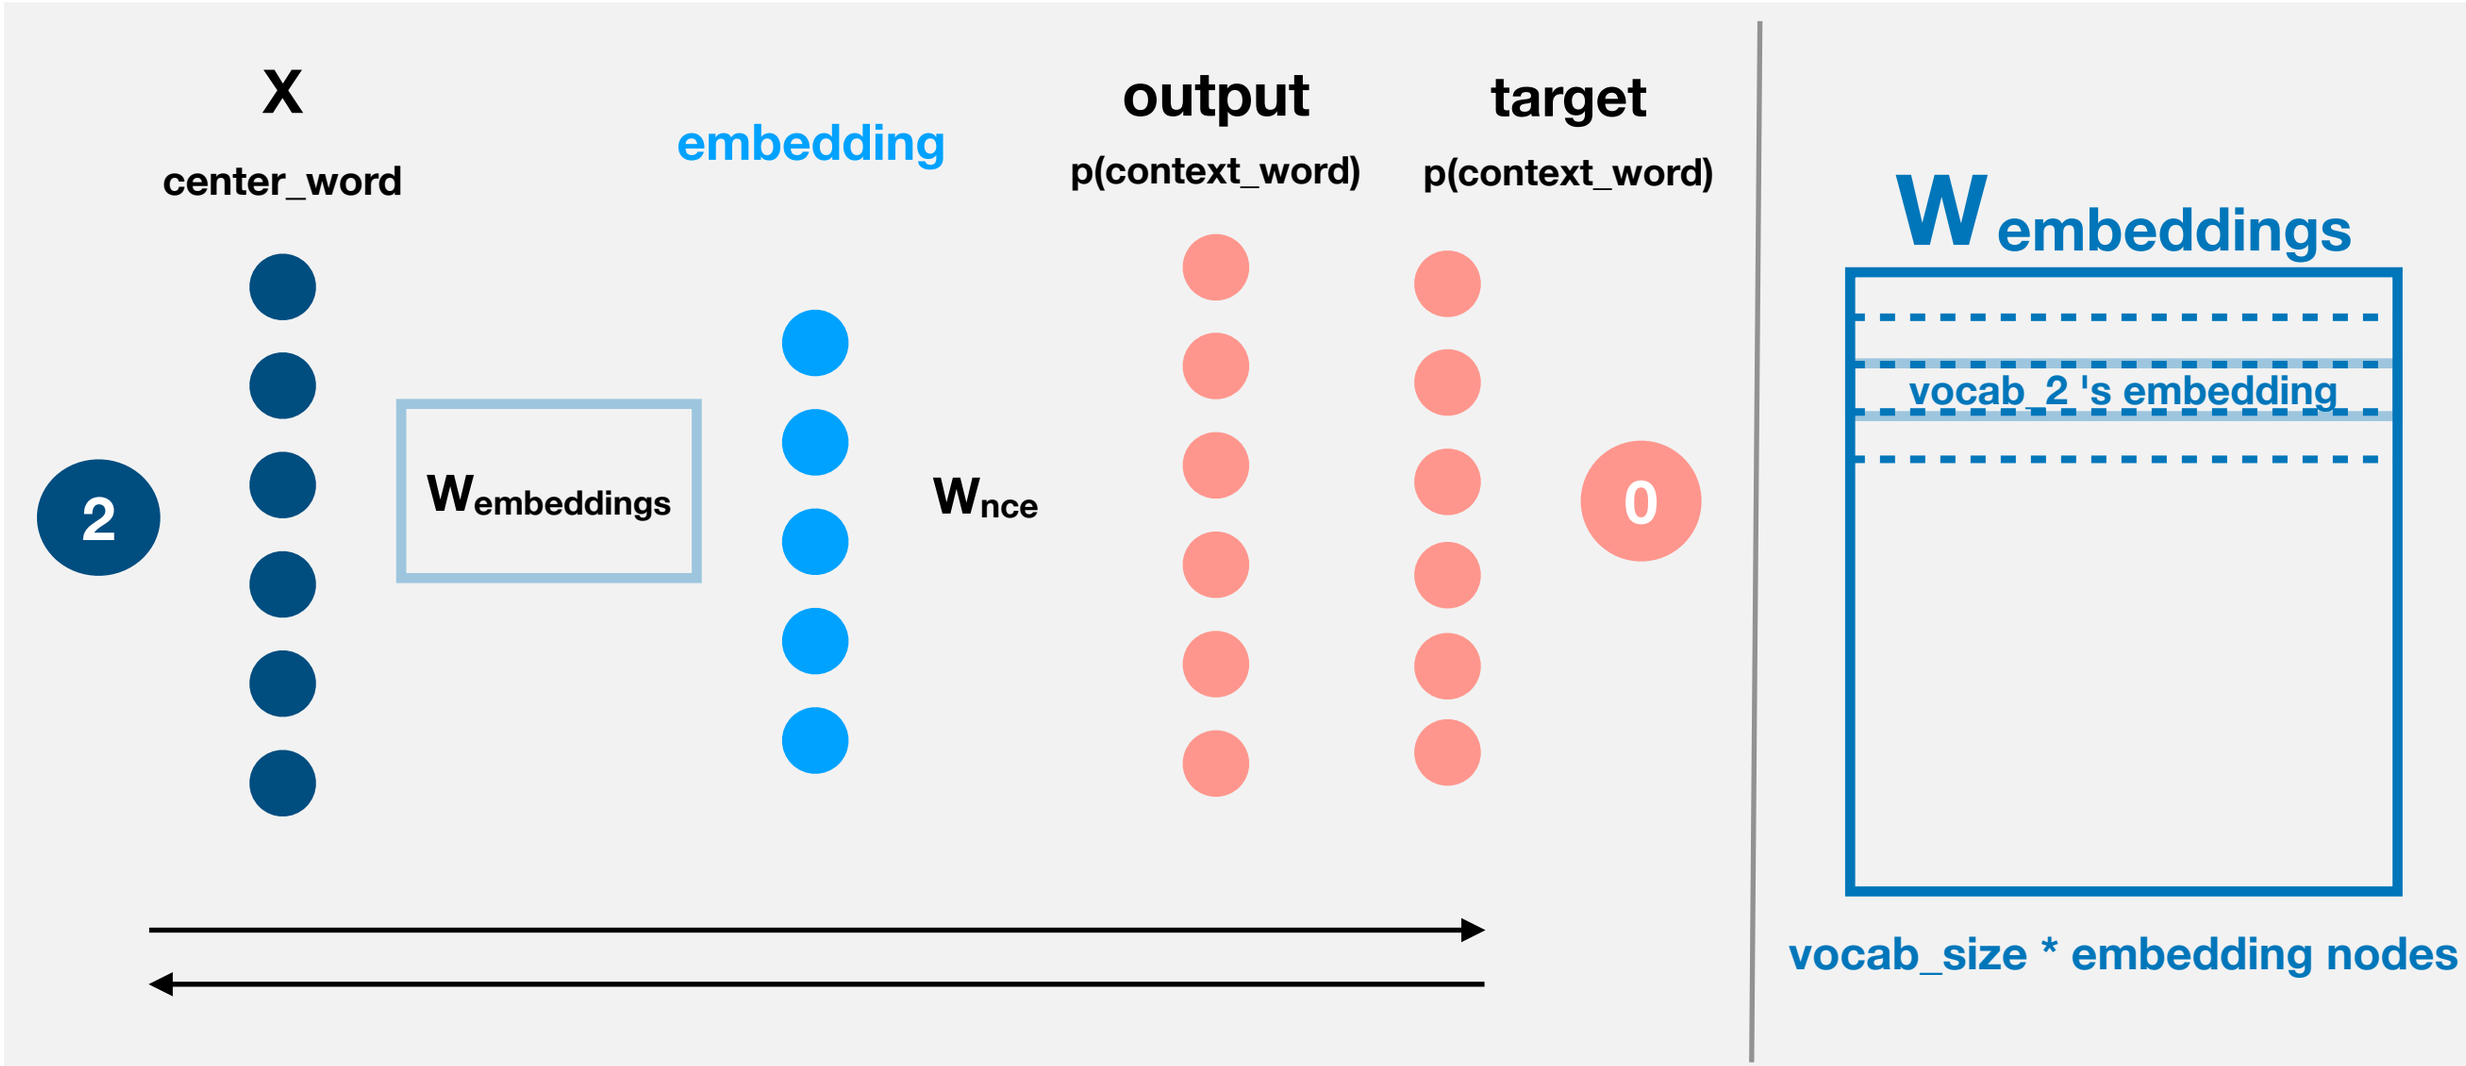

이 과정을 통해 center word와 context word 간의 관계를 vector로 표현하는 것이 목표입니다.

Word2Vec

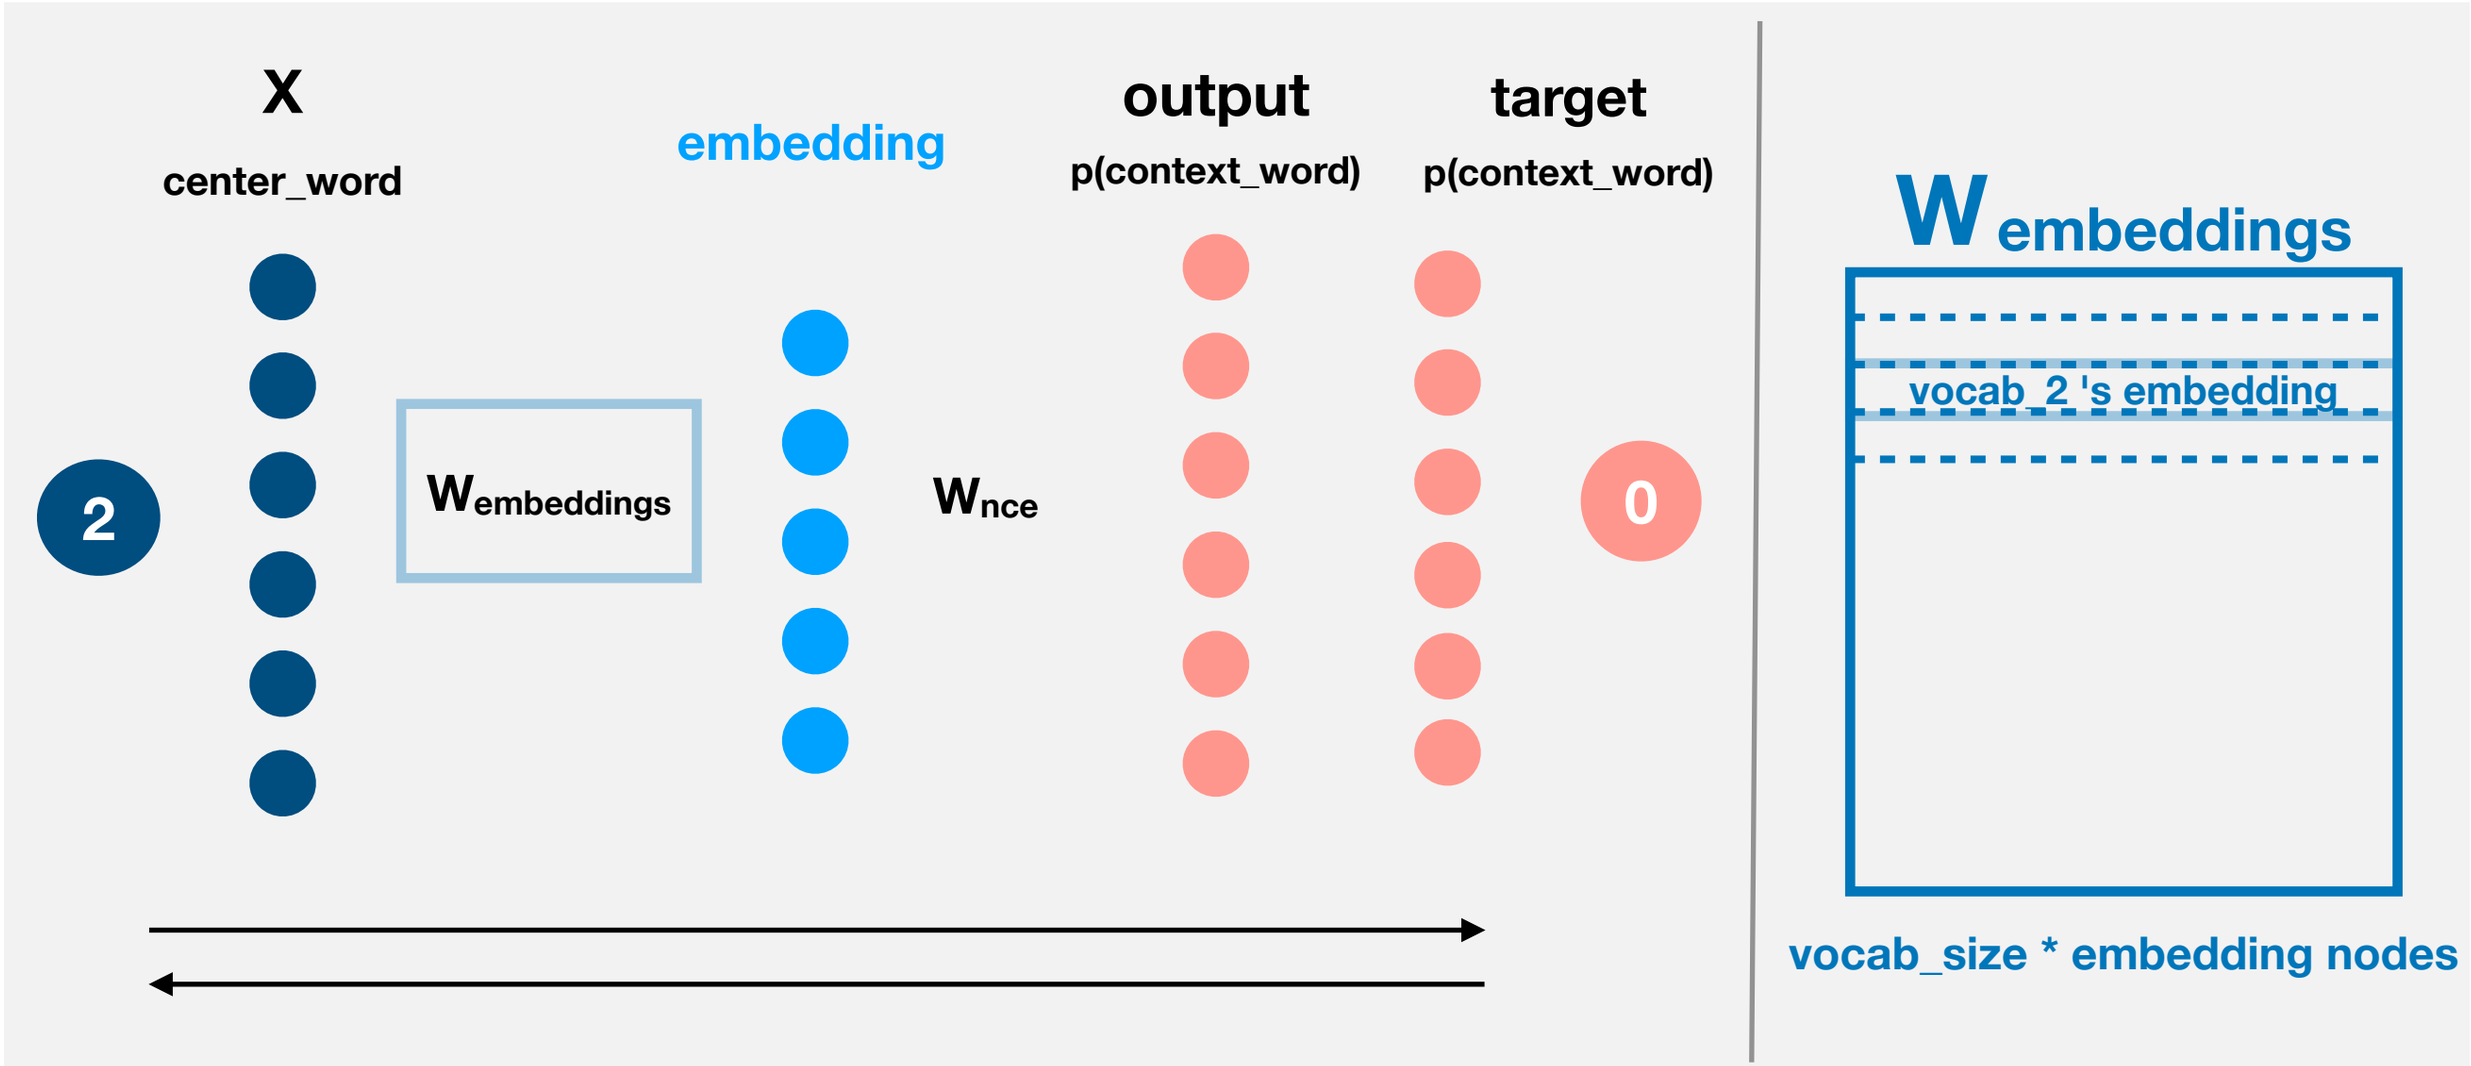

구체적 예시로 훈련을 해봅시다.

Word2Vec

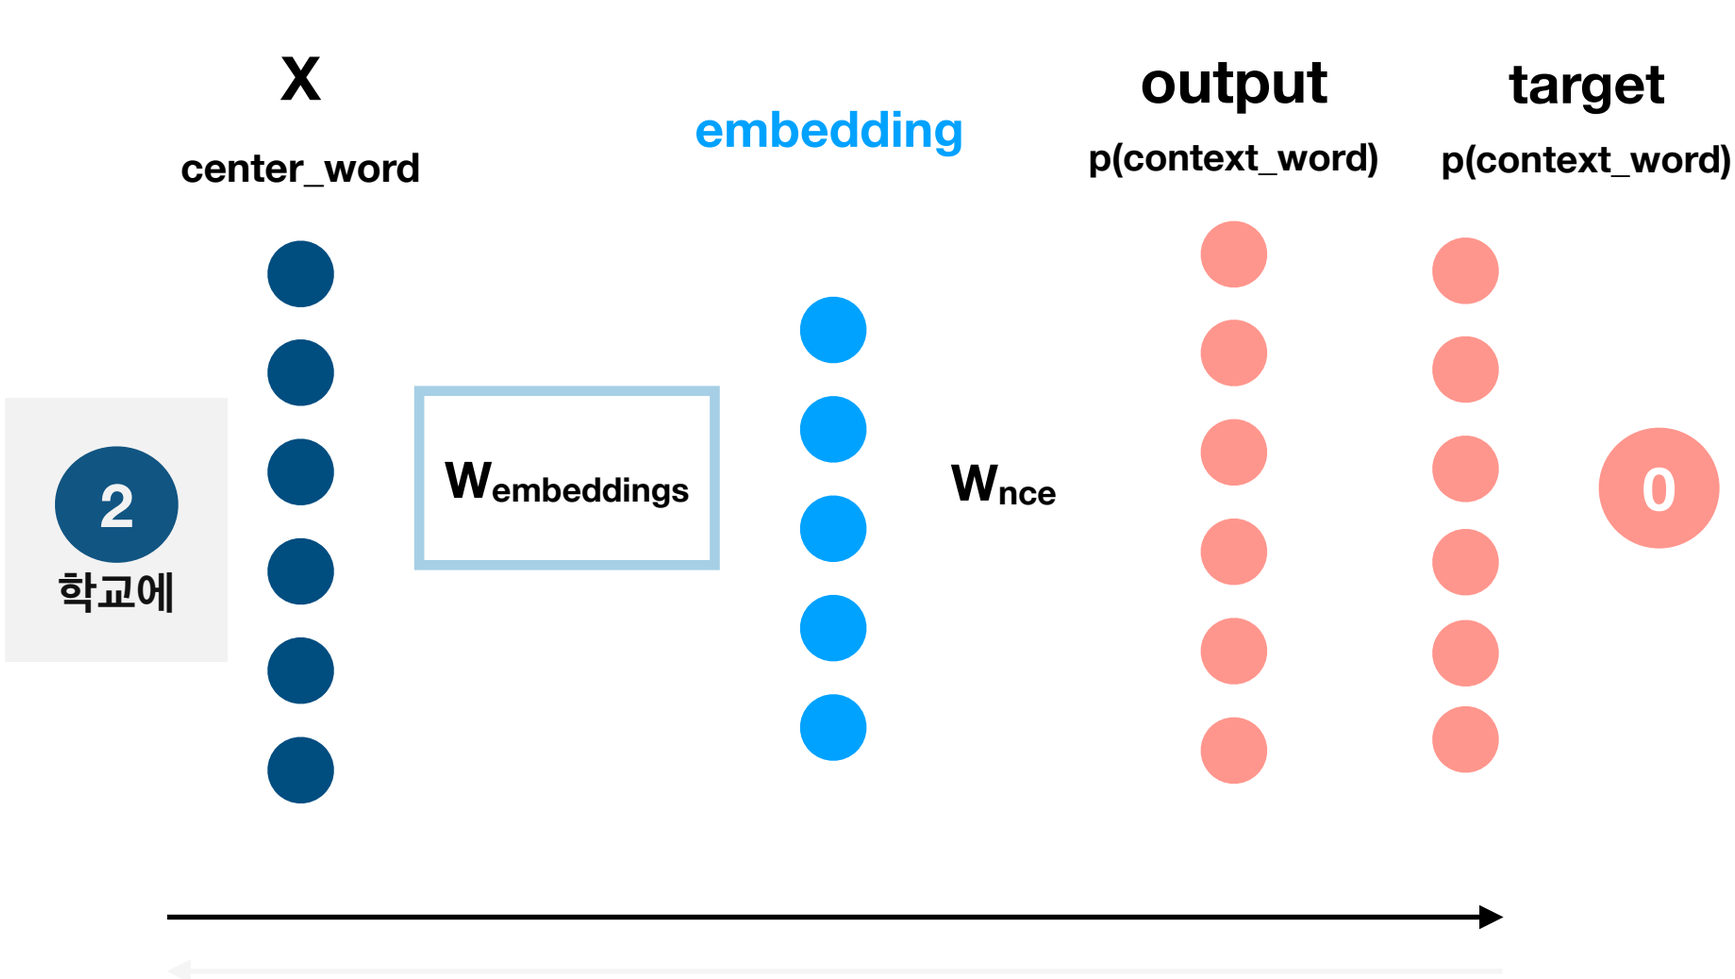

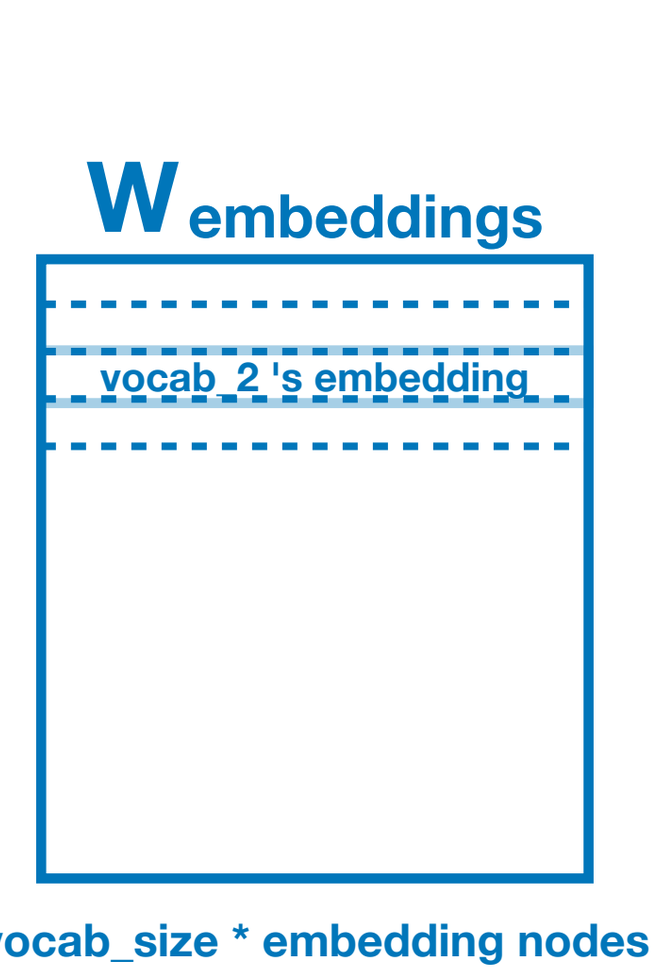

input에 '학교에'라는 center word가 들어가면

Word2Vec

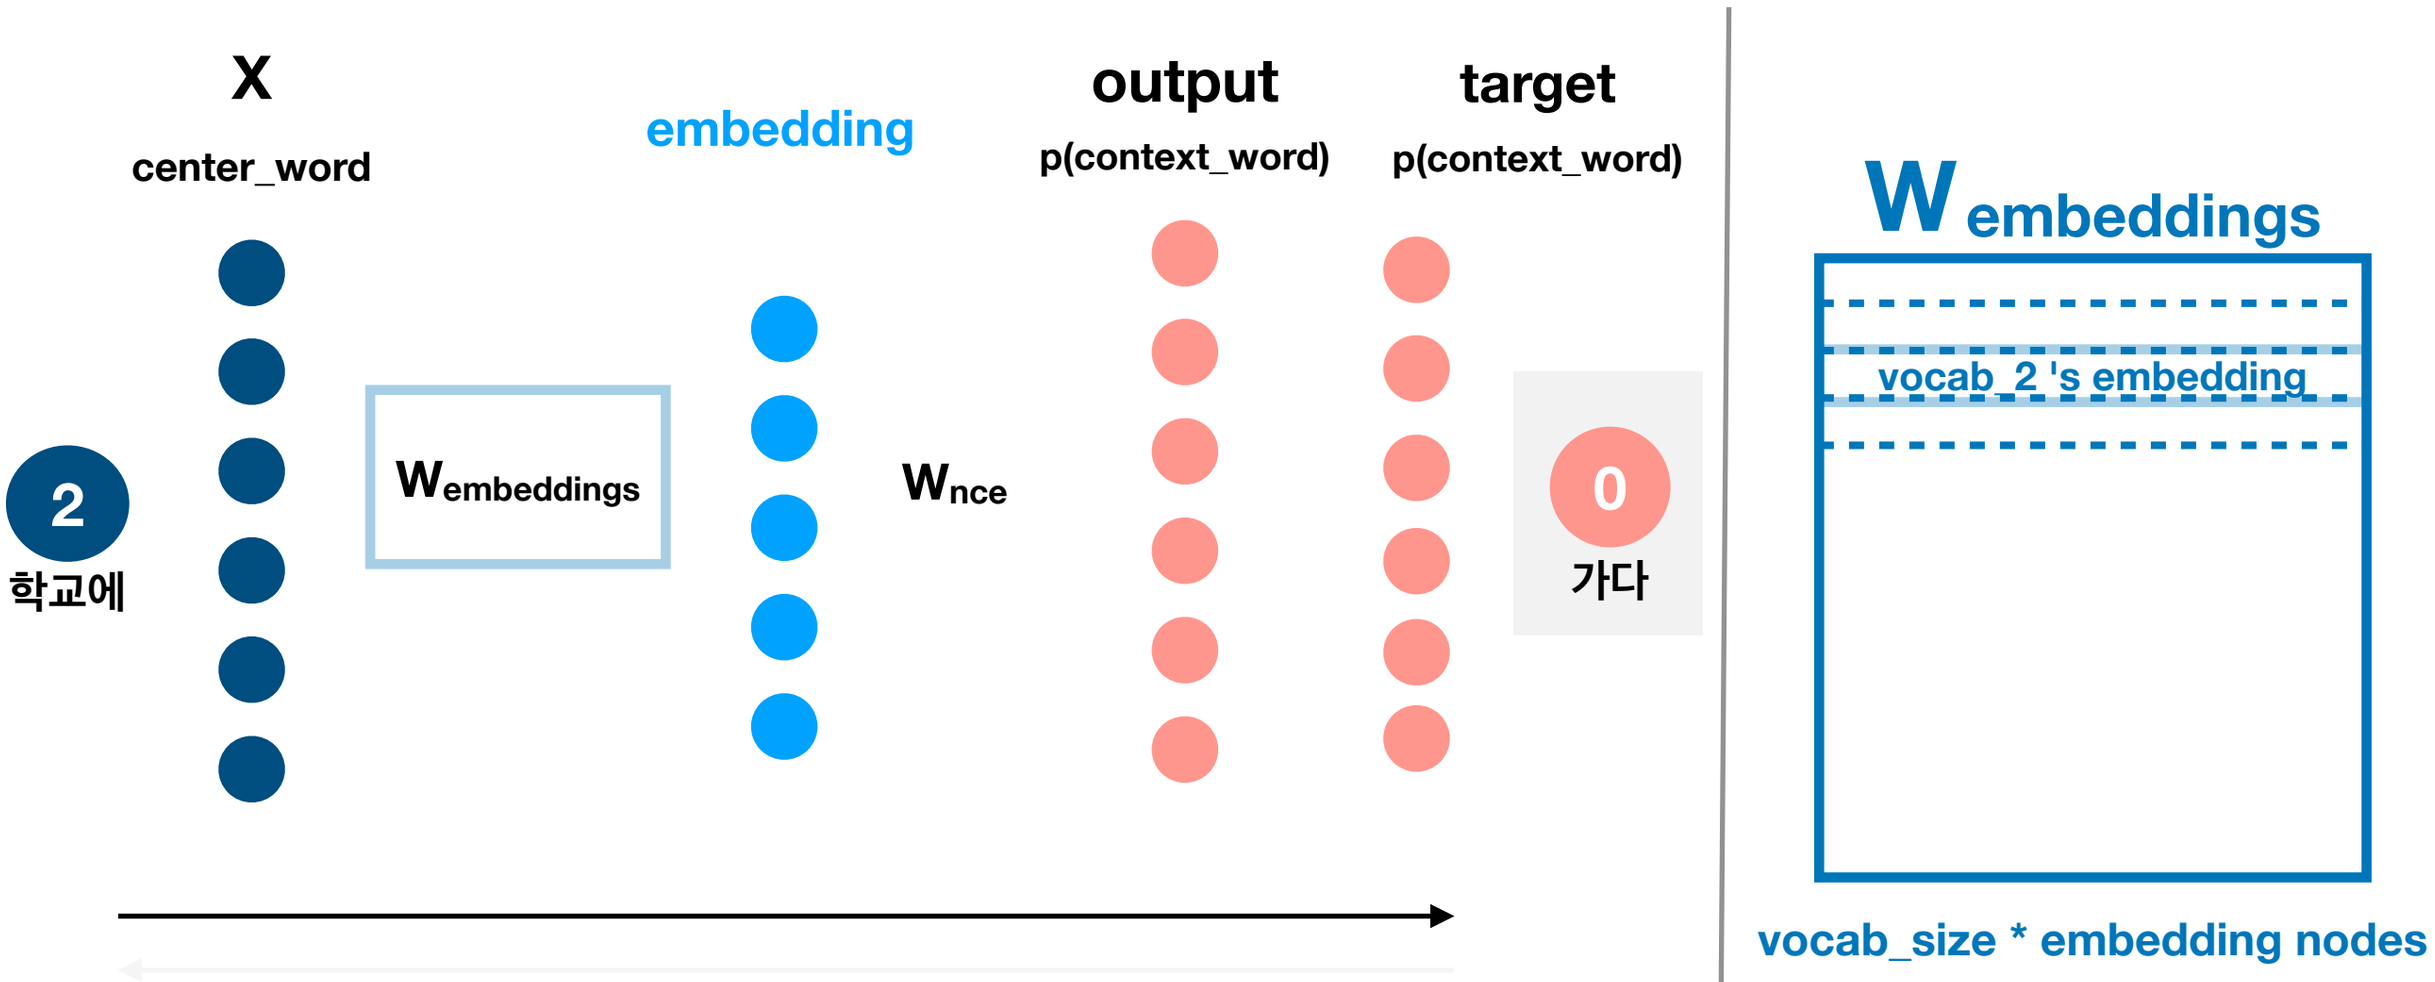

target은 '학교에'와 함께 쓰이는 context word '가다'가 됩니다.

Word2Vec

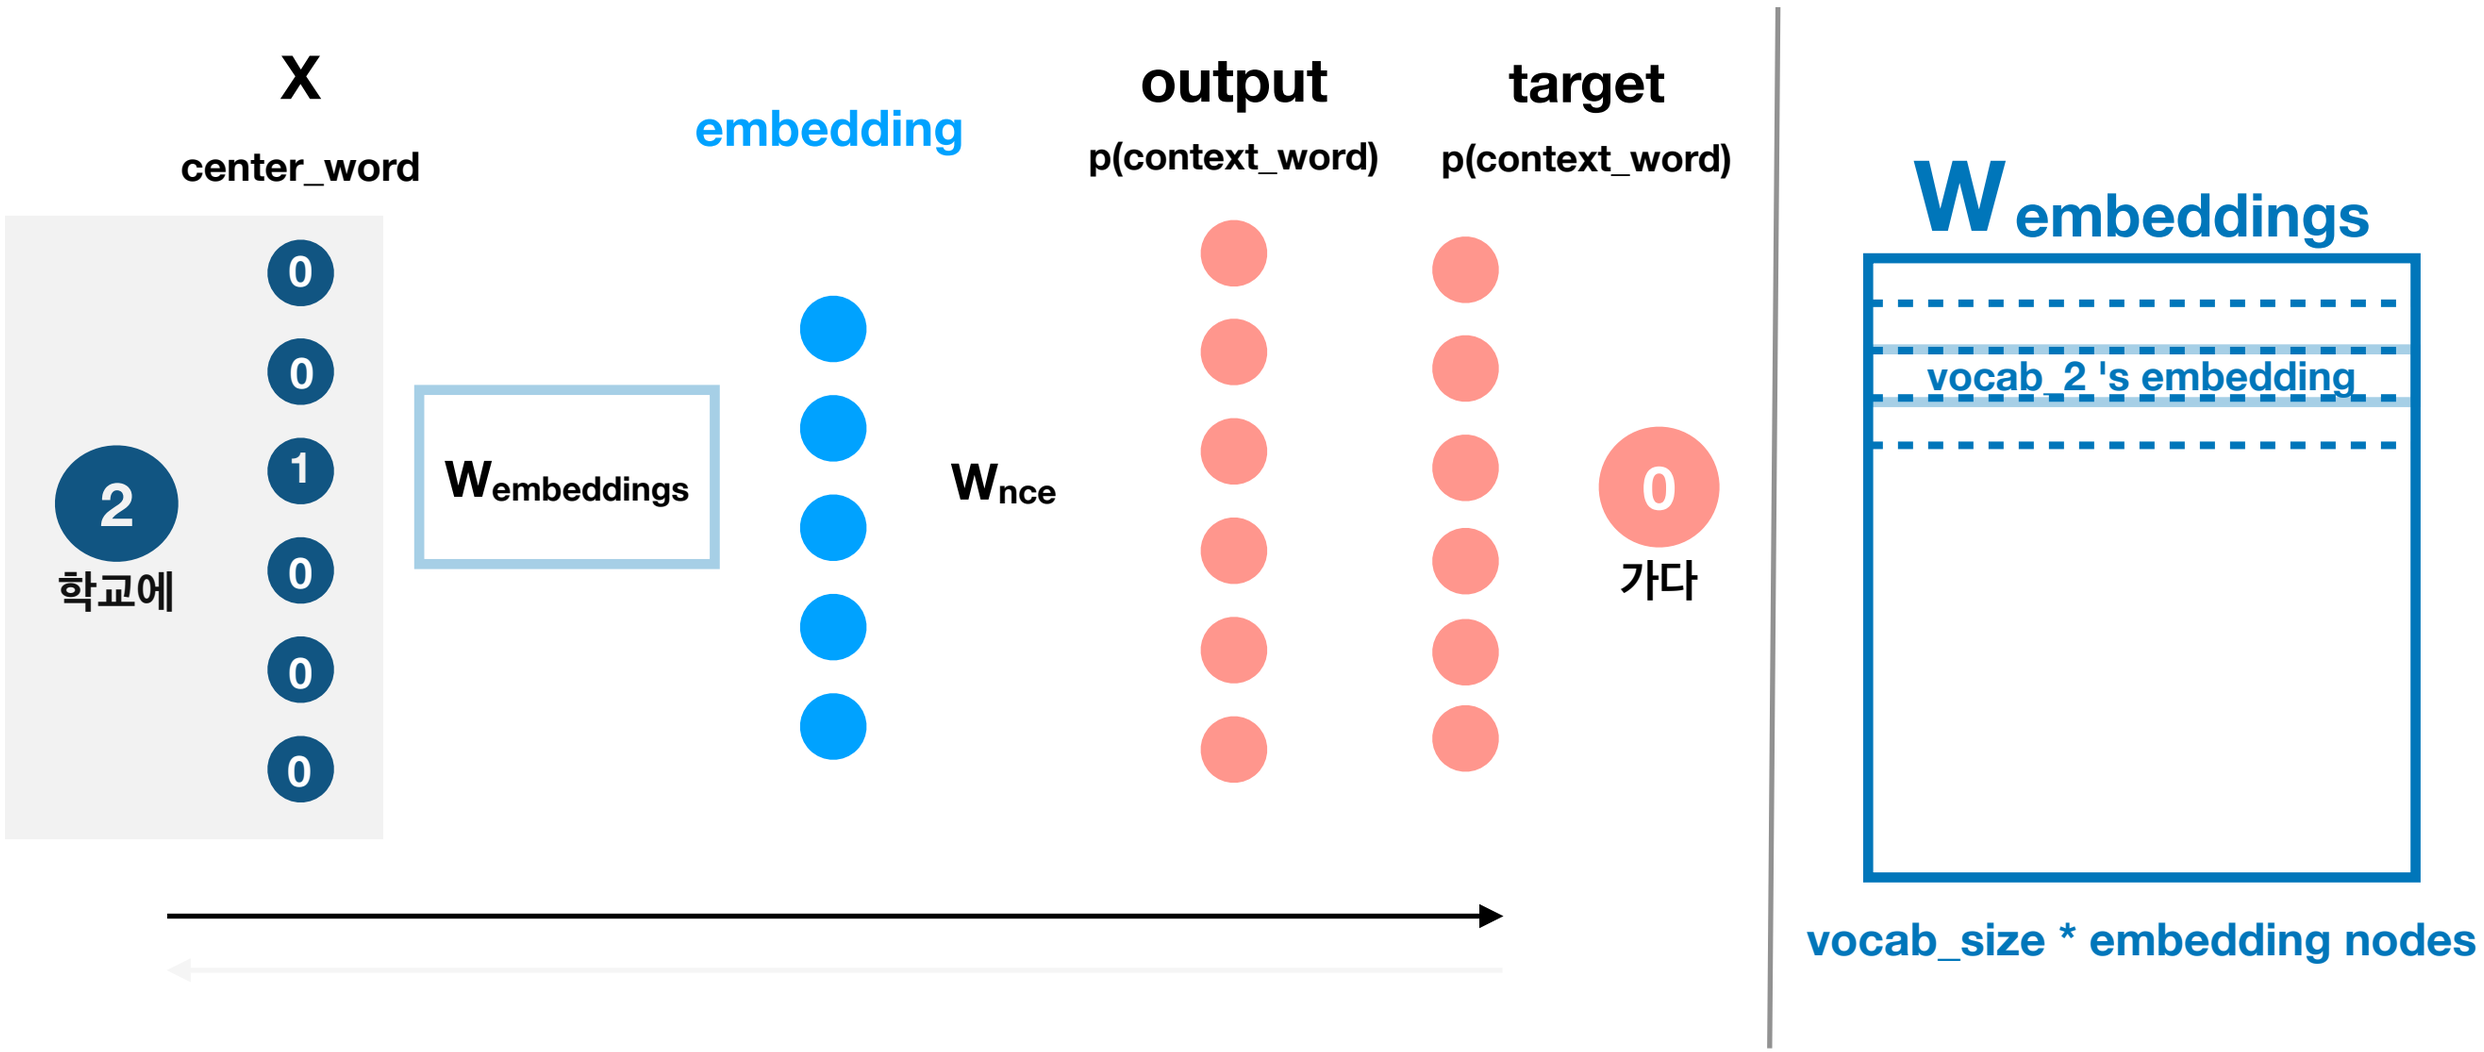

'학교에'라는 단어의 index가 2였다면,
input을 세 번째 칸의 값만 1이고 나머지는 0인 one-hot vector로 만들어줍니다.

Word2Vec

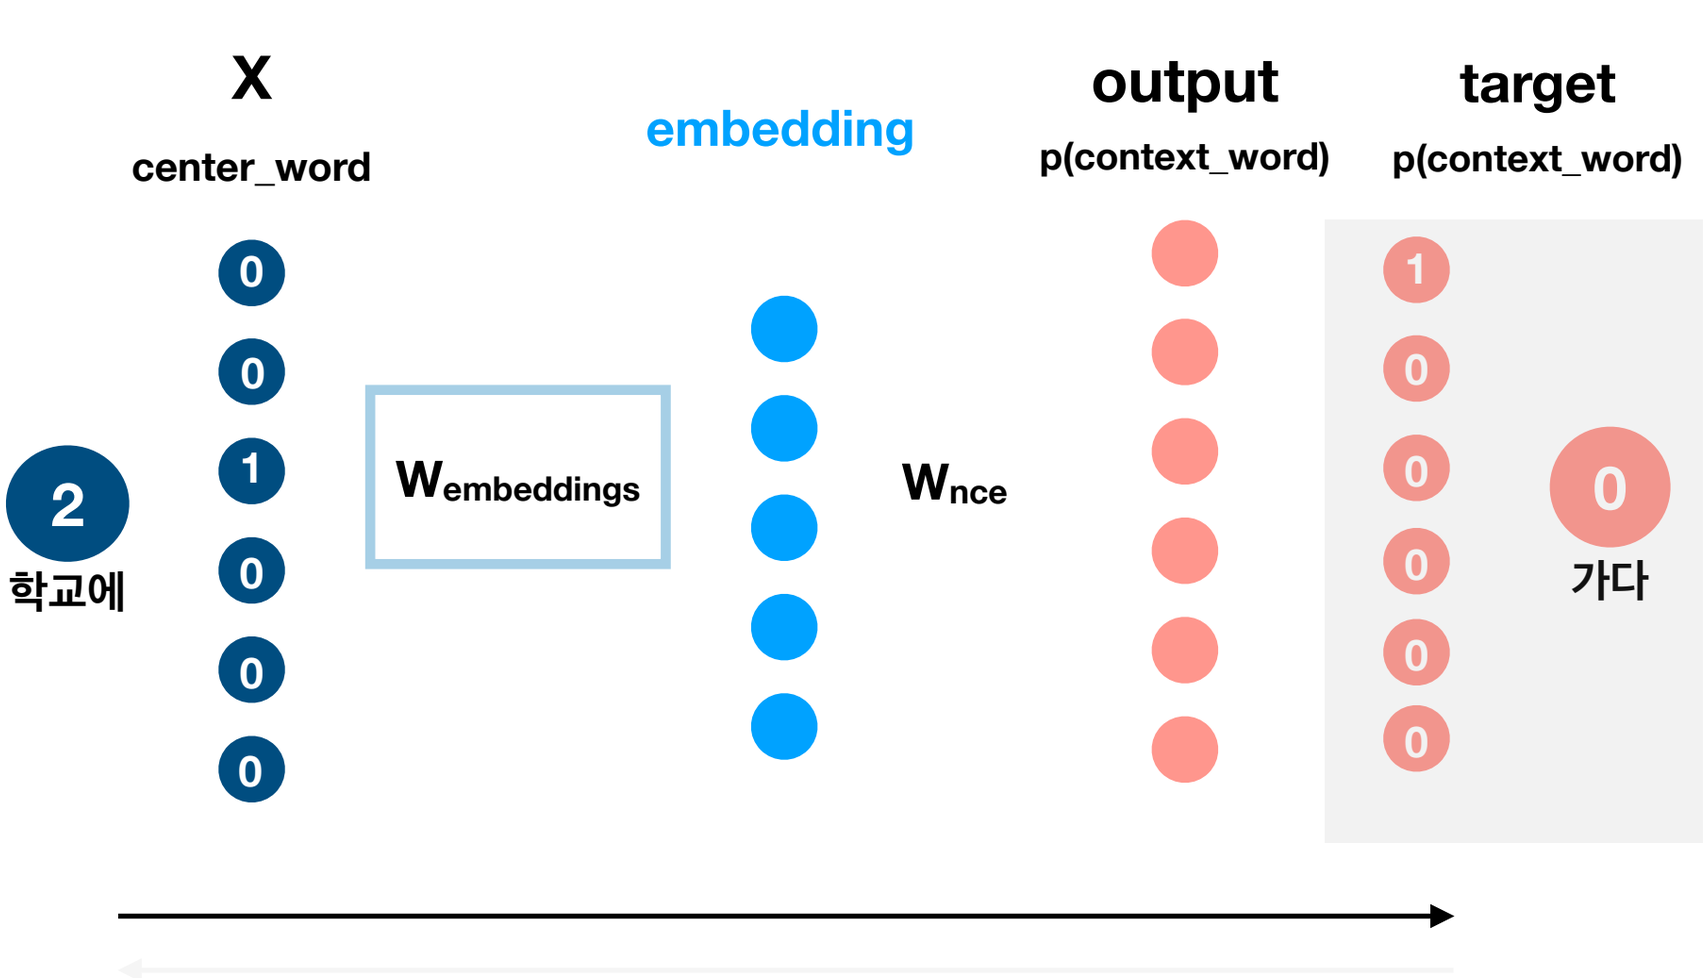

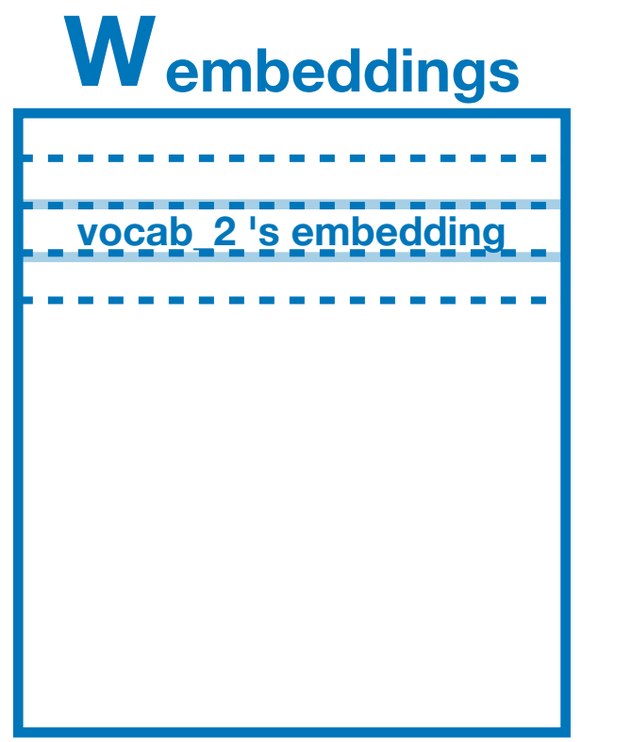

target도 마찬가지로 one-hot vector로 만들어줍니다.

Word2Vec

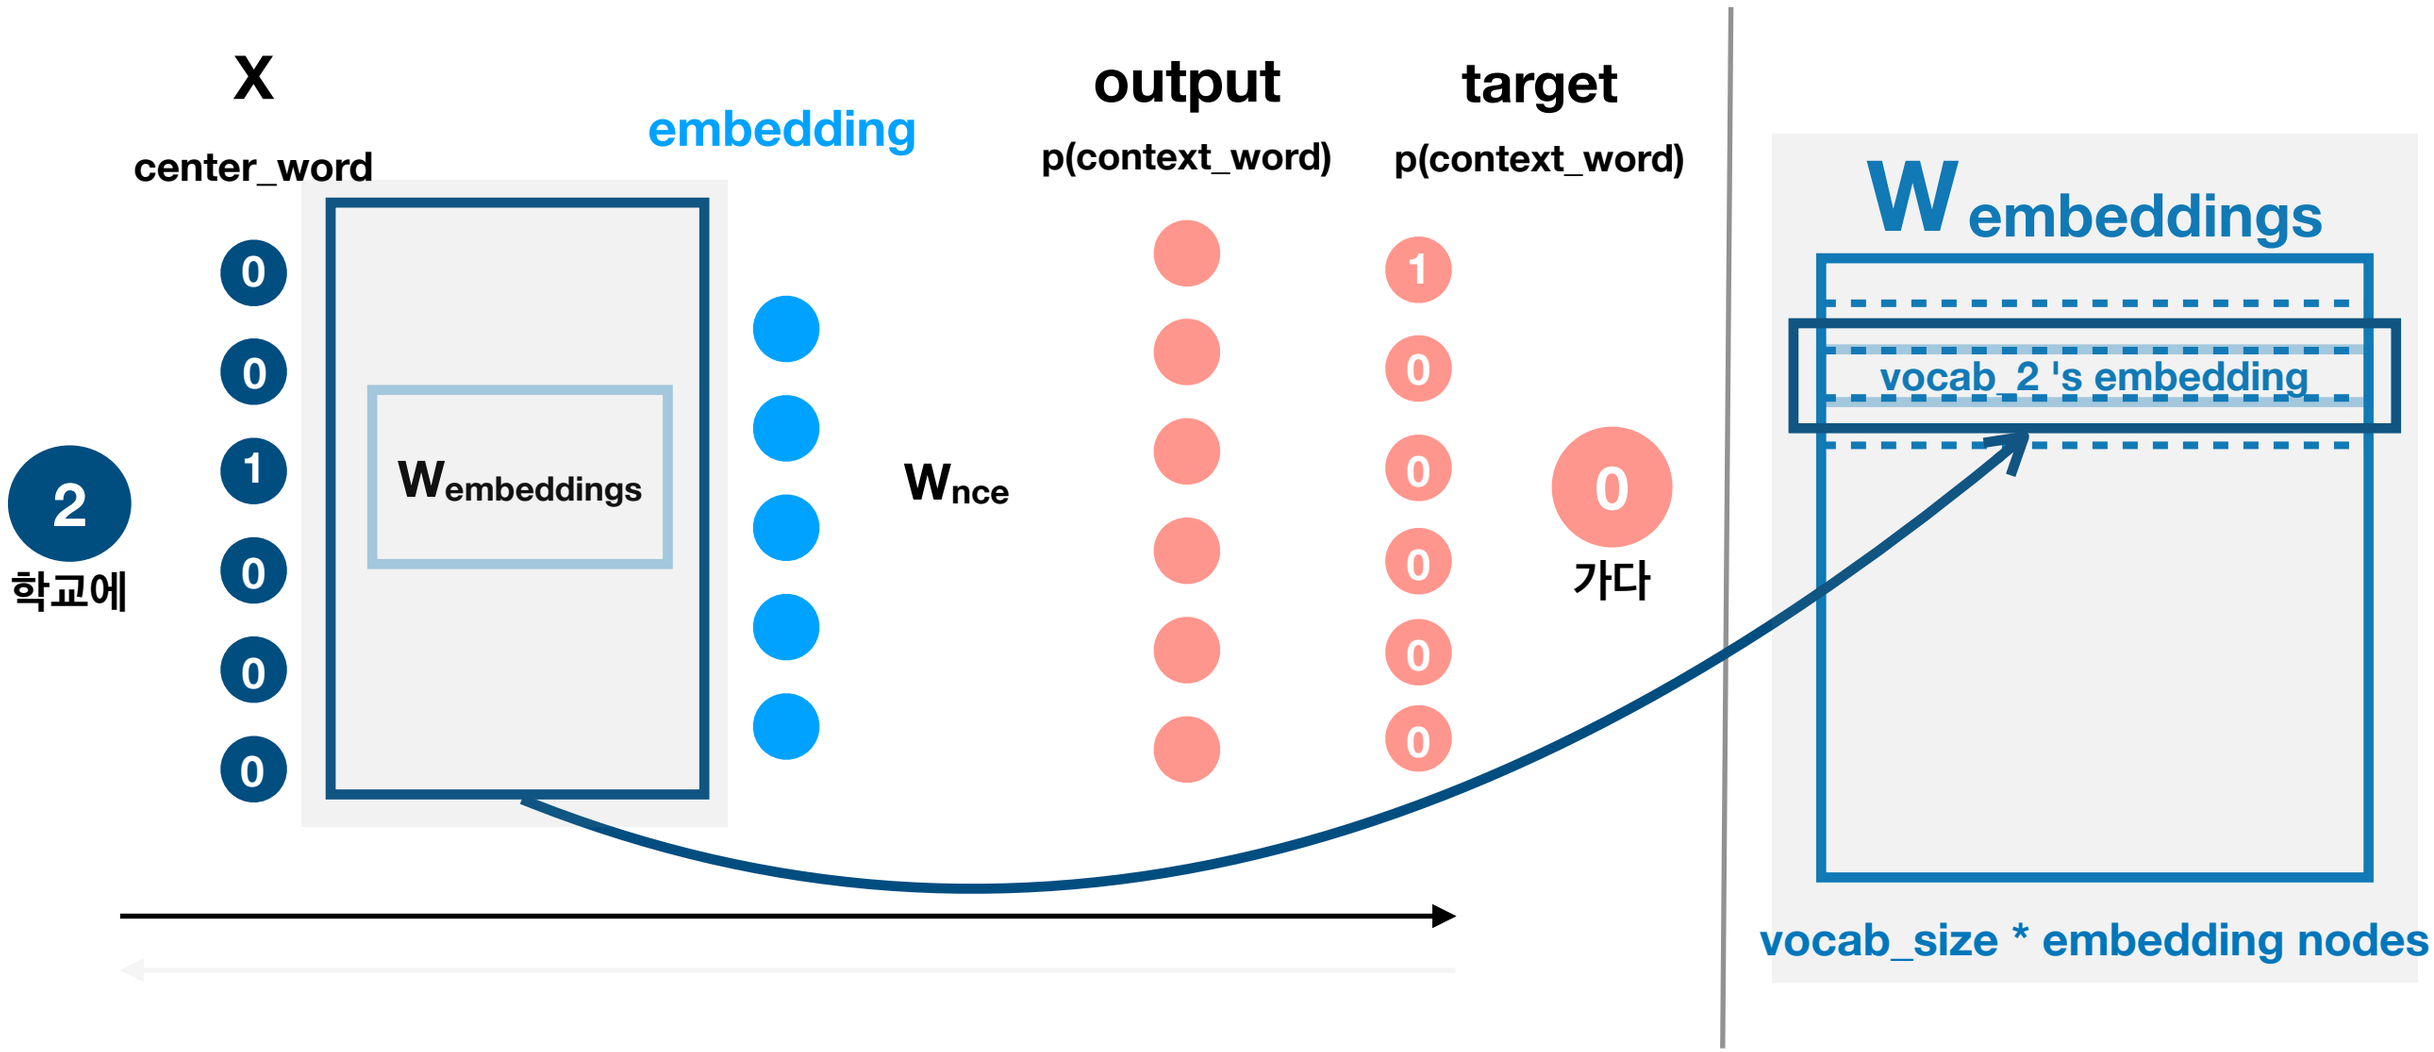

'학교에'라는 index에 해당하는 word vector를 $W_{embeddings}$란 표에서 찾습니다.

Word2Vec

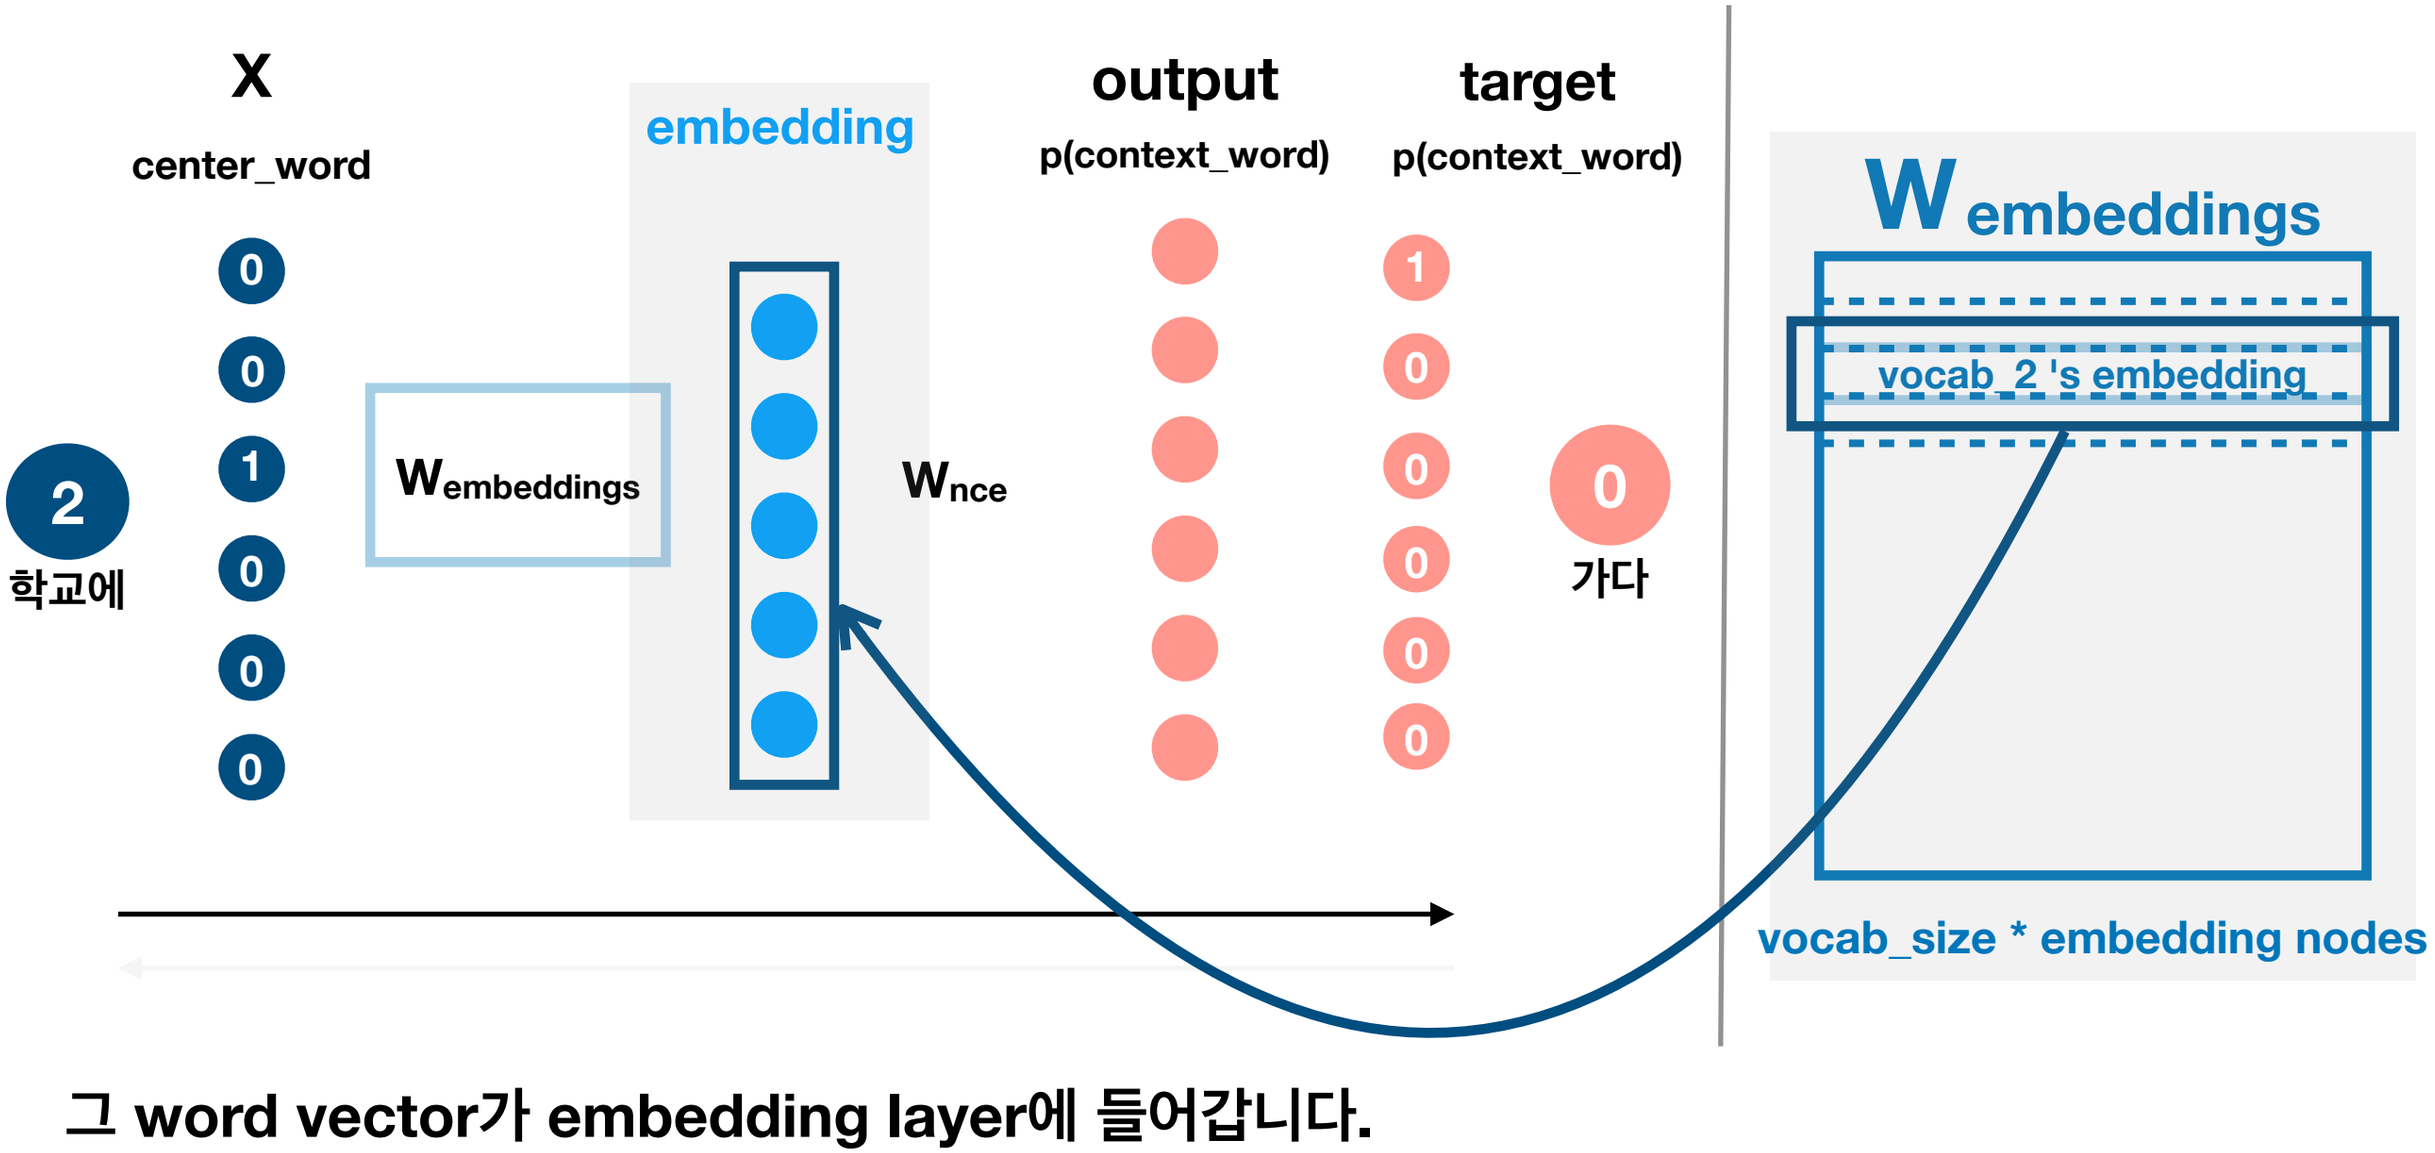

그 word vector가 embedding layer에 들어갑니다.

Word2Vec

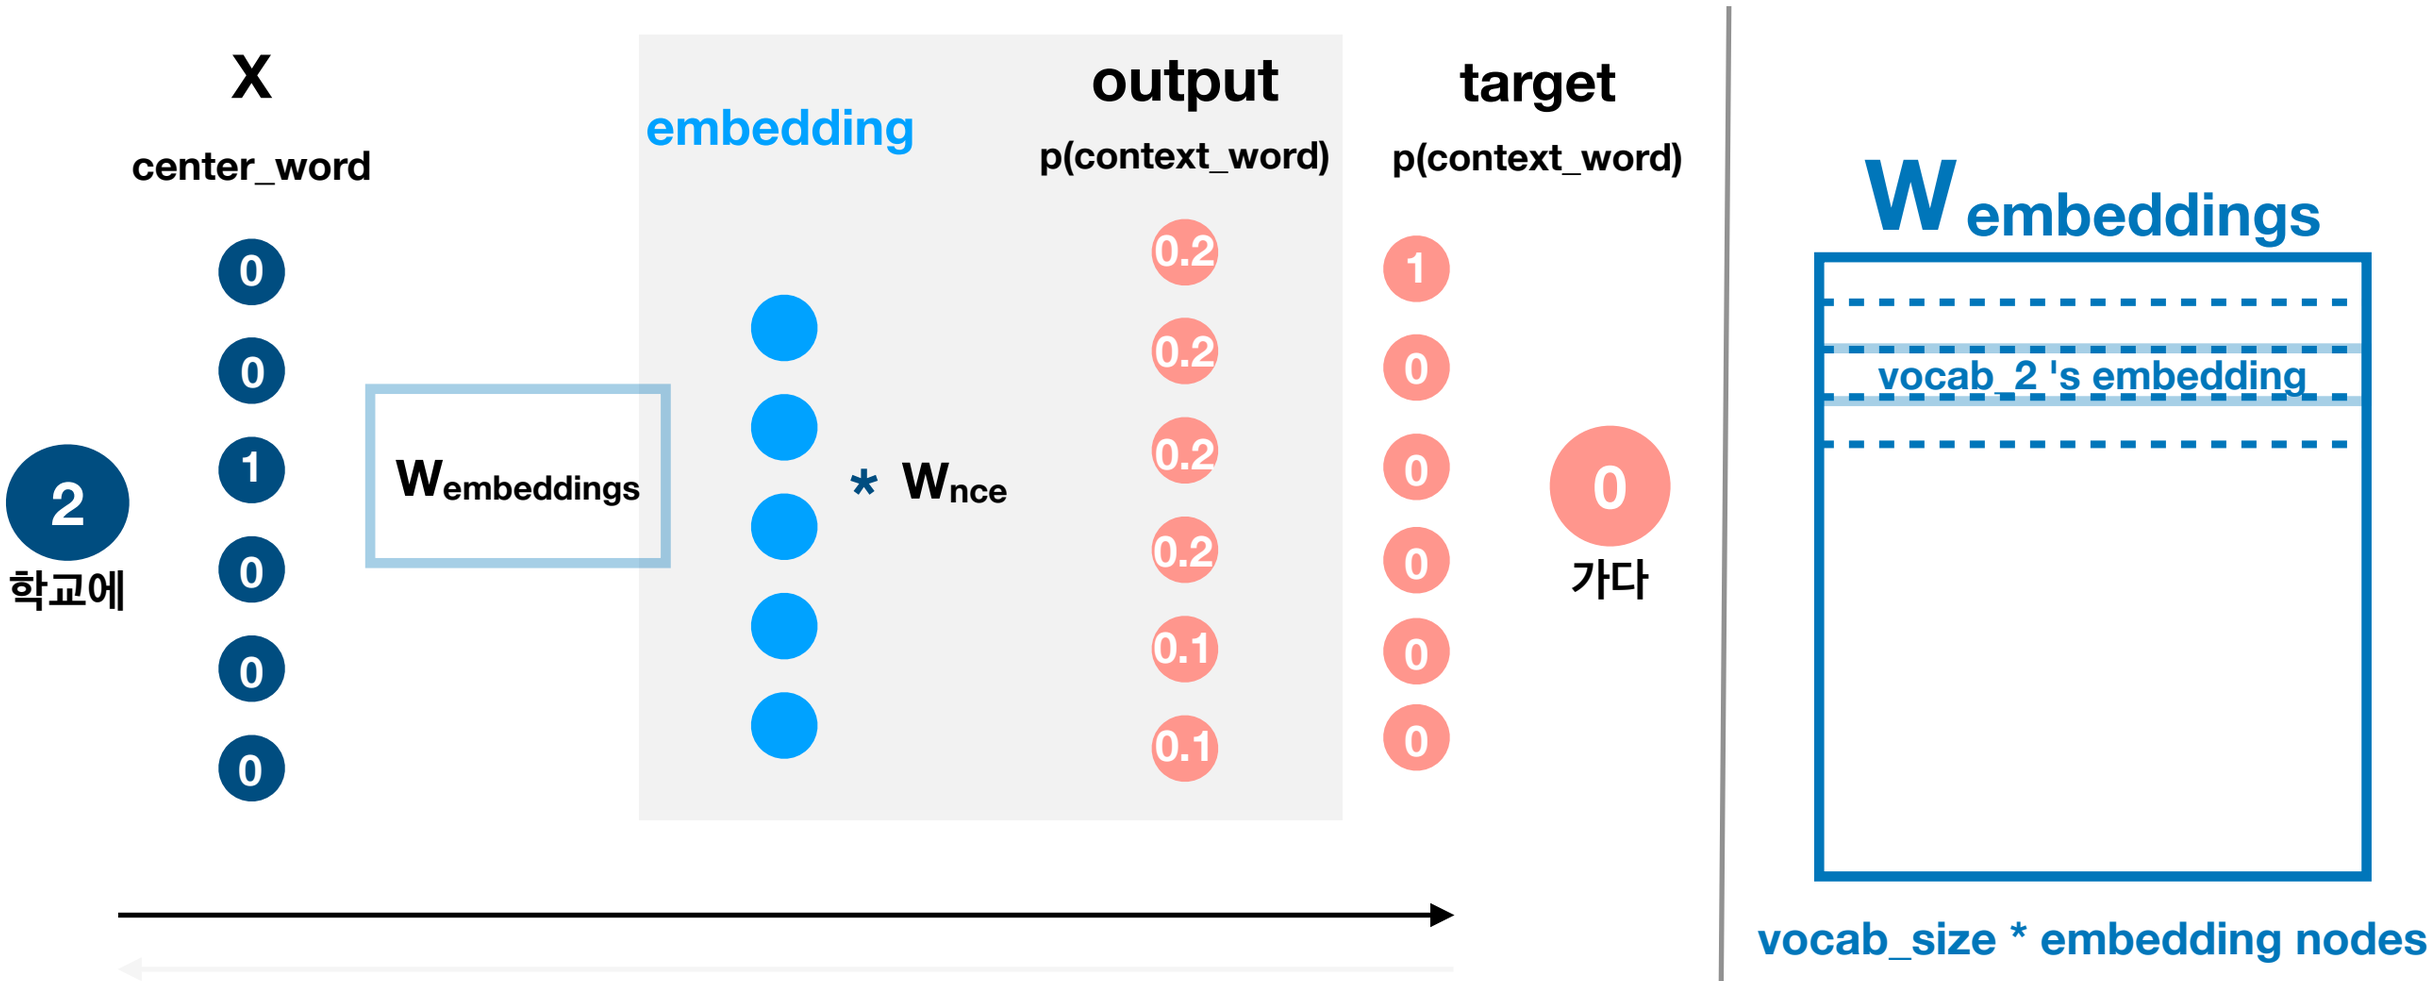

embedding layer의 값에 W_{nce}를 곱하여 output 값을 구합니다.
output 값은 각 단어가 '학교에'의 context word일 확률입니다.

Word2Vec

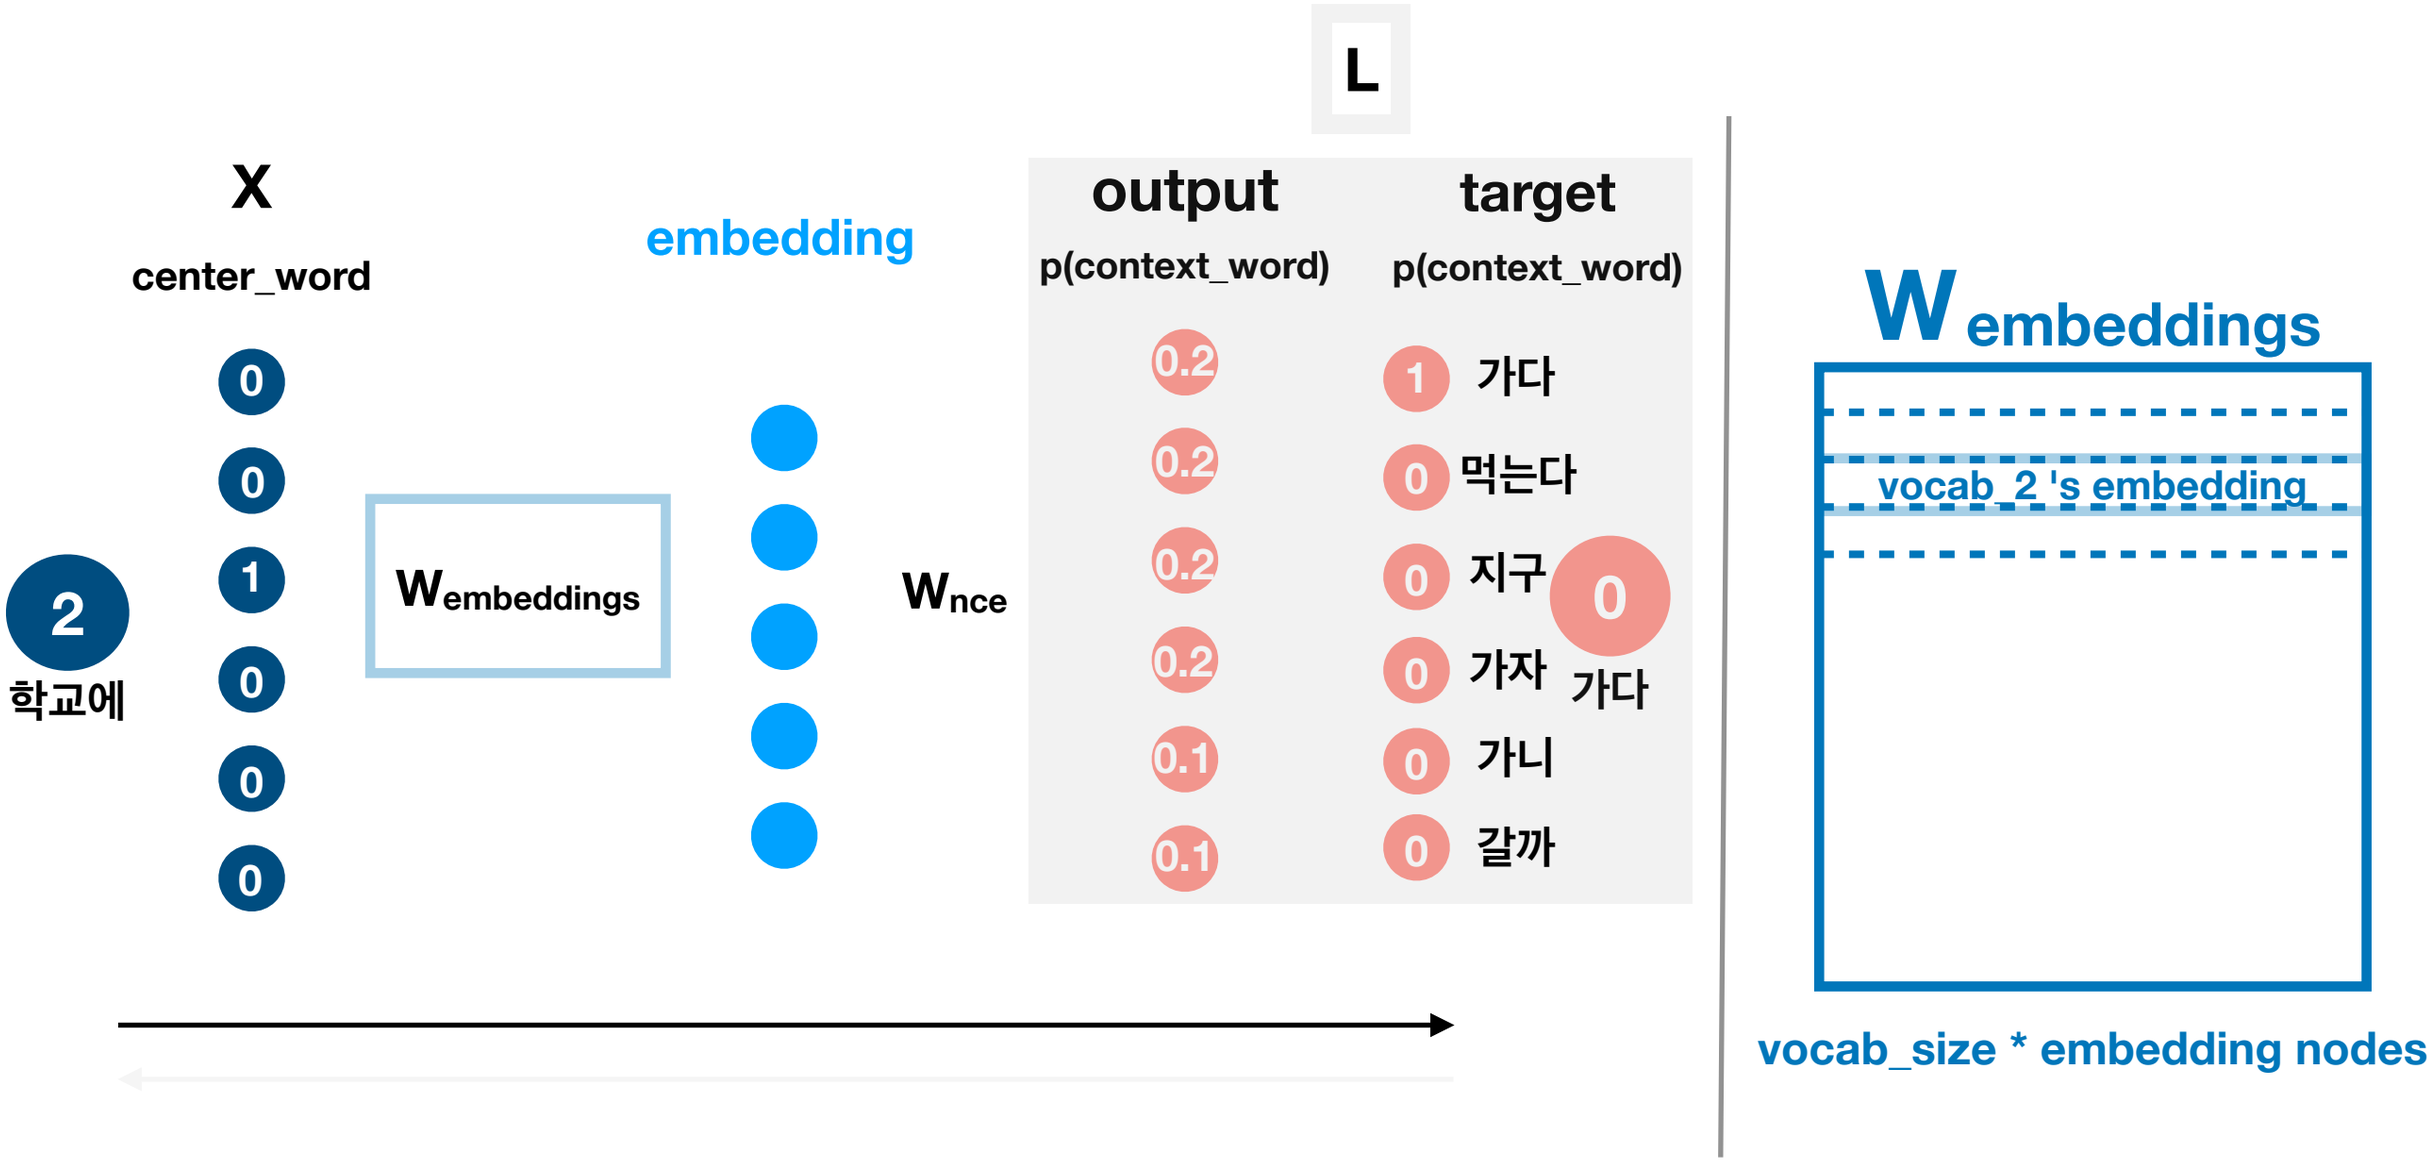

output과 정답 target (context_word)을 비교하여 loss를 구합니다.

Word2Vec

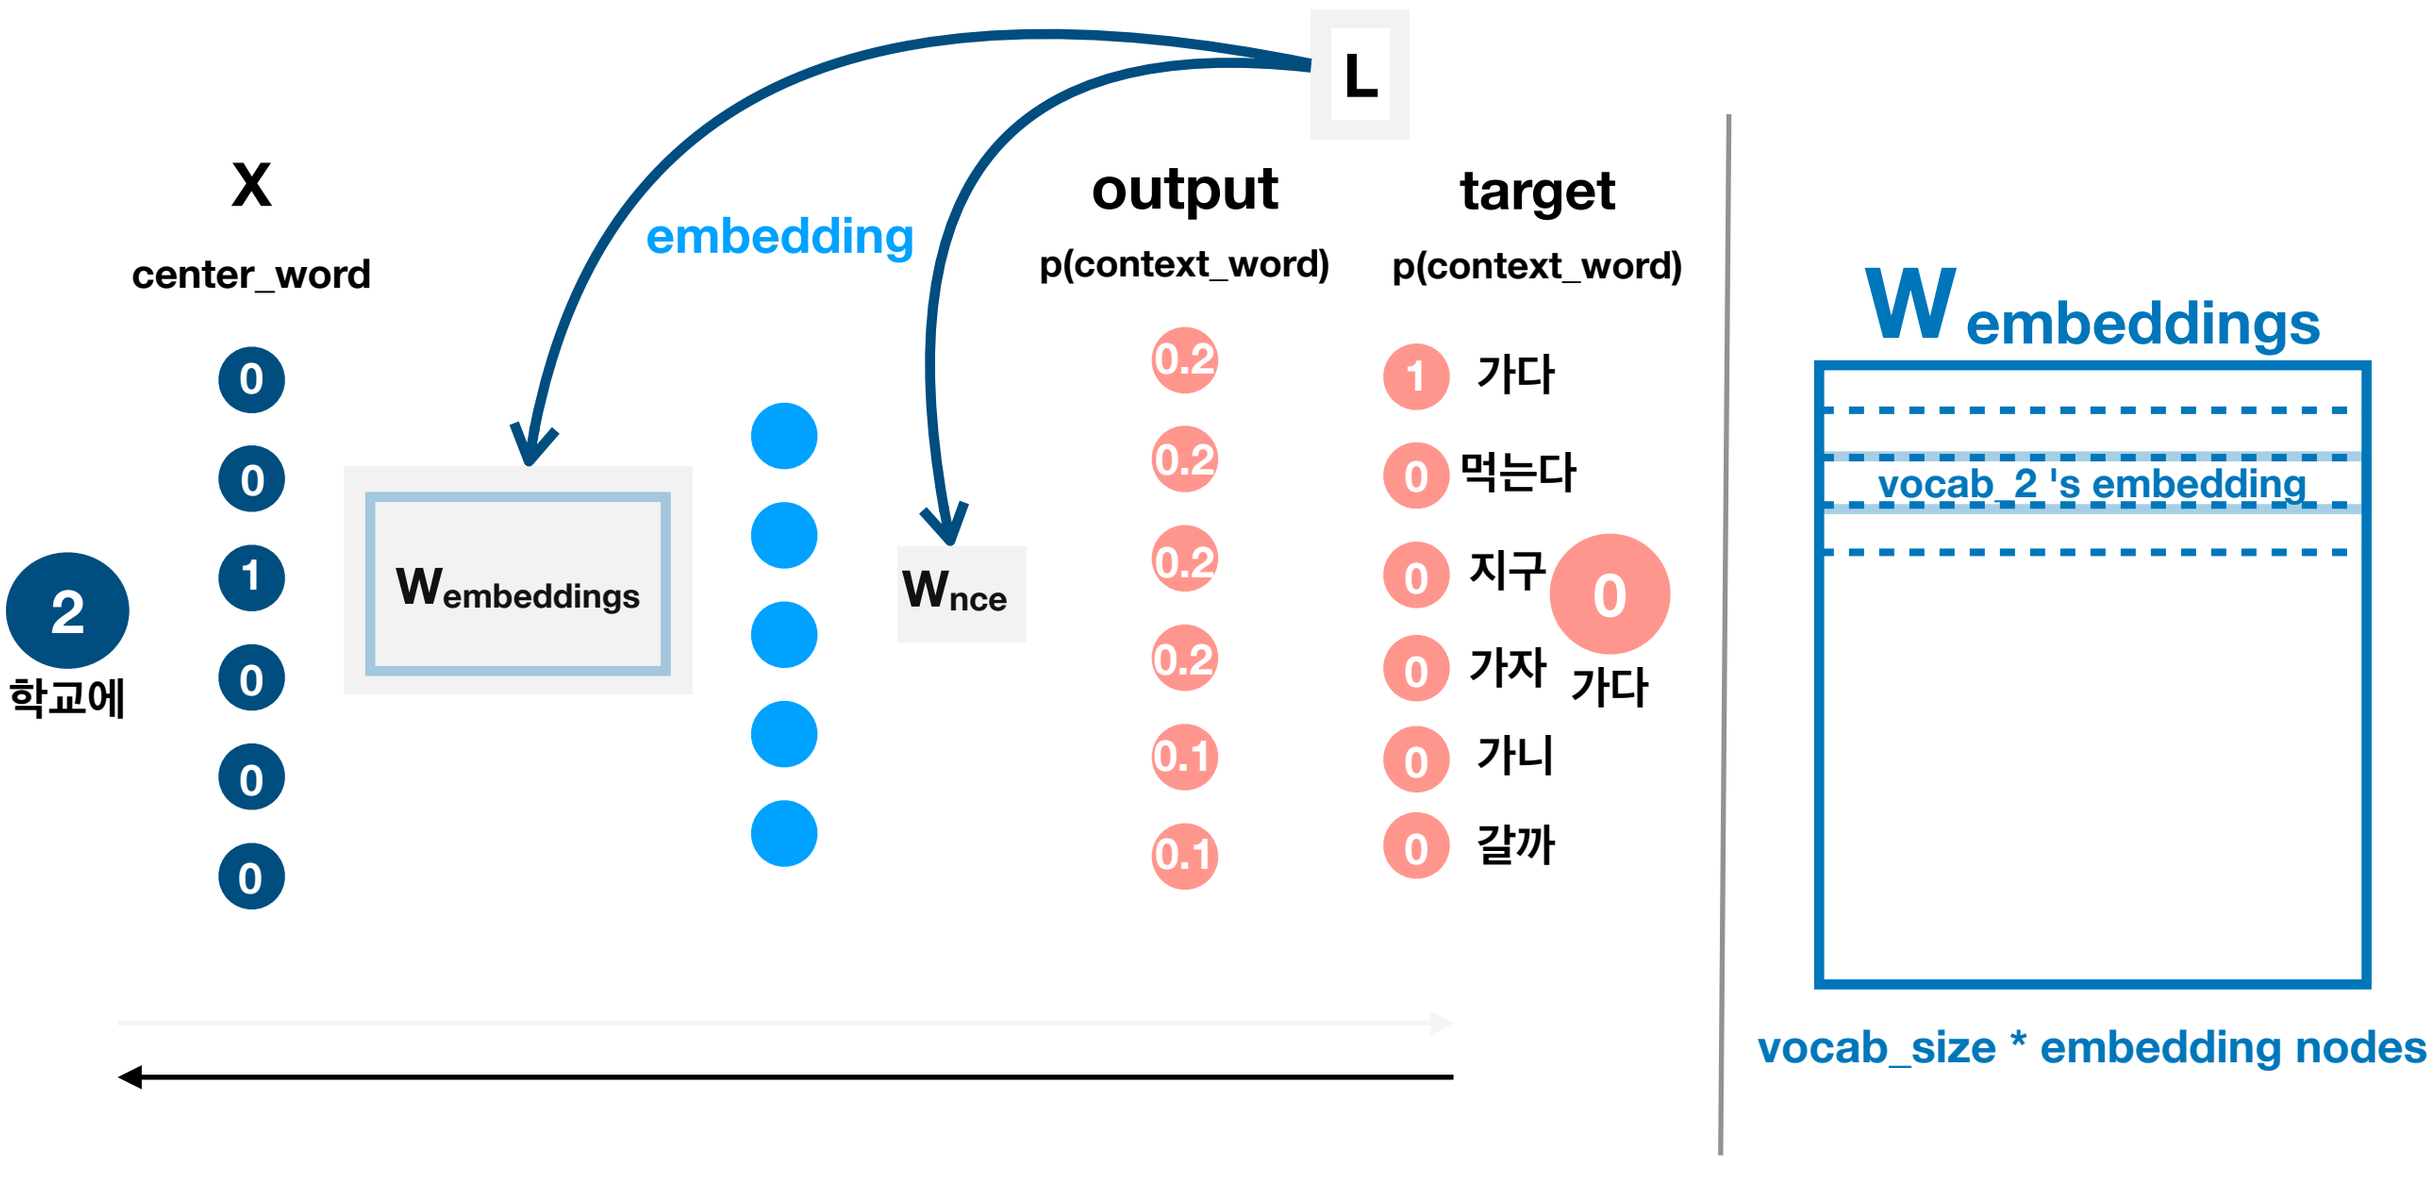

loss를 최소화하는 방향으로, weight을 update 합니다.

Word2Vec

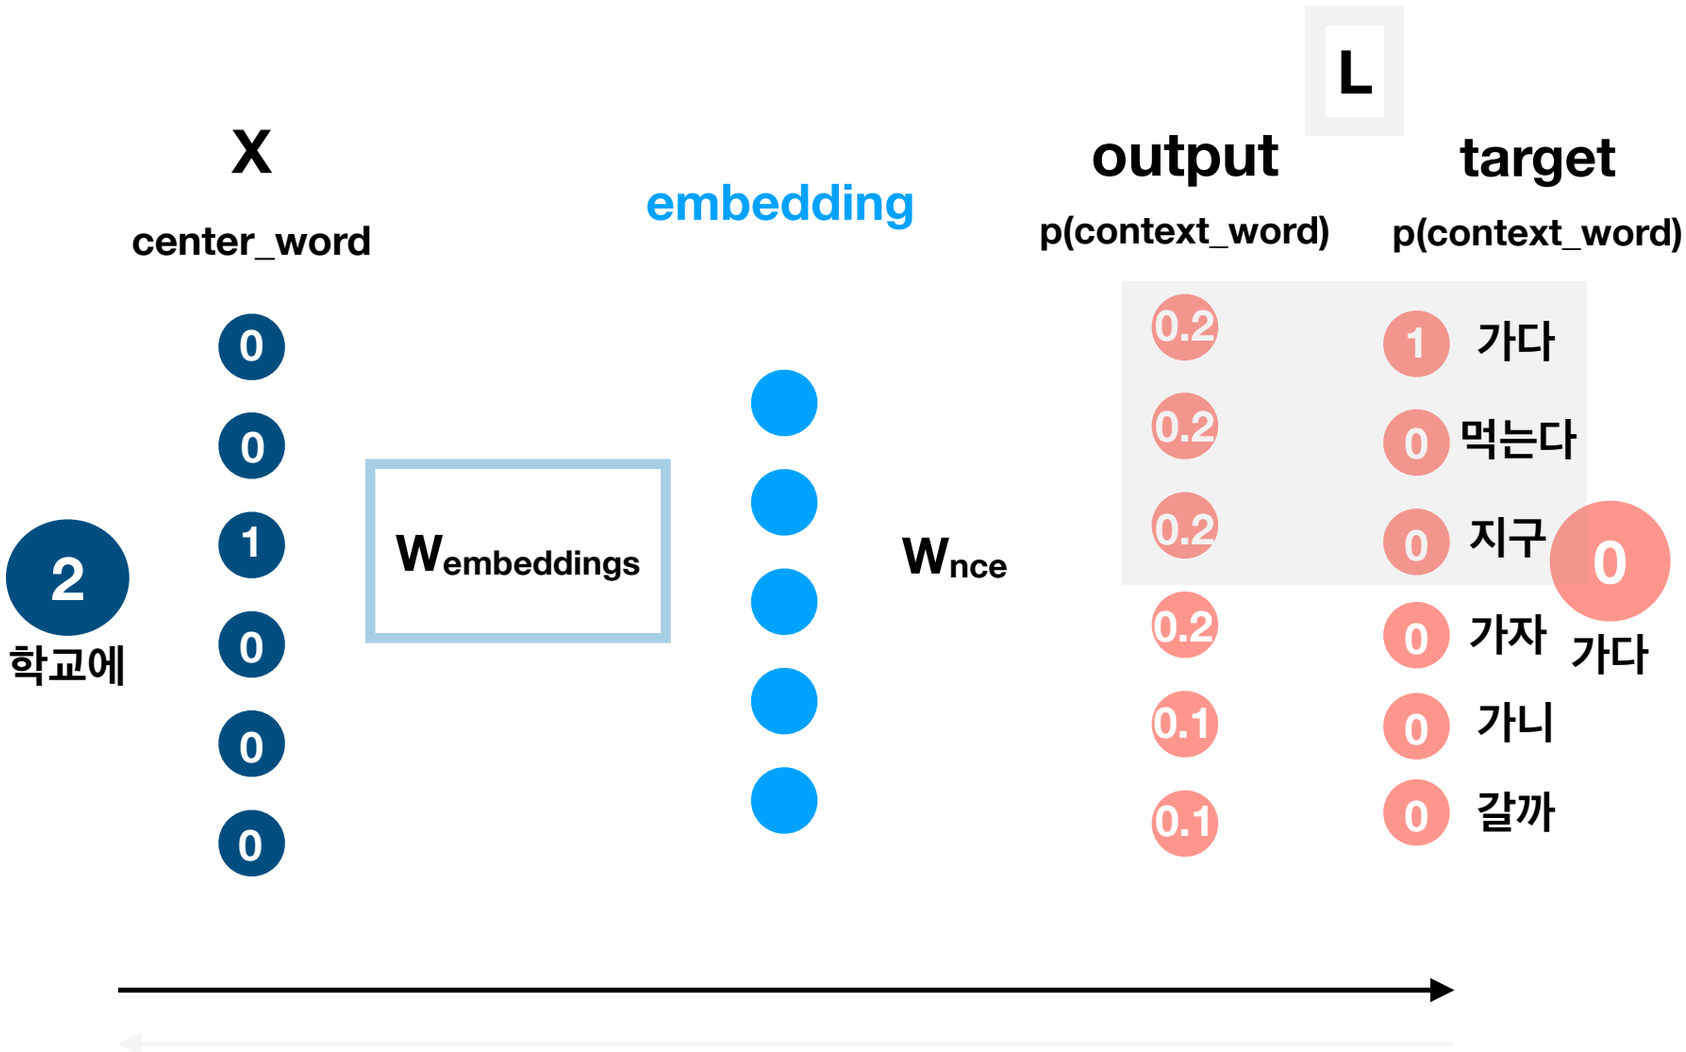

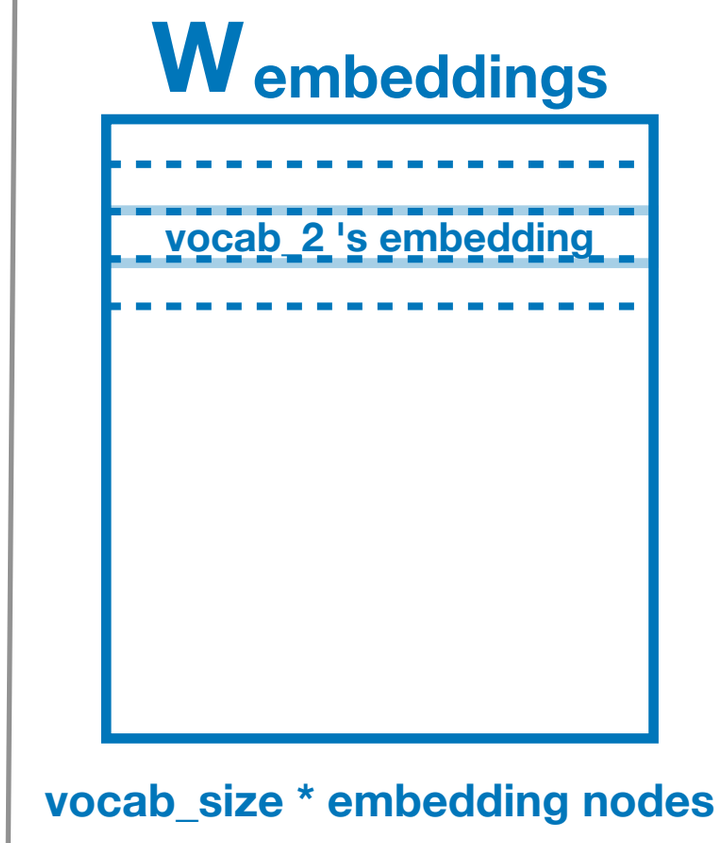

그러나, 훈련 대상이 되는 단어의 총 개수가 너무 많기 때문에,
실제로는 단어의 일부만 가지고 loss를 구합니다.
구체적으로는 정답인 '가다'와 정답과 거리가 먼 '먹는다', '지구' 등의 negative sample을 선별해 loss를 구하게 되는데 이런 방식을 negative sampling이라고 합니다.

RNN

RNN

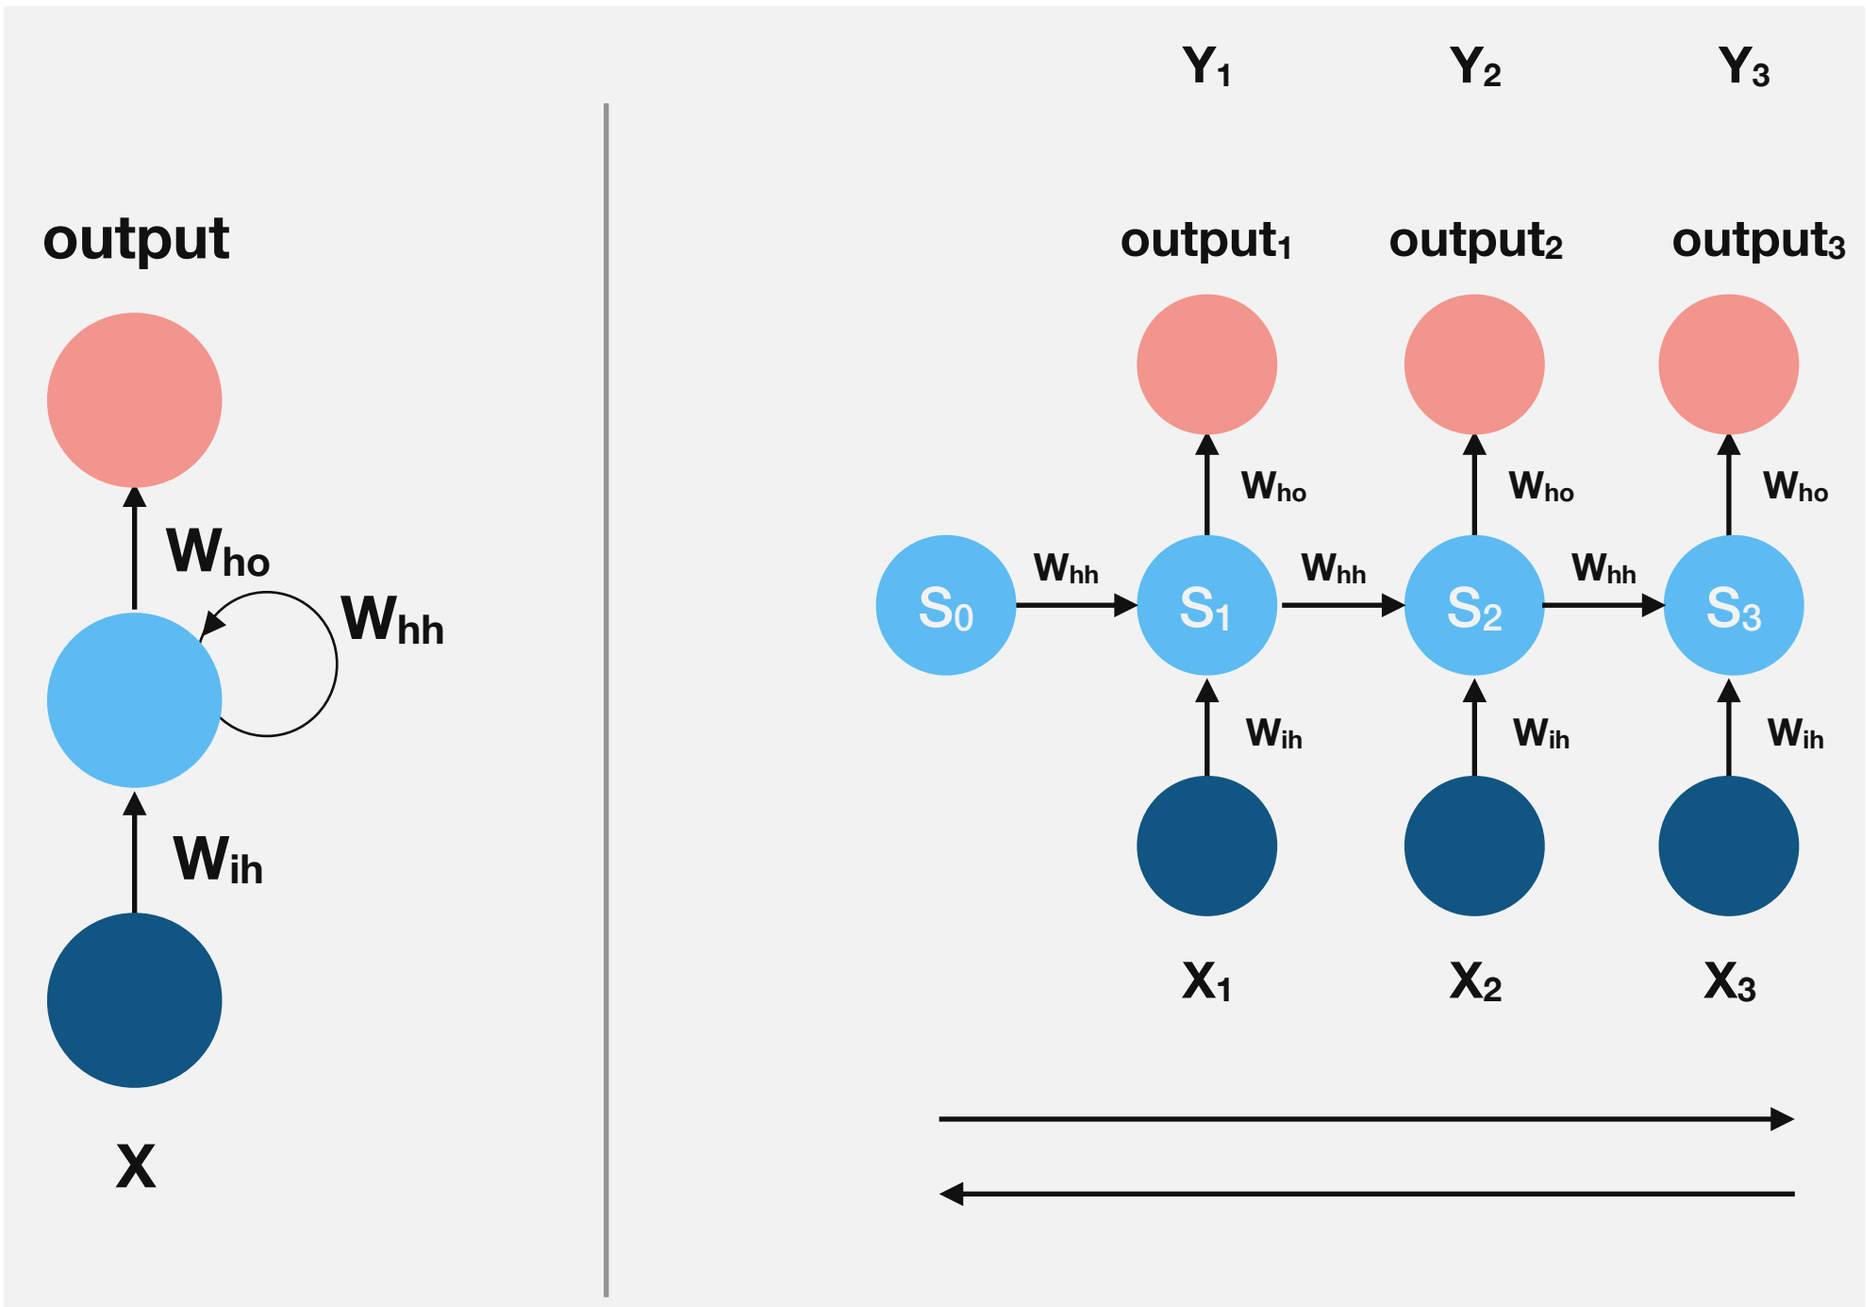

'나는 오늘 집에 간다'라는 문장을 단어 단위로 훈련해봅시다.

RNN

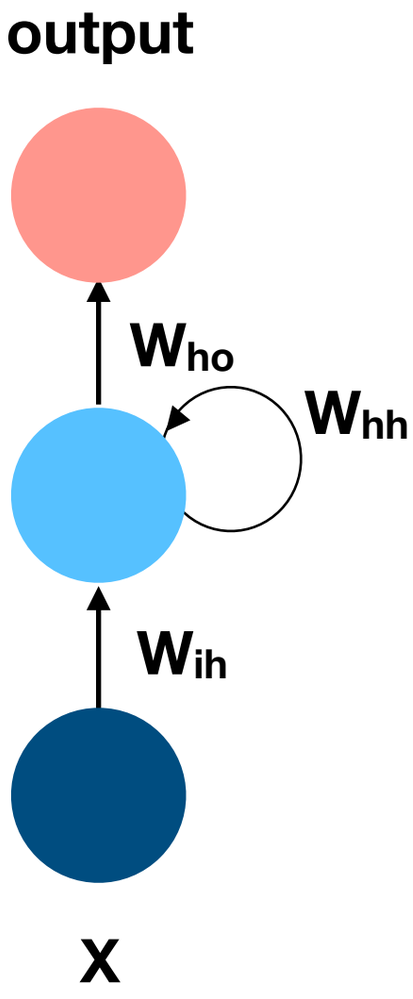

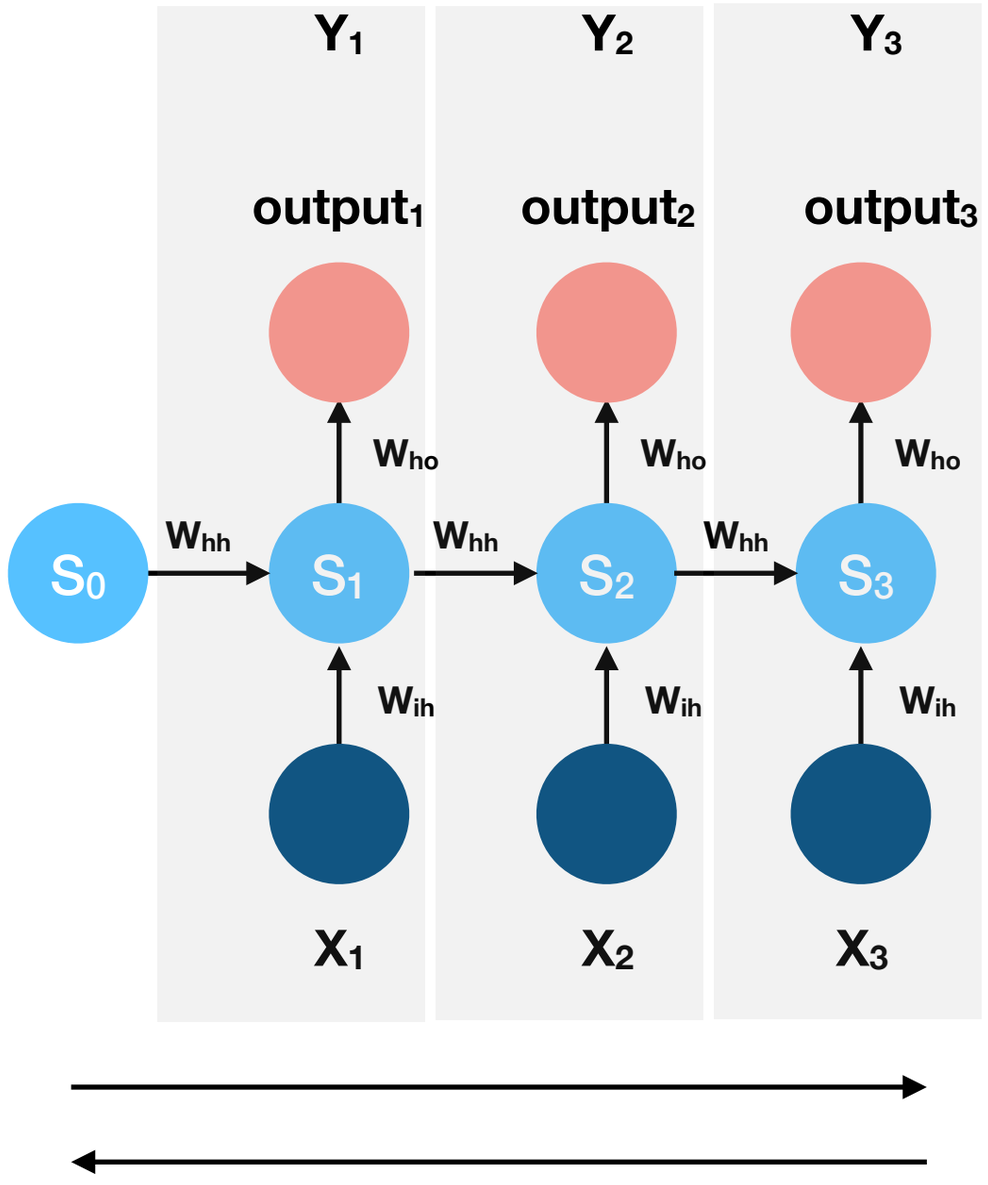

이 예시에서는 총 3개의 time step을 가지는 RNN을 훈련할 것입니다.

RNN

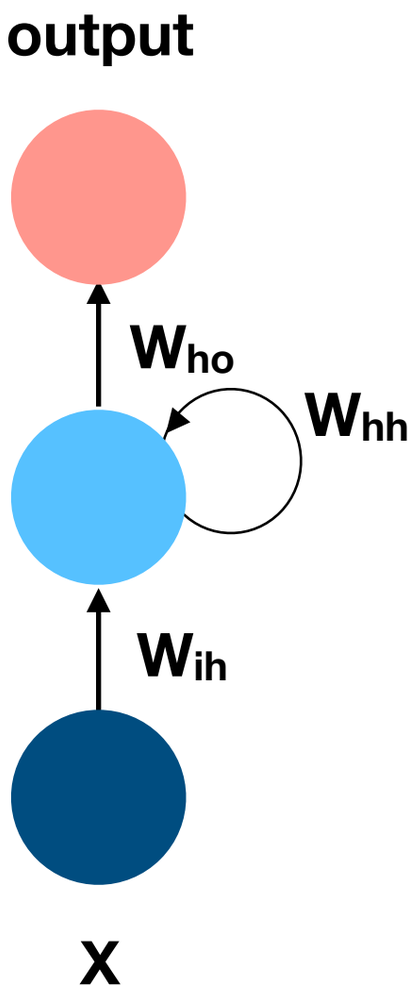

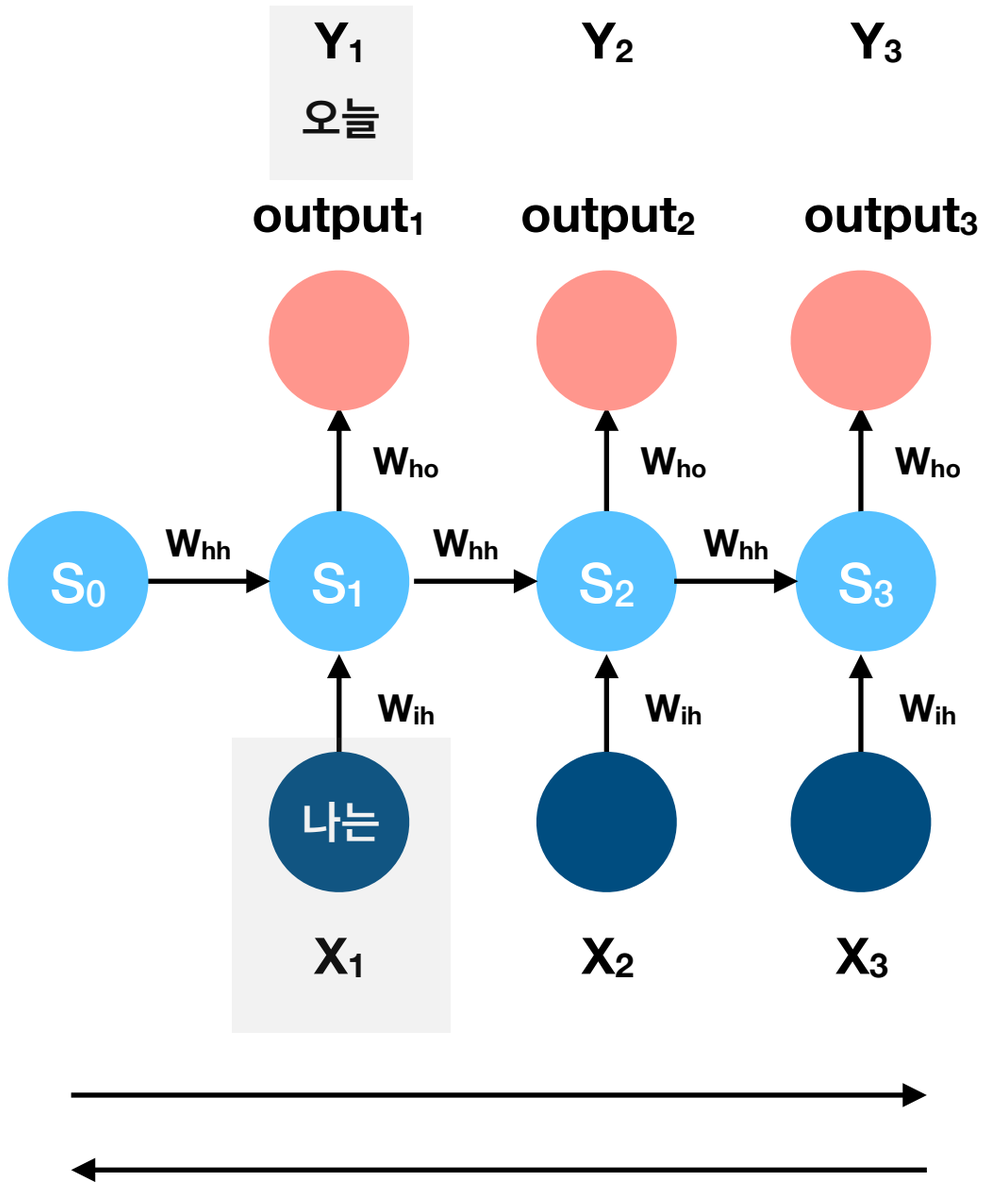

한 단어가 오면 그 다음 단어를 예측하도록 input과 target을 설정해줍니다.
첫 time step에서는 '나는'이 input일 때 '오늘'이 target이 되도록

RNN

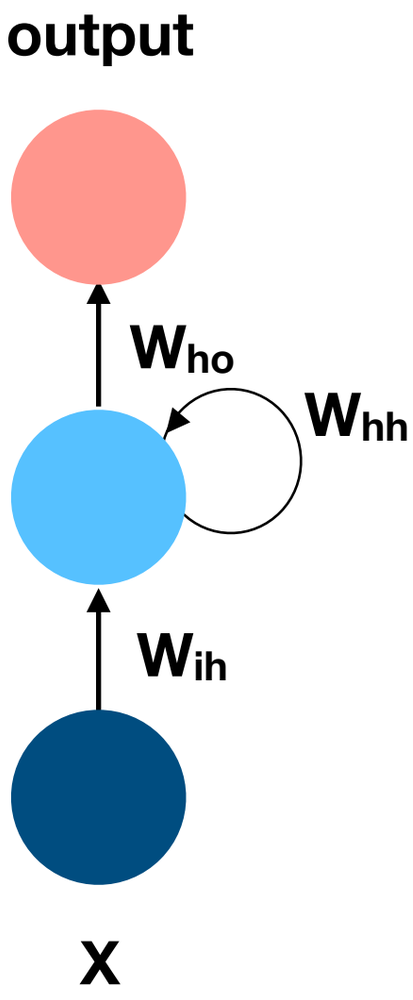

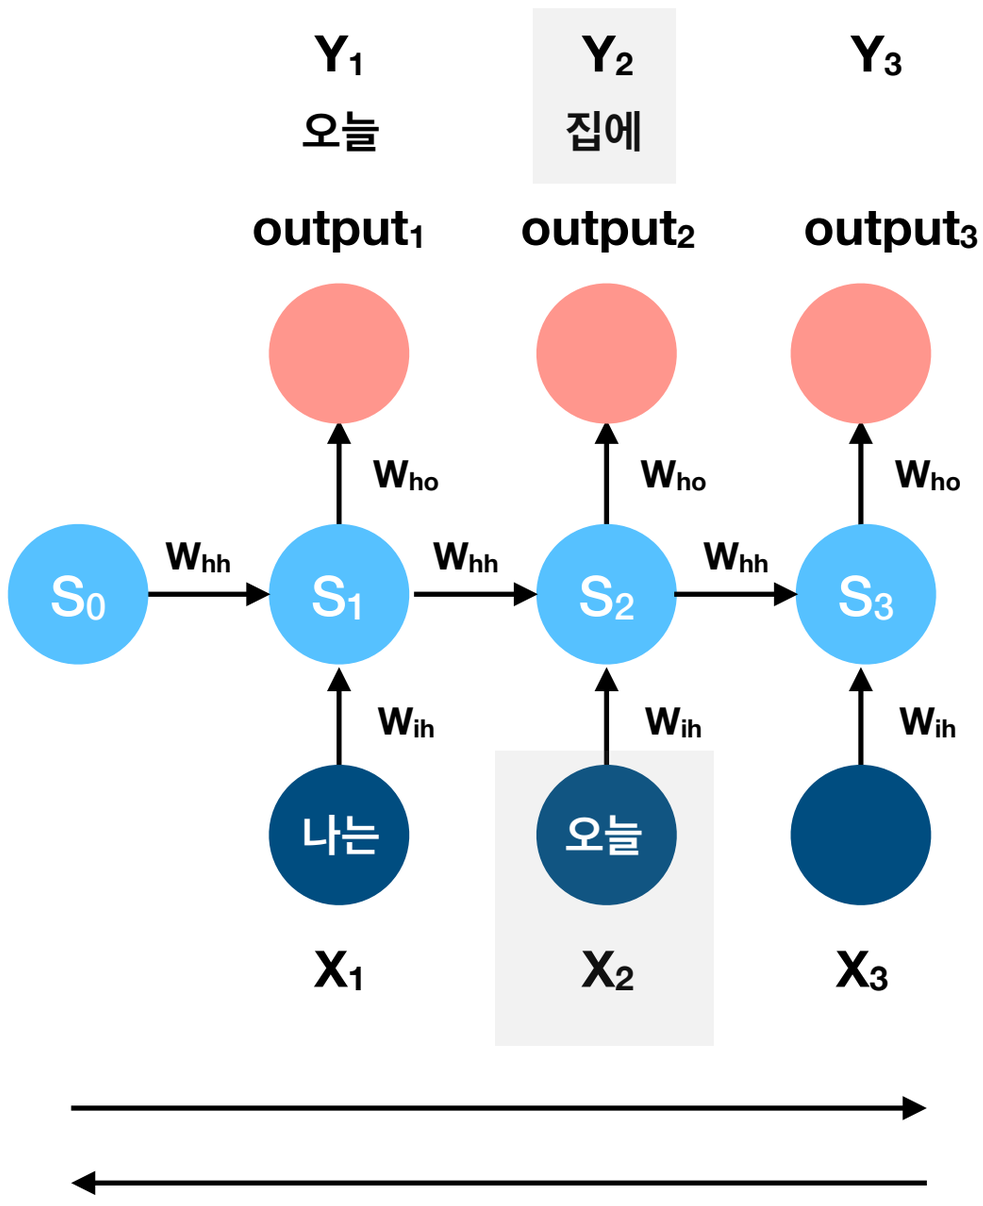

두 번째 time step에서는 '오늘'이 input일 때 '집에'가 target이 되도록

RNN

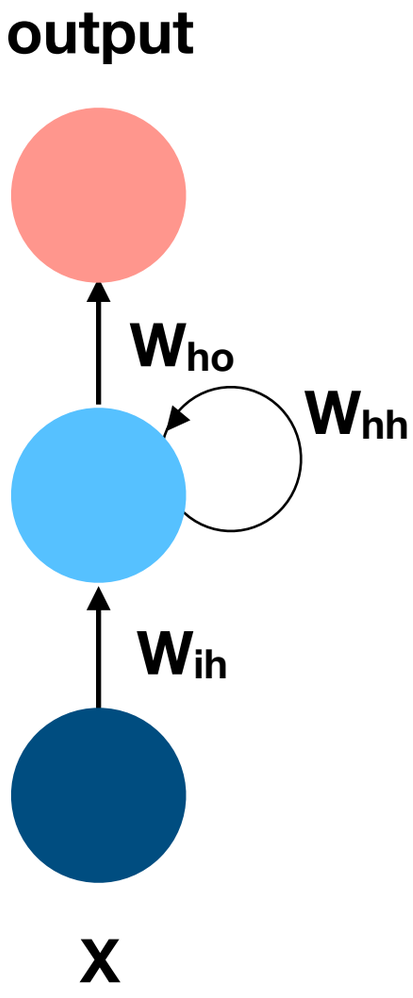

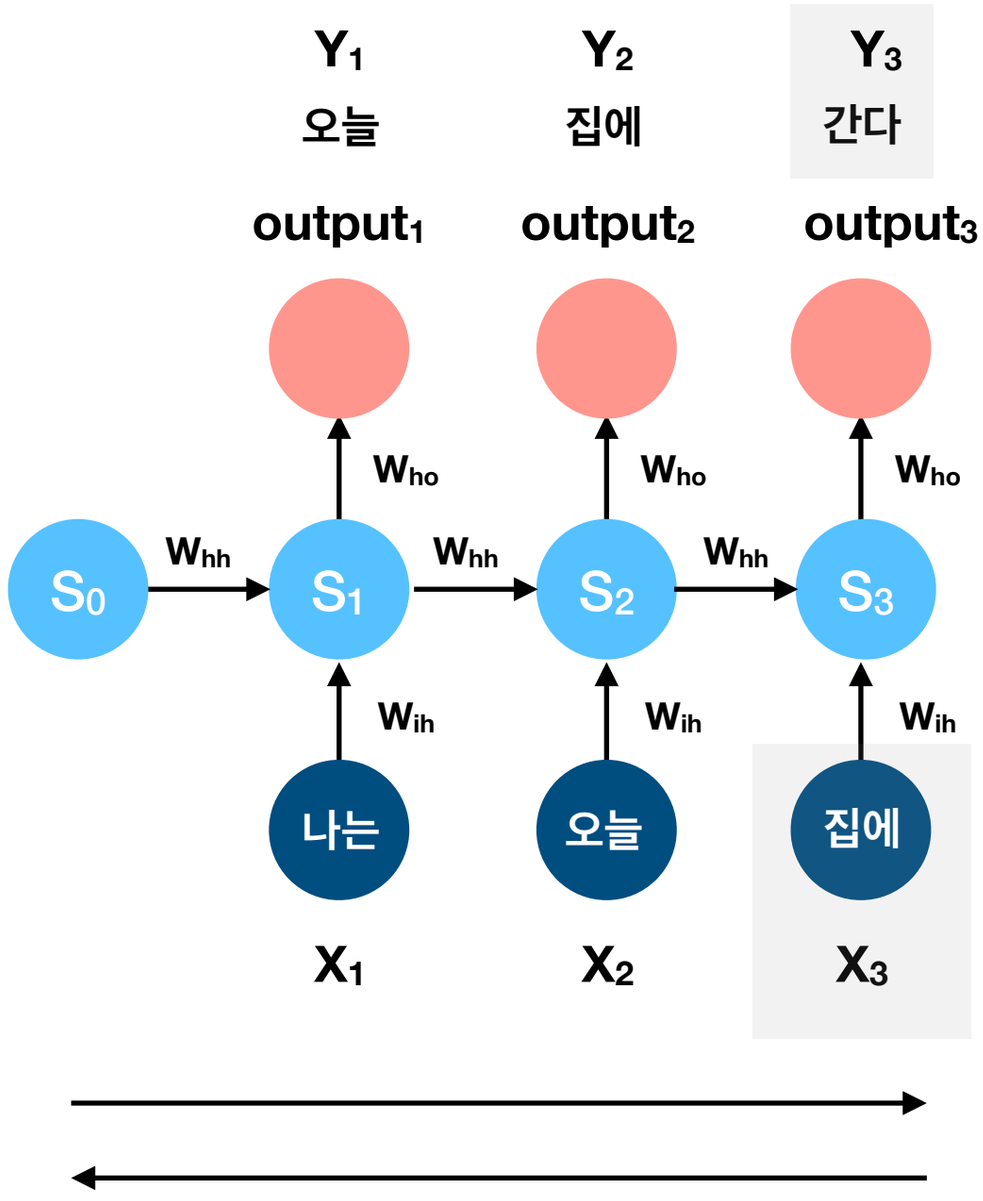

세 번째 time step에서는 '집에'가 input일 때 '간다'가 target이 되도록 RNN을 훈련해봅시다.

RNN

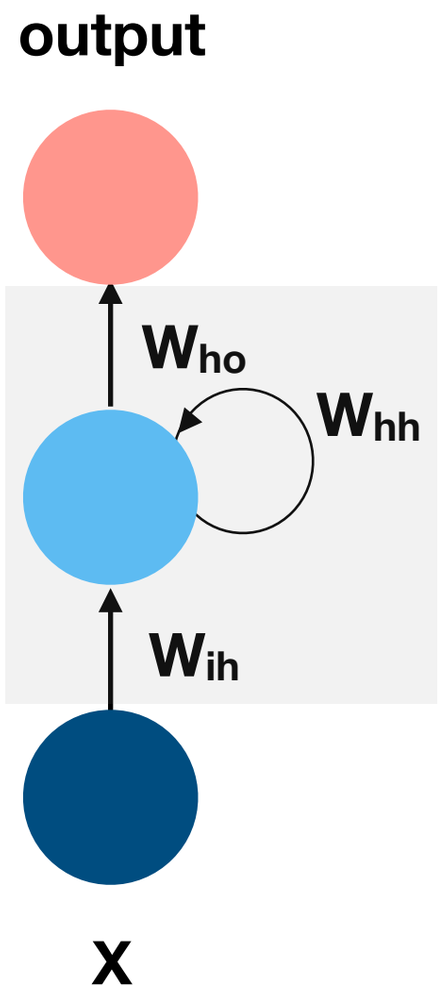

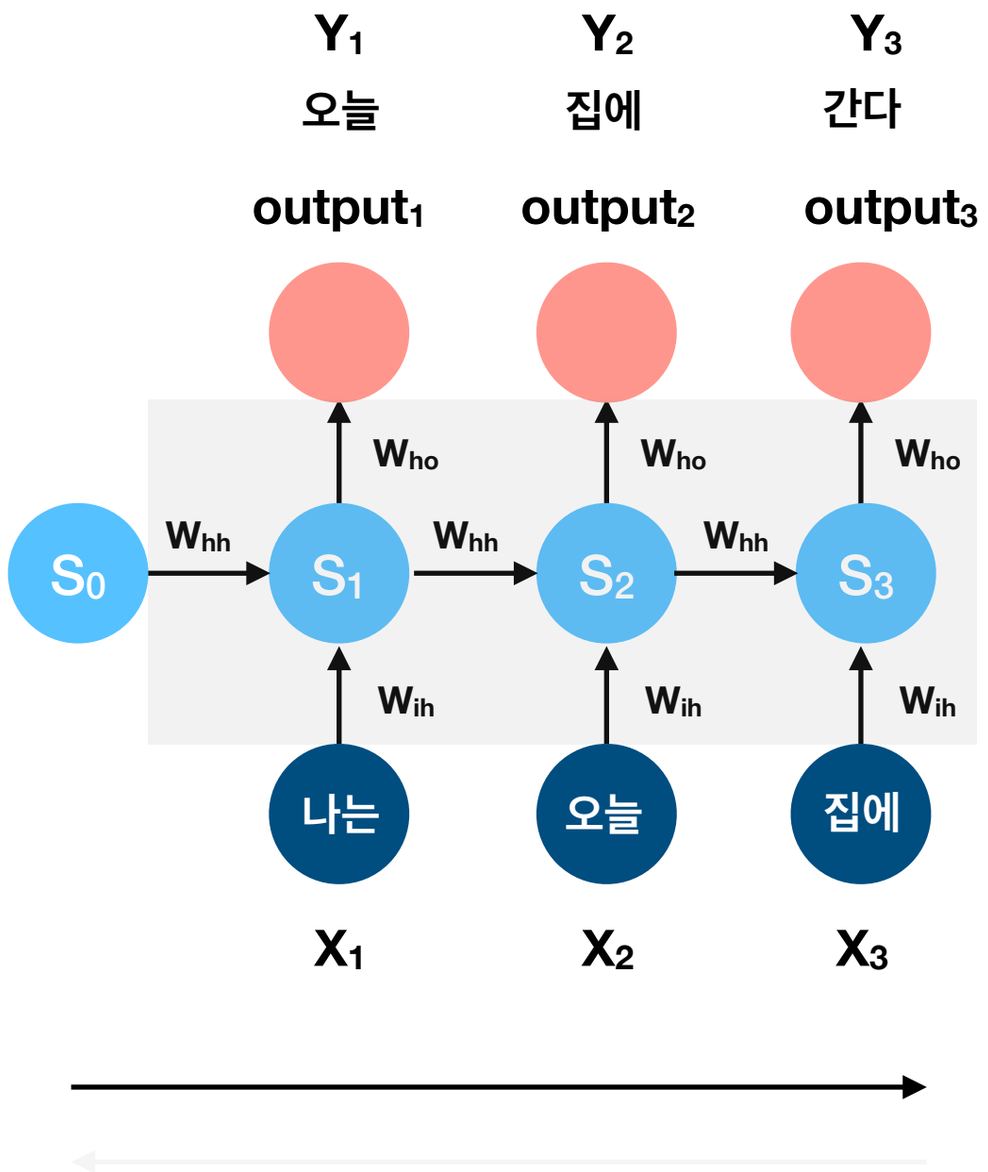

각 time step에서의 W_{ih}, W_{hh}, W_{ho}는 각각 동일한 weight입니다.

RNN

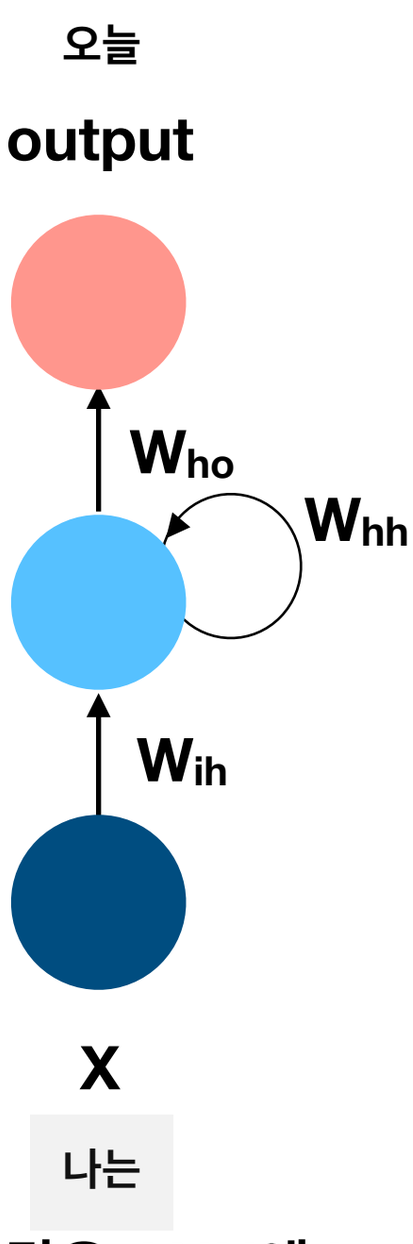

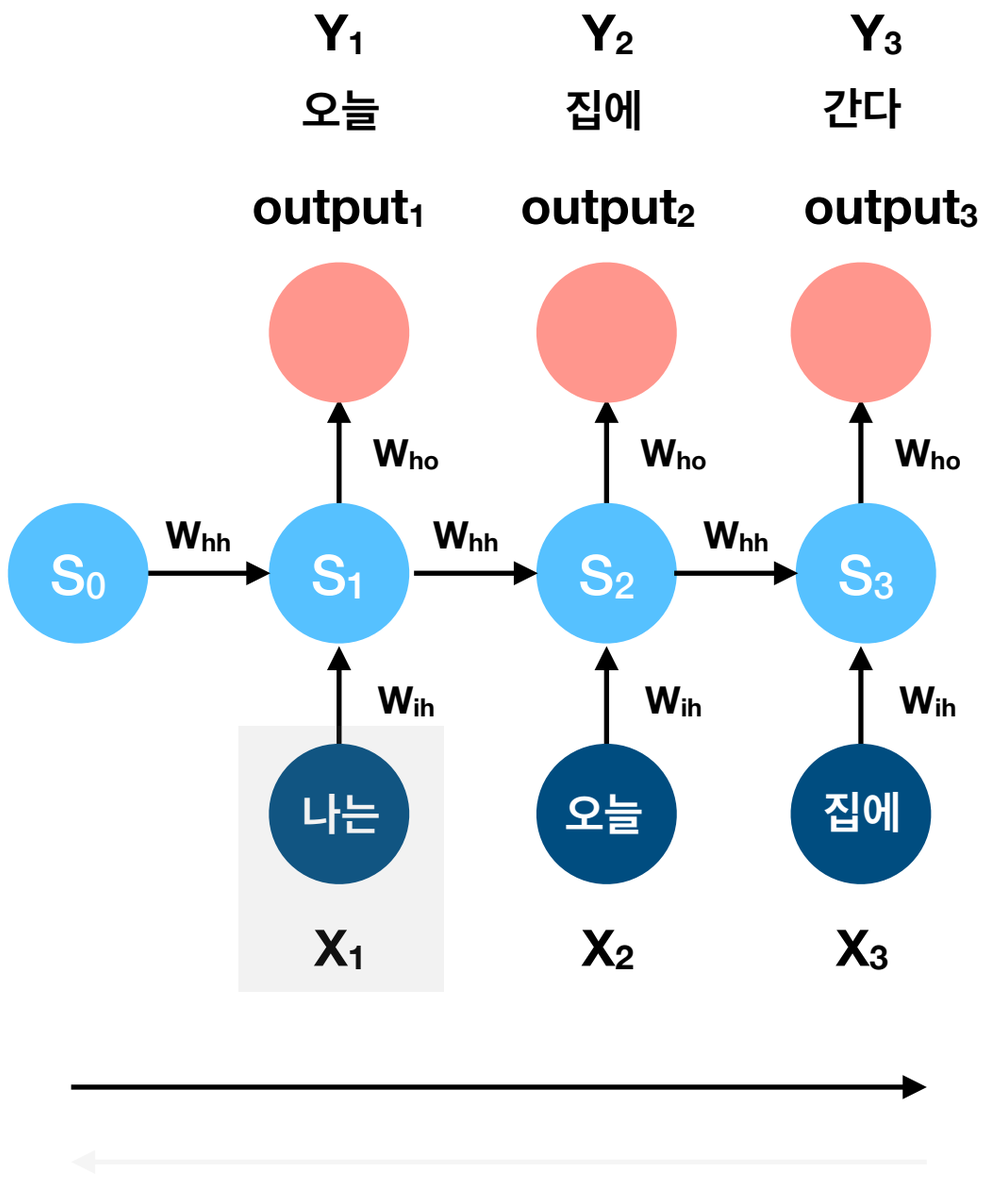

왼쪽 그림과 같은 ANN에 input X_1, X_2, X_3가 순서대로 들어간다고 생각하면 됩니다.

RNN

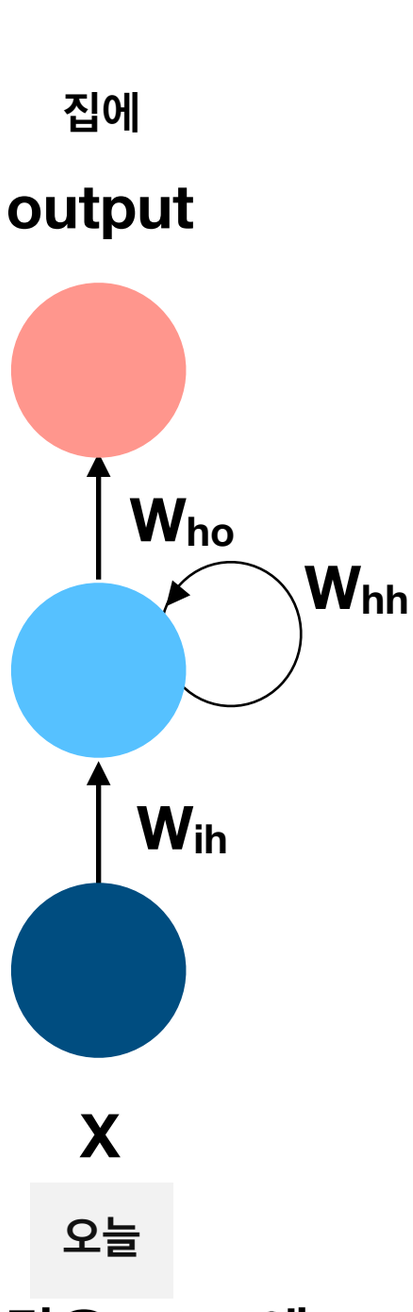

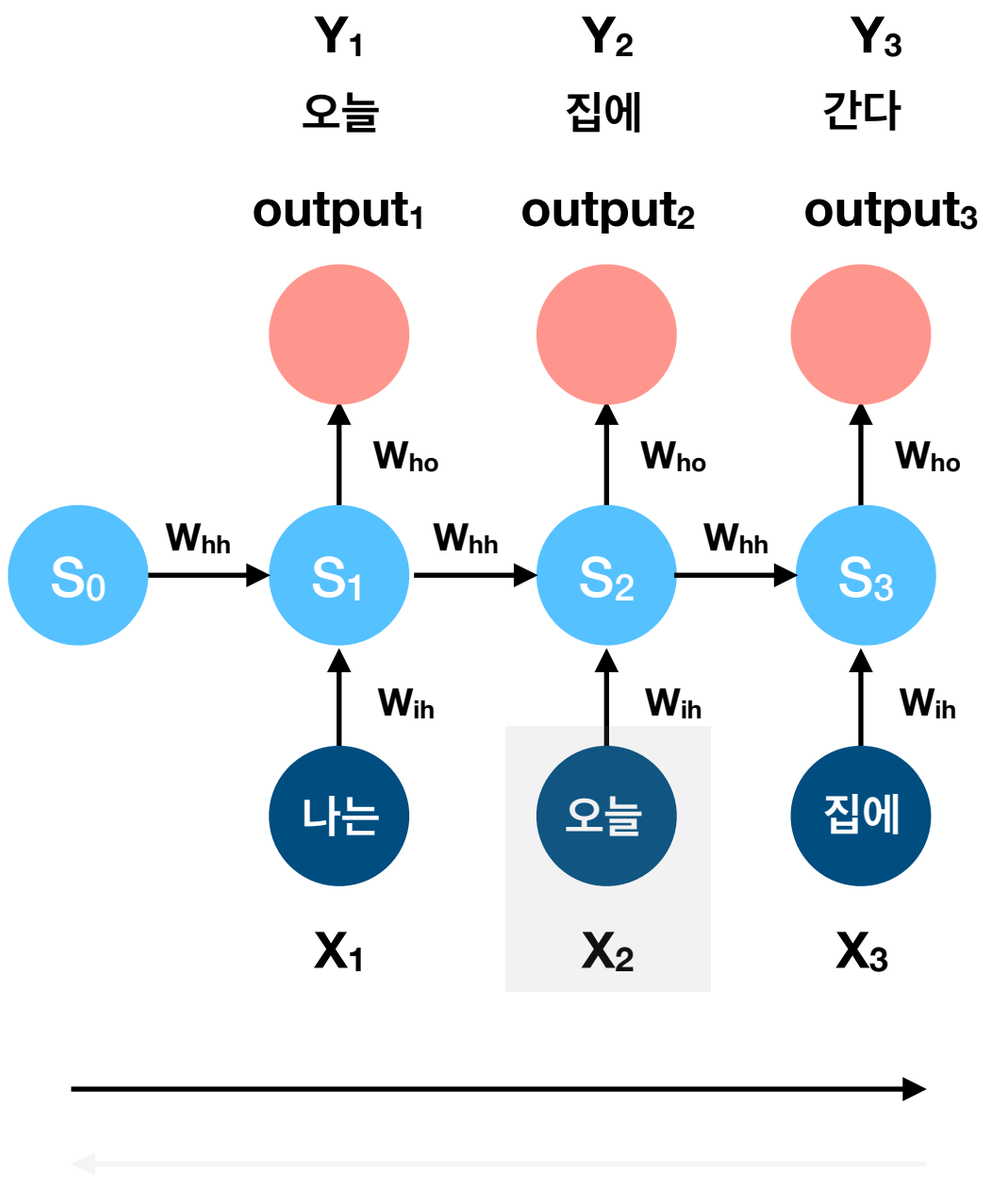

왼쪽 그림과 같은 ANN에 input X_1, X_2, X_3가 순서대로 들어간다고 생각하면 됩니다.

RNN

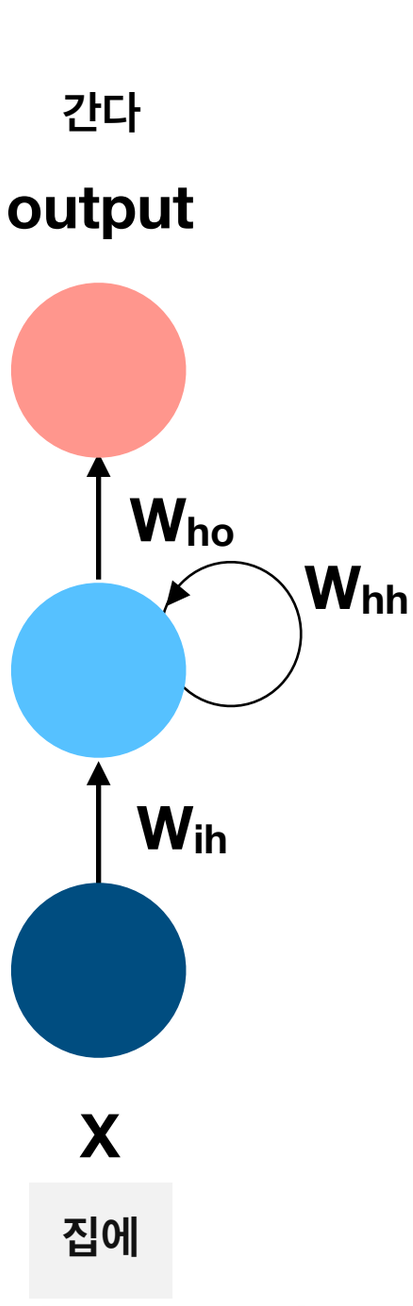

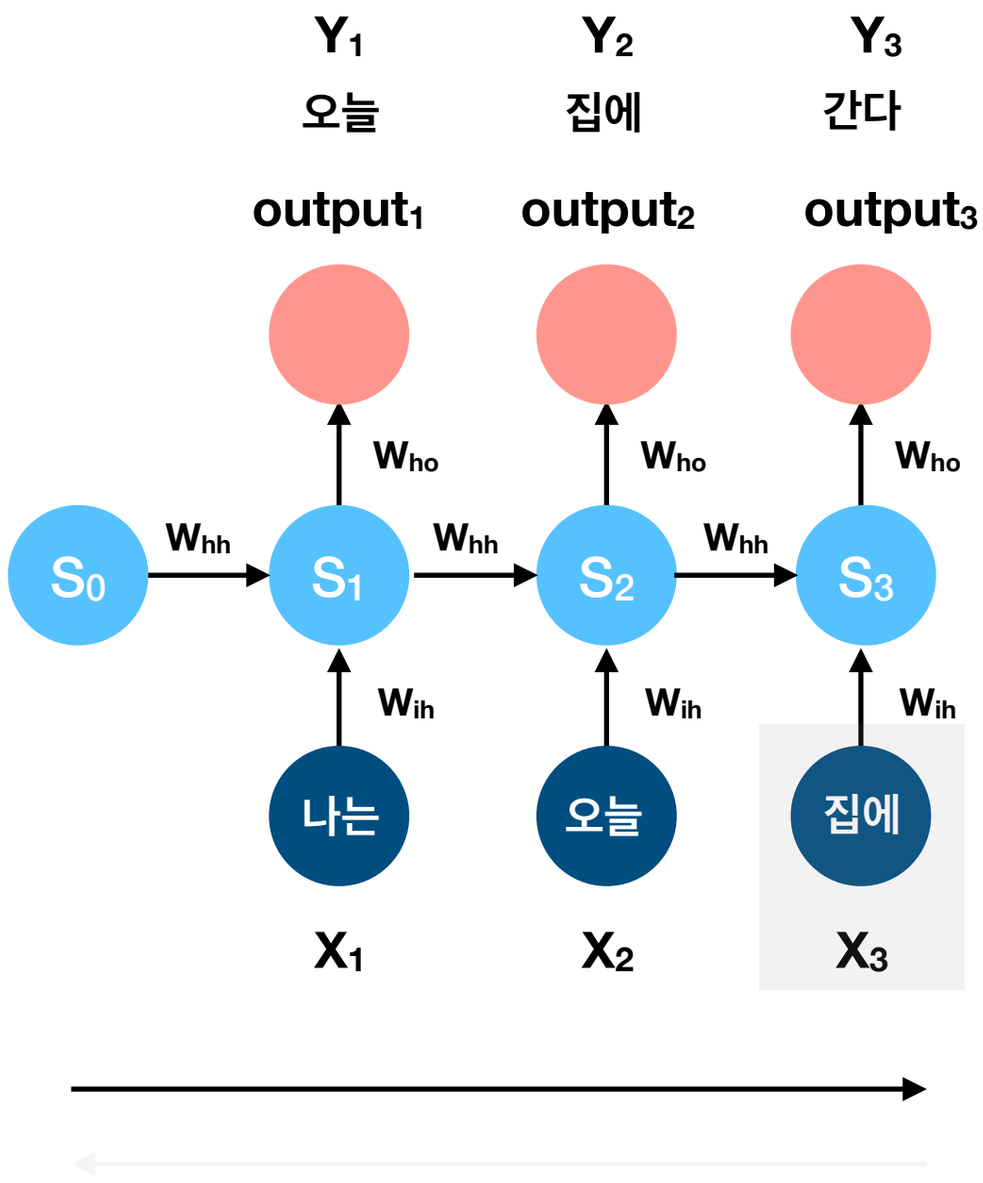

왼쪽 그림과 같은 ANN에 input X_1, X_2, X_3가 순서대로 들어간다고 생각하면 됩니다.

RNN

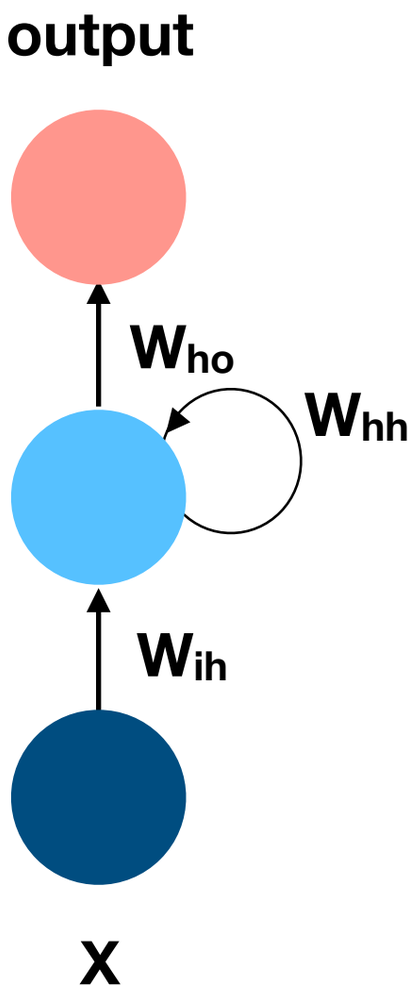

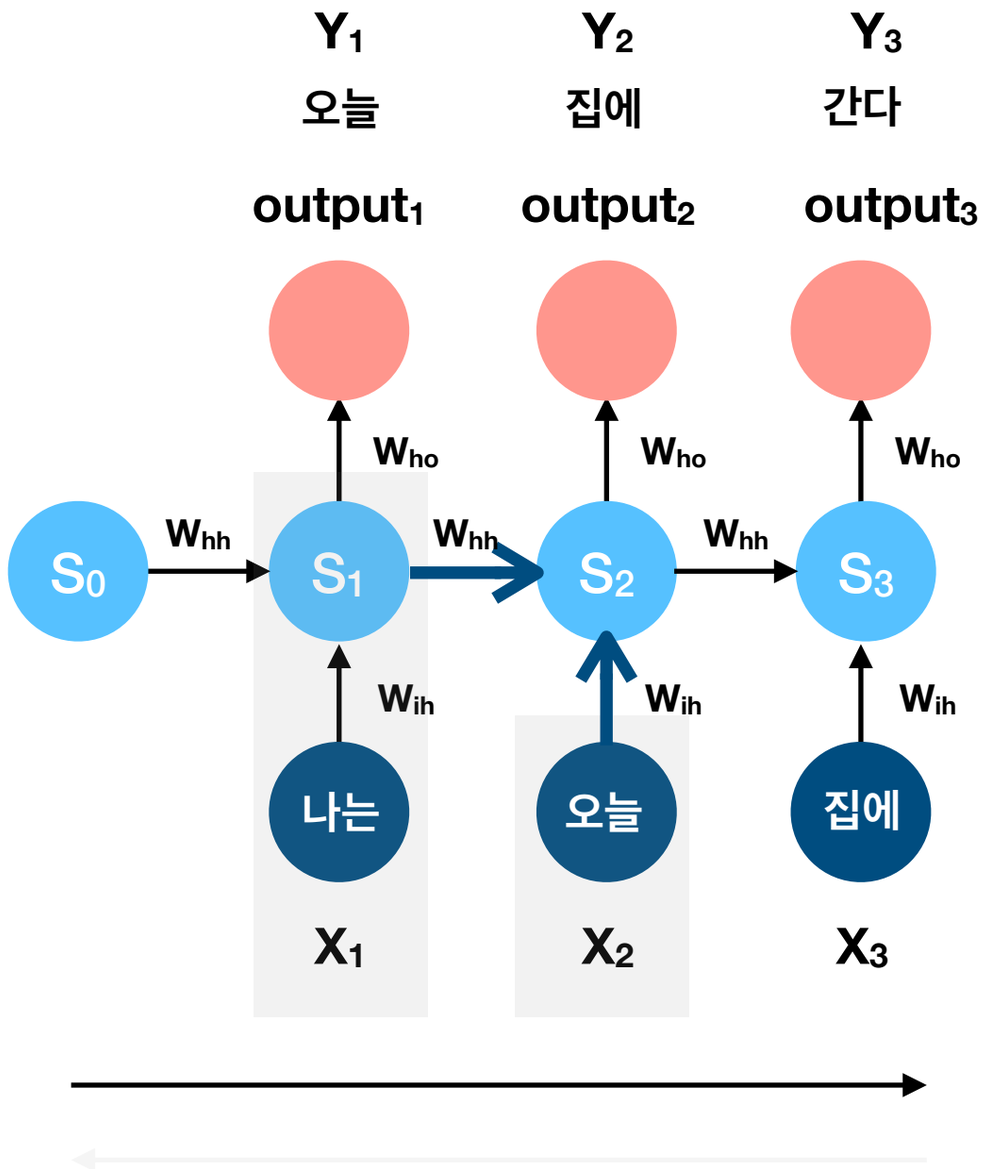

하지만 ANN과는 다르게 hidden layer는 현재 time step의 input 뿐만 아니라
이전 time step의 hidden layer의 영향도 받습니다. ($S(t) = S(t-1) * W_{hh} + X(t) * W_{ih}$)

RNN

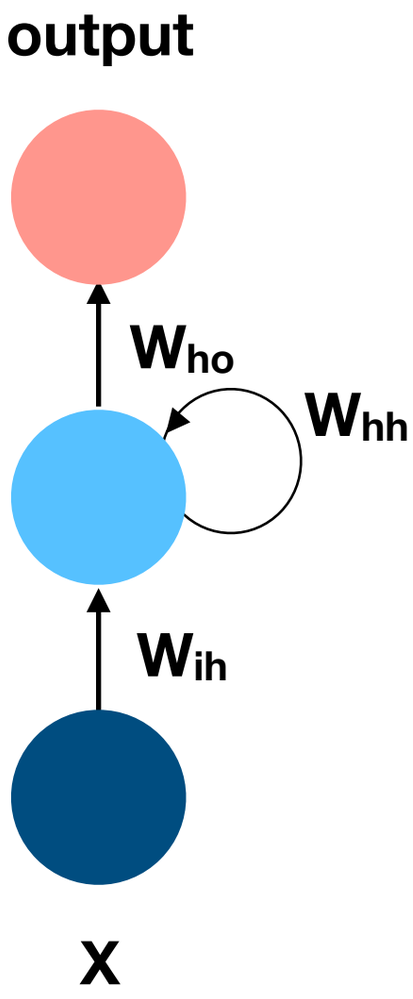

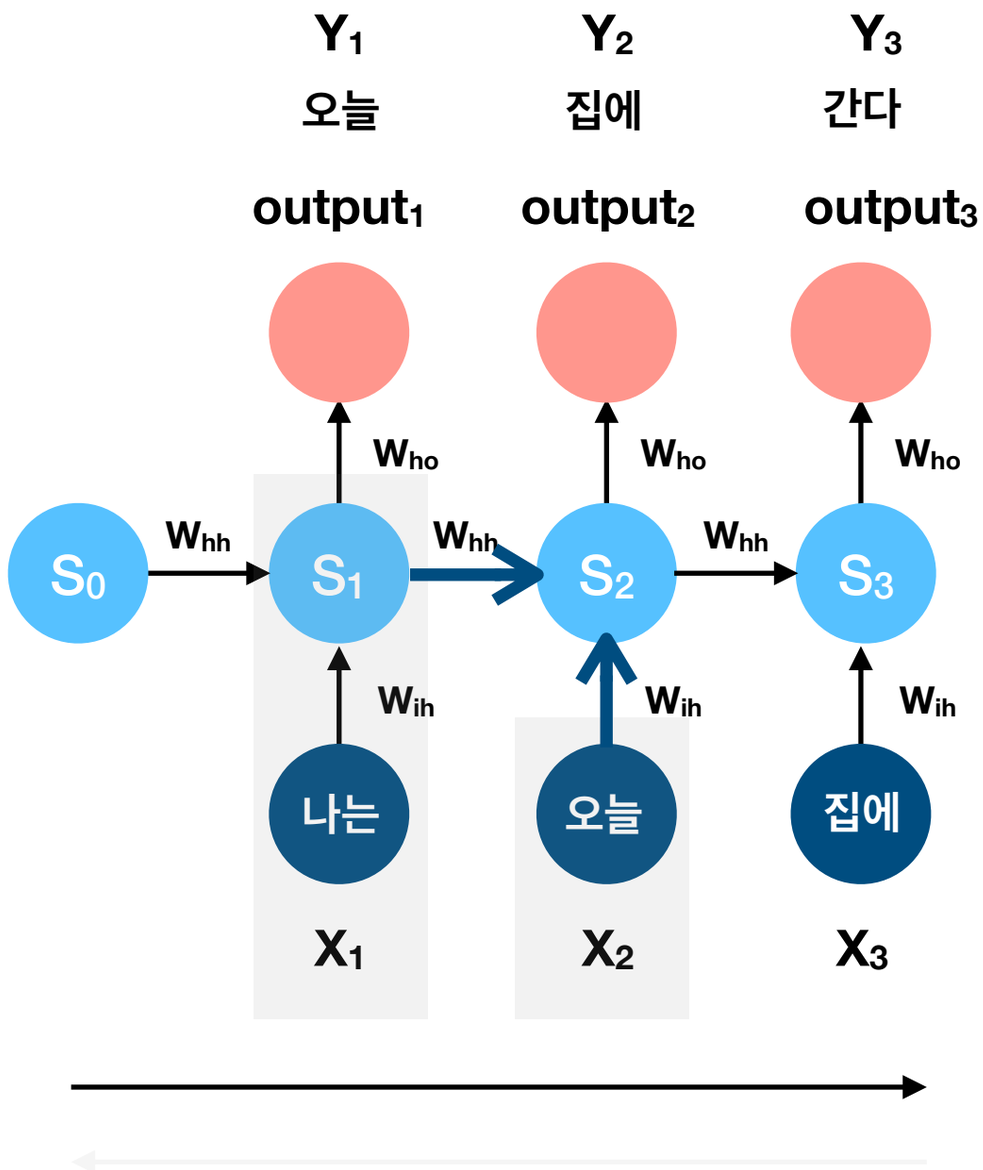

즉 '오늘'이란 단어가 두 번째 input (X_2)으로 들어갔을 때 이전 input (X_1)인 '나는'이 영향을 줍니다.

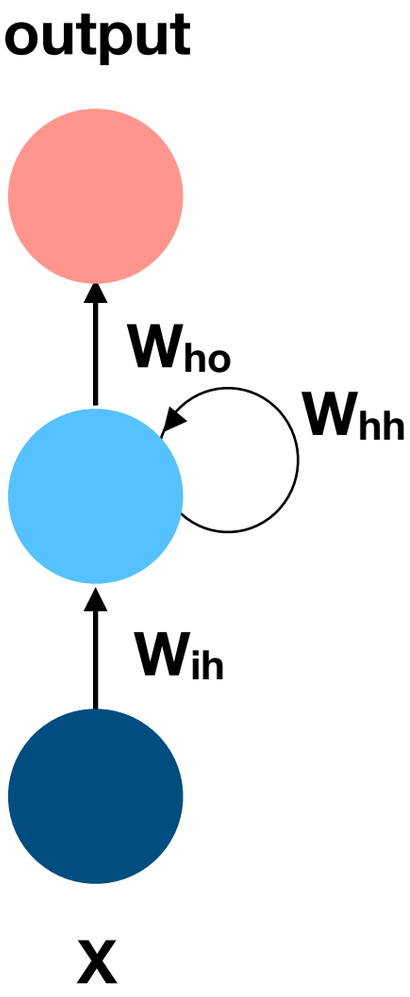

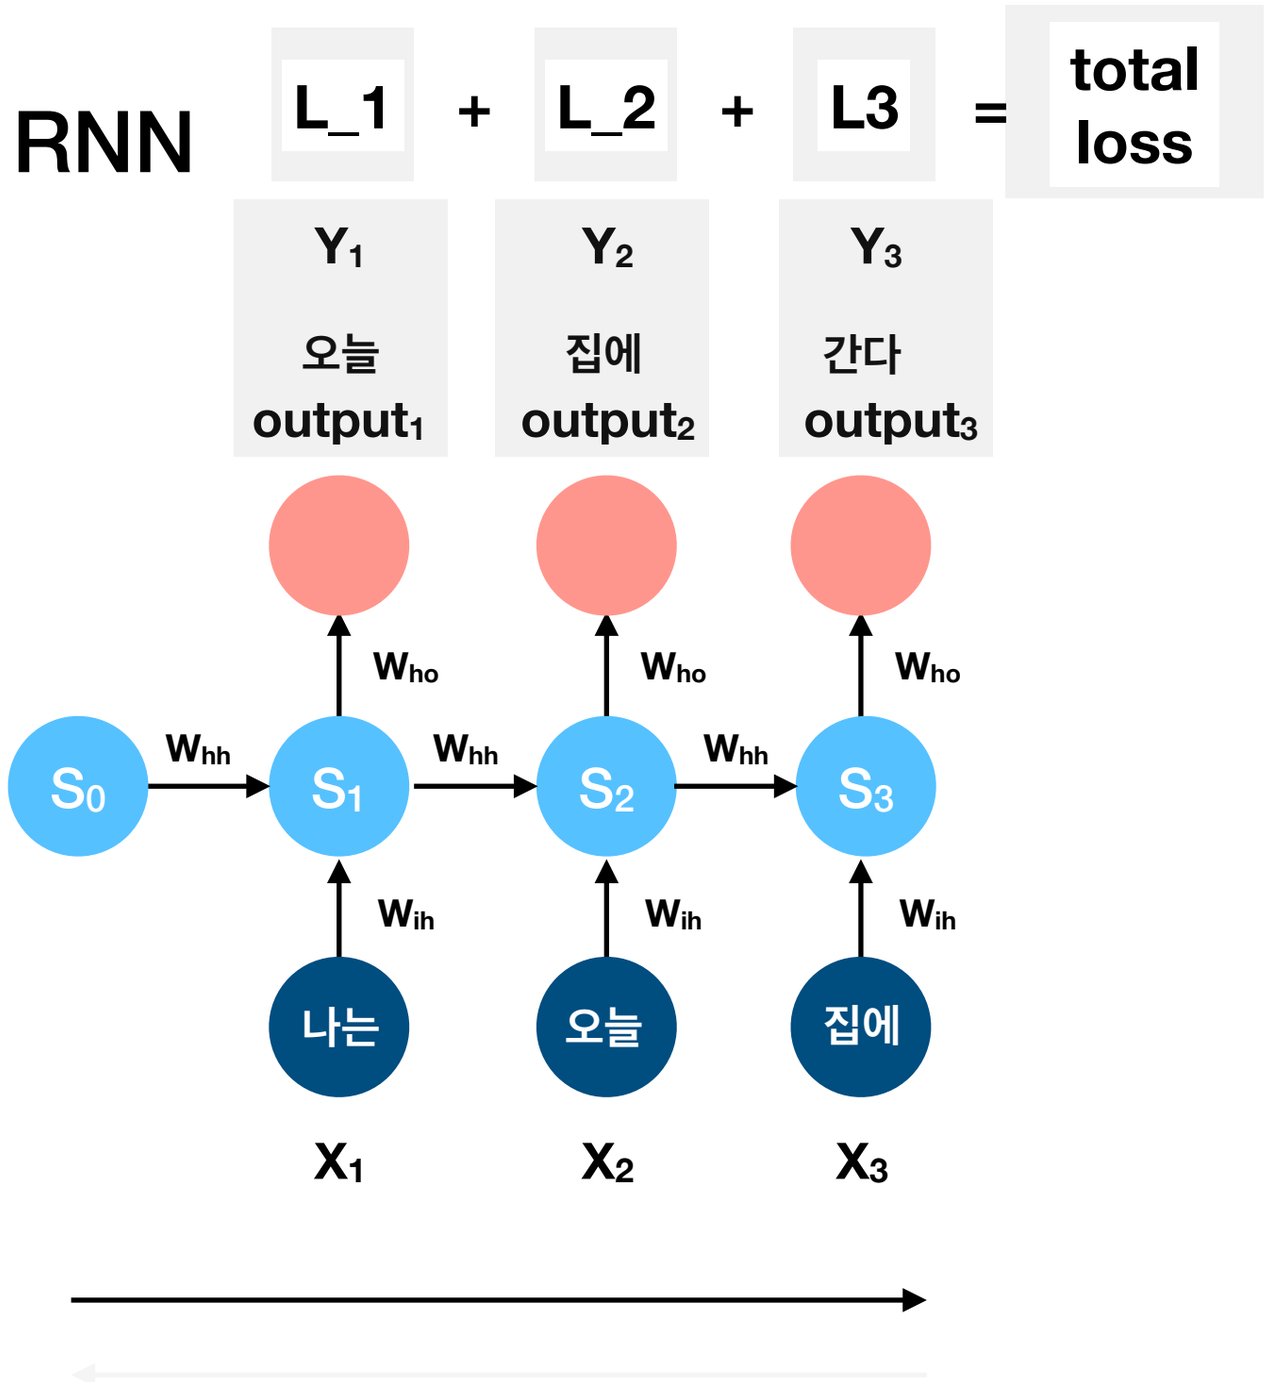

output과 정답 target (Y)을 비교하여 loss를 구합니다.
그러면 각각의 time step에서 loss가 나오게 될 것이고 이를 모두 더하여 전체 loss라고 정의합니다.

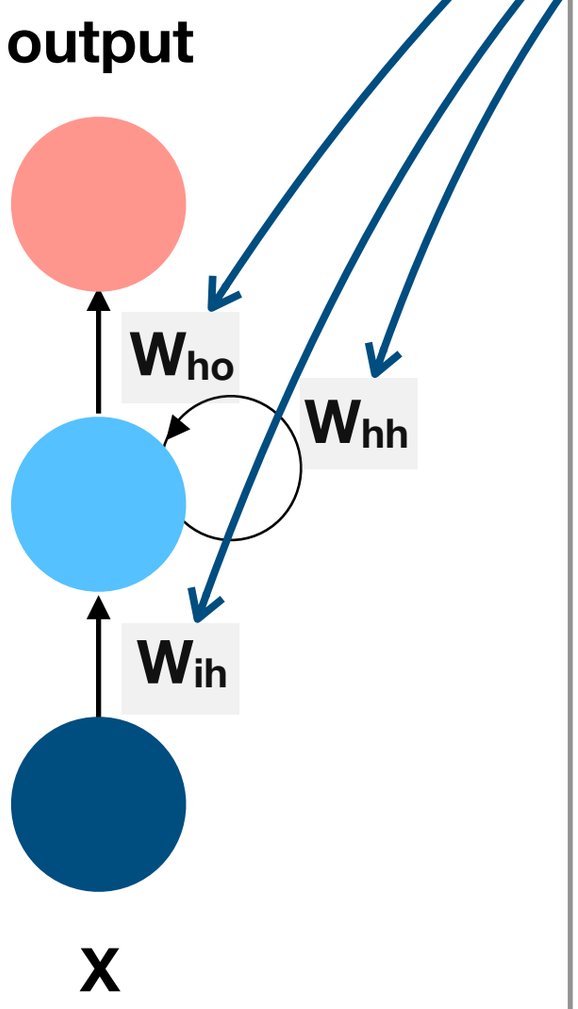

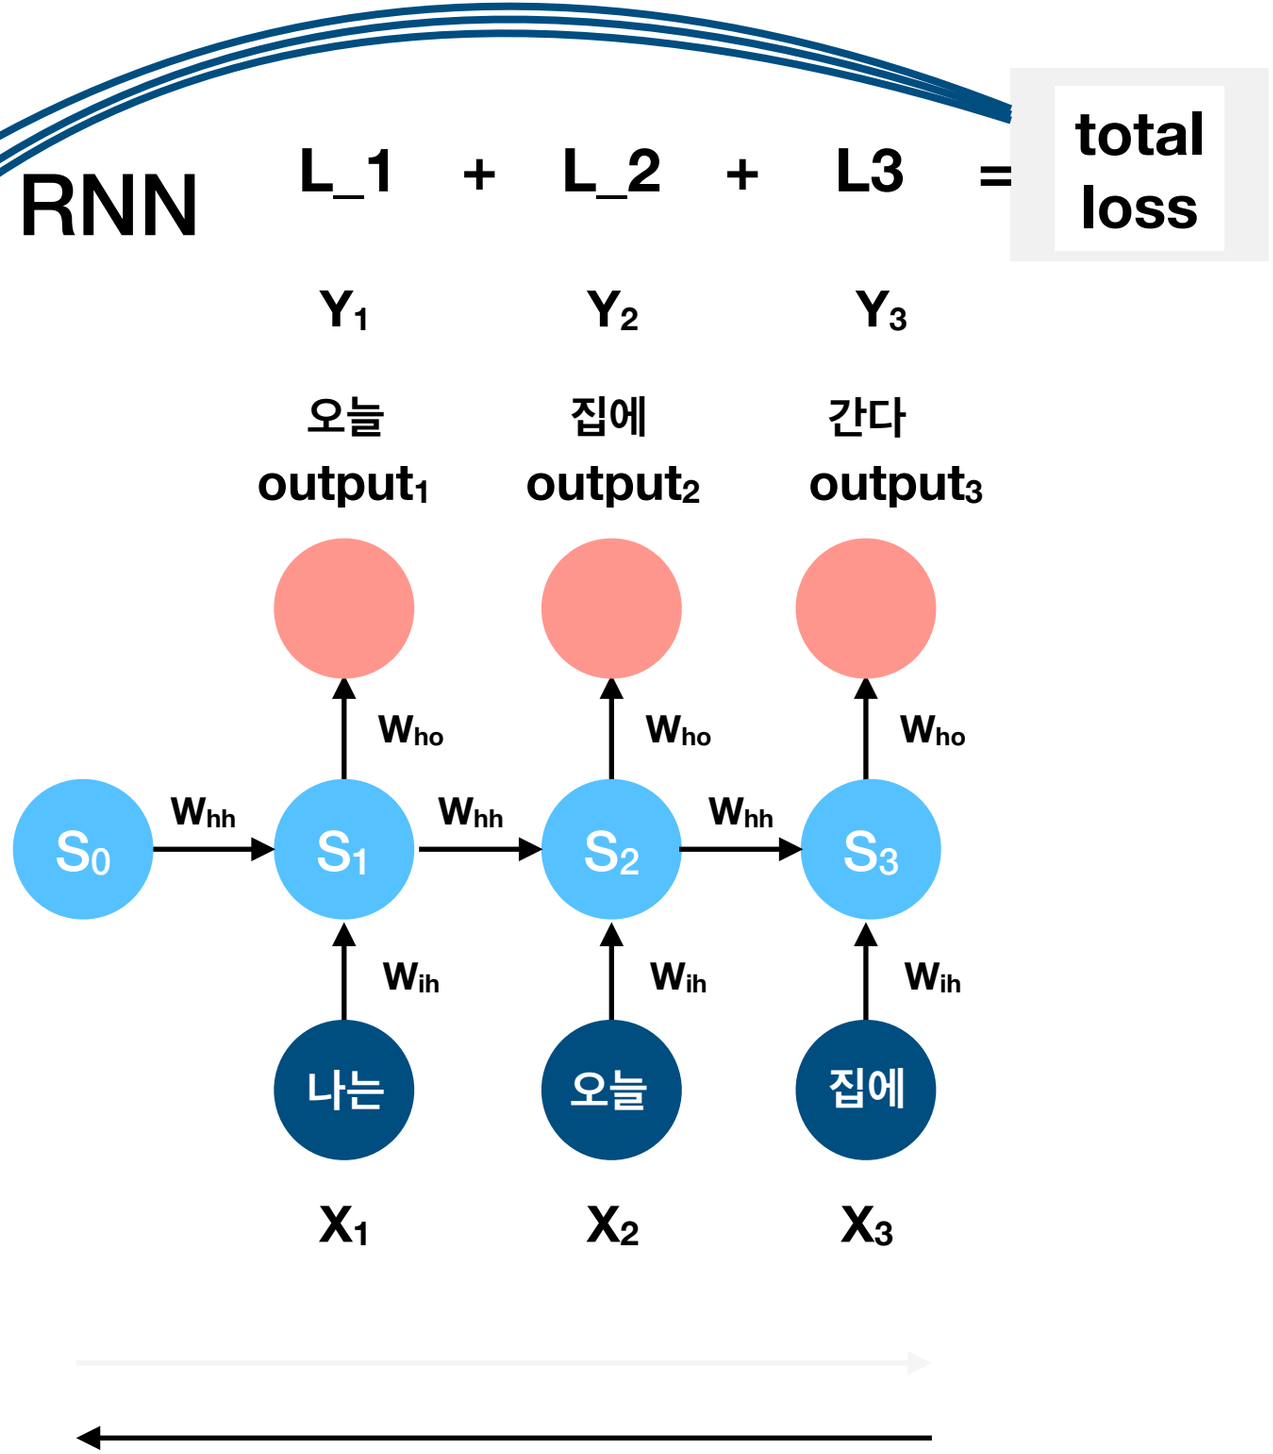

이 전체 loss를 최소화하는 방향으로, weight을 update 합니다.

RNN

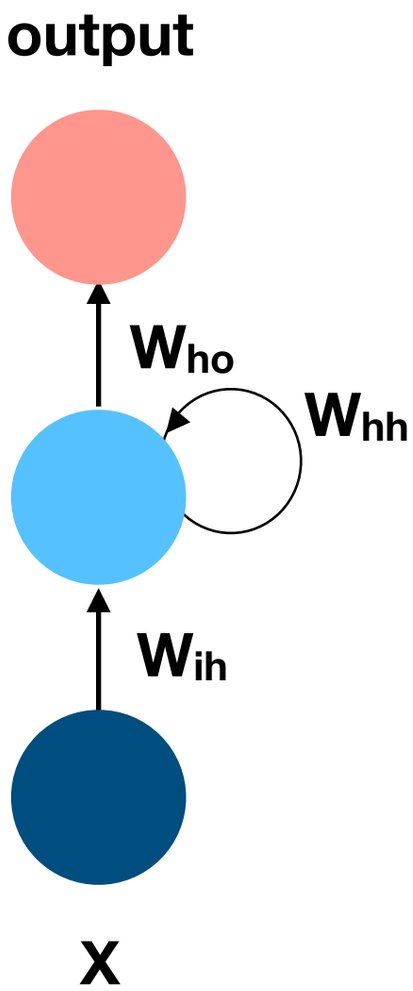

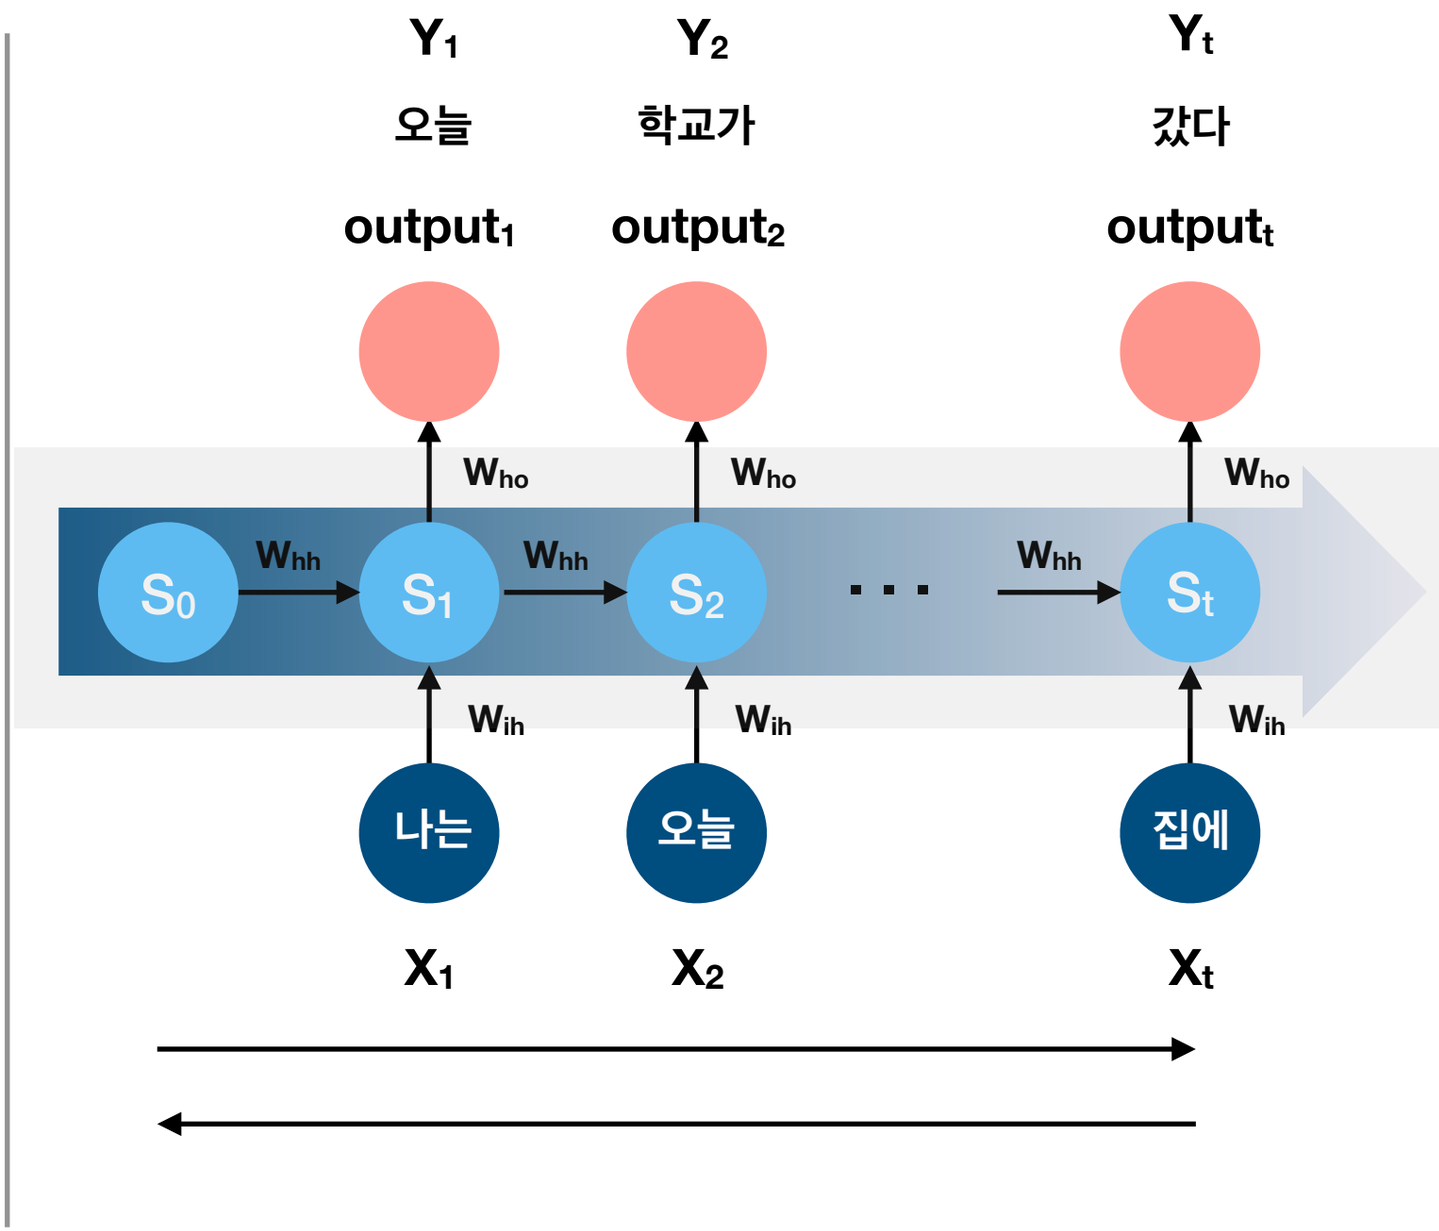

가장 기본적인 RNN은 훈련할 time step의 수가 많아졌을 때,
뒤쪽의 time step이 앞쪽 time step의 정보를 제대로 반영하지 못하는 한계가 있습니다.

RNN

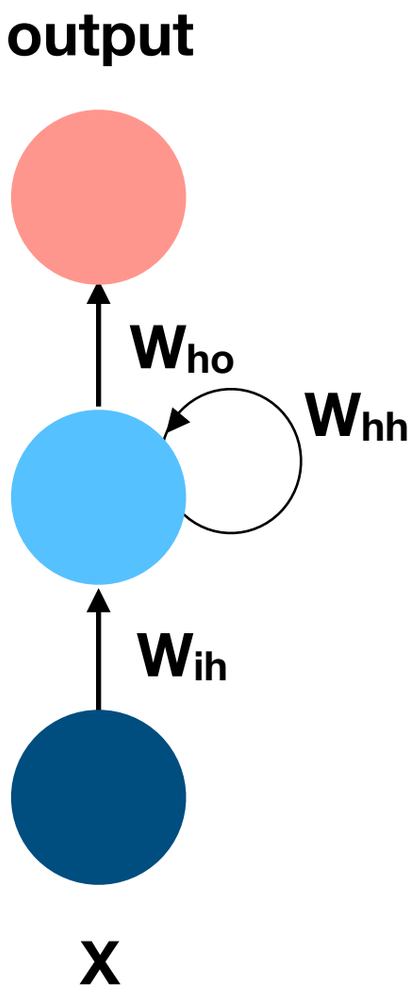

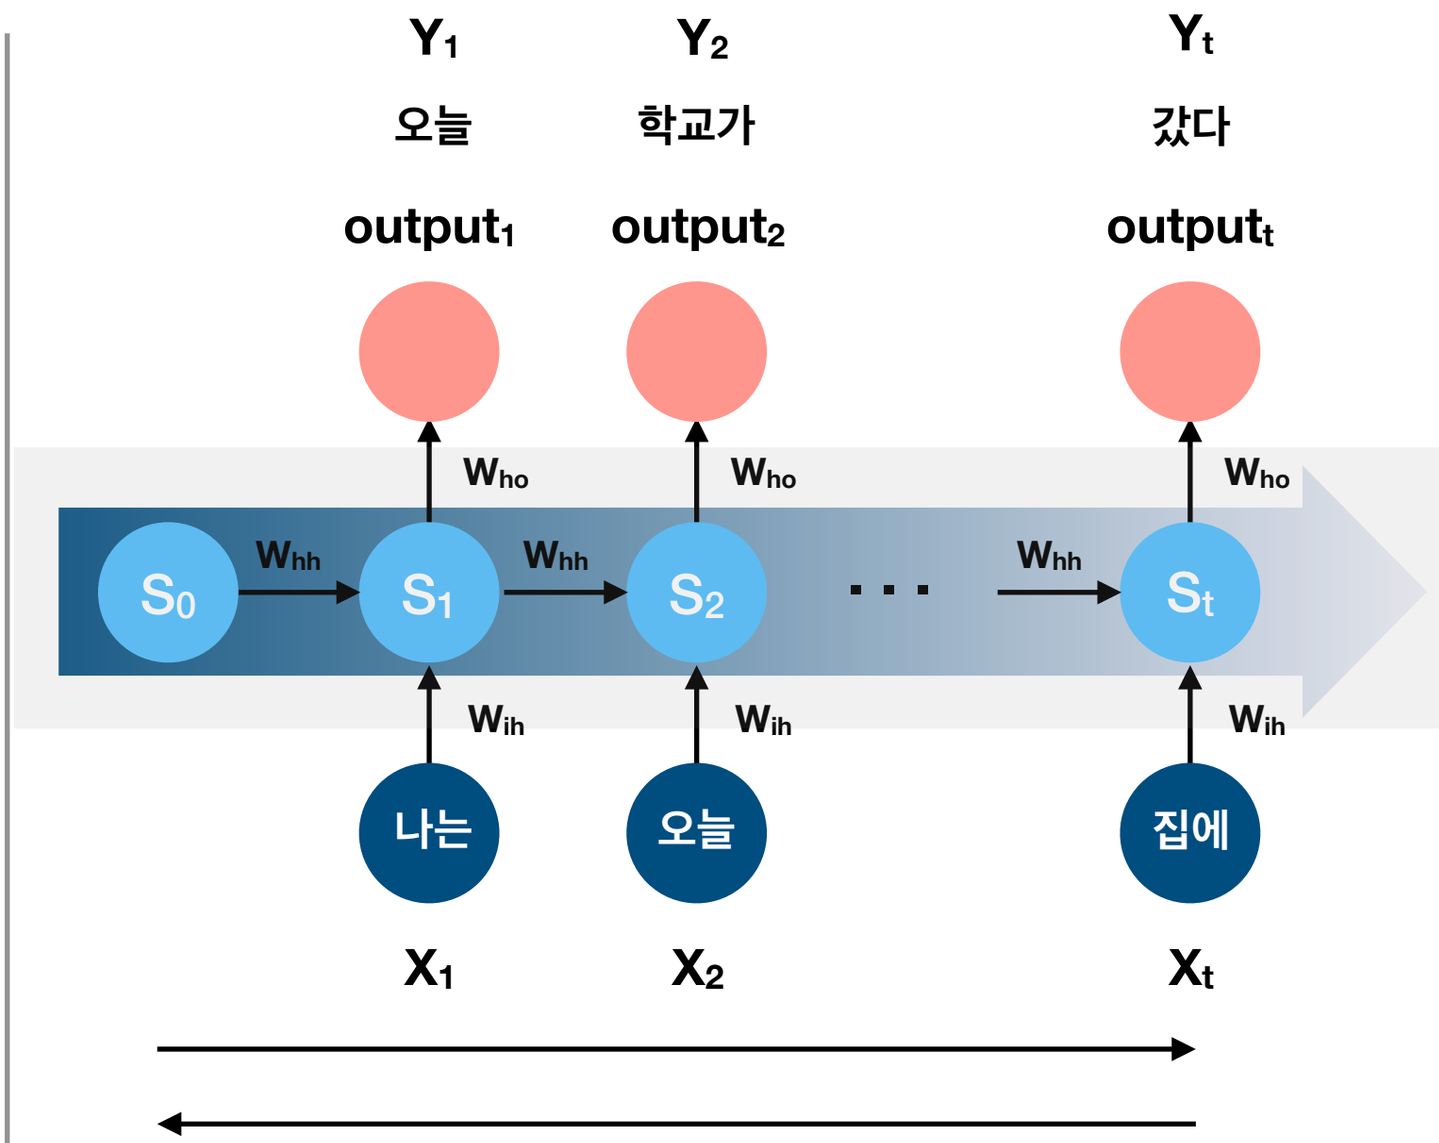

예를 들어, '나는 오늘 학교가 끝나고 서점에 들러 책을 산 후 집에 갔다'라는
11개의 time step으로 이루어진 문장을 훈련할 때
마지막 11번째 time step의 hidden node S_{11}은
첫 번째 time step의 input인 '나는'에 대한 정보를 거의 갖고 있지 않습니다.

RNN

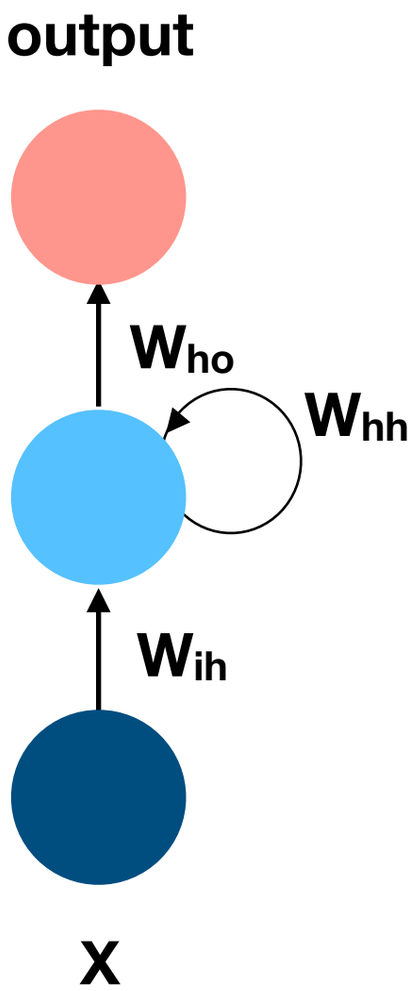

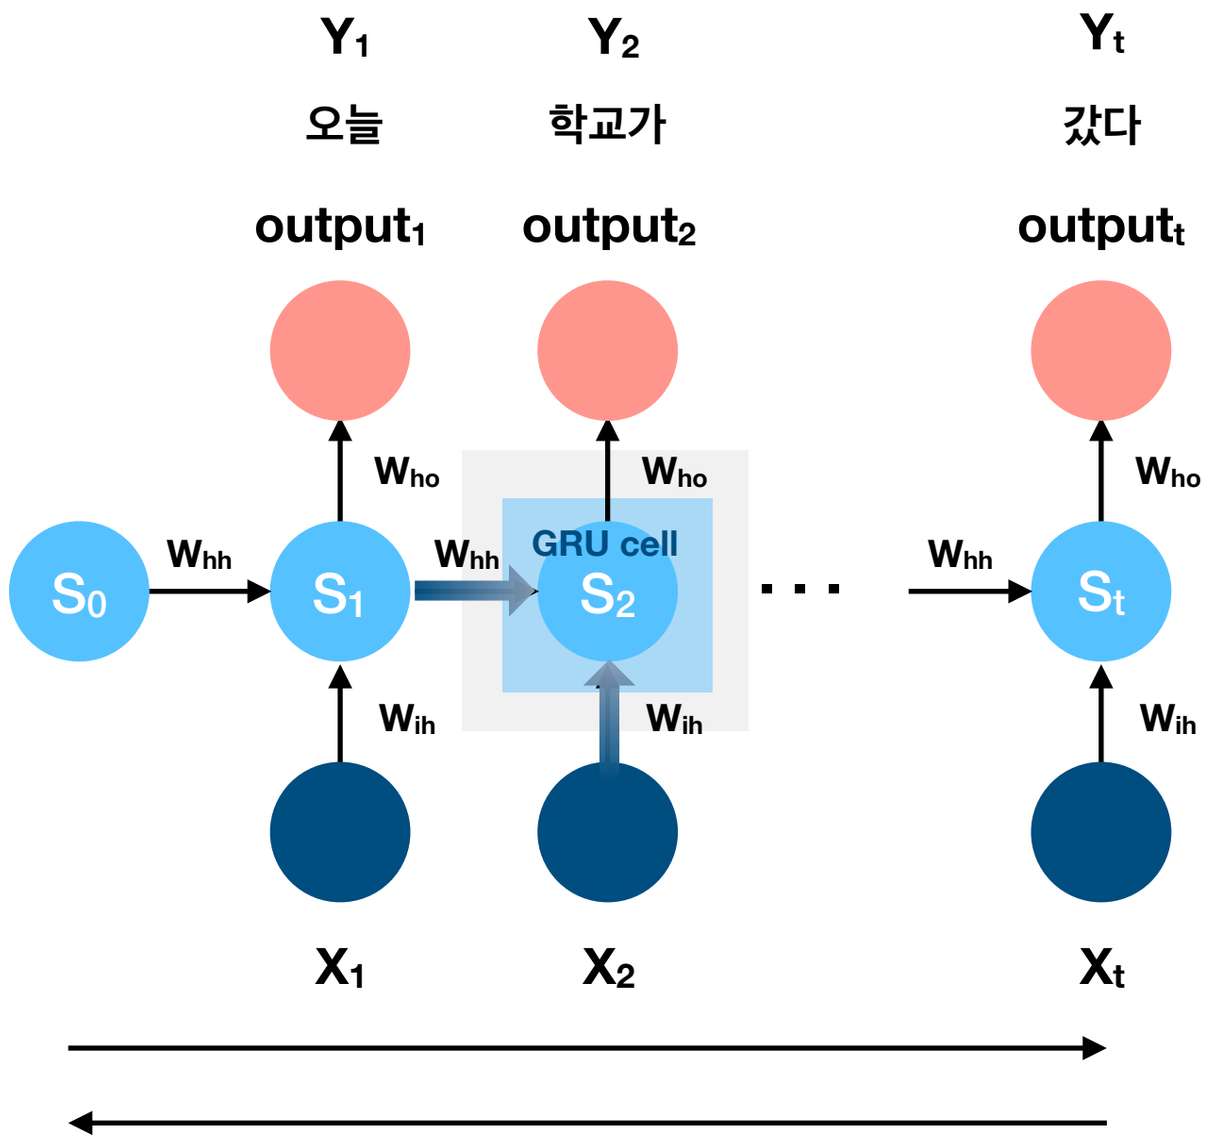

따라서 hidden layer가 이전 time step의 정보를 보다 효율적으로
기억할 수 있도록 하는 방법이 고안되었습니다.

Appendix: GRU cell

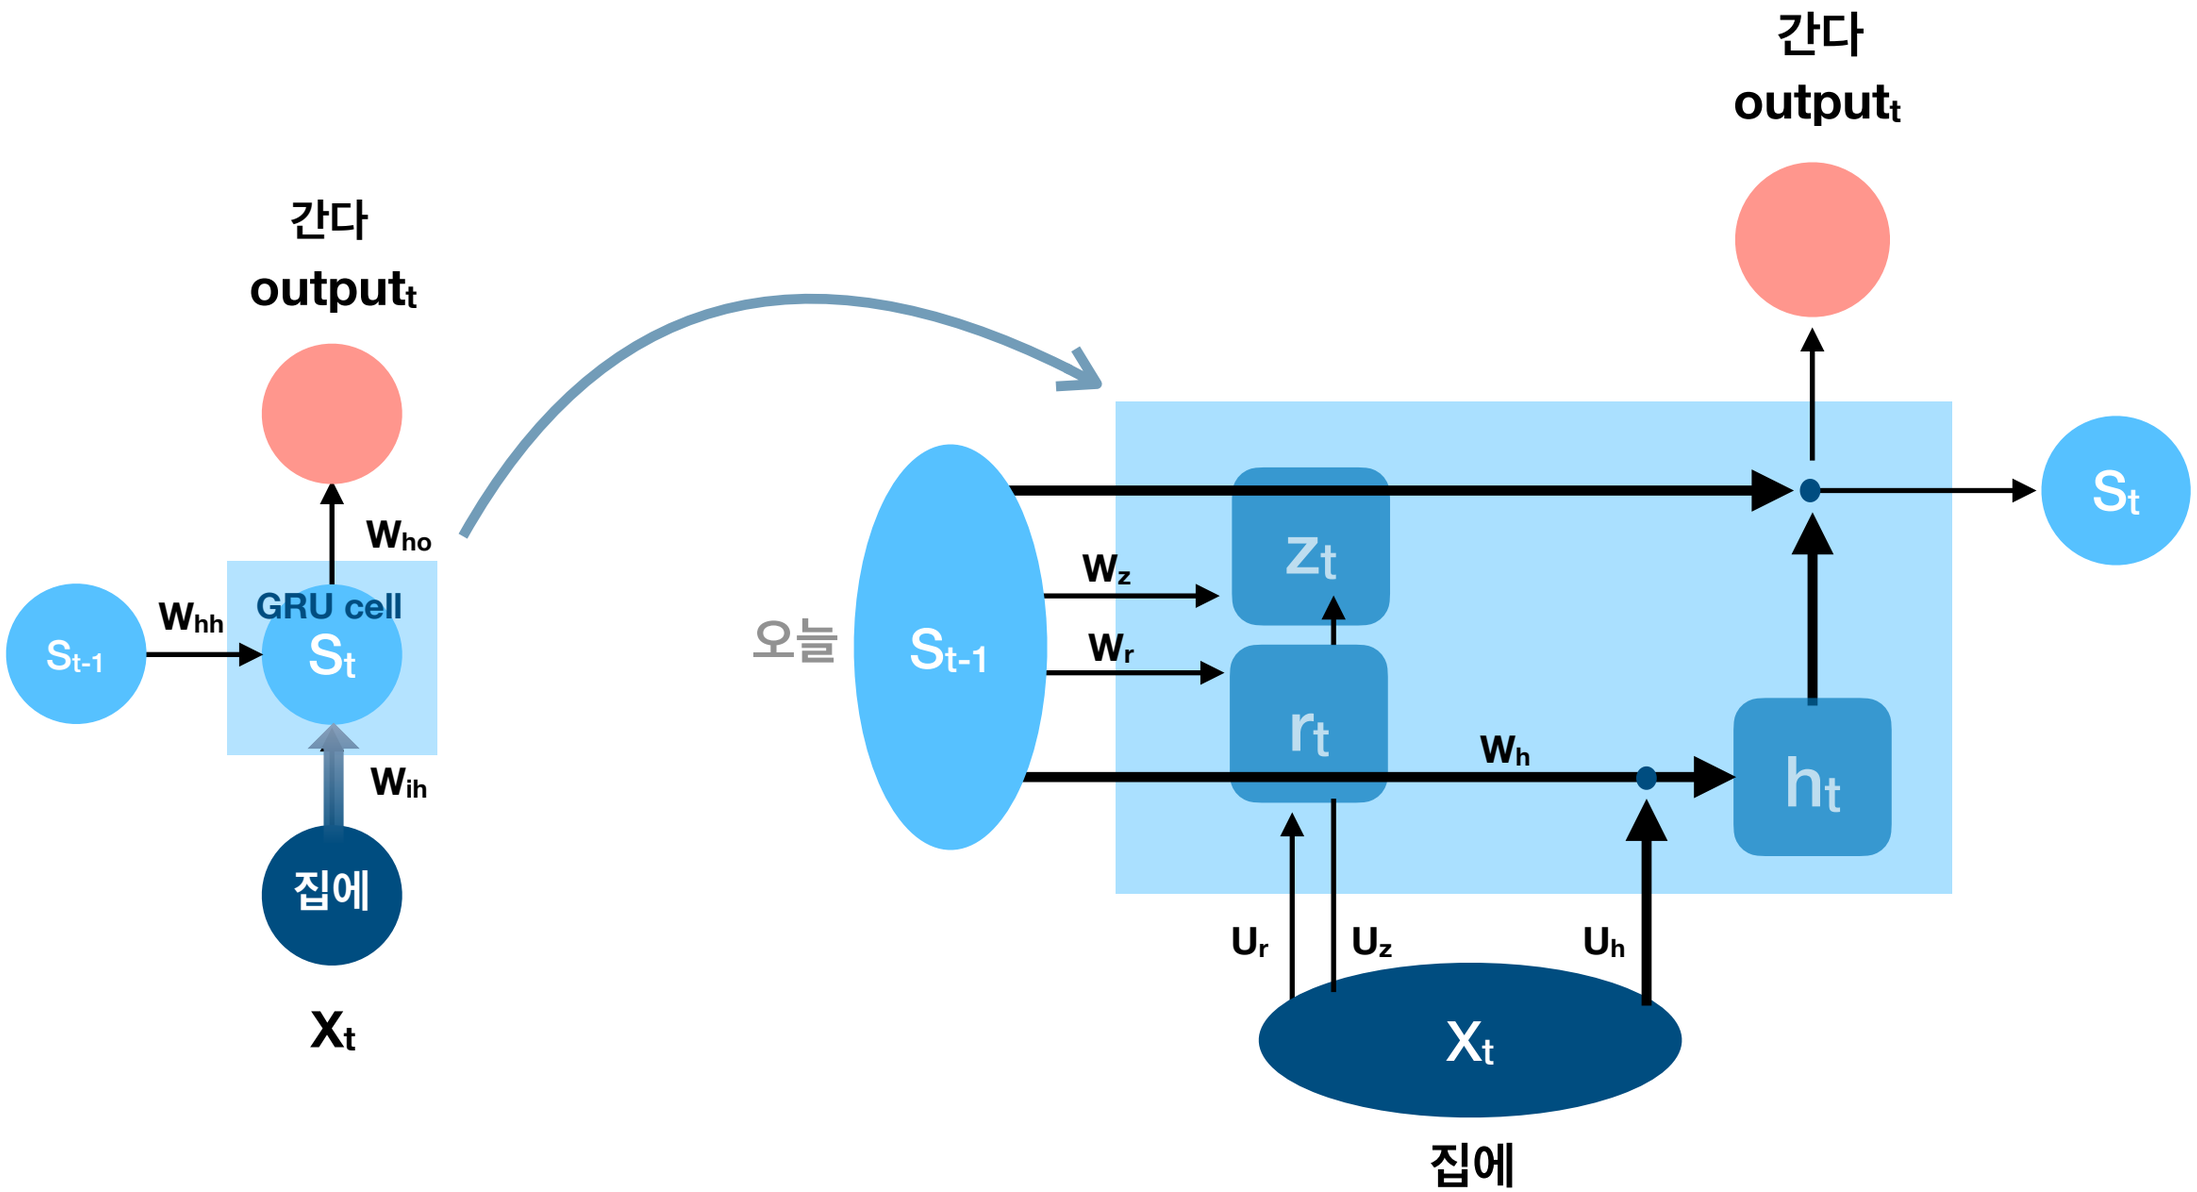

GRU cell은 쉽게 말해 hidden layer에 함수를 여러 개 만들고 함수들 간의 적절한 비율을 정하는 것입니다.

Appendix: GRU cell

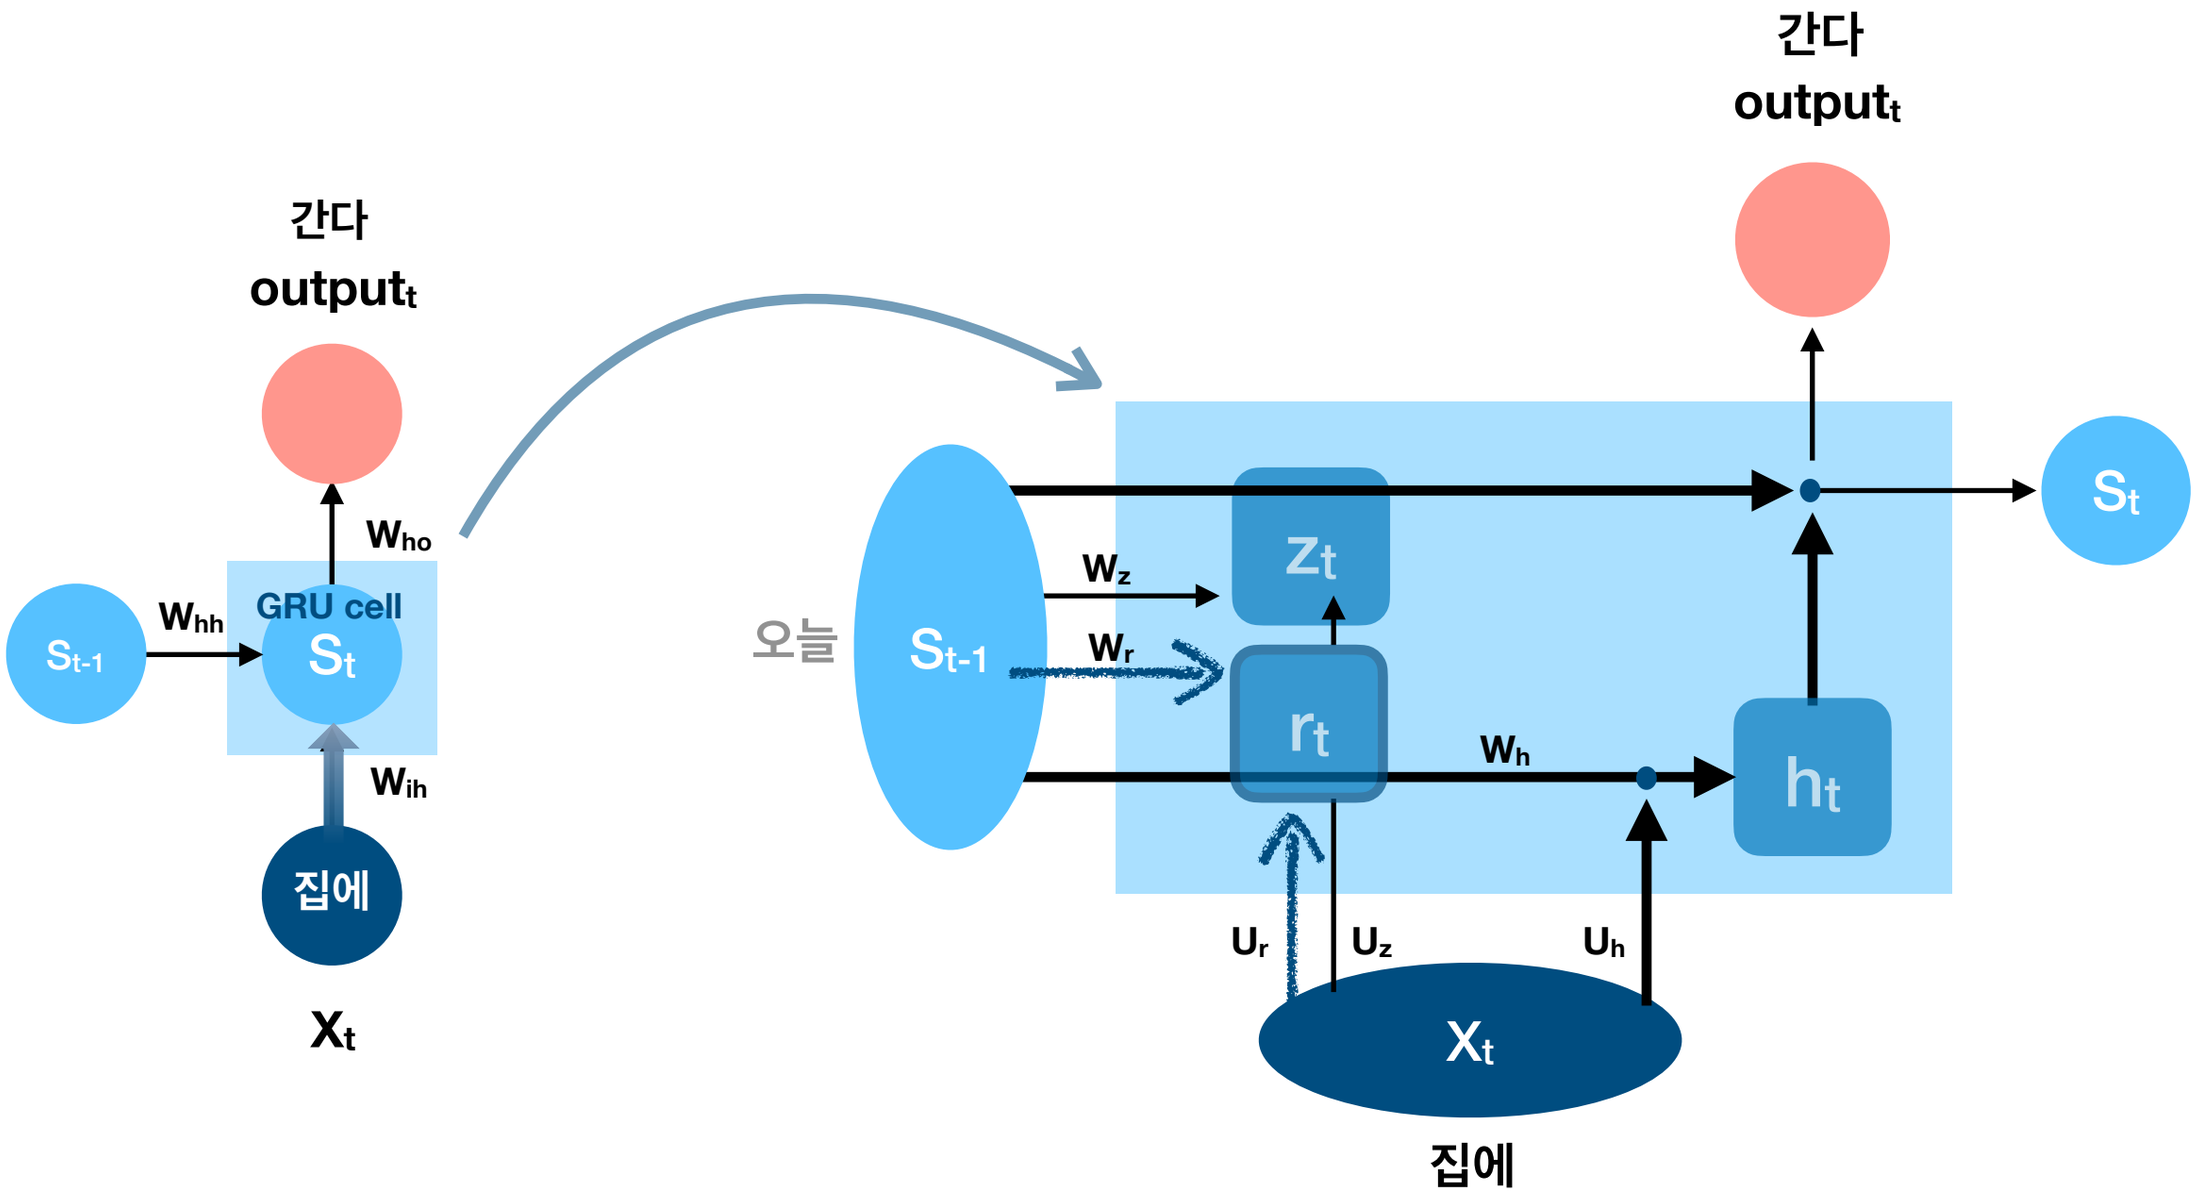

먼저 r_t라는 함수를 만듭니다.
이건 현재 input X_t와 이전 hidden activation S_{t-1}을 넣어준 것입니다.

Appendix: GRU cell

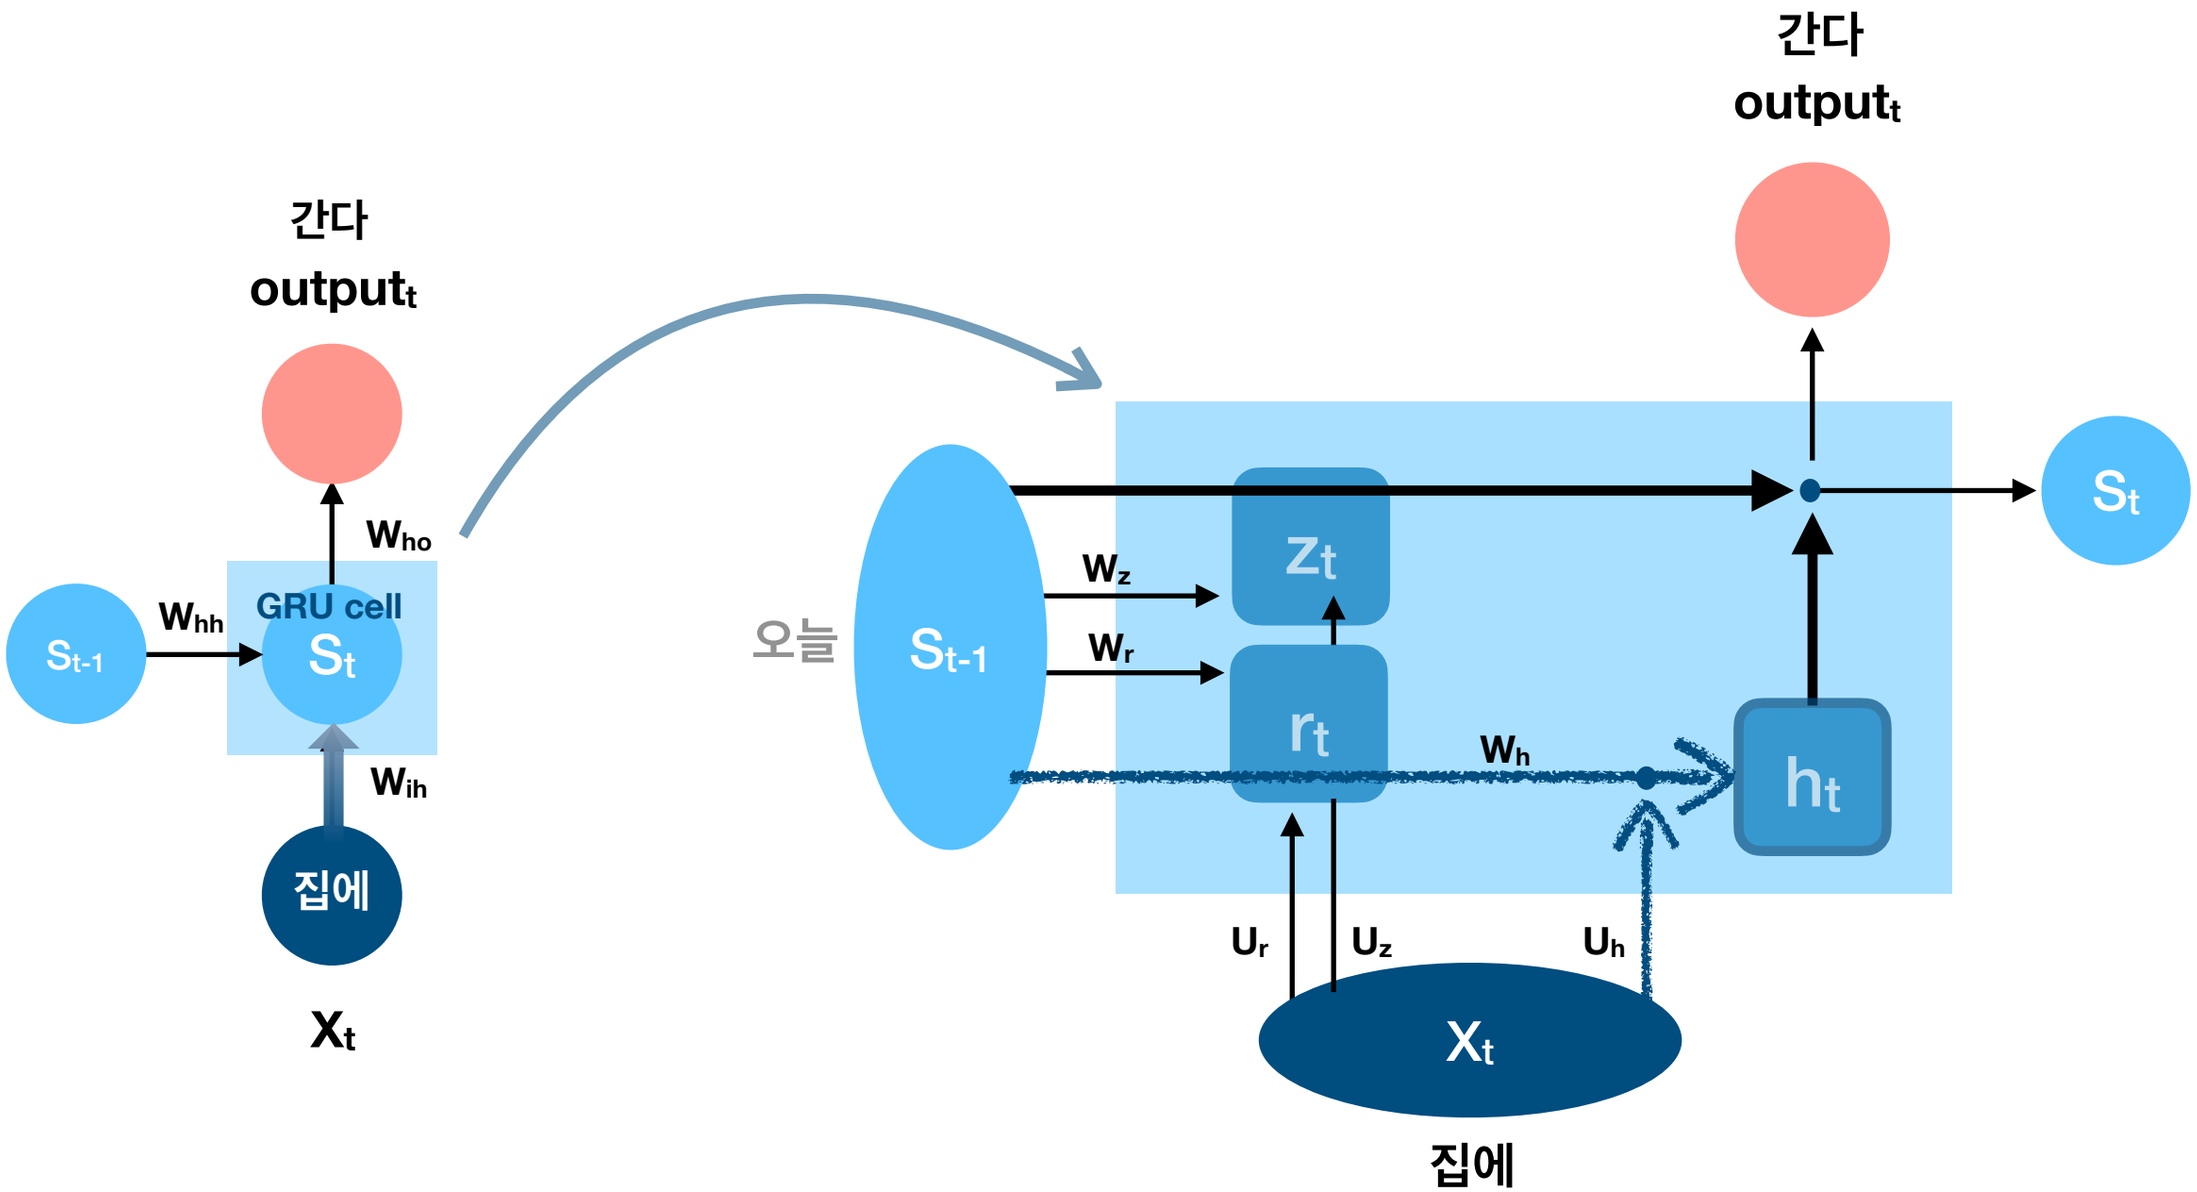

h_t라는 함수에는 r_t, S_{t-1}, X_t가 모두 영향을 줍니다. S_{t-1}이 r_t와 곱해진 다음 X_t가 더해집니다.

Appendix: GRU cell

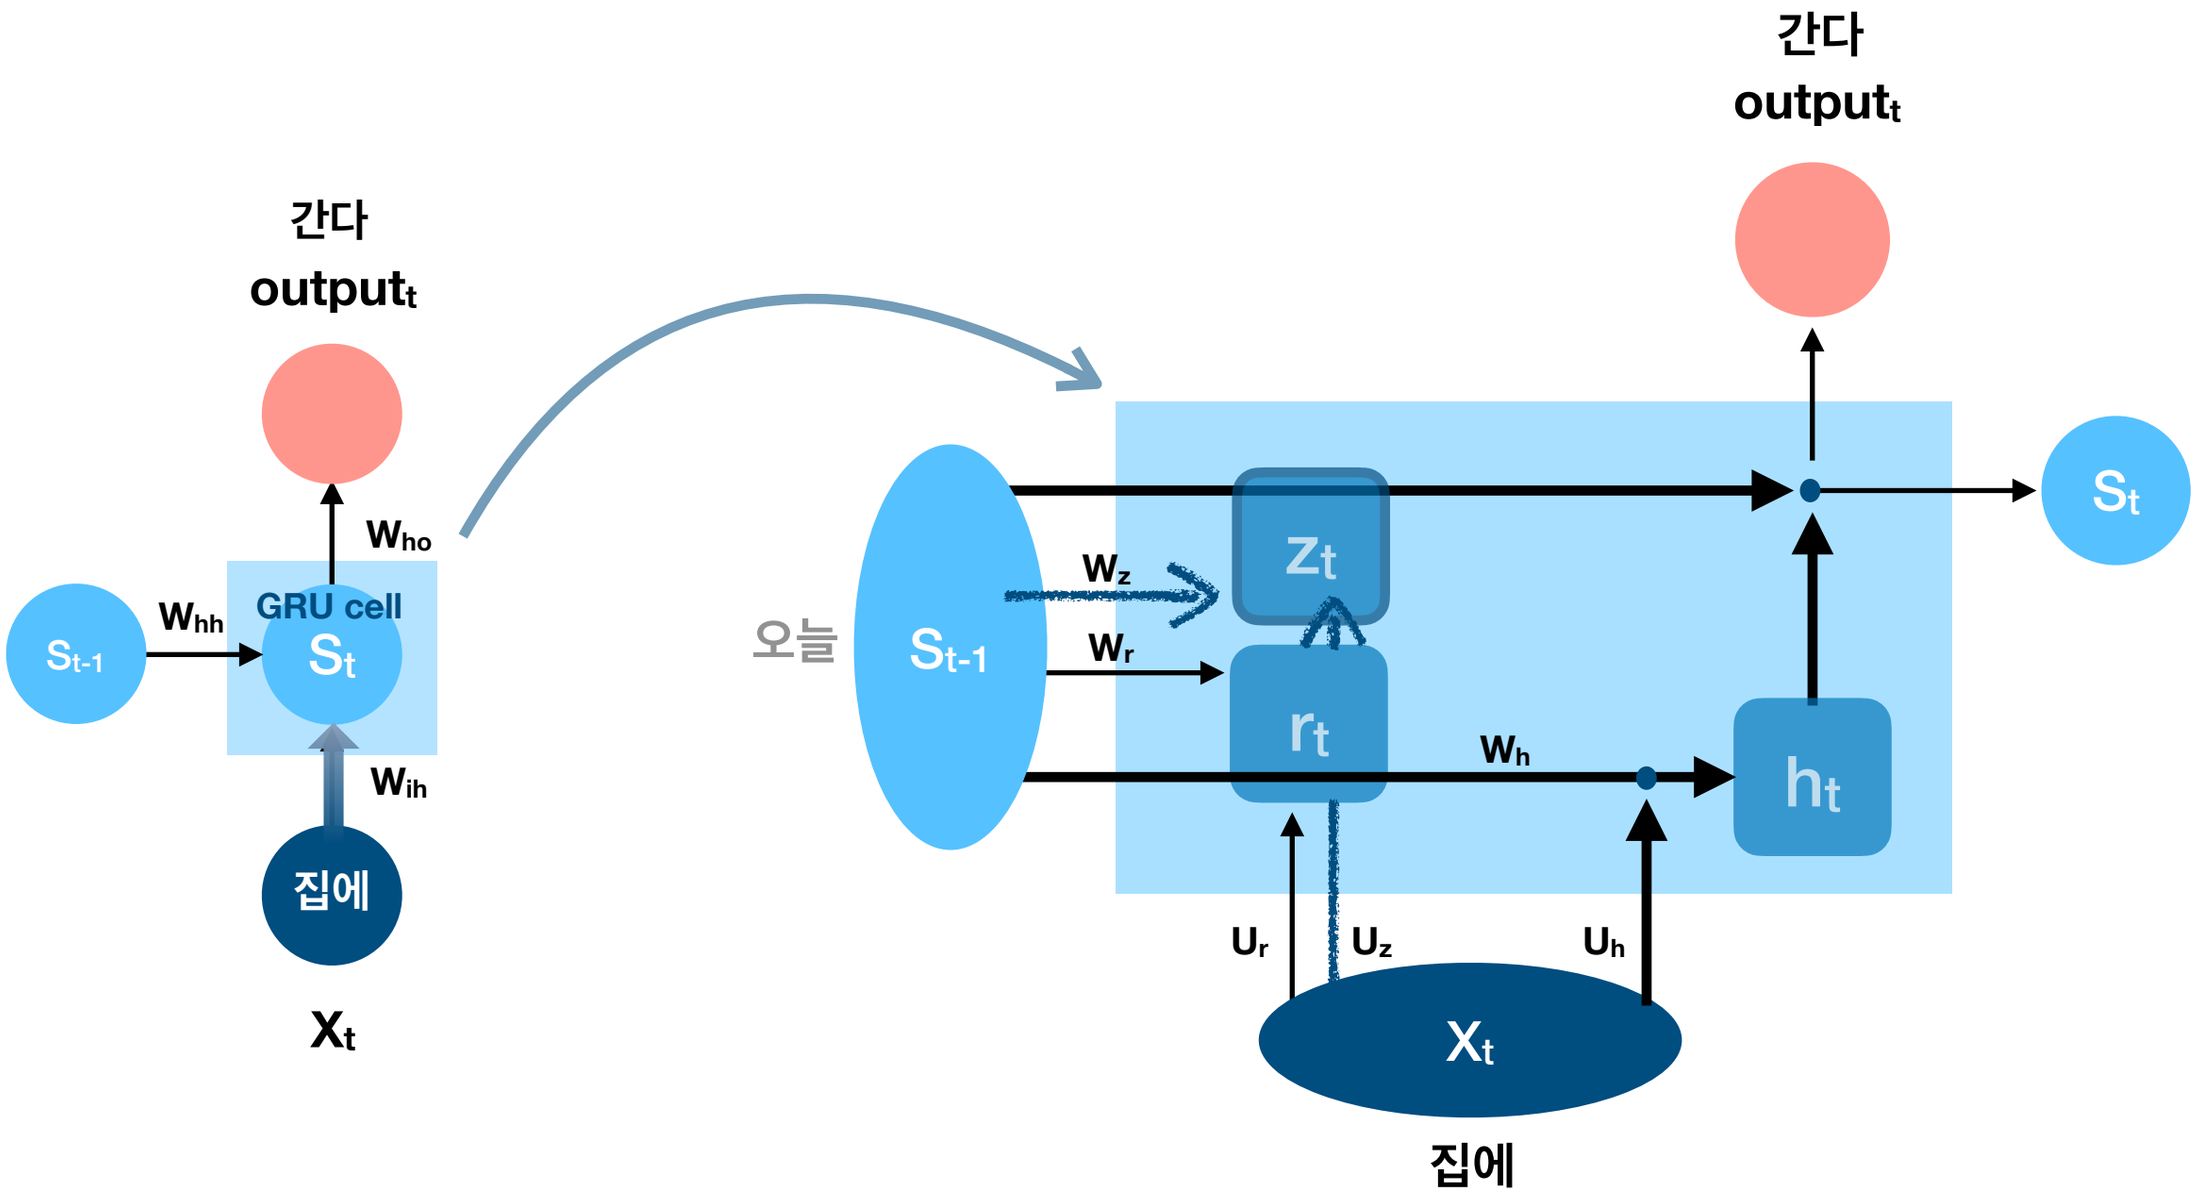

z_t라는 함수에는 S_{t-1} 그리고 X_t가 모두 영향을 줍니다.

Appendix: GRU cell

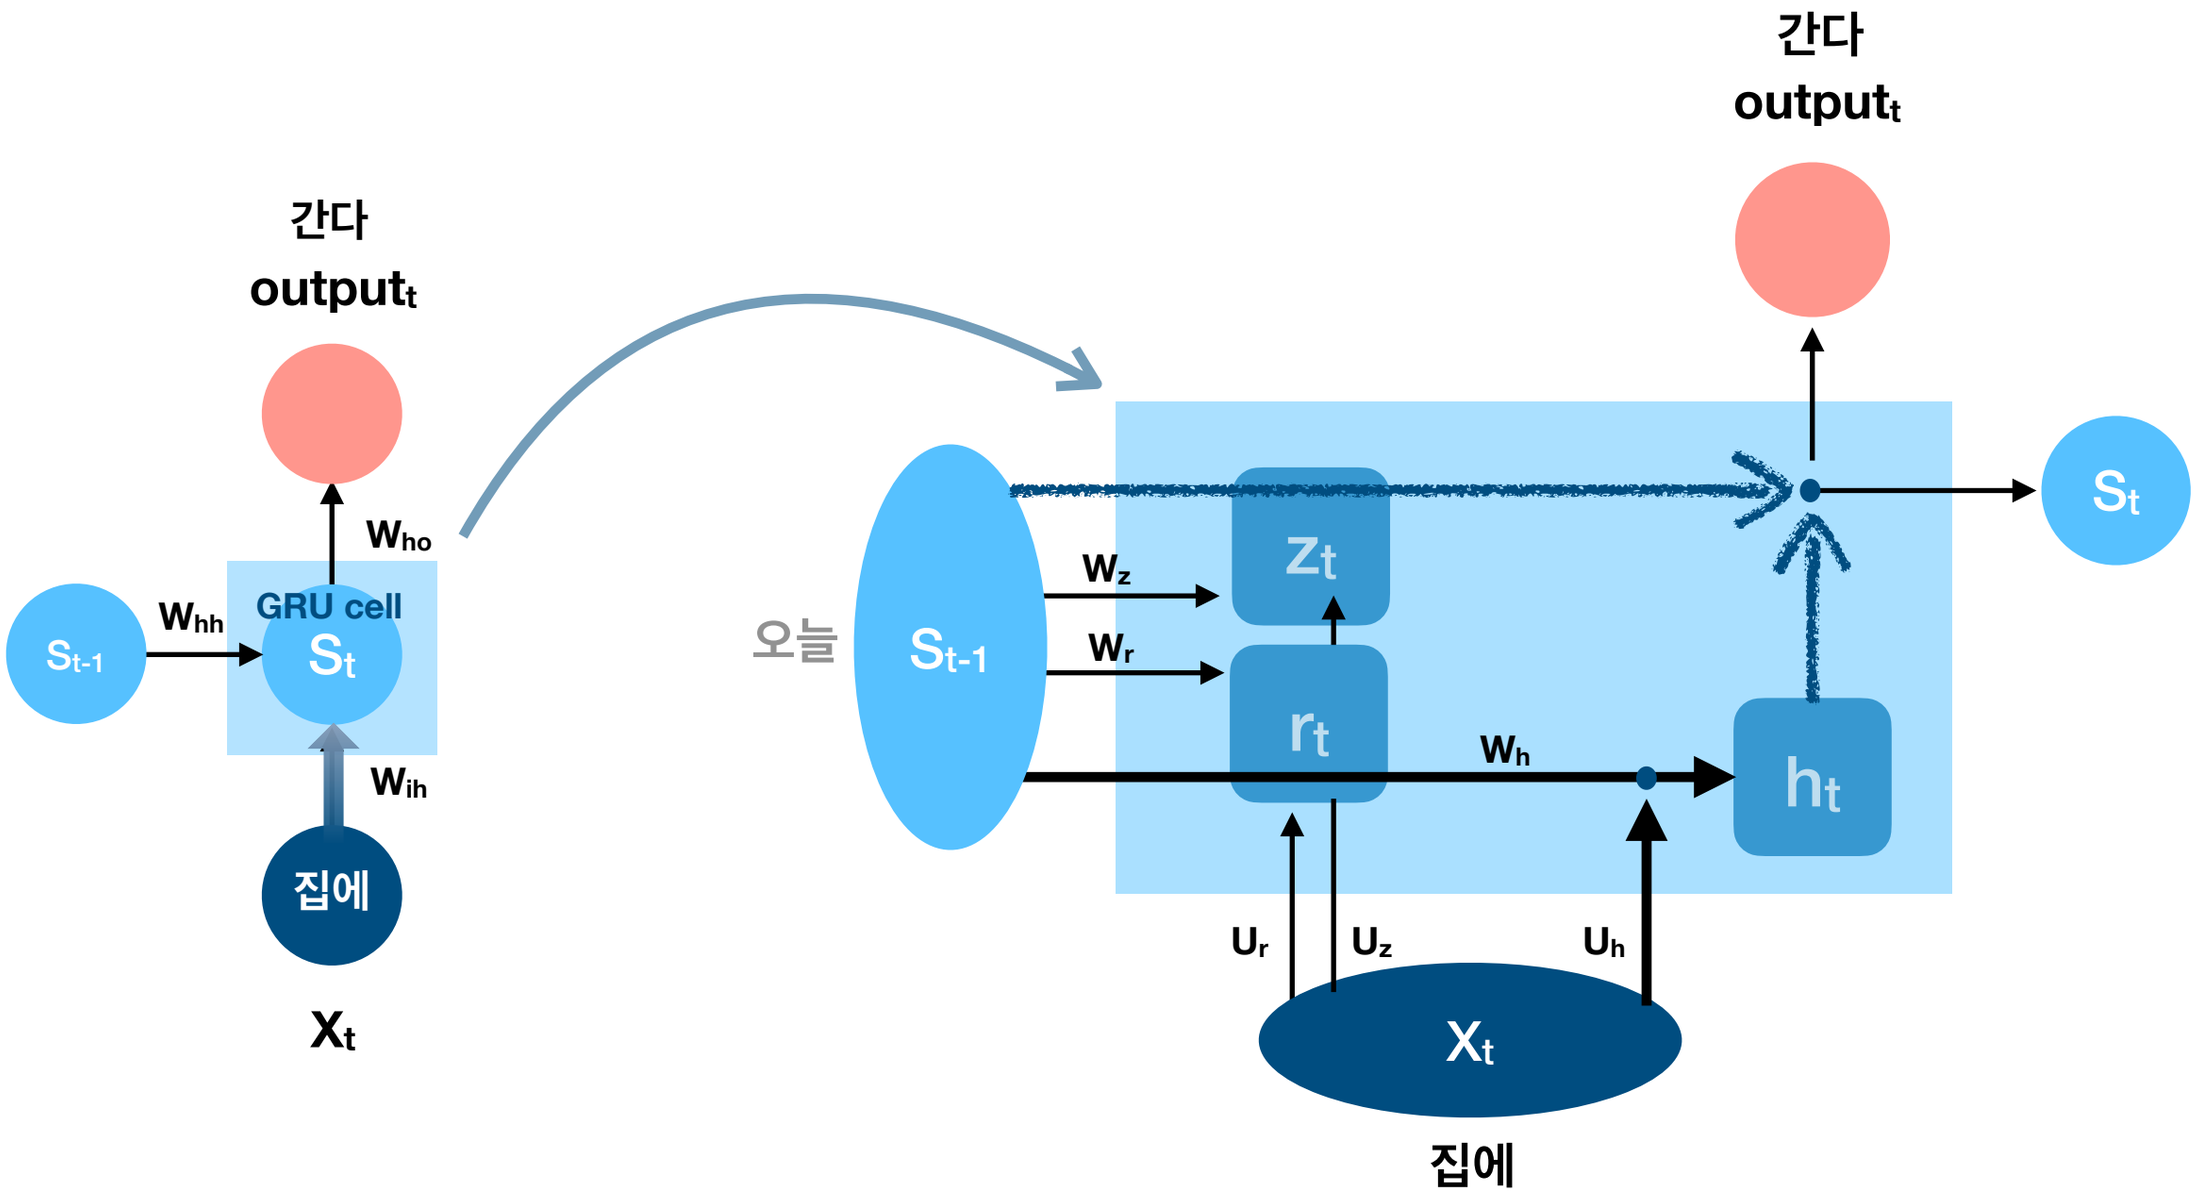

GRU cell에서 최종적으로 나오는 S_t에는 S_{t-1}, z_t, h_t가 모두 영향을 줍니다.

Appendix: GRU cell

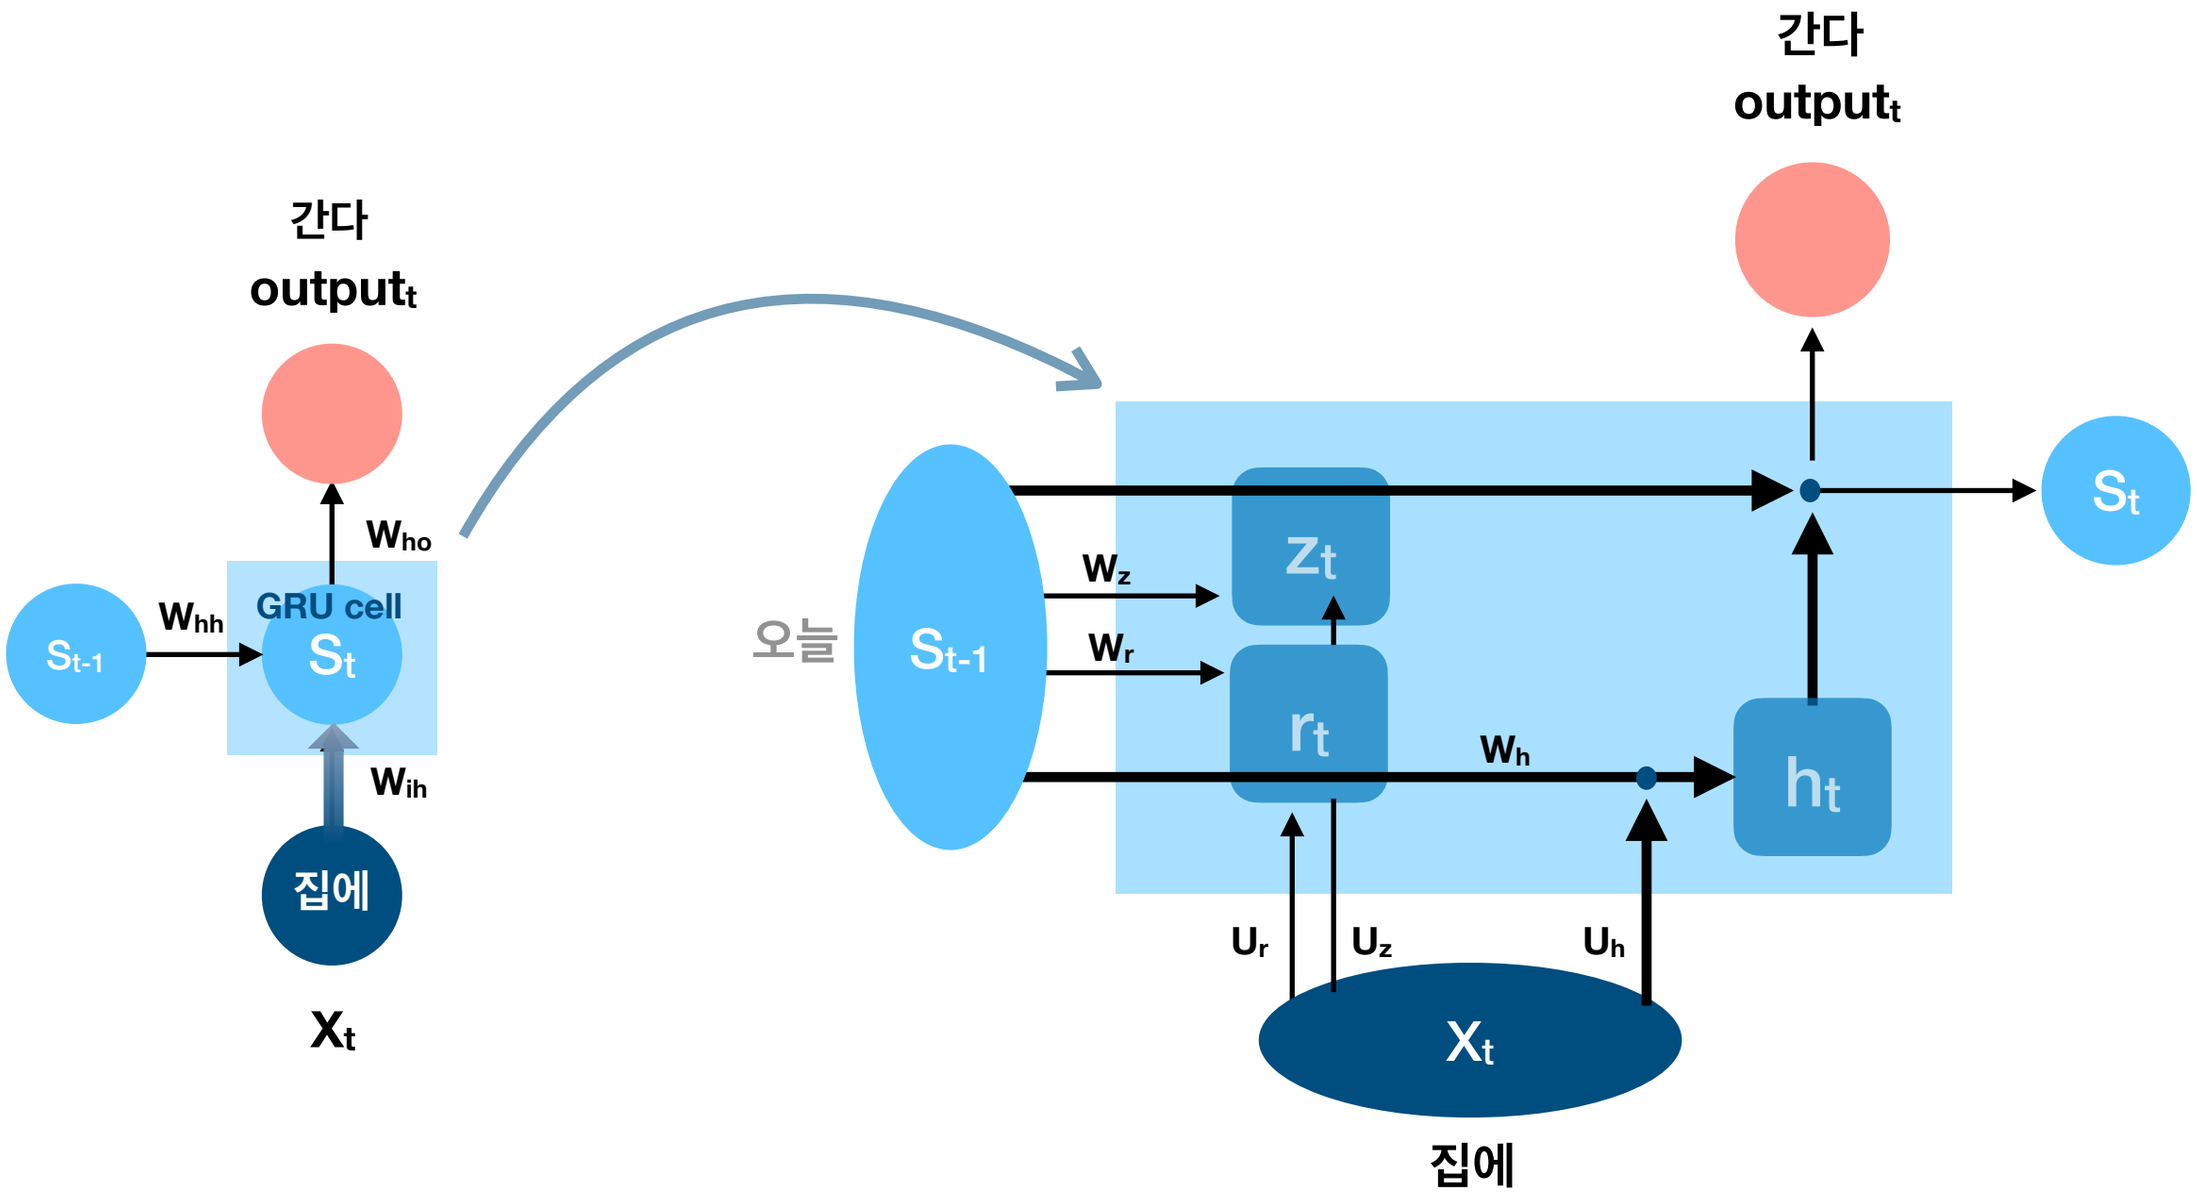

즉, hidden layer를 조금 더 복잡하게 만들어서
RNN이 이전 time step의 정보를 더 잘 기억하게 해주는 것이 GRU cell입니다.
(S_{t-1}에서 단순히 S_t로 가는게 아니라 조금 더 세련된 방법으로 가자는 것)

Appendix: multi-layer RNN

hidden layer가 2개 이상인 RNN

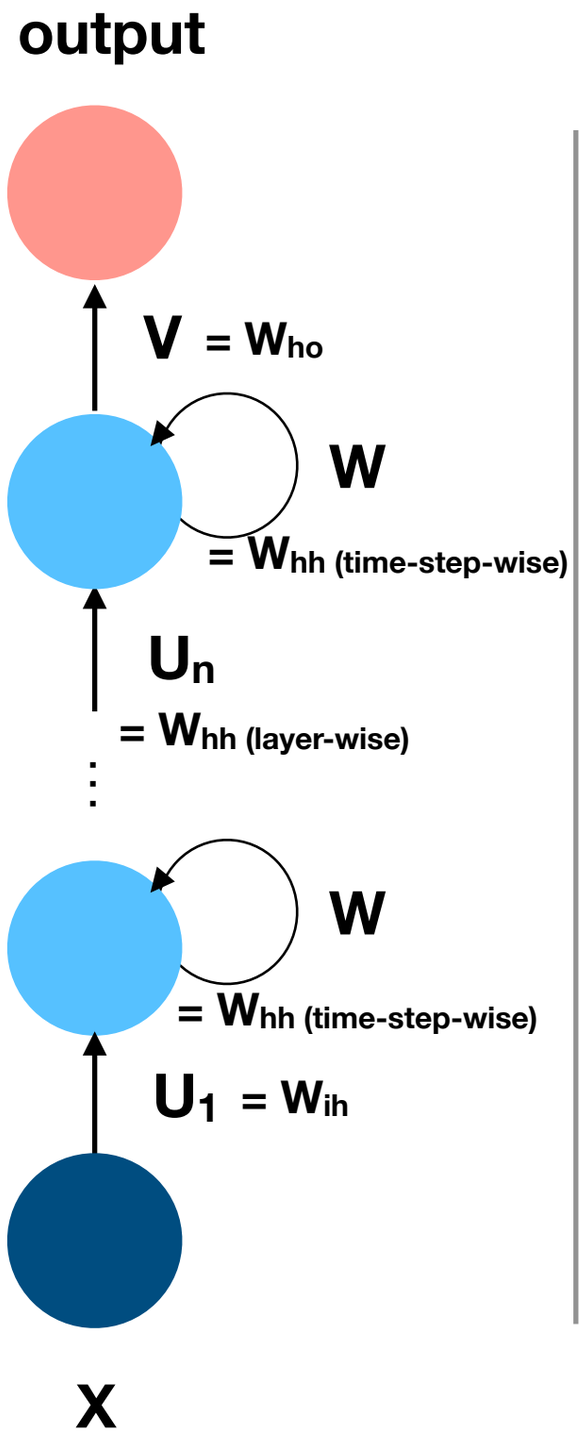

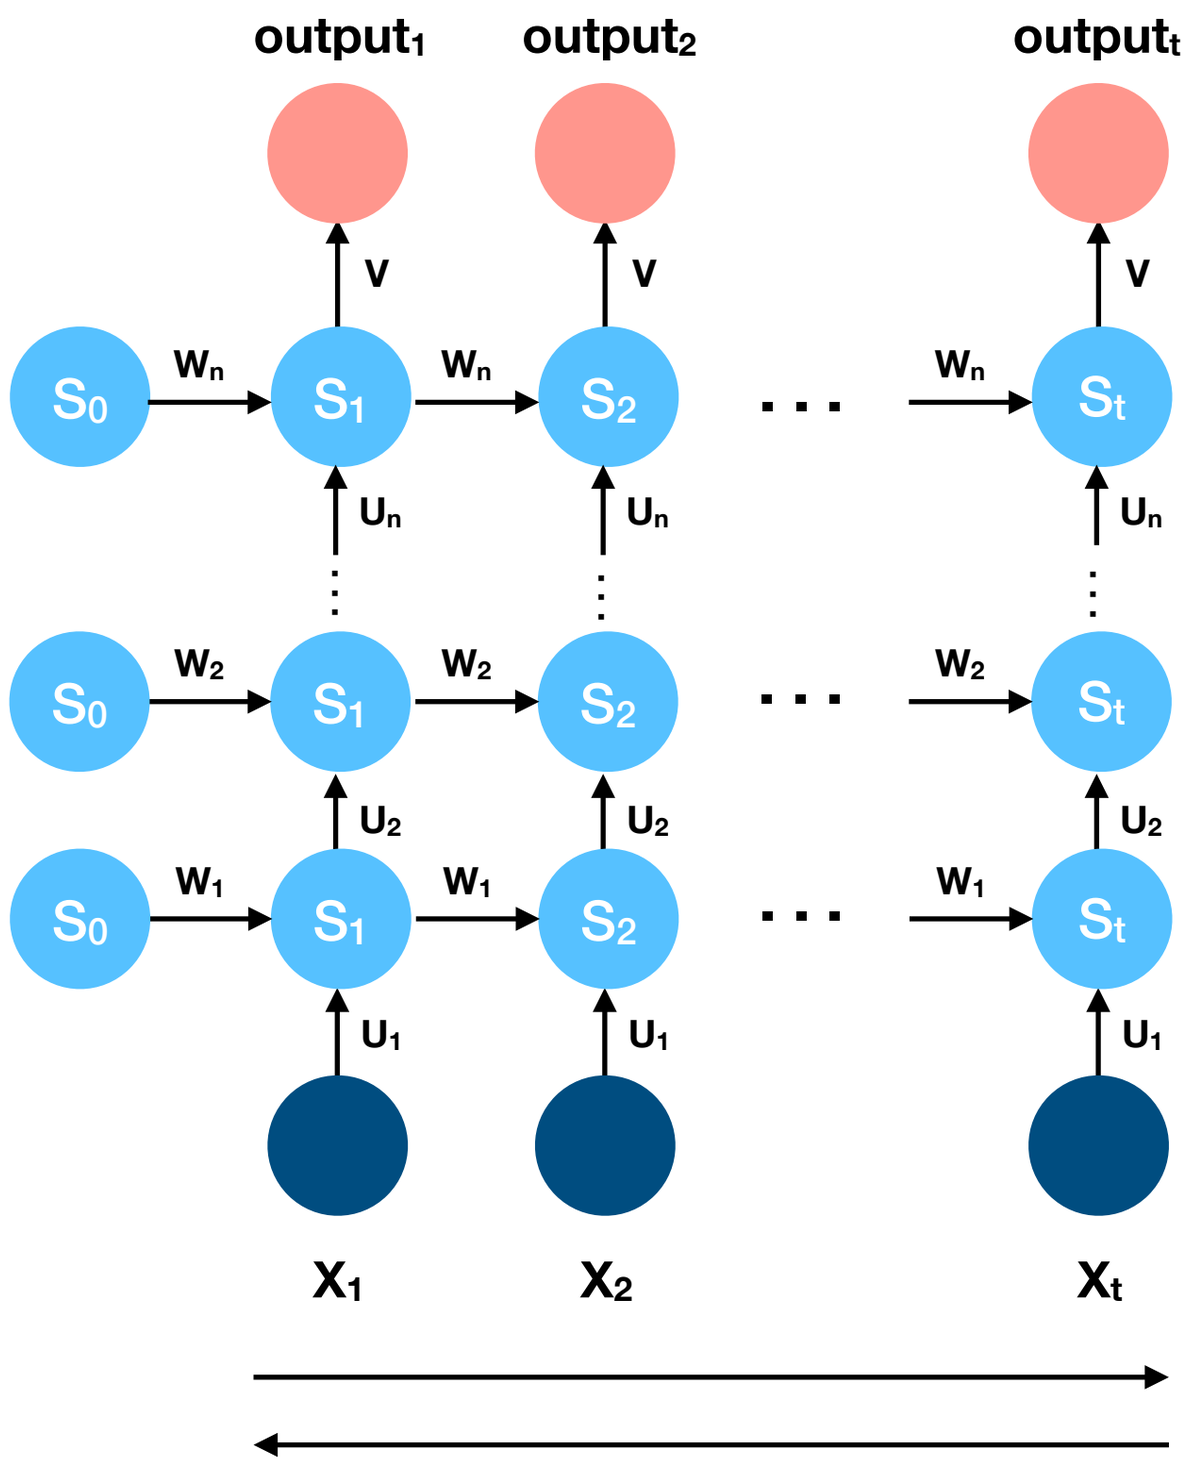

SEQ2SEQ

SEQ2SEQ

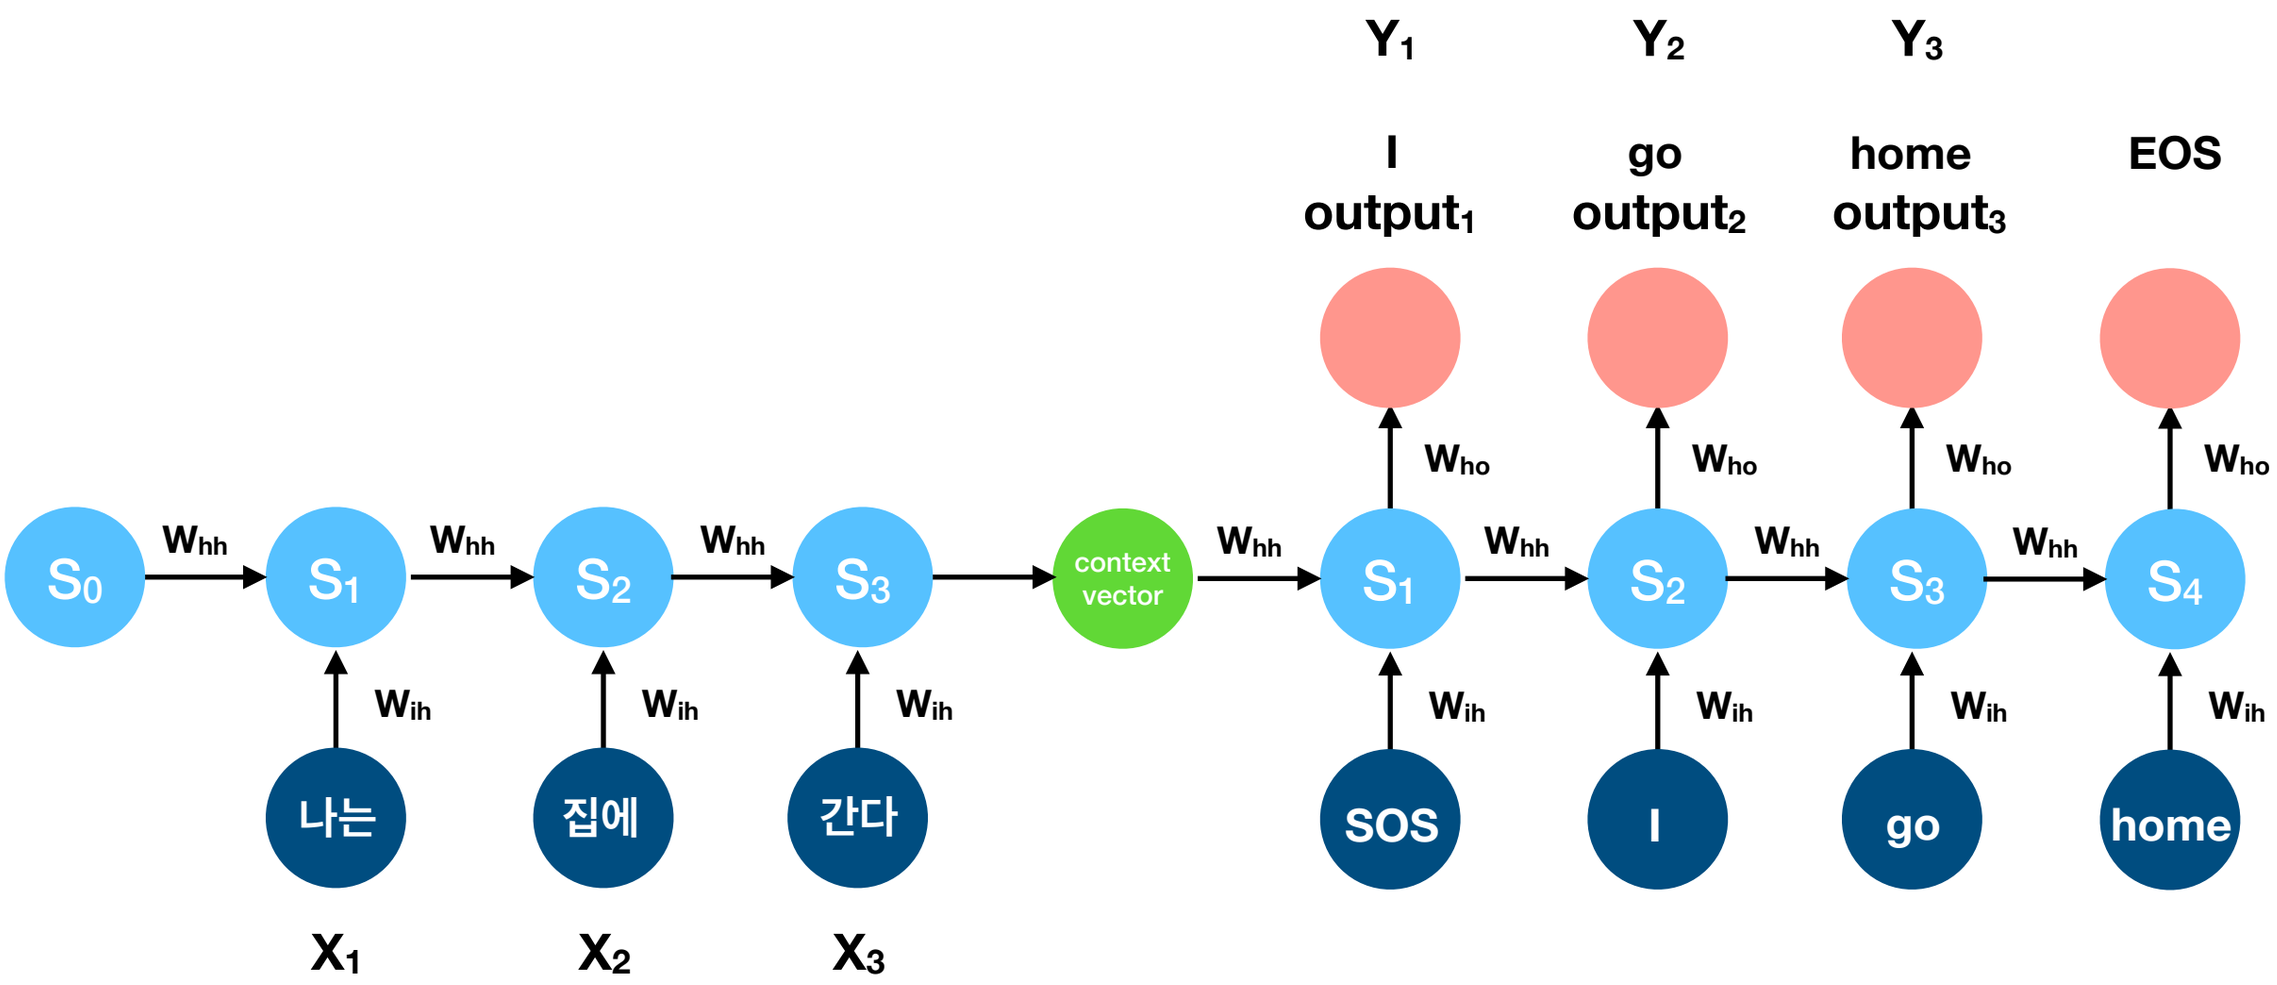
Y1
Y2
Y3
I
go
home
EOS
output1
output2
output3
Who
Who
Who
Who
S0
Whh
S1
Whh
S2
Whh
S3
context vector
Whh
S1
Whh
S2
Whh
S3
Whh
S4
Wih
Wih
Wih
Wih
Wih
Wih
나는
집에
간다
SOS
I
go
home
X1
X2
X3

Transformer

SEQ2SEQ

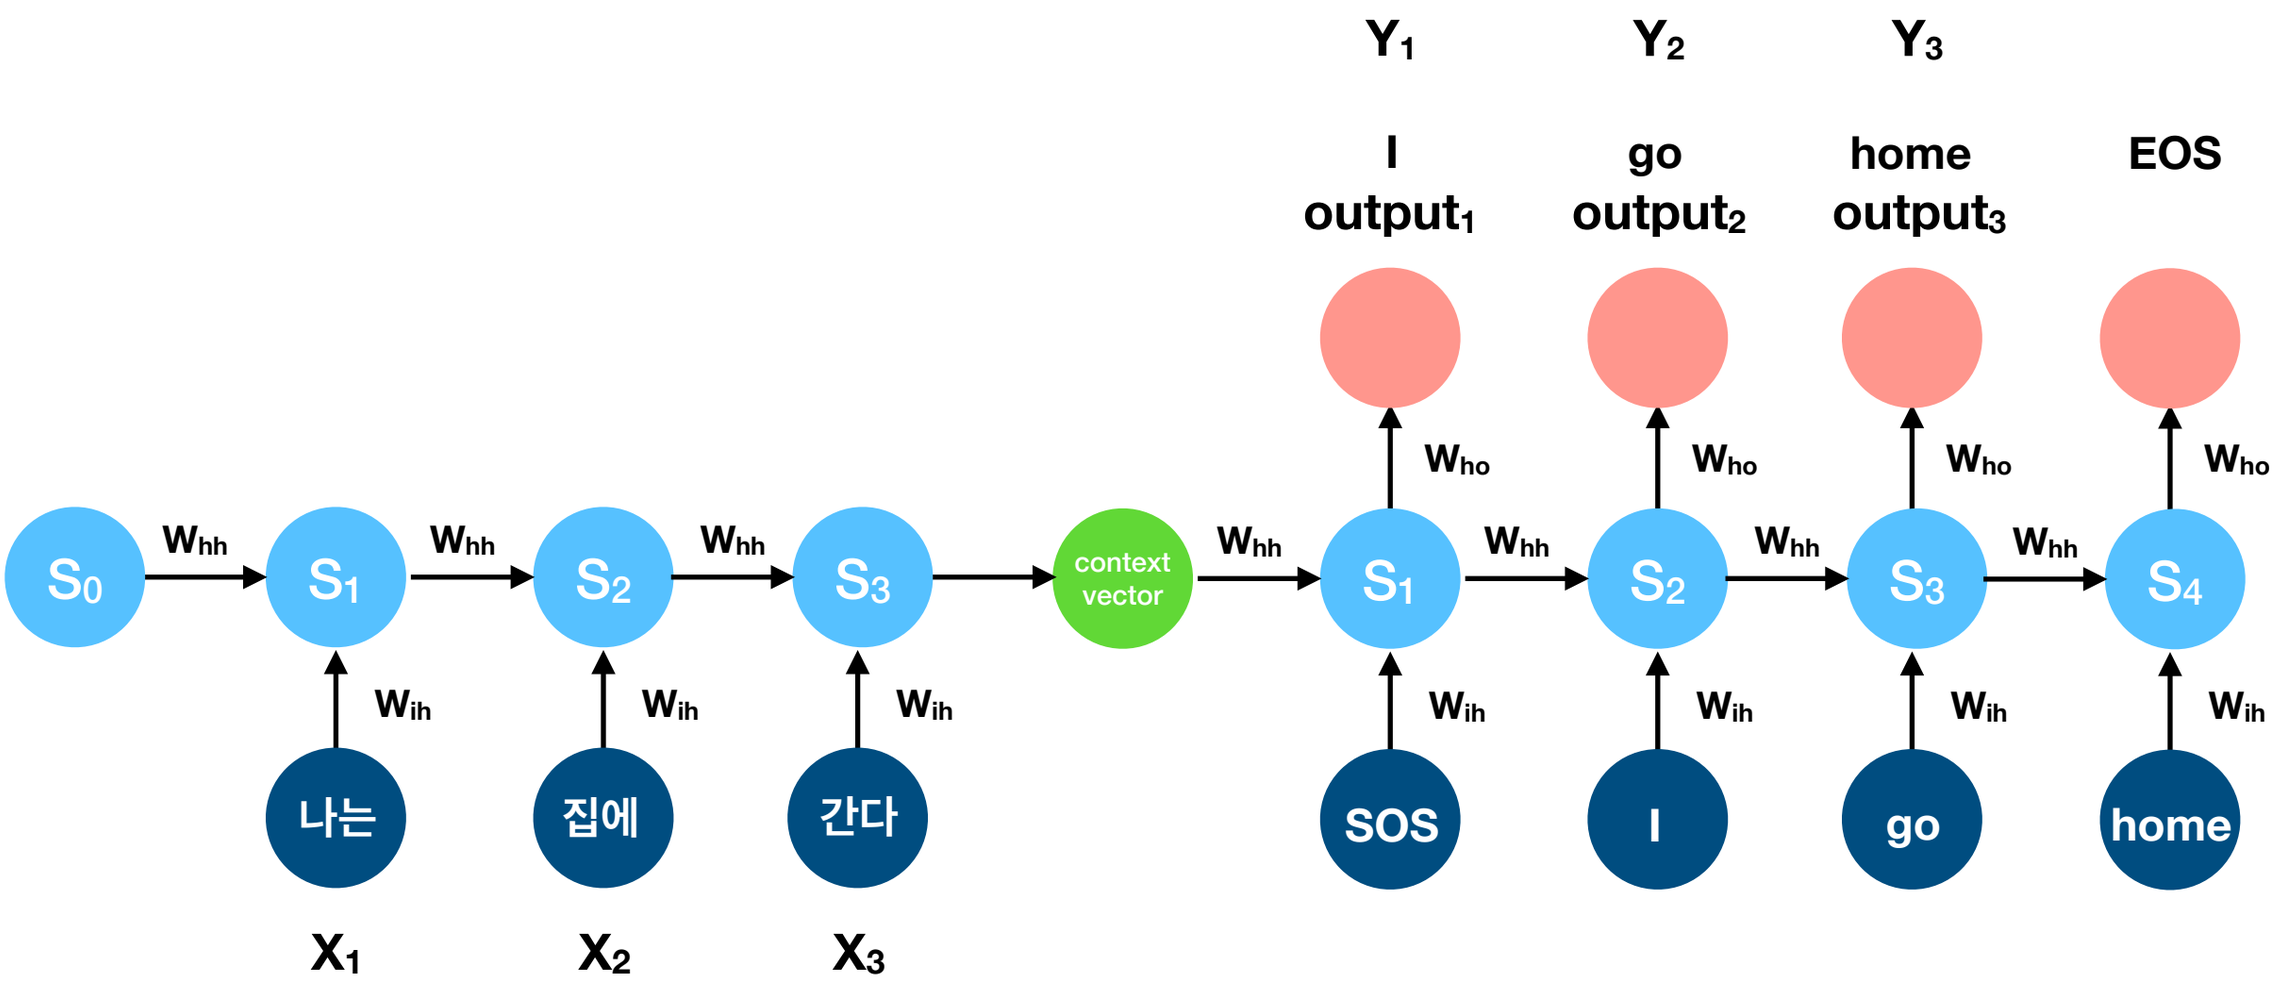
Y1
Y2
Y3
I
go
home
EOS
output1
output2
output3
Who
Who
Who
Who
S0
Whh
S1
Whh
S2
Whh
S3
context vector
Whh
S1
Whh
S2
Whh
S3
Whh
S4
Wih
Wih
Wih
Wih
Wih
Wih
나는
집에
간다
SOS
I
go
home
X1
X2
X3

Transformer

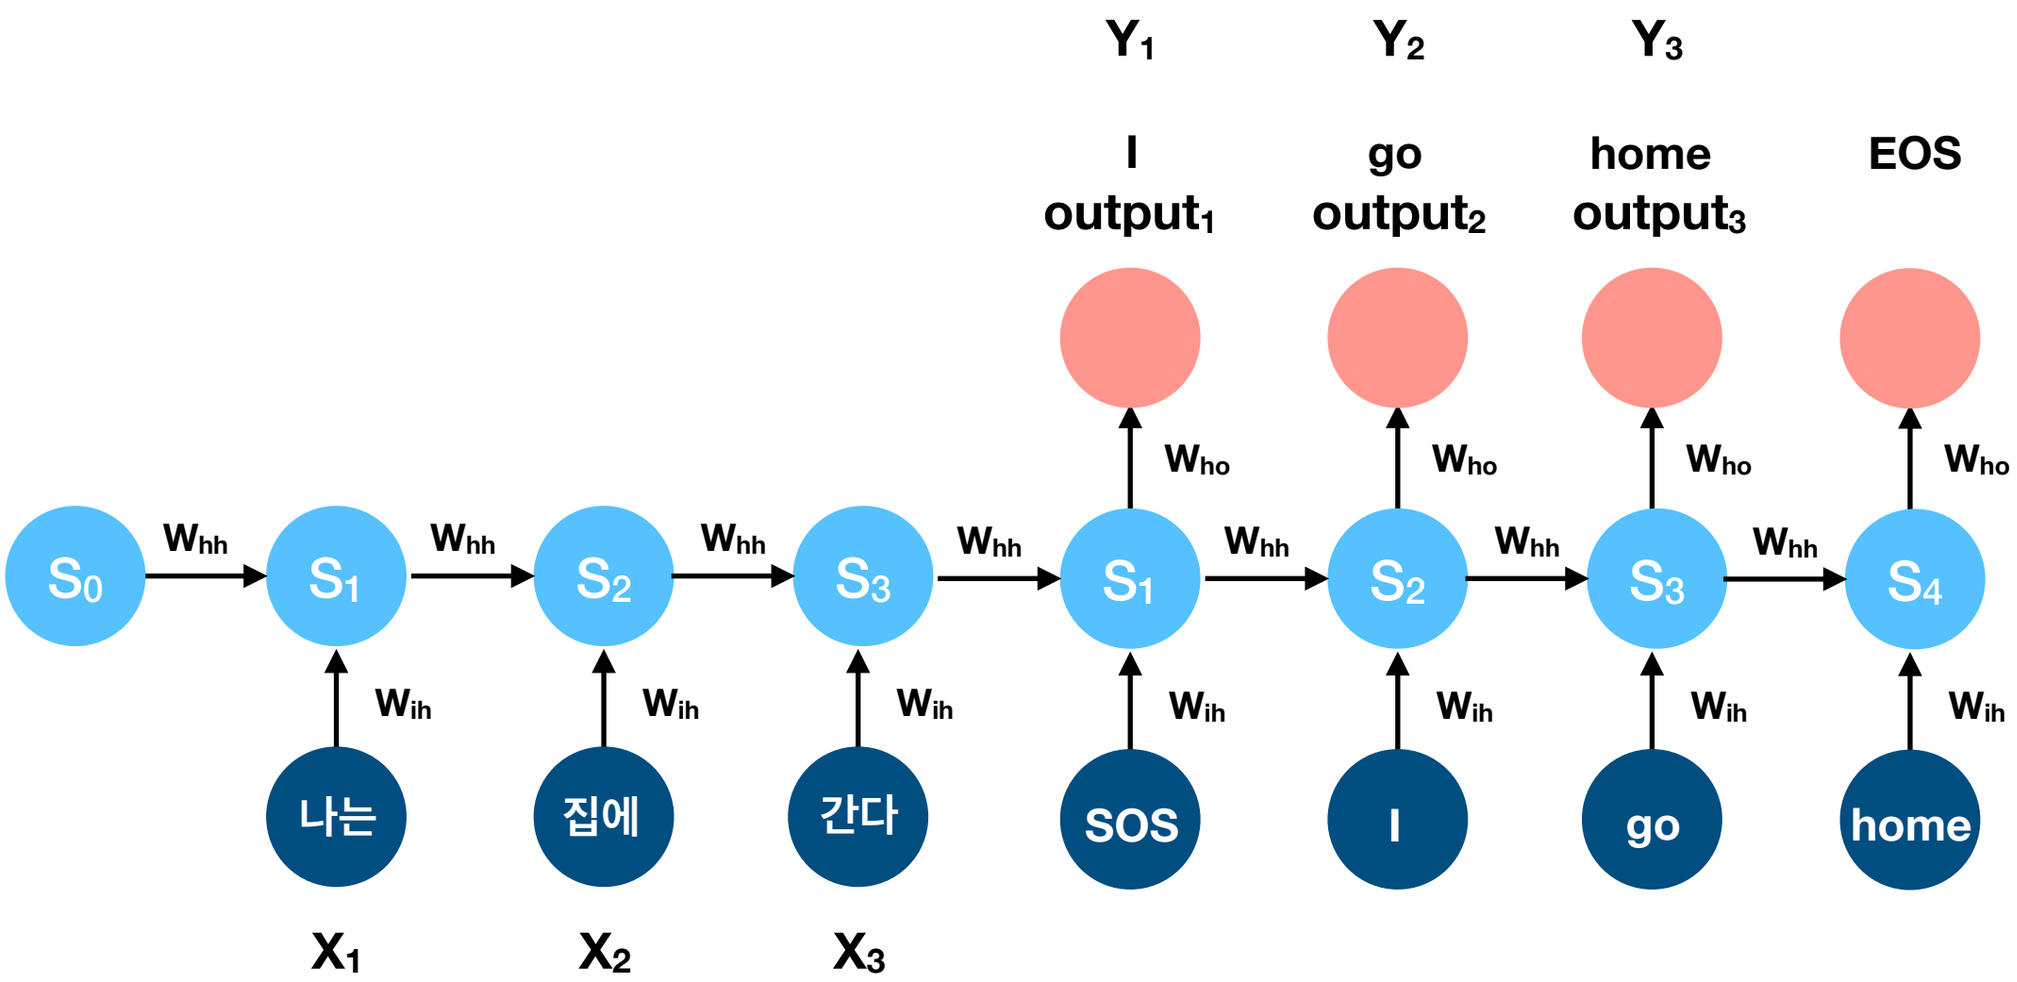

Transformer

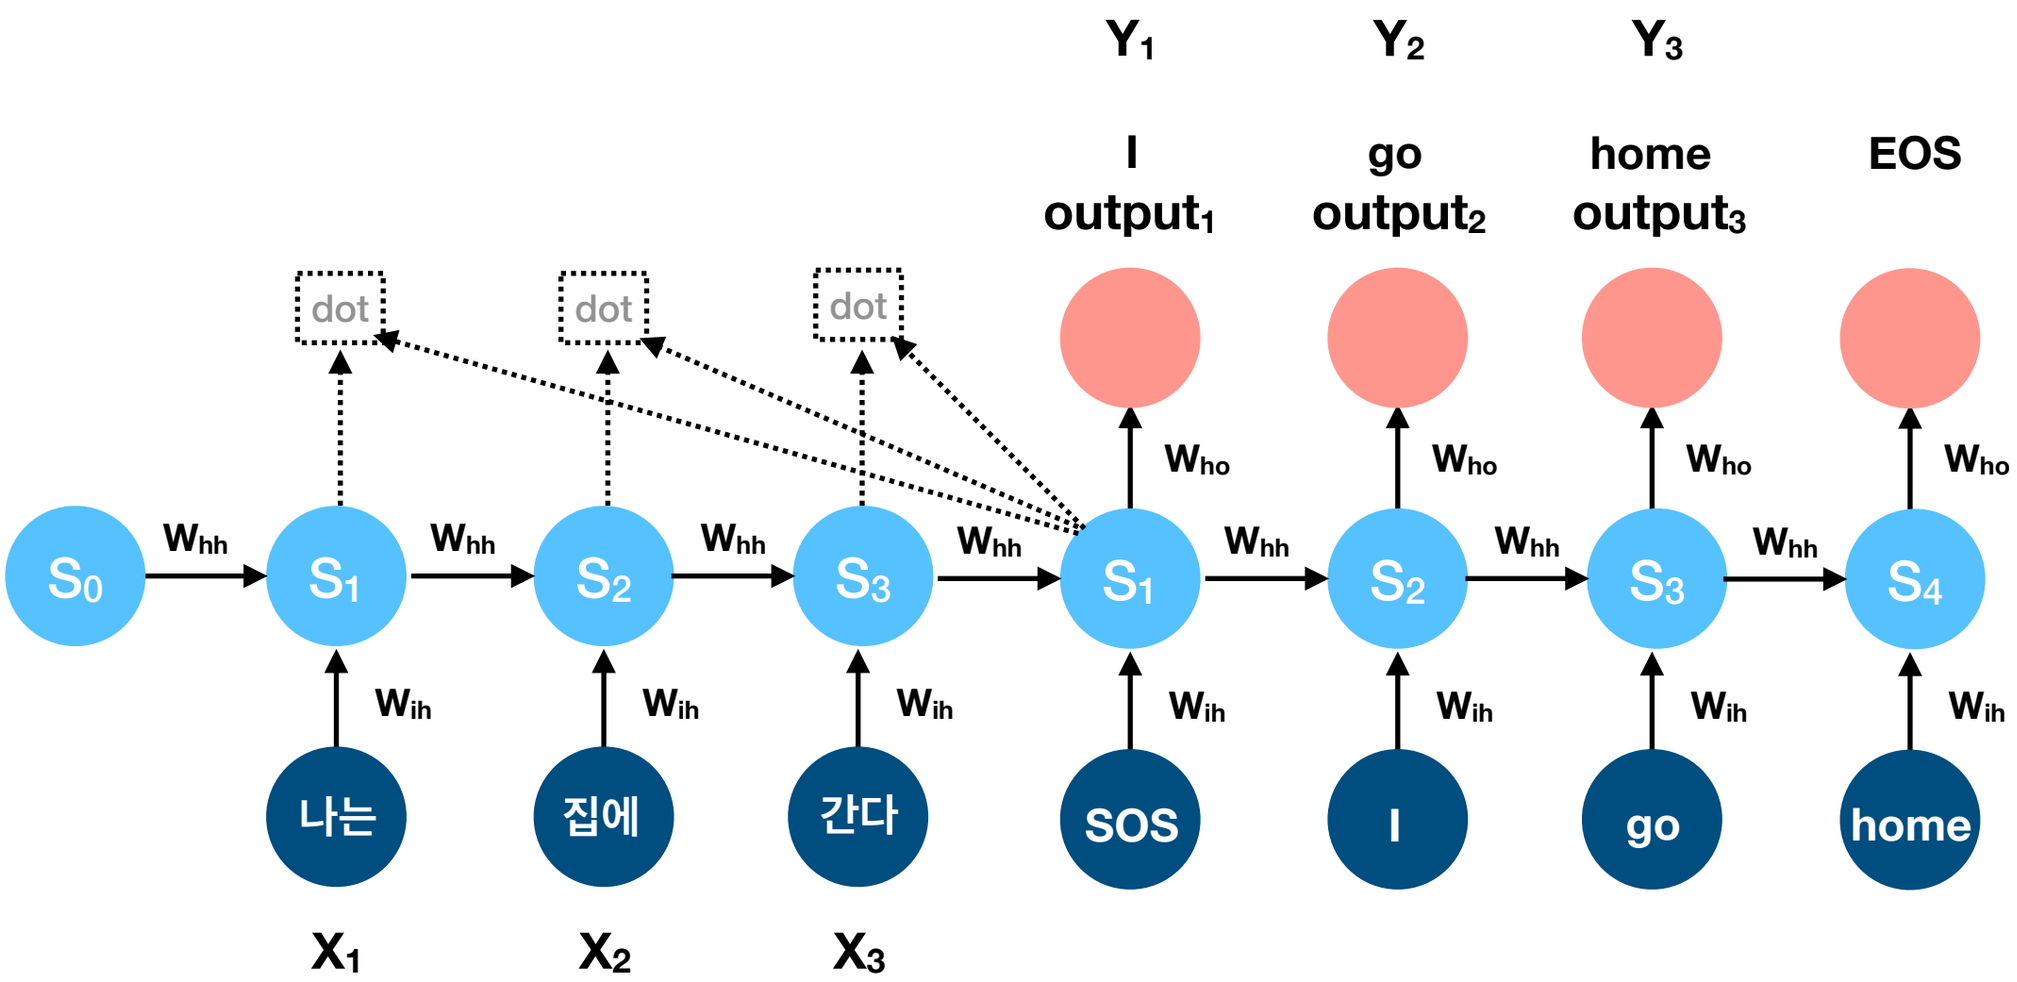

Transformer

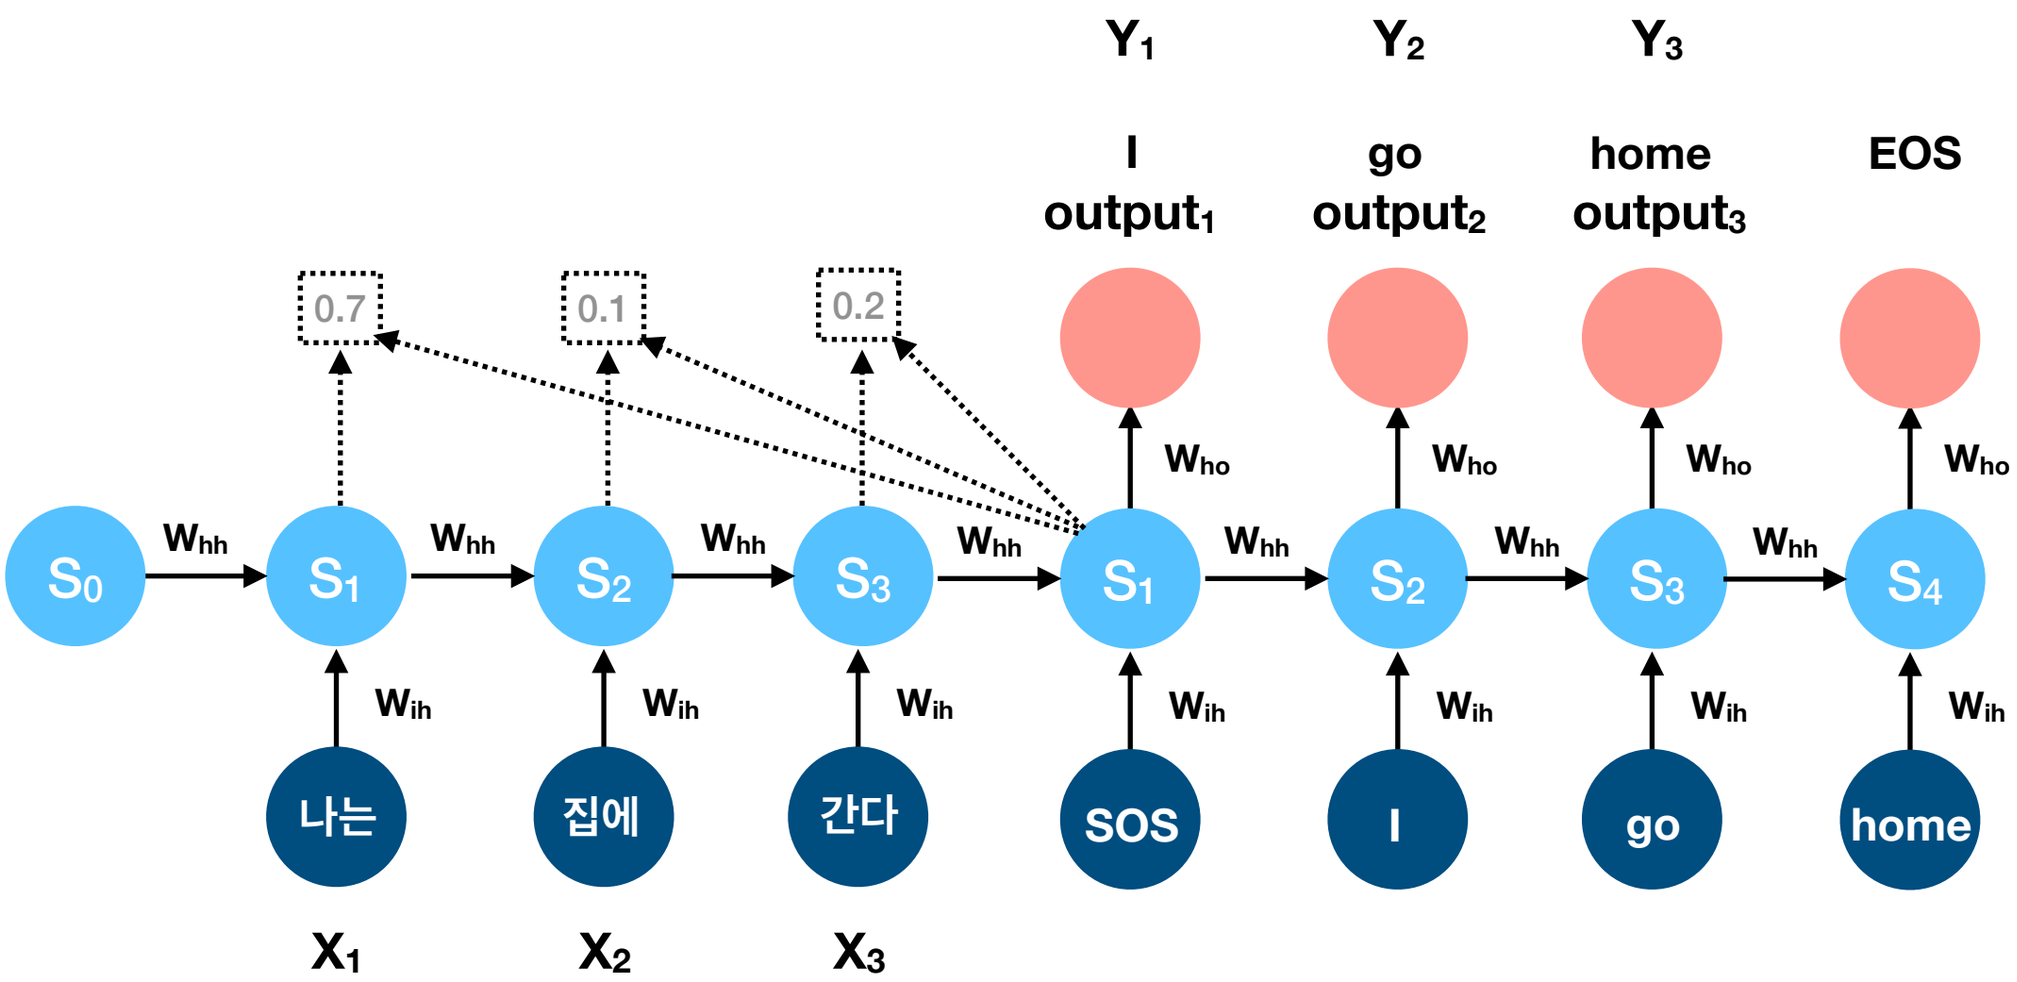

Transformer

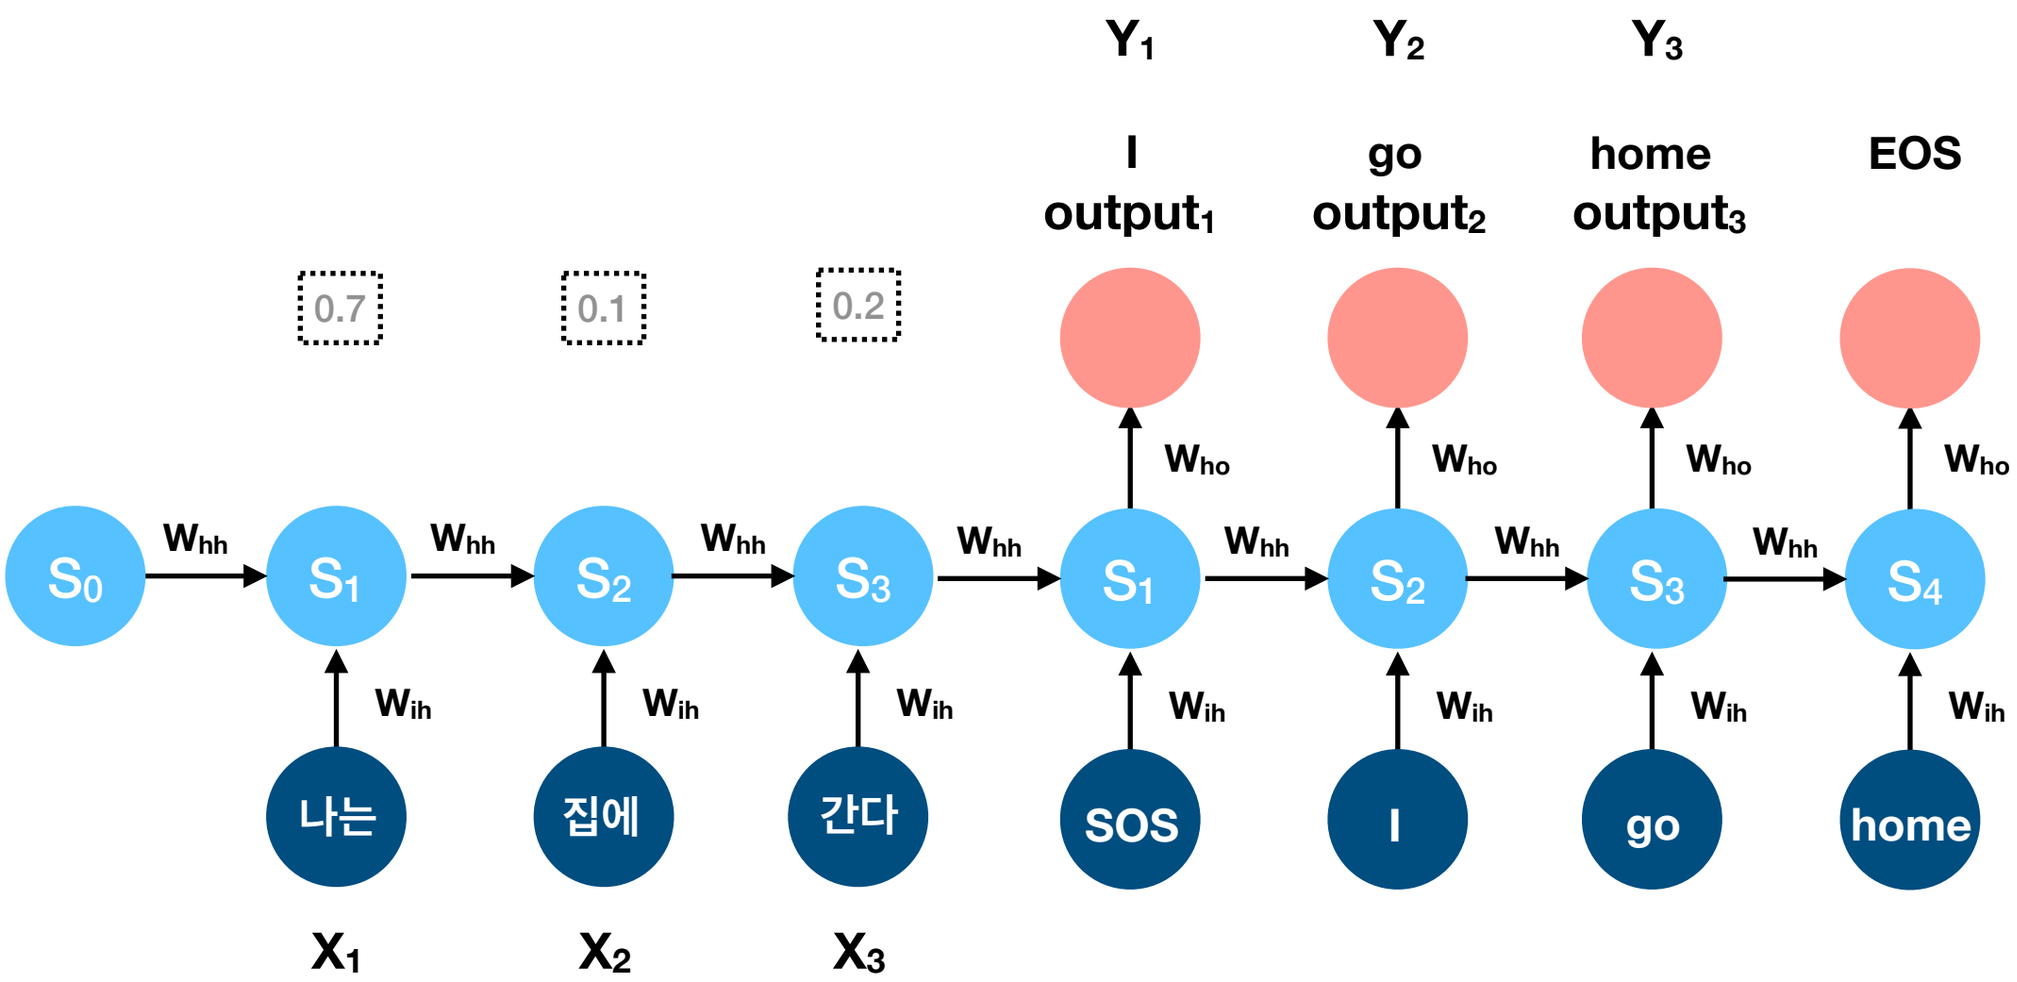

Transformer

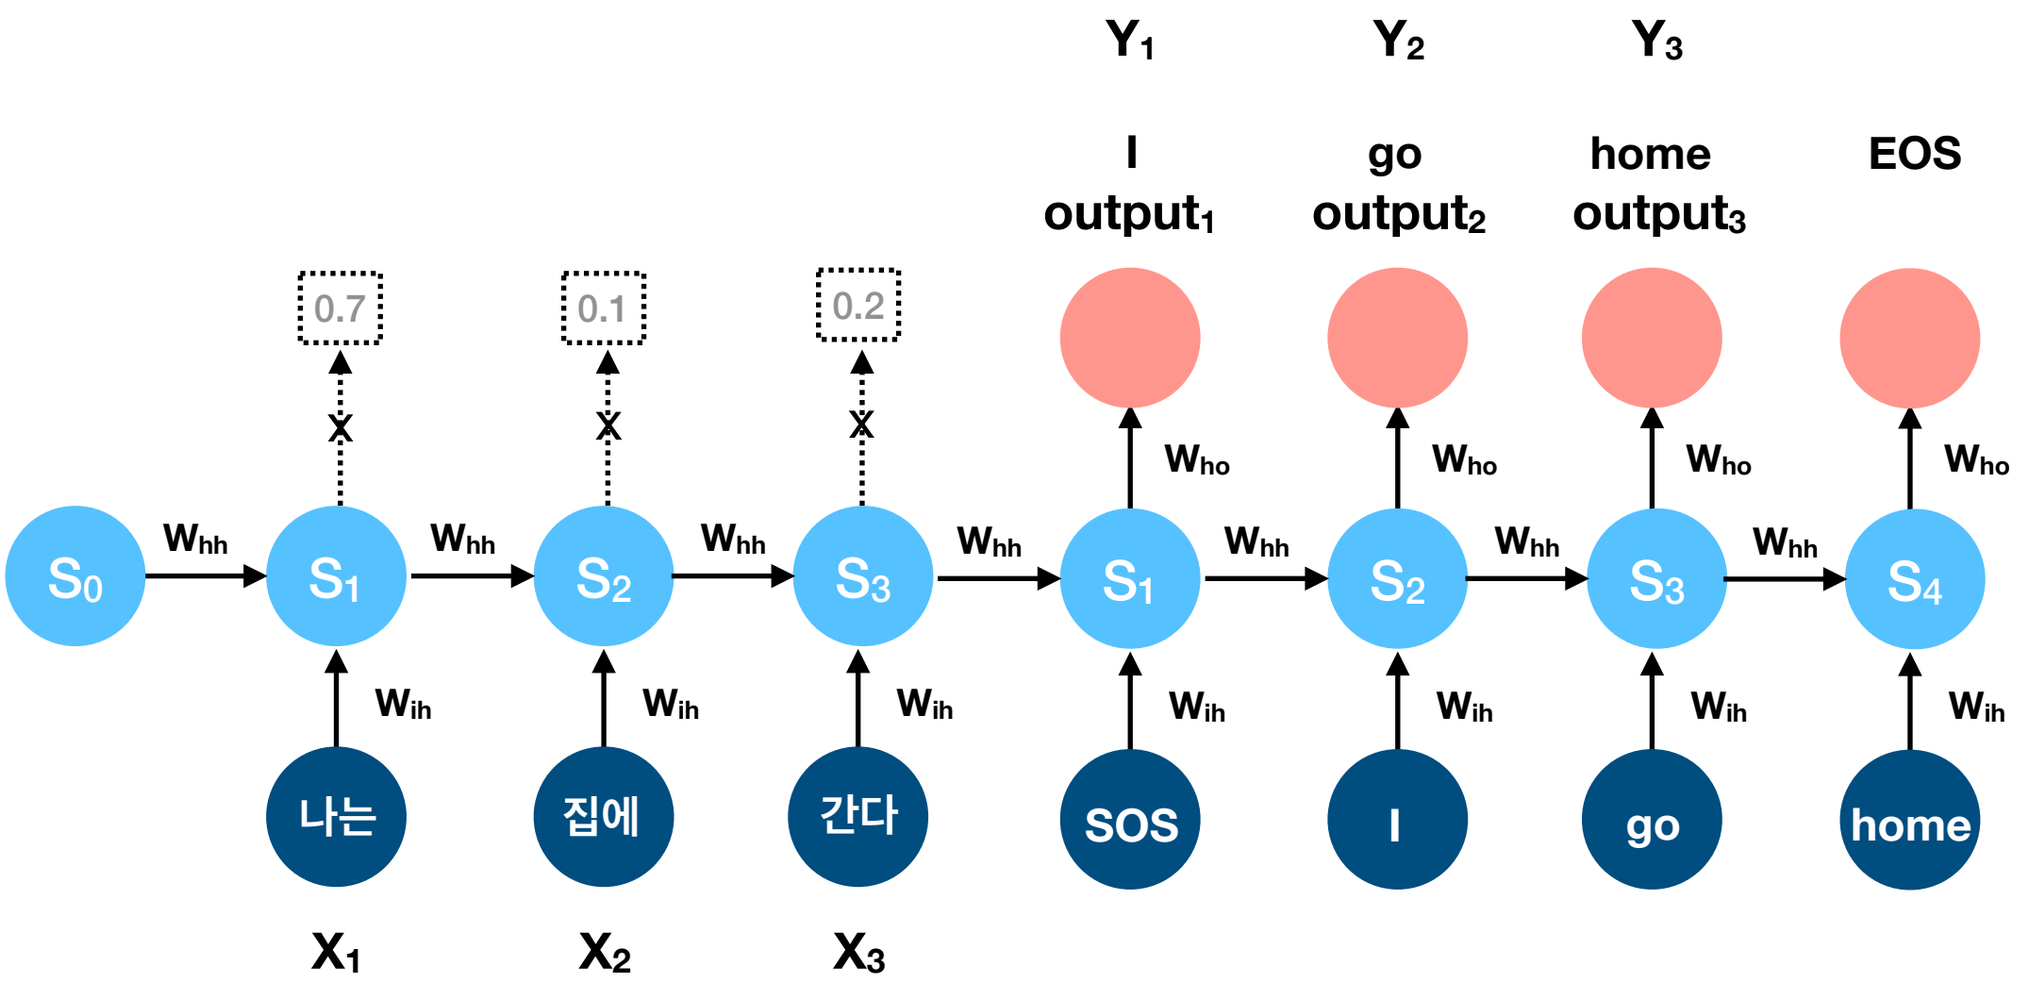

Transformer

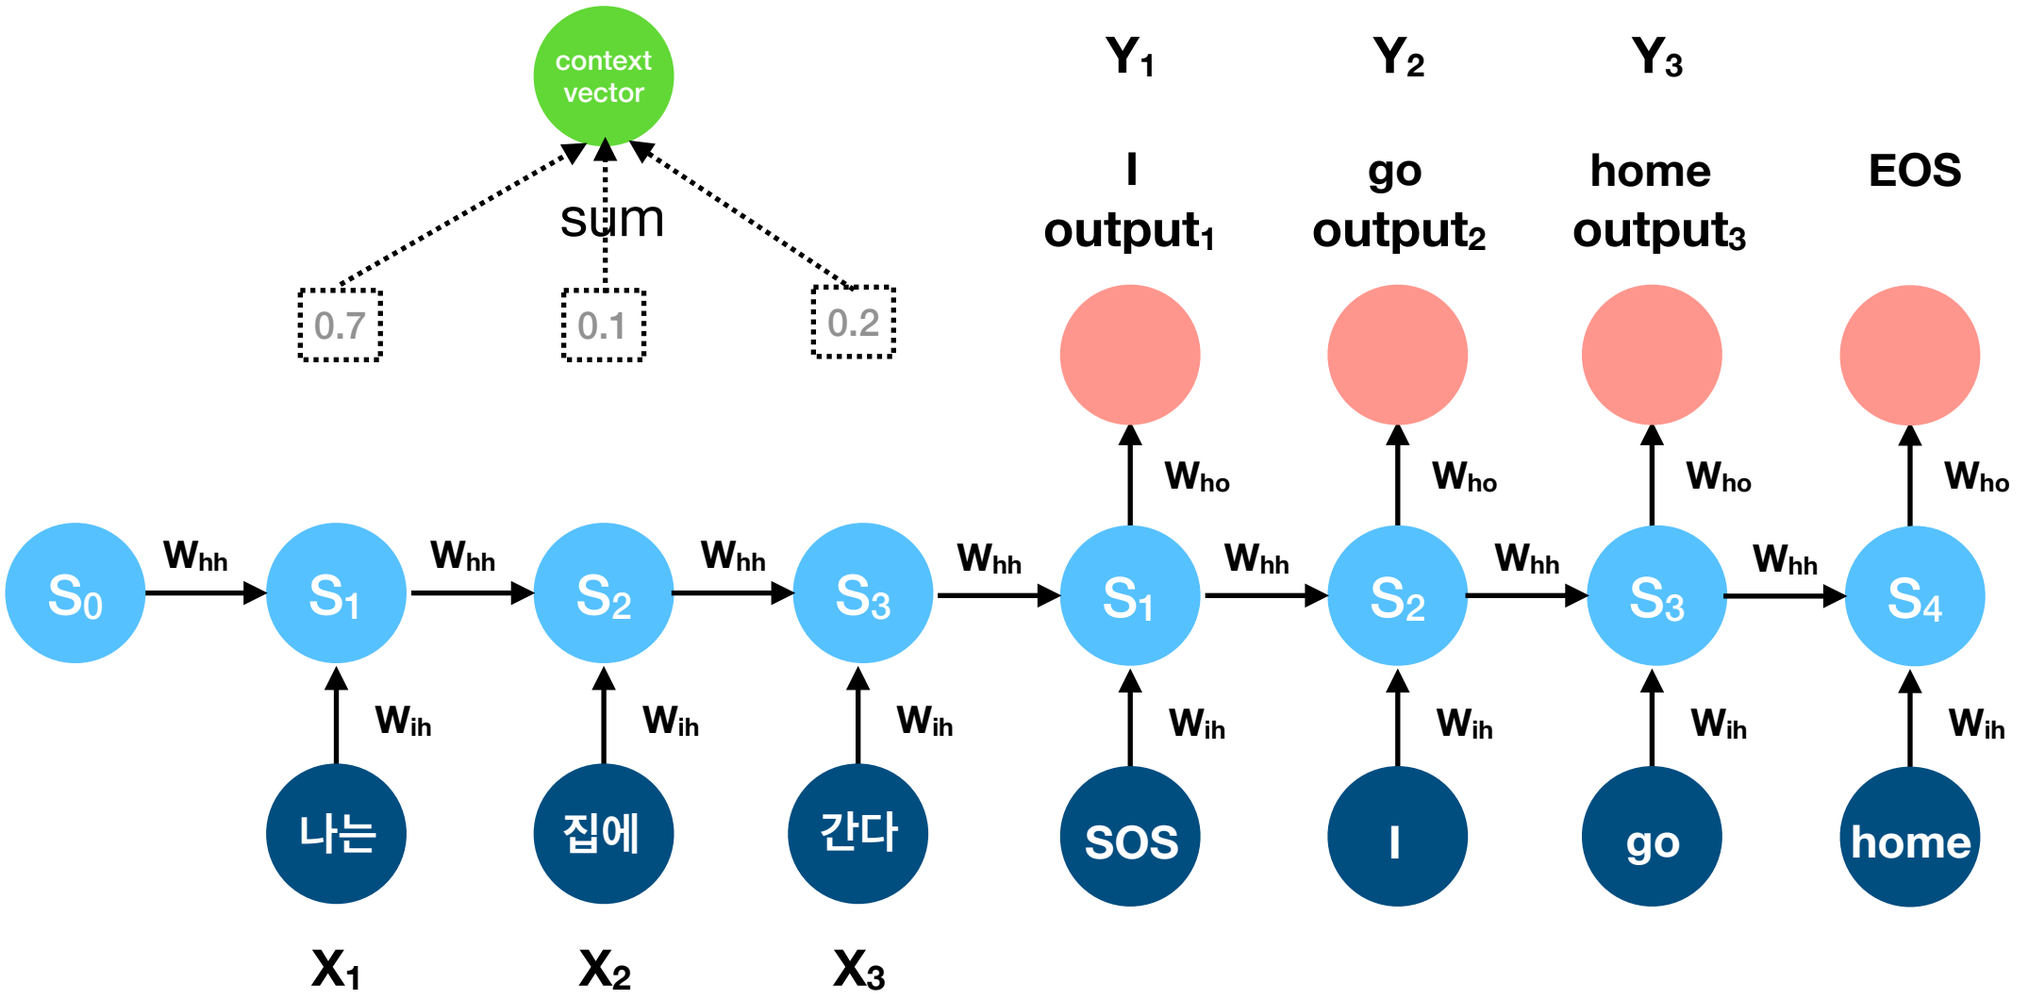

Transformer

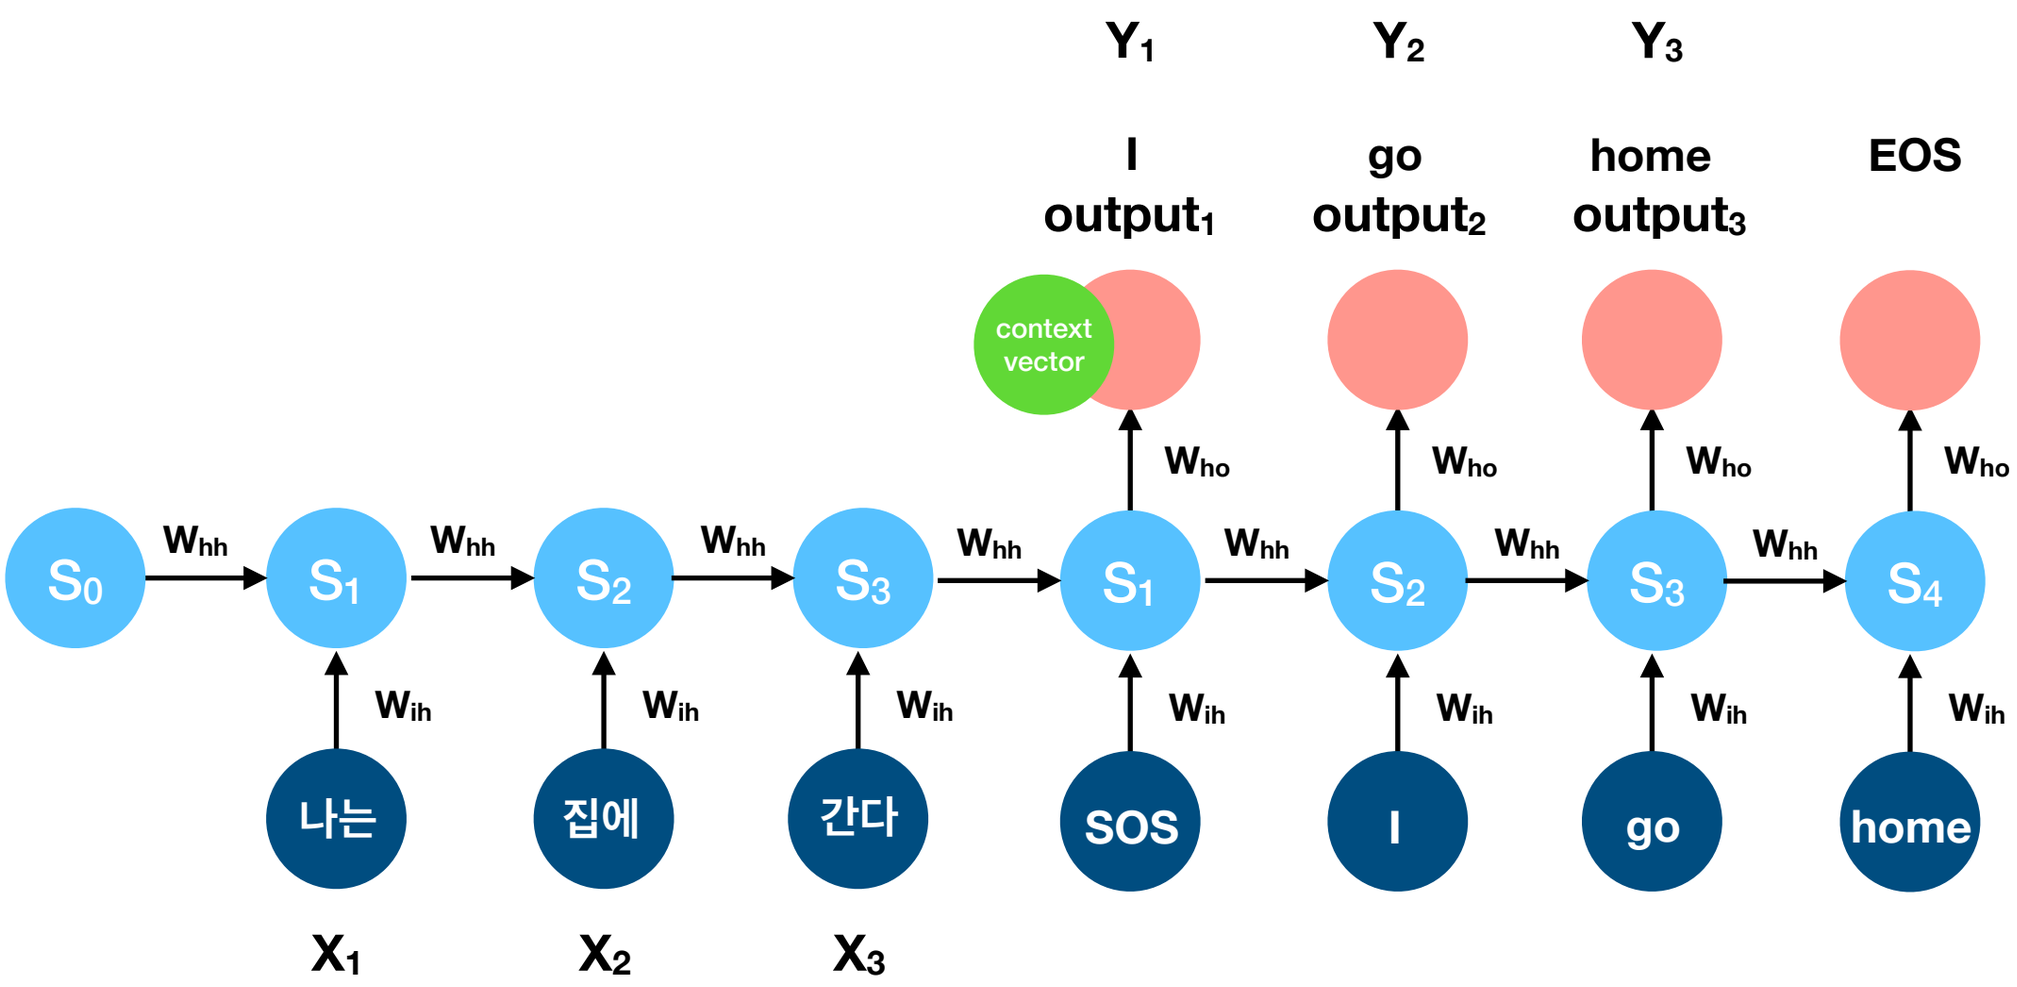

VAE

Variational Autoencoder

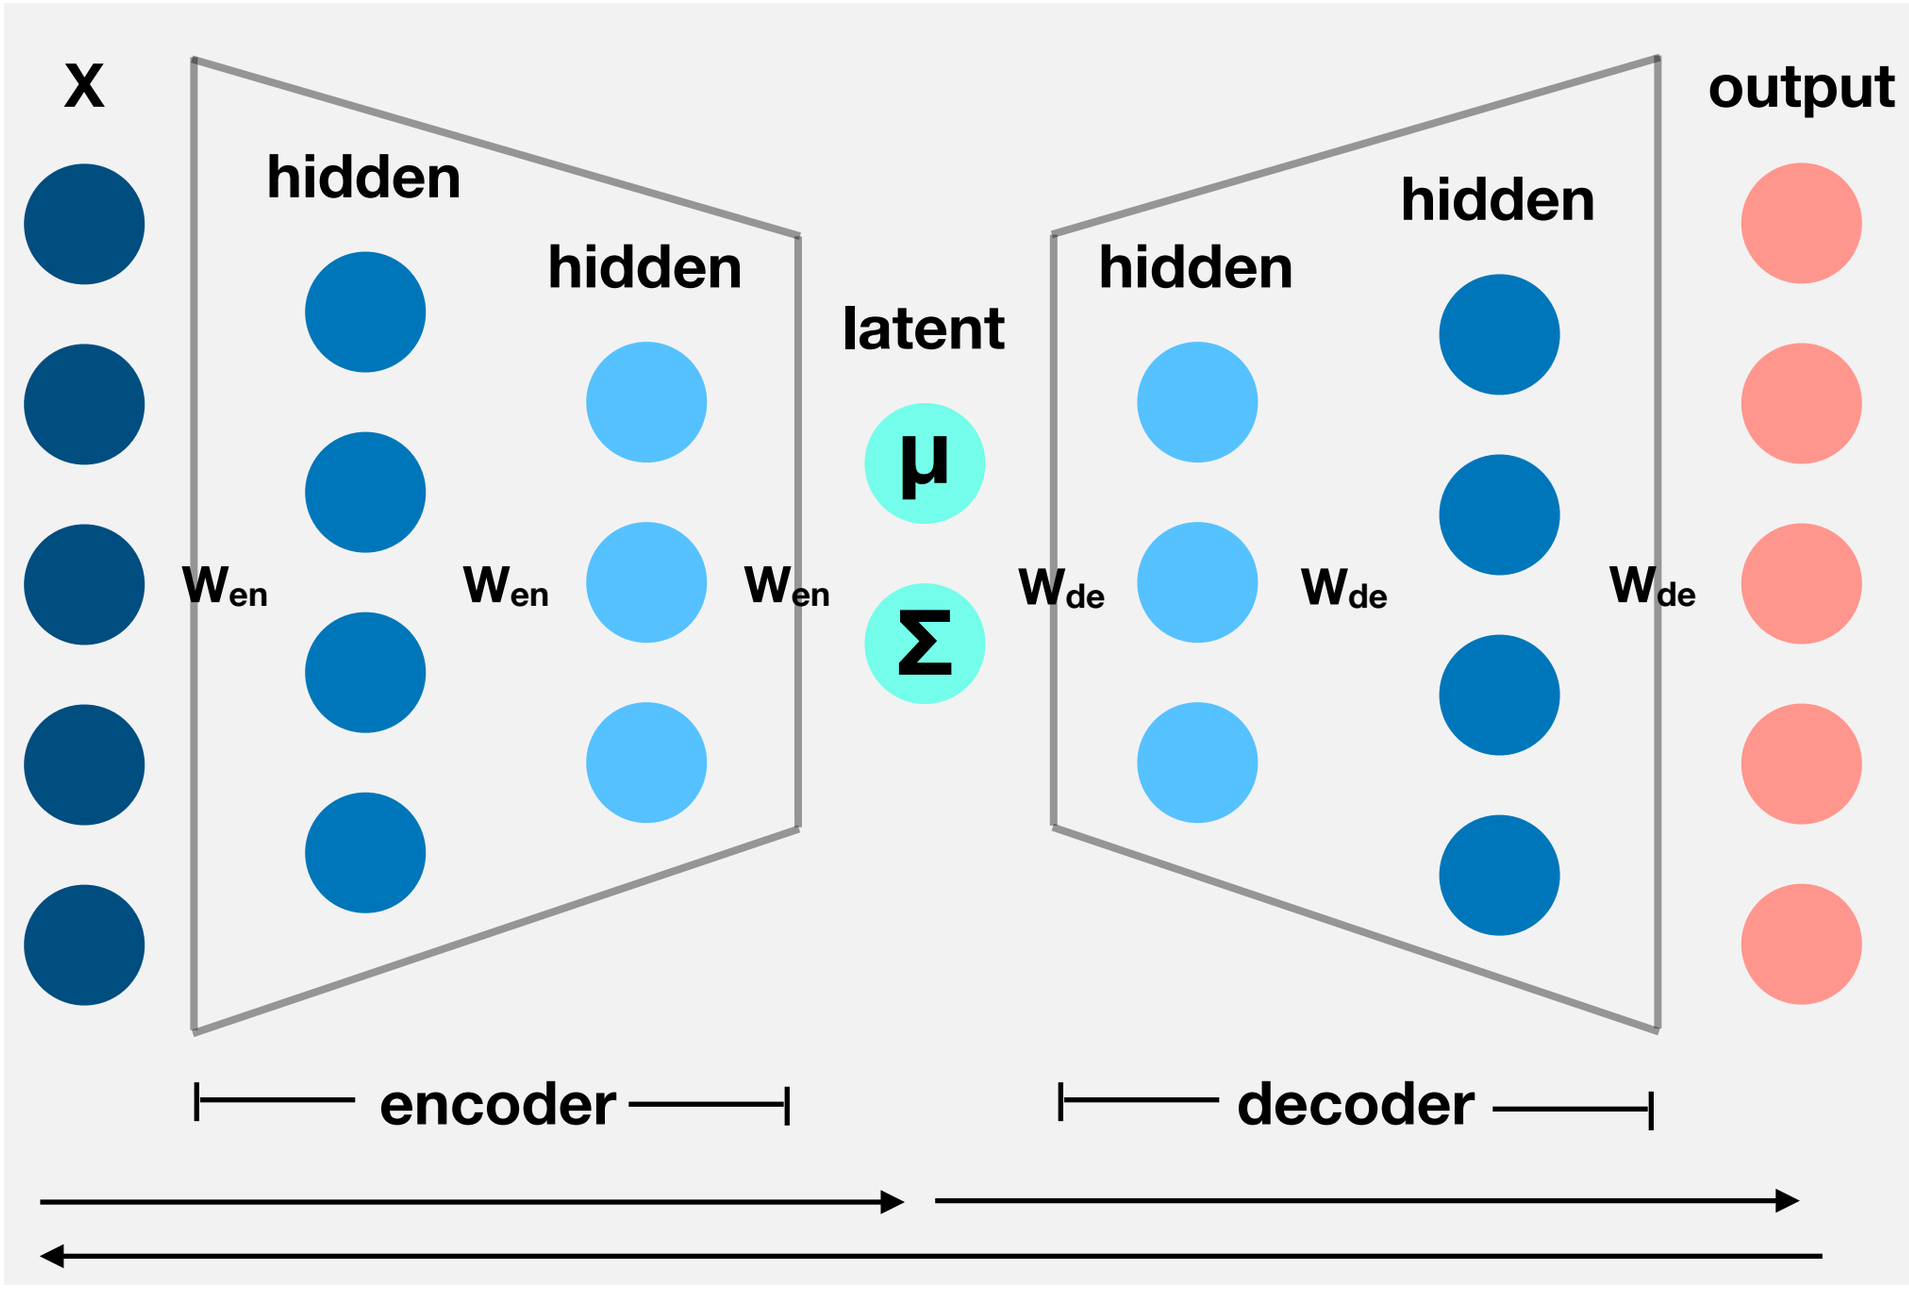

VAE는 기본적으로 autoencoder와 같이 encoder와 decoder로 이루어져 있습니다.

Variational Autoencoder

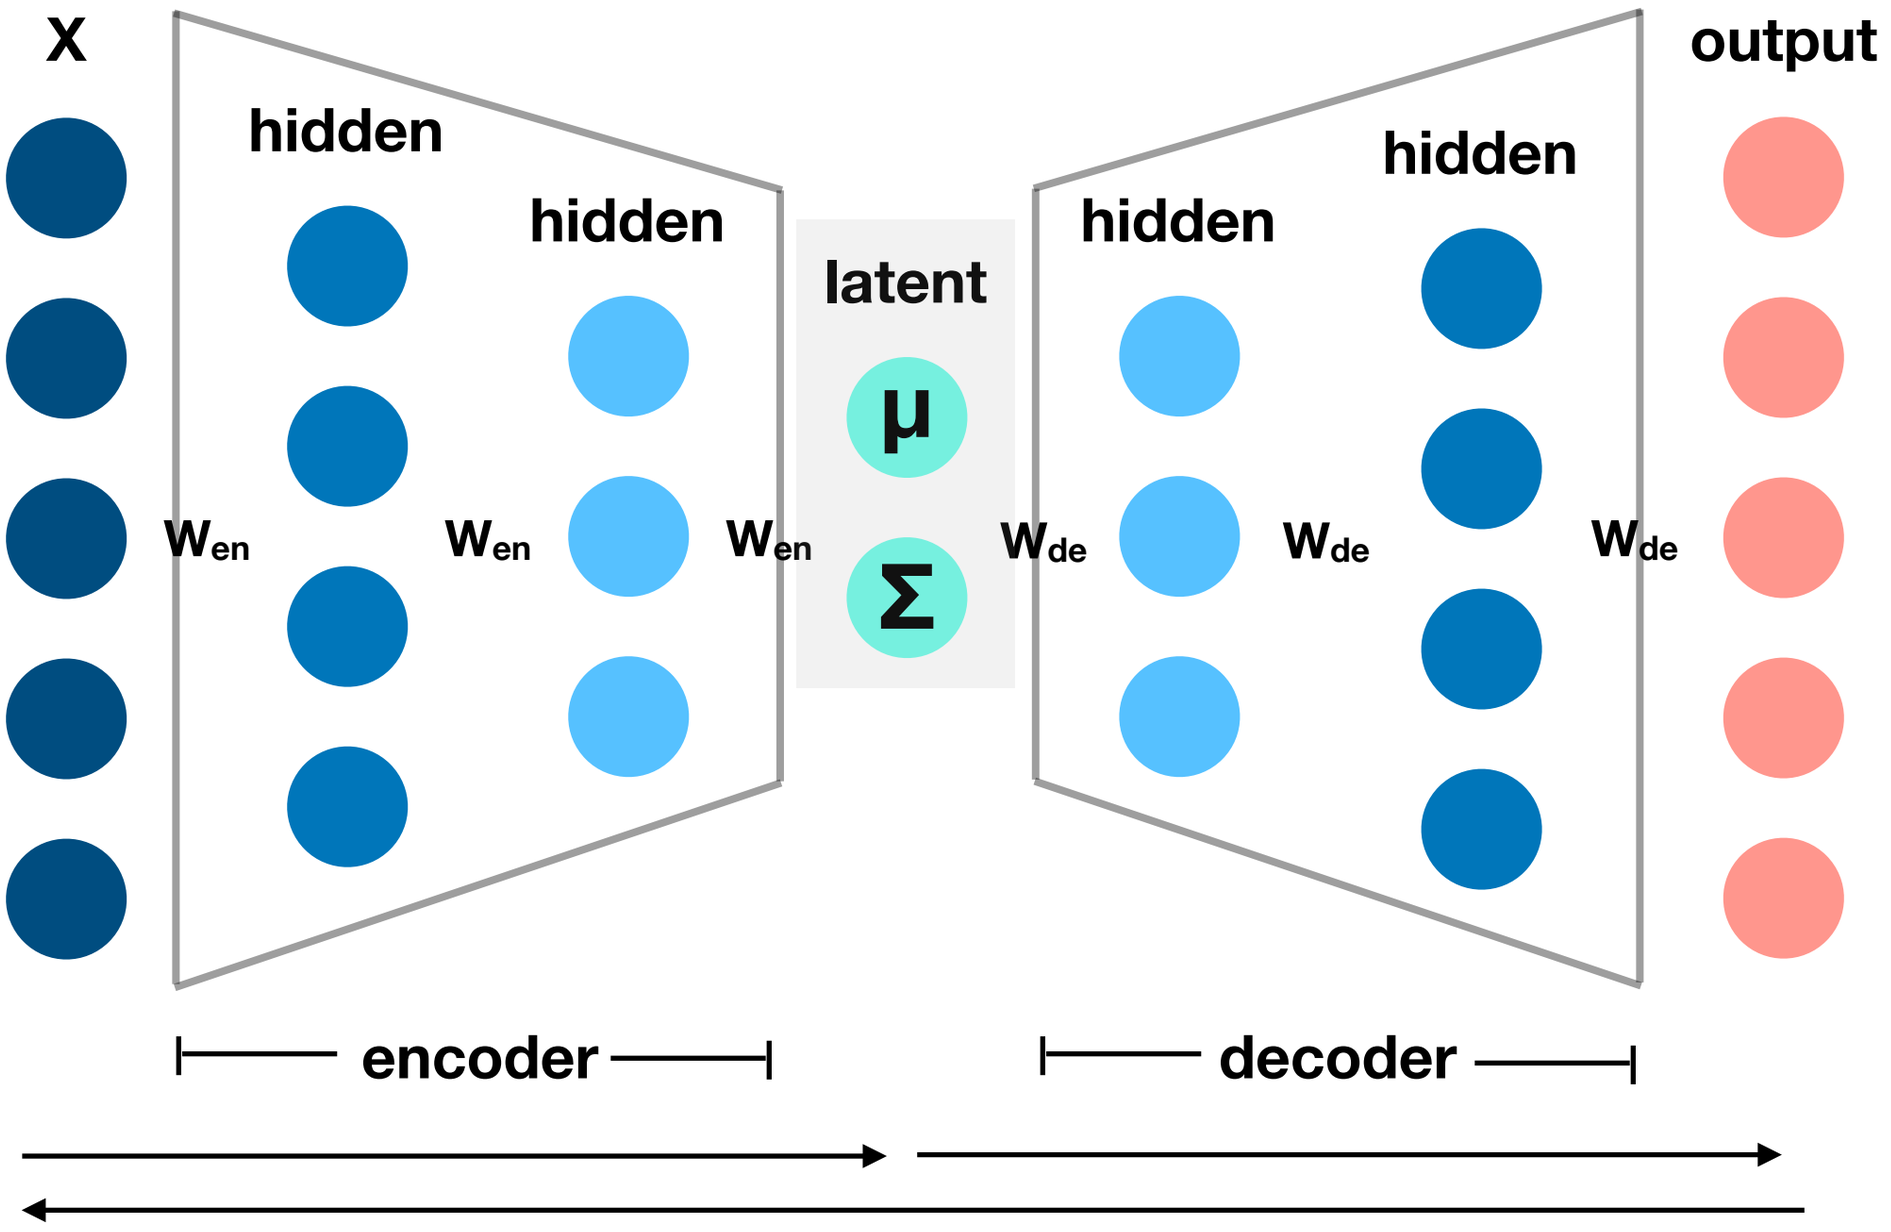

하지만 autoencoder와는 달리, 가운데에 layer 한 개를 추가해줍니다.
이를 latent layer라고 합니다.

Variational Autoencoder

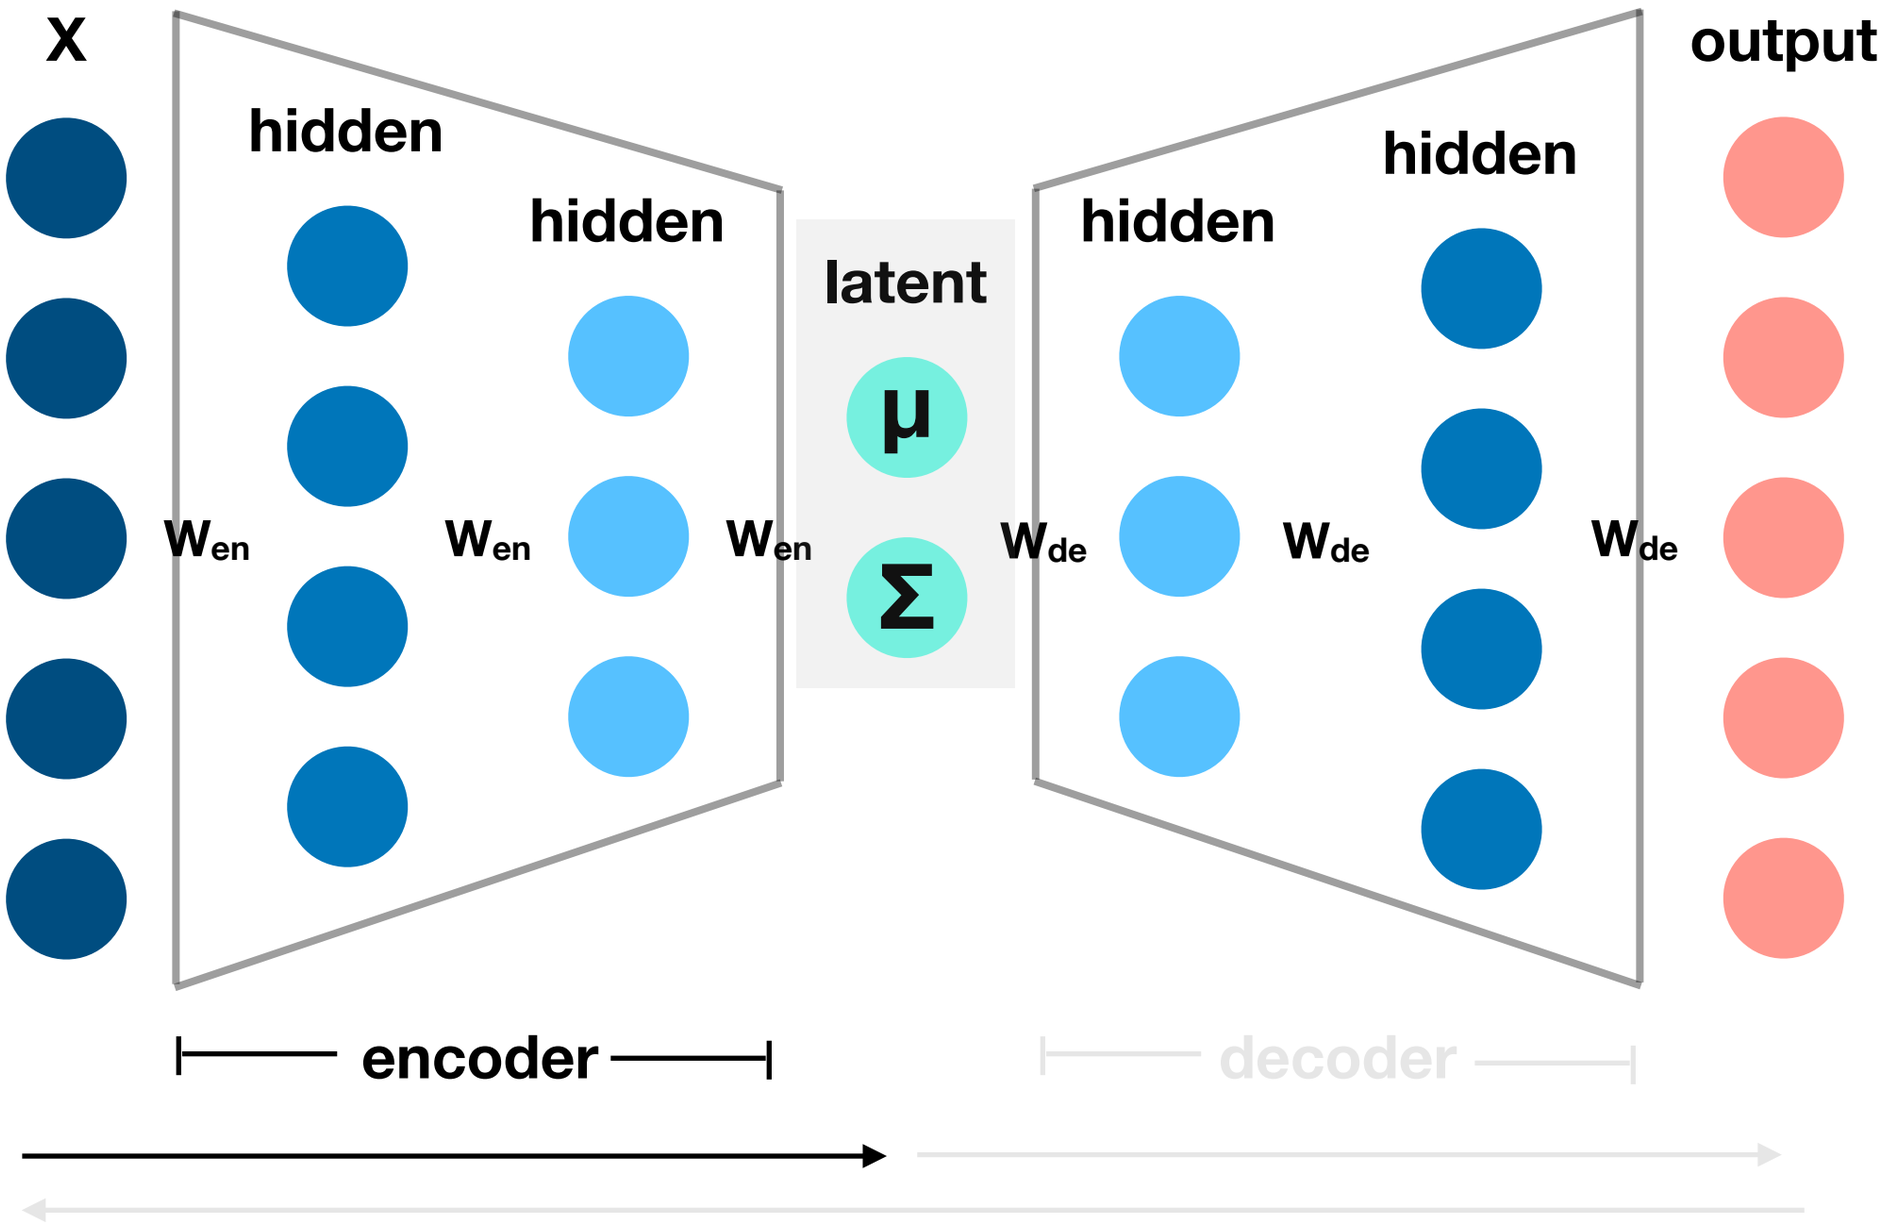

encoder를 거친 이 latent layer의 값이
input 데이터 분포의 평균(μ)과 표준편차(Σ)라고 가정해봅시다.

Variational Autoencoder

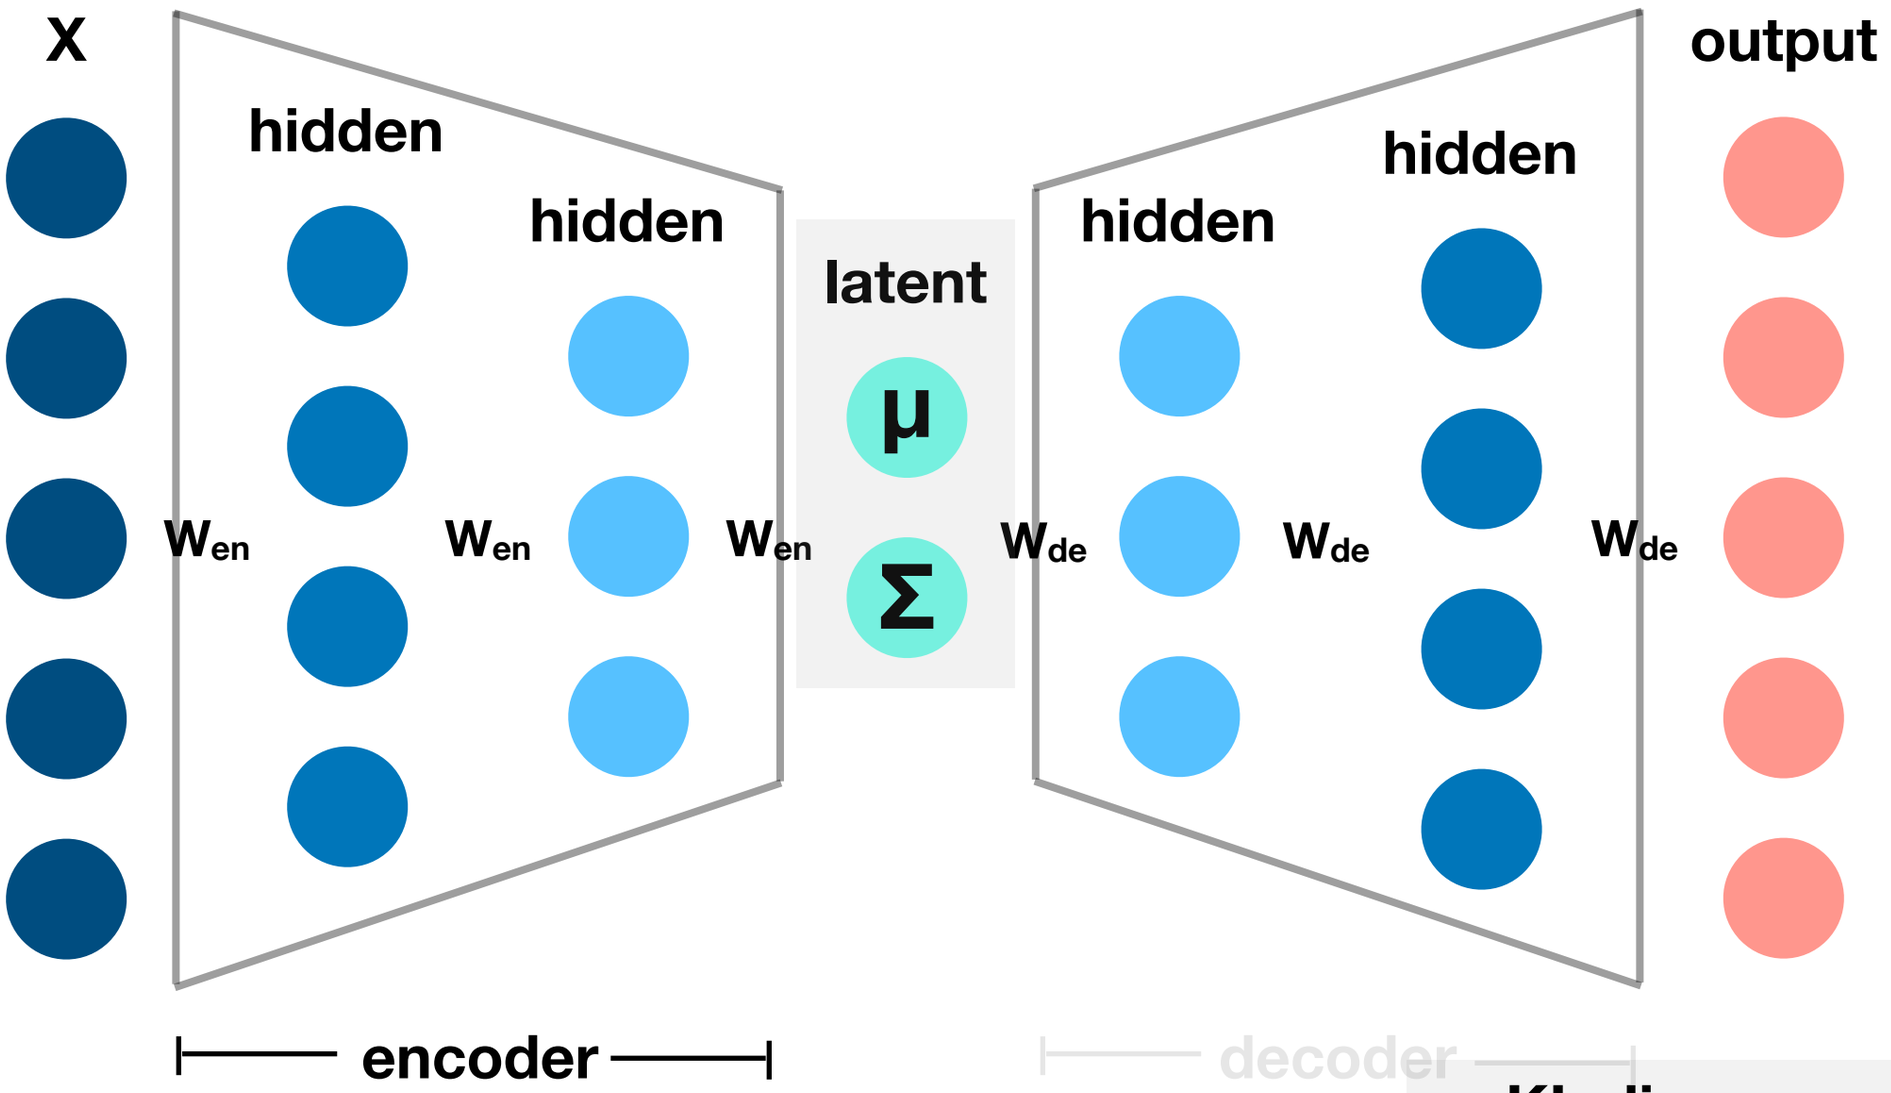

latent space 상의 input data 분포의 평균 μ, 표준편차 Σ와
정규 분포의 평균(0), 표준편차(1)와의
차이를 첫 번째 loss라고 하겠습니다.

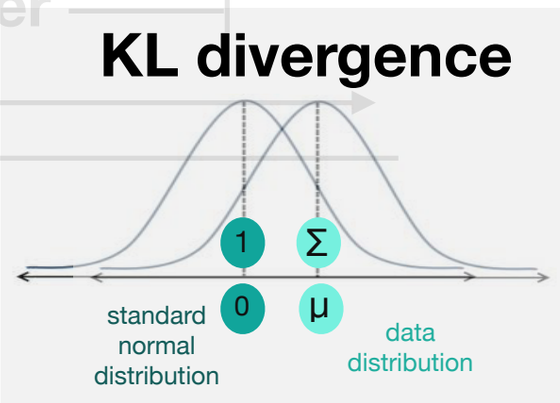

L_1

Variational Autoencoder

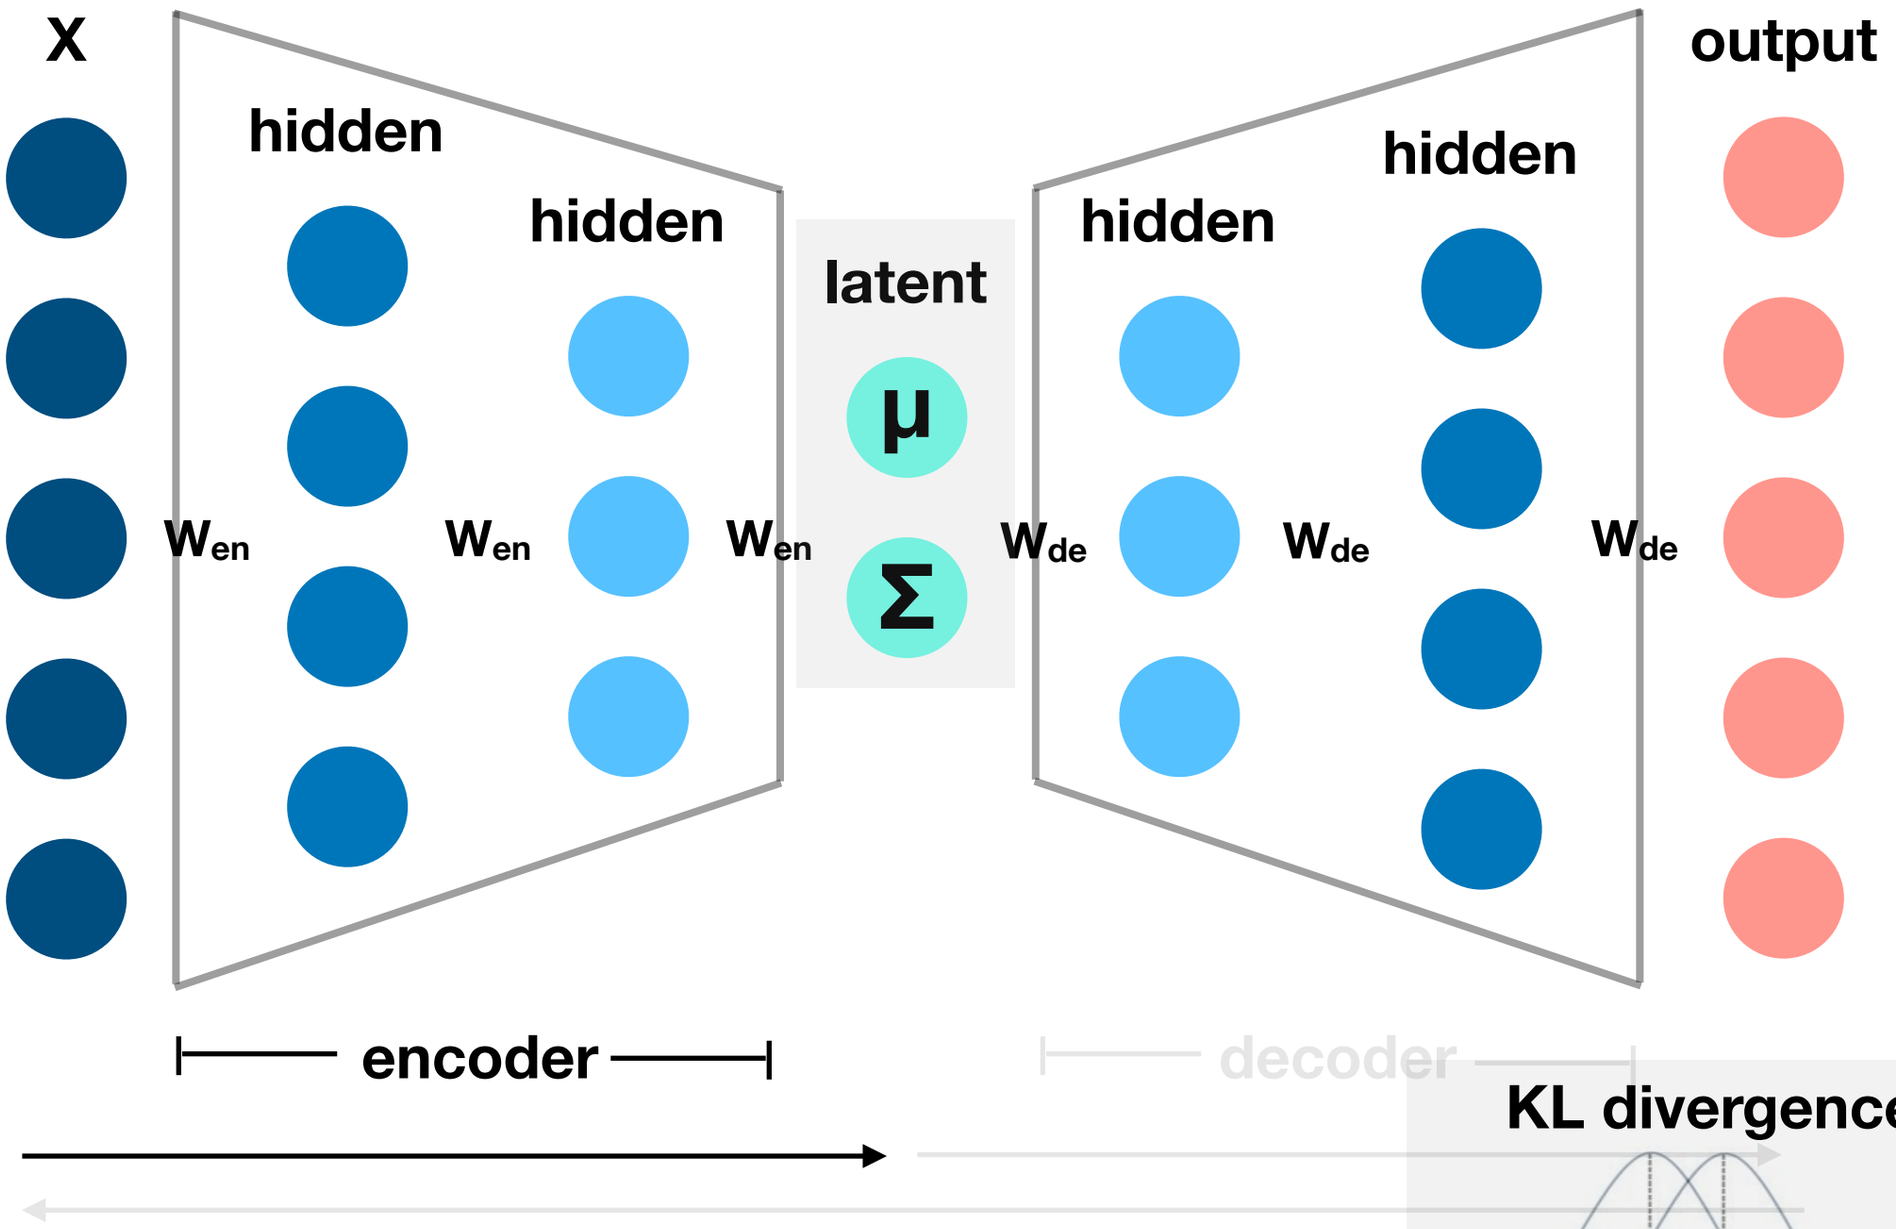

따라서, 첫 번째 loss를 최소화함에 따라
latent space 상의 데이터 분포는 점차 정규 분포가 됩니다.

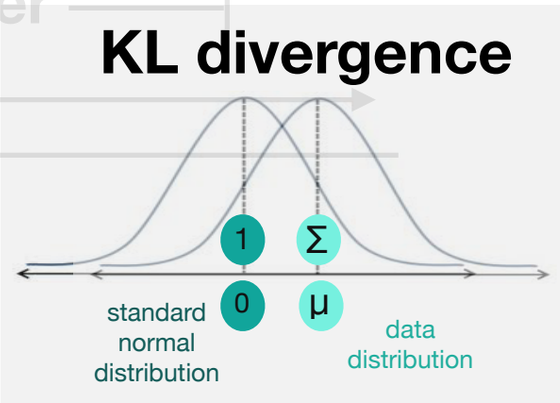

L_1

Variational Autoencoder

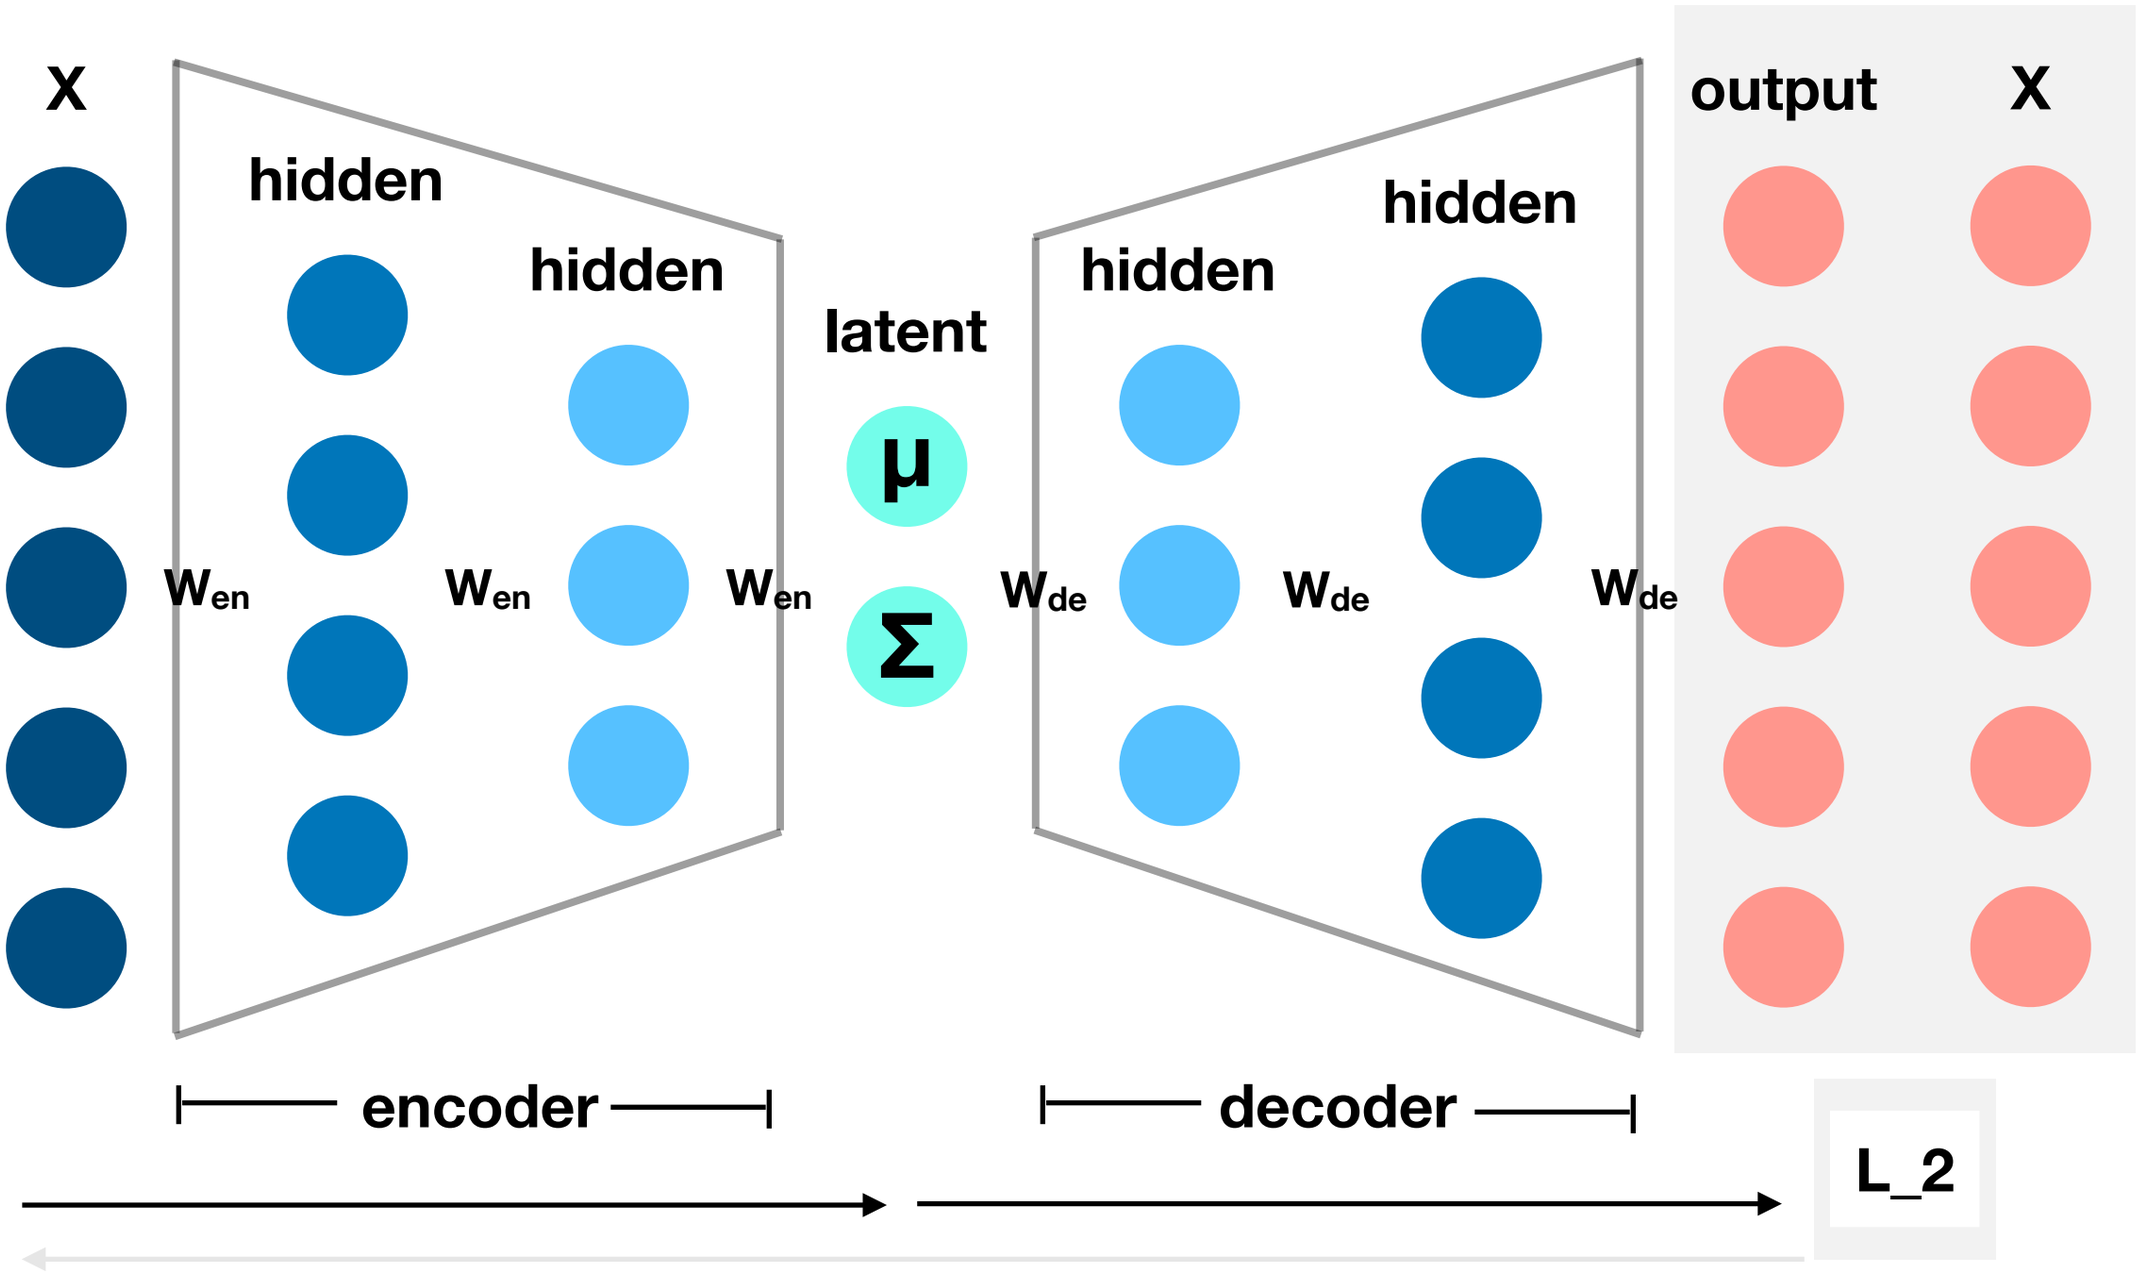

target은 X 자기 자신과 동일합니다.
output과 정답 target (X)을 비교하여 두 번째 loss를 구합니다.

Variational Autoencoder

L_1 + L_2 = total loss

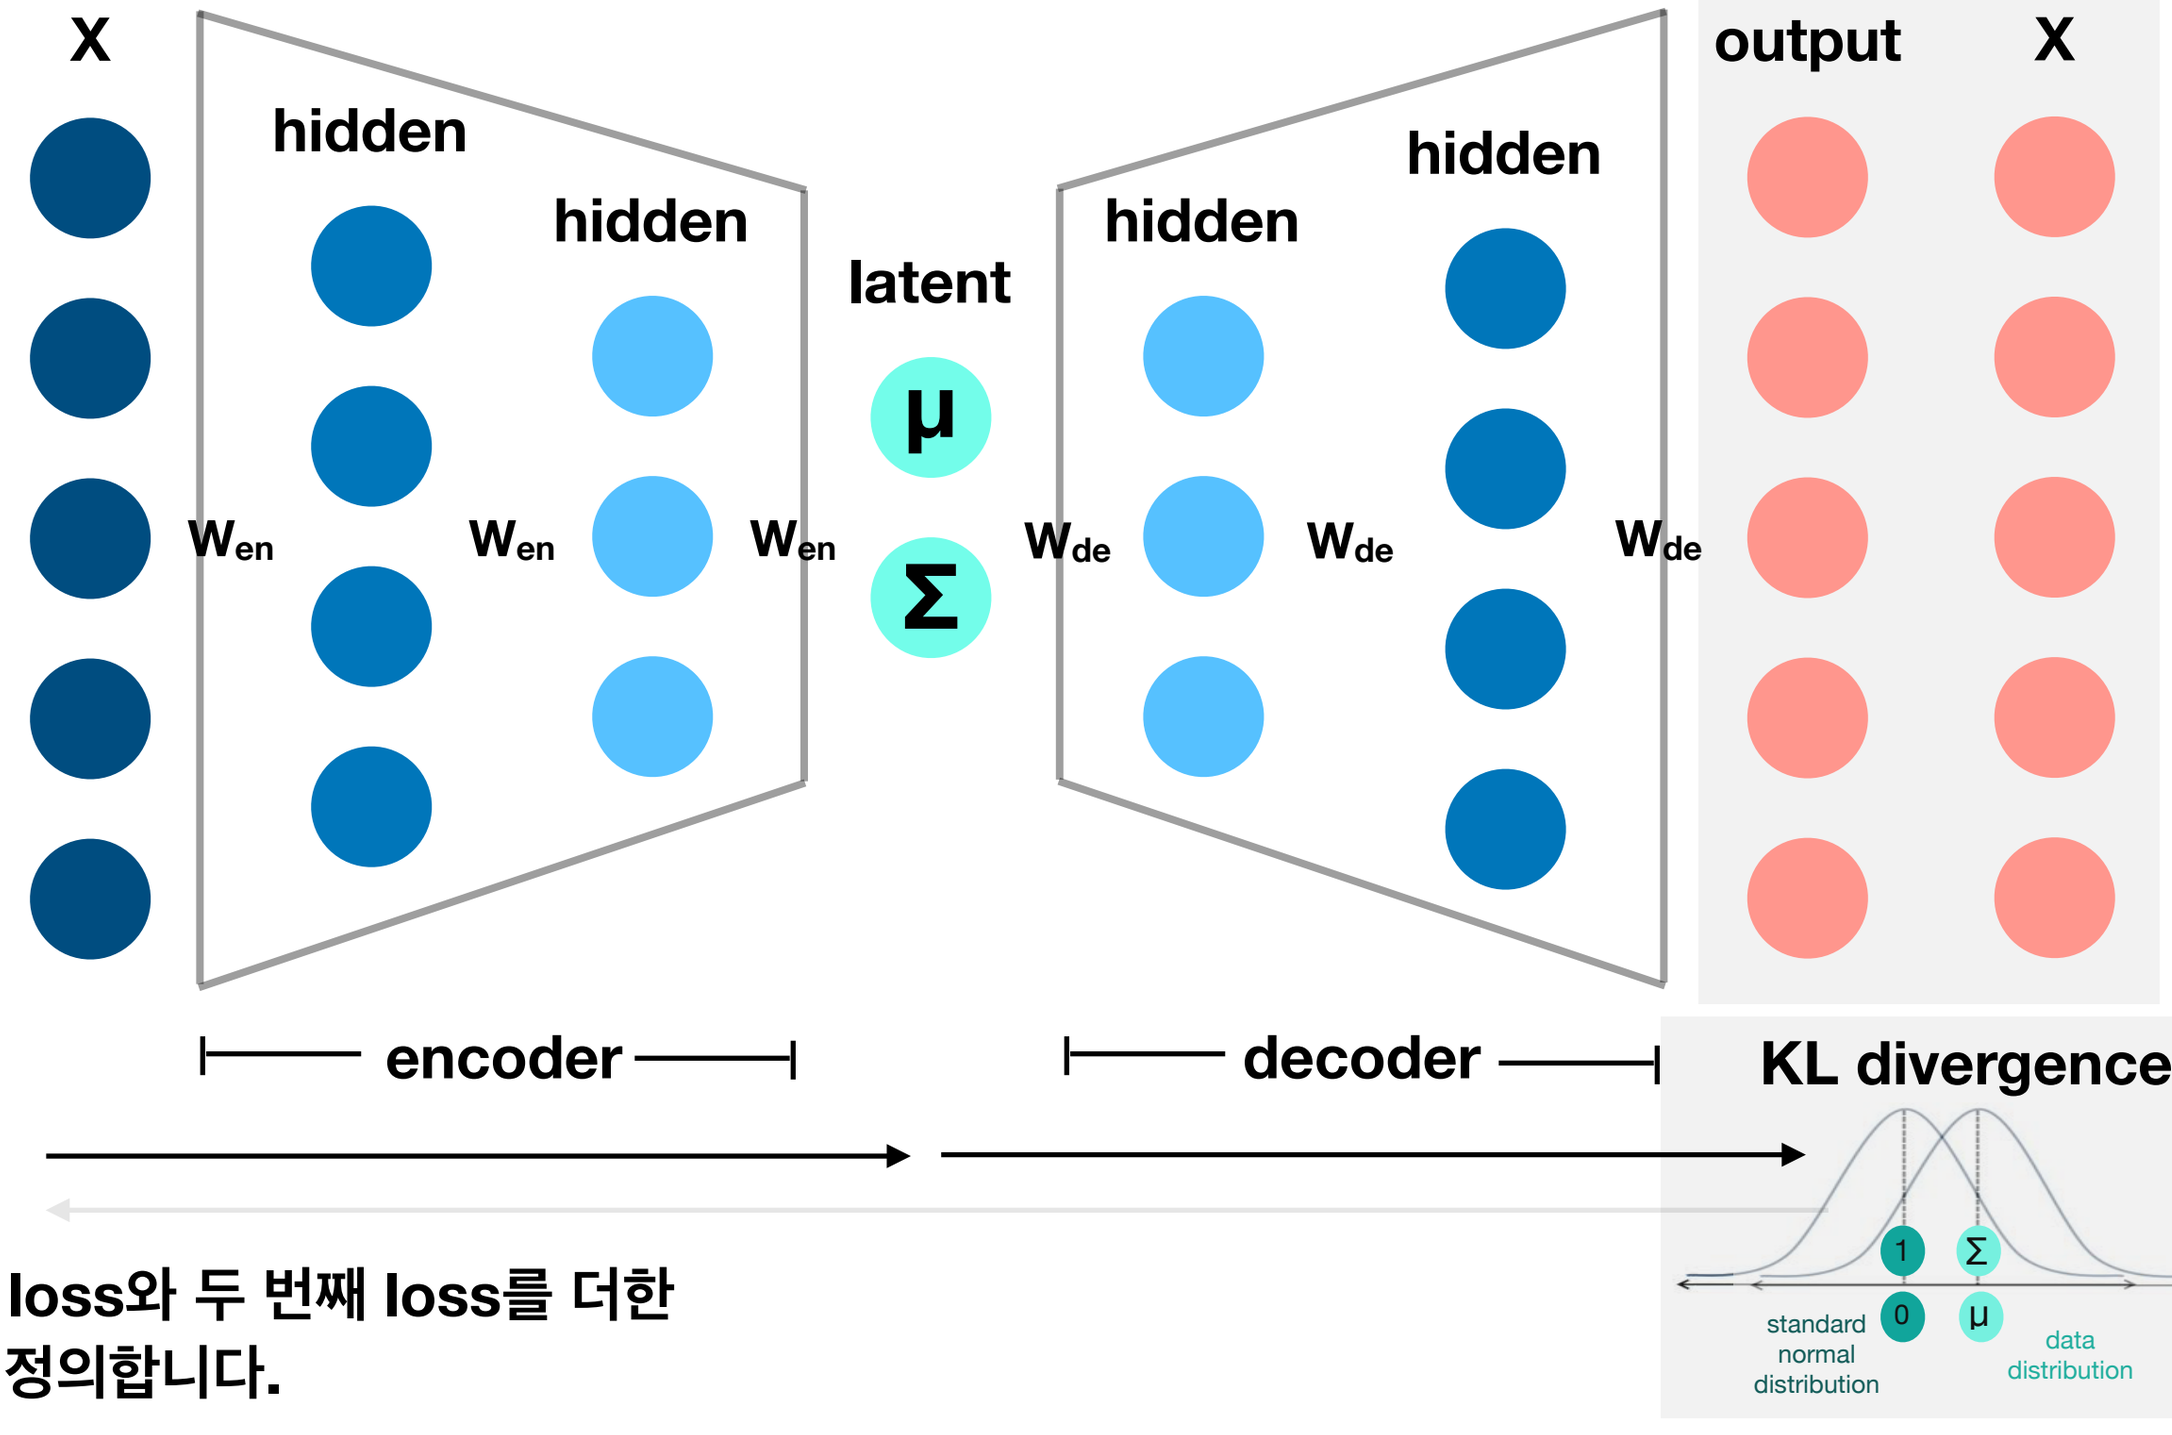

이제 첫 번째 loss와 두 번째 loss를 더한
전체 loss를 정의합니다.

Variational Autoencoder

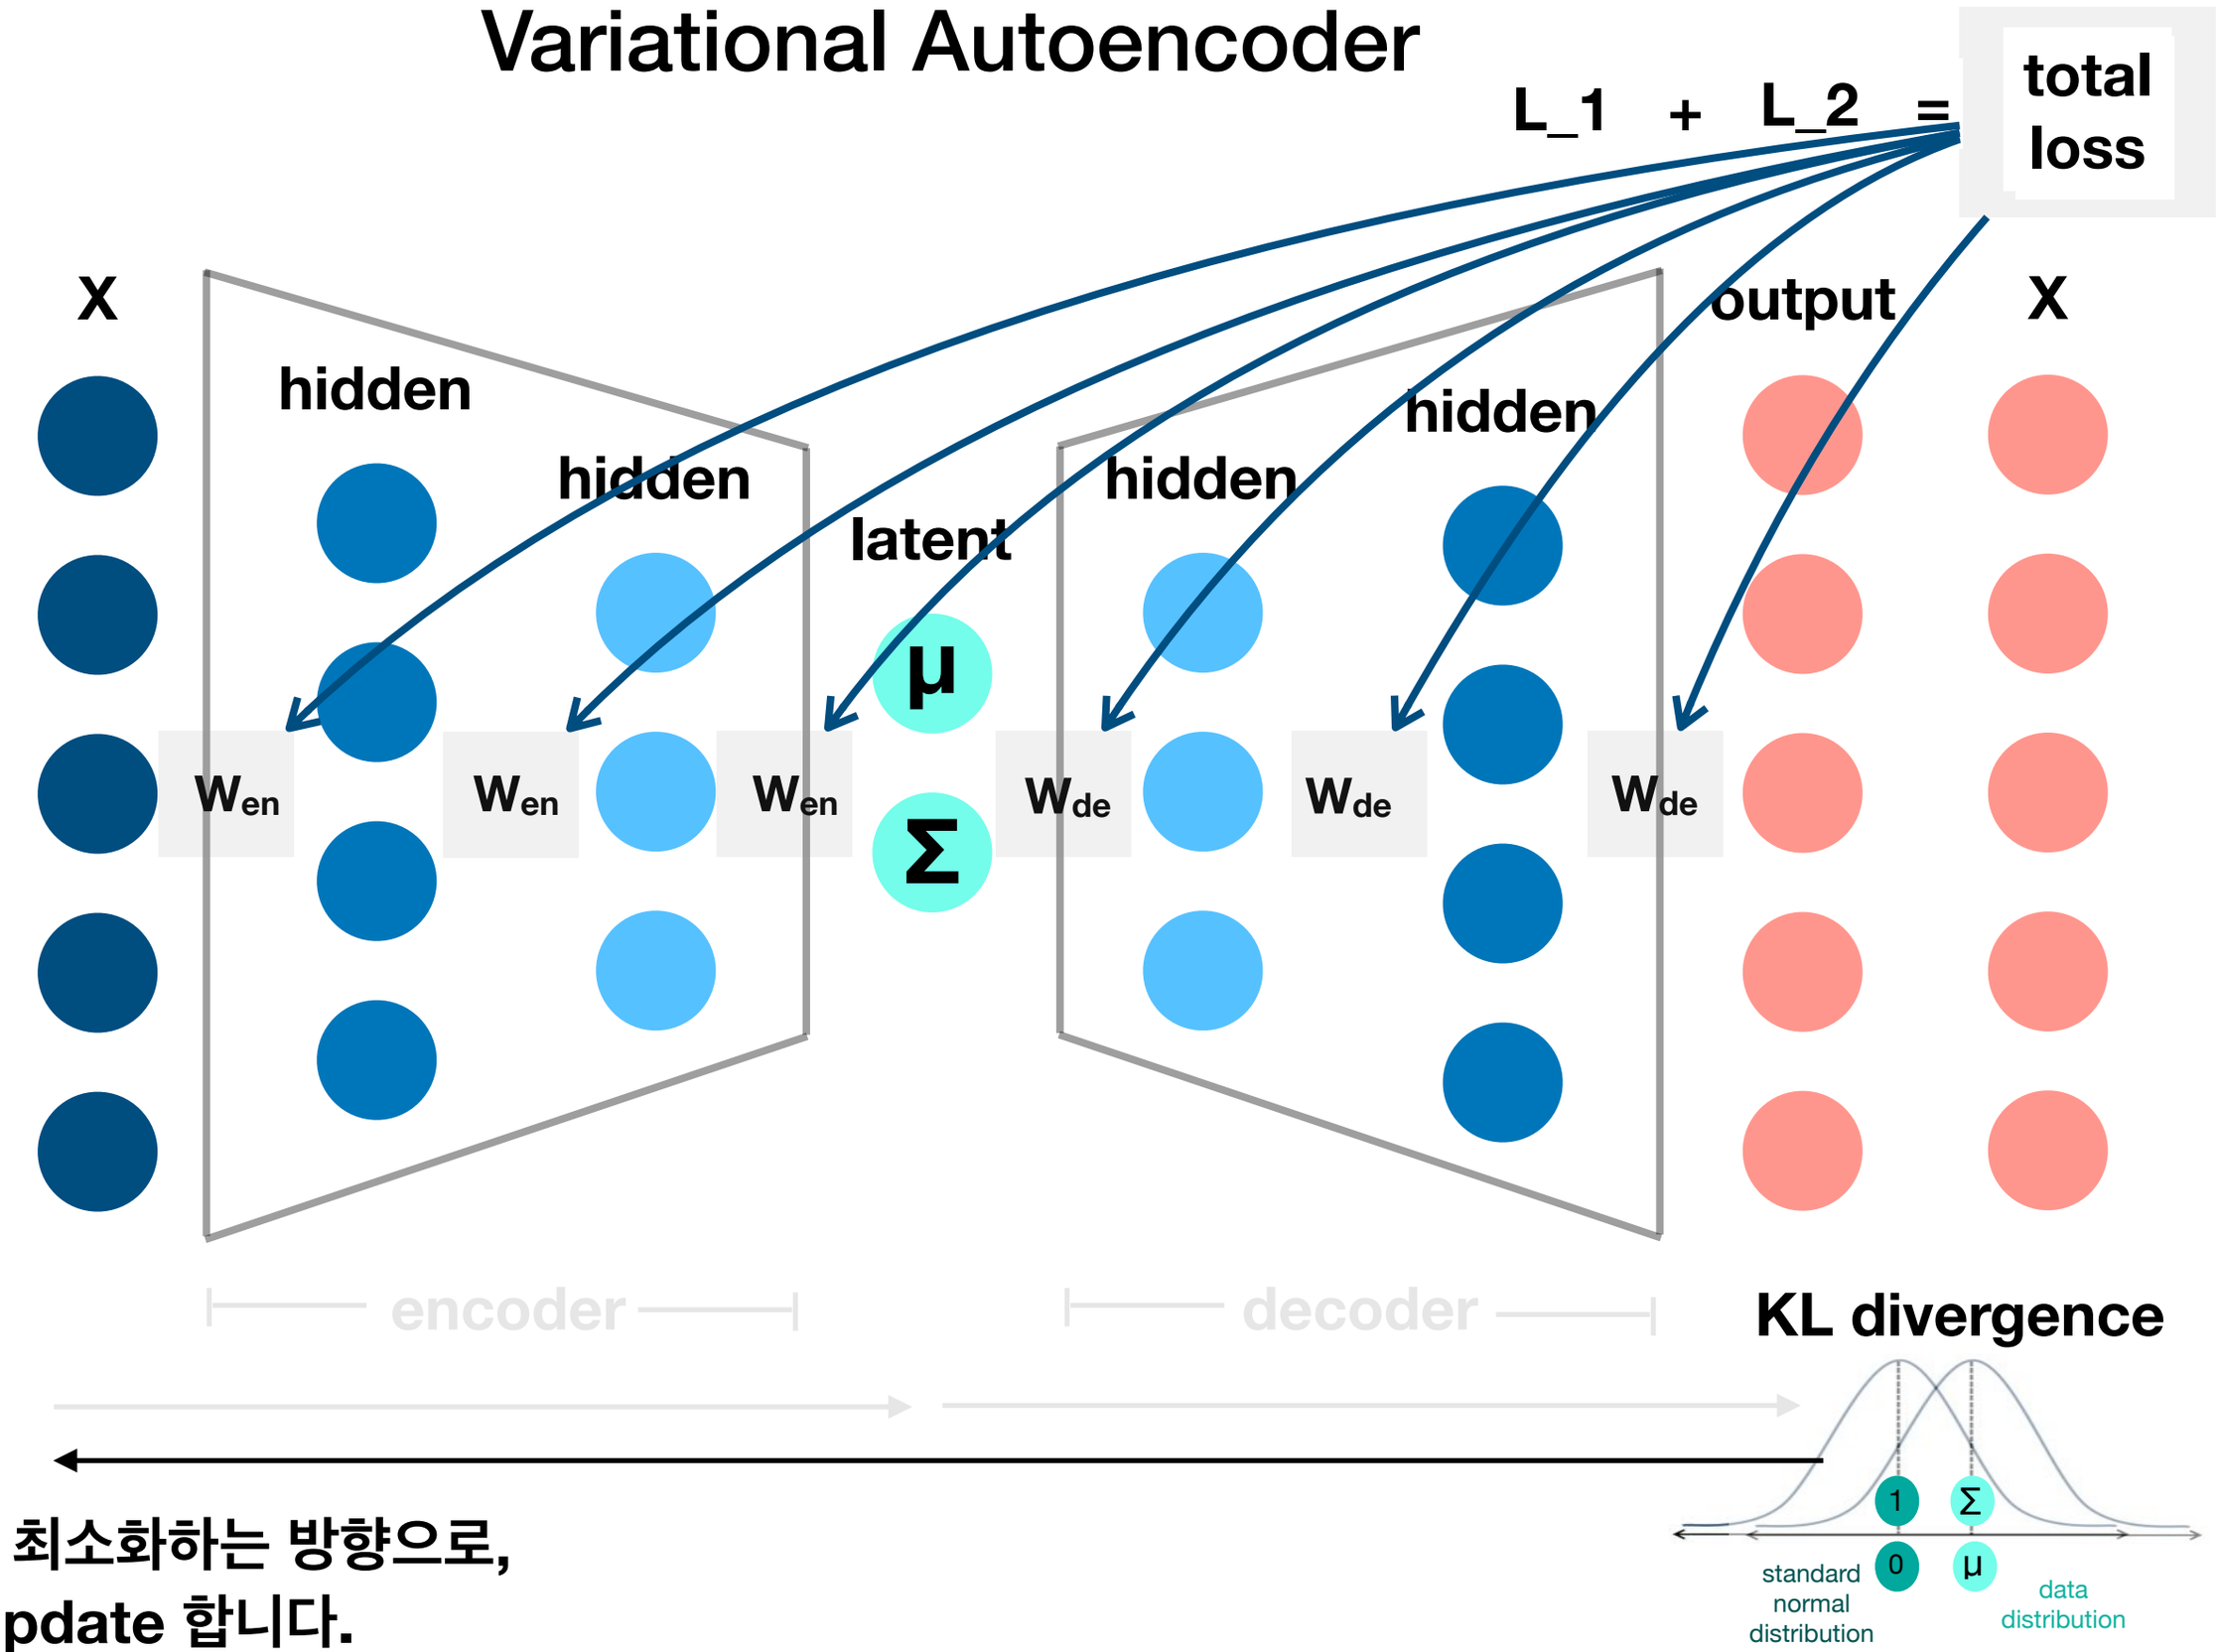

KL divergence

전체 loss를 최소화하는 방향으로,
weight을 update 합니다.

Variational Autoencoder

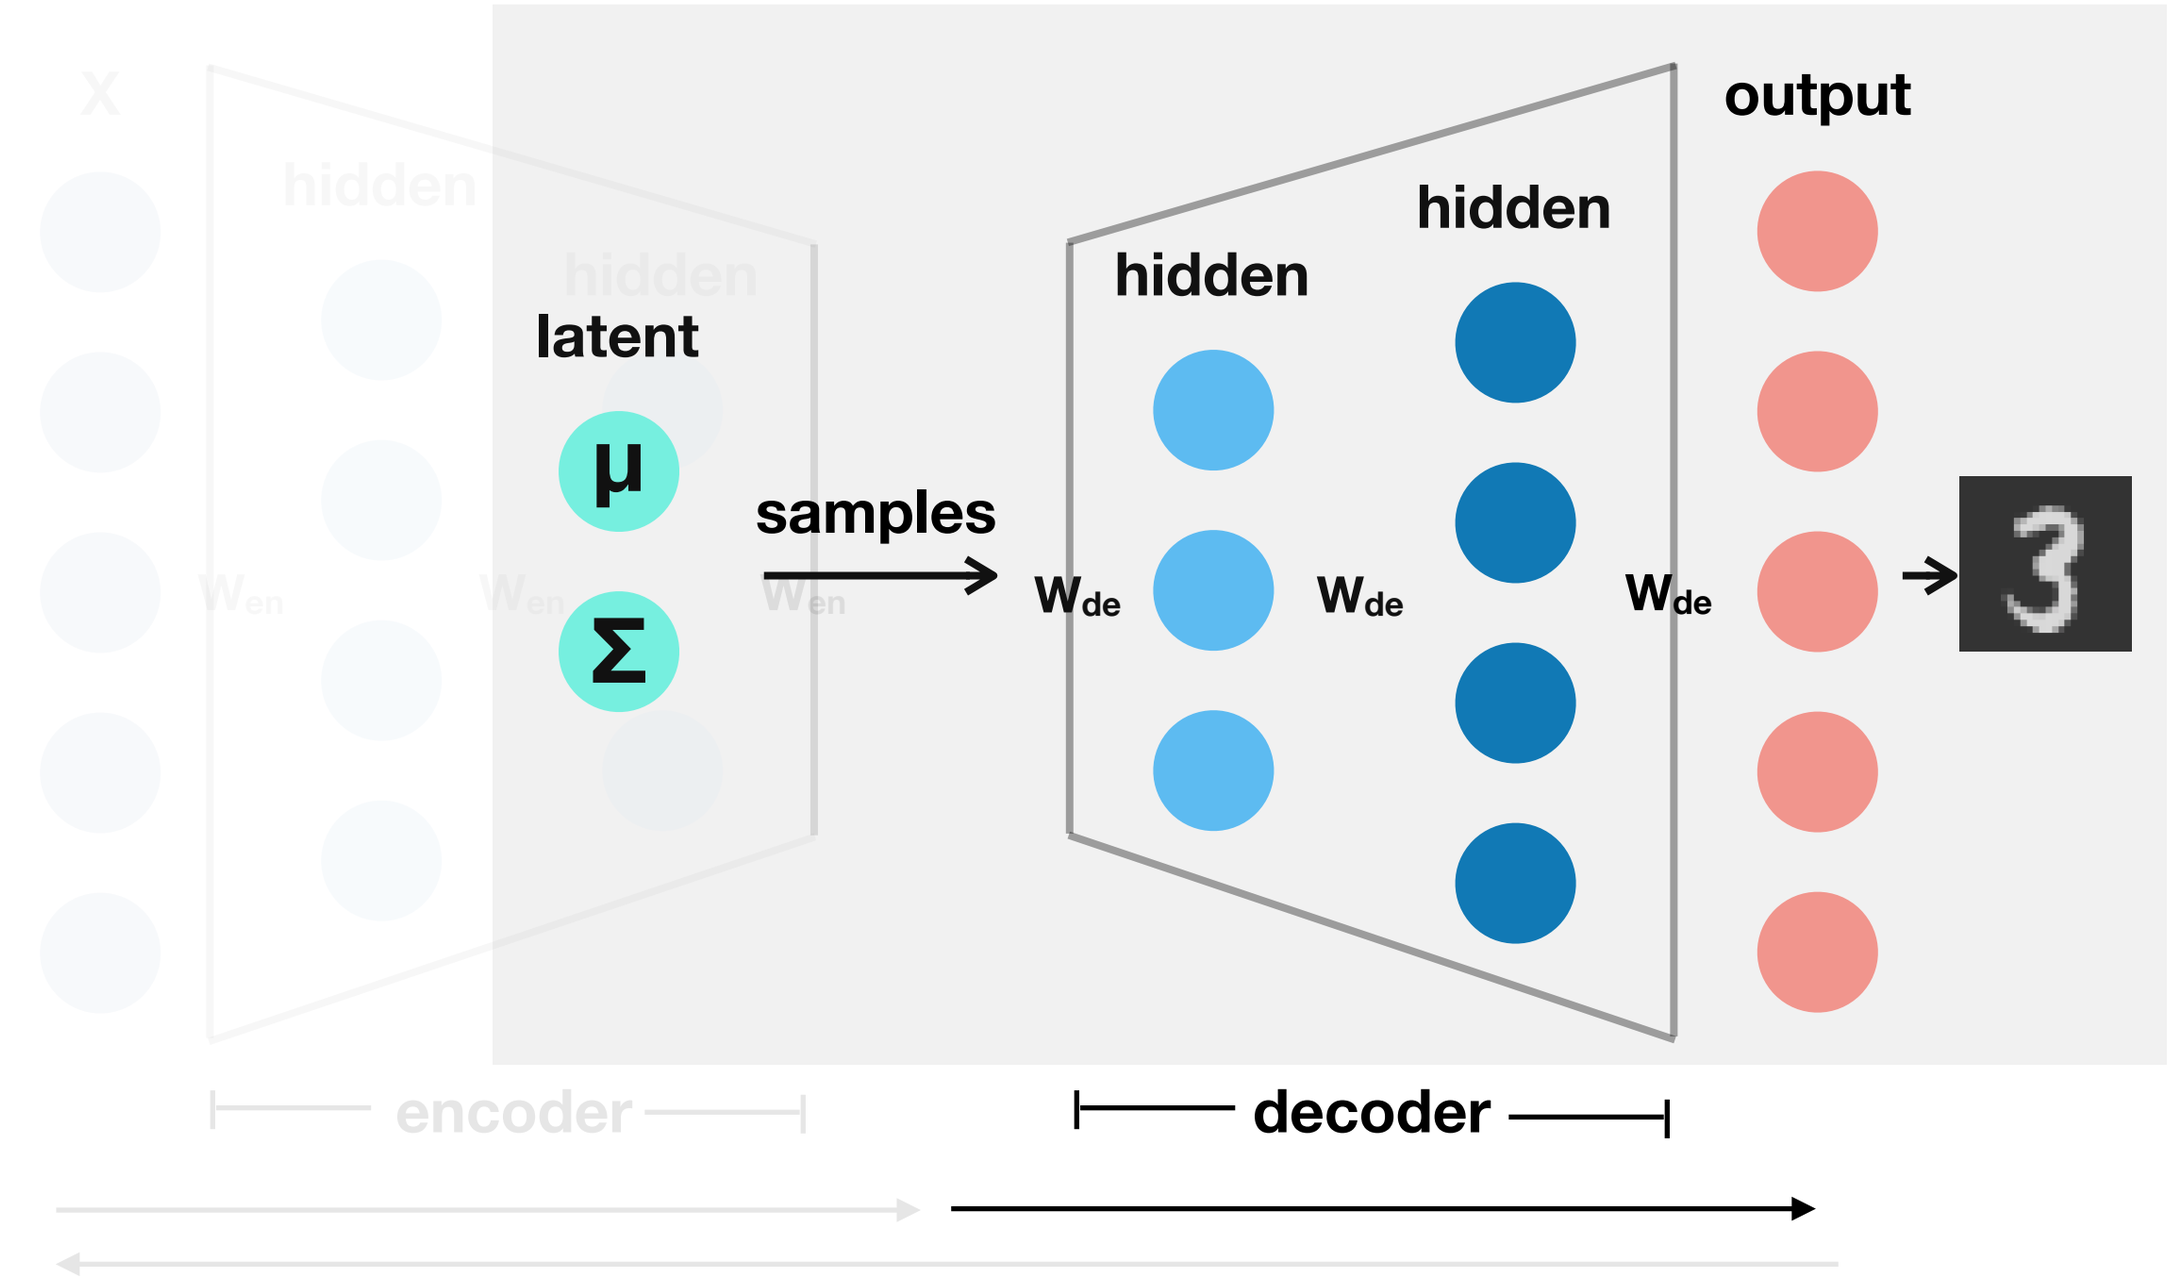

첫 번째 loss를 최소화함에 따라 latent layer 상의 데이터 분포는 점차 정규 분포가 되어가므로,
훈련 후에 latent layer의 정규 분포에서 random한 값을 뽑아 decoder에 넣으면
진짜 같은 이미지가 만들어집니다.

GAN

DCGAN

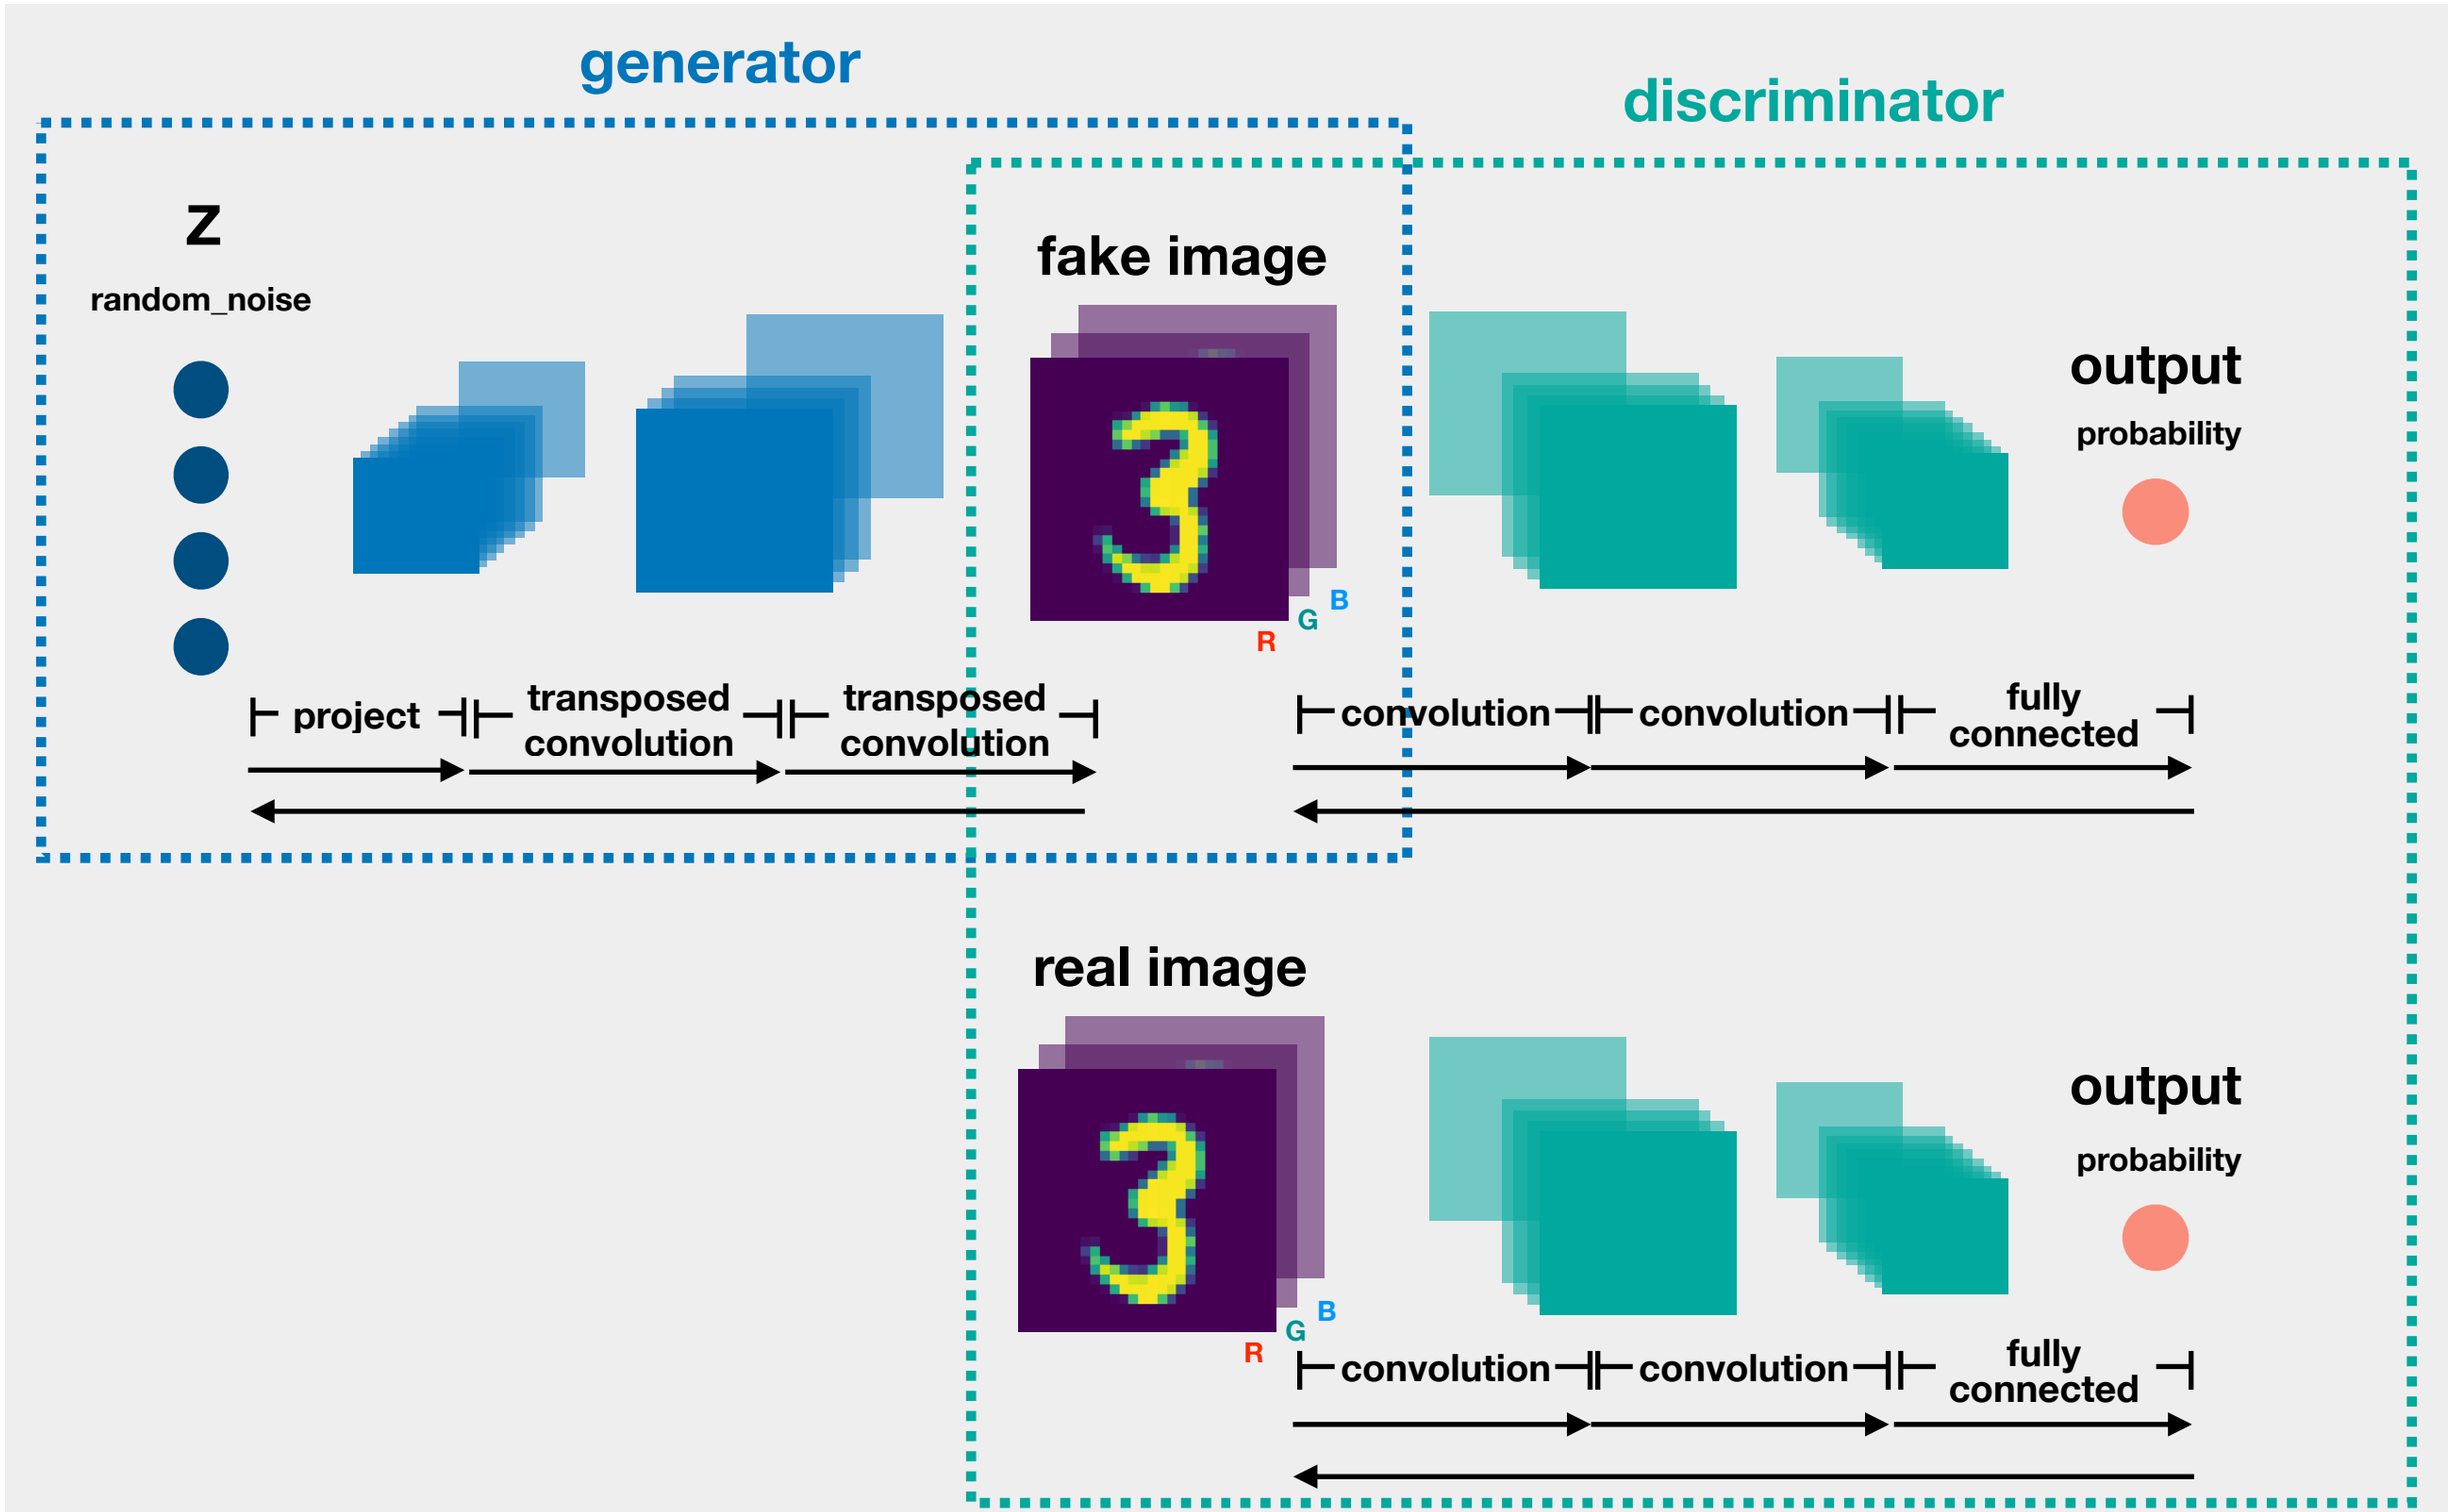

GAN은 두 부분으로 나뉩니다.

DCGAN

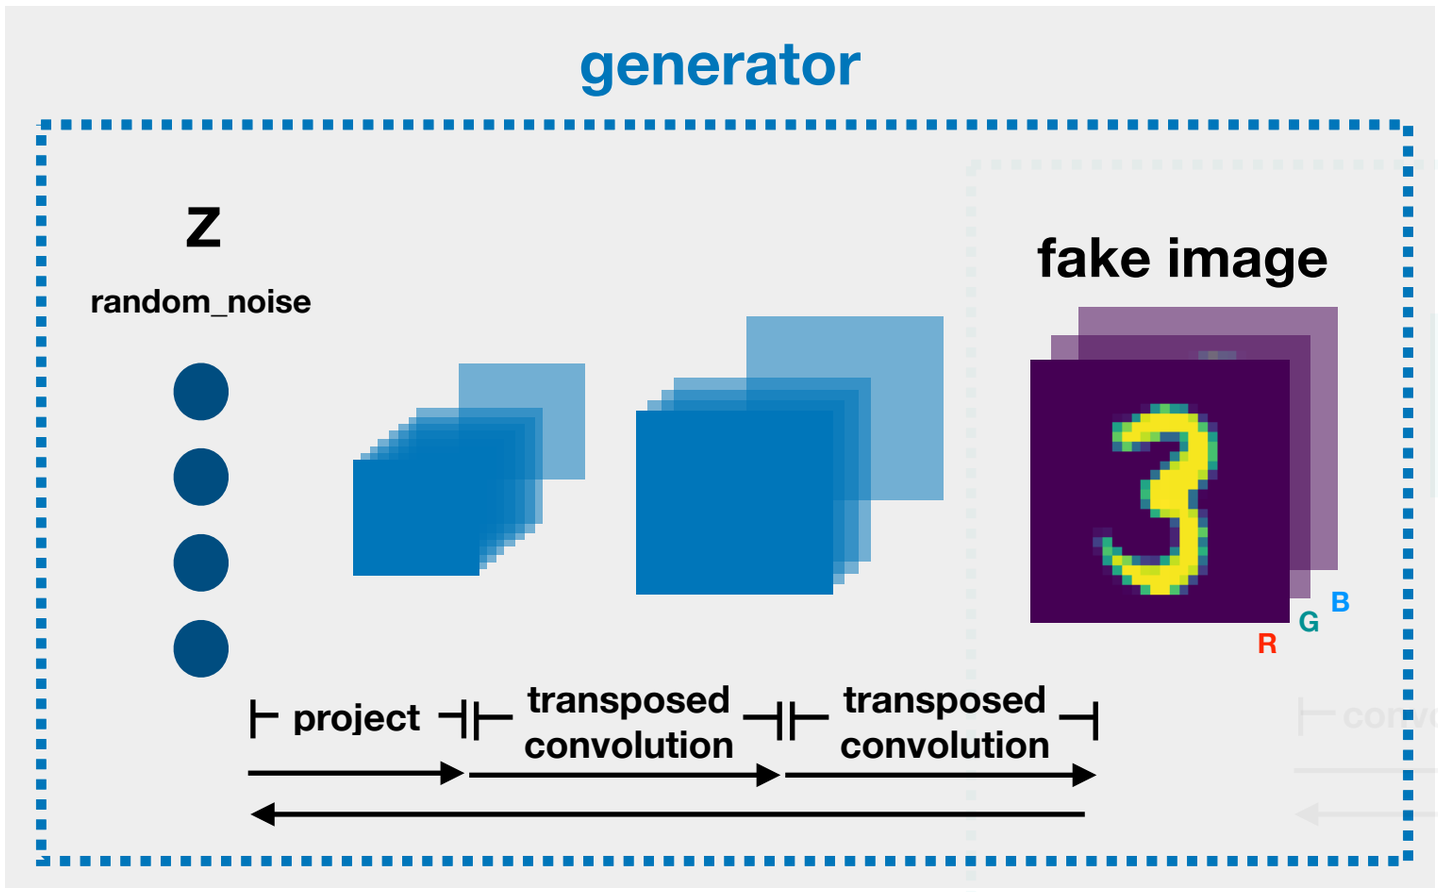

generator는 임의의 숫자 vector로부터 진짜 같은 이미지를 만듭니다.

DCGAN

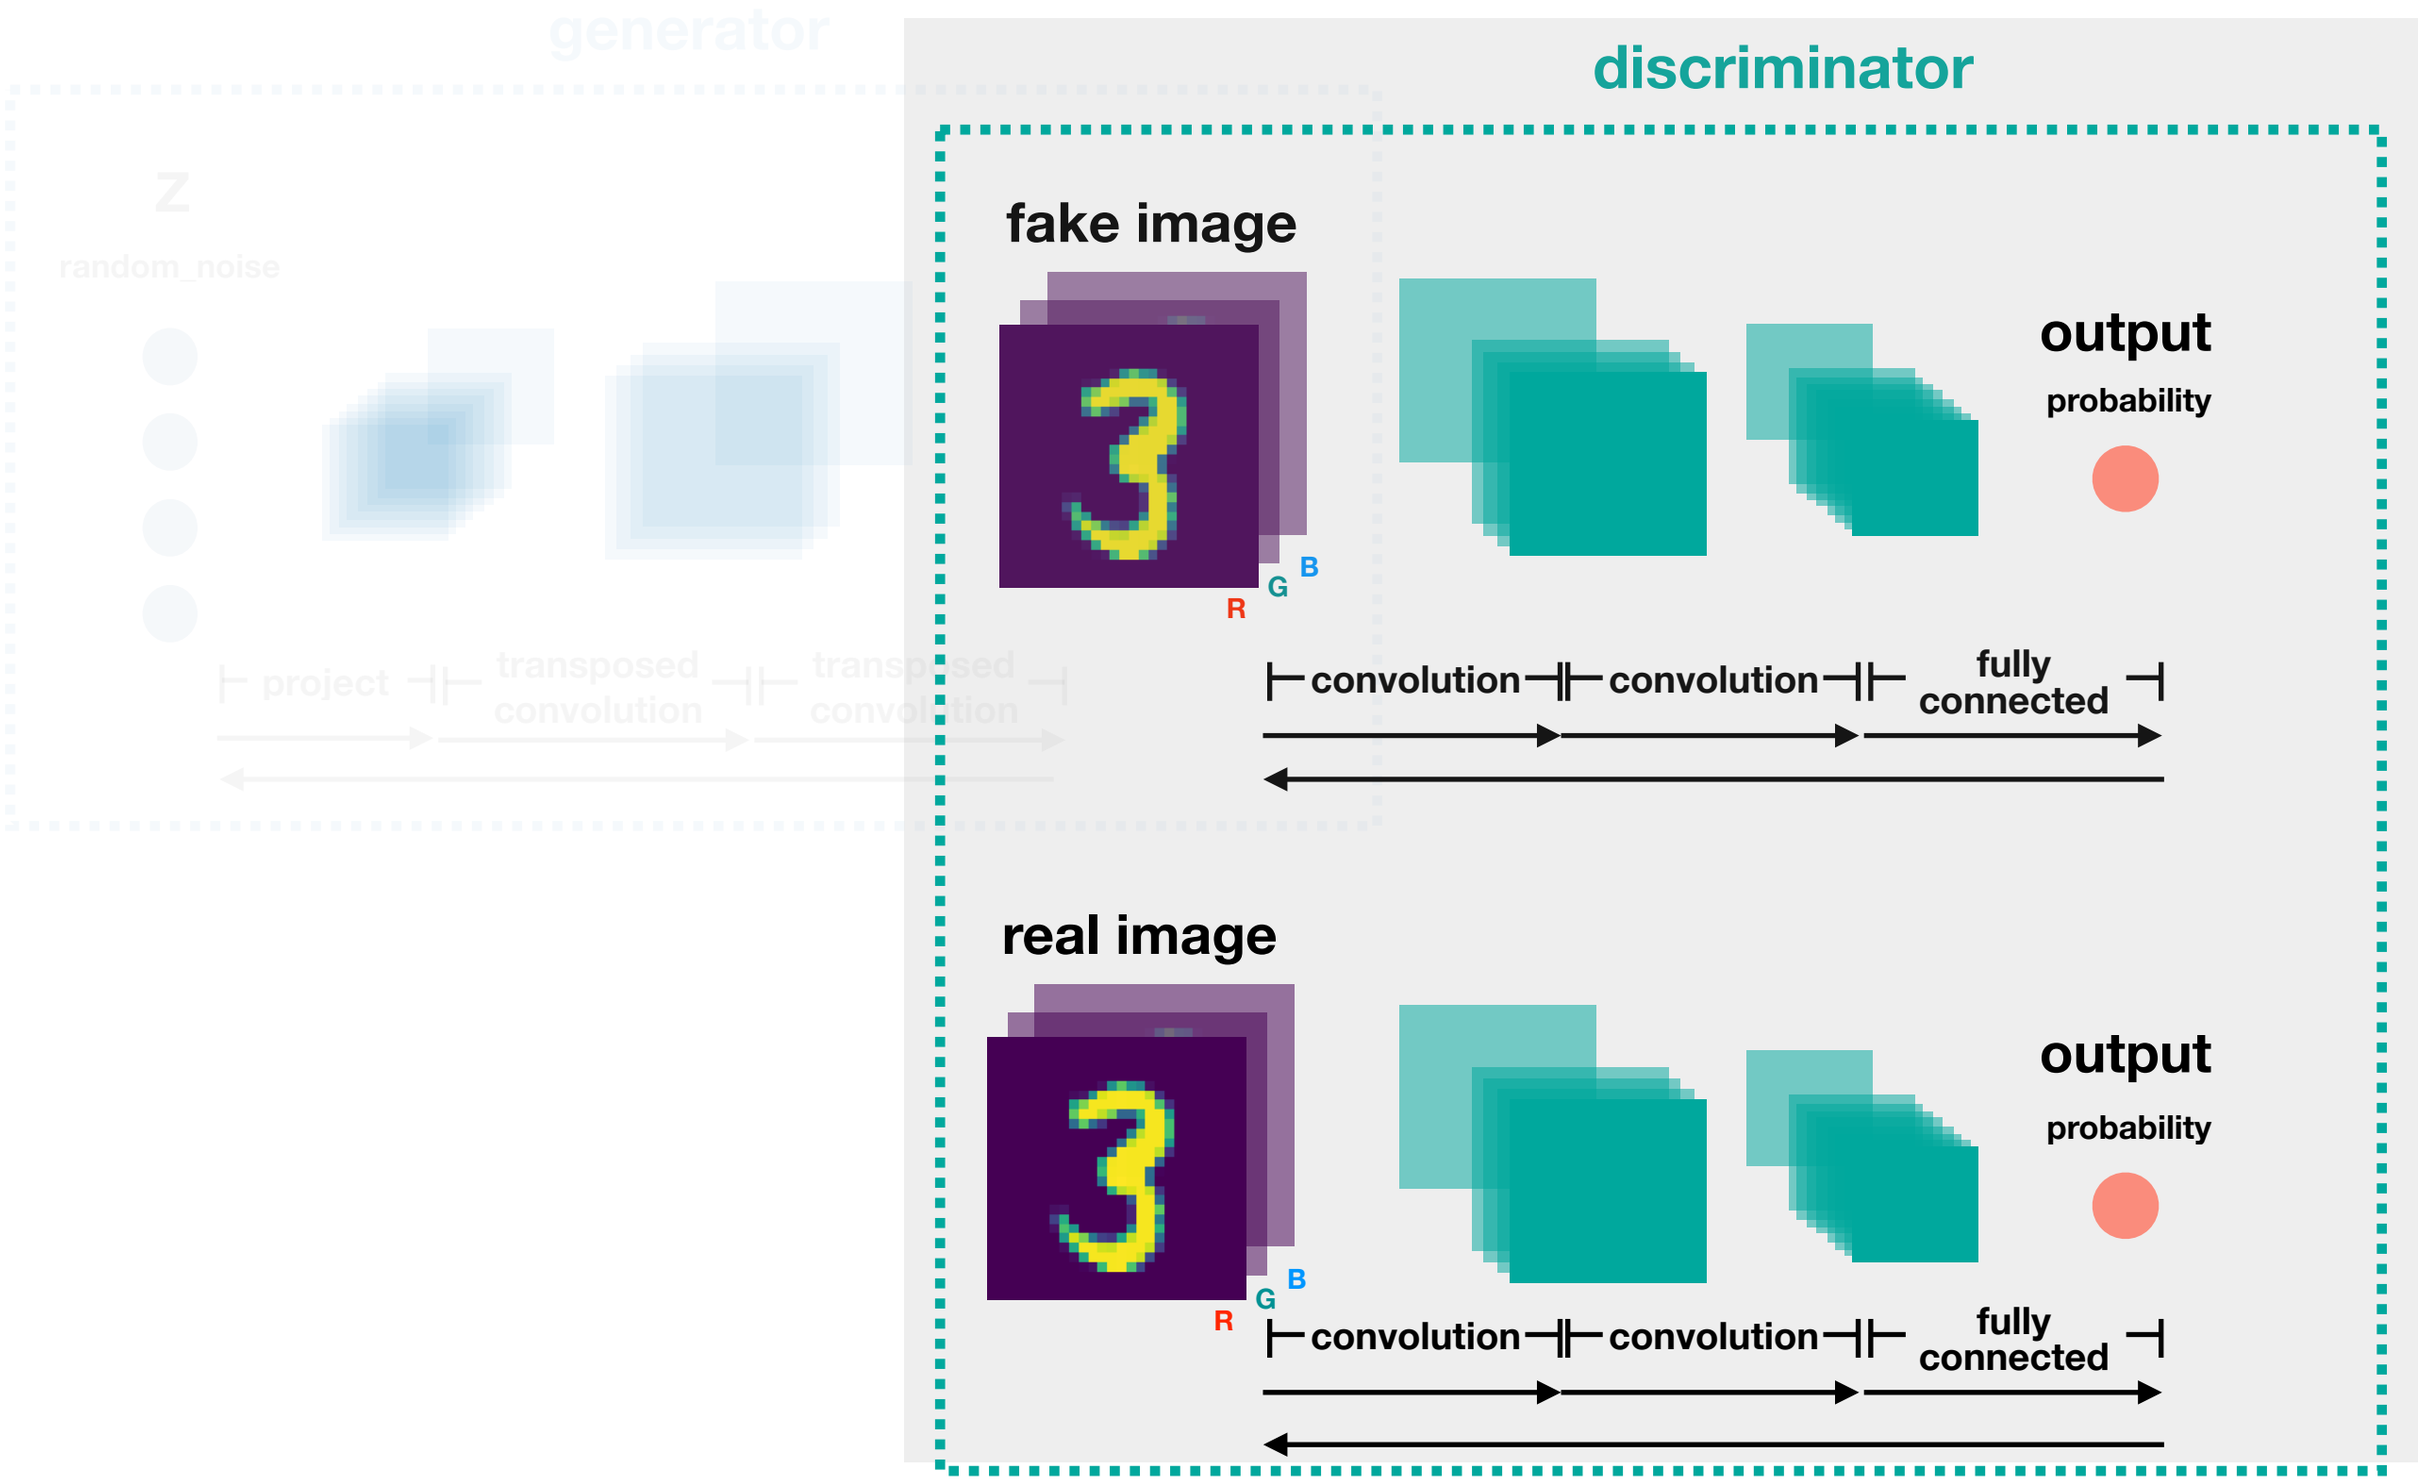

discriminator는 이미지를 input으로 받아서 그것이 진짜 이미지로 인식될 확률을 계산합니다.
generator가 만들어낸 가짜 이미지라면 0, 실제 데이터에서 온 진짜 이미지라면 1이라고 판단합니다.

DCGAN

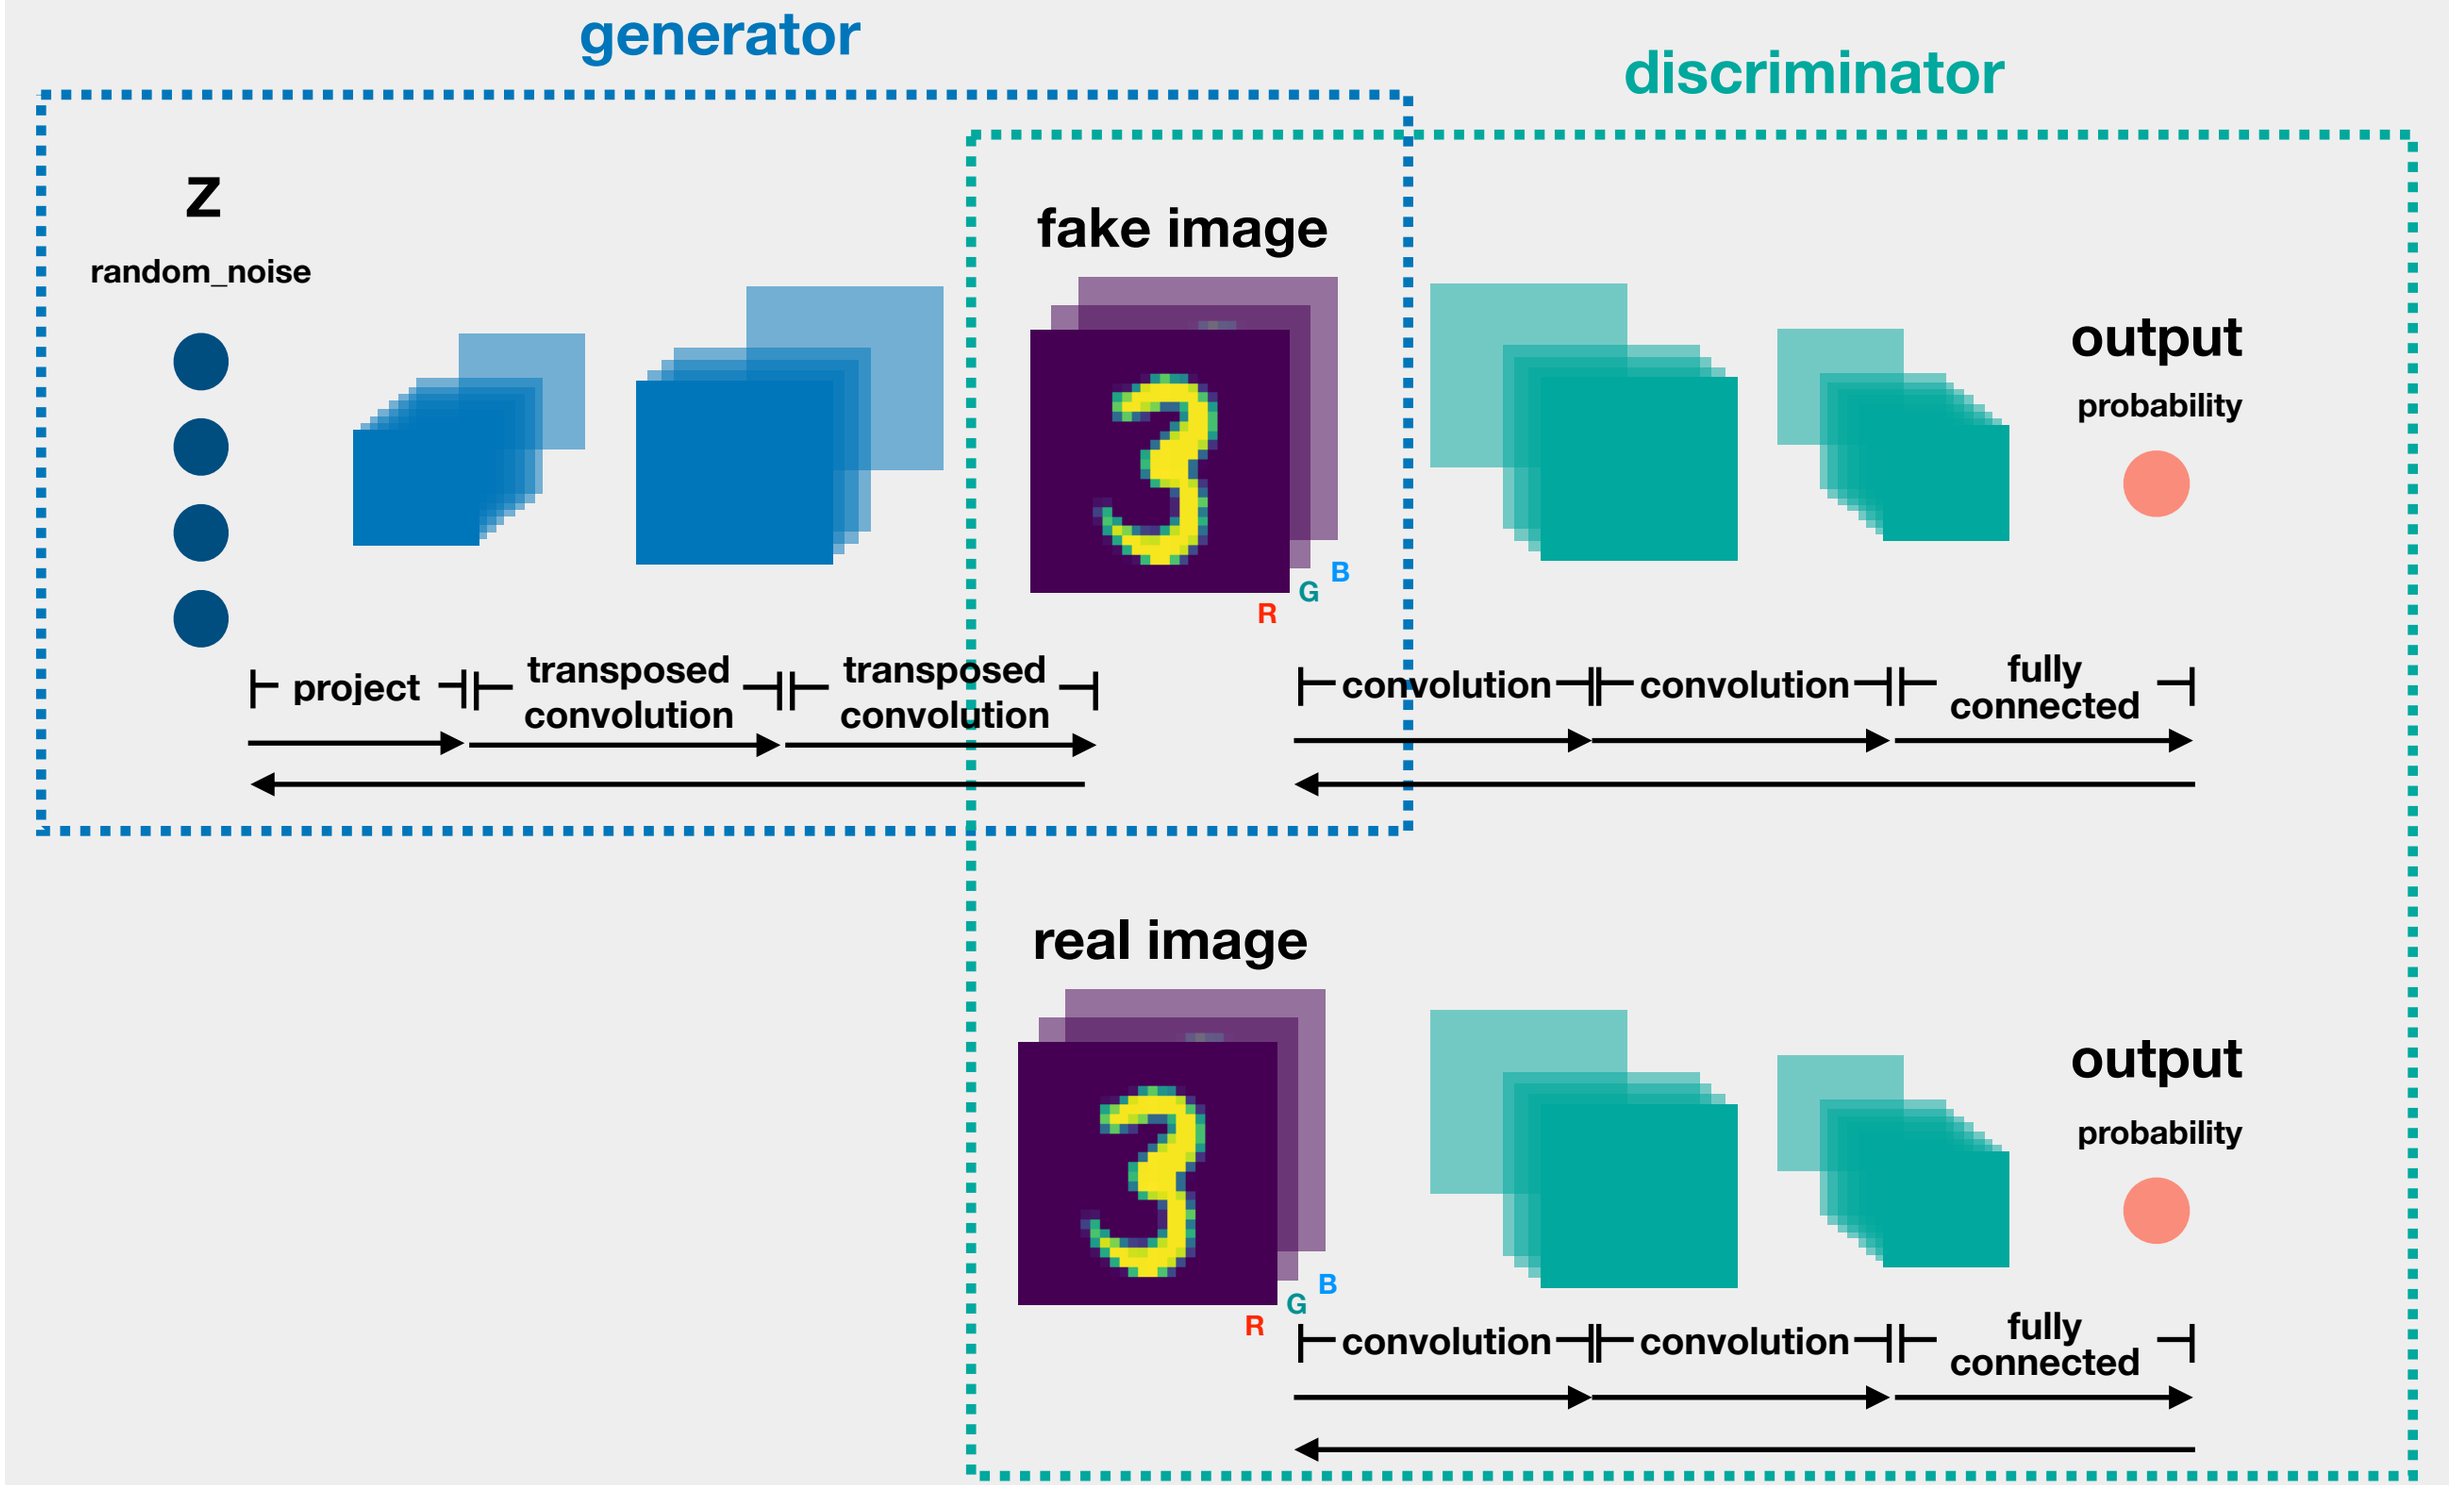

GAN의 훈련과정을 살펴봅시다.

DCGAN

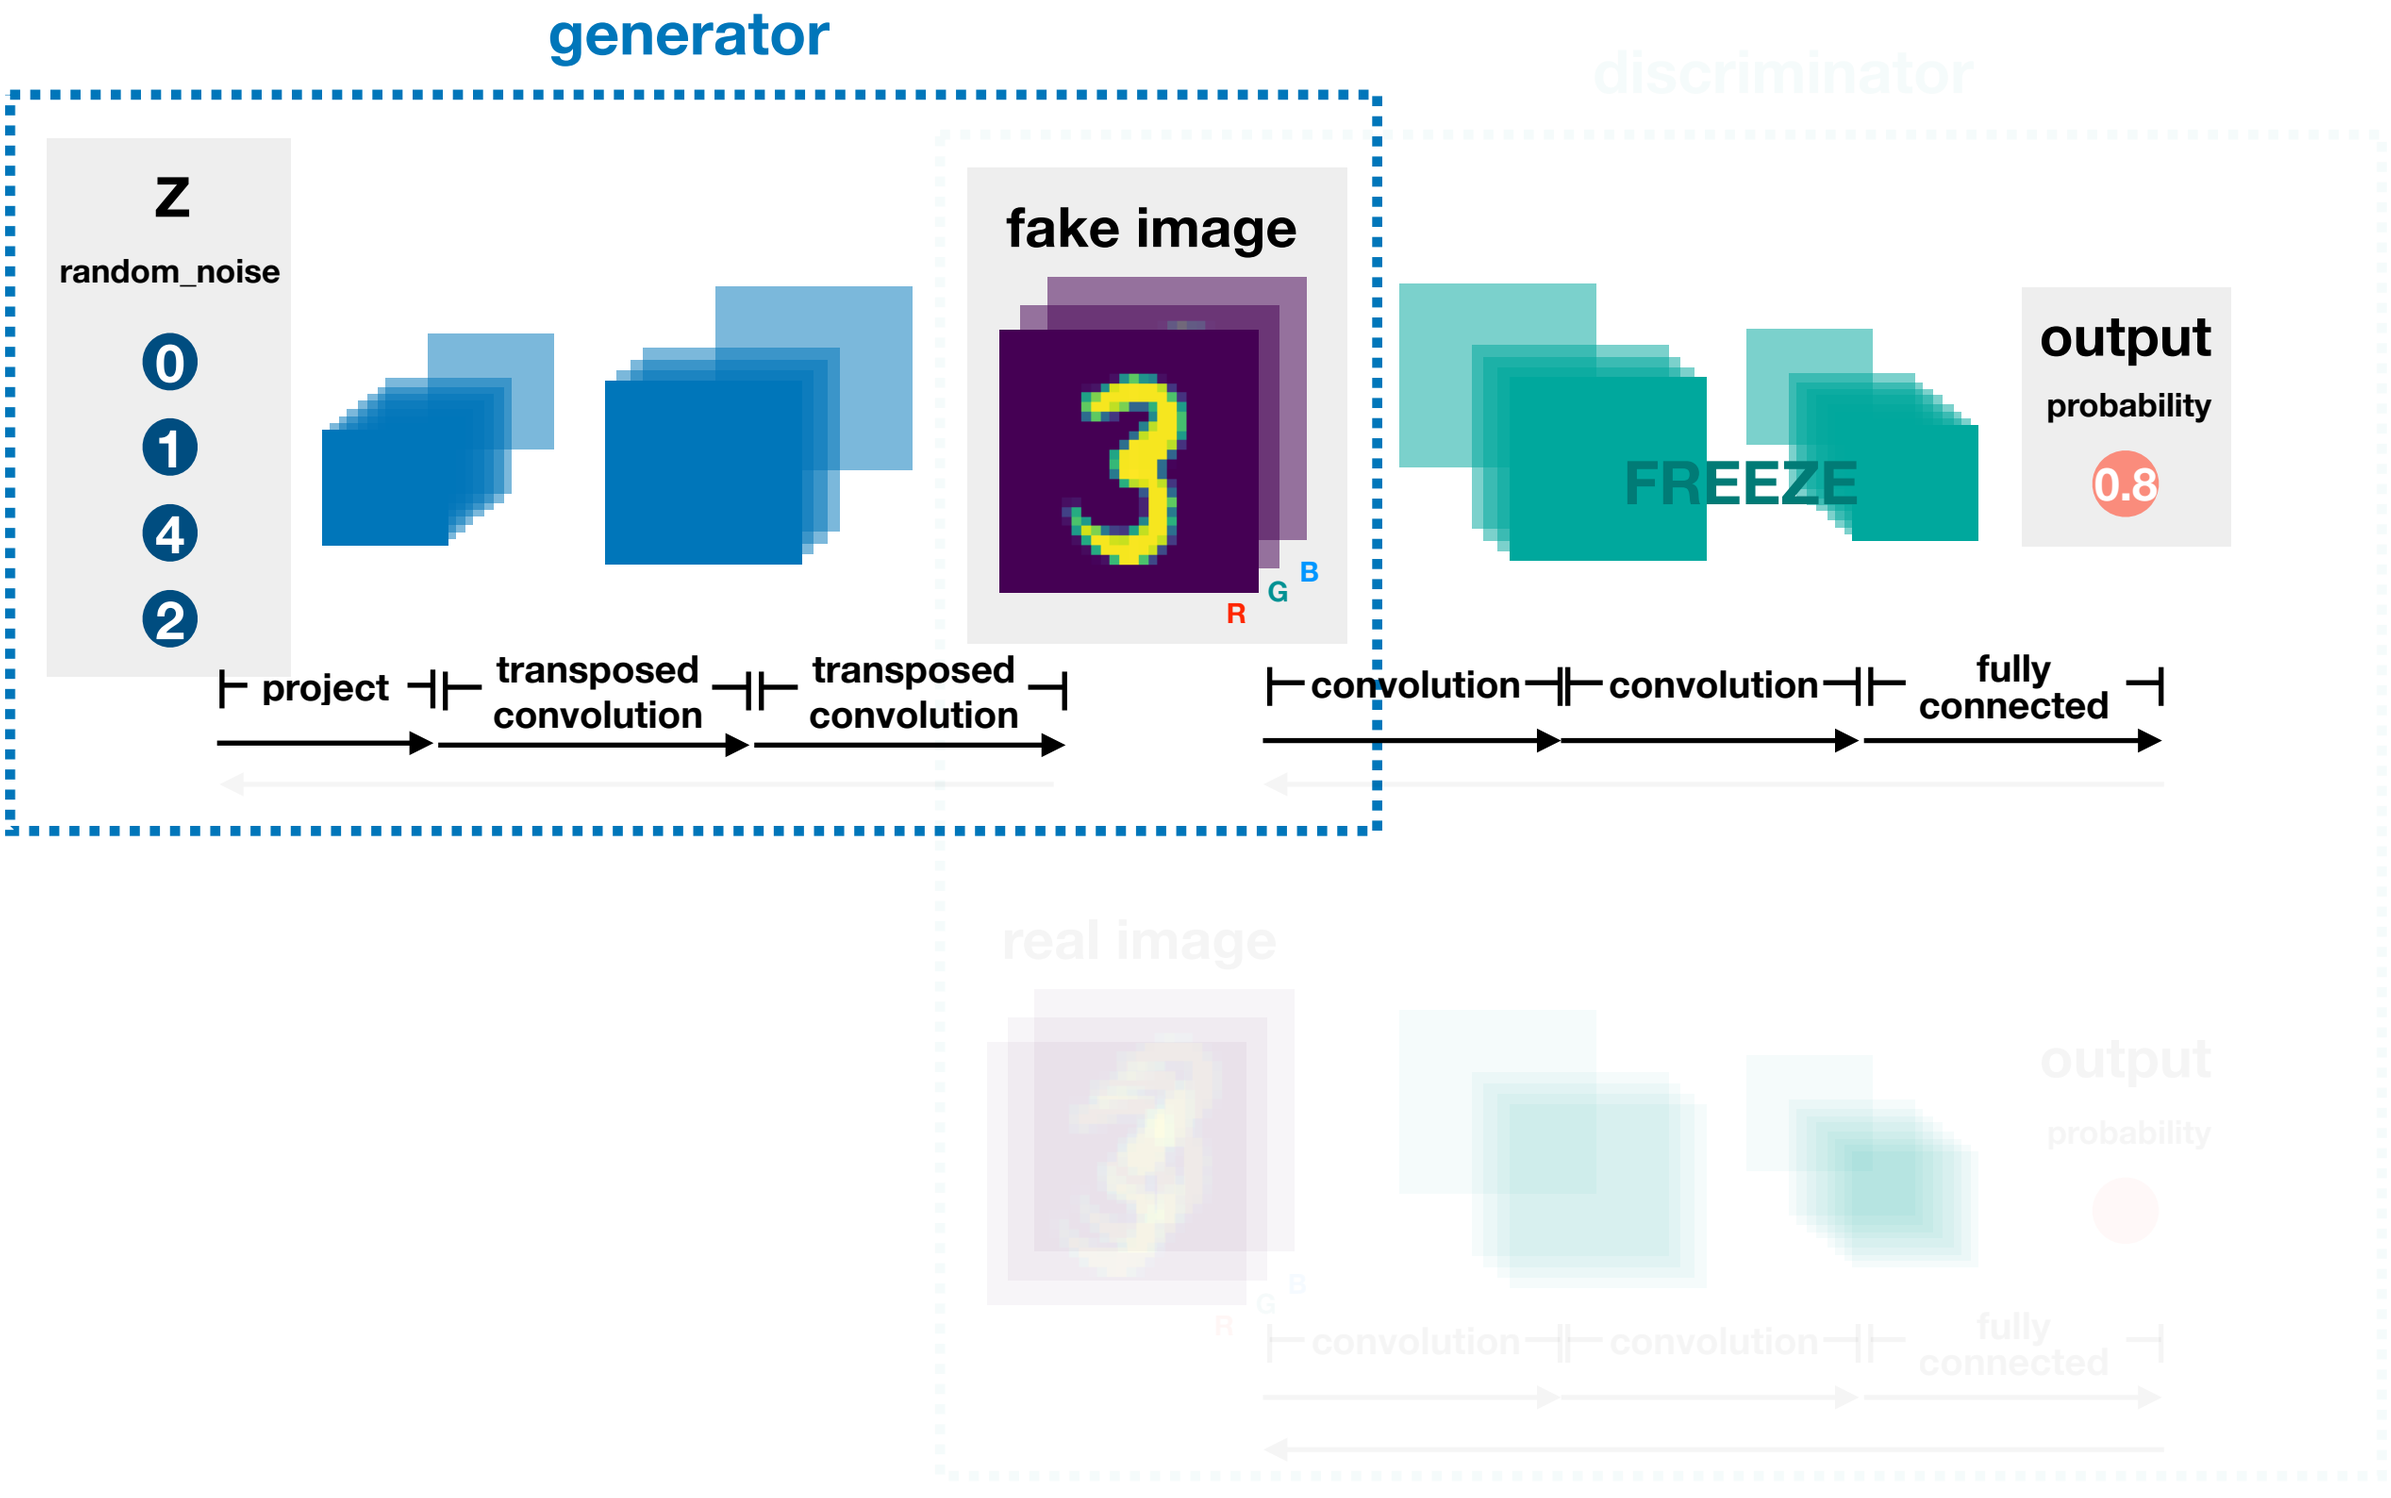

generator에 Z를 넣어 가짜 이미지를 만들어내고,
discriminator를 통해 가짜 이미지가 진짜로 인식될 확률을 구합니다.

DCGAN

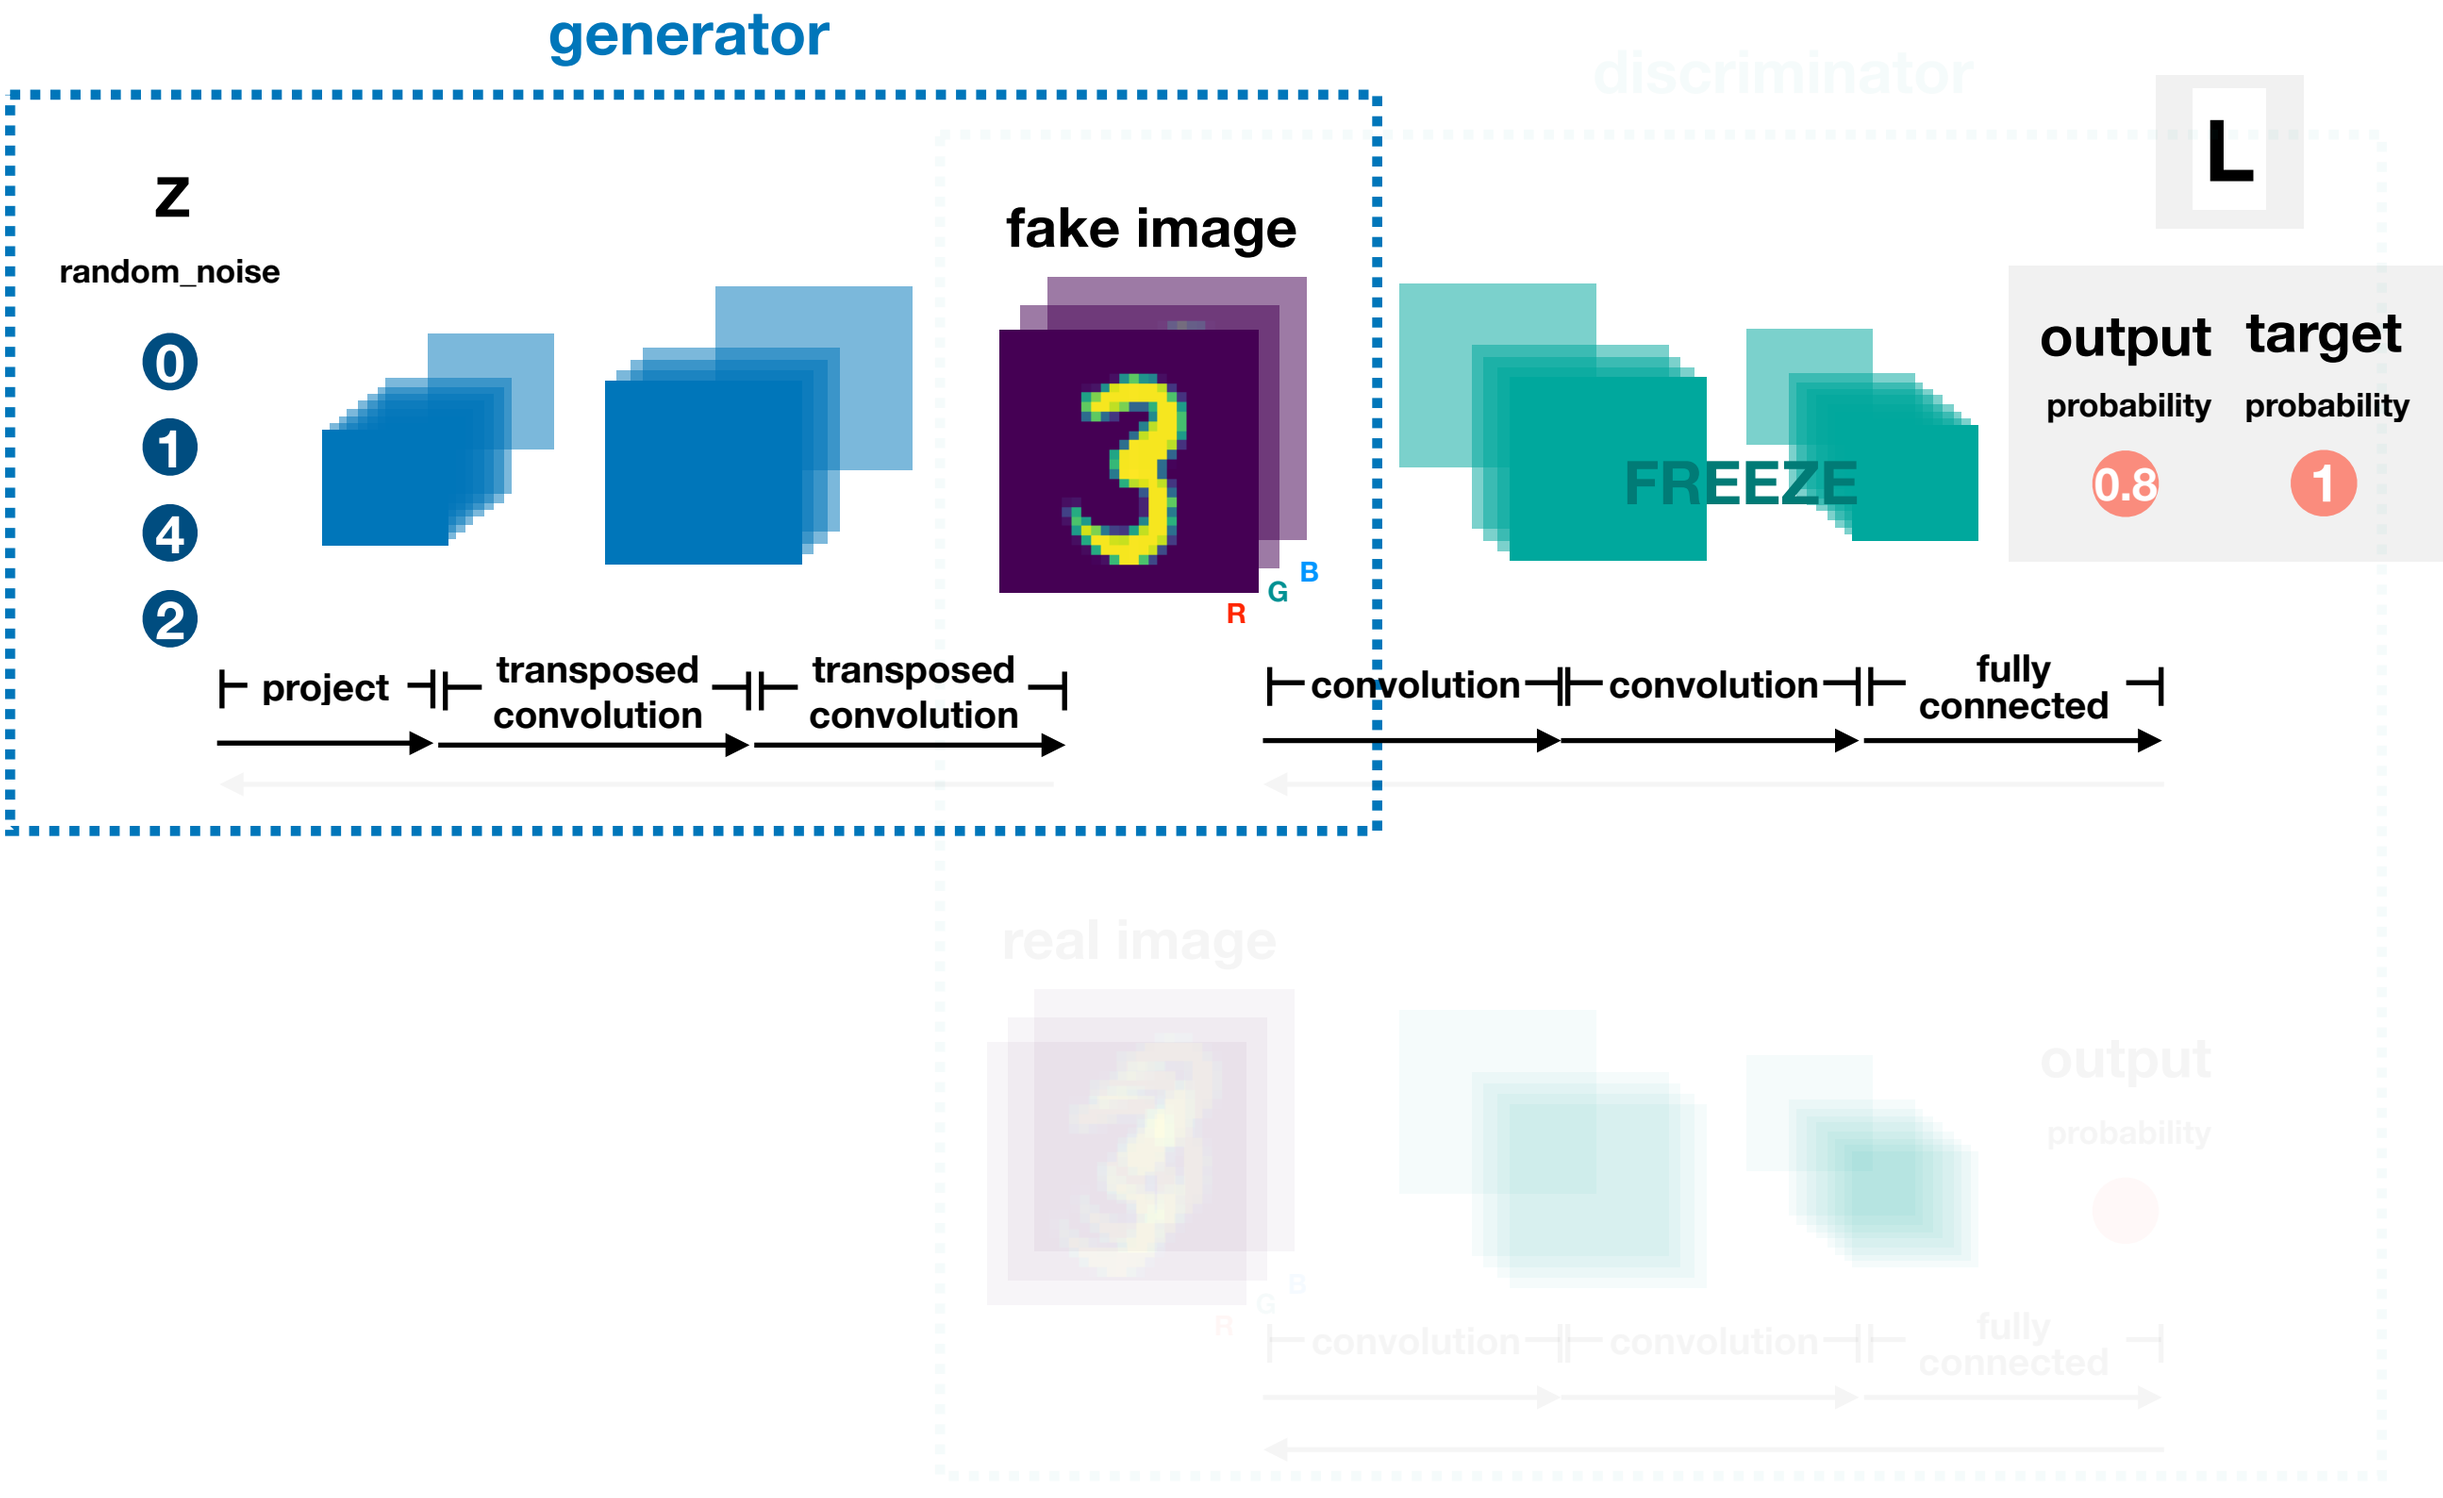

generator의 목적이 진짜 같은 이미지를 만드는 것이므로 target은 1입니다.
output과 정답 target (1)을 비교하여 loss를 구합니다.

DCGAN

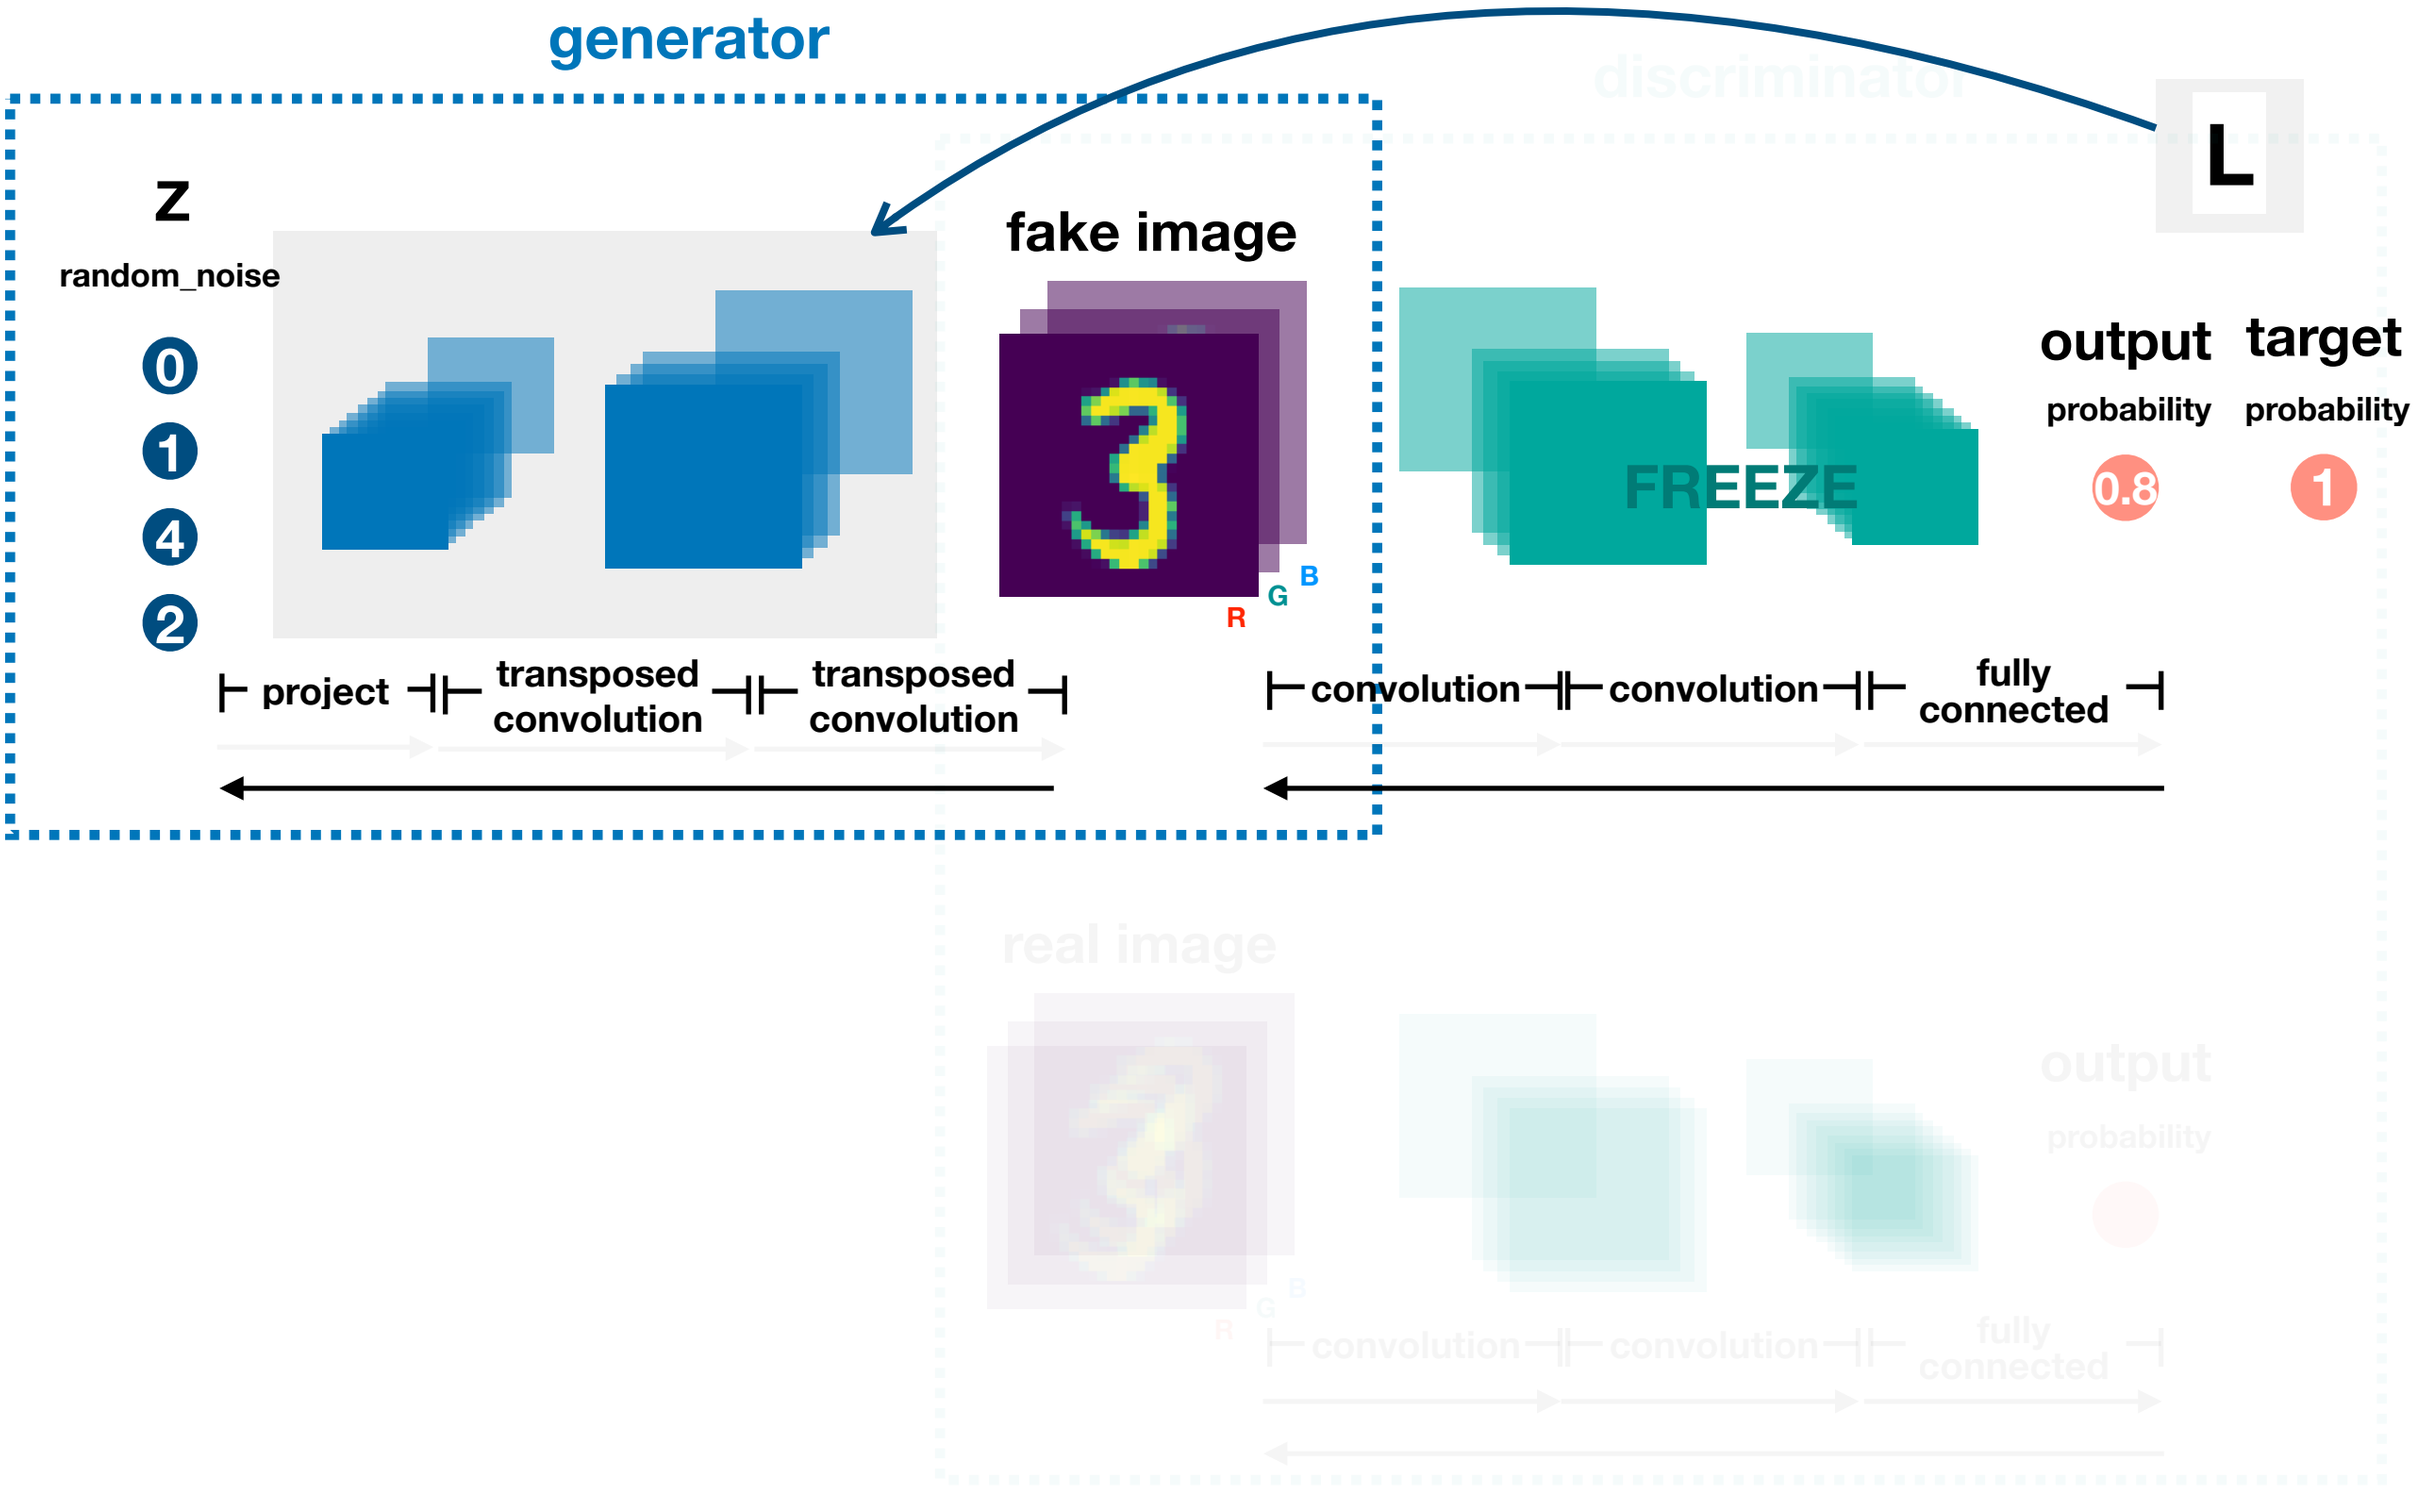

loss를 최소화하는 방향으로, weight을 update 합니다.

DCGAN

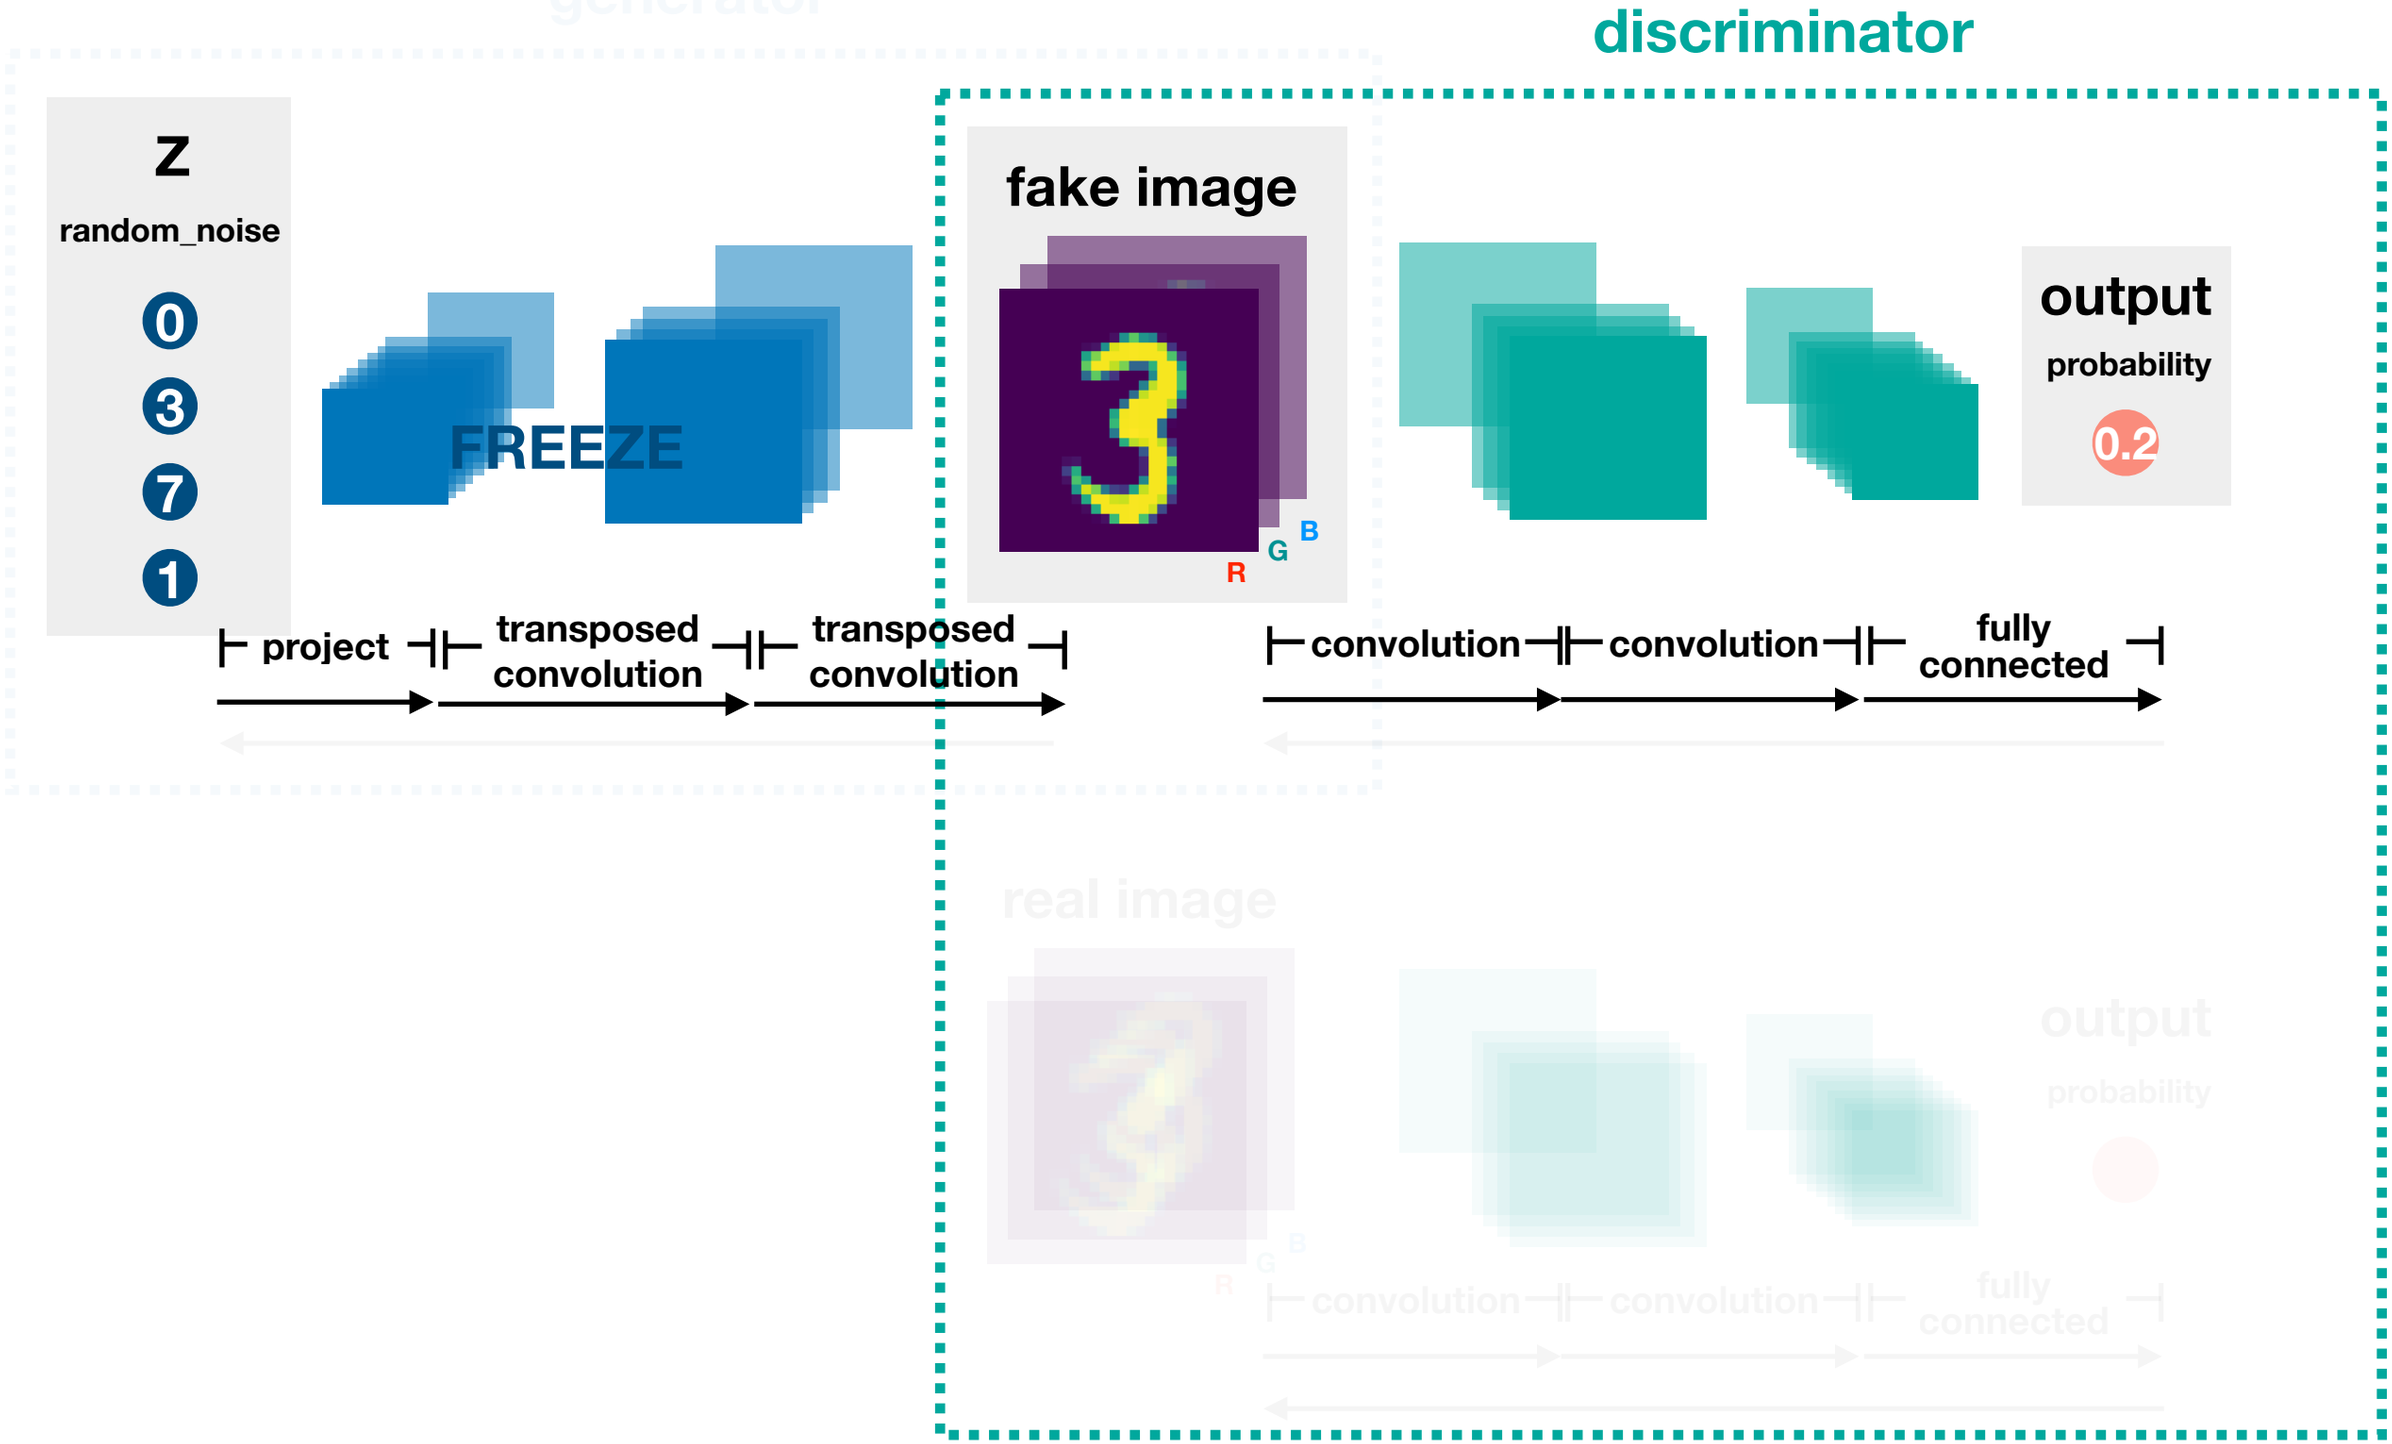

이번엔 discriminator 차례입니다. generator에 z를 넣어 가짜 이미지를 만들어내고, discriminator를 통해 가짜 이미지가 진짜로 인식될 확률을 구합니다.

DCGAN

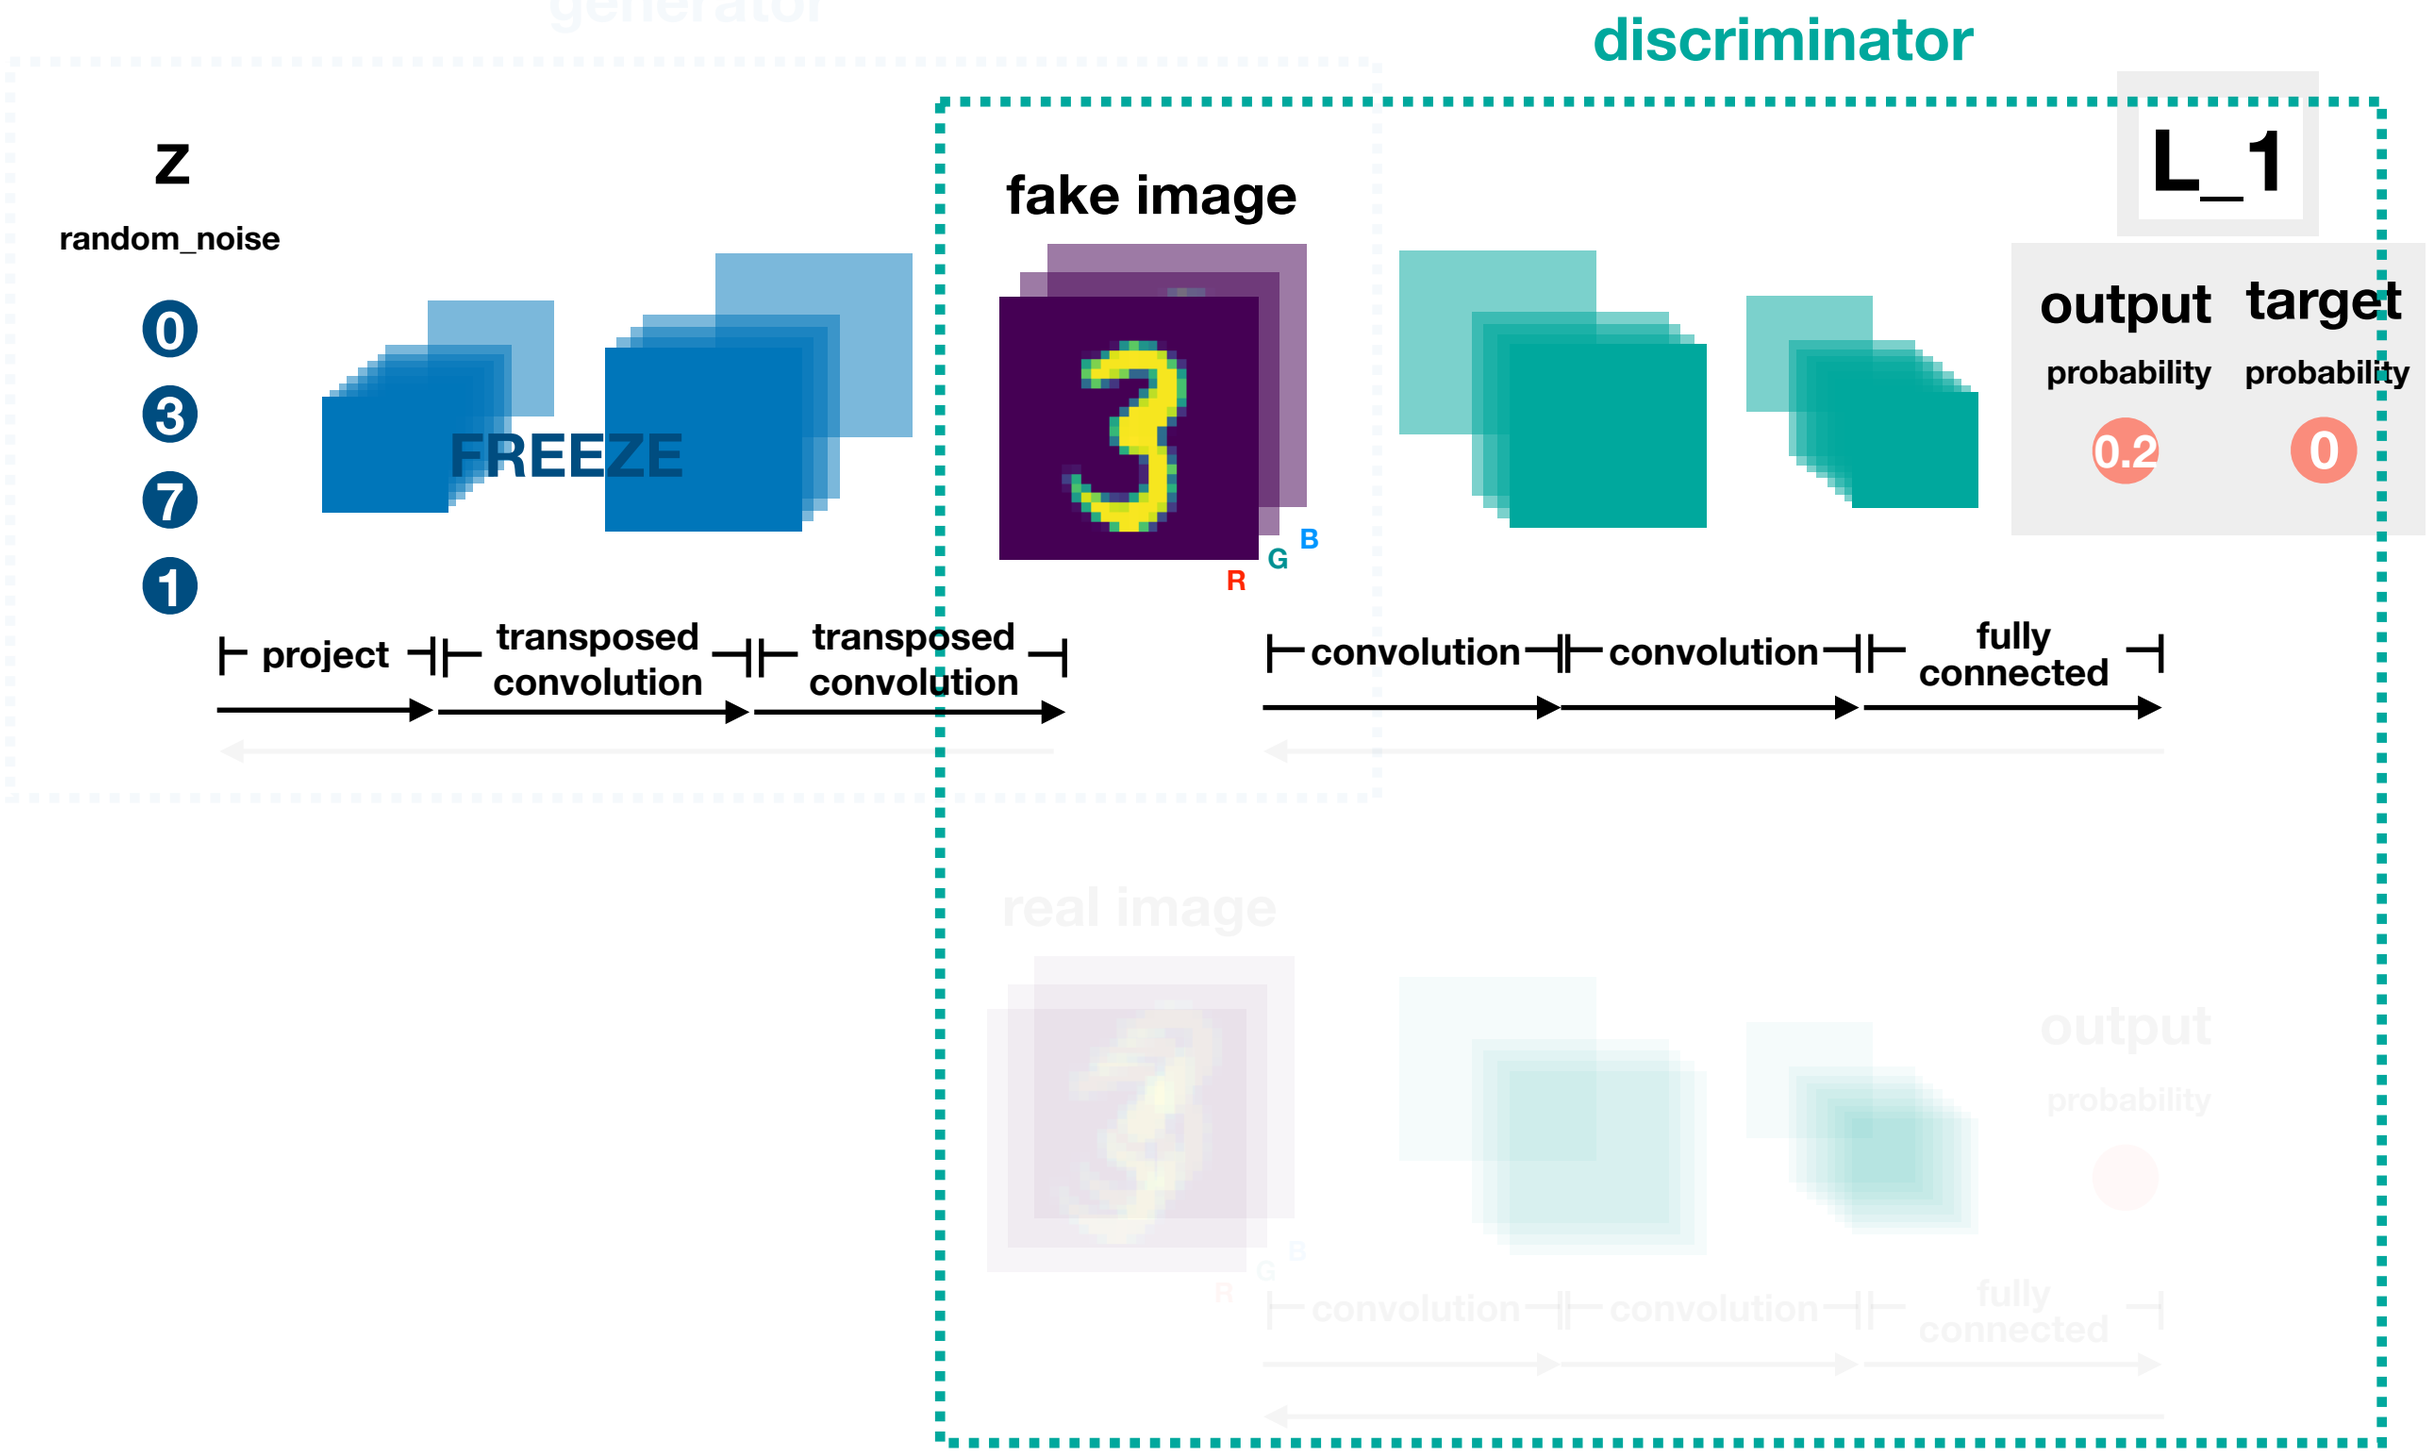

discriminator의 목적이 진짜 이미지를 구별하는 것이므로 target은 0입니다.
output과 정답 target (0)을 비교하여 첫 번째 loss를 구합니다.

DCGAN

이번에는 discriminator에 실제 이미지를 넣고 이미지가 진짜일 확률을 구합니다.

DCGAN

discriminator의 목적이 진짜 이미지를 구별하는 것이므로 target은 1입니다.
output과 정답 target (1)을 비교하여 두 번째 loss를 구합니다.

DCGAN

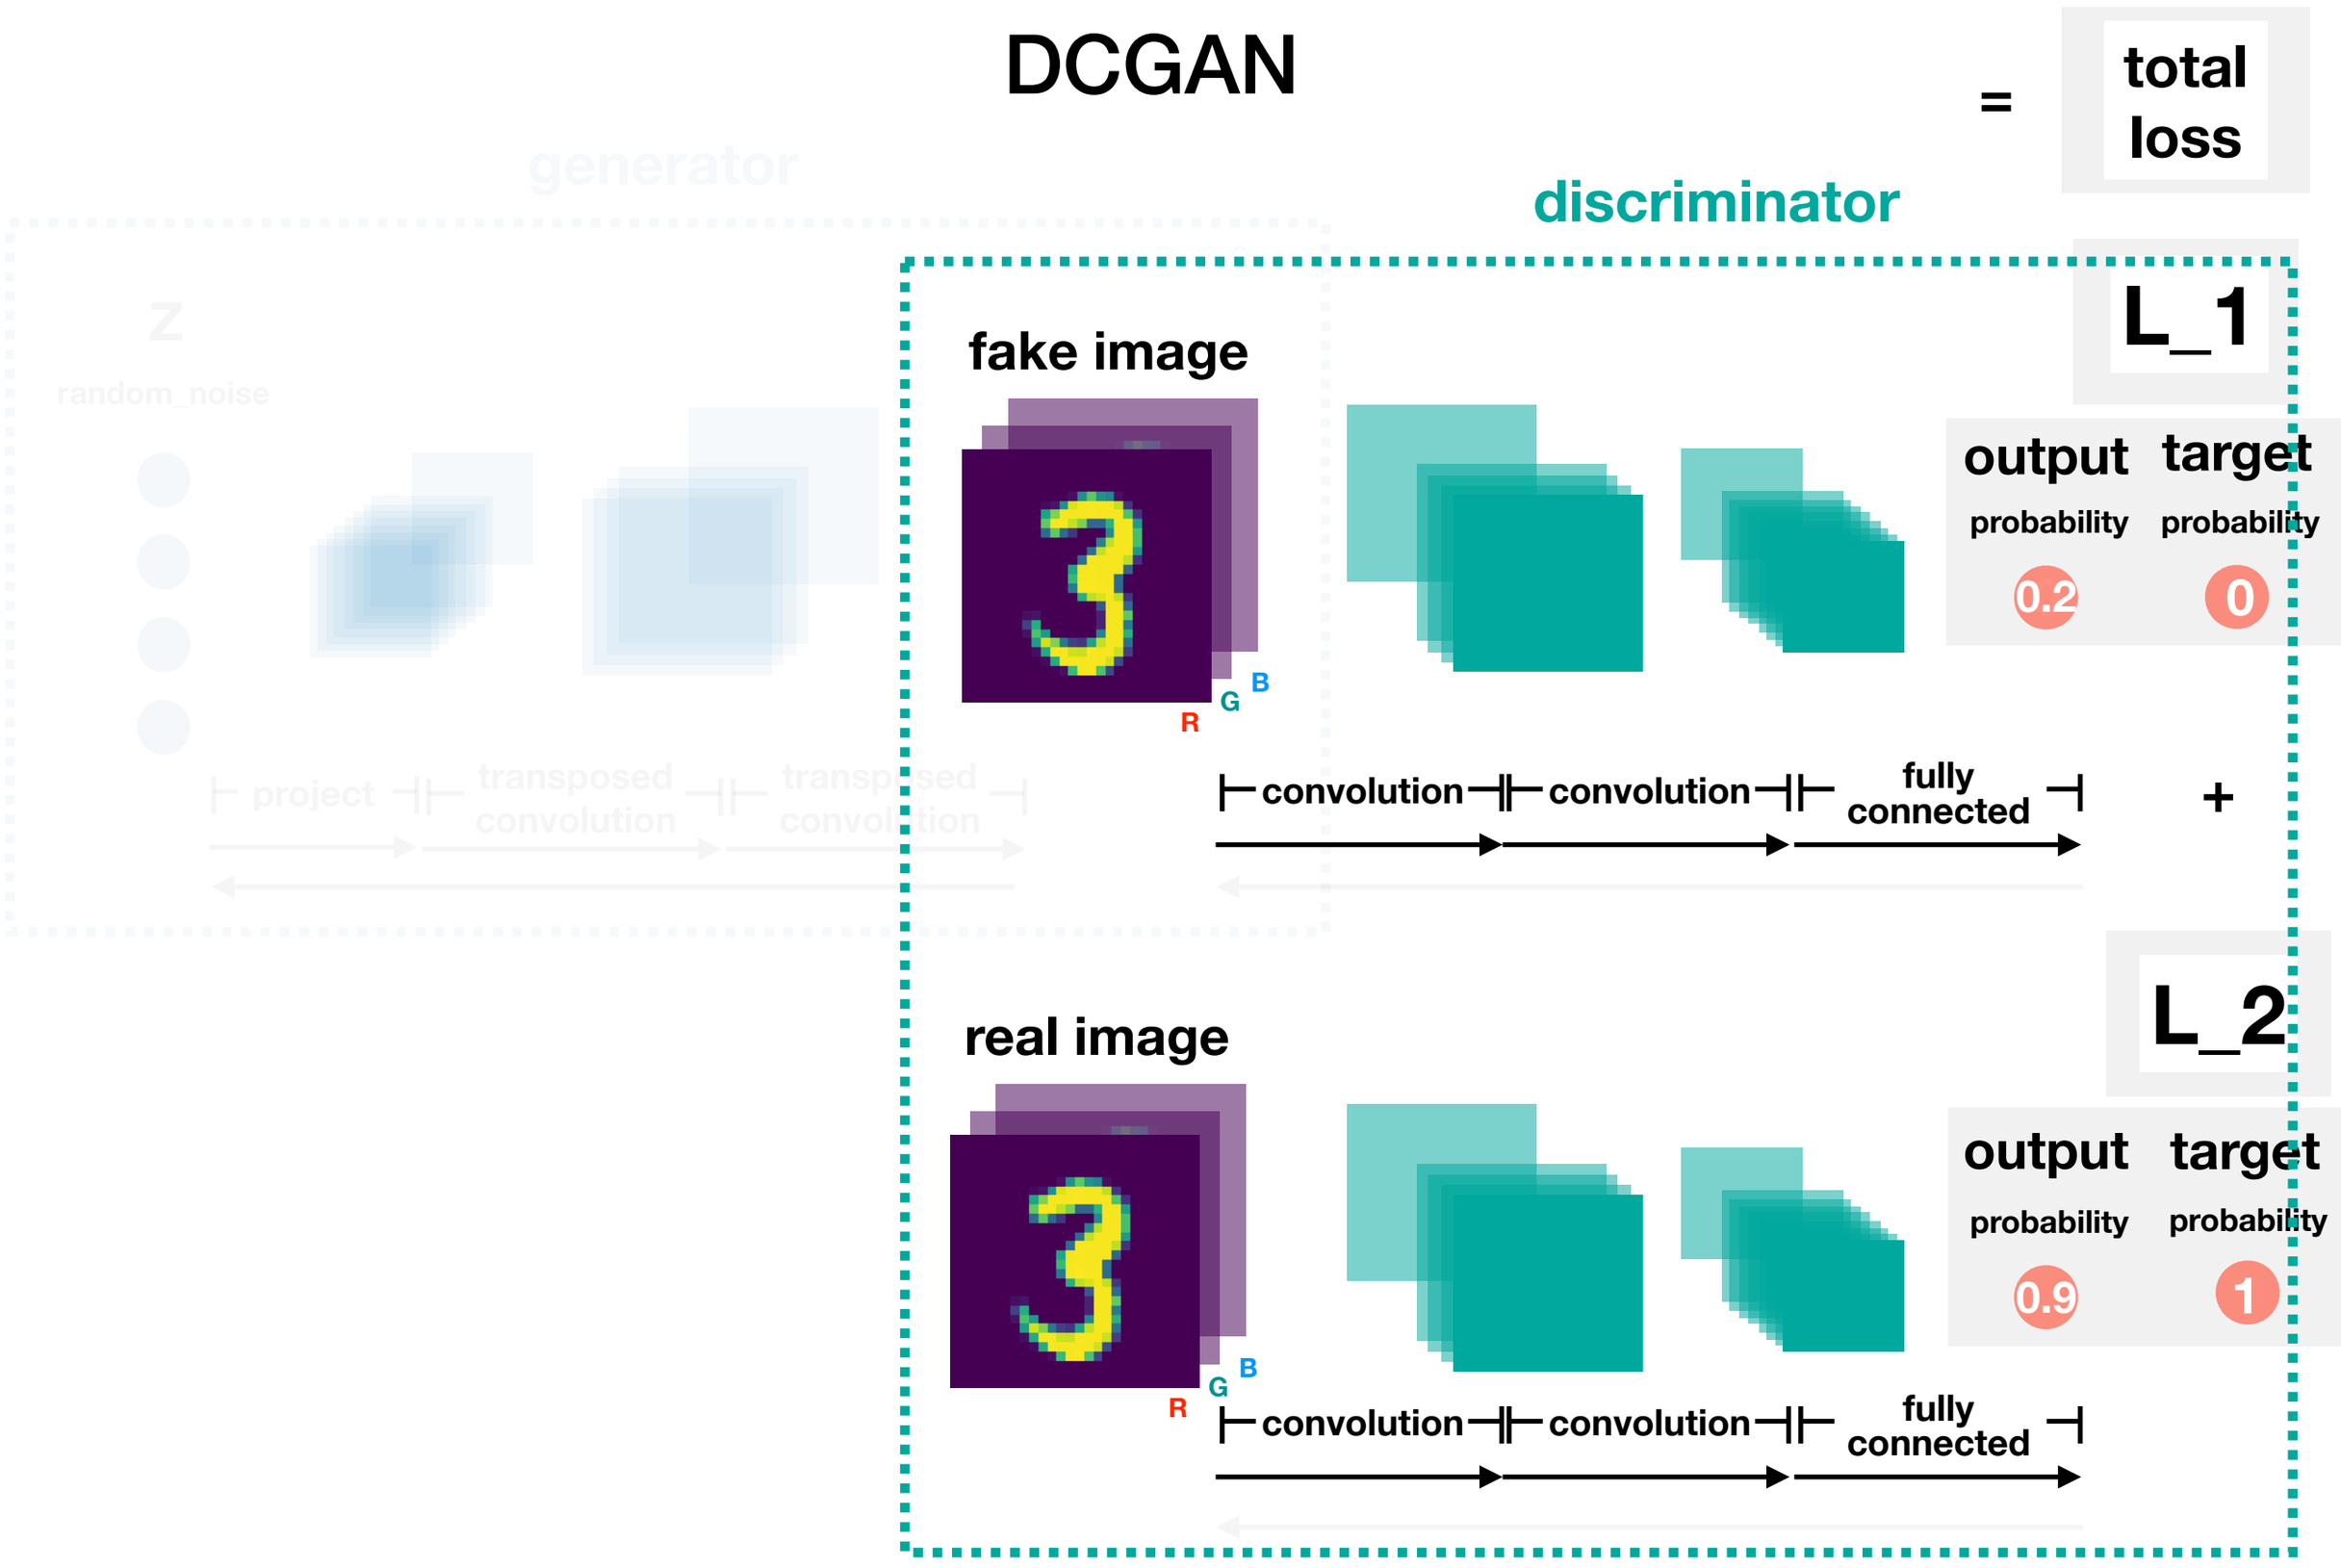

이제 첫 번째 loss와 두 번째 loss를 더한 전체 loss를 정의합니다.

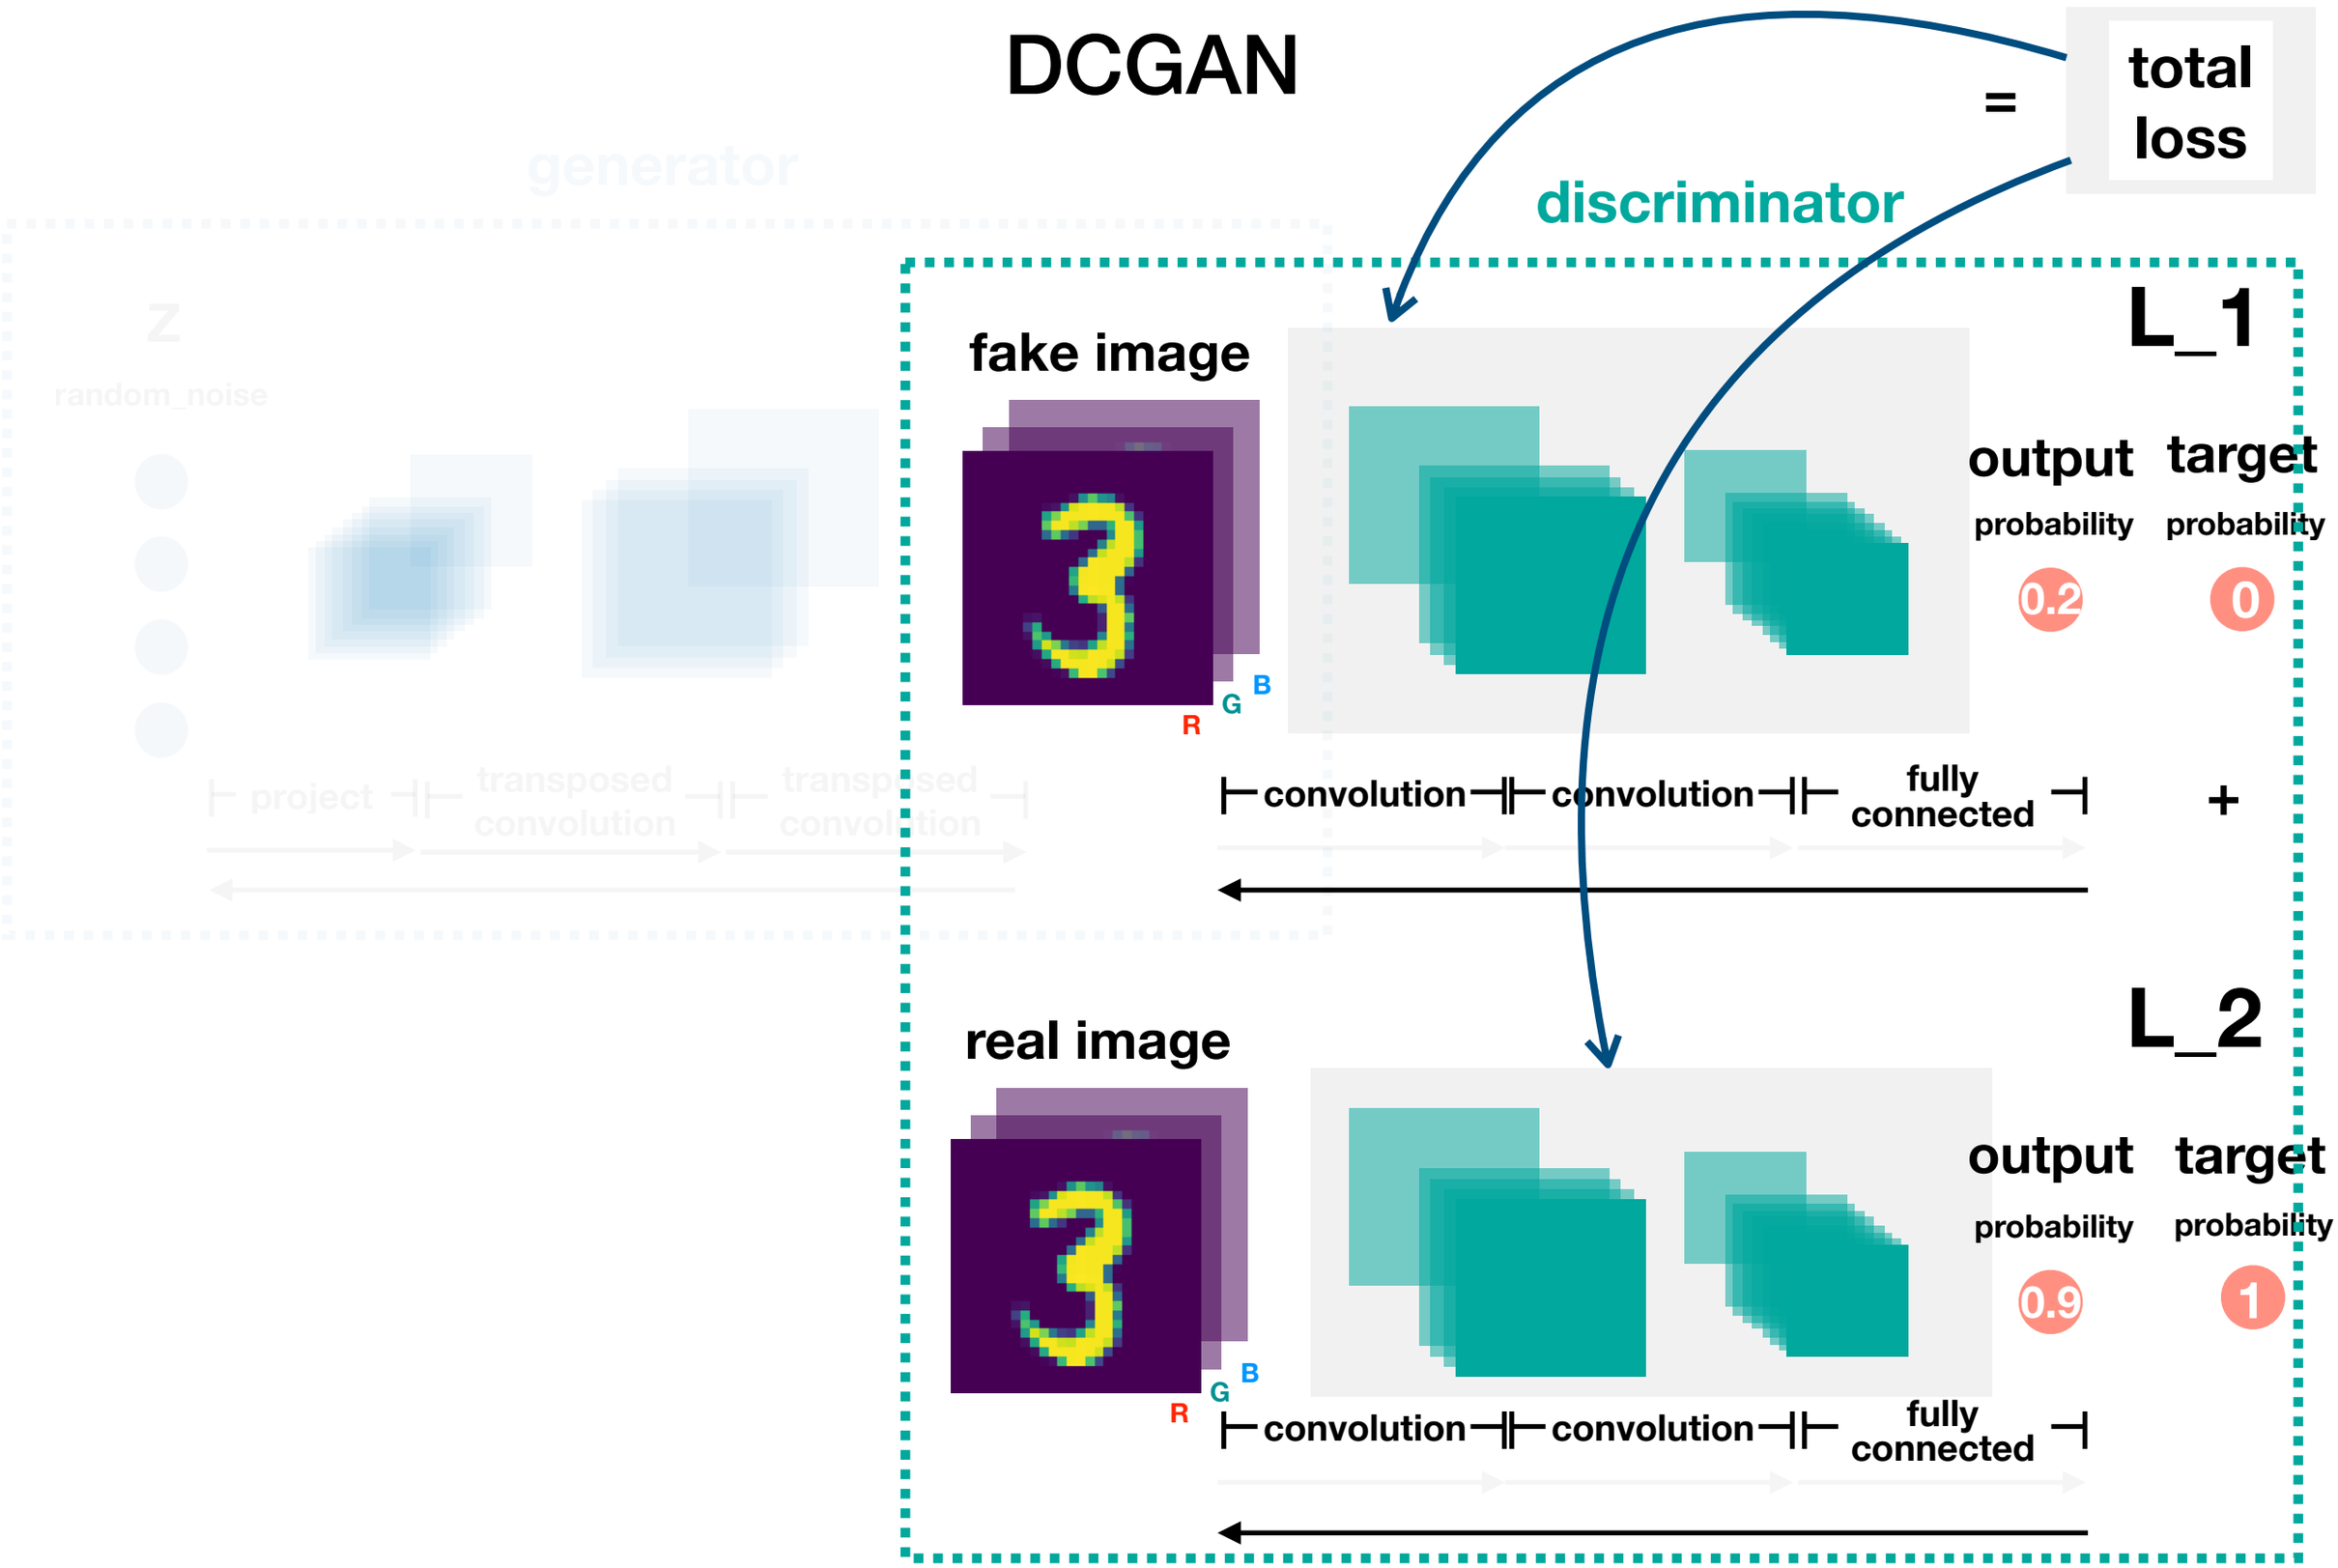

전체 loss를 최소화하는 방향으로, weight을 update 합니다.

DCGAN

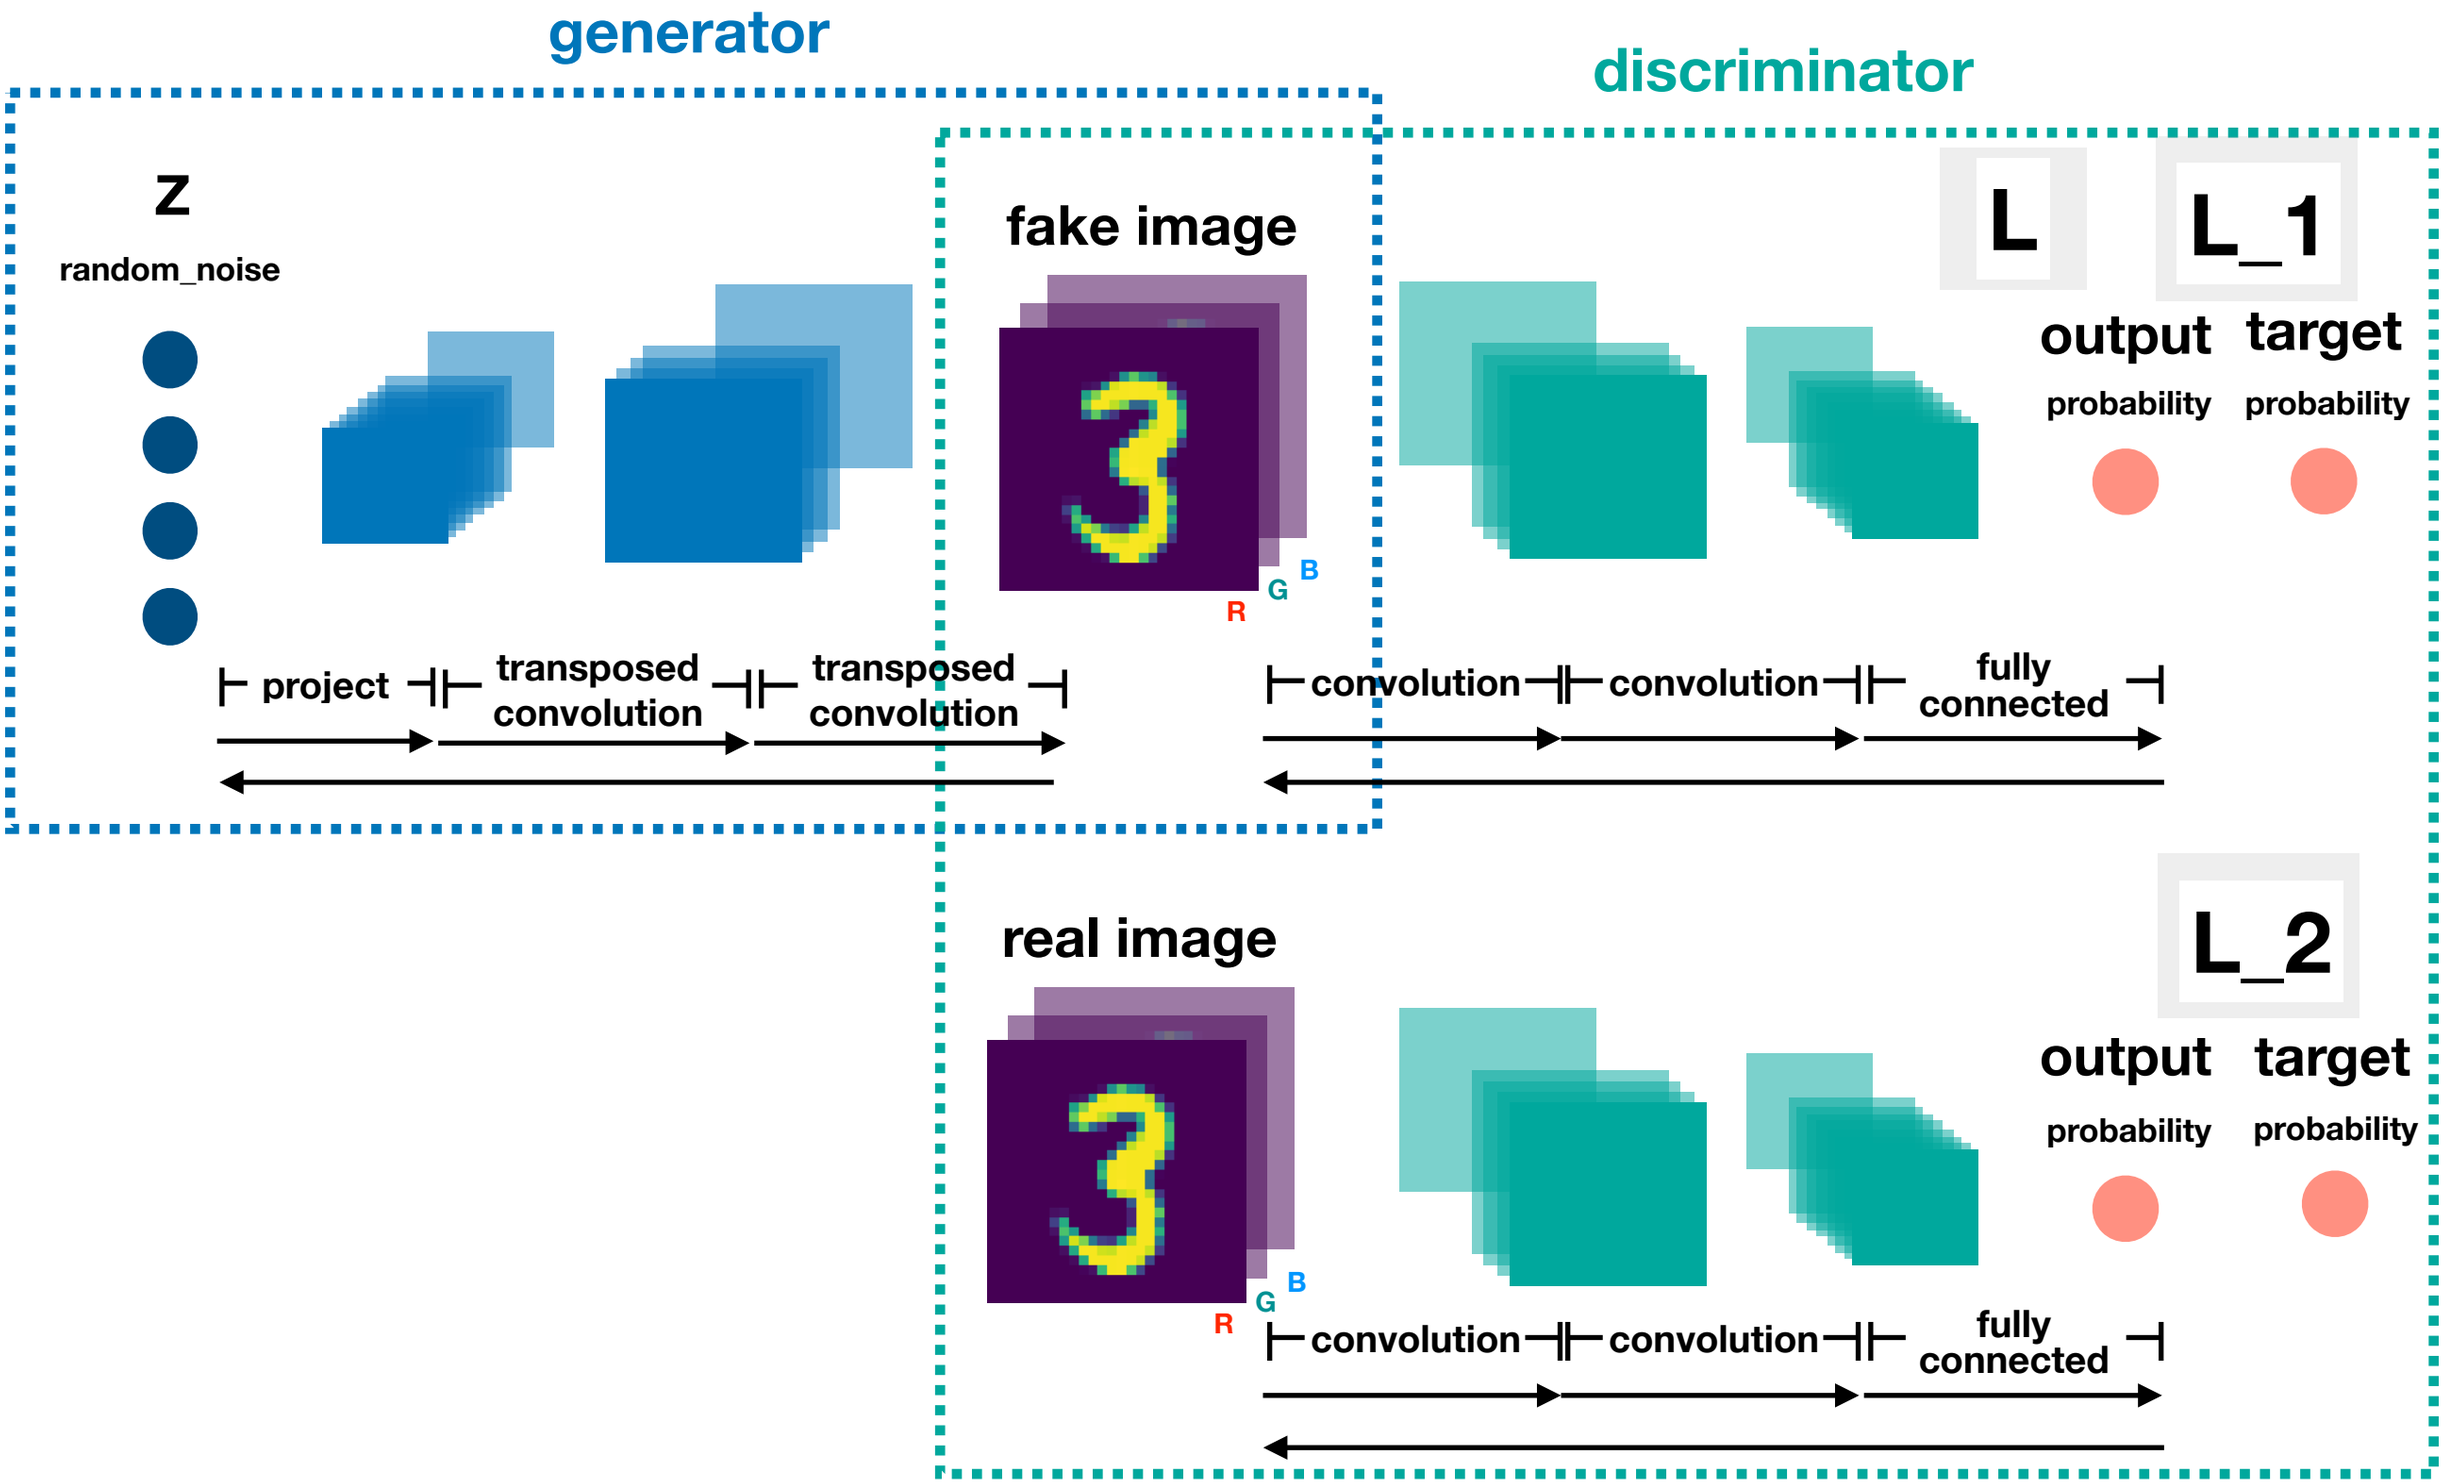

generator loss와 discriminator loss는 하나가 작아지면 다른 하나가 커지는 trade-off 관계입니다. 두 loss가 모두 적당히 작아지는 타협점은 모델에 따라 다를 수 있습니다.

DCGAN

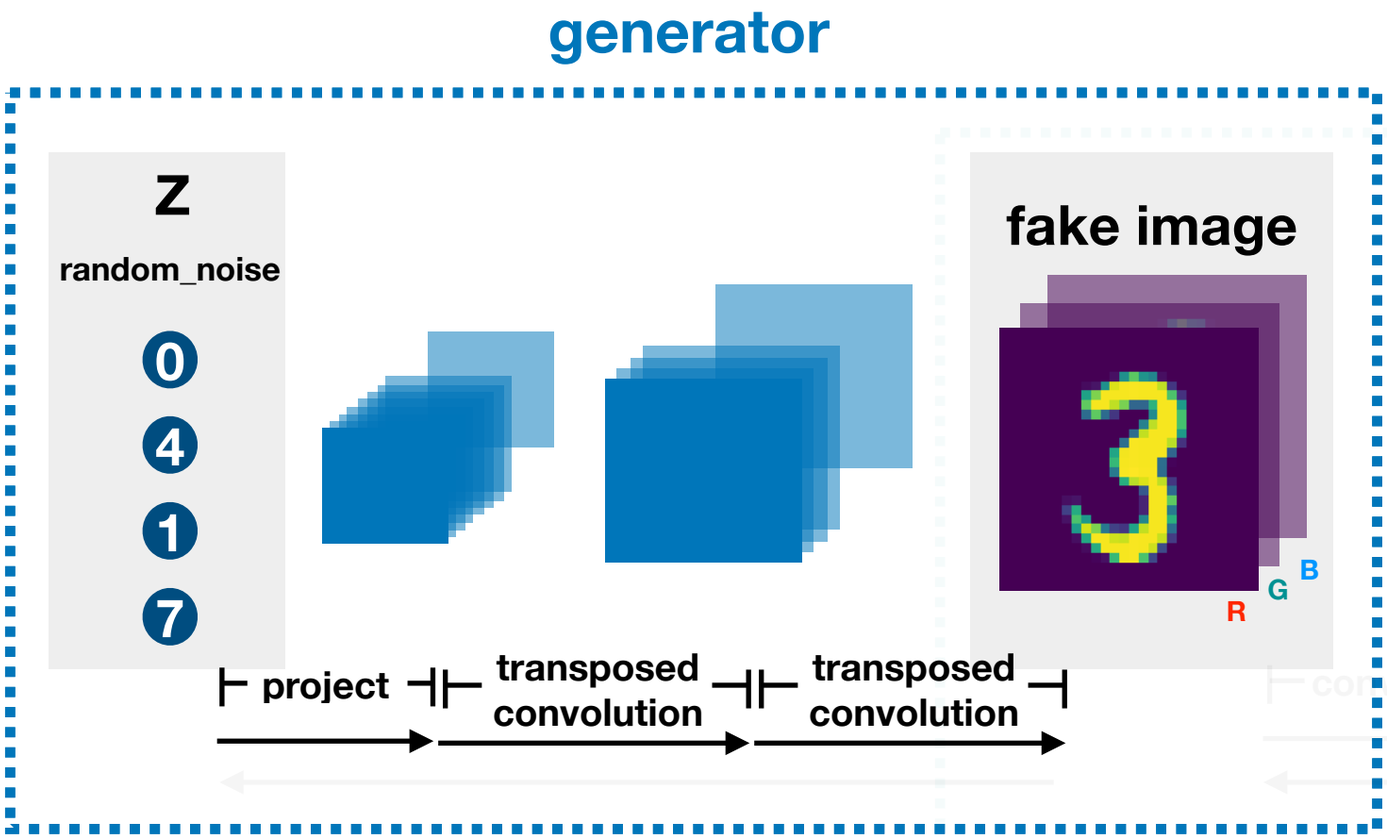

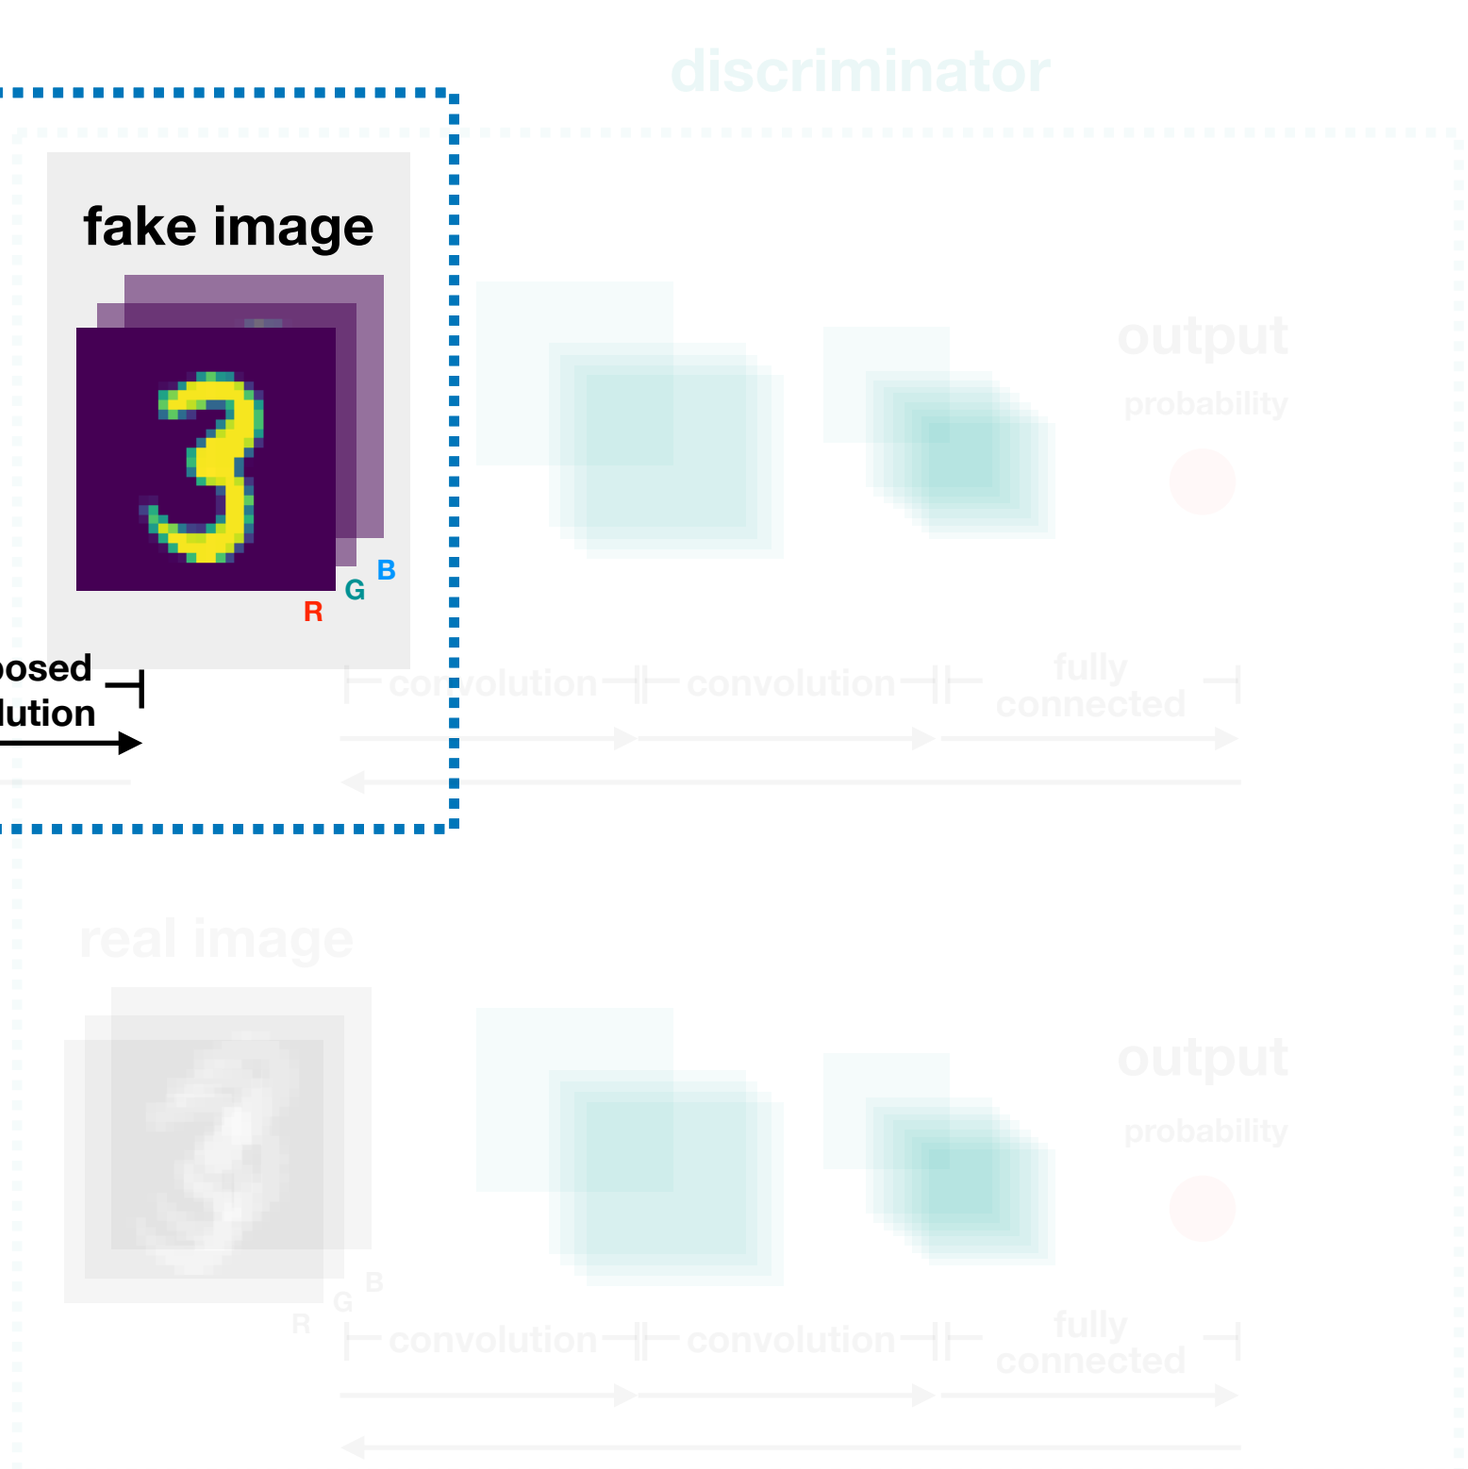

훈련이 끝난 뒤 random한 숫자 vector를 generator에 넣어주면 진짜 같은 이미지가 만들어집니다.